Análisis de Componentes Principales (APC- PCA)

Monica Giuliano

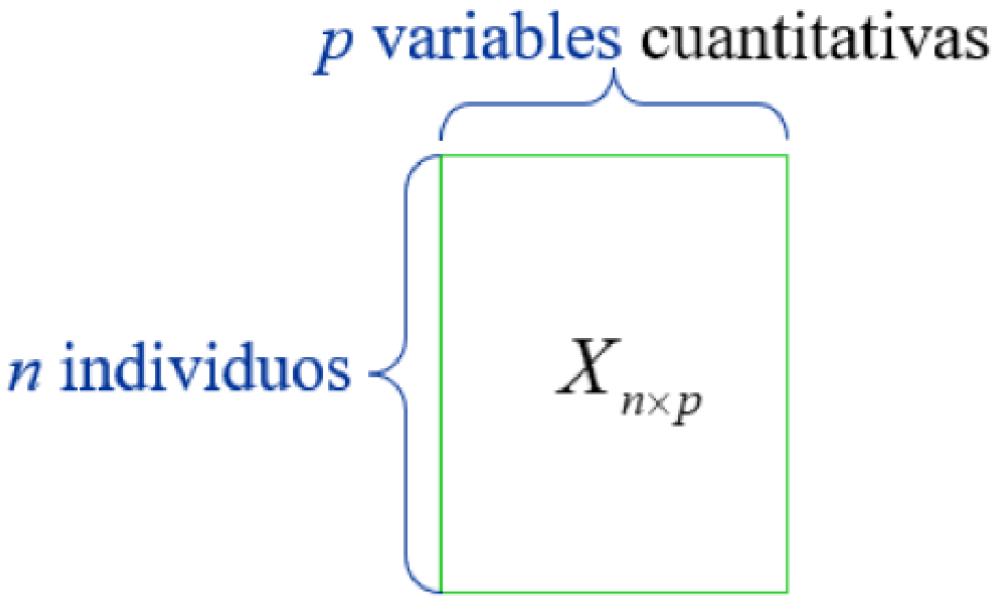
Maria Laura Vranic

Un poco de historia

- ACP: técnica de reducción de las dimensiones
- Pearson (1900): encontrar la recta de mejor ajuste en 2 dimensiones
- Hotelling (1933): encontrar variables sintéticas independientes de máxima varianza
- Pagès (1970): reducir la dimensión del espacio de representación de los individuos perdiendo el mínimo de información

p- variables; n-individuos

Se tiene una tabla de datos cuantitativos $n \times p$.



Objetivo

El Análisis de Componentes Principales (ACP) es una técnica estadística de síntesis de la información, o reducción de la dimensión (número de variables).

Es decir, ante un banco de datos con muchas variables, el objetivo será reducirlas a un menor número perdiendo la menor cantidad de información posible

MUCHAS VARIABLES

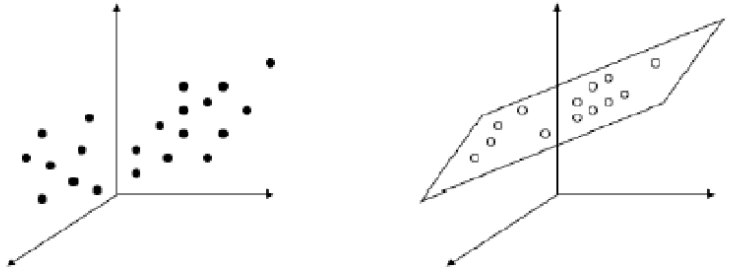


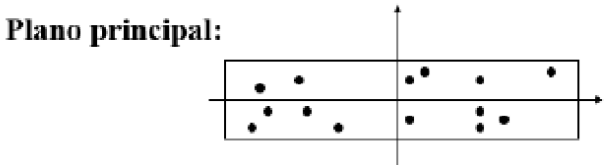
POCAS VARIABLES

Objetivo

Se quiere:

- obtener una representación en **pocas dimensiones** de los objetos, perdiendo el mínimo de información;
- obtener (pocas) **variables sintéticas**, basadas en las variables originales y no correlacionadas entre ellas;
- son objetivos equivalentes (y duales).





Análisis de Componentes Principales (ACP)

Análisis de la matriz de correlaciones

Un análisis de componentes principales tiene sentido si existen **altas correlaciones lineales entre las variables**, ya que esto es indicativo de que existe información redundante y, por tanto, pocos factores explicarán gran parte de la variabilidad total.

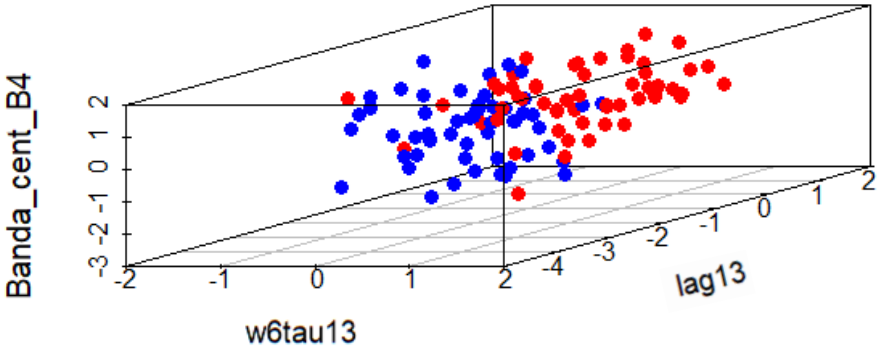
Selección de los factores

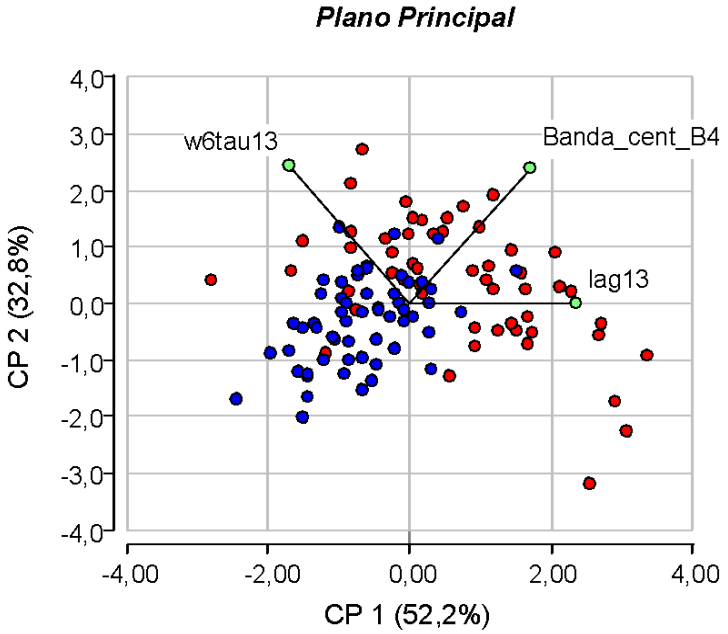
La elección de los factores se realiza de tal forma que el primero recoja la mayor proporción posible de la variabilidad original; el segundo factor debe recoger la máxima variabilidad posible no recogida por el primero, y así sucesivamente. Del total de factores se elegirán aquellos que recojan el porcentaje de variabilidad que se considere suficiente. A estos se les denominará componentes principales.

Biplot

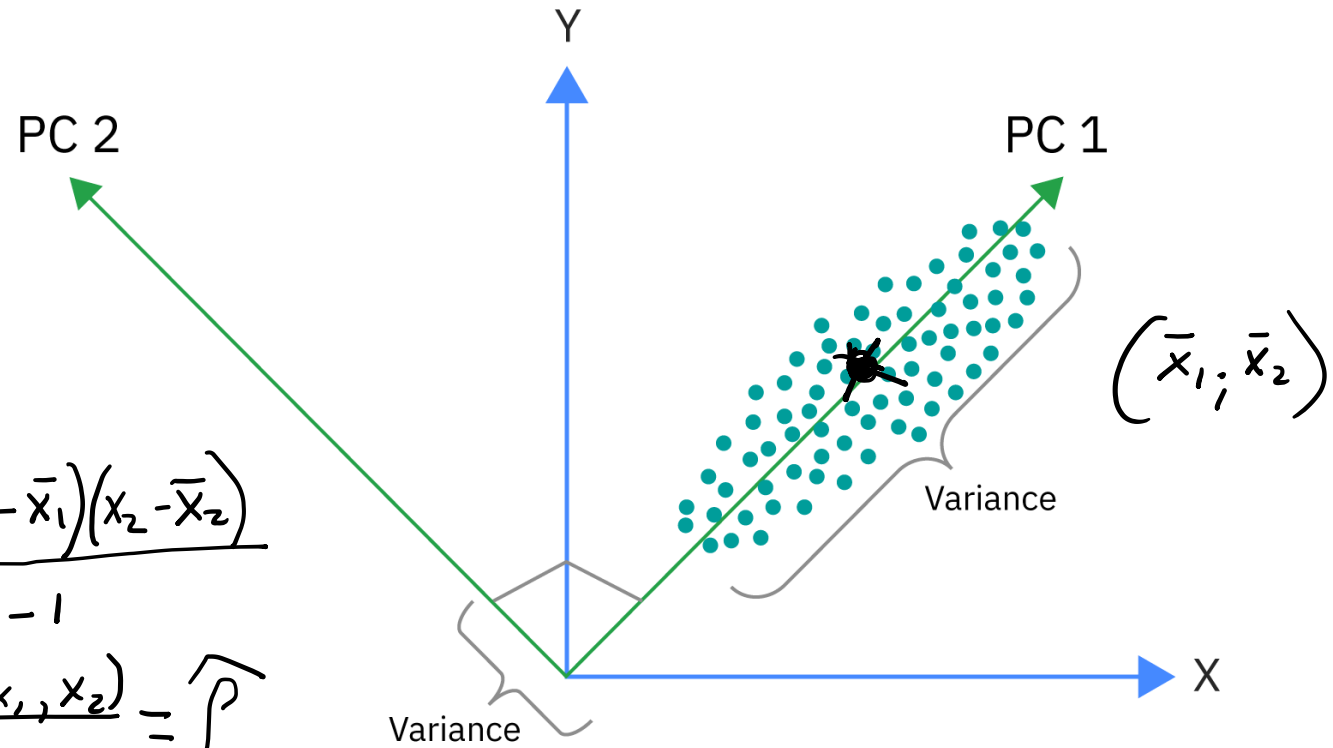
Transformación para proyectar en el mismo plano

n Individuos y p variables





Se centra en el la media



$$Cov = \frac{\sum (x_1 - \bar{x}_1)(x_2 - \bar{x}_2)}{n-1}$$

$$r = \frac{Cov(x_1, x_2)}{s_1 s_2} = \rho$$

$$(\bar{x}_1, \bar{x}_2)$$

Fórmula de la Covarianza Muestral

La covarianza muestral mide la relación lineal entre dos variables.

$$Cov(X,Y) = \frac{\sum_{i=1}^{n}(X_i - \bar{X})(Y_i - \bar{Y})}{n-1}$$

Donde:

- X_i: Cada valor de la variable X.
- Y_i: Cada valor de la variable Y.
- $\bar{X}$: La media de la variable X.
- $\bar{Y}$: La media de la variable Y.
- n: El número total de observaciones

Fórmula del Coeficiente de Correlación Muestral (Pearson)

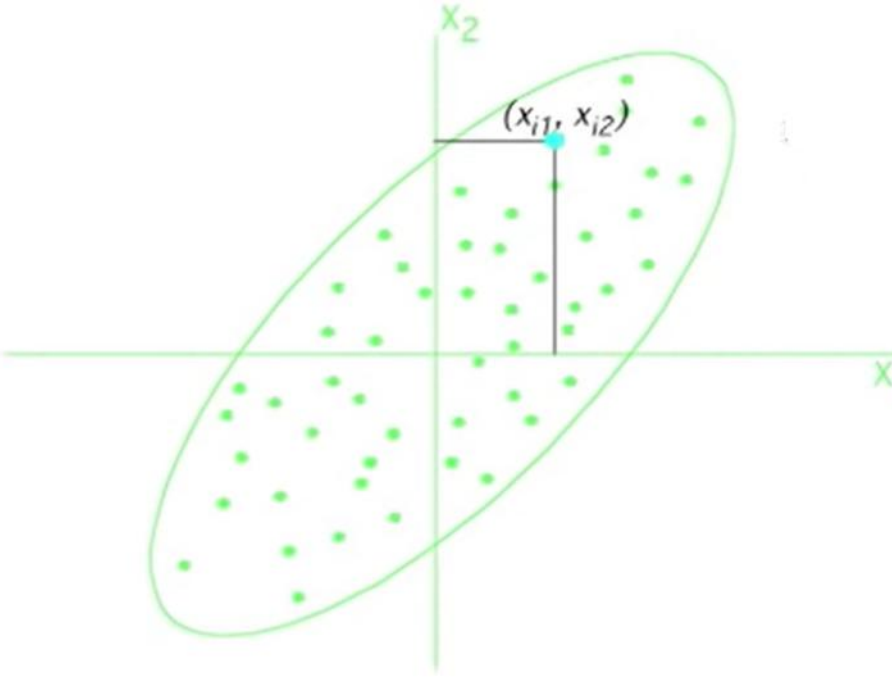
El coeficiente de correlación es una versión normalizada de la covarianza, lo que significa que está acotado entre -1 y 1.

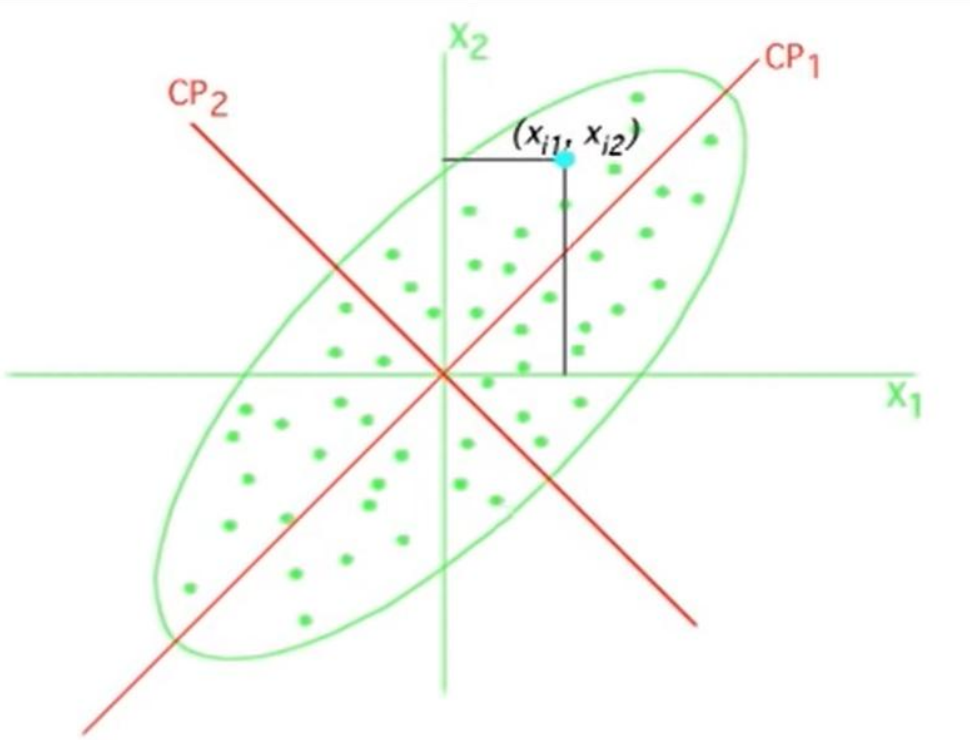
$$r = \frac{Cov(X,Y)}{S_X \cdot S_Y}$$

- S_X: La desviación estándar de la variable X.
- S_Y: La desviación estándar de la variable Y.

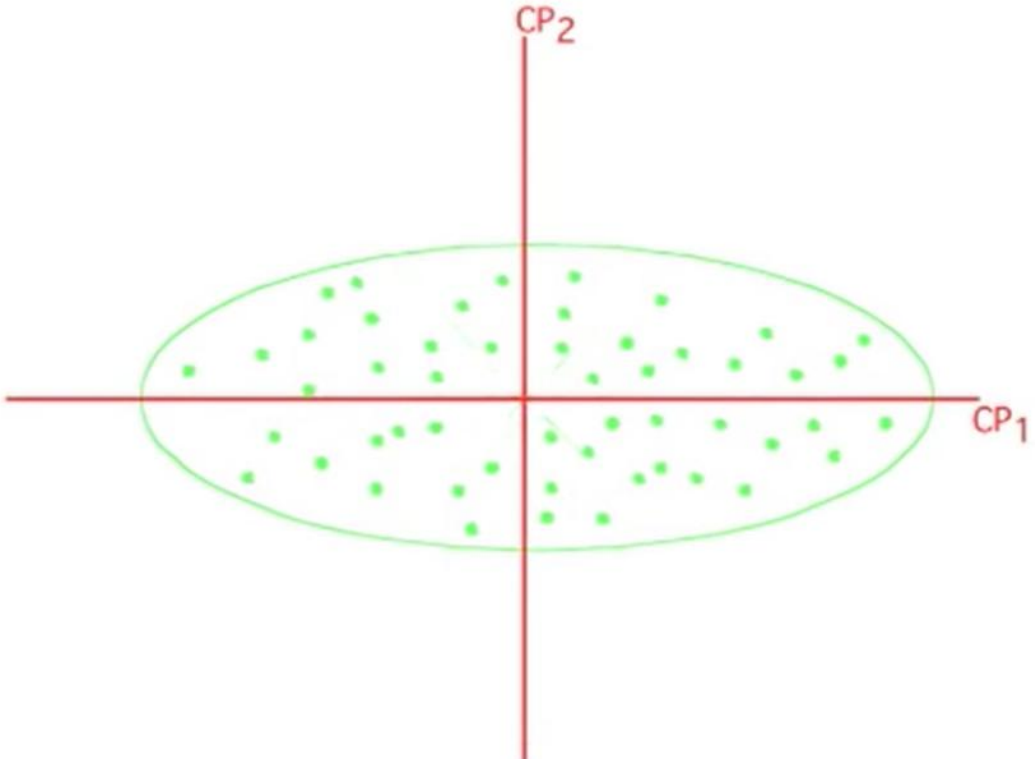
ACP

Proyecta en la dirección de máxima variabilidad con el centro en la media

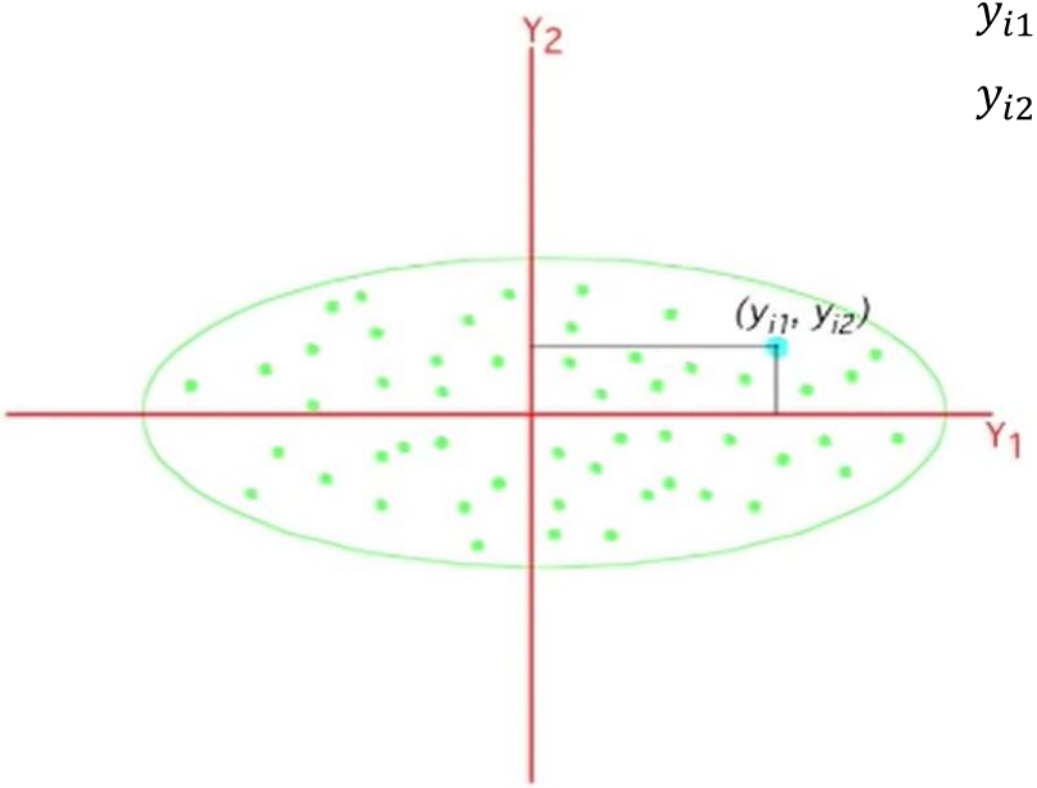




Rotación a las componentes



Rotación a las componentes



$$y_{i1} = x_{i1}v_{11} + x_{i2}v_{21}$$

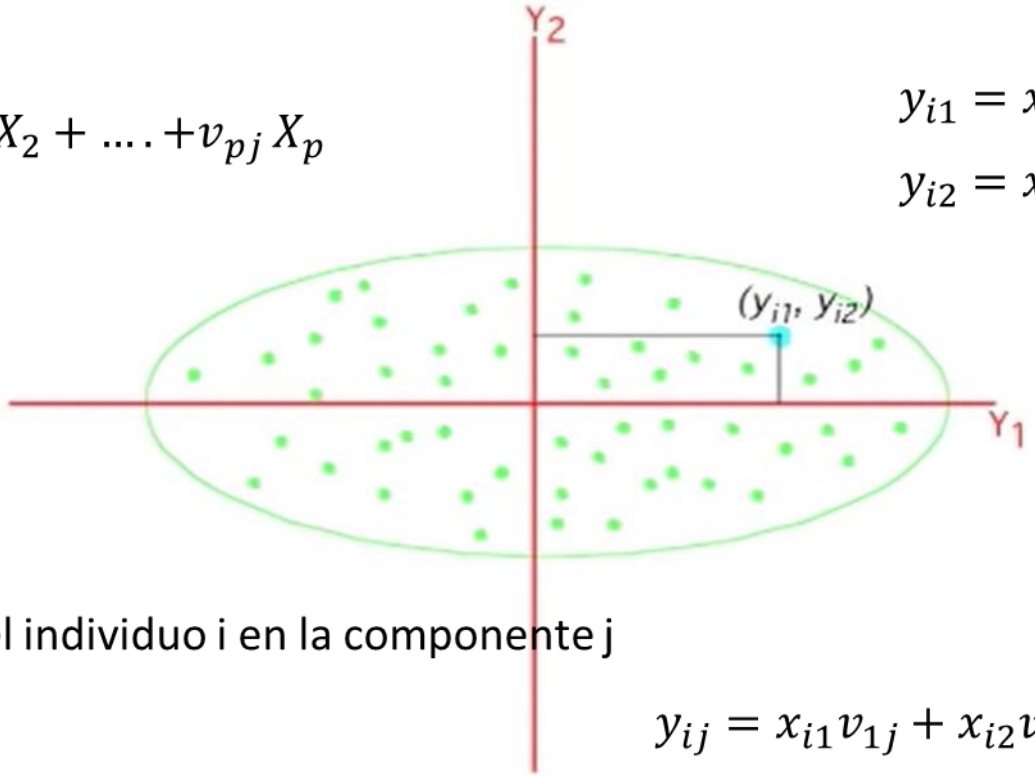
$$y_{i2} = x_{i1}v_{12} + x_{i2}v_{22}$$

Rotación a las componentes

$$Y_j = v_{1j}X_1 + v_{2j}X_2 + \ldots + v_{pj}X_p$$

$$y_{i1} = x_{i1}v_{11} + x_{i2}v_{21}$$

$$y_{i2} = x_{i1}v_{12} + x_{i2}v_{22}$$



La coordenada del individuo i en la componente j

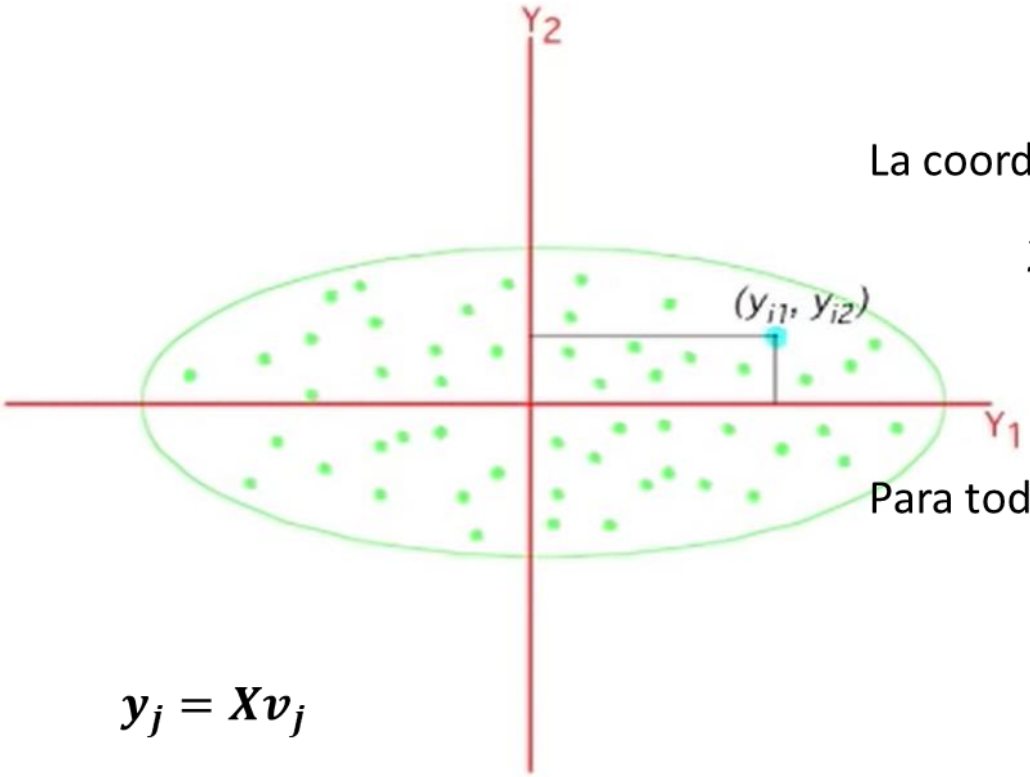
$$y_{ij} = x_{i1}v_{1j} + x_{i2}v_{2j} + \cdots + x_{ip}v_{pj}$$

Rotación a las componentes

$$Y_j = v_{1j}X_1 + v_{2j}X_2 + \ldots . + v_{pj}X_p$$

$$y_{i1} = x_{i1}v_{11} + x_{i2}v_{21}$$

$$y_{i2} = x_{i1}v_{12} + x_{i2}v_{22}$$



La coordenada del individuo i en la componente j

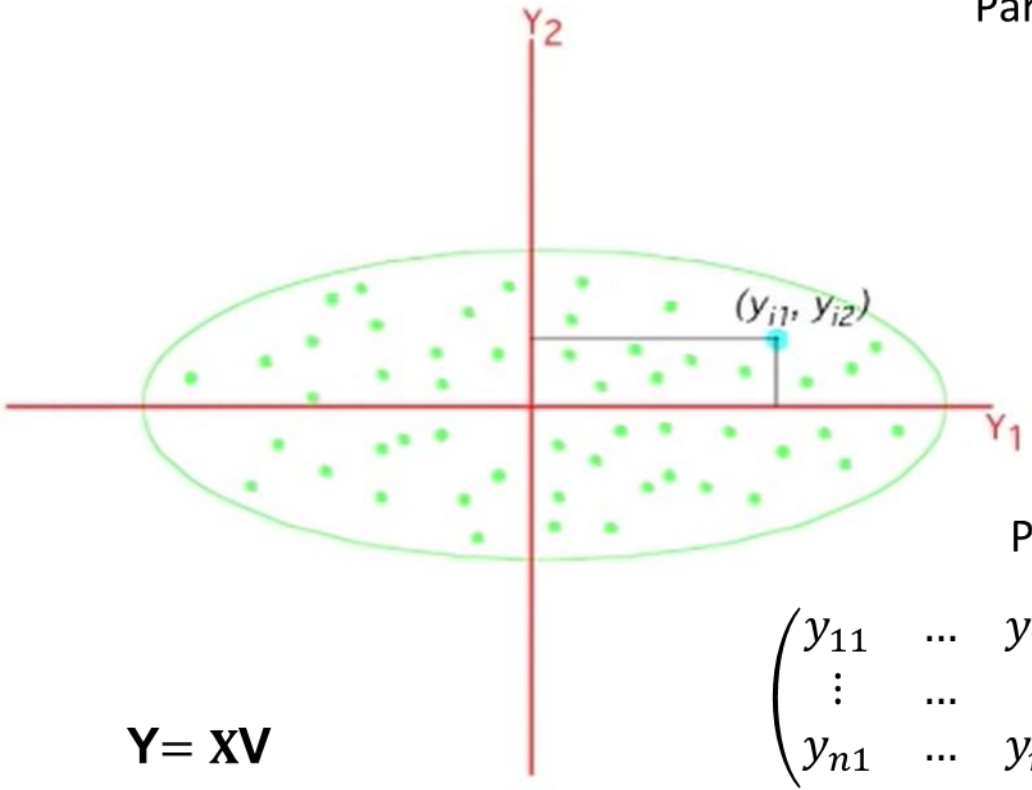
$$y_{ij} = x_{i1}v_{1j} + x_{i2}v_{2j} + \cdots + x_{ip}v_{pj}$$

Para todos los individuos

$$\begin{pmatrix} y_{1j} \\ \vdots \\ y_{nj} \end{pmatrix} = \begin{pmatrix} x_{11} & \ldots & x_{1p} \\ \vdots & \ldots & \vdots \\ x_{n1} & \ldots & x_{np} \end{pmatrix} \begin{pmatrix} v_{1j} \\ \vdots \\ v_{pj} \end{pmatrix}$$

$$\boldsymbol{y_j = Xv_j}$$

Rotación a las componentes



Para todos los individuos

$$\begin{pmatrix} y_{1j} \\ \vdots \\ y_{nj} \end{pmatrix} = \begin{pmatrix} x_{11} & \cdots & x_{1p} \\ \vdots & \cdots & \vdots \\ x_{n1} & \cdots & x_{np} \end{pmatrix} \begin{pmatrix} v_{1j} \\ \vdots \\ v_{pj} \end{pmatrix}$$

Para todo el conjunto de componentes

$$\begin{pmatrix} y_{11} & \cdots & y_{1p} \\ \vdots & \cdots & \vdots \\ y_{n1} & \cdots & y_{np} \end{pmatrix} = \begin{pmatrix} x_{11} & \cdots & x_{1p} \\ \vdots & \cdots & \vdots \\ x_{n1} & \cdots & x_{np} \end{pmatrix} \begin{pmatrix} v_{11} & \cdots & v_{1p} \\ \vdots & \cdots & \vdots \\ v_{p1} & \cdots & v_{pp} \end{pmatrix}$$

Y= XV

Varianza máxima

$$var\ Y_1 = \frac{1}{n} y_1^T y_1 = \frac{1}{n} v_1^T X^T X v_1 = \frac{1}{n} v_1^T R v_1$$

Maximizar la varianza equivale maximizar $F(v_1) = v_1^T R v_1$

$\max F = \max(v_1^T R v_1)$ Máxima variancia

$$v^T v = 1$$

para $ortogonalidad\ de\ los\ vectore$.

$$V^T V = I$$

Introduciendo el multiplicador de Lagrange

$$L(v_1) = v_1^T R v_1 - \lambda(v_1^T v_1 - 1)$$

$$\frac{dL(v_1)}{dv_1} = 2Rv_1 - 2\lambda v_1^T = 0$$

$$Rv_1 = \lambda v_1$$

$$Rv_1 - \lambda v_1 = 0$$

$$(R - \lambda I)v_1 = 0$$

Por el teorema de Roché-Frobenius, para que el sistema tenga una solución distinta de 0 la matriz (R − λI) tiene que ser singular. Esto implica que el determinante debe ser igual a cero:

Segunda componente principal

La segunda componente principal se obtiene de forma similar, pero añadiendo dos restricciones adicionales, primero que las componentes principales Y1 y Y2 no estén correlacionadas, y segundo que el vector de coeficientes sea perpendicular al primero. Eso significa que la covarianza debe ser cero.

$$cov\,(Y_1, Y_2) = \frac{1}{n} y_2^T y_1 = \frac{1}{n} v_2^T X^T X v_1 = \frac{1}{n} v_2^T R v_1 = 0$$

$v_2^T v_1 = 0$ v_2 Ortogonal al v_1

$v_2^T v_2 = 1$ Máxima variancia (2da)

$$L(v_2) = v_2^T R v_2 - \lambda_2(v_2^T v_2 - 1) - \delta(v_2^T v_1)$$

Ojo se han usado dos restricciones

$$\frac{dL(v_2)}{dv_2} = 2Rv_2 - 2\lambda_2 v_2 - \delta v_1 = 0$$

Multiplicamos todo por v_1^T

$$2v_1^T R v_2 - 2\lambda_2 v_1^T v_2 - \delta v_1^T v_1 = 0$$

$$2v_1^T R v_2 - \delta = 0$$

Como $v_2^T S v_1 = 0$, δ también debe ser 0, de forma que

$$\frac{dL(v_2)}{dv_2} = 2Rv_2 - 2\lambda_2 v_2 - \delta v_1 = 0$$

Se convierte en

$$Rv_2 = \lambda_2 v_2$$

Bondad del Ajuste

$$\sum_{j=1}^{p} Var(Y_j) = \sum_{j=1}^{p} \lambda_j = traza(\Lambda)$$

$$traza(\Lambda) = traza(\mathbf{V'SV}) = traza(\mathbf{SV'V}) =$$

$$traza(\mathbf{S}) = \sum_{j=1}^{p} Var(X_j)$$

$$\begin{cases} Var(y_1) = \lambda_1 \\ Var(y_2) = \lambda_2 \\ \vdots \\ Var(y_p) = \lambda_p \end{cases}$$

$$\Delta = \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \cdots & \cdots & \cdots & \cdots \\ 0 & 0 & \cdots & \lambda_p \end{pmatrix}$$

PROP. DE VARIANZA ABSORBIDA POR CADA COMPONENTE

$$\frac{\lambda_j}{\sum_{i=1}^{p} \lambda_i}$$

BONDAD DEL AJUSTE (q COMPONENTES)

$$\frac{\sum_{j=1}^{q} \lambda_j}{\sum_{i=1}^{p} \lambda_i}$$

Los nuevos componentes principales o factores serán una combinación lineal de las variables originales, y además serán independientes entre sí.

La coordenada del individuo i en la componente j

$$y_{ij} = x_{i1}v_{1j} + x_{i2}v_{2j} + \cdots + x_{ip}v_{pj}$$

Para todos los individuos

$$\begin{pmatrix} y_{1j} \\ \vdots \\ y_{nj} \end{pmatrix} = \begin{pmatrix} x_{11} & \cdots & x_{1p} \\ \vdots & \cdots & \vdots \\ x_{n1} & \cdots & x_{np} \end{pmatrix} \begin{pmatrix} v_{1j} \\ \vdots \\ v_{pj} \end{pmatrix}$$

Máxima Varianza

$$\mathbf{y}_j = \mathbf{X}\mathbf{v}_j$$

Para todo el conjunto de datos

$$\begin{pmatrix} y_{11} & \cdots & y_{1p} \\ \vdots & \ddots & \vdots \\ y_{n1} & \cdots & y_{np} \end{pmatrix} = \begin{pmatrix} x_{11} & \cdots & x_{1p} \\ \vdots & \ddots & \vdots \\ x_{n1} & \cdots & x_{np} \end{pmatrix} \begin{pmatrix} v_{11} & \cdots & v_{1p} \\ \vdots & \ddots & \vdots \\ v_{p1} & \cdots & v_{pp} \end{pmatrix}$$

En notación matricial

$$\mathbf{Y} = \mathbf{X}\mathbf{V}$$

Donde Y contiene las puntuaciones de cada individuo sobre cada componente, y V contiene los coeficientes (pesos) de las combinaciones lineales en columnas.

Máxima Varianza

Buscamos una primera componente principal Y_1 que tenga varianza máxima. Como las variables originales tienen media 0, también Y_1 tendrá media nula. La varianza de Y_1 se calcula como

$$Var(Y_1) = \frac{1}{n}\mathbf{y}_1'\mathbf{y}_1 = \frac{1}{n}\mathbf{v}_1'\mathbf{X}'\mathbf{X}\mathbf{v}_1 = \mathbf{v}_1'\mathbf{S}\mathbf{v}_1$$

Para que la maximización de la varianza de Y_1 tenga solución debemos imponer una restricción:

$$\mathbf{v}_1'\mathbf{v}_1 = 1 \qquad \mathbf{V}'\mathbf{V} = \mathbf{I}$$

Y de ahí se tiene que v1 es un autovector de la matriz S de covarianzas.

Se puede hacer también con la matriz de correlaciones (corresponde a las variables estandarizadas).

$$\mathbf{S}\mathbf{v}_1 = \lambda_1\mathbf{v}_1$$

Máxima Variancia

En definitiva, las componentes principales se obtienen de la descomposición en valores propios (autovalores) y vectores propios (autovectores) de la matriz de covarianzas

$$\mathbf{S} = \mathbf{V}'\Lambda\mathbf{V} \quad \begin{cases} \Lambda = diag(\lambda_1, \ldots, \lambda_p) \\ \mathbf{V}'\mathbf{V} = \mathbf{I} \end{cases}$$

Seleccionando q componentes, las puntuaciones de los individuos en las componentes están dadas por

$$\mathbf{Y}_q = \mathbf{X}\mathbf{V}_q$$

donde $\mathbf{V}_q$ está formada por las q primeras columnas de $\mathbf{V}$, y suponiendo $\mathbf{X}$ centrada.

Las componentes principales y los cambios de escala

Un problema importante del análisis de componentes principales es que sus resultados dependen de la escala de medida de las variables originales, X. Así, si se cambia de escala una variable (dejando las demás) las componentes principales se modifican, cambiando incluso la posible interpretación de las mismas.

En concreto, si se aumenta la escala de una variable, ésta verá incrementada su varianza y su aportación proporcional a la varianza total, atrayendo de este modo a la primera componente principal, que se asemejará a esta variable.

Este problema se puede solventar de dos maneras:

- Midiendo todas las variables en la misma escala (siempre que sean de la misma naturaleza).
- Aplicando el análisis de componentes principales a las variables estandarizadas. Esto último equivale a trabajar con la matriz de correlaciones, en lugar de la matriz de covarianzas.

- La solución del Análisis en Componentes Principales se obtiene al diagonalizar la matriz de correlaciones **R**, es decir, el cálculo de sus valores y vectores propios.

- Llamaremos **ACP normado o estandarizado** el caso en que se usan los datos centrados y estandarizados, lo que corresponde a usar la métrica de los inversos de las varianzas, en cuyo caso la solución se obtiene al diagonalizar **R**,

Resultados

Matriz de correlación/Coeficientes

	w6taul3	lagl3	Banda cent B4
w6taul3	1,00		
lagl3	-0,39	1,00	
Banda cent B4	-0,01	0,40	1,00

Matriz de correlación/Probabilidades

	w6taul3	lagl3	Banda cent B4
w6taul3			
lagl3	<0,0001		
Banda cent B4	0,8780	<0,0001	

Autovalores

Lambda	Valor	Proporción	Prop Acum
λ1	1,57	0,52	0,52
λ2	0,99	0,33	0,85
λ3	0,45	0,15	1,00

Autovectores

Variables	e1	e2
w6taul3	-0,50	0,71
lagl3	0,70	5,3E-04
Banda cent B4	0,51	0,70

Correlaciones con las variables originales

Variables	CP 1	CP 2
w6taul3	-0,62	0,71
lagl3	0,88	5,3E-04
Banda cent B4	0,64	0,69

$0,62^2 + 0,88^2 + 0,64^2 = \lambda_1$

$1,57 = \lambda_1$

$$CP_j = v_{1j}X_1 + v_{2j}X_2 + \ldots + v_{pj}X_p$$

$$CP_1 = -0,62 * X_1 + 0,88 * X_2 + 0,64 * X_3$$

$$CP_2 = +0,71 * X_1 + 0 * X_2 + 0,69 * X_3$$

Resultados

	CP1	CP2	Comunalidad (Coseno2)
w6tau13	-0,62	0,71	**0,8885**
lag13	0,88	0	**0,7744**
Banda_B4	0,64	0,69	**0,8857**
lambda	1,57	0,99	

Autovalores

Lambda	Valor	Proporción	Prop Acum
1	1,57	0,52	0,52
2	0,99	0,33	0,85
3	0,45	0,15	1,00

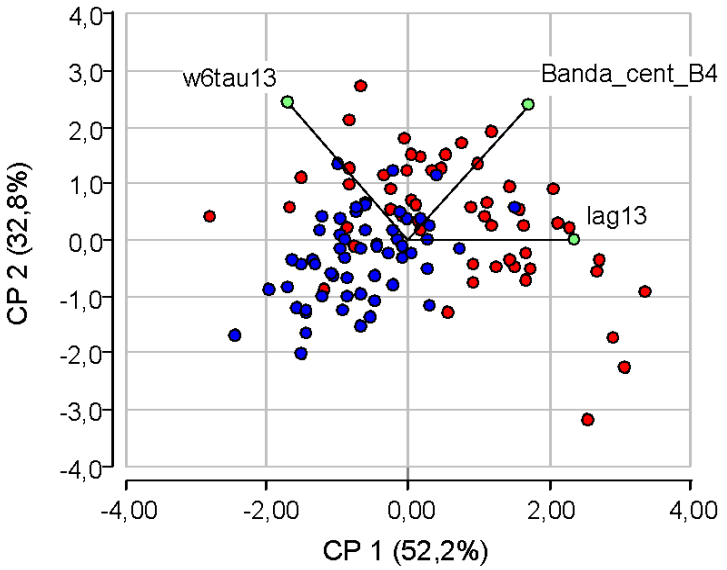
Autovectores

Variables	e1	e2
w6tau13	-0,50	0,71
lag13	0,70	5,3E-04
Banda cent B4	0,51	0,70

Correlaciones con las variables originales

Variables	CP 1	CP 2
w6tau13	-0,62	0,71
lag13	0,88	5,3E-04
Banda cent B4	0,64	0,69

Plano Principal



¿Cómo se calculan los vectores y valores propios de una matriz?

Valores y vectores propios de una matriz

Definición

Sea A una matriz de tamaño $n \times n$. El número λ se denomina valor propio de A si existe un vector v diferente de cero, tal que

$$Av = \lambda v$$

El vector v se denomina vector propio asociado al valor propio λ.

$$Av - \lambda v = 0$$
$$(A - \lambda I)v = 0.$$

Por lo tanto, se requiere que $\det(A - \lambda I) = 0$.

Definición

Sea A una matriz de tamaño $n \times n$. Se define el polinomio

$$p(\lambda) = \det(A - \lambda I).$$

El polinomio $p(\lambda)$ se denomina polinomio característico (si hay lugar a confusión, se denota como $p_A(\lambda)$).

Problema

Hallar los valores propios de la matriz A.

Procedimiento:

1. Calcular el polinomio característico de A.
2. Hallar los valores que hacen 0 al polinomio característico de A.

1. Calcular los valores propios λ.
2. Resolver el sistema de ecuaciones $(A - \lambda I)v = 0$ para cada valor propio λ.

Valores propios

Hallar los valores y vectores propios de $A = \begin{bmatrix} 3 & -2 & 3 \\ 4 & -3 & 3 \\ -2 & 2 & -2 \end{bmatrix}$.

Sea $p(\lambda) = \det\left(\begin{bmatrix} 3-\lambda & -2 & 3 \\ 4 & -3-\lambda & 3 \\ -2 & 2 & -2-\lambda \end{bmatrix}\right)$

Sea $p(\lambda) = \det\left(\begin{bmatrix} 3-\lambda & -2 & 3 \\ 4 & -3-\lambda & 3 \\ -2 & 2 & -2-\lambda \end{bmatrix}\right)$

$$(3-\lambda)\begin{vmatrix} -3-\lambda & 3 \\ 2 & -2-\lambda \end{vmatrix} - (-2)\begin{vmatrix} 4 & 3 \\ -2 & -2-\lambda \end{vmatrix} + 3\begin{vmatrix} 4 & -3-\lambda \\ -2 & 2 \end{vmatrix}$$

$$= (3-\lambda)\left[(-3-\lambda)(-2-\lambda) - (3)(2)\right] + 2\left[4(-2-\lambda) - (3)(-2)\right] + 3\left[4(2) - (-2)(-3-\lambda)\right].$$

Luego, $p(\lambda) = -\lambda^3 - 2\lambda^2 + \lambda + 2$

Luego, $p(\lambda) = -\lambda^3 - 2\lambda^2 + \lambda + 2 = -(\lambda - 1)(\lambda + 1)(\lambda + 2)$;
luego, los valores propios son: $\lambda_1 = 1,\ \lambda_2 = -1,\ \lambda_3 = -2$.

Vectores propios

Teniendo en cuenta que $\lambda_1 = 1,\ \lambda_2 = -1,\ \lambda_3 = -2$, se resuelve el sistema de ecuaciones

$$(A - \lambda I)v = 0,$$

para cada uno de los valores propios $\lambda_1,\ \lambda_2,\ \lambda_3$.

$$\begin{bmatrix} 3-\lambda & -2 & 3 \\ 4 & -3-\lambda & 3 \\ -2 & 2 & -2-\lambda \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \\ v_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

Si $\lambda = 1$, se tiene el sistema $\begin{bmatrix} 2 & -2 & 3 \\ 4 & -4 & 3 \\ -2 & 2 & -3 \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \\ v_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$

Si $\lambda = -1$, se tiene el sistema $\begin{bmatrix} 4 & -2 & 3 \\ 4 & -2 & 3 \\ -2 & 2 & -1 \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \\ v_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$.

Si $\lambda = -2$, se tiene el sistema $\begin{bmatrix} 5 & -2 & 3 \\ 4 & -1 & 3 \\ -2 & 2 & 0 \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \\ v_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$

Para la matriz $A = \begin{bmatrix} 3 & -2 & 3 \\ 4 & -3 & 3 \\ -2 & 2 & -2 \end{bmatrix}$

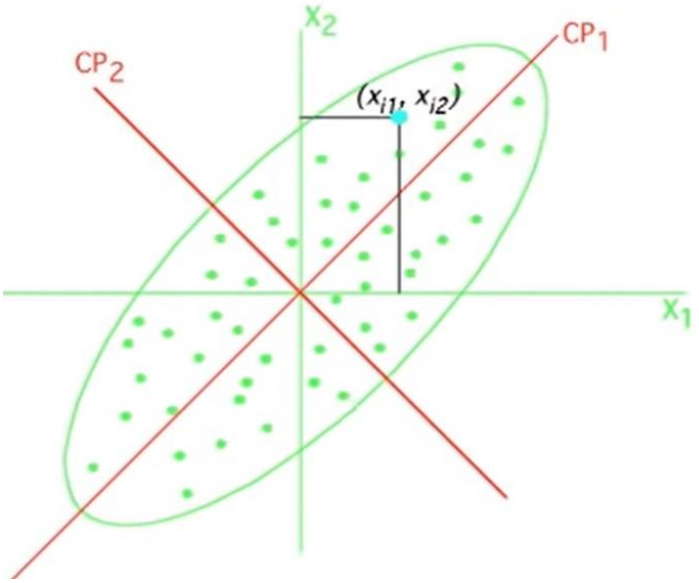
Los vectores propios son:

$$v_1 = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \; v_2 = \begin{bmatrix} 2 \\ 1 \\ -2 \end{bmatrix}, \; v_3 = \begin{bmatrix} 1 \\ 1 \\ -1 \end{bmatrix},$$

asociados a los valores propios $\lambda_1 = 1, \; \lambda_2 = -1, \; \lambda_3 = -2,$ respectivamente.

ACP (Análisis de Componentes Principales) es una técnica exploratoria (no establece supuestos y siempre puede aplicarse).

Pretende hallar aquellas **combinaciones (lineales) de las variables originales** que maximizan la varianza de la proyección sobre el espacio que ellas generan de las variables originales, es decir que **minimizan la pérdida de la información inicial.**



$$CP_j = v_{1j}X_1 + v_{2j}X_2 + \ldots + v_{pj}X_p$$

Observaciones:

- Todas las variables juegan el mismo papel, es decir, el conjunto no se divide en variables dependientes e independientes como en el caso de la regresión.

- El objetivo de ACP es reducir la dimensión del problema. Eliminar variables redundantes, o bien información redundante.

- Permite detectar la presencia de variables latentes (las componentes!).

Observaciones:

- Si las variables originales no están fuertemente correlacionadas, no tiene sentido buscar componentes principales.

- Las unidades de medición pueden influir en la variabilidad de las componentes principales, luego para seleccionar el método conviene considerar la **matriz de correlaciones y no la de covarianzas**.

- Debemos establecer un criterio para seleccionar la cantidad de componentes principales a seleccionar.

¿Cuál es la principal ventaja del ACP (PCA en inglés)?

El ACP tiene varias ventajas, como las siguientes:

- Reducir el número de variables de los datos eliminando las que son ruido, lo que también puede reducir el sobreajuste.

- Mejorar el rendimiento de los algoritmos posteriores centrándose solo en las características relevantes.

- Mejorar la visualización de los datos para comprenderlos mejor.

- Elimina colinealidad

¿Cuáles son los supuestos del ACP?

El análisis de componentes principales parte de los siguientes supuestos:

- Existe una combinación lineal entre variables.
- Supone que los componentes principales que tienen mayor varianza son más importantes que los que no la tienen, y considera que incluyen ruido en los datos.
- Los valores atípicos en los datos incluyen errores experimentales.
- El conjunto de datos del ACP ofrece una gran representación de los datos originales.

¿Cuáles son las limitaciones del ACP?

En primer lugar, el PCA solo funciona con variables numéricas. En segundo lugar, **no funciona** bien cuando las variables no están fuertemente correlacionadas (**correlación lineal débil**). Además, el PCA es sensible a la escala de las características y el resultado se ve afectado por los valores atípicos.

¿Cuándo debes utilizar el análisis PCA?
Se recomienda utilizar el PCA cuando se trate con variables con fuerte correlación lineal.

PRUEBAS UTILES DE PERTINENCIA (orientativas):

Test de esfericidad de Barlett
Propone una H0: no hay direcciones de máxima variabilidad (hay esfericidad).
Entonces, si el **pvalor es chico** hay evidencia de que se puede extraer componentes. **Rechazo esfericidad**

Medida Kaiser-Meyer-Olkin:
de varianza en las variables que pueden ser causadas por factores subyacentes.
Los valores altos (cercanos a 1) indican que un ACP puede ser útil.

Medida de adecuación muestral
Indicador de cantidad de variables y cantidad de casos adecuados para valores altos (cercanos a 1).

Espacios rotados

Los componentes se forman por opuestos

Lo que esta en el (0,0) no aporta a los componentes

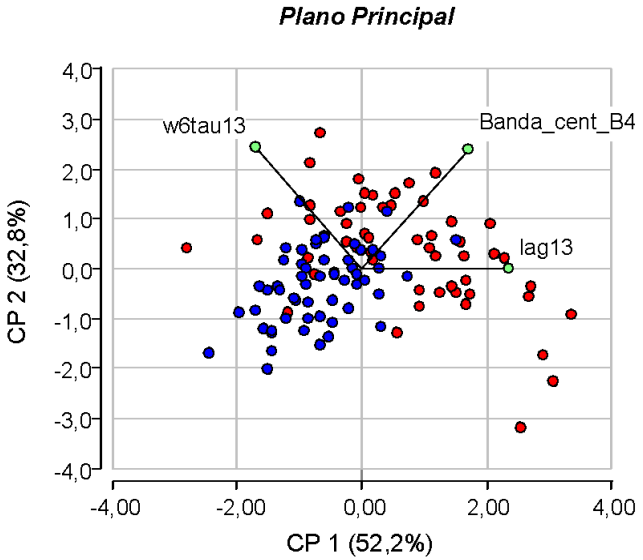
Rotación Varimax → Maximiza la carga de las variables en los ejes o componentes para darle sentido a los ejes en relación a las varibles

¿Qué es PC1 y PC2 en ACP?

- ACP nos permite lograr una representación gráfica de información multidimensional en menos dimensiones.

- Representación en dos dimensiones → Plano Principal: CP1 vs CP2

- El eje PC1 corresponde a la primera dirección principal a lo largo de la cual los datos presentan la mayor variación.
- El eje PC2 corresponde a la segunda dirección más importante a lo largo de la cual los datos presentan la mayor variación.
- Además, PC1 es siempre ortogonal con respecto a PC2.



¿Cuántas componentes?

Criterio 1: Porcentaje de la variabilidad mínimo que se desea explicar.

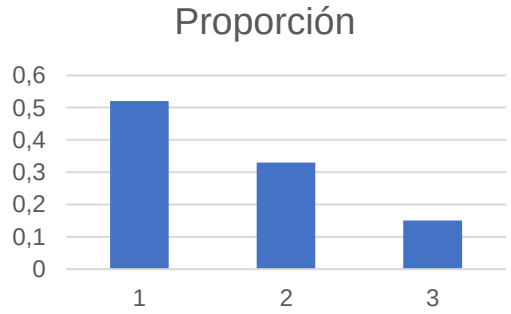
Criterio 2: (Kaiser) retener las m primeras componentes tales que su valor propio (lambda) resulte igual o mayor a 1 (o mayor a 0,7- 0,8…).

Criterio 3: Criterio del bastón roto. En un gráfico de sedimentación , ver la cantidad de componentes hasta que se estabiliza el gráfico.

Criterio 4: Seleccionamos aquellas componentes cuyo autovalor excede de la media de los autovalores

Autovalores Lambda

	Valor Lambda	Proporción	Prop Acum
1	**1,57**	0,52	0,52
2	**0,99**	0,33	0,85
3	0,45	0,15	1
	Suma 3		



Procedimiento

Paso 1: normalización de datos

Pensando en el ejemplo de la introducción, consideremos, por ejemplo, la siguiente información para un cliente determinado.

- Media Gastos mensuales: 300 $
- Media de Edad: 27
- Media de la Valoración: 4,5.

Esta información tiene escalas diferentes y realizar el PCA utilizando esos datos conducirá a un resultado sesgado. Aquí es donde entra en juego la normalización de datos. Garantiza que cada atributo tenga el mismo nivel de contribución, para que una variable no domine a las demás. Para cada variable, la normalización se hace restando su media y dividiendo entre su desviación típica.

Procedimiento

Paso 2: matriz de covarianza

Como su nombre sugiere, este paso consiste en computar la **matriz de covarianza** a partir de los datos normalizados. Se trata de una matriz simétrica, y cada elemento (i, j) corresponde a la covarianza entre las variables i y j.

Paso 3: vectores propios y valores propios

Geométricamente, cada **vector propio** representa **una dirección** y son perpendiculares entre sí los distintos vectores.

Un **valor propio** es un número que representa la cantidad de varianza presente en los datos para una dirección determinada.

Cada vector propio tiene su correspondiente valor propio.

Procedimiento

Paso 4: selección de los componentes principales

Hay tantos pares de vectores propios y valores propios como variables haya en los datos. En los datos con solo gastos mensuales, edad y valoración, habrá tres pares.

No todos los pares son relevantes. Por tanto, el vector propio con el valor propio más alto corresponde al primer componente principal. El segundo componente principal es el vector propio con el segundo valor propio más alto, y así sucesivamente.

Paso 5: transformación de datos en nuevo espacio dimensional

Este paso consiste en reorientar los datos originales hacia un nuevo subespacio definido por los componentes principales. Esta reorientación se realiza multiplicando los datos originales por los vectores propios calculados previamente.

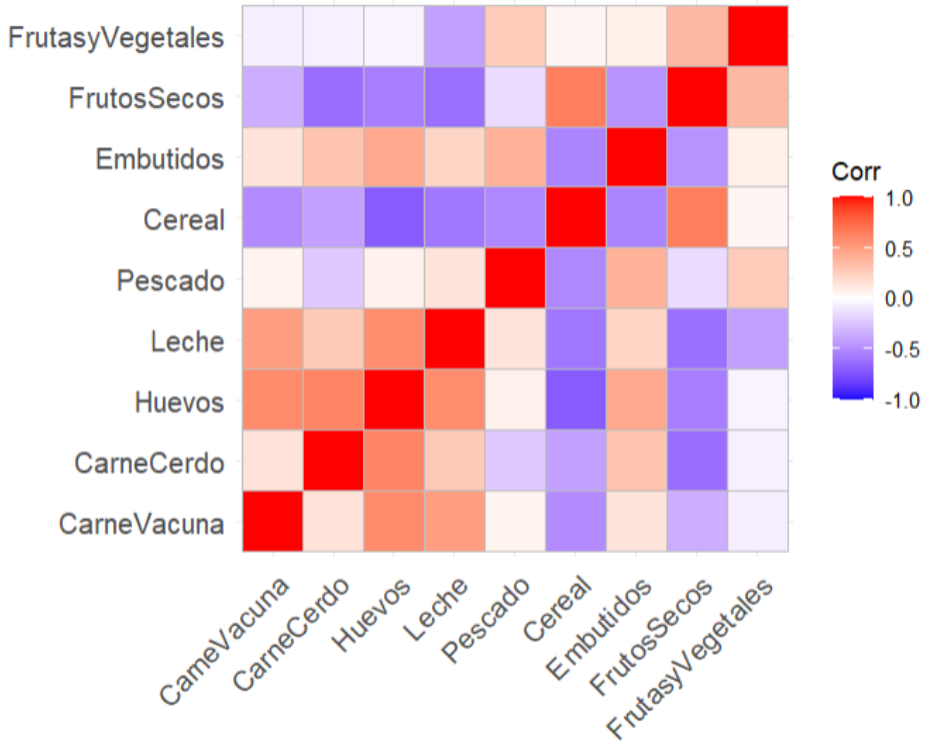
Es importante recordar que esta transformación no modifica los datos originales en sí, sino que proporciona una nueva perspectiva para representar mejor los datos.

Explorar correlaciones

Diagonal = 1

Positivas:
en el mismo sentido crece
r > 0,5

Negativas:
Sentido opuestos
de crecimiento
r < - 0,5

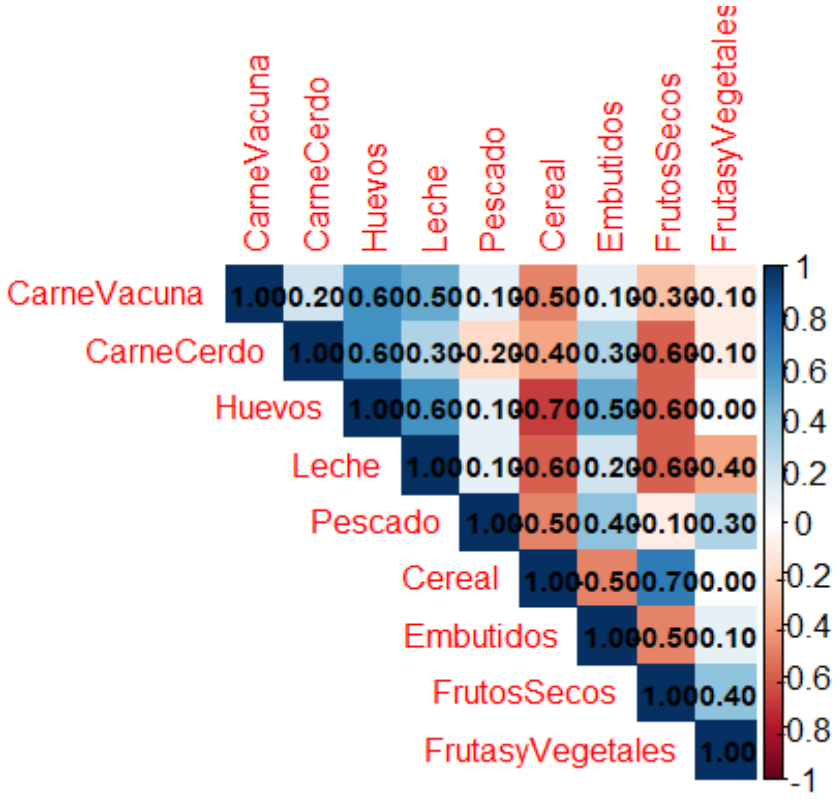


Explorar correlaciones

Diagonal = 1

Positivas:
en el mismo sentido crece
r > 0,5

Negativas:
Sentido opuestos
de crecimiento
r < - 0,5



Ejemplo 1: datos de Alimentación

Datos estandarizados

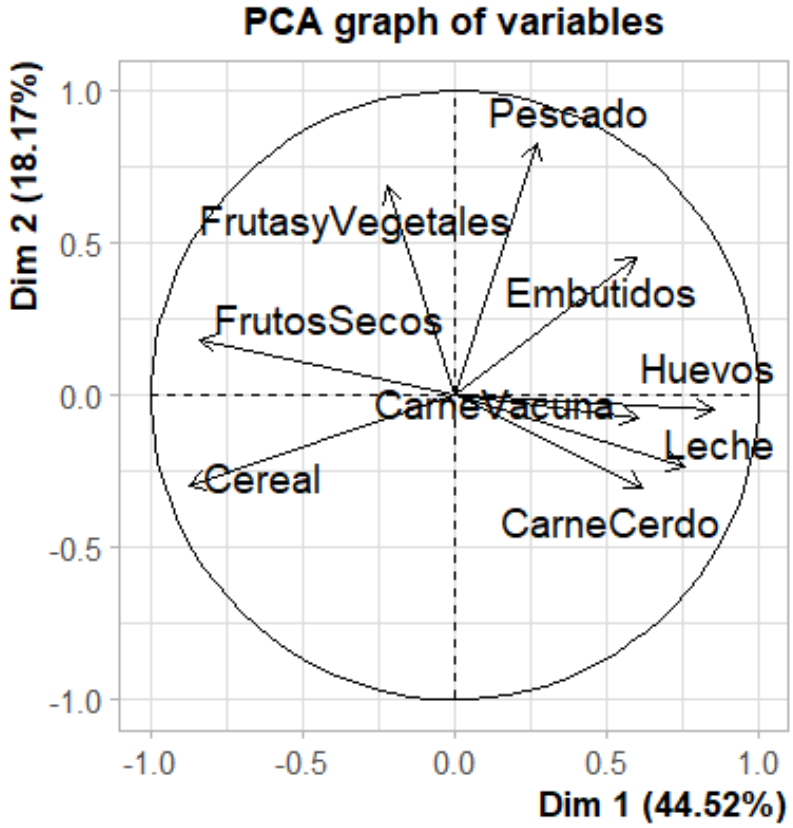
Datos estandarizados

Autovalores: con

Lambda	Valor	Proporción	Prop Acum
1	**4,01**	0,45	0,45
2	**1,63**	0,18	0,63
3	1,13	0,13	0,75
4	0,95	0,11	0,86
5	0,46	0,05	0,91
6	0,33	0,04	0,95
7	0,27	0,03	0,98
8	0,12	0,01	0,99
9	0,10	0,01	1,00

Cargas (loadings): con cp$rotation

Variables	PC1	PC2
CarneVacuna	-0,30	-0,06
CarneCerdo	-0,31	-0,24
Huevos	-0,43	-0,04
Leche	-0,38	-0,18
Pescado	-0,14	0,65
Cereal	0,44	-0,23
Embutidos	-0,30	0,35
FrutosSecos	0,42	0,14
Frutas yVegetales	0,11	0,54


PCA graph of variables
Dim 2 (18.17%)
1.0
0.5
0.0
-0.5
-1.0
Pescado
FrutasyVegetales
Embutidos
FrutosSecos
Huevos
CarneVacuna
Leche
Cereal
CarneCerdo
-1.0
-0.5
0.0
0.5
1.0
Dim 1 (44.52%)

Ejemplo 2

Se desea analizar la economía de distintos países de acuerdo las variables siguientes:

https://www.datacamp.com/es/tutorial/pca-analysis-r

SECTORES:

AGR: Agricultura, MIN: Minería, MAN: Manufacturas, ENER: Energía, CON: Construcción, SER: Industrias de servicios, FIN: finanzas, SSP: Servicios sociales y personales, TC: Transportes y comunicaciones.

Ejemplo 2

PAISES	AGR	MIN	MAN	ENER	CON	SER	FIN	SSP	TC
BÉLGICA	3.3	0.9	27.6	0.9	8.2	19.1	6.2	26.6	7.2
DINAMARCA	9.2	0.1	21.8	0.6	8.3	14.6	6.5	32.2	7.1
FRANCIA	10.8	0.8	27.5	0.9	8.9	16.8	6.0	22.6	5.7
RFA	6.7	1.3	35.8	0.9	7.3	14.4	5.0	22.3	6.1
IRLANDA	23.2	1.0	20.7	1.3	7.5	16.8	2.8	20.8	6.1
ITALIA	15.9	0.6	27.6	0.5	10.0	18.1	1.6	20.1	5.7
LUXEMBURGO	7.7	3.1	30.8	0.8	9.2	18.5	4.6	19.2	6.2
HOLANDA	6.3	0.1	22.5	1.0	9.9	18.0	6.8	28.5	6.8
U.K.	2.7	1.4	30.2	1.4	6.9	16.9	5.7	28.3	6.4
AUSTRIA	12.7	1.1	30.2	1.4	9.0	16.8	4.9	16.8	7.0
FINLANDIA	13.0	0.4	25.9	1.3	7.4	14.7	5.5	24.3	7.6
GRECIA	41.4	0.6	17.6	0.6	8.1	11.5	2.4	11.0	6.7
NORUEGA	9.0	0.5	22.4	0.8	8.6	16.9	4.7	27.6	9.4
PORTUGAL	27.8	0.3	24.5	0.6	8.4	13.3	2.7	16.7	5.7
ESPAÑA	22.9	0.8	28.5	0.7	11.5	9.7	8.5	11.8	5.5
SUECIA	6.1	0.4	25.9	0.8	7.2	14.4	6.0	32.4	6.8
SUIZA	7.7	0.2	37.8	0.8	9.5	17.5	5.3	15.4	5.7
TURQUÍA	66.8	0.7	7.9	0.1	2.8	5.2	1.1	11.9	3.2
BULGARIA	23.6	1.9	32.3	0.6	7.9	8.0	0.7	18.2	6.7
CHECOSLOVAQUIA	16.5	2.9	35.5	1.2	8.7	9.2	0.9	17.9	7.0
RDA	4.2	2.9	41.2	1.3	7.6	11.2	1.2	22.1	8.4
HUNGRÍA	21.7	3.1	29.6	1.9	8.2	9.4	0.9	17.2	8.0
POLONIA	31.1	2.5	25.7	0.9	8.4	7.5	0.9	16.1	6.9
RUMANIA	34.7	2.1	30.1	0.6	8.7	5.9	1.3	11.7	5.0
URSS	23.7	1.4	25.8	0.6	9.2	6.1	0.5	23.6	9.3
YUGOSLAVIA	48.7	1.5	16.8	1.1	4.9	6.4	11.3	5.3	4.0

Ejemplo 2

Se desea analizar la economía de distintos países de acuerdo las variables siguientes:

SECTORES:

AGR: Agricultura, MIN: Minería, MAN: Manufacturas, ENER: Energía, CON: Construcción, SER: Industrias de servicios, FIN: finanzas, SSP: Servicios sociales y personales, TC: Transportes y comunicaciones.

Ejemplo 2

PAISES	AGR	MIN	MAN	ENER	CON	SER	FIN	SSP	TC
BÉLGICA	3.3	0.9	27.6	0.9	8.2	19.1	6.2	26.6	7.2
DINAMARCA	9.2	0.1	21.8	0.6	8.3	14.6	6.5	32.2	7.1
FRANCIA	10.8	0.8	27.5	0.9	8.9	16.8	6.0	22.6	5.7
RFA	6.7	1.3	35.8	0.9	7.3	14.4	5.0	22.3	6.1
IRLANDA	23.2	1.0	20.7	1.3	7.5	16.8	2.8	20.8	6.1
ITALIA	15.9	0.6	27.6	0.5	10.0	18.1	1.6	20.1	5.7
LUXEMBURGO	7.7	3.1	30.8	0.8	9.2	18.5	4.6	19.2	6.2
HOLANDA	6.3	0.1	22.5	1.0	9.9	18.0	6.8	28.5	6.8
U.K.	2.7	1.4	30.2	1.4	6.9	16.9	5.7	28.3	6.4
AUSTRIA	12.7	1.1	30.2	1.4	9.0	16.8	4.9	16.8	7.0
FINLANDIA	13.0	0.4	25.9	1.3	7.4	14.7	5.5	24.3	7.6
GRECIA	41.4	0.6	17.6	0.6	8.1	11.5	2.4	11.0	6.7
NORUEGA	9.0	0.5	22.4	0.8	8.6	16.9	4.7	27.6	9.4
PORTUGAL	27.8	0.3	24.5	0.6	8.4	13.3	2.7	16.7	5.7
ESPAÑA	22.9	0.8	28.5	0.7	11.5	9.7	8.5	11.8	5.5
SUECIA	6.1	0.4	25.9	0.8	7.2	14.4	6.0	32.4	6.8
SUIZA	7.7	0.2	37.8	0.8	9.5	17.5	5.3	15.4	5.7
TURQUÍA	66.8	0.7	7.9	0.1	2.8	5.2	1.1	11.9	3.2
BULGARIA	23.6	1.9	32.3	0.6	7.9	8.0	0.7	18.2	6.7
CHECOSLOVAQUIA	16.5	2.9	35.5	1.2	8.7	9.2	0.9	17.9	7.0
RDA	4.2	2.9							
HUNGRÍA	21.7	3.1							
POLONIA	31.1	2.5							
RUMANIA	34.7	2.1							
URSS	23.7	1.4							
YUGOSLAVIA	48.7	1.5							

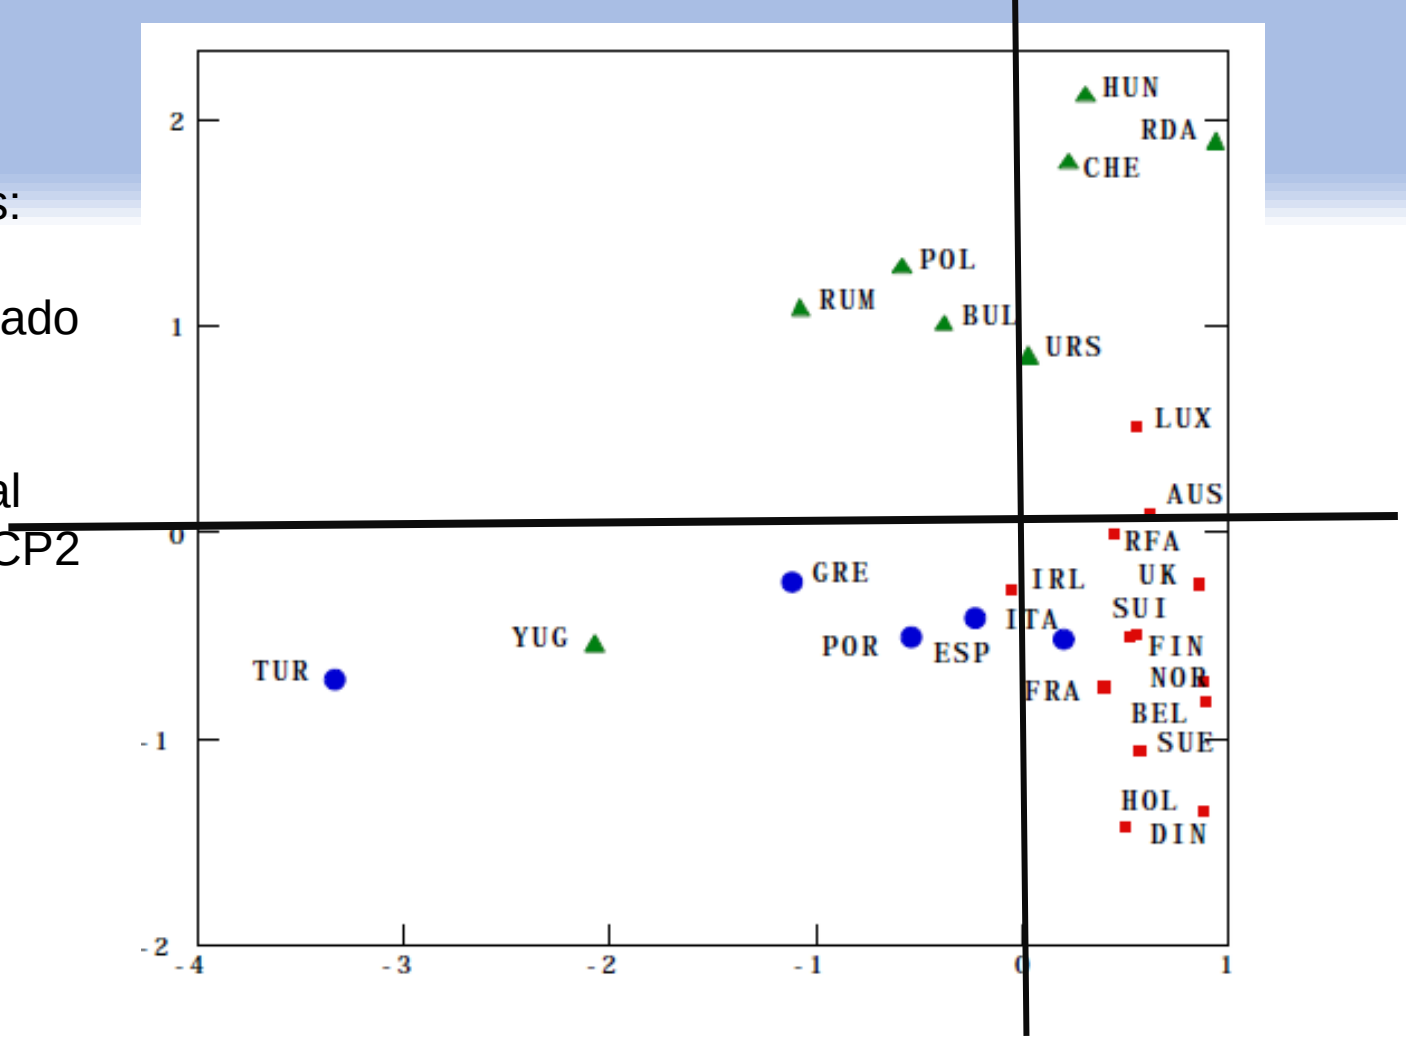
SECTORES:

AGR: Agricultura, MIN: Minería, MAN: Manufacturas, ENER: Energía, CON: Construcción, SER: Industrias de servicios, FIN: finanzas, SSP: Servicios sociales y personales, TC: Transportes y comunicaciones.

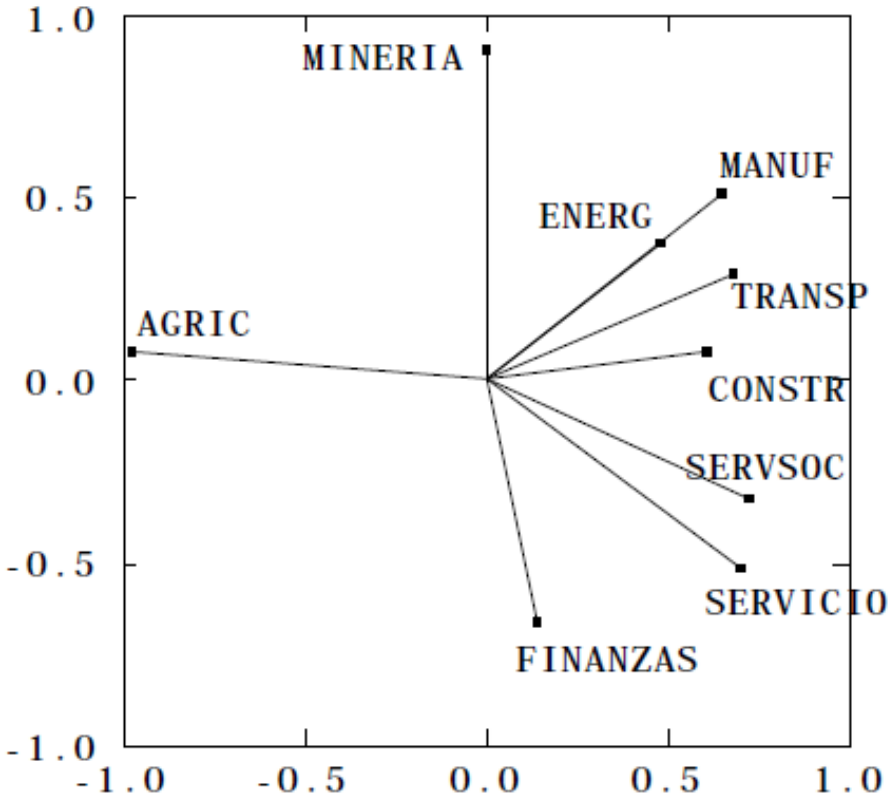
COMPONENT LOADINGS

	1	2
AGRIC	-0.978	0.078
MINERIA	-0.002	0.902
MANUF	0.649	0.518
ENERG	0.478	0.381
CONSTR	0.607	0.075
SERVICIO	0.708	-0.511
FINANZAS	0.139	-0.662
SERVSOC	0.723	-0.323
TRANSP	0.685	0.296

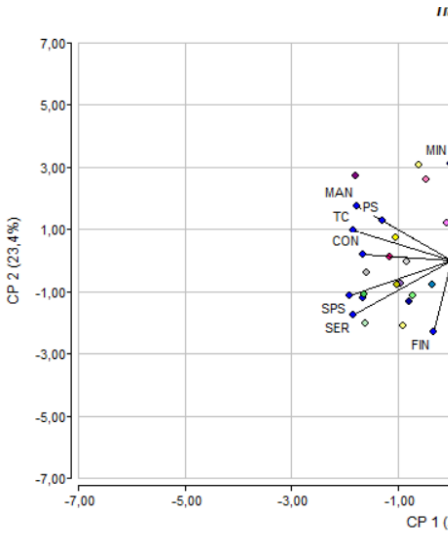
n casos: países proyectados en el plano principal CP1 y CP2



P variables: países proyectadas en cuanto correlación con los ejes CP1 y CP2 (plano principal)



Representación gráfica de los factores de carga.



COMPONENT LOADINGS

	1
AGRIC	-0.978
MINERIA	-0.002
MANUF	0.649
ENERG	0.478
CONSTR	0.607
SERVICIO	0.708
FINANZAS	0.139
SERVSOC	0.723
TRANSP	0.685

Autovectores

Variables	e1	e2
AGR	0,524	0,065
MIN	-0,007	0,623
MAN	-0,354	0,347
PS	-0,260	0,258
CON	-0,331	0,036
SER	-0,367	-0,348
FIN	-0,068	-0,457
SPS	-0,382	-0,225
TC	-0,371	0,196

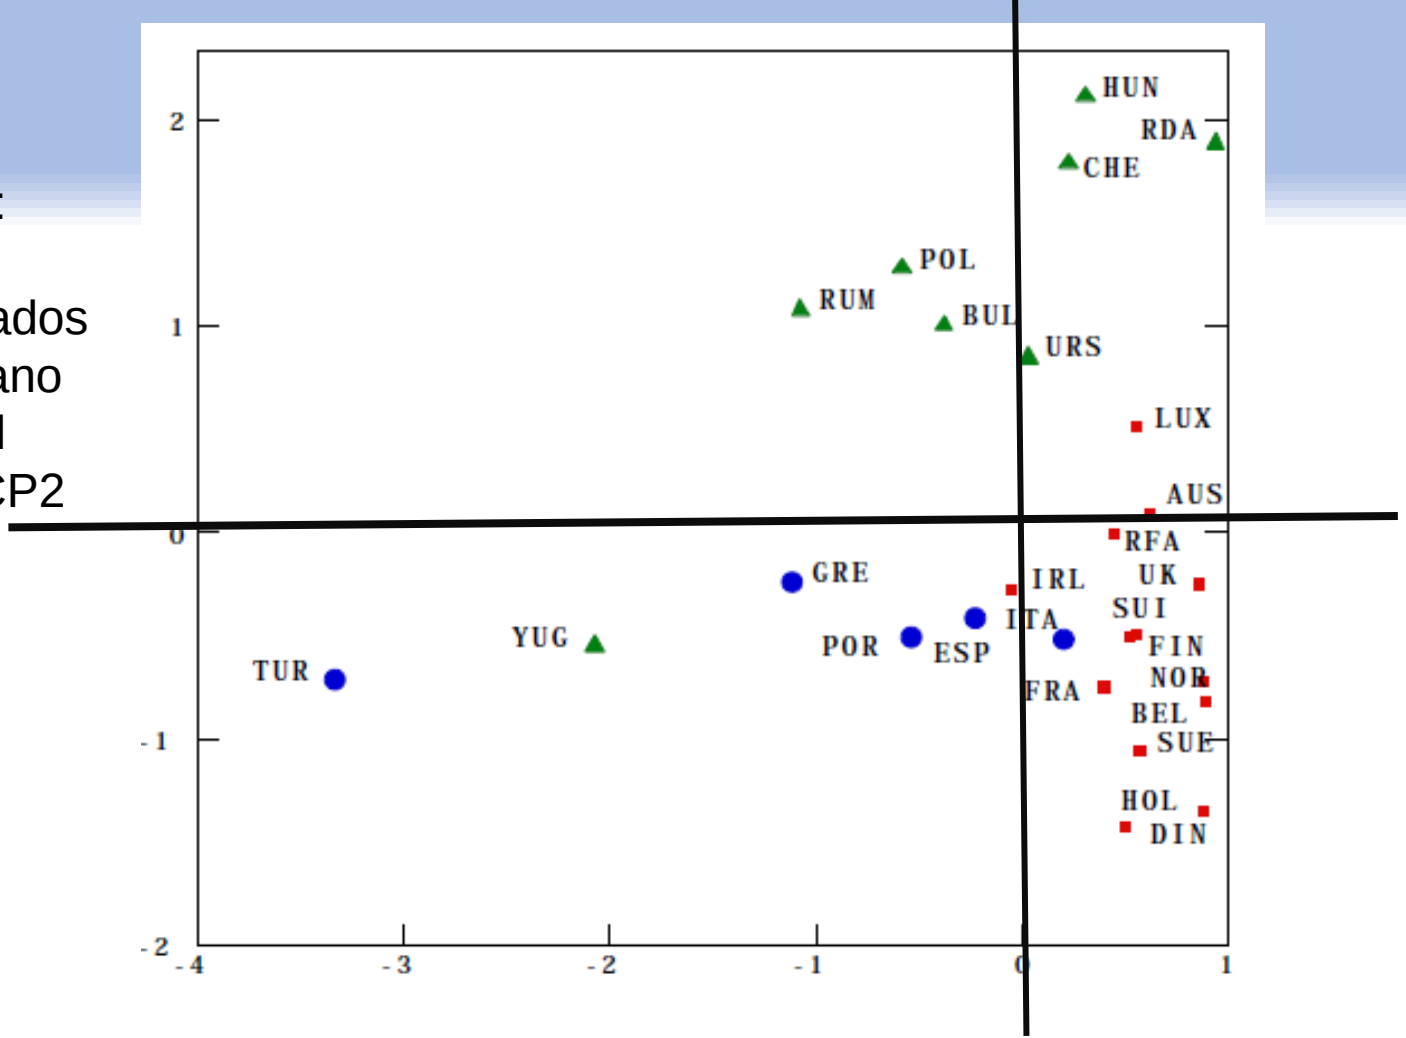
Correlaciones con las variables originales

Variables	CP 1	CP 2
AGR	0,975	0,094
MIN	-0,012	0,904
MAN	-0,659	0,504
PS	-0,484	0,375
CON	-0,616	0,052
SER	-0,684	-0,506
FIN	-0,126	-0,664
SPS	-0,710	-0,326
TC	-0,690	0,284

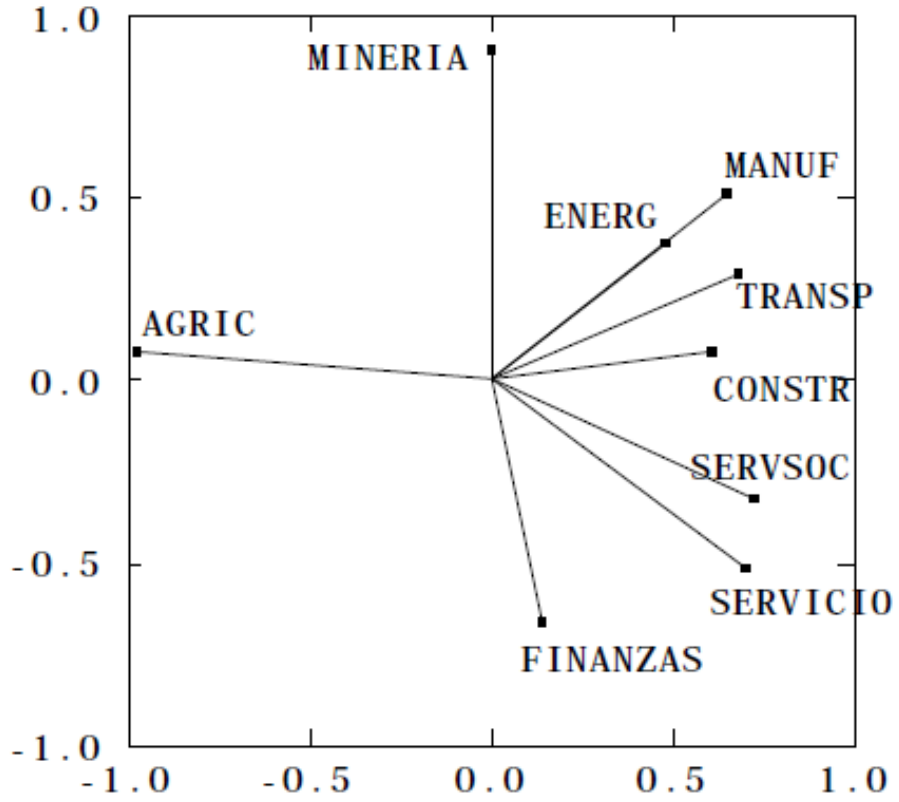
Correlación cofenética= 0,908

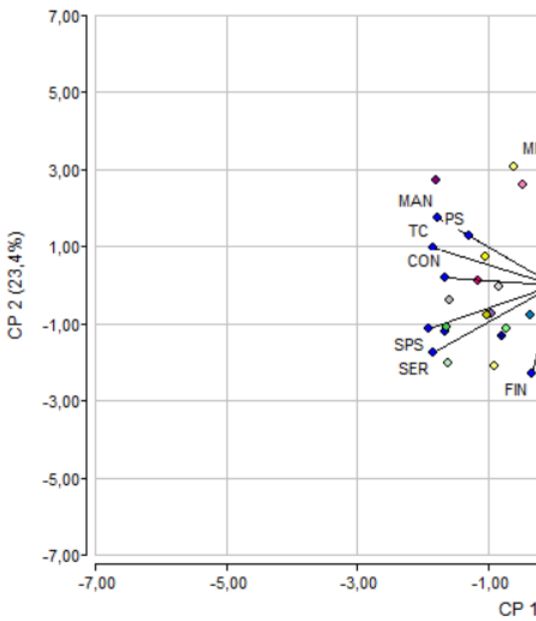
n casos: países proyectados en el plano principal CP1 y CP2

Casos



P variables: países proyectadas en cuanto correlación con los ejes CP1 y CP2 (plano principal)





Representación gráfica de los factores de carga.

Interpretación de resultados

- Diagramas de dispersión que representan los valores de los individuos en las primeras componentes principales.
- Interpretación de las distancias en términos de similitud.
- Búsqueda de agrupamientos (**clusters**) y patrones.
- Interpretación de las componentes mediante las correlaciones con las variables originales.
- Las posiciones de los individuos se interpretan posteriormente en relación con la interpretación dada a las componentes.
- Componentes 1 y 2 → Plano Principal

Aplicaciones del análisis de componentes principales

El análisis de componentes principales tiene diversas aplicaciones en nuestra vida cotidiana, como, por ejemplo, las finanzas, el procesamiento de imágenes, la sanidad, seguridad, encuestas (escalas de Likert)…..

Finanzas: Prever los precios de las acciones a partir de precios pasados.

Procesamiento de imágenes: Compresión para conservar los detalles esenciales de una imagen dada, reduciendo el número de dimensiones.

Sanidad: reducir la dimensionalidad de las imágenes con el fin de mejorar la visualización y el análisis médico.

Seguridad: Los sistemas biométricos para extraer las características más relevantes, como la textura de la huella dactilar e información adicional.

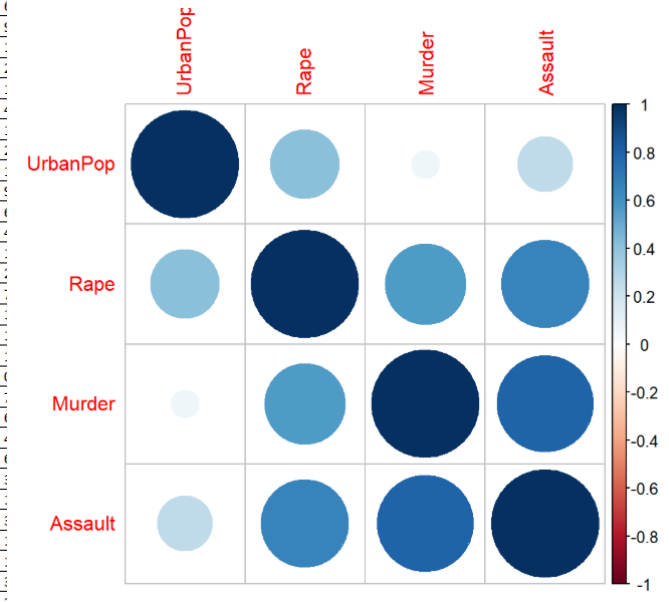
Encuestas (escalas de Likert): perfiles de respuesta

Eje

Estado
Asesinatos
Asaltos
Pintadas
Ataques Sexuales

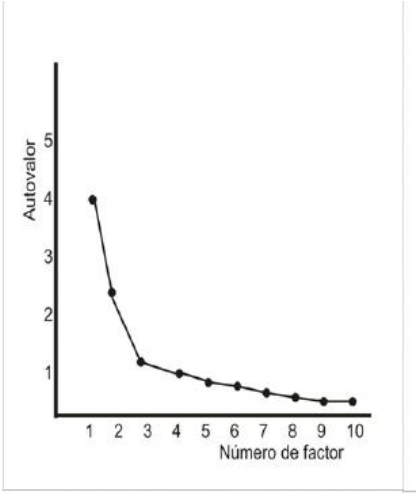
	Asesinato	Asalto	Pintadas	Sexuales
Asesinato	1,00	0,80	0,07	0,56
Asalto	0,80	1,00	0,26	0,67
Pintadas	0,07	0,26	1,00	0,41
Sexuales	0,56	0,67	0,41	1,00

	Asesinato	Asalto	Pintadas	Sexuales
Alabama	13,2	236	58	21,2
Alaska	10,0	263	48	44,5
Arizona	8,1	294	80	31,0
Arkansas	8,8	190	50	19,5
California	9,0	276	91	40,6
Colorado	7,9	204	78	38,7
Connecticut	3,3	110	77	11,1
Delaware	5,9	238	72	15,8
Florida	15,4	335	80	31,9
Georgia	17,4	211	60	25,8
Hawaii	5,3	46	83	20,2
Idaho	2,6	120	54	14,2
Illinois	10,4	249	83	24,0
Indiana	7,2	113	65	21,0
Iowa	2,2	56	57	11,3
Kansas				
Kentucky				
Louisiana				
Maine				
Maryland				
Massachusetts				
Michigan				
Minnesota				
Mississippi				
Missouri				
Montana				
Nebraska				
Nevada				
NewHampshire				
NewJersey				
NewMexico				
NewYork				
NorthCarolina				
NorthDakota				
Ohio				
Oklahoma				
Oregon				
Pennsylvania				
RhodeIsland				
SouthCarolina				
SouthDakota				
Tennessee				
Texas				
Utah				
Vermont				
Virginia	8,5	156	63	20,7
Washington	4,0	145	73	26,2
WestVirginia	5,7	81	39	9,3
Wisconsin	2,6	53	66	10,8

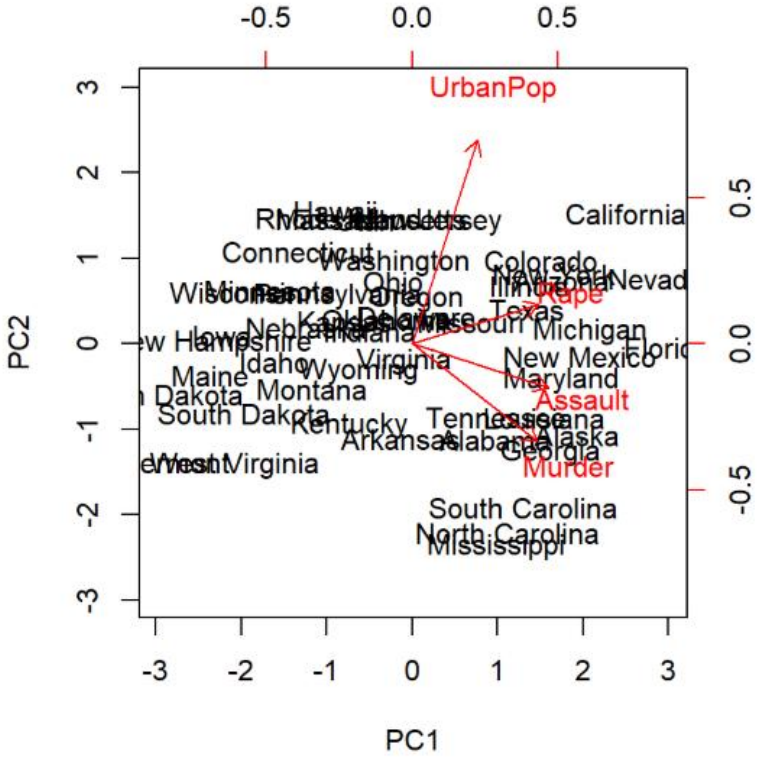


Pintadas diferente comportamiento

	CP1	CP2
Asesinato	-0,53	0,41
Asalto	-0,58	0,18
Pintadas	-0,27	-0,87
Sexuales	-0,54	-0,16



	CP1	CP2
Alabama	-0,97	1,12
Alaska	-1,93	1,06
Arizona	-1,74	-0,73
Arkansas	0,13	1,10
California	-2,49	-1,52
Colorado	-1,49	-0,97
Connecticut	1,34	-1,07
Delaware	-0,04	-0,32
...	...	...
Florida	-2,98	0,03
Wisconsin	2,05	-0,60
Wyoming	0,62	0,31



Ejemplo aguas

https://ojs.latu.org.uy/index.php/INNOTEC/article/view/526/1056

Parámetro	Unidad	RANGO (Nº DE POZOS) Mínimo	Máximo	Media	LMP Decreto 883*	OMS	Desvia Están
Temperatura	ºC	28.20 (P-4)	31.20 (P-3)	29.51 (P-3,5,8)			0.6
pH		4.12 (P-6)	7.56 (P-1)	5.57	6.0-8.5		1.0
Dureza	mg/l	15.15 (P-4)	217.17 (P-1)	27.73	500.0		63.0
CE	µS/cm	30.00 (P-4)	600.00 (P-1)	152.19		3000	177.
Fe	mg/l	0.00 (P-6)	0.54 (P-1)	0.09 (P-3)	0.1	0.3	0.1
Mn	mg/l	0.00 (P-1,2,3,4,5,6,7)	0.50 (P-8)	0.09	0.1	0.5	0.1
Na	mg/l	2.53 (P-4)	90.62 (P-)	30.35	200		22.3
K	mg/l	5.00 (P-2)	40.00 (P-1,4,7)	25.00		50	8.3
NO_2	mg/l	0.00 (P-2,3,4,5,6,7,8)	22.00 (P-8)	4.04	5	3	6.0
NO_3	mg/l	4.50 (P-3)	59.50 (P-2)	25.13	5	50	12.8
SO_4	mg/l	0.00 (P-1,2,3,4,5,6,7,8)	45.00 (P-1)	5.42	400	250	12.2
Cl	mg/l	30.00 (P-2)	150.00 (P-6)	67.92	600	250	27.9
Fenoles	mg/l	0.0026(P-2)	0.0224 (P-3)	0.0075	0.002		0.06
CF	NMP/100ml	0 (P-1,2,3,4,5,6,7,8)	4300 (P-1)	260.75	0		913.1

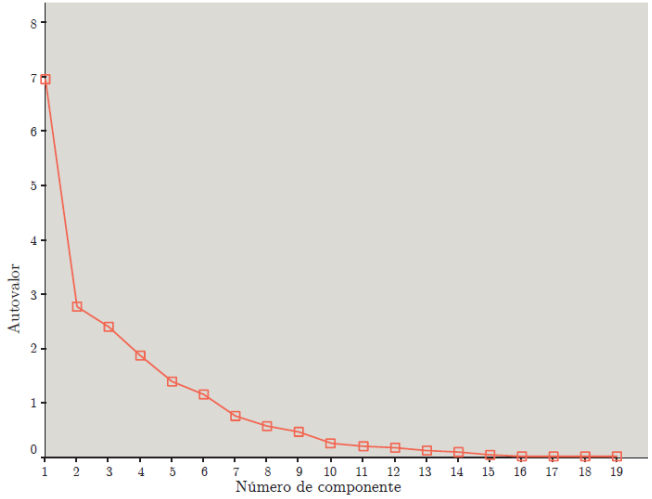
Ejemplo aguas

Esfericidad de Barlett

Medida de adecuación muestral de Kaiser-Meyer-Olkin.	0.575
Prueba de esfericidad de Bartlett	
Chi-cuadrado aproximado	571.638
Gl	171
Sig.	0.00

Varianza total explicada

Componente	Autovalores iniciales			Sumas de las saturaciones al cuadrado de la extracción			Sumas de las saturaciones al cuadrado de la rotación		
	Total	% de la varianza	% acumulado	Total	% de la varianza	% acumulado	Total	% de la varianza	% acumulado
1	6.930	36.475	36.475	6.930	36.475	36.475	5.966	31.400	31.400
2	2.766	14.558	51.033	2.766	14.558	51.033	2.934	15.443	46.843
3	2.392	12.587	63.620	2.392	12.587	63.620	2.098	11.043	57.887
4	1.847	9.719	73.338	1.847	9.719	73.338	2.095	11.024	68.911
5	1.375	7.238	80.577	1.375	7.238	80.577	1.976	10.400	79.311
6	1.139	5.996	86.573	1.139	5.996	86.573	1.380	7.262	86.573
7	.732	3.854	90.427						
8	.732	2.943	93.370						
9	.443	2.330	95.700						
10	.250	1.313	97.014						
11	.182	.958	97.972						
12	.161	.846	98.818						
13	.118	.621	99.439						
14	.069	.365	99.804						
15	.018	.096	99.900						
16	.012	.063	99.964						
17	.007	.034	99.998						
18	.000	.001	99.999						
19	.000	.001	100.000						



Componentes Rotados (Rotación Varimax)

	Componente					
	1	2	3	4	5	6
Temperatura	.114	-.003	.060	.079	.186	.922
pH	.794	.013	.394	.123	-.075	.304
CE	.946	.258	.046	-.017	.111	-.014
TDS	.944	.251	.062	-.033	.111	-.018
Dureza	.973	.195	.052	.041	.013	-.025
Fe	.569	.56			23	.194
Ca	.971	.21			10	.004
Mg	.015	.05			63	.057
Mn	.055	-.207	.233	.195	.878	-.056
Na	-.178	-.095	-.923	.096	-.167	.044
K	.006	.430	.132	.536	.119	-.467
NO_2	.105	.121	-.012	-.235	.868	.242
NO_3	.185	-.058	.057	-.812	.030	-.032
SO_4	.580	.512	.047	.194	-.034	-.117
CI	.359	.098	-.482	.671	.059	-.059
HCO_3	.830	-.168	-.261	-.234	.118	.117
Fenol	.025	-.200	.537	.685	-.068	.259
CT	.172	.956	.058	.026	-.050	-.112

Permite
Selección de Variables

Descripción de los CP 1 a CP6 según variables.

El primer componente (CP1), denominado componente geológico, explica el 36.48% de la varianza total, presentando una fuerte correlación positiva con las variables pH, CE, Ca, dureza, TDS, y HCO3. Esta combinación de variables destaca el grado natural de mineralización del agua y podría estar relacionada con la geología del área estudiada, derivada de los procesos de evaporación y disolución.

Evitar colinealidad
con ACP
Luego:
Regresión múltiple

- Con Variables seleccionadas
- Con componentes

Las componentes no rotadas son no colineales

Tabla 5. Análisis de regresión múltiple para determinar los factores que contribuyen con Índice de calidad del Agua (ICA).

Parámetros	Coeficiente β	Error Típico (ET)	β Estandarizado	Posición	t student's	Valor p
(Constante)	-39.477	0.487			-81.102	<0.001a
pH	6.373	0.084	0.053	IV	76.024	<0.001a
CE	0.005	0.001	0.007	VIII	5.905	<0.001a
Fe	9.417	0.436	0.011	VII	21.614	<0.001a
Mn	-31.618	0.434	0.04	V	72.895	<0.001a
Na	0.017	0.003	0.003	X	5.107	<0.001a
NO_2	2.104	0.01	0.105	III	217.646	<0.001a
NO_3	0.136	0.004	0.014	VI	32.413	<0.001a
SO_4	0.02	0.005	0.002	XI	3.731	<0.003a
CI	0.025	0.003	0.006	IX	7.526	<0.001a
Fenol	6318.542	10.973	0.332	II	575.81	<0.001a
CF	0.126	0	0.95	I	1919.101	<0.001a

a Altamente significativo

Selección de variables con ACP -> 339 a 33

Selección de Medidas de Disfonía para la Identificación de Enfermos de Parkinson

Selection of Dysphonia Measures for the Identification of Parkinson's Disease

Monica Giuliano
Engineering Departament
Universidad Nacional de La Matanza
San Justo, Argentina
mgiuliano@unlam.edu.ar

Luis Fernandez
Engineering Departament
Universidad Nacional de La Matanza
San Justo, Argentina
lfernaar@yahoo.com.ar

Silvia Pérez
Engineering Departament
Universidad Nacional de La Matanza
San Justo, Argentina
sperez@unlam.edu.ar

Selección de 11 variables

ACP
ANOVA
Lasso

Tabla 1: Clasificación de las 339 medidas de disfonía.

Grupo	Medidas	Variables	Cantidad
G1	Variaciones de F0	V1-V22, V49-V51, V155-336, V337, V339	209
G2	Variaciones de la amplitud	V23-V44	22
G3	Ruido	V45-V48, V52-V70, V338	24
G4	Problemas en la articulación	V71-V154	84

G	ACP y diferencia de Medias
G1	V51 V239 V271 V330 V336 V339
G2	V23 V37
G3	V45 V58 V59 V60
G4	V137 V141 V152

Luego
Clasificación con métodos supervisados

Conclusión

- Sabemos que los conjuntos de datos grandes son cada vez más frecuentes y, a menudo, difíciles de comprender. El Análisis de Componentes Principales reduce la dimensionalidad de estos conjuntos de datos, a la vez que aumenta la interpretabilidad y minimiza la pérdida de información. Maximiza la varianza gradualmente al introducir nuevas variables no correlacionadas.
- PCA se utiliza principalmente para reducir la dimensionalidad en muchas aplicaciones de IA, como visión artificial, compresión de imágenes, etc.
- Si los datos tienen una gran dimensión, también pueden utilizarse para descubrir patrones ocultos.

El PCA suele buscar la superficie de menor dimensión sobre la que proyectar los datos de mayor dimensión. Por eso, el PCA resulta beneficioso y práctico.

GRACIAS POR SU ATENCIÓN