ANALISIS INTELIGENTE DE DATOS



Profesora: Maria Laura Vranic

Análisis de Componentes principales

Conceptos clave del ACP

Transformación de variables:

- **El ACP convierte un conjunto de variables correlacionadas en un conjunto de variables no correlacionadas (componentes principales), mediante combinaciones lineales.**

Reducción de dimensión:

- **Su objetivo es preservar la mayor variabilidad posible del conjunto original, simplificando el problema al reducir el número de variables.**

Técnica descriptiva:

- **Es exploratoria, libre de distribución y no requiere supuestos, por lo que siempre puede aplicarse.**

Maximización de varianza:

- **Busca encontrar las combinaciones lineales que maximizan la varianza de los datos, minimizando la pérdida de información.**

Base matemática:

- **Se parte de una matriz $X \in \mathbb{R}^{n \times p}$, donde se registran p variables sobre n individuos.**

Aspectos claves del ACP



Todas las variables tienen el mismo rol: **no hay independientes ni dependientes.**



El objetivo es **reducir la dimensión del problema**, descartando información redundante.



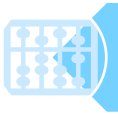
Permite visualizar datos multidimensionales.



Se explora la existencia de variables latentes.



Su aplicación tiene sentido solo si las variables están fuertemente correlacionadas.



Se recomienda usar la **matriz de correlaciones** (no la de covarianzas) para evitar distorsiones por unidades de medida.



Es necesario **definir un criterio de finalización** para seleccionar el número de componentes.

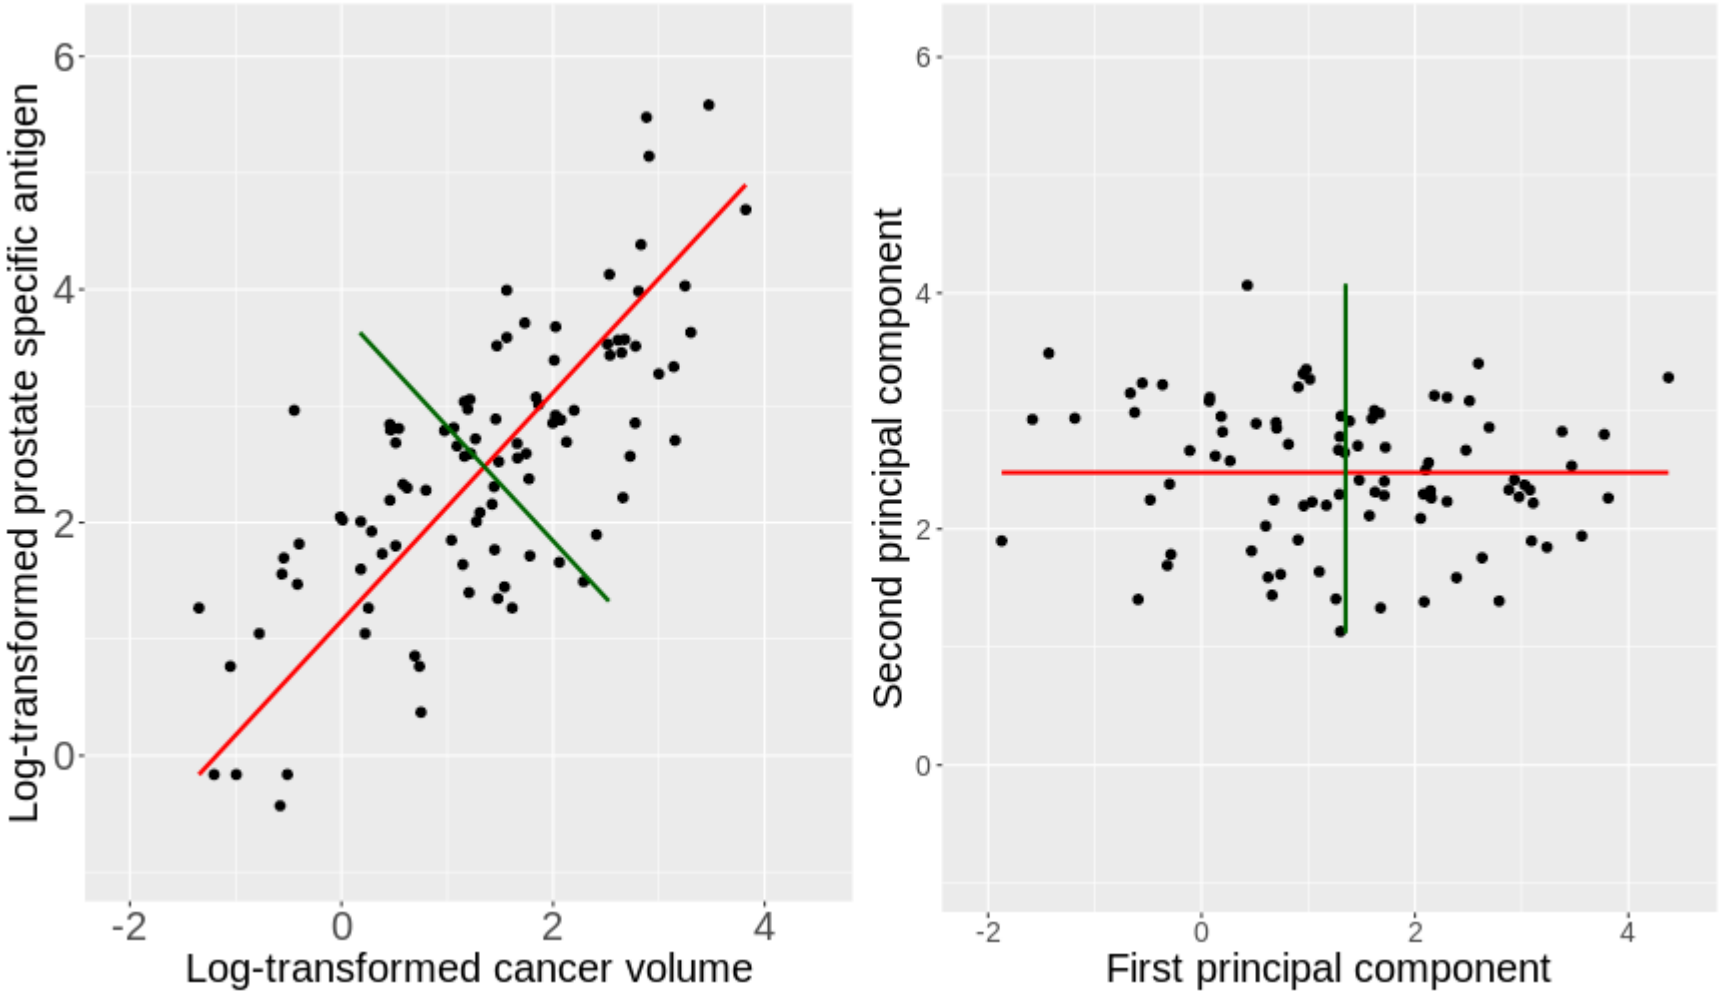


Los análisis confirmatorios ayudan a evaluar la estabilidad de los componentes y detectar observaciones atípicas.



Puede ser útil para identificar anomalías en los datos.

ANALISIS DE COMPONENTES PRINCIPALES



CRITERIOS PARA DECIDIR EL NUMERO DE COMPONENTES PRINCIPALES

- Porcentaje de varianza explicada
- Criterio de Kaiser
- Criterio del bastón roto
- Prueba de esfericidad

Ejemplo 1

EJEMPLO 1: Celtis Tala, fruto





https://es.wikipedia.org/wiki/Celtis_ehrenbergiana

Palacio FX, M Lacoretz, M Ordano. 2014. Bird-mediated selection on fruit display traits in *Celtis ehrenbergiana* (Cannabaceae). *Evolutionary Ecology Research*, 16(1): 51-62.

Variables

diam: diámetro,

az: Concentración de azúcar,

pulpa: peso de la pulpa,

sem: peso de la semilla y

pulpa.sem: relación peso de la pulpa-peso de la semilla



```
> round(cor(Celtis),3)
             diam      az   pulpa     sem pulpa.sem
diam        1.000 -0.330   0.993   0.450     0.560
az         -0.330  1.000  -0.373   0.200    -0.494
pulpa       0.993 -0.373   1.000   0.342     0.645
sem         0.450  0.200   0.342   1.000    -0.430
pulpa.sem   0.560 -0.494   0.645  -0.430     1.000
```

Matriz de correlación de Pearson

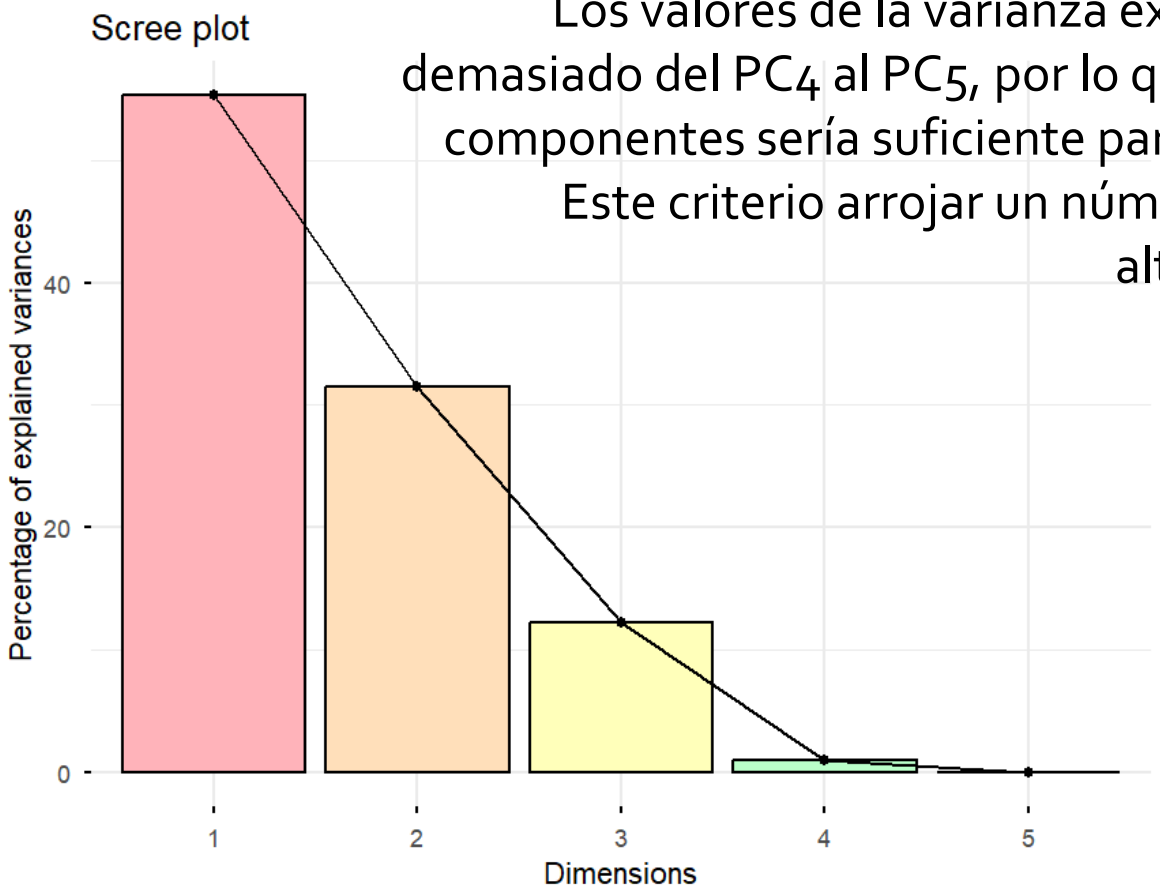
Para realizar el PCA usaremos la función PCA() del paquete FactoMineR aplicado a las variables estandarizadas

```
library(FactoMineR)
pca <- PCA(Celtis, scale.unit = TRUE)
round(pca$eig,2)
```

```
> round(pca$eig,2)
       eigenvalue percentage of variance cumulative percentage of variance
comp 1       2.76                 55.30                               55.30
comp 2       1.58                 31.54                               86.84
comp 3       0.61                 12.19                               99.02
comp 4       0.05                  0.98                              100.00
comp 5       0.00                  0.00                              100.00
```

Número de componentes y variación total:
Hay tantos componentes como variables, y juntos explican el **100% de la variación** en los datos.
Criterio de Kaiser-Guttman:
Un componente principal se considera relevante si su **eigenvalor > 1,** porque explica más variación que una sola variable original.
Las 2 primeras componentes explican ~87% de la variación total, lo que permite resumir los datos sin perder demasiada información.

Gráfico de sedimentación (*scree plot*),



El punto donde se produce una estabilización de la varianza explicada ("codo") indica el número de componentes que se deben retener.
Los valores de la varianza explicada no cambian demasiado del PC_4 al PC_5, por lo que utilizando cuatro componentes sería suficiente para su interpretación.
Este criterio arrojar un número irracionalmente alto de componentes.

el PC1 (Dim.1) tiene una asociación fuerte y positiva con el diámetro, el peso de la pulpa y la relación peso de la pulpa-peso de la semilla, y, en menor medida, una asociación negativa con la concentración de azúcar. Esto es consistente con el análisis de la matriz de correlación.

```
> round(pca$var$coord,3)
            Dim.1  Dim.2  Dim.3  Dim.4  Dim.5
diam        0.939  0.328  0.085 -0.063 -0.002
az         -0.575  0.465  0.673 -0.004  0.000
pulpa       0.965  0.220  0.117 -0.082  0.002
sem         0.174  0.953 -0.213  0.127  0.000
pulpa.sem   0.769 -0.544  0.300  0.148  0.000
```

Loadings (coeficiente de correlación entre una variable y su respectivo componente principal)

VARIABLES: contribución a las componentes

```
> round(pca$var$cos2, 3)
           Dim.1 Dim.2 Dim.3 Dim.4 Dim.5
diam       0.881 0.108 0.007 0.004     0
az         0.331 0.217 0.453 0.000     0
pulpa      0.931 0.049 0.014 0.007     0
sem        0.030 0.908 0.046 0.016     0
pulpa.sem  0.592 0.296 0.090 0.022     0
```

TOTAL (λ_j) 2.765 1.578 0.610 0.049 0.000

```
> round(pca$var$contrib, 3)
            Dim.1  Dim.2  Dim.3  Dim.4  Dim.5
diam       31.874  6.823  1.184  7.998 52.120
az         11.966 13.736 74.271  0.027  0.000
pulpa      33.667  3.080  2.258 13.924 47.071
sem         1.093 57.587  7.471 33.040  0.809
pulpa.sem  21.400 18.774 14.817 45.010  0.000
```

TOTAL 100.000 100.000 100.000 100.000 100.000

Si sumamos los cuadrados de los cosenos para todas las variables en un componente j (Dim.j), obtenemos:

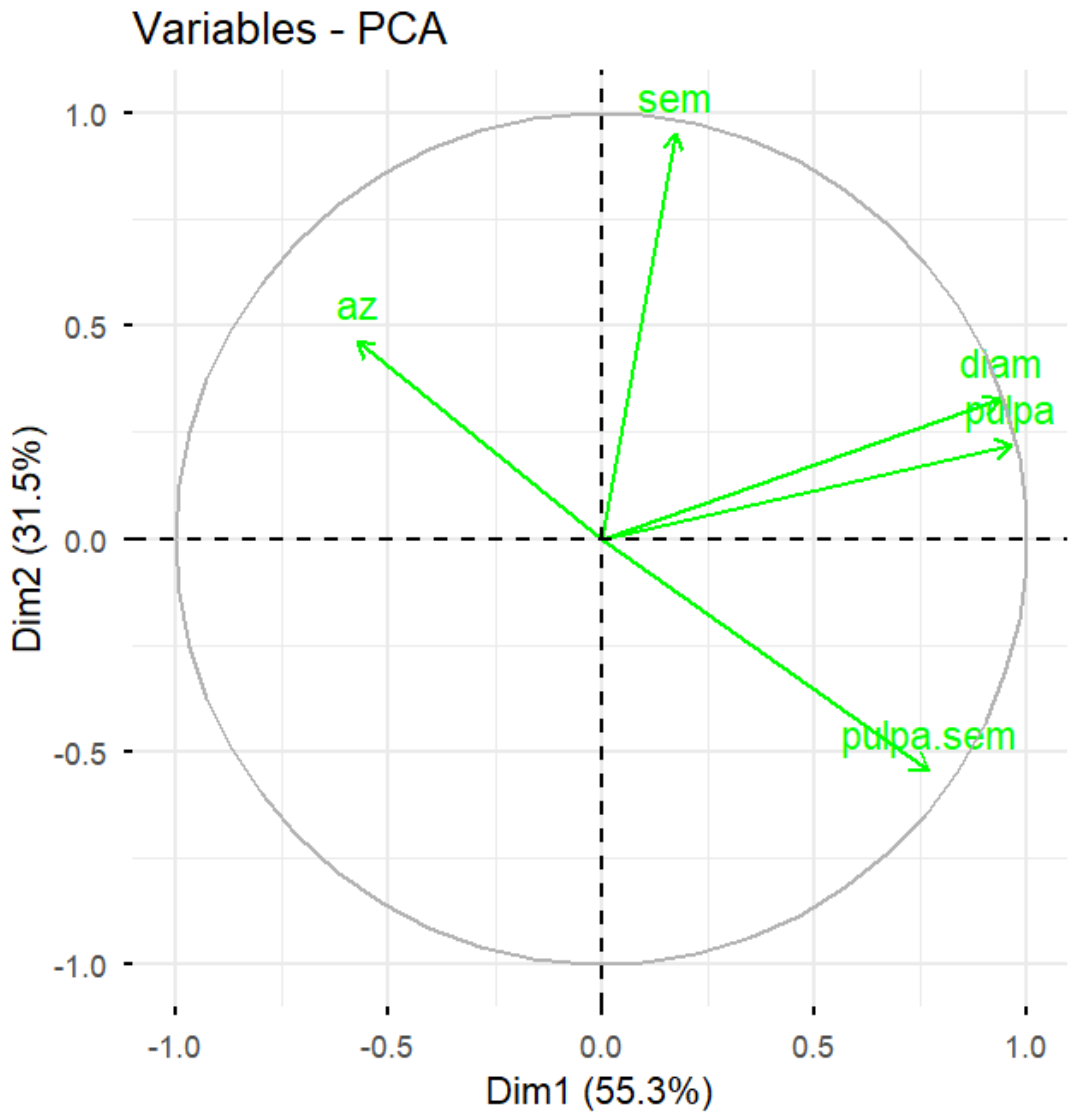
$$\sum_{i=1}^{p} \cos_{ij}^2 = \lambda_j$$

donde λ_j es el **autovalor** del componente j.

El porcentaje de contribución de la variable diámetro a la PC1 (Dim.1) 31.874.

$$31.874 = \frac{\overset{cos^2}{0{,}881 \times 100}}{\underset{\lambda_j}{2.765}}$$

CIRCULO de CORRELACIÓN




```
> round(pca$var$coord,3)
             Dim.1  Dim.2
diam         0.939  0.328
az          -0.575  0.465
pulpa        0.965  0.220
sem          0.174  0.953
pulpa.sem    0.769 -0.544
```

Las variables **diámetro y peso de la pulpa** son las mejor representadas y que más contribuyen al PC1,

El **peso de la semilla** es la más pobremente representada en el PC1 y contribuye más al PC2.

Pulpa semilla y az son vectores diametralmente opuestos indican una alta correlación negative.

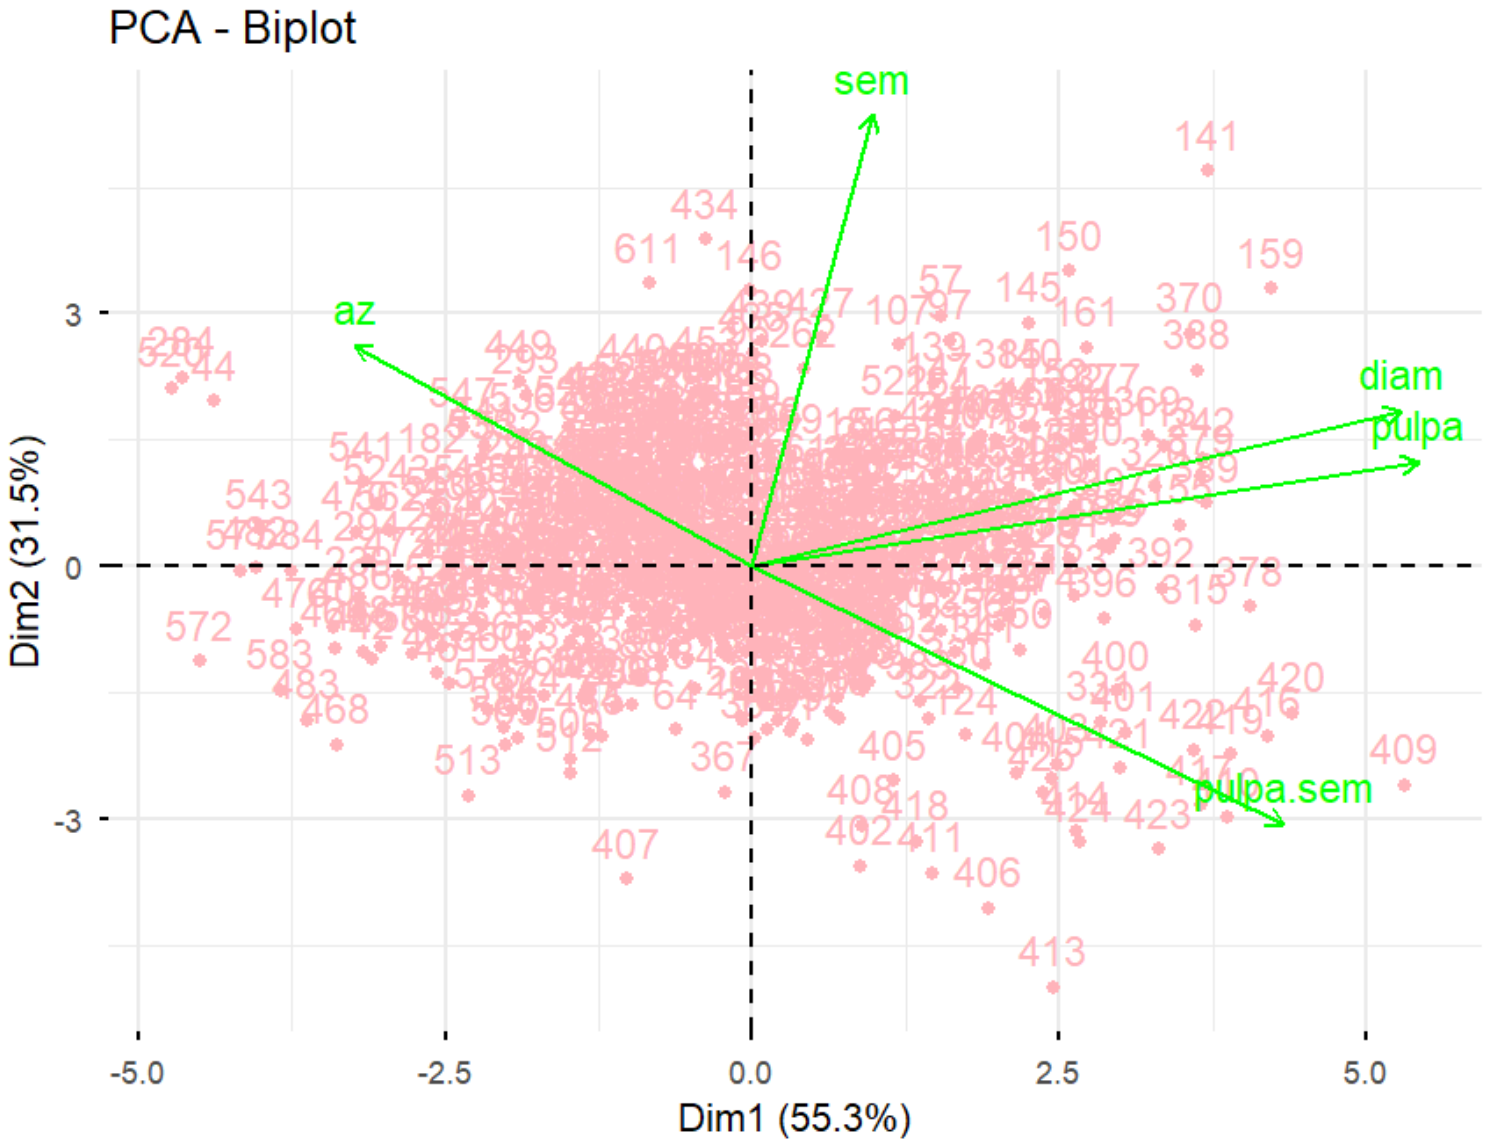
Tamaño Semilla y pulpa_sem vectores aproximadamente perpendiculares indican una correlación nula

INDIVIDUOS

```
> pca$ind$cos2[1:10,]
          Dim.1      Dim.2        Dim.3        Dim.4        Dim.5
1  0.818303025 0.01657493 0.1598106036 5.307150e-03 4.286583e-06
2  0.222149967 0.75385170 0.0146741045 9.322308e-03 1.918324e-06
3  0.443692245 0.10546745 0.4505278686 3.054617e-04 6.972661e-06
4  0.080215250 0.91778547 0.0003659218 1.624963e-03 8.391418e-06
5  0.296186991 0.11586293 0.5879469728 1.531659e-06 1.570317e-06
6  0.339771202 0.39884137 0.2518325113 9.545898e-03 9.017193e-06
7  0.784044370 0.15538358 0.0014983983 5.894533e-02 1.283162e-04
8  0.004087016 0.90092213 0.0893679052 5.616216e-03 6.733705e-06
9  0.517971140 0.23380817 0.2456546682 2.565106e-03 9.148400e-07
10 0.061273927 0.52298789 0.4106857442 5.050238e-03 2.201655e-06
```

```
> pca$ind$contrib[1:10,]
           Dim.1       Dim.2        Dim.3        Dim.4      Dim.5
1  0.1214058105 0.004311596 1.075920e-01 0.0445634801 0.35813117
2  0.0110283922 0.065616463 3.305725e-03 0.0261927910 0.05362823
3  0.0514627186 0.021448172 2.371274e-01 0.0020052110 0.45542300
4  0.0014674162 0.029437336 3.037623e-05 0.0016824116 0.08644448
5  0.1022567918 0.070134492 9.211144e-01 0.0000299282 0.30529445
6  0.0245875181 0.050604516 8.269688e-02 0.0390964492 0.36745573
7  0.0045827283 0.001592390 3.974294e-05 0.0194995806 0.42234790
8  0.0002740117 0.105903668 2.718902e-02 0.0213107622 0.25422741
9  0.0557541296 0.044125751 1.199902e-01 0.0156267677 0.05545263
10 0.0041268384 0.061758157 1.255164e-01 0.0192506779 0.08350192
```

BIPLOT PC1 Y PC2



- Las **UE** se muestran en rosa.
- Los números son etiquetas que coinciden con el orden ,
- Las flechas corresponden a las **variables** (representadas como vectores).
- La **posición** de cada UE (fruto) en el espacio de componentes principales está dada por sus coordenadas, denominadas *scores*.

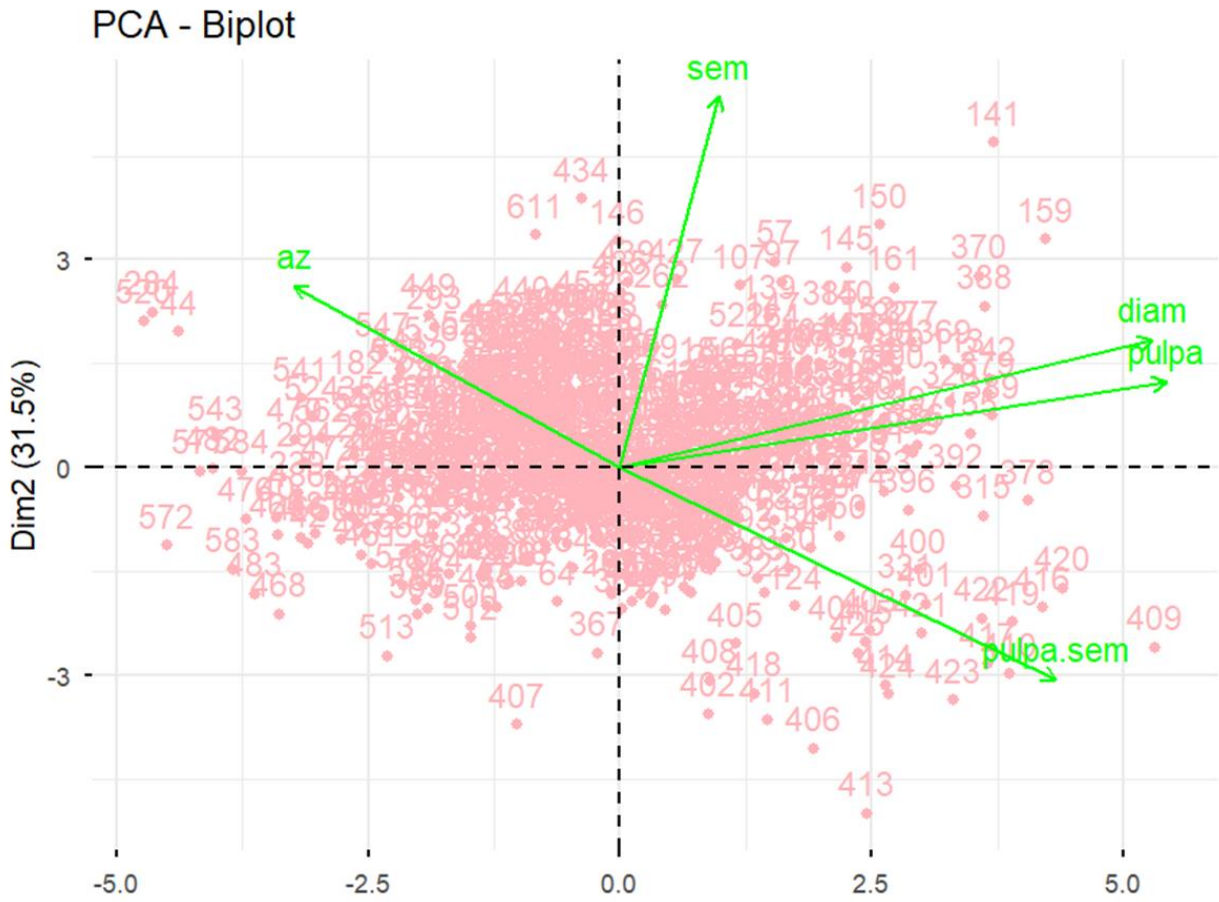
REGLAS DE INTERPRETACIÓN DE UN *biplot*

(1) las UE cercanas en el espacio tienen características similares en cuanto a sus variables;

(2) el coseno del ángulo entre dos vectores corresponde a su correlación. Por lo tanto, vectores cercanos indican una alta correlación positiva, vectores diametralmente opuestos indican una alta correlación negativa, y vectores perpendiculares indican una correlación nula;

(3) el coseno del ángulo entre un vector y un componente principal corresponde a su correlación;

(4) una UE en la dirección y sentido de una variable y alejada del centro de origen tiene un valor alto para esa variable.

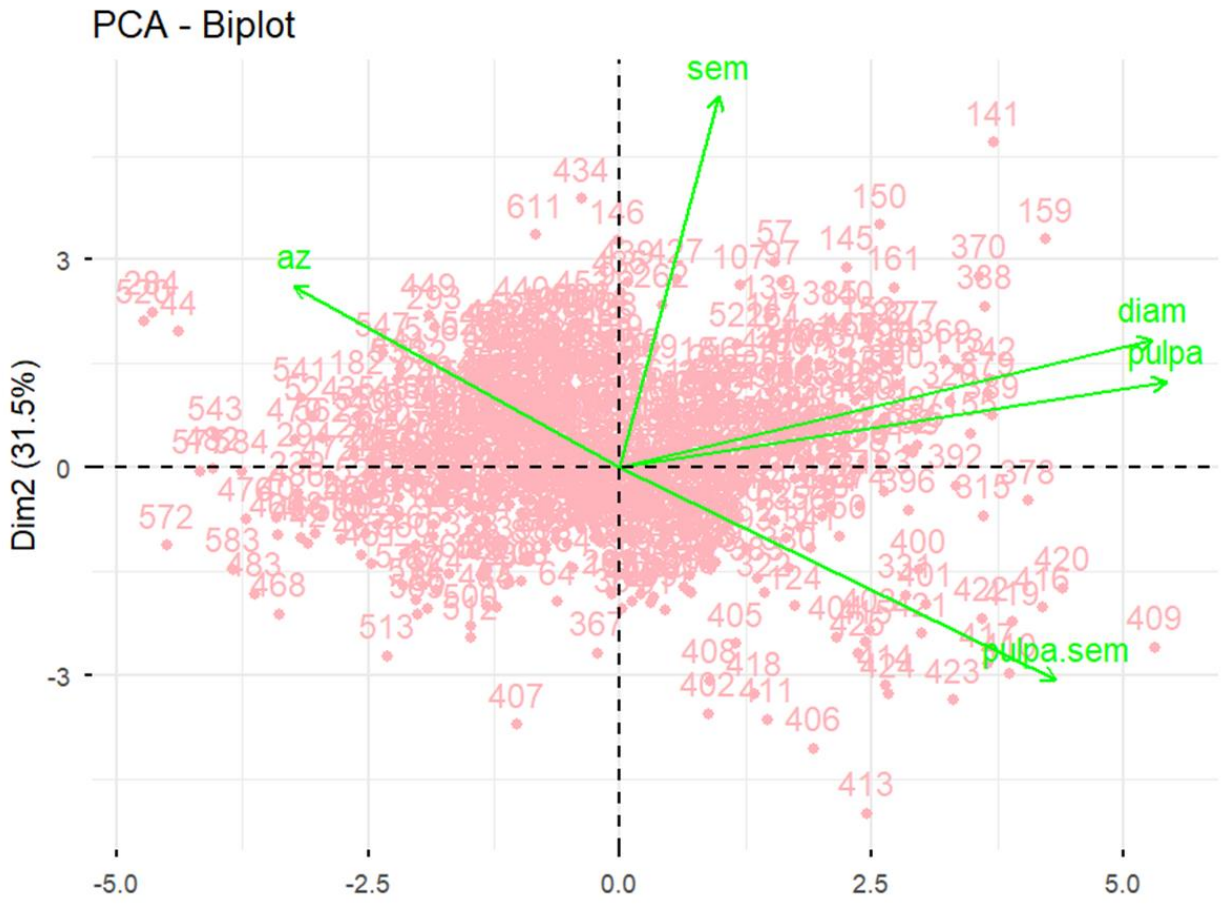


REGLAS DE INTERPRETACIÓN DE UN *biplot*

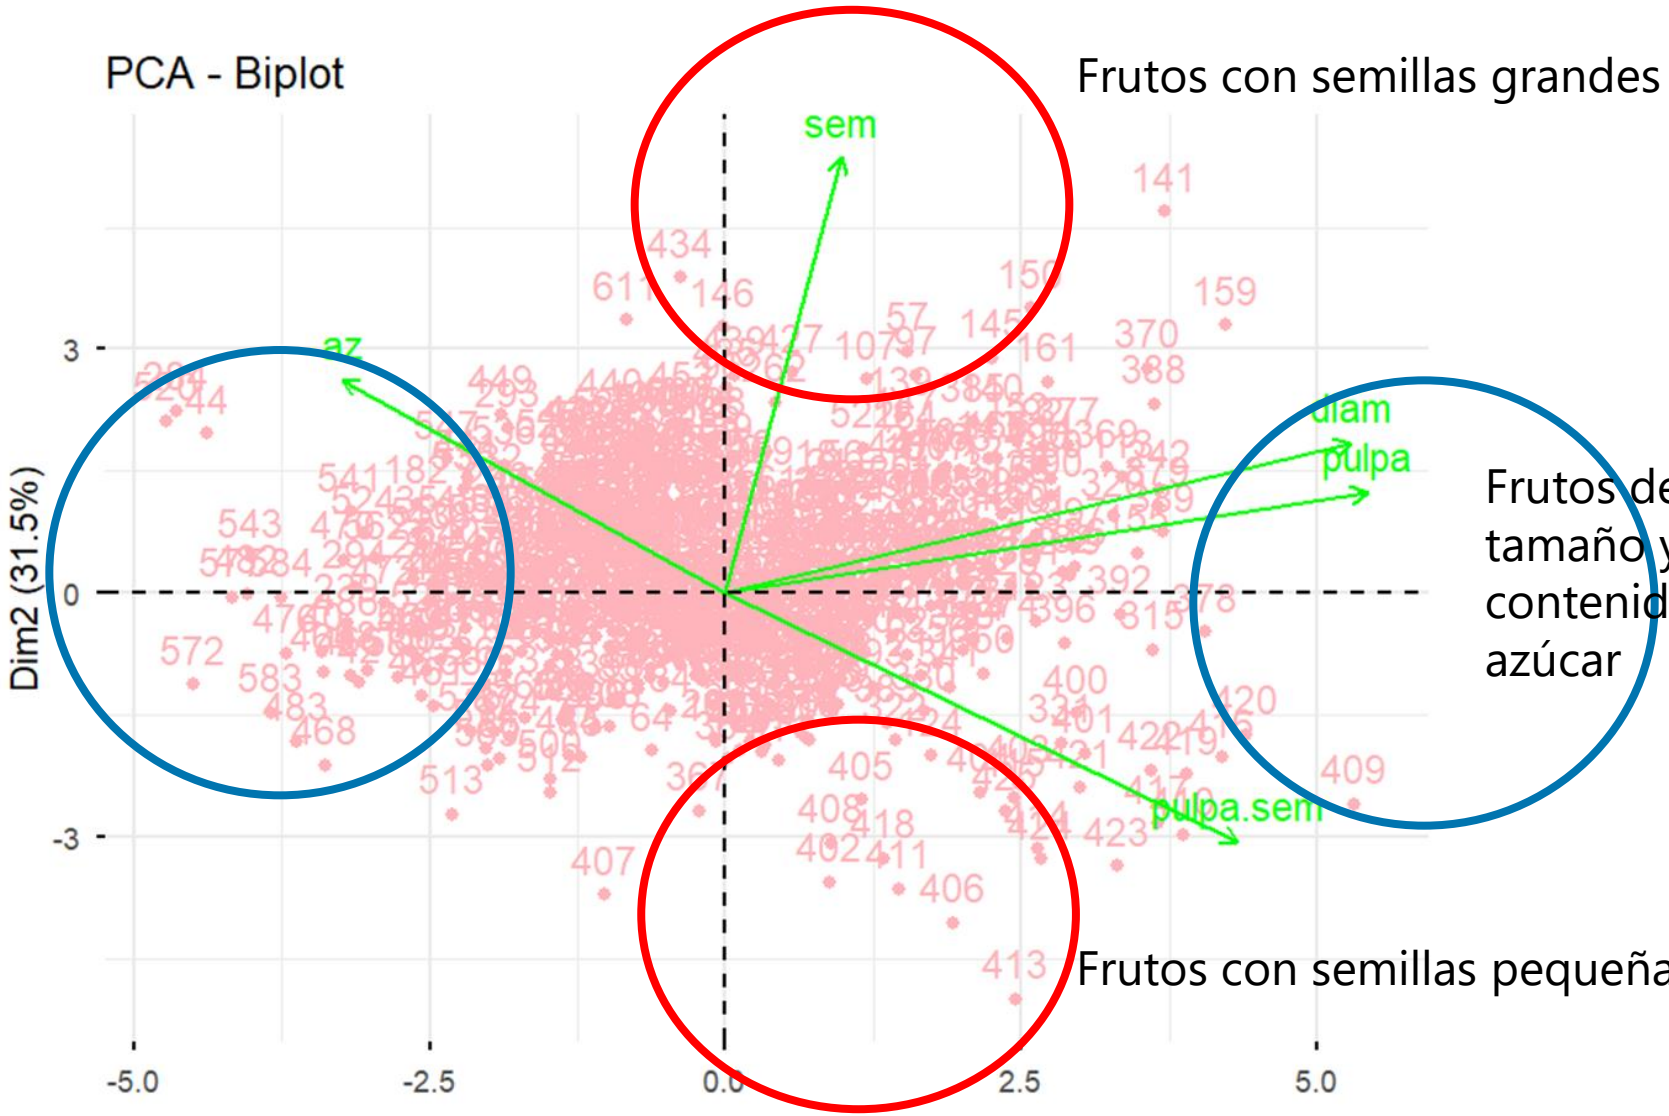
El diámetro del fruto y el **peso de la pulpa** se encuentran muy correlacionados entre sí y de forma positiva, mientras que ambos se encuentran levemente correlacionados y de forma negativa con la concentración de **azúcar.**

Son las variables que se encuentran **más correlacionadas con el PC1** y también las que más contribuyen a este componente,

El **peso de la semilla** se encuentra casi paralelo al PC2, y es también la que más contribuye a este último.



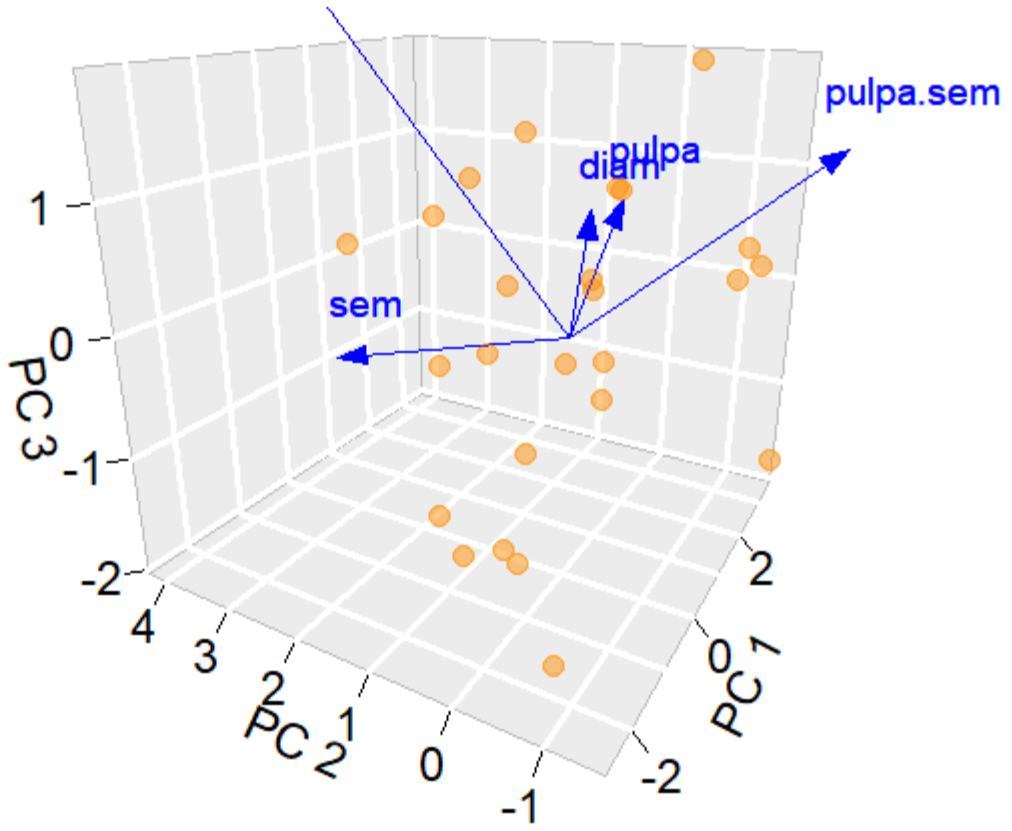
Frutos pequeños y con alto contenido de azúcar



Frutos con semillas grandes

Frutos de gran tamaño y bajo contenido de azúcar

Frutos con semillas pequeñas



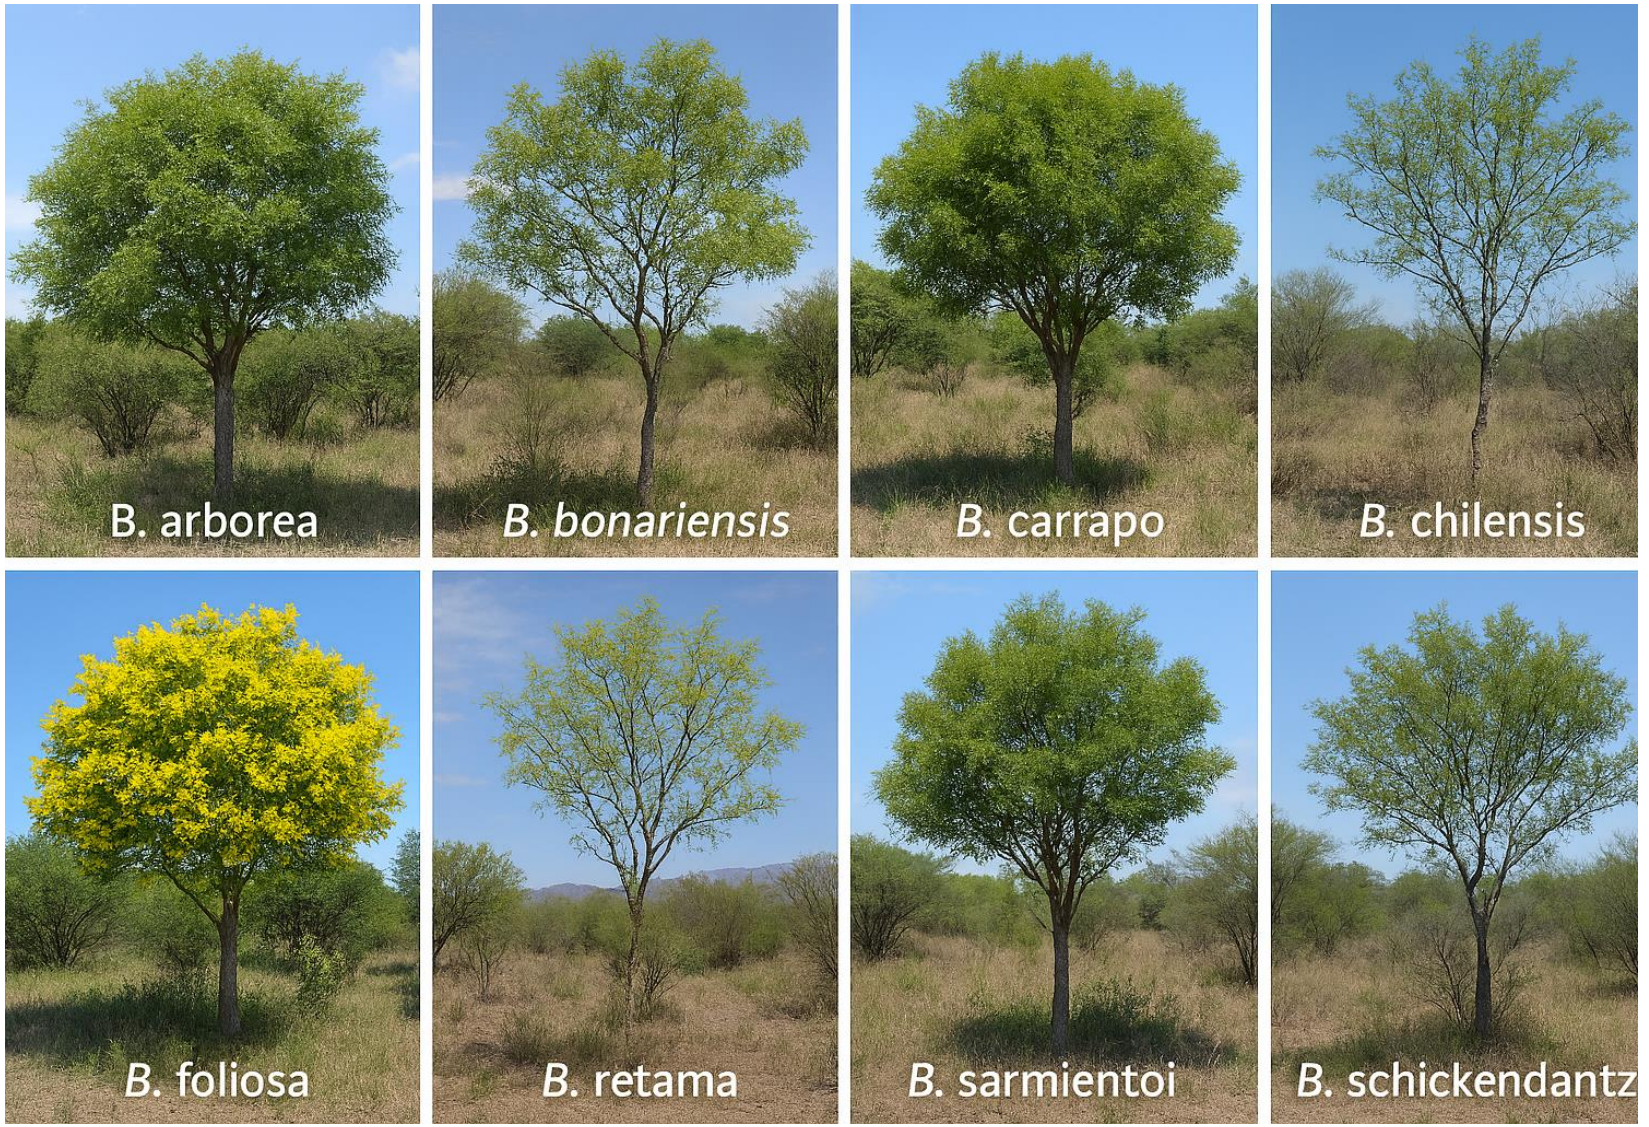
Neal Creative ©

eative | **Más información**

Ejemplo 2

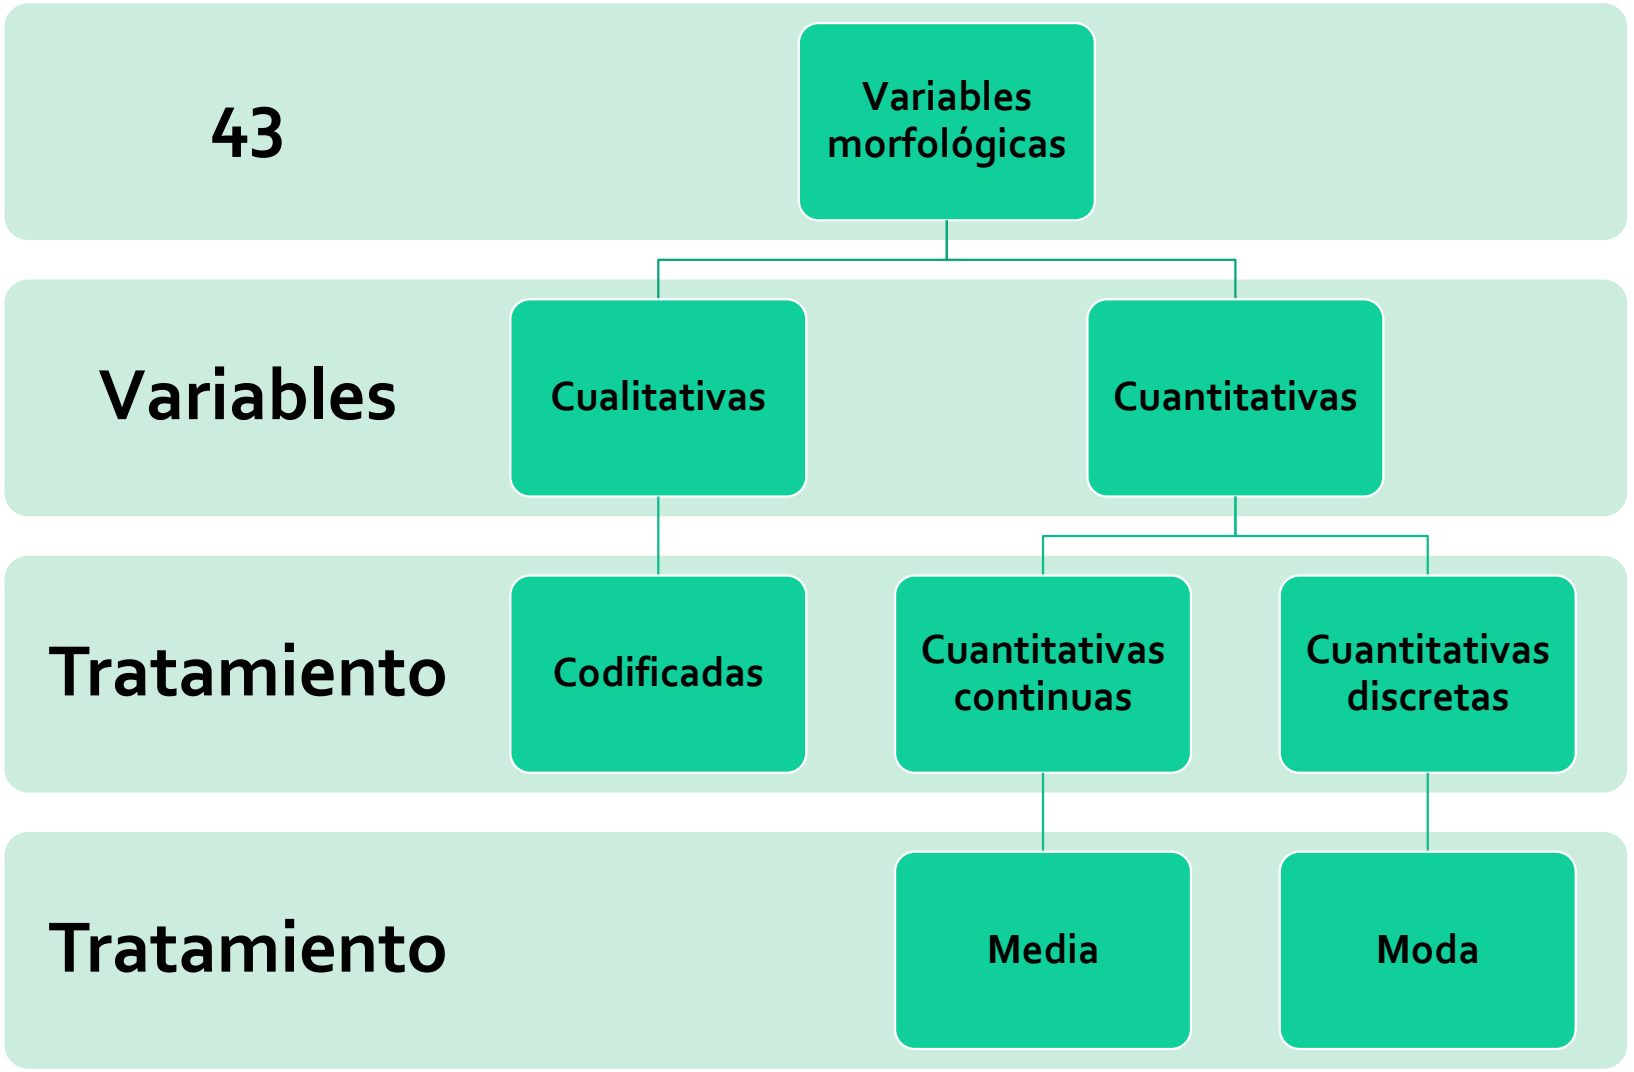
ESTUDIO DE CASO: ANÁLISIS MULTIVARIADO DEL GÉNERO BULNESIA (ZYGOPHYLLACEAE)

Las ocho especies del género *Bulnesia* representan las UE



https://fundacionazara.org.ar/analisis-multivariado-para-datos-biologicos/

Descripción de datos



Las variables que presentan guiones corresponden a variables cuantitativas y no requieren codificación.

Variable	Estados	Codificación
1. Hábito	Arbustos	0
	Arbustos y árboles	1
	Árboles	2
2. Longitud del internodio (cm)	-	-
3. Diámetro del internodio (cm)	-	-
4. Longitud de la hoja (cm)	-	-
5. Ancho de la hoja (cm)	-	-
6. Longitud del peciolo (cm)	-	-
7. Número de folíolos	-	-
8. Presencia de peciólulos	Folíolos no sésiles	0
	Folíolos sésiles o no sésiles	1
	Folíolos sésiles	2
9. Disposición de los folíolos en el raquis	Folíolos alternos	0
	Folíolos subopuestos	1
	Folíolos opuestos	2
10. Pubescencia de la hoja	Ausente	0
	Ausente y presente	1
	Presente	2

Las variables que presentan guiones corresponden a variables cuantitativas y no requieren codificación.

11. Longitud del folíolo (mm)	-	-
12. Ancho del folíolo (mm)	-	-
13. Número de nervaduras primarias del folíolo	-	-
14. Posición de los folíolos terminales	Paralelos	0
	Paralelos y divergentes	1
	Divergentes	2
15. Presencia de mucrón en folíolos	Folíolos no mucronados	0
	Folíolos mucronados	1
16. Tipo de inflorescencia	Flores solitarias	1
	Inflorescencia en dicasio	2
17. Longitud del pedúnculo (mm)	-	-
18. Longitud del sépalo (mm)	-	-
19. Ancho del sépalo (mm)	-	-

Las variables que presentan guiones corresponden a variables cuantitativas y no requieren codificación.

Variable	Estados	Codificación
20. Color de los pétalos	Blanco	1
	Amarillo	2
21. Longitud del pétalo (mm)	-	-
22. Ancho del pétalo (mm)	-	-
23. Número de nervaduras del pétalo	-	-
24. Tipo de estambres	Heterogéneos	0
	Heterogéneos y homogéneos	1
	Homogéneos	2
25. Modificación de los estambres	No modificados	0
	Modificados y no modificados	1
	Modificados	2
26. Presencia de gran escama junto al estambre	Ausente	0
	Ausente y presente	1
	Presente	2
27. Presencia de pelos en la base del filamento estaminal	Sin pelos	0
	Con o sin pelos	1
	Con pelos	2
28. Presencia de una escama suplementaria junto al estambre	Ausente	0
	Presente	1
29. Agrupación de los estambres	No agrupados	0
	Agrupados o no agrupados	1
	Agrupados	2

Las variables que presentan guiones corresponden a variables cuantitativas y no requieren codificación.

30. Longitud del filamento (mm)	-	-
31. Longitud de la antera (mm)	-	-
32. Longitud de la escama (mm)	-	-
33. Presencia de ápice laciniado en la escama estaminal	Sin ápice laciniado	0
	Con o sin ápice laciniado	1
	Con ápice laciniado	2
34. Número de carpelos	En número de 3	0
	En número de 3 y 5	1
	En número de 5	2
35. Curvatura del estilo	Estilo no curvado	0
	Estilo curvado o no curvado	1
	Estilo curvado	2
36. Número de óvulos por carpelo	-	-
37. Pubescencia del fruto	Glabro	0
	Pubescente	1
38. Longitud del fruto (mm)	-	-
39. Ancho del fruto (mm)	-	-
40. Desarrollo del carpóforo	Reducido	1
	Bien desarrollado	2
41. Longitud del carpóforo (mm)	-	-
42. Forma de la semilla	Semicircular o semielíptica	1
	Oblongo-reniforme	2
43. Longitud de la semilla (mm)	-	-

Veamos alguna variable

Variables cualitativas

Hábito







Arbusto	Arbusto y árbol	Árbol
0	1	2

Los datos obtenidos se presentan en forma de una matriz

Variables (p)

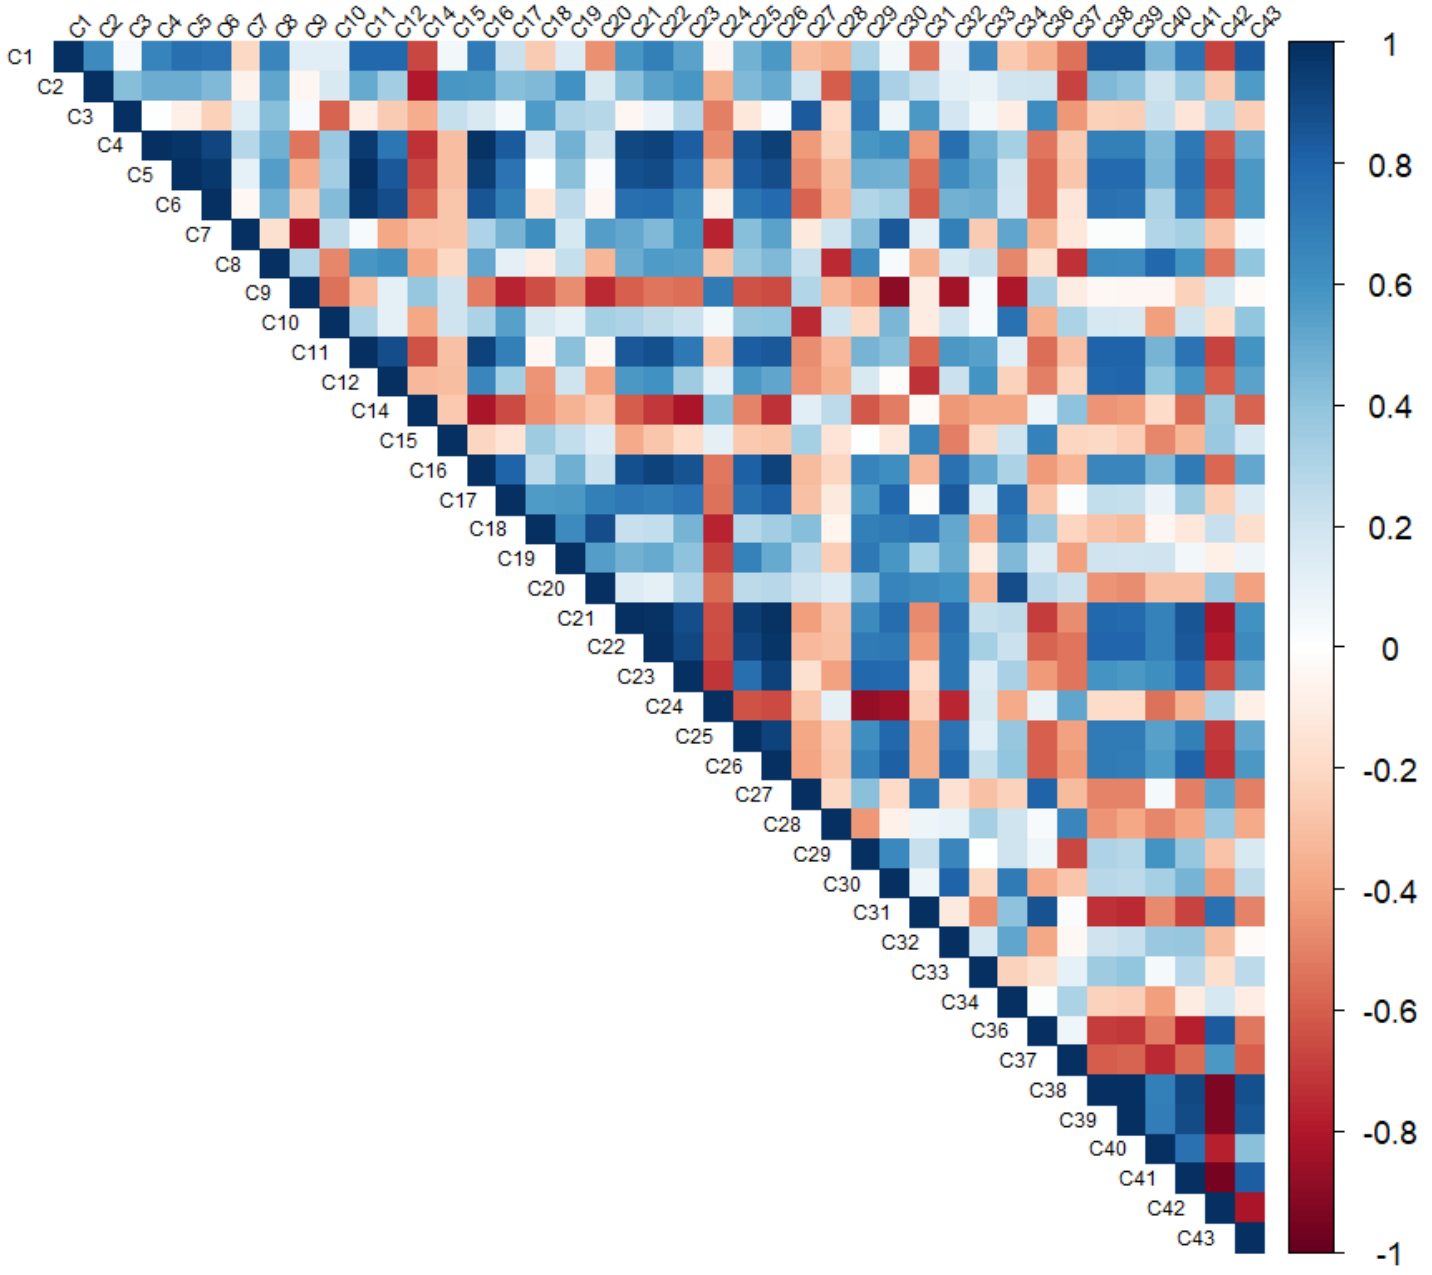
U

(n)

Especie	C1	C2	C3	C4	C5	C6	C7	C8	C9	C10	C11	C12	C13	C14	C15	C16	C17	C18	C19	C20	C21
B. arborea	2	35	2,1	85	57	7,7	13	2	0	2	30	8,6	6	0	1	2	17	7,1	3,4	2	22
B. carrapo	2	36	1,6	97	71	9	7	2	0	2	40	16	6	1	1	2	18	6,4	5,8	2	24
B. chilensis	0	24	2,6	14	8,9	1,8	8	2	1	0	5,2	2,4	NA	2	1	1	9	7,1	4,2	2	9,8
B. bonariensis	0	20	1,3	26	18	3,4	14	1	0	2	8,9	2	1	2	1	1	12	6,8	3,9	2	18
B. retama	1	40	2	13	11	3,1	5	1	1	2	6,6	2,6	2	1	2	1	10	7,4	4,4	2	7,7
B. foliosa	0	19	1,3	28	25	5,8	4	1	1	2	14	7,8	3	2	1	1	13	5,3	3	2	8,5
B. schicklendantzii	0	10	1,9	20	12	2,7	10	0	0	2	5,7	1,9	1	2	1	1	10	5,9	3,1	2	9,3
B. sarmientoi	2	22	1,4	21	27	5,1	2	2	2	1	17	12	5	2	1	1	3,9	2,9	2,3	1	12

Especie	C22	C23	C24	C25	C26	C27	C28	C29	C30	C31	C32	C33	C34	C35	C36	C37	C38	C39	C40	C41	C42	C43
B. arborea	17	16	0	1	2	0	1	2	10	1,5	5,2	2	2	1	2	1	46	41	2	7,7	1	13
B. carrapo	19	12	0	2	2	0	1	2	9,9	1,4	53	2	2	2	2	1	56	52	2	5,3	1	12
B. chilensis	5,7	8	0	0	0	2	1	2	7	2	4,4	1	1	NA	7	1	13	12	2	0,6	2	2,7
B. bonariensis	10	10	0	1	1	0	1	1	11	1,6	4,4	0	2	2	1	1	36	33	2	4,8	1	11
B. retama	4,6	7	1	0	0	1	1	1	7,1	2,2	3,1	1	2	1	8	1	23	19	1	0,8	2	11
B. foliosa	2,7	6	2	0	0	0	1	0	6,2	1,6	3,9	1	2	1	4	2	16	13	1	0,7	2	4,9
B. schicklendantzii	4,3	5	1	0	0	0	2	0	7,4	1,7	4,4	2	2	1	4	2	12	13	1	0,4	2	5,3
B. sarmientoi	7	6	2	0	0	0	1	0	4,1	1,1	2,9	2	0	0	2	1	52	48	2	5,2	1	14

1) Elimina NA, quito 2 columnas.
2) Estandarizo
3) Calculo la matriz de correlación de Pearson



En un análisis de componentes principales (PCA), el N° máximo de componentes

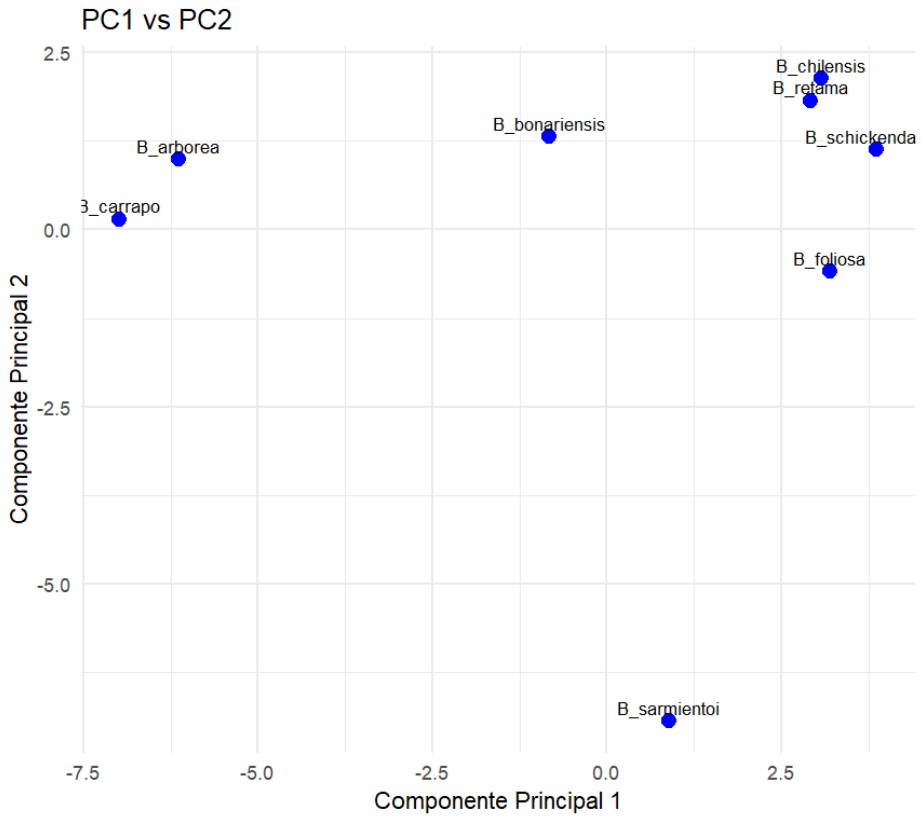
el **número máximo de componentes** que se pueden extraer está limitado por:

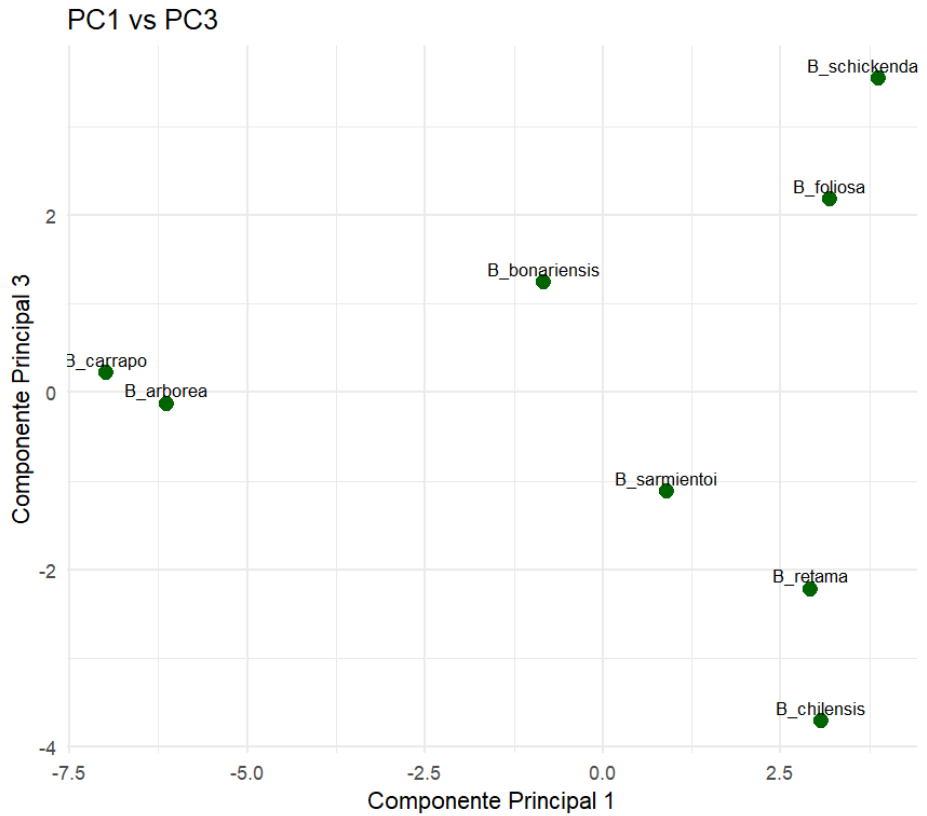
$$número\ máximo\ de\ componentes = \min(número\ de\ observaciones - 1, número\ de\ variables)$$

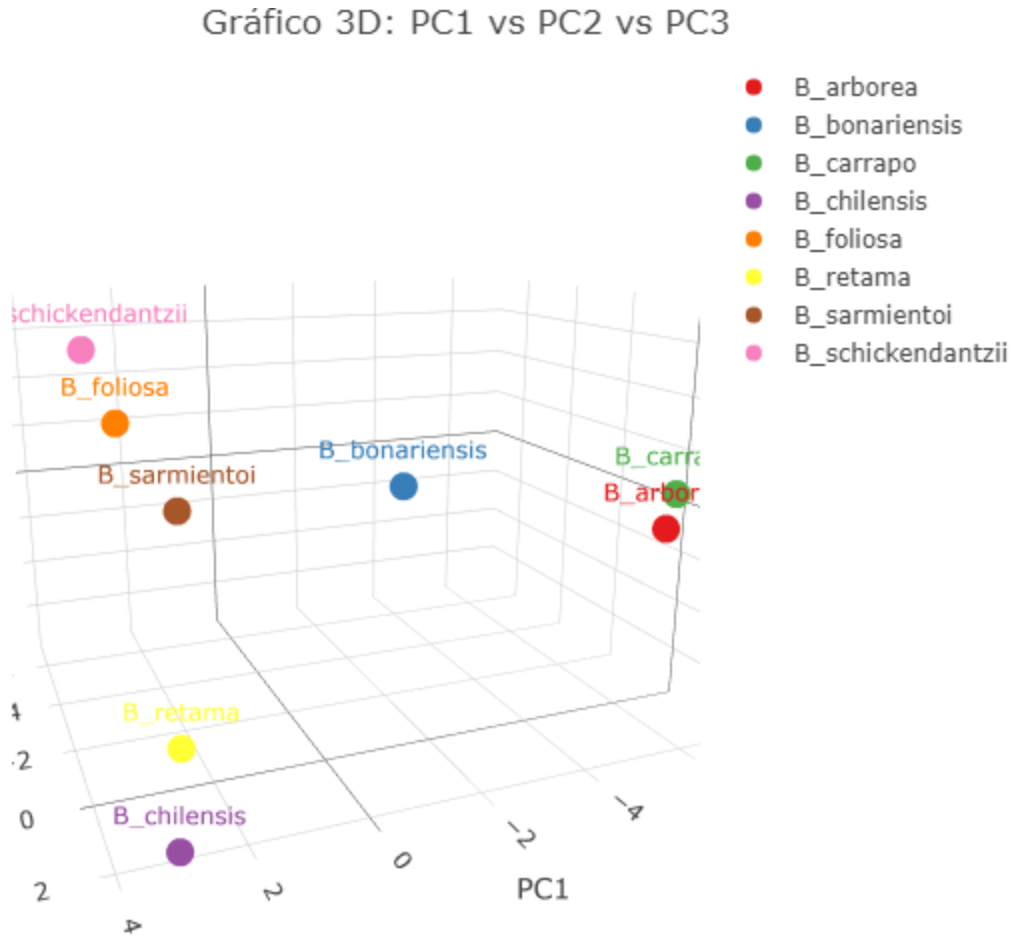
Esto se debe a que la matriz de covarianza/correlación tiene rango máximo igual a $.\min(n-1, p)$.

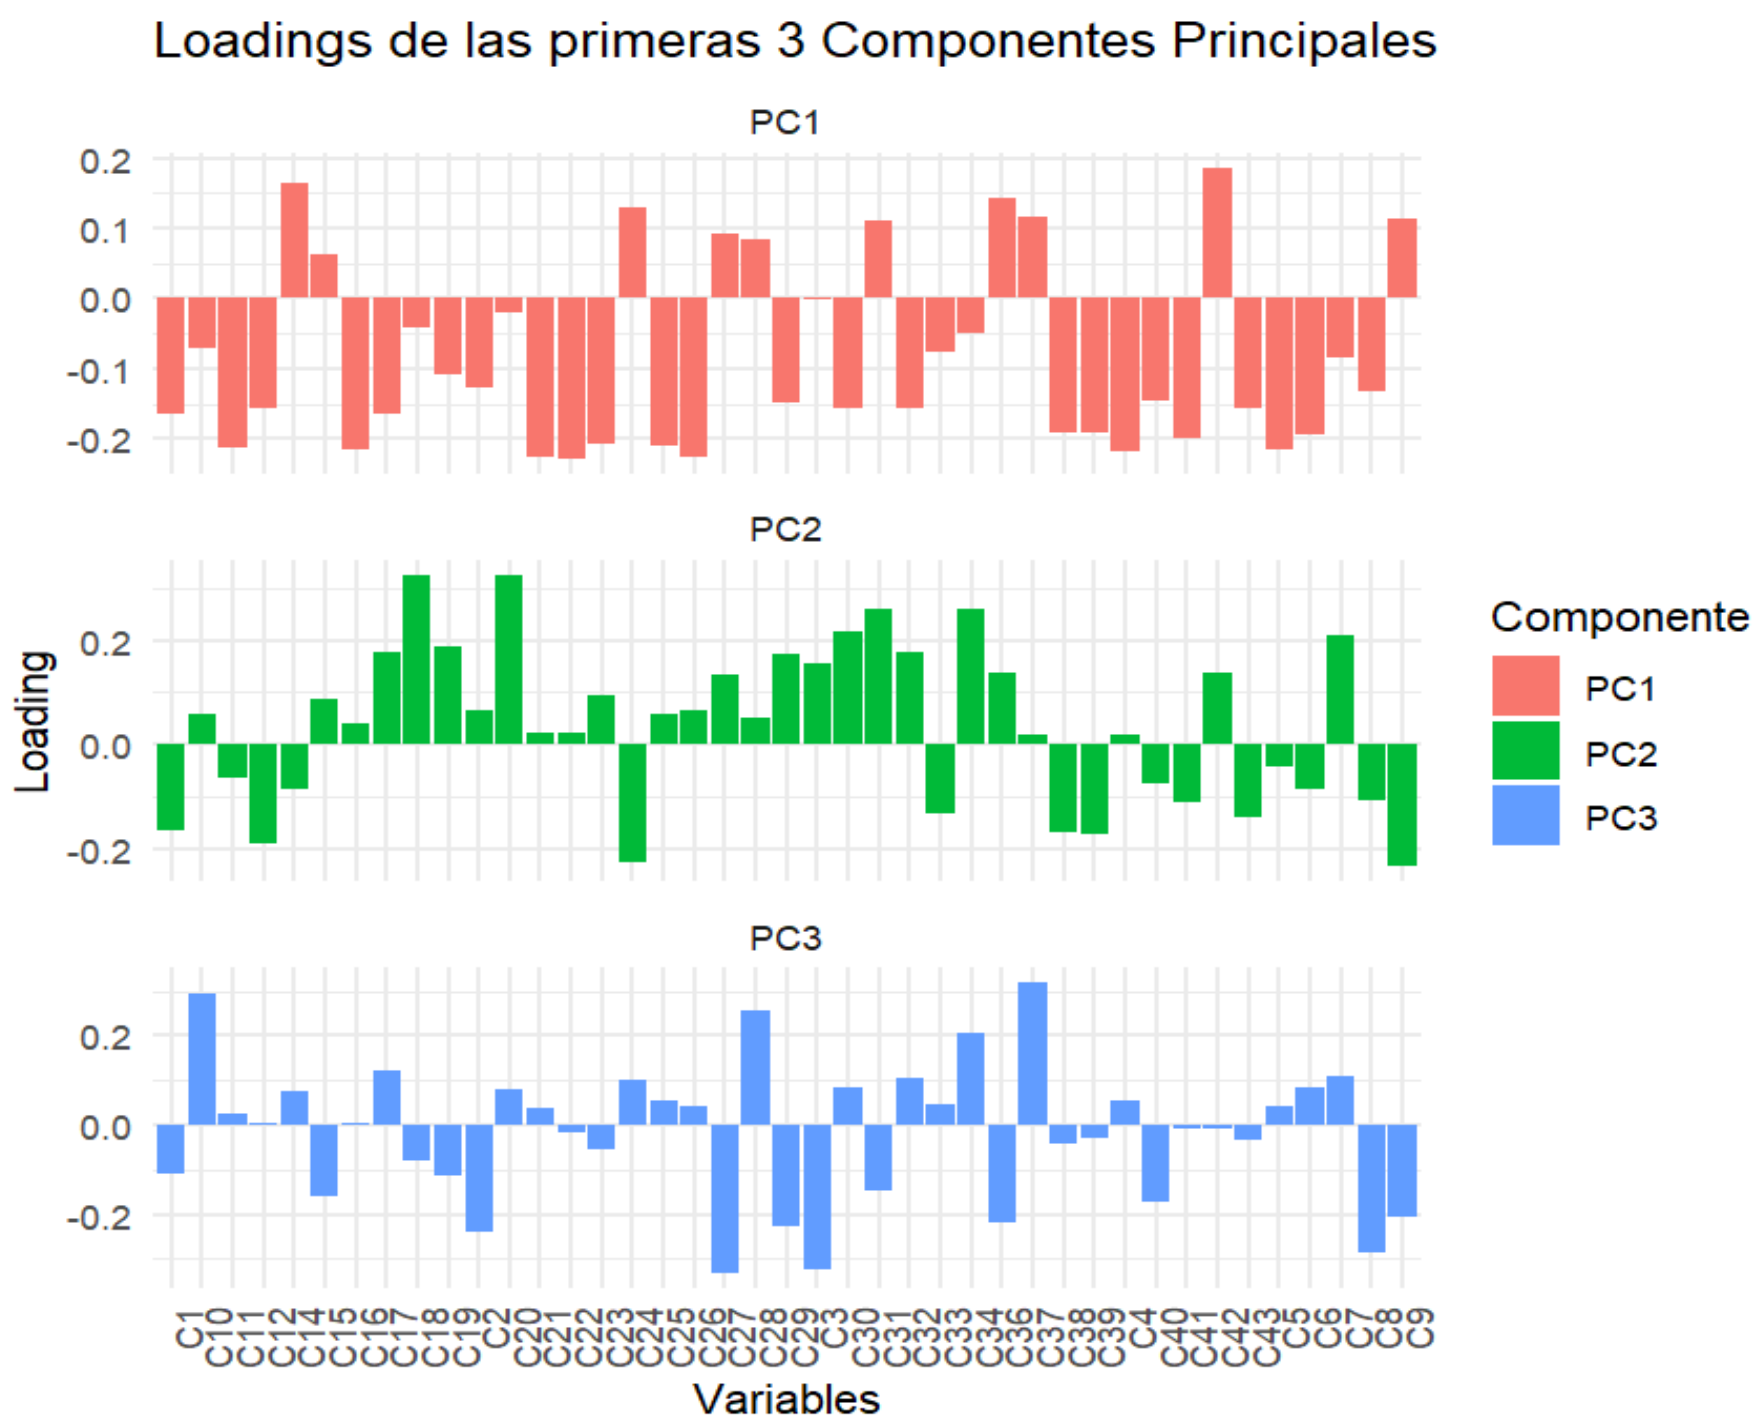
Componentes principales, sus eigenvalores (λ_i), el porcentaje de variación explicada por cada componente y el porcentaje acumulado.

Componente	Eigenvalor	Varianza.Explicada	Varianza.Acumulada
1	18.7308	45.68	45.68
2	8.6200	21.02	66.71
3	5.5458	13.53	80.24
4	3.3532	8.18	88.41
5	2.3930	5.84	94.25
6	1.4453	3.53	97.78
7	0.9119	2.22	100.00


PC1 vs PC2
B_chilensis
B_retama
B_bonariensis
B_schickenda
B_arborea
B_carrapo
B_foliosa
B_sarmientoi
Componente Principal 2
Componente Principal 1
2.5
0.0
-2.5
-5.0
-7.5
-5.0
-2.5
0.0
2.5


PC1 vs PC3
B_schickenda
B_foliosa
B_bonariensis
B_carrapo
B_arborea
B_sarmientoi
B_retama
B_chilensis
Componente Principal 3
Componente Principal 1
2
0
-2
-4
-7.5
-5.0
-2.5
0.0
2.5


Gráfico 3D: PC1 vs PC2 vs PC3
B_arborea
B_bonariensis
B_carrapo
B_chilensis
B_foliosa
B_retama
B_sarmientoi
B_schickendantzii
schickendantzii
B_foliosa
B_sarmientoi
B_bonariensis
B_retama
B_chilensis
PC1


Loadings de las primeras 3 Componentes Principales
PC1
PC2
PC3
0.2
0.1
0.0
-0.1
-0.2
Loading
Componente
PC1
PC2
PC3
C1
C10
C11
C12
C14
C15
C16
C17
C18
C19
C2
C20
C21
C22
C23
C24
C25
C26
C27
C28
C29
C3
C30
C31
C32
C33
C34
C36
C37
C38
C39
C4
C40
C41
C42
C43
C5
C6
C7
C8
C9
Variables

Alimentación

Gracias por escucharme..