ANALISIS INTELIGENTE DE DATOS



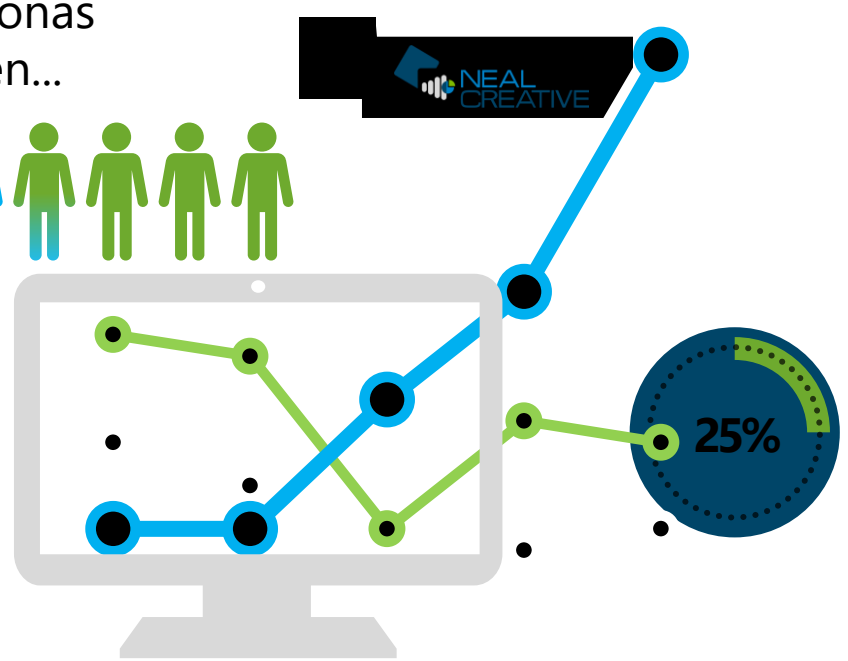
Profesora: Maria Laura Vranic

DATOS

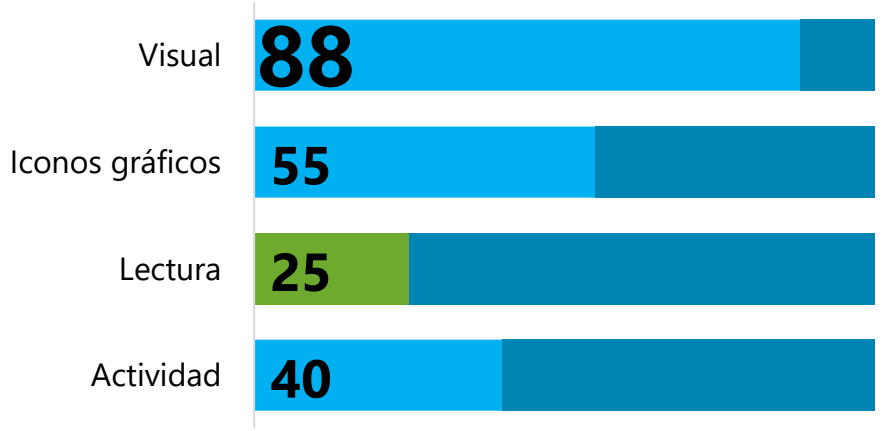
DATOS

6,5 de cada 10 personas
recuerdan lo que ven...





UE	Variables 1	2	3	...	p
1	x_{11}	x_{12}	x_{13}	...	x_{1p}
2	x_{21}	x_{22}	x_{23}	...	x_{2p}
3	x_{31}	x_{32}	x_{33}	...	x_{3p}
⋮	⋮	⋮	⋮	⋱	⋮
n	x_{n1}	x_{n2}	x_{n3}	...	x_{np}



ESTUDIOS

OBSERVACIONALES

surgen como resultado de un proceso de observación, el investigador **observa** y **recoge datos** sin intervenir directamente en el proceso que está estudiando.



EXPERIMENTALES

son el resultado de la provocación de un fenómeno, o experimento, bajo condiciones controladas



ESTUDIOS



OBSERVACIONALES

- La información registrada en un **proceso de observación** es tratada, en un primer momento, con el objetivo de describir y resumir sus características más sobresalientes.
- Esto se conoce como estadística descriptiva y generalmente se basa en el uso de tablas y gráficos, y en la obtención de medidas resumen.



EXPERIMENTALES

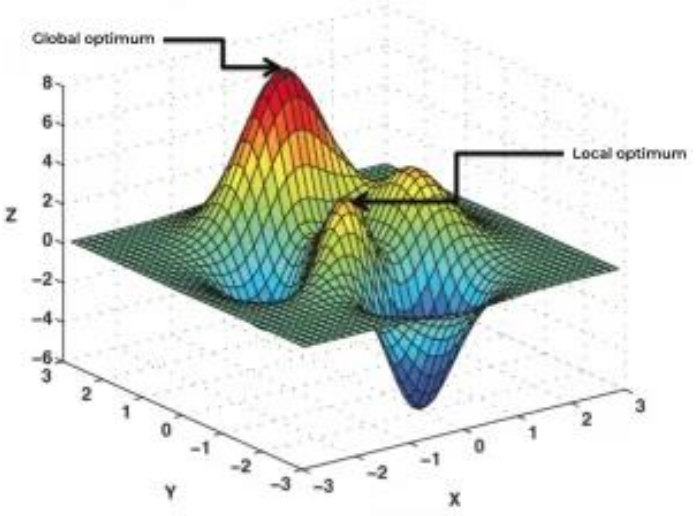
- es un tipo de investigación en el que **el investigador interviene activamente** en el proceso que está estudiando.
- Su objetivo principal es **establecer relaciones causales entre variables**, es decir, demostrar que una variable (por ejemplo, un tratamiento) causa un efecto en otra (por ejemplo, una mejora en la salud).

ESTUDIOS

OBSERVACIONALES



EXPERIMENTALES



ESTUDIOS

OBSERVACIONALES

- **No hay intervención del investigador**: se limita a observar y registrar lo que ocurre de manera natural.
- **No se manipulan variables**: se estudian asociaciones entre variables tal como se presentan en la realidad.
- Ejemplo: observar si personas que consumen más frutas tienen menor incidencia de enfermedades cardiovasculares.

EXPERIMENTALES

- **Hay intervención: el investigador** manipula una o más variables (por ejemplo, administra un tratamiento).
- **Asignación aleatoria**: los participantes suelen ser asignados aleatoriamente a grupos (por ejemplo, grupo control y grupo experimental).
- **Permiten establecer causalidad**: al controlar las variables, se puede determinar si una causa produce un efecto.
- Ejemplo: dar un suplemento nutricional a un grupo y comparar los resultados con otro grupo que no lo recibe.



PREPARACIÓN de DATOS

MIREMOS LOS DATOS

FUNCIÓN EN PYTHON (PANDAS)	DESCRIPCIÓN	EQUIVALENTE EN R
pd.read_csv("archivo.csv")	Carga datos desde un archivo CSV	read.csv("archivo.csv")
data.head()	Muestra las primeras 5 filas	head(data)
data.tail()	Muestra las últimas 5 filas	tail(data)
data.columns	Lista los nombres de las columnas	colnames(data)
data.shape	Cantidad de filas y columnas	dim(data)
data.dtypes	Tipo de dato por columna	str(data) o sapply(data, class)
data.describe()	Estadísticas descriptivas	summary(data)
data.isnull().sum()	Valores nulos por columna	colSums(is.na(data))
data.info()	Resumen general del DataFrame	str(data)

PREPARACIÓN DE DATOS

1. Datos faltantes
2. Columnas irrelevantes
3. Registros repetidos (filas)
4. Valores extremos (outliers)
5. Errores tipográficos, en el caso de variables categóricas.
6. Datos censurados

1. DATOS FALTANTES

📄 **data.info()**

•Muestra **información general** del DataFrame data.

•Incluye:

- •Número de filas y columnas
- •Nombres de las columnas
- •Tipo de datos de cada columna (int, float, object, etc.)
- •Cantidad de **valores no nulos** por columna
- •Uso de memoria

🔍 **Sirve para detectar rápidamente si hay datos faltantes** y qué tipo de datos hay en cada columna.

🧹 **data.dropna(inplace=True)**

•Elimina **todas las filas** que contengan **al menos un valor faltante (NaN)**.

•El parámetro inplace=True indica que la operación **modifica directamente el DataFrame original**, sin necesidad de reasignarlo.

⚠️ **Advertencia**: puede eliminar muchas filas si hay muchos datos faltantes. Es útil cuando querés trabajar solo con datos completos.

1. DATOS FALTANTES



🧹 **data.dropna(inplace=True) en Python**
Equivalente en R:
data<-na.omit(data) # na.omit(data)

•elimina **todas las filas** que contienen al menos un valor faltante (NA).
•La reasignación (<-) es necesaria porque R no modifica el objeto original a menos que lo indiques.

📋 **data.info() en Python**
Equivalente en R:
str(data) summary(data)

•str(data) muestra la estructura del objeto (tipo de datos, número de observaciones, etc.).
•summary(data) da estadísticas básicas por columna, incluyendo cuántos NA hay.

1. DATOS FALTANTES







1) MECANISMO DETRÁS DE ESA PÉRDIDA DE DATOS

Datos faltantes completamente aleatorios (o *MCAR: Missing Completely at Random*)

Datos Faltantes Aleatorios (o *MAR: Missing at Random*)

Datos Faltantes NO aleatorios (o *MNAR: Missing Not at Random*)

VEAMOS UN EJEMPLO

El Departamento de Pesca y Vida Silvestre de Virginia Tech realizó un estudio para evaluar el efecto de un pesticida organofosforado (OF) sobre la actividad cerebral de ratones silvestres (*Peromyscus leucopus*). Se trabajó con 25 hembras de edad y condiciones similares, distribuidas en 5 grupos de 5 individuos. Cada grupo recibió una dosis distinta del pesticida, excepto uno que actuó como grupo control (sin exposición). Los datos que se obtuvieron son los siguientes:

Animal	Dosis, x (mg/kg de peso corporal)	Actividad, y (moles/litro/min)
1	0.0	10.9
2	0.0	10.6
3	0.0	10.8
4	0.0	9.8
5	0.0	9.0
6	2.3	11.0
7	2.3	11.3
8	2.3	9.9
9	2.3	9.2
10	2.3	10.1
11	4.6	10.6
12	4.6	10.4
13	4.6	8.8
14	4.6	11.1
15	4.6	8.4
16	9.2	9.7
17	9.2	7.8
18	9.2	9.0
19	9.2	8.2
20	9.2	2.3
21	18.4	2.9
22	18.4	2.2
23	18.4	3.4
24	18.4	5.4
25	18.4	8.2

Datos faltantes completamente aleatorios (o *MCAR: Missing Completely at Random*)

Animal	Dosis (mg/kg de p. c.)	Actividad (moles/litro/min)
1	0.0	
2	0.0	10.6
3	0.0	
4	0.0	9.8
5	0.0	9.0
6	2.3	11.0
7	2.3	
8	2.3	9.9
9	2.3	9.2
10	2.3	10.1
11	4.6	10.6
12	4.6	10.4
13	4.6	8.8
14	4.6	11.1
15	4.6	
16	9.2	9.7
17	9.2	7.8
18	9.2	9.0
19	9.2	
20	9.2	2.3
21	18.4	2.9
22	18.4	2.2
23	18.4	3.4
24	18.4	
25	18.4	8.2

Datos Faltantes Aleatorios (o *MAR: Missing at Random*)

Animal	Dosis (mg/kg de p. c.)	Actividad (moles/litro/min)
1	0.0	10.9
2	0.0	10.6
3	0.0	10.8
4	0.0	9.8
5	0.0	9.0
6	2.3	
7	2.3	
8	2.3	9.9
9	2.3	9.2
10	2.3	10.1
11	4.6	10.6
12	4.6	10.4
13	4.6	8.8
14	4.6	
15	4.6	8.4
16	9.2	9.7
17	9.2	7.8
18	9.2	9.0
19	9.2	8.2
20	9.2	2.3
21	18.4	2.9
22	18.4	2.2
23	18.4	3.4
24	18.4	5.4
25	18.4	8.2

Datos Faltantes NO aleatorios (o MNAR: Missing Not at Random)

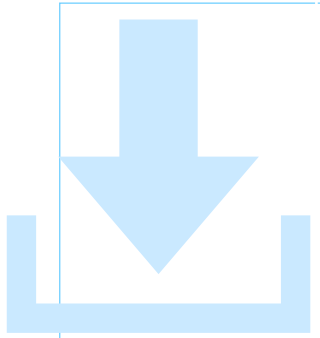
Animal	Dosis (mg/kg de p. c.)	Actividad (moles/litro/min)
1	0.0	10.9
2	0.0	10.6
3	0.0	10.8
4	0.0	9.8
5	0.0	9.0
6	2.3	11.0
7	2.3	11.3
8	2.3	9.9
9	2.3	9.2
10	2.3	10.1
11	4.6	10.6
12	4.6	10.4
13	4.6	8.8
14	4.6	11.1
15	4.6	8.4
16	9.2	9.7
17	9.2	7.8
18	9.2	9.0
19	9.2	8.2
20	9.2	2.3
21	18.4	
22	18.4	
23	18.4	
24	18.4	
25	18.4	



¿CÓMO MANEJAR LOS DATOS FALTANTES?

Descarte

Eliminación de los registros que contengan datos faltantes



Imputación

Estimación del valor del dato faltante usando la información de los registros vecinos o la información presente en otras variables (o columnas) del set de datos



Método de DESCARTE

De la lista (listwise deletion)

- Se elimina la fila completa

Animal	Dosis (mg/kg de p. c.)	Actividad (moles/litro/min)
1	0.0	10.9
2	0.0	
3	0.0	10.8
4	0.0	9.8
5	0.0	9.0
6	2.3	
7	2.3	11.3
8	2.3	
9	2.3	9.2
10	2.3	10.1
11	4.6	10.6
12	4.6	10.4
13	4.6	8.8



Eliminación por pares (pirwise deletion)

- Se elimina la casilla con el dato faltante

Animal	Dosis (mg/kg de p. c.)	Actividad (moles/litro/min)
1	0.0	10.9
2	0.0	
3	0.0	10.8
4	0.0	9.8
5	0.0	9.0
6	2.3	
7	2.3	11.3
8	2.3	
9	2.3	9.2
10	2.3	10.1
11	4.6	10.6
12	4.6	10.4
13	4.6	8.8

Método de IMPUTACIÓN



Simple

- **Media o Mediana**
- **Regresión**
- **Hot-Deck**

se reemplazan los datos faltantes con la media o la mediana, puede alterar la ~

El dato faltante es reemplazado con el valor predicho por un modelo de regresión

reemplaza el valor faltante con el promedio de estos vecinos

Múltiple

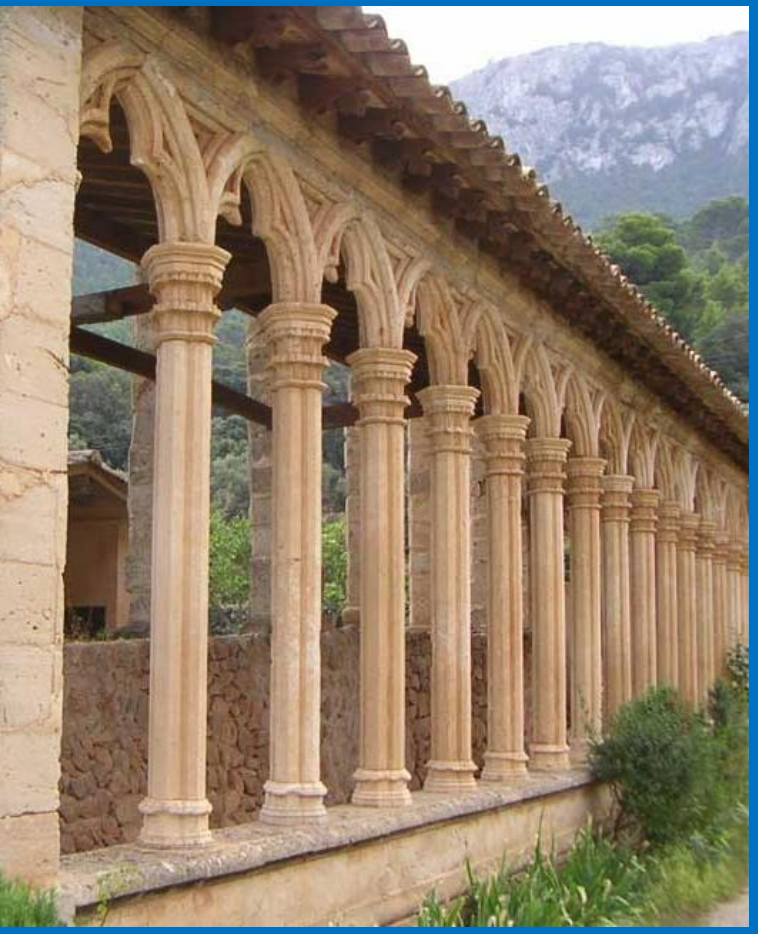
- **MICE (Imputación múltiple con ecuaciones encadenadas)**

Algoritmo: inicia imputando por la media, pero en los pasos restantes se aplica una regresión lineal entre pares consecutivos de columnas

📌 Ideas principales sobre el manejo de datos faltantes

1. **Identificar el mecanismo de pérdida de datos**:
   - **MCAR (Missing Completely At Random)**: los datos faltan de forma completamente aleatoria.
   - **MAR (Missing At Random)**: los datos faltan de forma aleatoria, pero dependen de otras variables observadas.
   - **MNAR (Missing Not At Random)**: los datos faltan por razones no aleatorias, lo que puede generar sesgos.
2. **Elección de la técnica según el mecanismo**:
   - Si los datos son **MCAR o MAR**, se pueden aplicar técnicas de imputación sin riesgo significativo de sesgo.
   - Si los datos son **MNAR**, lo ideal es **recolectar nuevos datos**, ya que las técnicas de imputación podrían distorsionar la distribución.
3. **Técnicas recomendadas**:
   - **Imputación simple con K-vecinos más cercanos (KNN)**: robusta y efectiva para muchos casos.
   - **Imputación múltiple con MICE (Multiple Imputation by Chained Equations)**: considerada una de las más completas y precisas.

2. COLUMNAS IRRELEVANTES



🔍 **No aportan información útil para el análisis o modelo:**

1. **No tienen relación con la variable objetivo** (en problemas supervisados).
2. **Tienen valores constantes o casi constantes** (por ejemplo, una columna con el mismo valor en todas las filas).
3. **Son identificadores únicos** como ID, nombres o códigos que no tienen significado predictivo.
4. **Tienen demasiados valores faltantes**, lo que dificulta su uso sin imputación compleja.
5. **Generan ruido** o confusión en el modelo, afectando su rendimiento.

2. COLUMNAS IRRELEVANTES



📊 **Ejemplos comunes de columnas irrelevantes:**

- ID_cliente, Nombre, Número de factura
- Columnas con más del 90% de valores nulos
- Columnas con un solo valor (por ejemplo, País = Argentina en todos los casos)

🧠 **¿Por qué eliminarlas?**

- Mejoran la **eficiencia computacional**
- Reducen el **riesgo de sobreajuste**
- Facilitan la **interpretación del modelo**

2. COLUMNAS IRRELEVANTES

```
cols_cat = ["nombre1", "nombre2", "nombre3"]
for col in cols_cat:
    print(f"Columna {col}: {data[col].nunique()} subniveles")   #Va categoricas

data.describe()  #Va continuas
```

1. Define una lista de nombres de columnas categóricas (cols_cat).
2. Recorre cada columna en esa lista.
3. Para cada columna, imprime cuántos **valores únicos** (subniveles) tiene en el DataFrame data.

2. COLUMNAS IRRELEVANTES



✅ **Opción 1: Usando sapply() (más compacta)**

```
cols_cat <- c("nombre1", "nombre2", "nombre3")
sapply(cols_cat, function(col) {
  cat("Columna", col, ":", length(unique(data[[col]]
)), "subniveles\n")
})
```

✅ **Opción 2: Usando for (más explícita)**

```
cols_cat <- c("nombre1", "nombre2", "nombre3")
for (col in cols_cat) {
  cat("Columna", col, ":", length(unique(data[[col]]
)), "subniveles\n")
}
```

🧠 **¿Qué hace?**

- cols_cat: vector con los nombres de las columnas categóricas.
- data[[col]]: accede a cada columna del data.frame.
- unique(): obtiene los valores únicos.
- length(): cuenta cuántos hay.
- cat(): imprime el resultado en consola.

¿Querés que lo adapte para un data.frame específico o que lo guarde en un archivo?

3. REGISTROS REPETIDOS (FILAS)
ELIMINAR FILAS DUPLICADAS



3. REGISTROS REPETIDOS (FILAS) ELIMINAR FILAS DUPLICADAS

La función drop_duplicates() de **pandas** en Python se usa para **eliminar filas duplicadas** de un DataFrame.

🔍 **¿Qué hace exactamente?**
Busca filas que sean **idénticas en todas o algunas columnas** y elimina las repetidas, dejando solo la primera ocurrencia (por defecto).

📌 **Sintaxis básica**
data.drop_duplicates() #Esto elimina filas duplicadas considerando **todas las columnas**.

```
# Elimina duplicados considerando todas las columnas
    data_clean = data.drop_duplicates()
# Elimina duplicados solo considerando la columna "nombre"
    data_clean = data.drop_duplicates(subset="nombre")
# Elimina duplicados y conserva solo la última aparición
   data_clean = data.drop_duplicates(keep="last")
# Elimina duplicados directamente en el DataFrame original
   data.drop_duplicates(inplace=True)
```



3. CONTAR DUPLICADOS

```
# Cuenta cuántas filas están duplicadas (considerando todas las columnas)

duplicados = data.duplicated()
cantidad_duplicados = duplicados.sum()
print(f"Hay {cantidad_duplicados} filas duplicadas.")
```

3. REGISTROS REPETIDOS (FILAS) ELIMINAR DUPLICADOS



Función contar_y_eliminar_duplicados

```
contar_y_eliminar_duplicados <- function(df, columnas =
NULL) {
  # Si se especifican columnas, se usan para detectar
duplicados
  if (!is.null(columnas)) {
    duplicados <- duplicated(df[columnas])
  } else {
    duplicados <- duplicated(df)
  }

  cantidad <- sum(duplicados)
  cat("Se encontraron", cantidad, "duplicados.\n")

  # Elimina duplicados
  df_sin_duplicados <- df[!duplicados, ]

  return(df_sin_duplicados)
}
```

```
# Usar todas las columnas para detectar duplicados
nuevo_df <- contar_y_eliminar_duplicados(data)

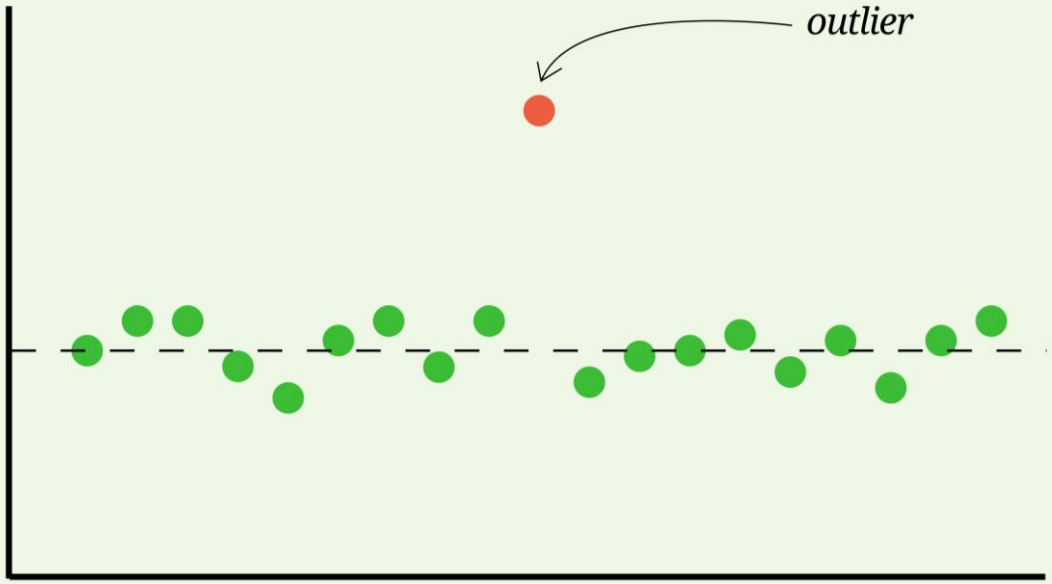
# Usar solo algunas columnas
nuevo_df <- contar_y_eliminar_duplicados(data, columnas
= c("nombre", "edad"))
```

4. VALORES OUTLIERS

- ¿**Qué es** un valor extremo?
- ¿Qué factores dan **origen** a este tipo de valores?
- Las **técnicas** más usadas para su **detección y su manejo**.



4. VALORES OUTLIERS



En estadística, un **outlier** (o **valor atípico**) es una observación que se **aleja significativamente del resto de los datos**.

Puede indicar una variabilidad inusual, un error de medición, o una característica interesante del fenómeno que se estudia.

¿QUÉ DA ORIGEN A LOS *OUTLIERS*?

errores en la captura de los datos

Error Humano

Dispositivo

el dato observado es un valor extremo



¿Qué son los valores atípicos?

- **Definición**: Observaciones que se desvían notablemente del resto de los datos.
- Pueden indicar errores, condiciones especiales o fenómenos reales importantes.



- **Regla de oro:** *Nunca descartar sin investigar primero*.



Causas posibles de valores atípicos

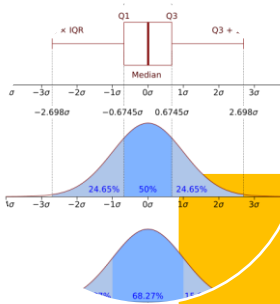
Causas artificiales (errores)

- ❑ Errores de muestreo o análisis (instrumentos, calibración).
- ❑ Errores de transcripción o codificación de datos.
- ❑ Problemas en la digitación.

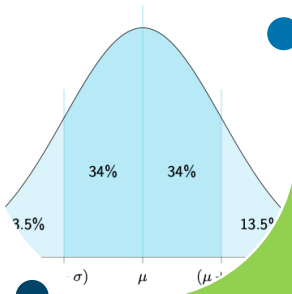
Causas reales (variabilidad natural o factores externos)

- ✓ Variaciones espaciales o temporales.
- ✓ Fallos operativos: derrames, paradas de planta.
- ✓ Situaciones relevantes que deben investigarse.

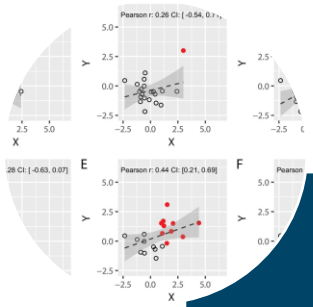
¿CÓMO DETECTAR LOS VALORES EXTREMOS?



uso del rango intercuartiles.



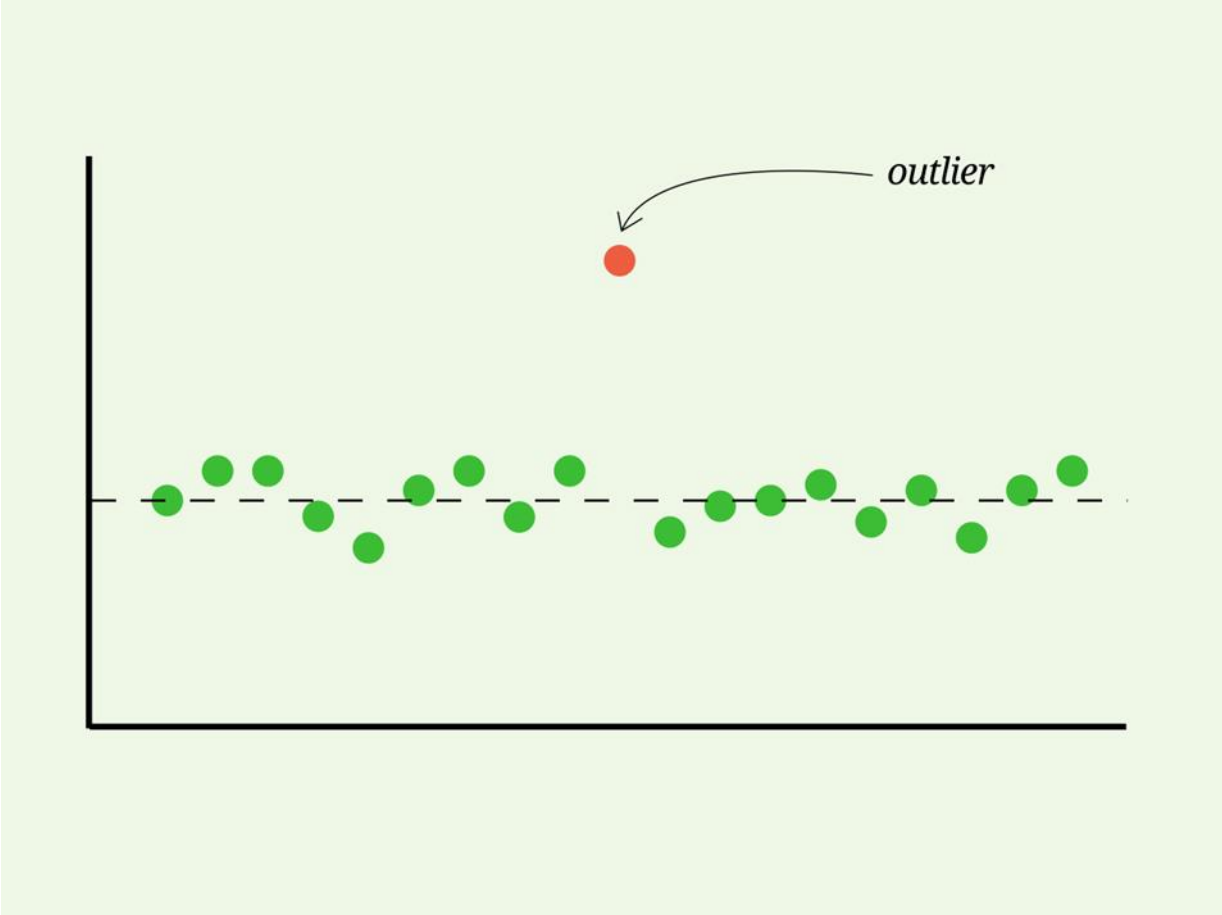
uso de la desviación estándar



visualización

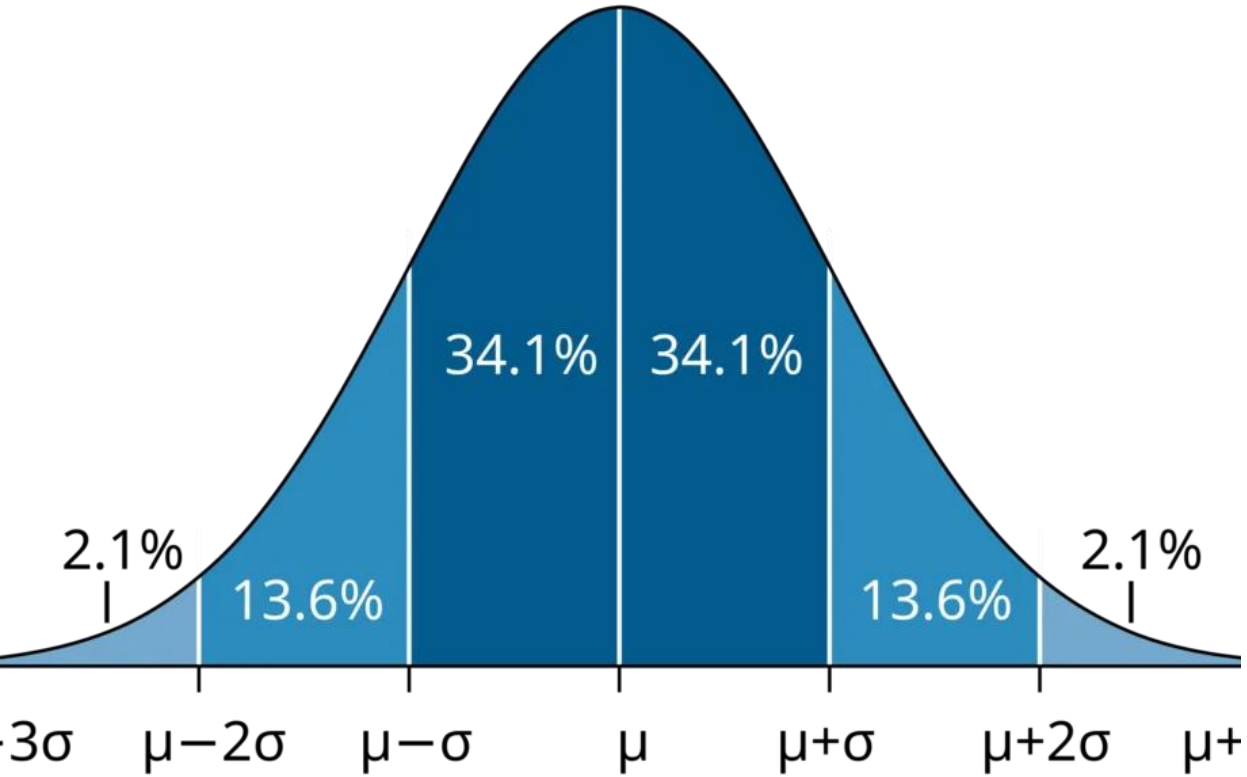
OUTLIERS - VISUALIZACIÓN

Más sencilla de todas, aunque no siempre es la más efectiva.
Consiste simplemente en **generar una gráfica de nuestro set de datos** y detectar posteriormente los *outliers* por simple inspección visual.




```
fig = px.scatter(df_salarios, y='Salarios (USD)', width=1200, height=350) fig.show()
```

OUTLIERS _ MÉTODO DE LA DESVIACIÓN ESTÁNDAR



Para datos que se distribuyen normalmente.

Conociendo los parámetros de esta distribución podemos establecer una serie de umbrales dentro de los cuales se encontrarán distriubidos nuestros datos, así:

En el rango $\mu \pm \sigma$ tendremos el 68% de los datos

En el rango $\mu \pm 2\sigma$ tendremos el 95% de los datos

En el rango $\mu \pm 3\sigma$ tendremos el 99.7% de los datos

Así que si, por ejemplo, tomamos como criterio el rango $\mu \pm 3\sigma$ (donde se encuentra la gran mayoría de los datos), podemos etiquetar a un dato como valor extremo si se encuentra por fuera de este rango.

Tratamiento



Verificación y corrección

- Volver a muestrear o repetir el análisis.
- Corregir errores si se detectan.

Eliminación justificada

- Solo si hay una justificación estadística y/o práctica
- Nunca basarse únicamente en una prueba estadística

Conservación

- Usar métodos estadísticos **robustos** (mediana, rango intercuartílico, regresión robusta, etc.).

OUTLIERS ¿CÓMO MANEJAR LOS VALORES EXTREMOS?

antes de tomar cualquier decisión:
es fundamental que entendamos claramente cómo fueron adquiridos los datos, los objetivos de nuestro proyecto y el campo de aplicación del mismo.

OUTLIERS

Método de eliminación (*trimming*)



se elimina el valor extremo de nuestro set de datos

Método de recorte (*capping*)



cambiar el valor de los *outliers* a los límites inferior y superior

Probar con y sin valores extremos

NO hacer nada

Herramientas estadísticas para detectar outliers



Muestras pequeñas

- Prueba de Grubbs
- Prueba de Dixon
- Prueba de Rosner

Muestras grandes o datos no normales

- Para Métodos gráficos (boxplots, scatterplots, histograma).
- Z-scores, rango intercuartílico (IQR), transformaciones.

Muestras pequeñas

Prueba Z



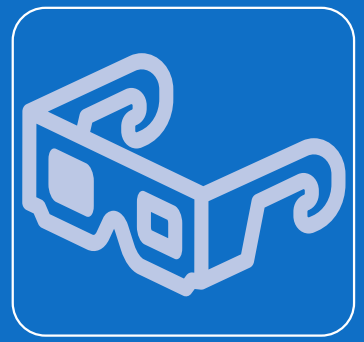
Calculo del estadístico

- Se utiliza la media y la desviación estándar de todo el conjunto de datos para obtener el **valor z** de cada punto
- $z_i = \frac{x_i - \bar{x}}{s}$



Regla de decisión

- El punto de datos se rechaza si z > 3.



Observaciones

- La **media como la desviación estándar** se ven afectadas por la presencia de valores atípicos.
- La **prueba Z requiere que el conjunto de datos siga una distribución normal**.

Prueba GRUBBS

Primero, se deben ordenar los datos de forma ascendente .Los valores más bajo $(x_{(1)})$ y más alto $(x_{(n)})$ pueden ser evaluados como posibles valores atípicos



Calculo del estadístico

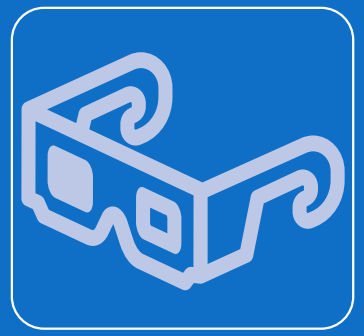
Inicialmente se utiliza la media y la desviación estándar de todo el conjunto de datos

$$T = \frac{\bar{x} - x_{(1)}}{s} \quad o \quad T = \frac{x_{(n)} - \bar{x}}{s}$$



Regla de decisión

- El valor de **T** se compara con un **valor crítico de T** correspondiente al **tamaño de muestra** y al **nivel de significancia α seleccionado** (normalmente 5%).
  El dato se considera un **valor atípico si T > $T_{crítico}$.**



Observaciones

- La prueba puede continuar para evaluar otros posibles valores atípicos $x_{(2)}$. $x_{(n-1)}$
- Se debe recalcular la la media y la desviación estándar con elconjunto reducido de datos.

Prueba GRUBBS

Table 2.3 Critical values used for the Grubbs' test

Degree of freedom $(n-1)$	Critical T		Degree of freedom $(n-1)$	Critical T	
	$T_{0.05}$	$T_{0.01}$		$T_{0.05}$	$T_{0.01}$
3	1.153	1.155	13	2.331	2.607
4	1.463	1.492	14	2.371	2.659
5	1.672	1.749	15	2.409	2.705
6	1.822	1.944	16	2.443	2.747
7	1.938	2.097	17	2.475	2.785
8	2.032	2.221	18	2.504	2.821
9	2.110	2.323	19	2.532	2.854
10	2.176	2.410	20	2.557	2.884
11	2.234	2.485	30	3.103	2.745
12	2.285	2.550	50	2.956	3.336

Ejemplo: Supongamos que tenemos la siguiente muestra de datos de concentraciones medidas en una muestra Ambiental:

10.2, 10.5, 10.7, 10.3, 10.4, 10.6, 15.0

Ordenamos y miramos:

10.2, 10.3, 10.4, 10.5, 10.6, 10.7, 15.0

Media = 11,10

Desvio Standard = 1,73

$$T = \frac{x_{(n)} - \bar{x}}{s} = \frac{15 - 11{,}10}{1{,}73} = 2{,}75$$

Como $T_{calculado} = 2,75 >$ $T_{crítico} =$ 1.822 el dato se considera un valor atípico

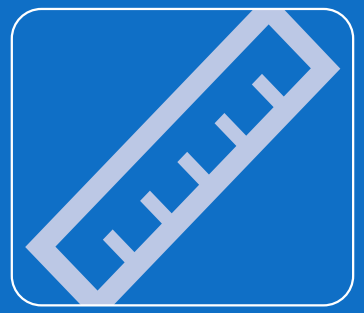
Prueba de DIXON

Primero, se deben ordenar los datos de forma ascendente .Los valores más bajo $(x_{(1)})$ y más alto $(x_{(n)})$ pueden ser evaluados como posibles valores atípicos



Calculo del estadístico

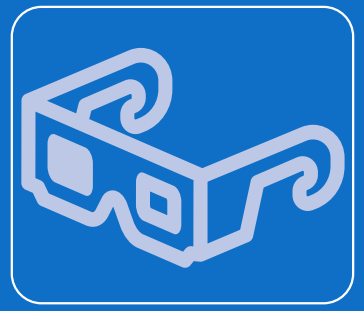
Según el número de observaciones y si sospechas de un outlier **mínimo** $(x_{(1)})$ o **máximo** $(x_{(n)})$ se calcula el estadístico D



Regla de decisión

El valor de D obtenido se compara con una **tabla de valores críticos de Dixon**

- Si Dcalculado > Dcritico entonces el valor sospechoso se considera un *outlier*.



Observaciones

Si bien el **Test de Dixon** es una herramienta útil para detectar **un único valor atípico** en **muestras pequeñas** (entre 3 y 25 datos), **no es tan eficiente** cuando se trata de identificar **múltiples outliers** en conjuntos de datos más grandes.

Fórmulas para el cálculo de D (según el tamaño muestral):

Tamaño n	Si el sospechoso es x_n (máximo)	Si el sospechoso es x_1 (mínimo)
3 – 7	$D_{10} = \frac{x_n - x_{n-1}}{x_n - x_1}$	$D_{10} = \frac{x_2 - x_1}{x_n - x_1}$
8 – 10	$D_{11} = \frac{x_n - x_{n-1}}{x_n - x_2}$	$D_{11} = \frac{x_2 - x_1}{x_{n-1} - x_1}$
11 – 13	$D_{21} = \frac{x_n - x_{n-2}}{x_n - x_2}$	$D_{21} = \frac{x_3 - x_1}{x_{n-1} - x_1}$

> La elección de la fórmula depende del **tamaño de la muestra** y de si sospechas del valor máximo o mínimo.

Ejemplo: Supongamos que tenemos la siguiente muestra de datos de concentraciones medidas en una muestra Ambiental:

10.2, 10.5, 10.7, 10.3, 10.4, 10.6, 15.0

n = 7

$$D_{10} = \frac{x_n - x_{n-1}}{x_n - x_1}$$

$$D_{10} = \frac{15 - 10{,}6}{15 - 10{,}2} = 0{,}917$$

Table 2.5 Critical values for the Dixon's test*

Critical value	n	Risk of false rejection 0.5%	1%	5%	10%
	3	0.994	0.988	0.941	0.886
	4	0.926	0.899	0.765	0.679
D_{10}	5	0.821	0.780	0.642	0.557
	6	0.740	0.698	0.560	0.482
	7	0.680	0.637	0.507	0.434
	8	0.727	0.683	0.554	0.479
D_{11}	9	0.677	0.635	0.512	0.441
	10	0.639	0.597	0.477	0.409
	11	0.713	0.679	0.576	0.517
D_{21}	12	0.675	0.642	0.546	0.490
	13	0.649	0.615	0.521	0.467

*Reference: Robracher (1991)

Como $D_{10} = 0,917$ es mayor que Dcritico = 0,507 el valor se considera un *outlier*

PRUEBA de DIXON

⚠️ Puntos clave a considerar:

🔍 Dixon se recomienda solo para detectar un outlier a la vez.

👨‍🔬 Si se sospechan múltiples outliers, se debe aplicar el test en forma iterativa, empezando por el valor menos extremo.

🔁 Con cada repetición, se elimina el outlier detectado y se vuelve a aplicar el test al nuevo subconjunto de datos.

📉 El poder estadístico del test disminuye con cada repetición, lo que reduce la probabilidad de detectar los siguientes outliers.

¿Qué hacer si hay múltiples outliers?

La EPA (Environmental Protection Agency) recomienda utilizar el Test de Rosner

Test de Rosner

📈 Tiene **mayor potencia estadística** para detectar **múltiples valores atípicos**.

🔢 Puede aplicarse a muestras de **mayor tamaño**.

📊 Permite una **detección simultánea** de varios outliers (k posibles outliers) sin necesidad de aplicar el test repetidas veces.

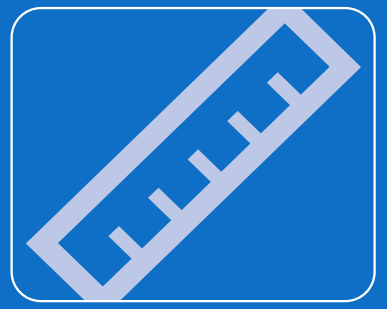
Prueba de Rosner

Definir el número máximo de outliers sospechados: k



Calculo del estadístico

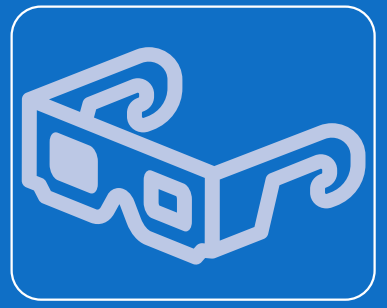
Eliminar el valor más extremo (mayor o menor) del conjunto. Calcular la media $(\bar{x}_i)$y la desviación estándar (s_i) del conjunto reducido. Calcular el estadístico: $R_i = \frac{|x_i - \bar{x}_i|}{s_i}$



Regla de decisión

Comparar cada R_i con su valor crítico correspondiente (según tablas basadas en el nivel de significancia y n).

Si R_i > Rcritico, entonces el valor eliminado en el paso i se considera un outlier.



Observaciones

Detecta **múltiples outliers** en una sola ejecución.

Mantiene mayor **potencia estadística**.

Es el método recomendado por la **EPA** para análisis de datos ambientales y de calidad.

📌 Valores críticos de R_i

Se calcula un valor crítico λ_i para cada iteración i como:

$$\lambda_i = \frac{(n-i) \cdot t_{\alpha/(2(n-i)),n-i-1}}{\sqrt{(n-i-1+t^2)}}$$

Donde:

- n: tamaño total de la muestra,
- i: número de valores extremos eliminados hasta esa iteración,
- $t_{\alpha/(2(n-i)),n-i-1}$: valor crítico de la distribución t de Student con $n-i-1$ grados de libertad y un nivel de significancia ajustado para múltiples pruebas.

🧪 ¿Cuándo se considera un outlier?

Para cada i, si:

$$R_i > \lambda_i$$

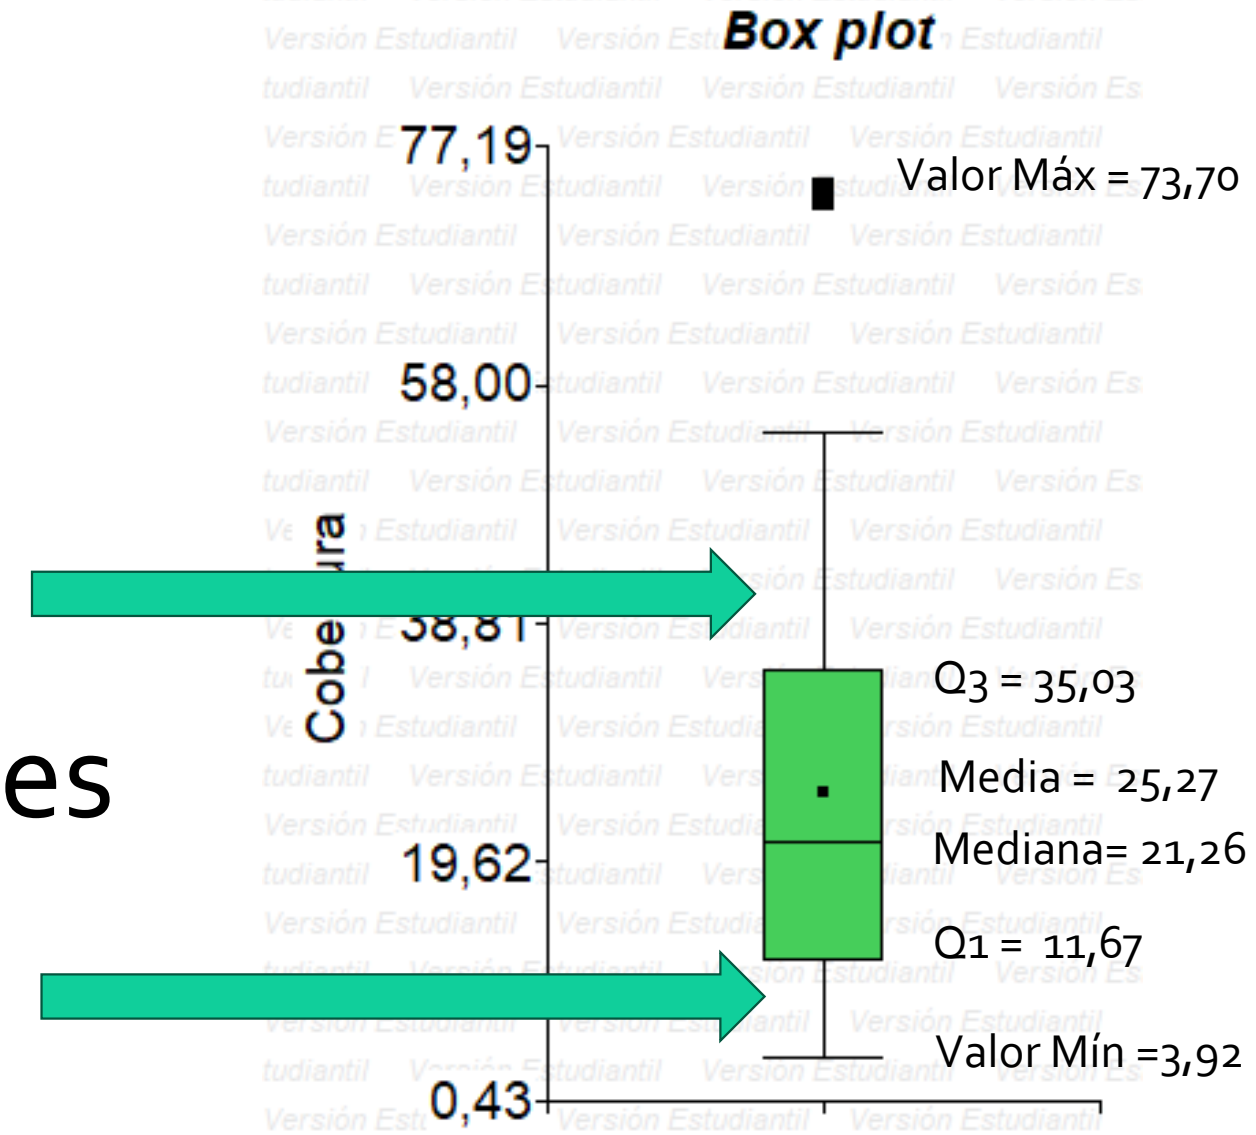
Entonces el valor x_i se considera un **outlier**.

Muestras grandes

- **Medidas resumen**

n	75,00
Media	25,27
D.E.	16,13
Mín	3,92
Máx	73,70
Mediana	21,26
Q1	11,67
Q3	35,03

Bigotes

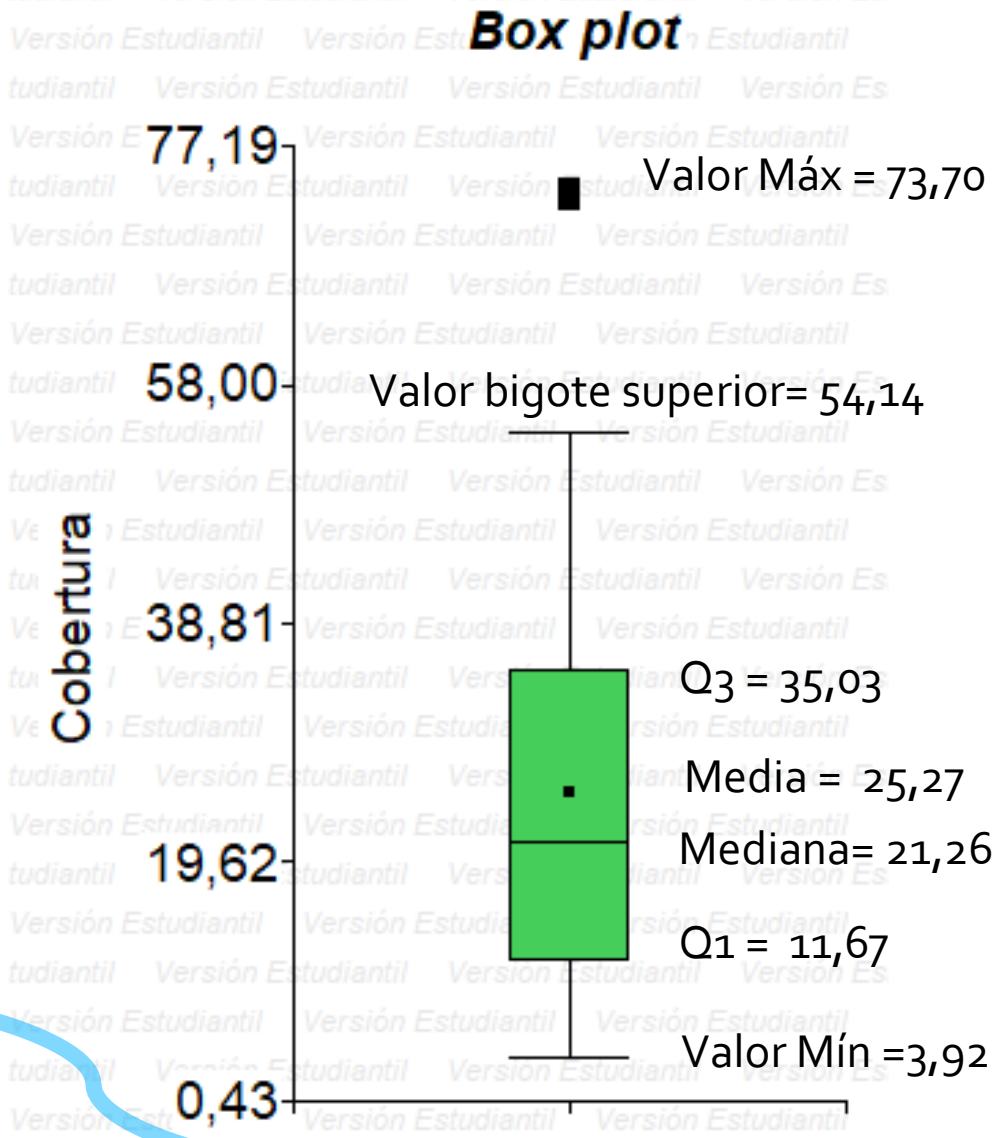


- ¿Cómo se trazan los bigotes?
- Q1 11,67
- Q3 35,03

- **1) RI** = Q3 – Q1
- =35,03-11,67 = **23,36**
- **2) Valor del Bigote Superior teórico**

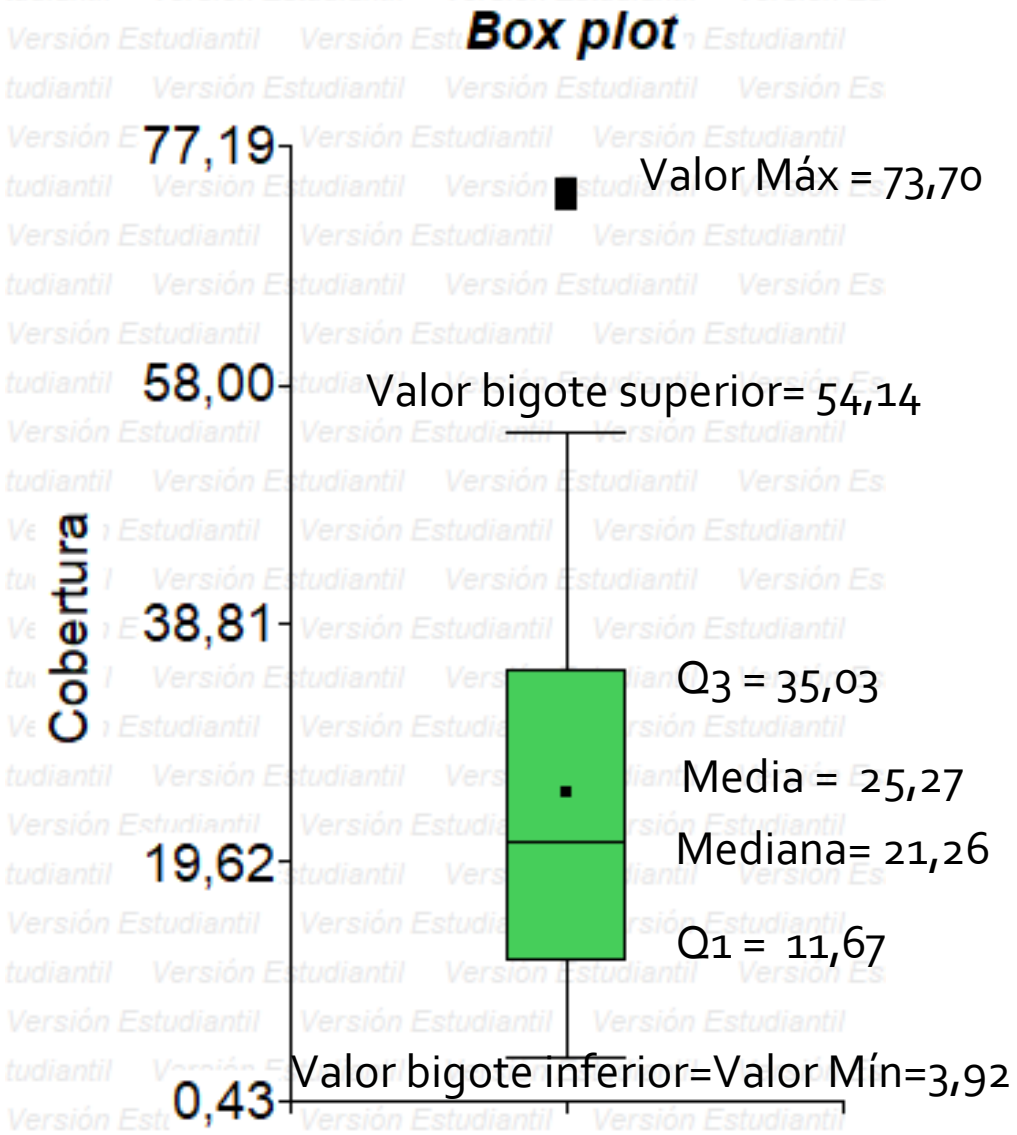
VBST = Q3 + 1,5 RI

- = 35,03 + 1,5 x 23,36 = **70,07**
- 3) Busco en la muestra el valor más cercano por debajo de **70,07**



Datos ordenados: 3.92, 5.88, 6.70, 7.10, … , 53.14, 54.14, 72.78, 73,70

- ¿Cómo se trazan los bigotes?
- Q1 11,67
- Q3 35,03
- **1) RI** = Q3 – Q1
- =35.03-11.67 = **23.36**
- **2) Valor del Bigote Inferior teórico VBIT** = Q1 – 1.5 RI
- = 11.67 -1.5 x 23.36 = **-23.37**
- 3) Busco en la muestra el valor más cercano por arriba a **-23.37**



Datos ordenados: 3.92, 5.88, 6.70, 7.10, … , 53.14, 54.14, 72.78, 73,70

OUTIERS MÉTODO DEL RANGO INTERCUARTILES

cuando los datos no tienen una distribución normal

se definen también dos límites (inferior y superior):

Límite inferior: cuartil 1 – k x IQR
Límite superior: cuartil 3 + k x IQR

donde k es un valor que usualmente es igual a 1.5.

4. VALORES EXTREMOS (OUTLIERS)

```
import seaborn as sns
import matplotlib.pyplot as plt
import pandas as pd

# DataFrame de ejemplo
data = pd.DataFrame({
    'Variable1': [10, 20, 15, 30, 25],
    'Variable2': [5, 7, 6, 8, 7],
    'Variable3': [100, 120, 110, 130, 125]
})

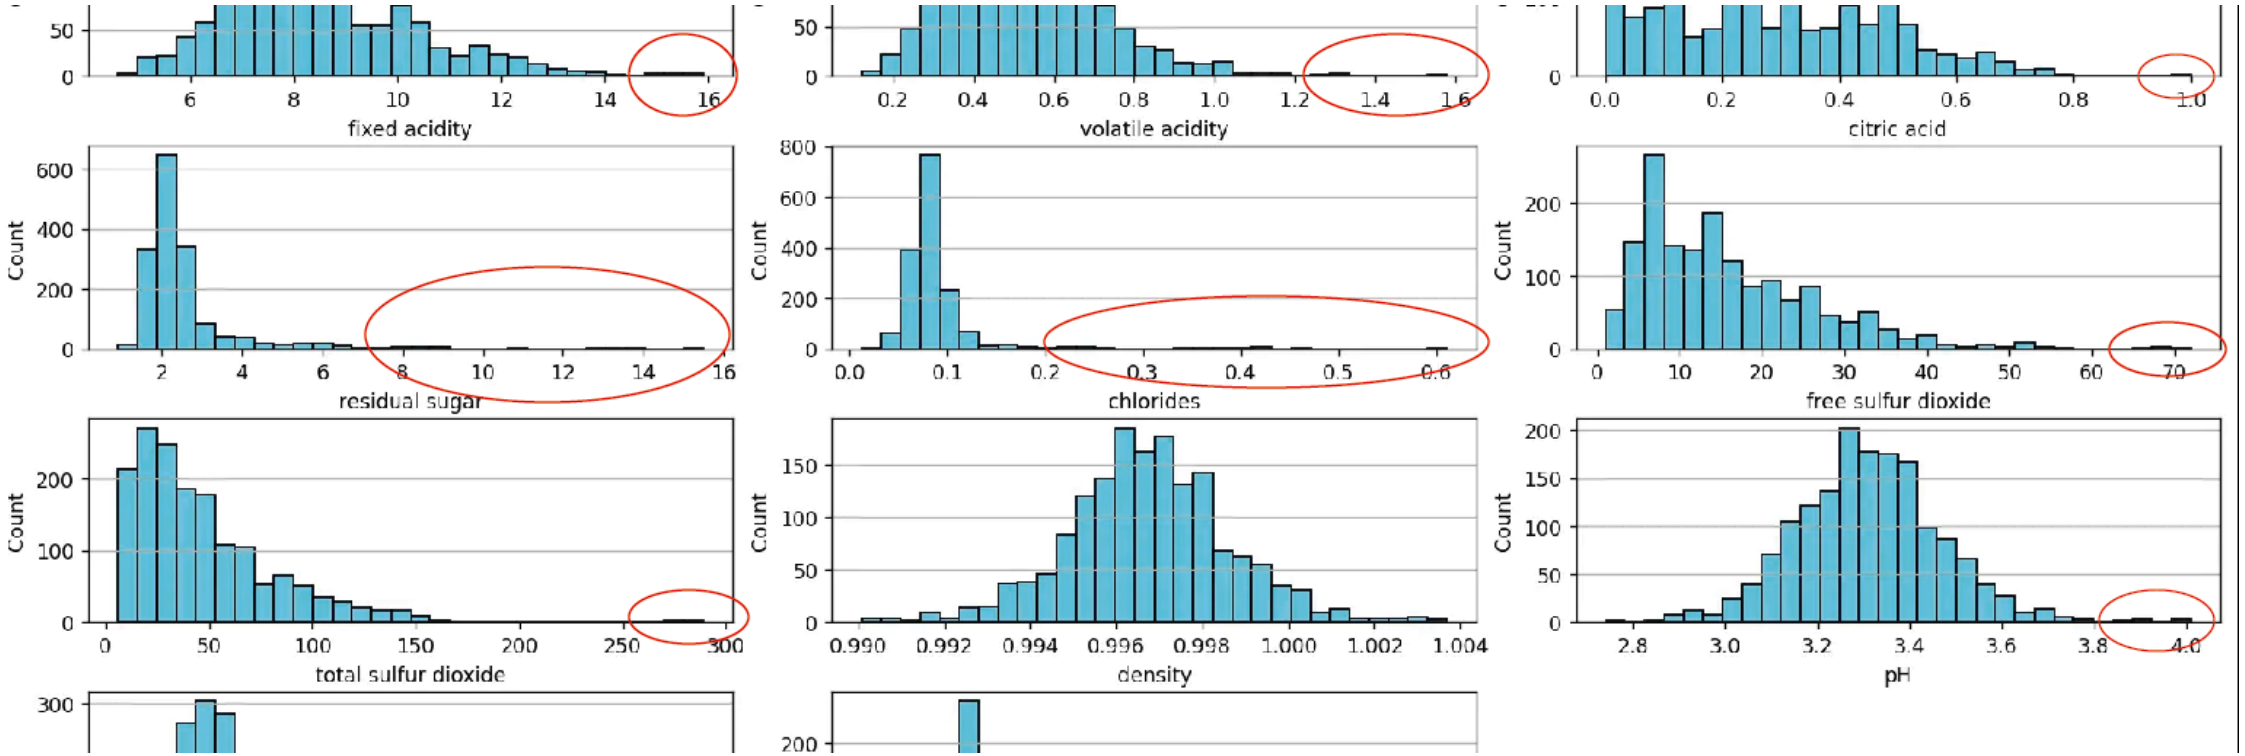
# Convertir a formato largo
data_long = data.melt(var_name='Variable',
value_name='Valor')
# Crear el boxplot
plt.figure(figsize=(8, 6))
sns.boxplot(x='Variable', y='Valor', data=data_long)
plt.title('Boxplot de varias variables')
plt.tight_layout()
plt.show()
```

```
library(ggplot2)
library(tidyr)

# DataFrame de ejemplo
data <- data.frame(
  Variable1 = c(10, 20, 15, 30, 25),
  Variable2 = c(5, 7, 6, 8, 7),
  Variable3 = c(100, 120, 110, 130, 125)
)

# Convertir a formato largo
data_long <- pivot_longer(data, cols = everything(),
names_to = "Variable", values_to = "Valor")

# Crear el boxplot
ggplot(data_long, aes(x = Variable, y = Valor)) +
  geom_boxplot() +
  ggtitle("Boxplot de varias variables") +
  theme_minimal()
```



Frecuencia absoluta

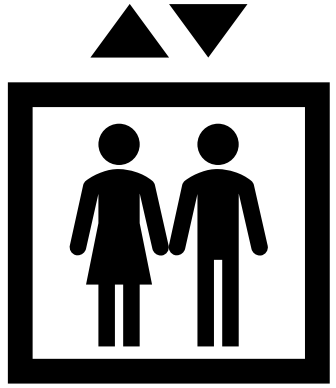
Conclusiones sobre outliers

- Los outliers **pueden ser ruido o información valiosa**.
- La decisión sobre cómo tratarlos **debe estar fundamentada**.
- Es clave considerar tanto el contexto como las herramientas estadísticas.

“Los outliers no siempre son errores… A veces son la clave para descubrir algo importante.”

6 _Datos censurados

¿ Qué son los Datos censurados?

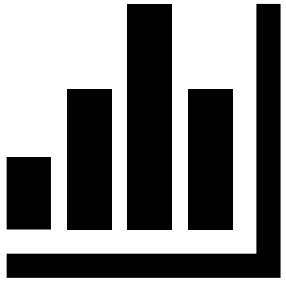


Valores con una cantidad conocida *menor que* un umbral.

Ejemplo: "<1.0 mg/L" significa que el valor está por debajo del límite de cuantificación.



Tienen relevancia en estudios ambientales (contaminación en agua, aire, suelos).



Problema: No pueden analizarse directamente con métodos estadísticos comunes.

Se midió la concentración de mercurio en agua potable: 2.5, <1.0, 1.9, 2.6 mg/L.
¿Se cumple con el límite regulatorio de 2.0 mg/L?

Se dificulta calcular la **media y desviación estándar**.
No se puede aplicar directamente una prueba de hipótesis.



¿Por qué es un problema serio?

- Los Métodos estadísticos paramétricos requieren datos numéricos completos.
- En censura alta (80–95%), el sesgo en estimaciones puede ser muy grande.
- Casos comunes:
  - Aguas subterráneas con contaminantes en trazas.
  - Estudios de metales pesados.

Errores comunes al tratar datos censurados

No hacer esto





Eliminar valores censurados →.

Sesgo fuerte y comparaciones inválidas



Sustituir por "0"→ subestima la media y distorsiona el análisis.

Subestimación

Límite

Sustituir por el límite tal cual → puede sobrestimar.

Sobrestimación

🔍 Recomendaciones de la EPA (1998)

% de censura	Recomendación
< 15%	Sustitución simple (LD, LD/2, valor pequeño)
15–50%	Estimación por máxima verosimilitud o exclusión balanceada
> 50%	Análisis basado en proporciones (cuántos superan el umbral)

Conclusiones

- Los datos censurados no deben ignorarse ni tratarse arbitrariamente.
- El tratamiento correcto depende del porcentaje de censura.
- Métodos avanzados existen, pero requieren formación estadística.
- La interpretación debe ser cuidadosa, especialmente si hay decisiones regulatorias.



5. ERRORES TIPOGRÁFICOS, EN EL CASO DE VARIABLES CATEGÓRICAS.

Proceso artesanal, revisar la categorías: cambiar tipo de letra y unificar.



```
import pandas as pd

for columna in data.columna:

If columna in cols_cat:
data[column] = data[columna].str.lower()
```

```
# Convertir a minúsculas las columnas categóricas
for (col in names(data)) {
  if (is.character(data[[col]]) || is.factor(data[[col]])) {
    data[[col]] <- tolower(as.character(data[[col]]))
  }
}
# Ver el resultado
print(data)
```