Análisis de Cluster
(Clustering – Agrupamiento Conglomerado)

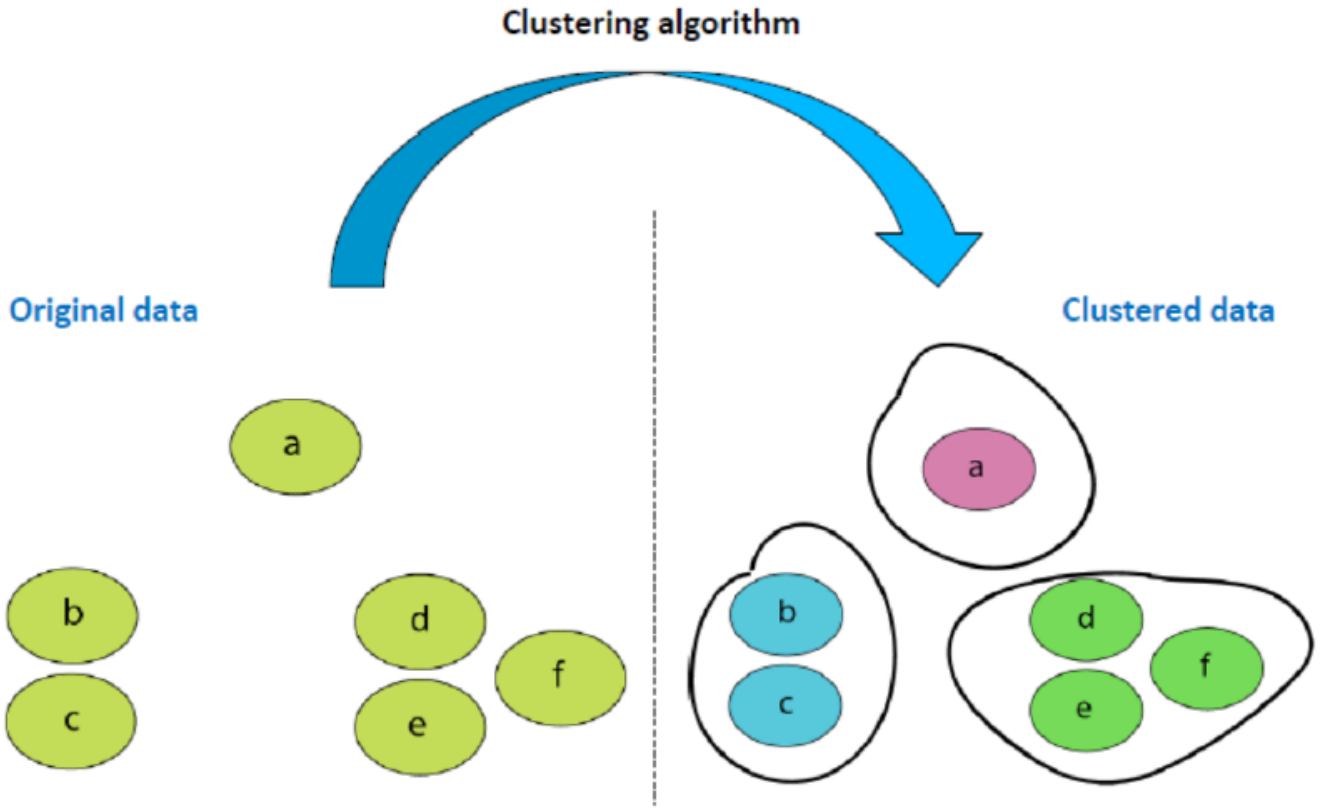
Mónica Giuliano
Maria Laura Vranic

Clase 3
Análisis Inteligente de Datos

Objetivo del Clustering

Clasificación
No Supervisada

Método
exploratorio



AGRUPAMIENTO O CLUSTERING

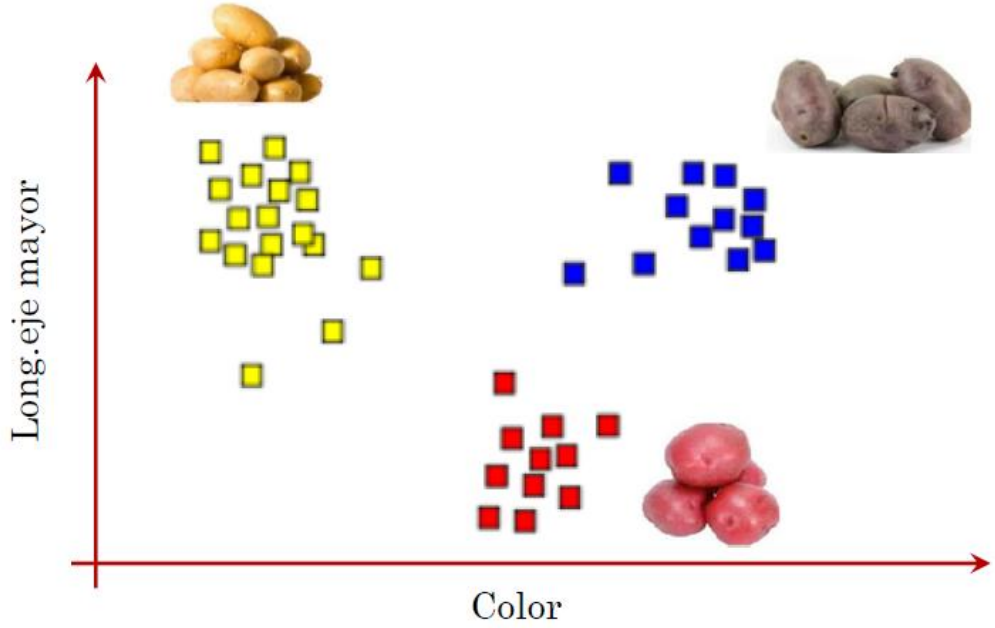
- El *clustering* es uno de los métodos de aprendizaje **no supervisado** más importantes y busca caracterizar conceptos desconocidos a partir de los ejemplos disponibles.
- Generalmente, en un problema real **se desconoce la clase** y es allí donde el agrupamiento puede ayudar a identificar las características comunes entre instancias.
- Al no disponer de la clase utiliza una **medida de similitud** para determinar el parecido entre instancias.



Elementos Básicos del Agrupamiento

- Identificar las características relevantes de cada tipo de elemento.
- Indicar la manera en que se realizará la comparación **(DISTANCIA)**

- El resultado de aplicar una técnica de *clustering* es una serie de agrupamientos o *clusters* formados al particionar las instancias.



CLUSTERING: Aplicaciones

Descubrimiento de Grupos

Permite encontrar y describir grupos de instancias con características similares dentro de un conjunto de datos.

Segmentación de Clientes

Identifica clientes con perfiles y comportamientos similares para ofrecer servicios y productos adecuados y personalizados.

Análisis Académico

Identifica alumnos con rendimientos académicos similares, con el objetivo de diseñar estrategias para reducir la deserción escolar.

Detección de Anomalías

Permite detectar casos o patrones anómalos que se desvían significativamente del comportamiento esperado.

Detección de Fraudes

Facilita la identificación temprana de actividades o transacciones fraudulentas mediante el análisis de patrones.

Análisis exploratorio de datos

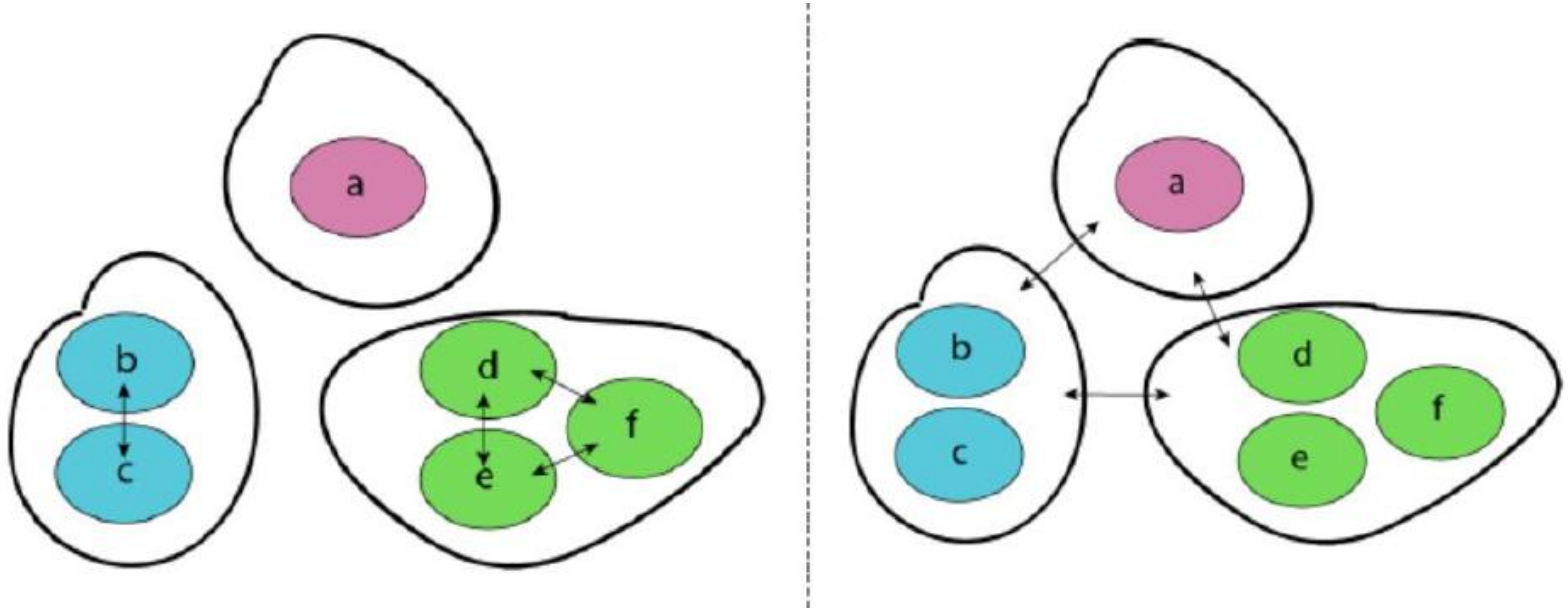
Descubrir patrones ocultos, comprender la estructura de los datos y obtener conocimientos iniciales antes de aplicar otras técnicas analíticas más complejas.

CALIDAD DEL AGRUPAMIENTO OBTENIDO

- Un buen método de agrupamiento producirá grupos de alta calidad en los cuales
- El parecido entre los elementos que componen un mismo grupo es alto (intra-cluster).
- El parecido entre los elementos de grupos distintos es bajo (inter-cluster).

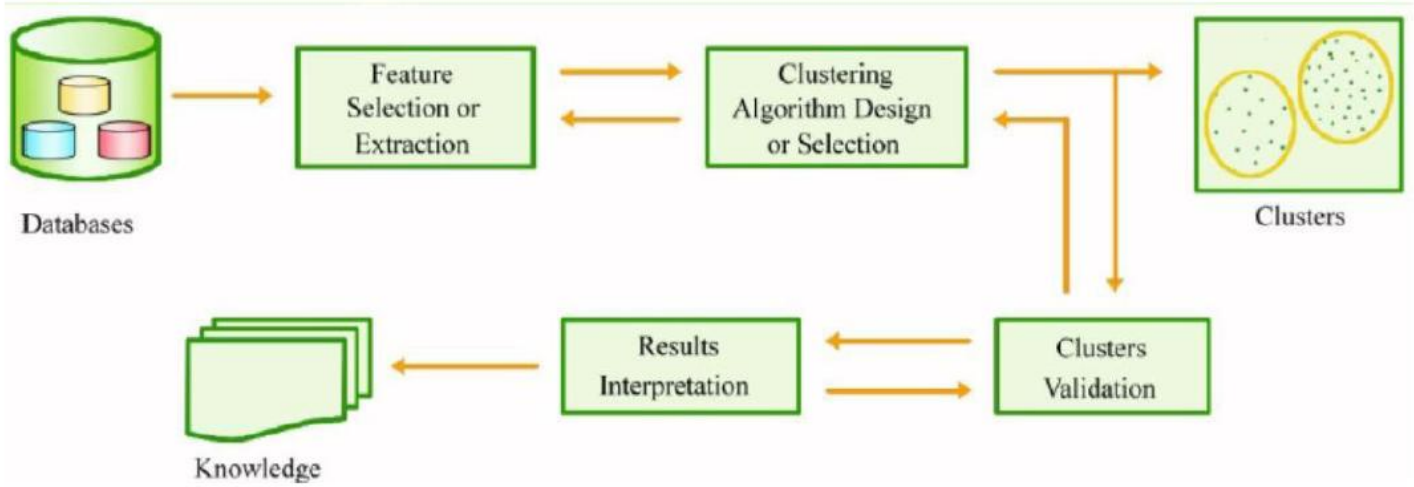
Ojo que los clusters son sensibles a la escala de las variables, tienen que estar estandarizadas.

- Minimizar la distancia entre los elementos de un mismo cluster (intra-cluster)
- Maximizar la distancia entre clusters (inter-cluster)

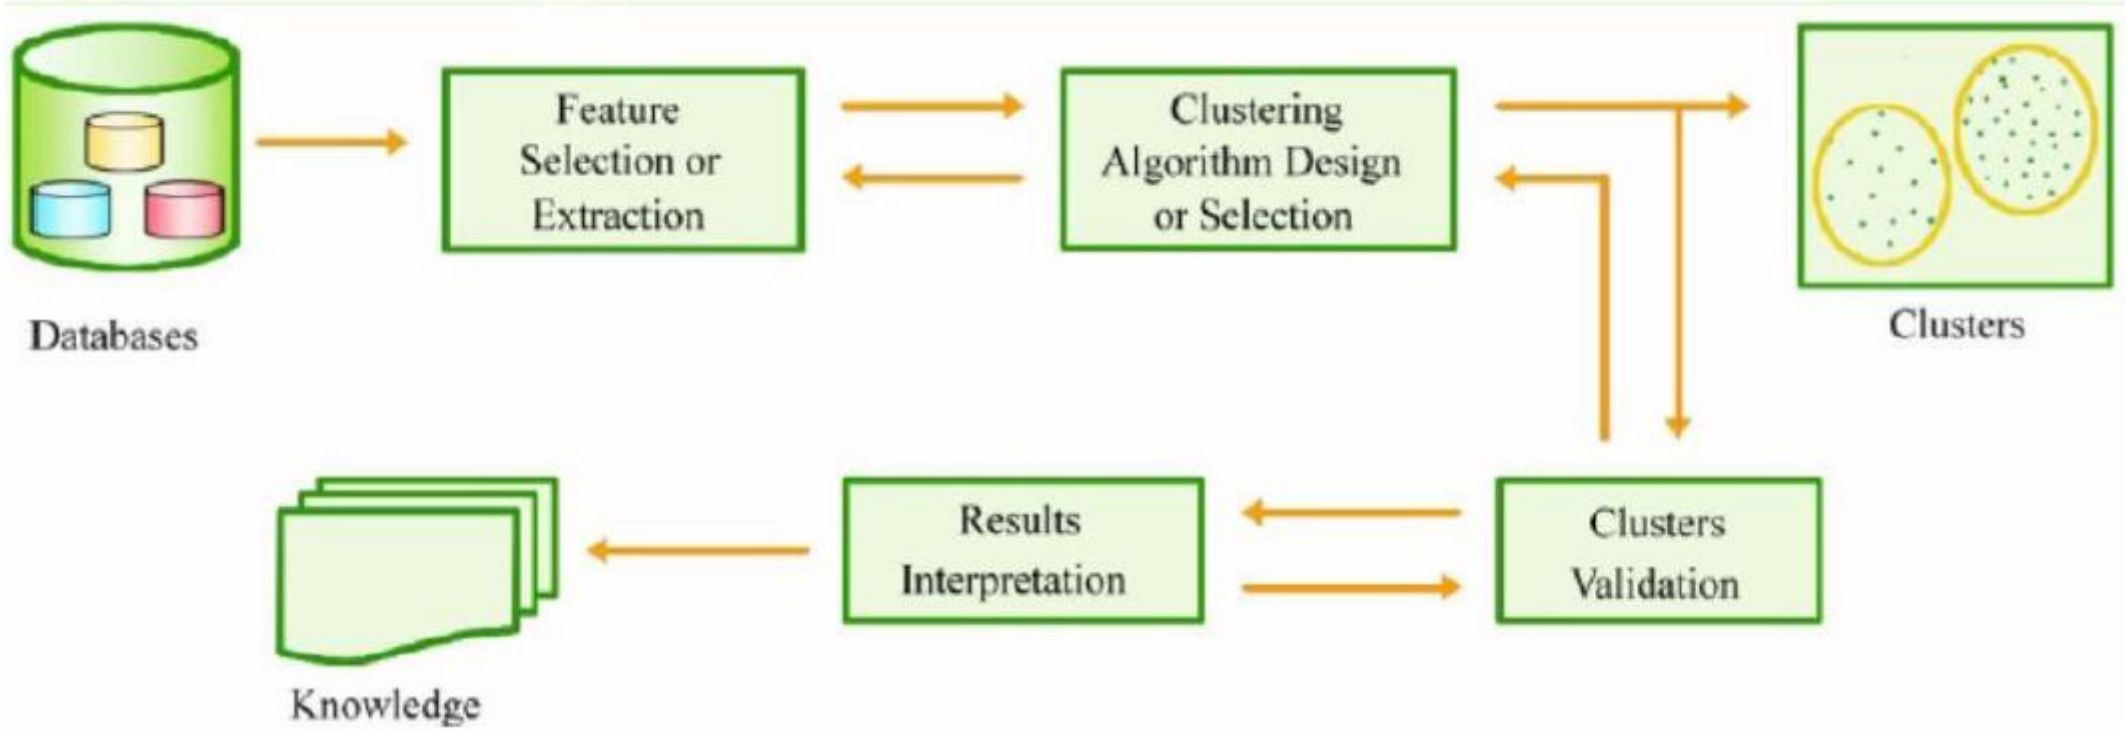


Proceso de Clustering

- Seleccionar las características relevantes (Por ejemplo con ACP: Componentes principales)
- Definir una representación adecuada.
- Definir la medida de similitud a utilidad (medida de distancia). Depende del problema.
- Aplicar un algoritmo de agrupamiento
- Validar los grupos obtenidos y de ser necesario volver a repetir el proceso.
- Analizar en el contexto de los datos y la interpretabilidad de los clusters



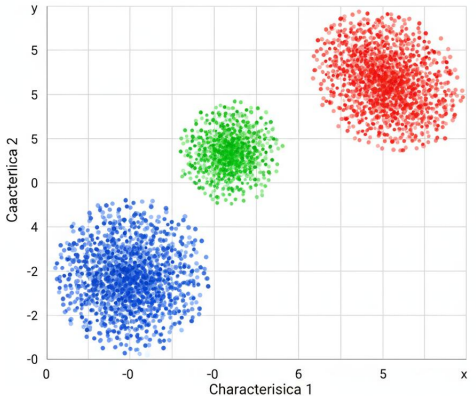
Proceso de Clustering



TIPOS DE ALGORITMOS DE AGRUPAMIENTO

Algoritmo basado en centroides

Particionan los datos creando un número K de clusters.
Una instancia pertenece a un único grupo.



Algoritmo Jerárquico

Generan una estructura jerárquica de clusters que permiten ver las particiones d granularidad.
Una instancia pertenece a un único grupo.

Algoritmo basado en distribuciones

Los clusters se definen como los objetos que pertenecen con mayor probabilidad a la misma distribución.

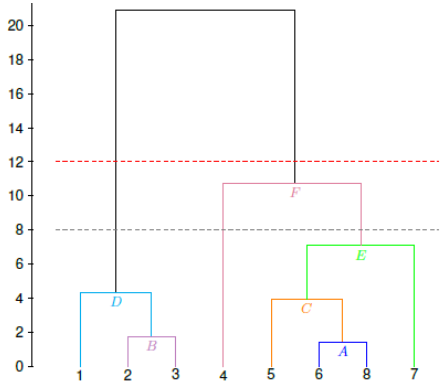
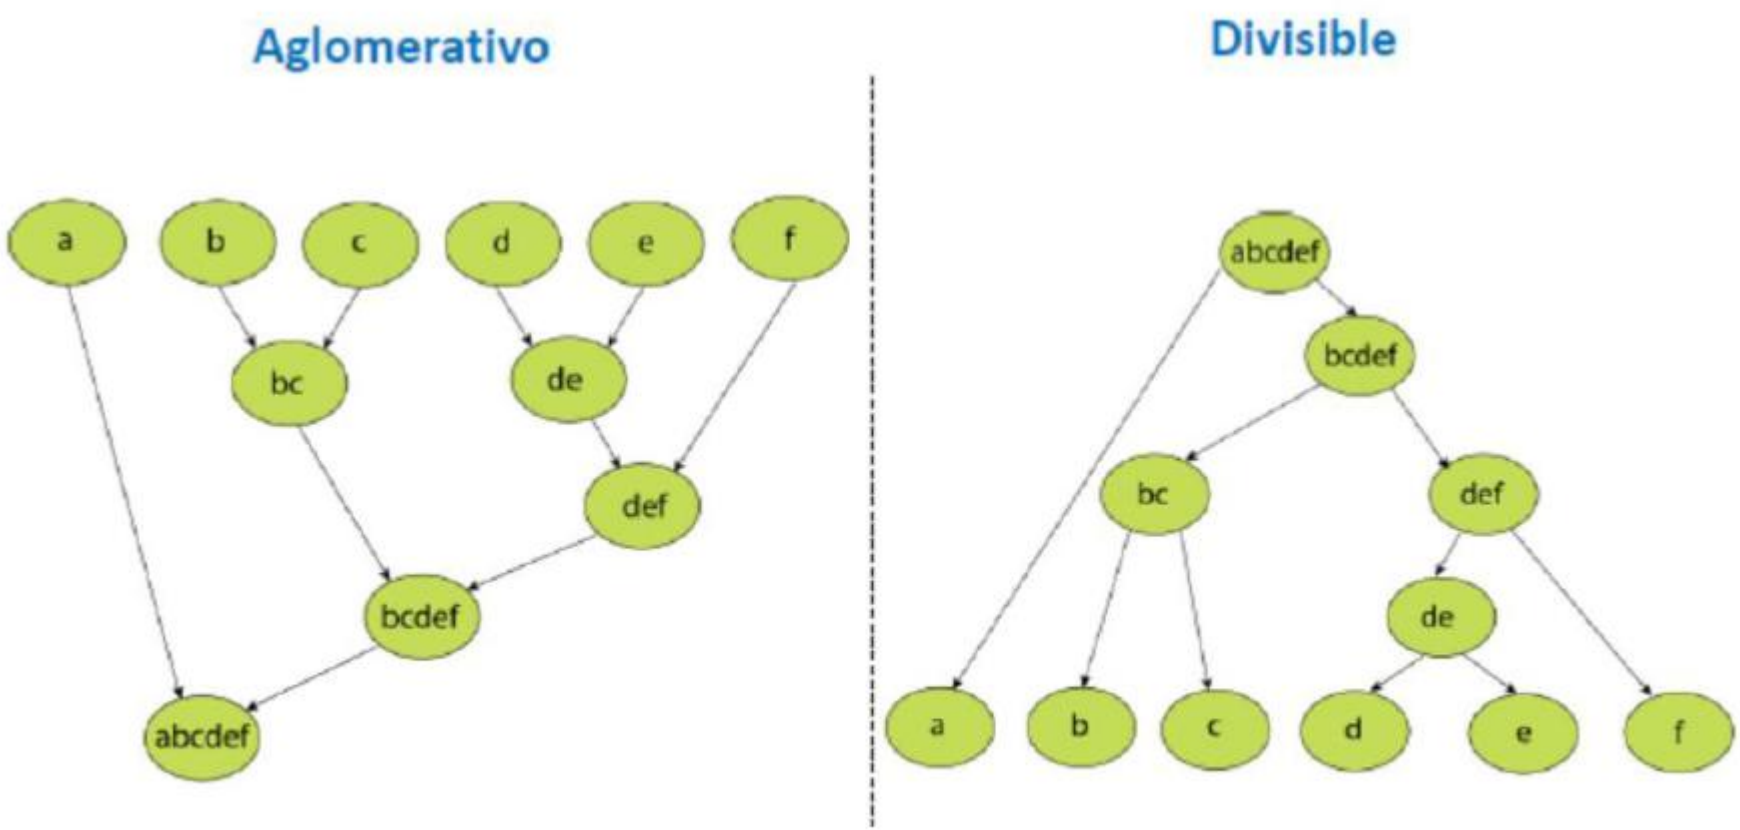


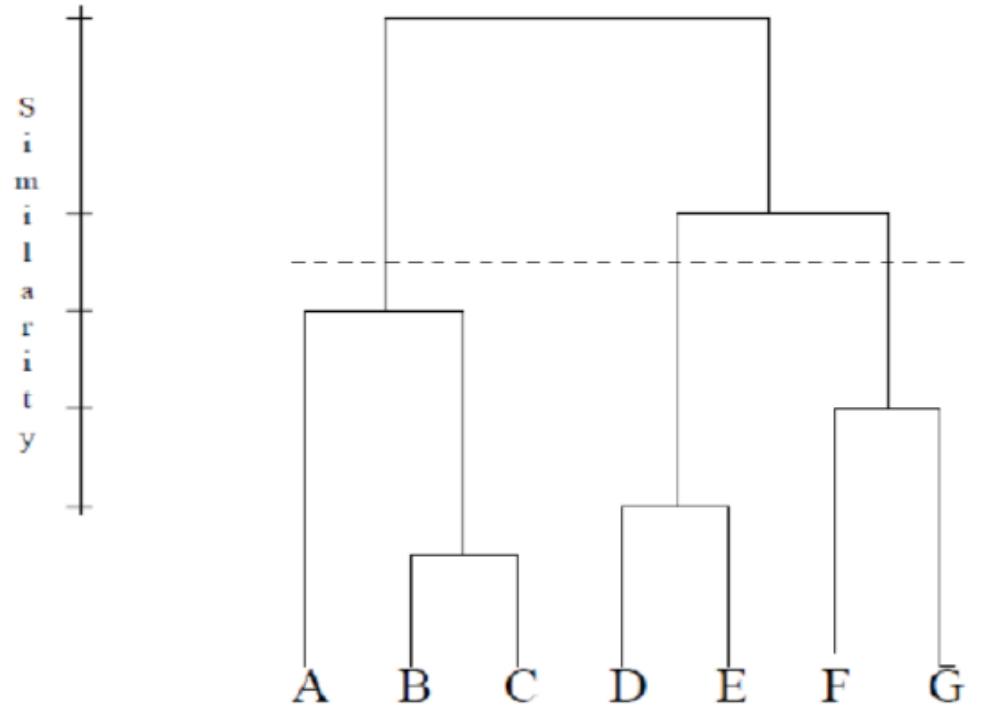
Figura 10.12: Dendograma con elección de cantidad de *clusters*

Algoritmo basado en densidad Espacial

DBSCAN: Agrupamiento Espacial Basado en la Densidad de Aplicaciones con Ruido

ALGORITMO DE CLUSTERING JERÁRQUICOS





Algoritmo De Clustering Jerárquicos

Algoritmo De Clustering Jerárquicos

- Todos los algoritmos jerárquicos producen como resultado un **dendrograma**
- A partir del dendrograma se pueden obtener distintas particiones (estructuras de clusters) de los datos

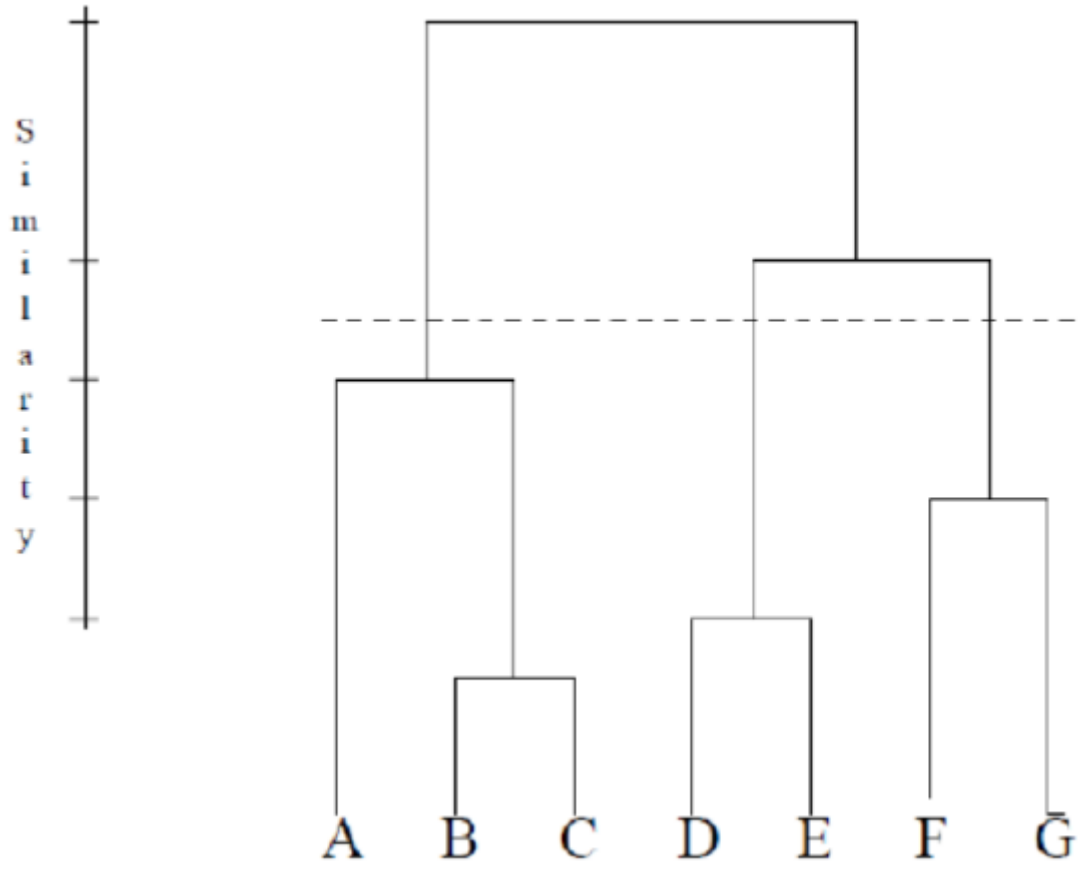


Gráfico del proceso de los tipos de agrupamiento jerárquico

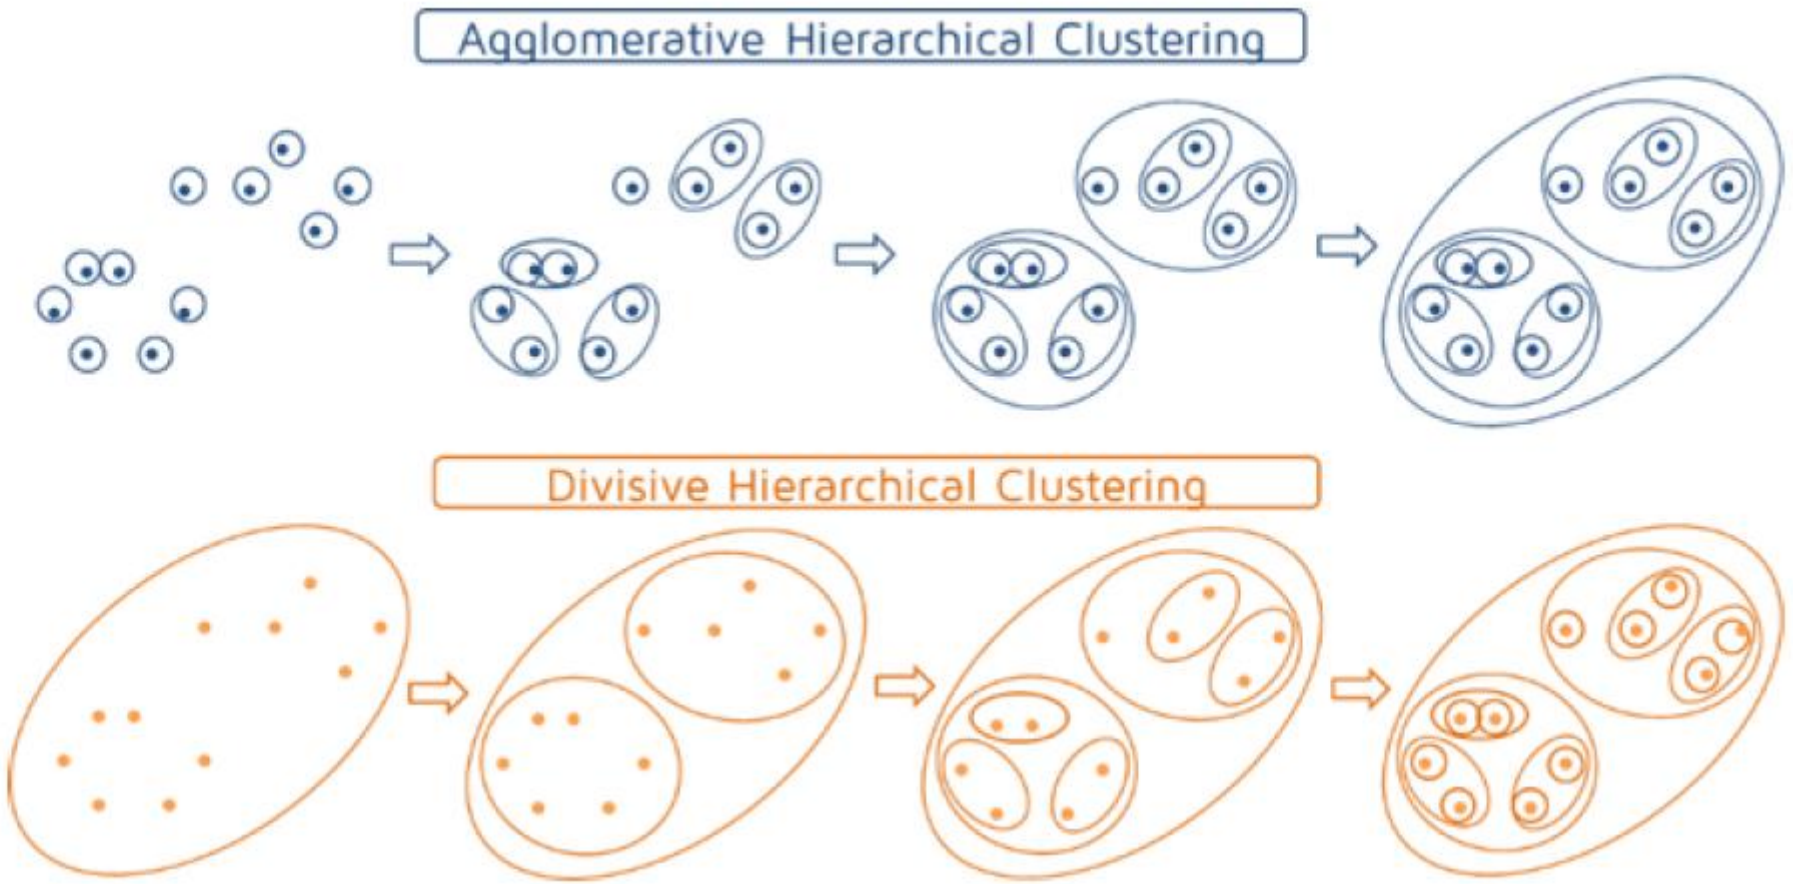


Gráfico de proceso de los tipos de agrupamiento

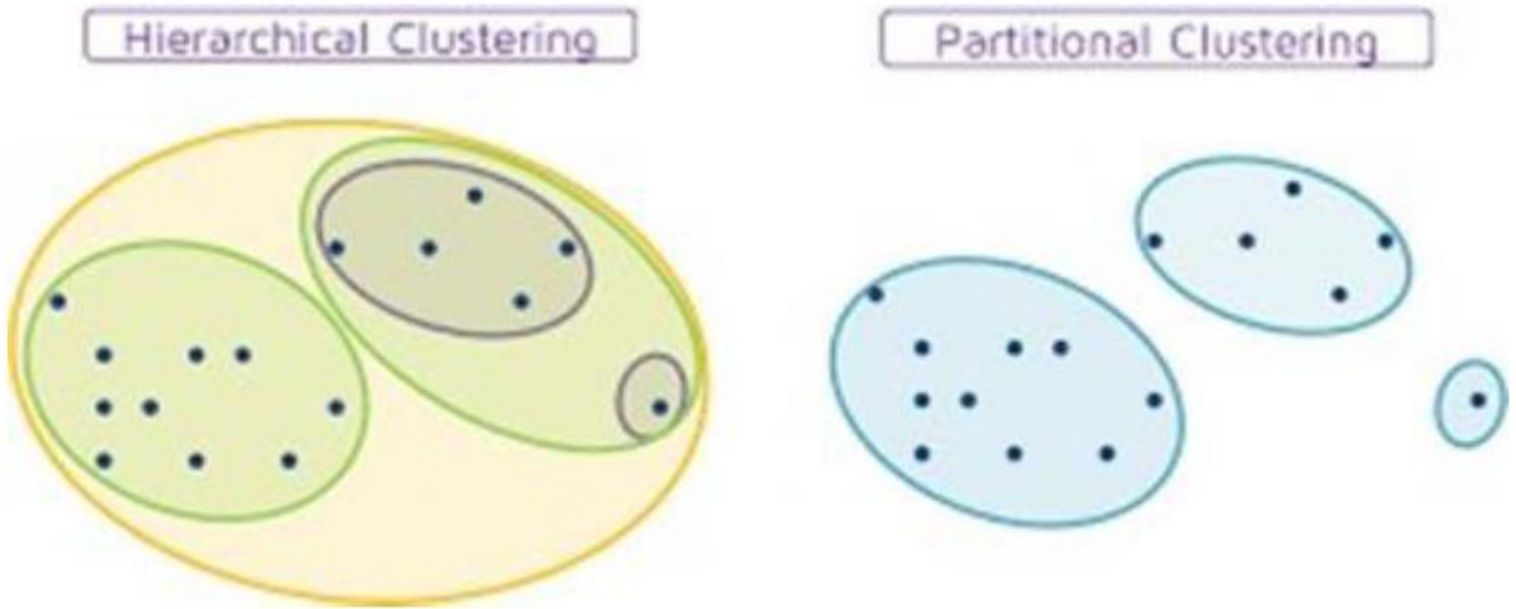
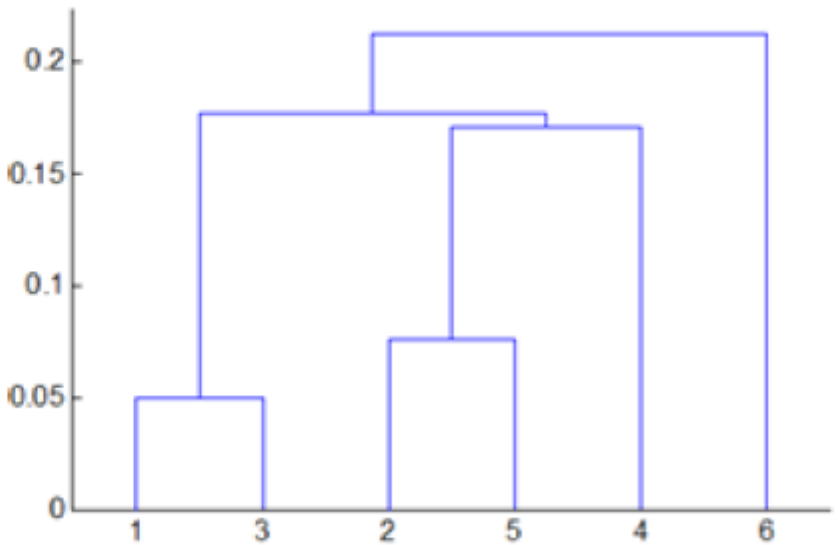
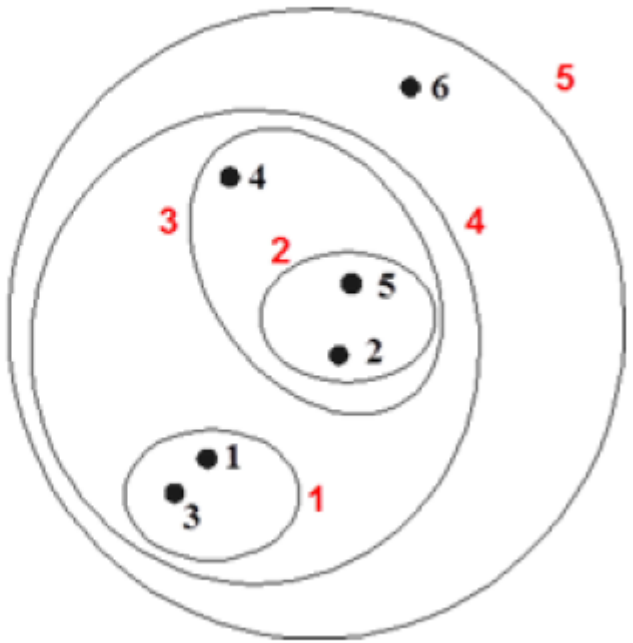
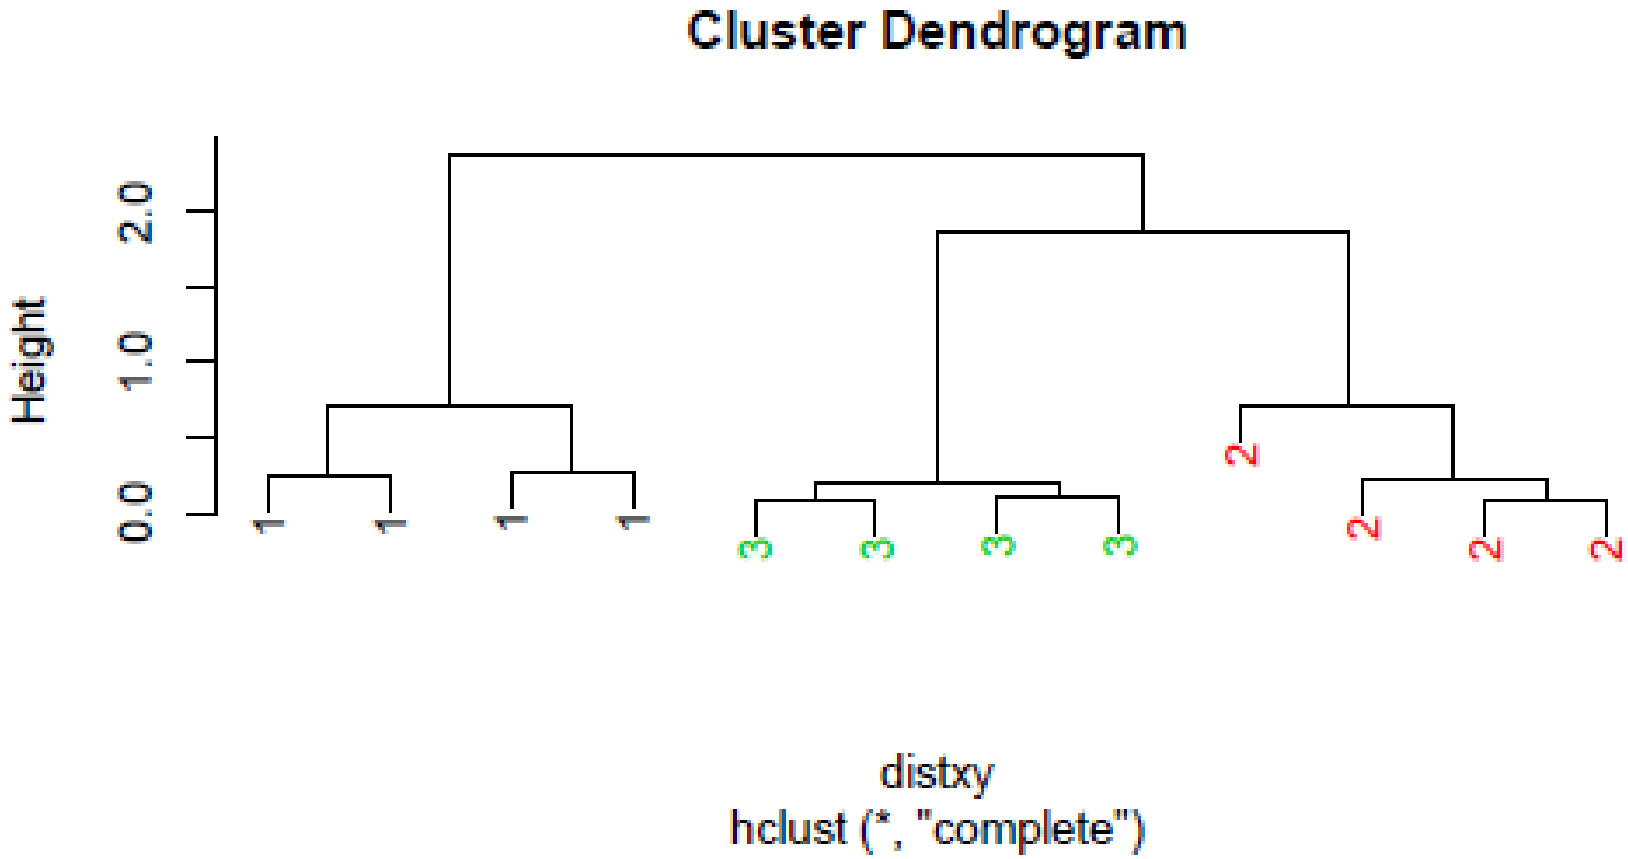


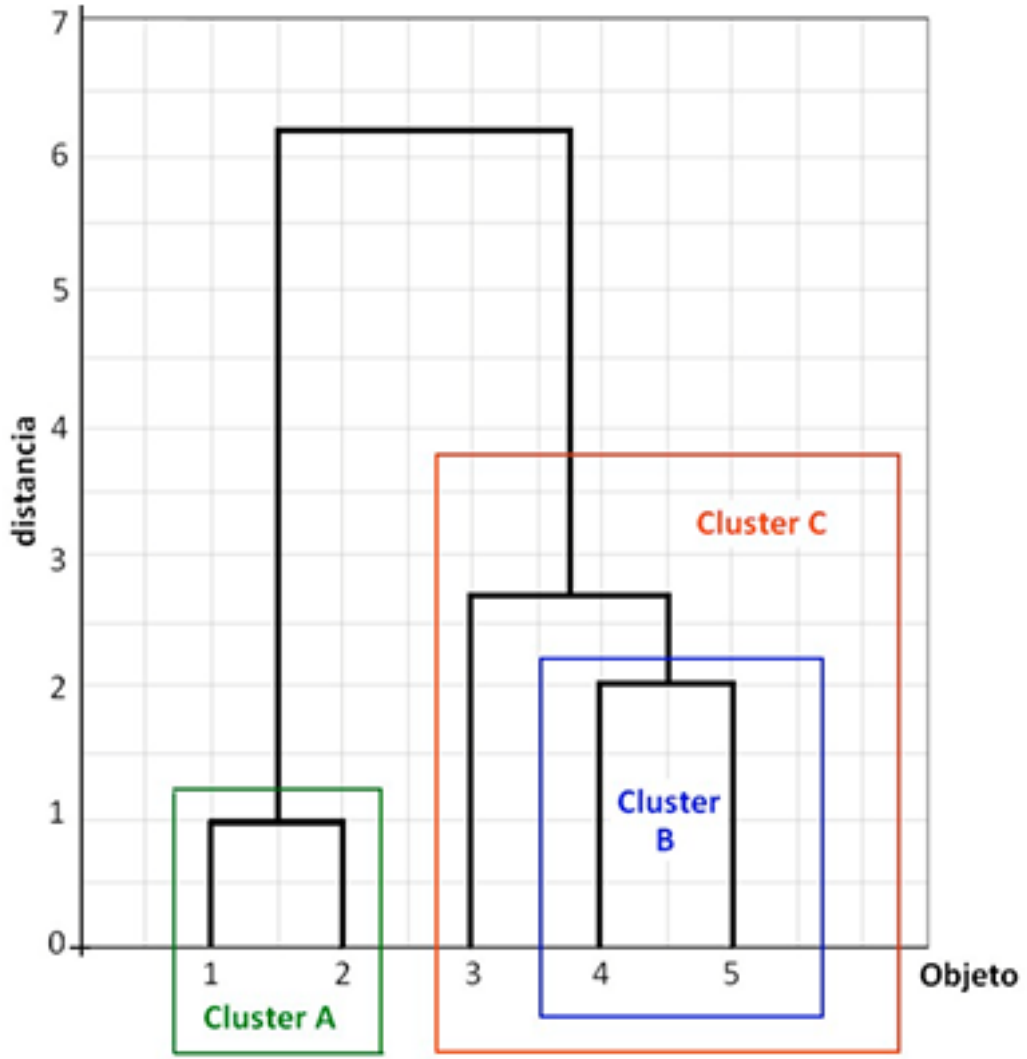
Gráfico de un agrupamiento jerárquico



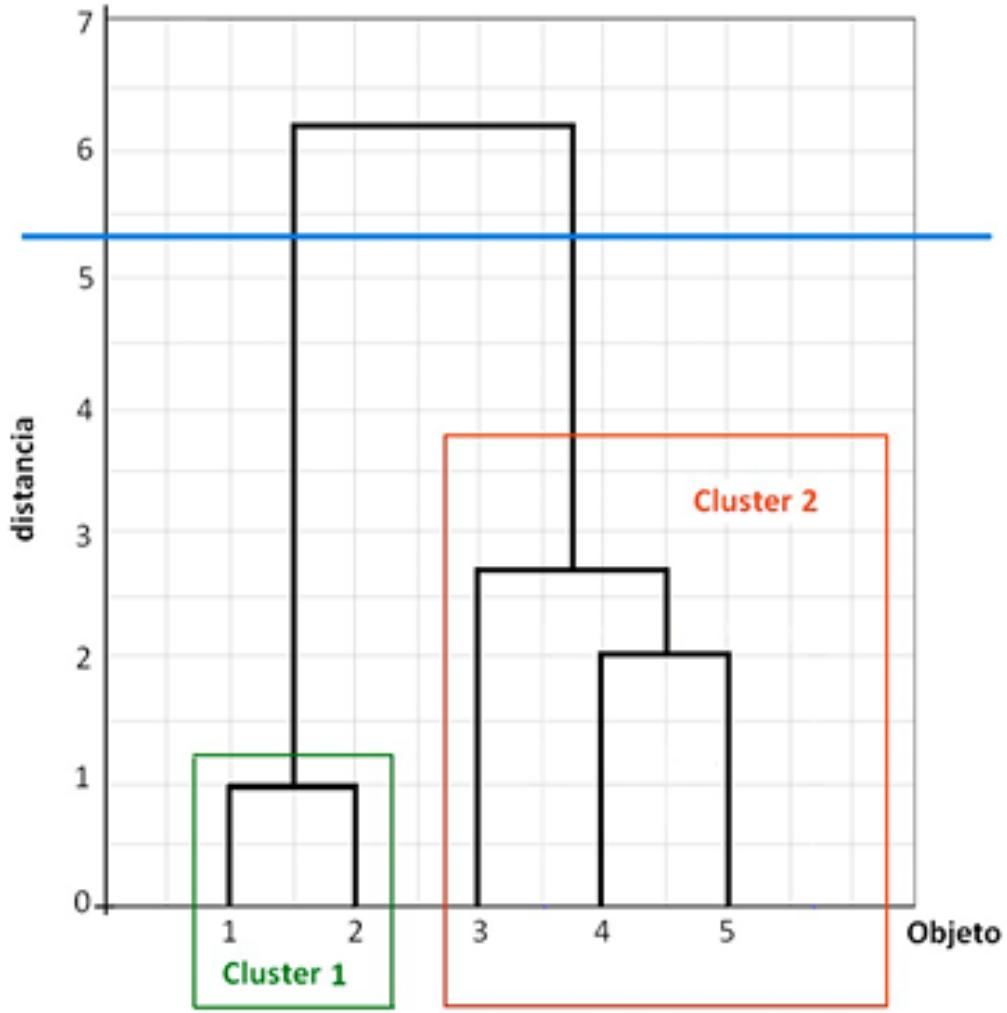


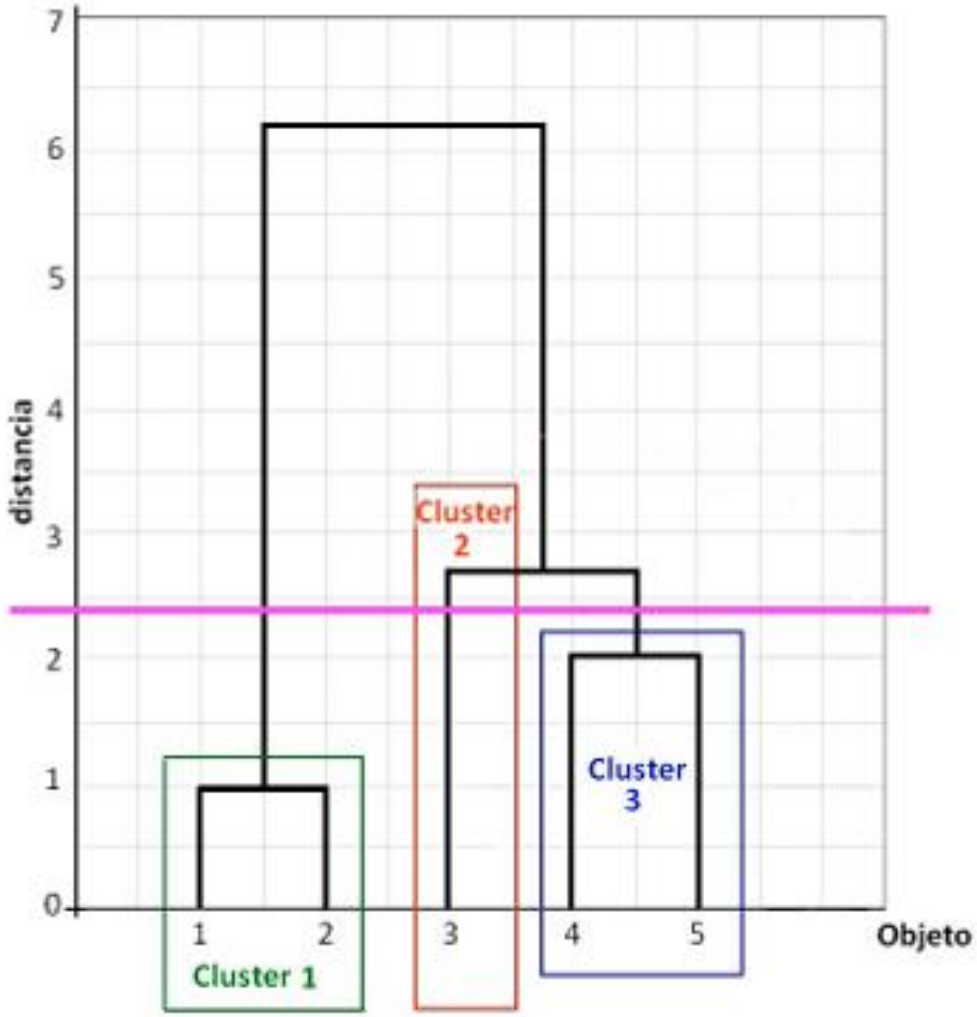
Se busca…


Cluster Dendrogram
Height
0.0
1.0
2.0
1
1
1
1
3
3
3
3
2
2
2
2
distxy
hclust (*, "complete")


7
6
5
4
3
2
1
0
distancia
Cluster C
Cluster
B
1
2
3
4
5
Objeto
Cluster A

Se fija distancia → corte y cantidad de clusters





Cantidad de cluster

- Cluster jerárquico se puede utilizar en la primera etapa para ver la estructura y definir la cantidad de clusters de kmedias (2da etapa).
- Se puede usar para casos o variables.
- Cercanía en cuanto la distancia (no la dirección)

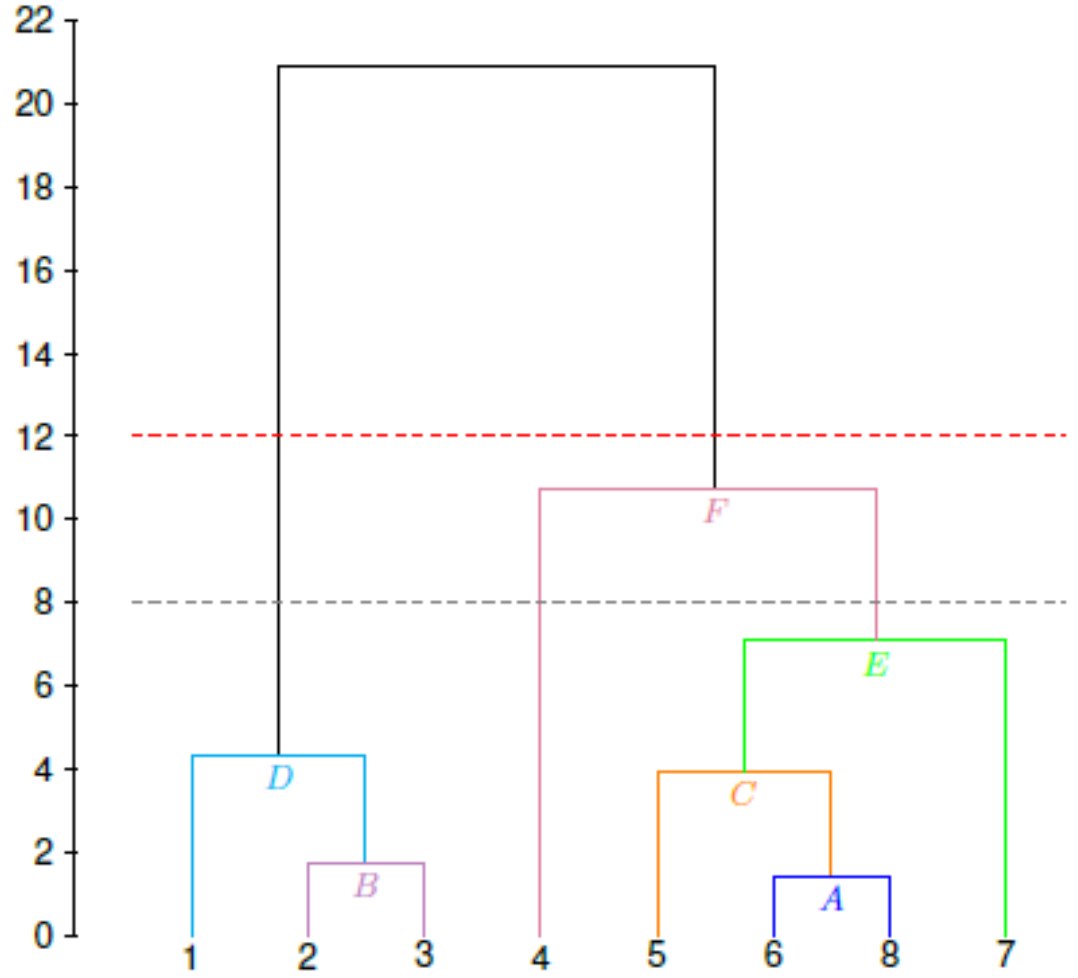


Figura 10.12: Dendograma con elección de cantidad de *clusters*

	CCAA	Nº Cines	Nº Películas	Nº espectadores Películas Españolas	Nº espectadores Películas Extranjeras	Recaudación (miles pesetas)
1	Andalucía	448	330	1380202	13976149	7709721
2	Aragón	76	310	580526	3513294	2370874
3	Asturias	55	383	207100	1524423	1000709
4	Baleares	68	523	280851	2081987	1496299
5	Canarias	94	394	345213	4056725	2288764
6	Cantabría	26	315	190540	1149257	847231
7	Cast. Mancha	211	295	1049698	5319556	3464668
8	Cast. León	102	234	404716	2406798	1490303
9	Cataluña	585	502	2179229	19324988	14234196
10	Valencia	300	435	1267581	9849692	6061359
11	Extremadura	69	309	226139	1614986	912405
12	Galicia	166	341	570921	4465381	2680531
13	Madrid	474	764	3188742	1926469	15282573
14	Murcia	88	358	326445	2669391	1647870
15	Navarra	37	441	245750	1403940	981839
16	País Vasco	171	385	730241	5277214	3673712
17	La Rioja	22	309	120135	769674	526496
		2992	6.628	13.294.029	81.329.924	66.669.550

Ejemplo: Espectarores de películas y comunidad

Ejemplo: Espectarores de películas y comunidad

Las Comunidades Autónomas españolas se rán clasificadas considerando
N° Cines (ZCinesR),
N° Películas proyectadas (ZPeliculasR),
N° de espectadores de películas españolas (ZPelis_EspañaR),
N°de espectadores de películas extranjeras (ZPelis_ExtranR)
Recaudación total

Generadas:
Gasto medio por espectador (ZGasto_medio).
% de Películas extranjeras del total

	CCAA	Nº Cines	Nº Películas	Nº espectadores Películas Españolas	Nº espectadores Películas Extranjeras	Recaudación (miles pesetas)
1	Andalucía	448	330	1380202	13976149	7709721
2	Aragón	76	310	580526	3513294	2370874
3	Asturias	55	383	207100	1524423	1000709
4	Baleares	68	523	280851	2081987	1496299
5	Canarias	94	394	345213	4056725	2288764
6	Cantabría	26	315	190540	1149257	847231
7	Cast. Mancha	211	295	1049698	5319556	3464668
8	Cast. León	102	234	404716	2406798	1490303
9	Cataluña	585	502	2179229	19324988	14234196
10	Valencia	300	435	1267581	9849692	6061359
11	Extremadura	69	309	226139	1614986	912405
12	Galicia	166	341	570921	4465381	2680531
13	Madrid	474	764	3188742	1926469	15282573
14	Murcia	88	358	326445	2669391	1647870
15	Navarra	37	441	245750	1403940	981839
16	País Vasco	171	385	730241	5277214	3673712
17	La Rioja	22	309	120135	769674	526496
		2992	6.628	13.294.029	81.329.924	66.669.550

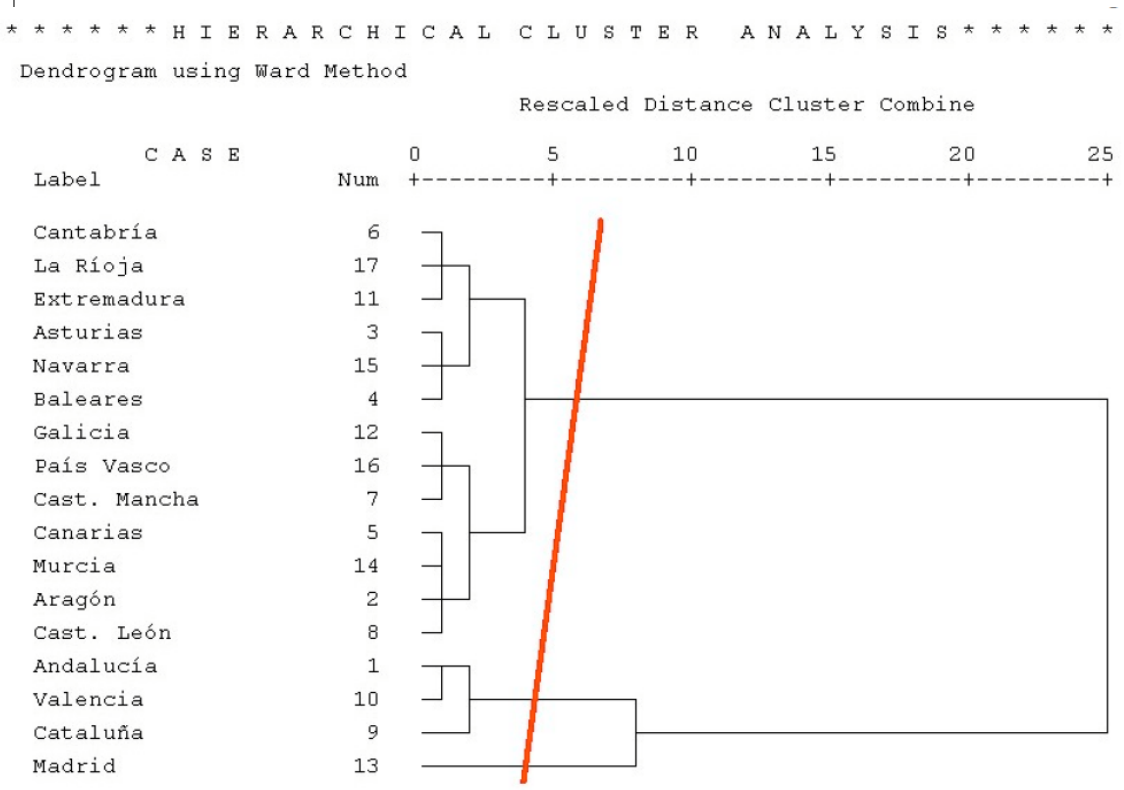
Procedimiento

- Estandarizar las variables, ya que tienen diferentes escalas
- Clasificar casos en base a las variables

	CCAA	ZCinesR	ZPeliculasR	ZPelis_EspañaR	ZPelis_ExtranR	ZGasto_medio
1	Andalucía	1,5409	- 0,4846	0,9484	1,8129	1,7626
2	Aragón	- 0,5340	- 0,6803	- 0,0792	- 0,1008	- 0,2651
3	Asturias	- 0,7510	0,0071	- 0,8428	- 0,7576	- 0,6904
4	Baleares	- 0,6126	1,1620	- 0,6565	- 0,5438	- 0,5767
5	Canarias	- 0,3711	0,1048	- 0,5132	0,0427	- 0,2096
6	Cantabría	- 1,1372	- 0,6308	- 0,8890	- 0,9245	- 0,7609
7	Cast. Mancha	0,4341	- 0,8313	0,5744	0,3427	0,1446
8	Cast. León	- 0,3037	- 1,4890	- 0,3922	- 0,4324	- 0,4959
9	Cataluña	2,0444	0,9996	1,6984	2,4879	2,8694
10	Valencia	0,8999	0,4575	0,8265	1,1969	0,9994
11	Extremadura	- 0,6025	- 0,6903	- 0,7919	- 0,7205	- 0,6706
12	Galicia	0,1604	- 0,3795	- 0,0950	0,1443	- 0,0954

	CCAA	Nº Cines	Nº Películas	Nº espectadores Películas Españolas	Nº espectadores Películas Extranjeras	Recaudación (miles pesetas)
1	Andalucía	448	330	1380202	13976149	7709721
2	Aragón	76	310	580526	3513294	2370874
3	Asturias	55	383	207100	1524423	1000709
4	Baleares	68	523	280851	2081987	1496299
5	Canarias	94	394	345213	4056725	2288764
6	Cantabría	26	315	190540	1149257	847231
7	Cast. Mancha	211	295	1049698	5319556	3464668
8	Cast. León	102	234	404716	2406798	1490303

2
7
1
5
9



Interpretacion de resultados

CARACTERÍSTICAS DE CADA CONGLOMERADO

CLU3_1		Cines	Peliculas	Pelis_España	Pelis_Extran	Recaudación
1	Media	444,33	422,33	1609004,00	14383609,67	9335092,00
	N	3	3	3	3	3
	Desv. típ.	142,535	86,697	497029,461	4750771,171	4322058,459
	Máximo	585	502	2179229	19324988	14234196
	Mínimo	300	330	1267581	9849692	6061359
	% de la suma total	44,6%	19,1%	36,3%	53,1%	42,0%
2	Media	91,15	353,62	406021,15	2788663,54	1798592,38
	N	13	13	13	13	13
	Desv. típ.	58,452	73,656	262767,108	1577430,521	1018943,994
	Máximo	211	523	1049698	5319556	3673712
	Mínimo	22	234	120135	769674	526496
	% de la suma total	39,6%	69,4%	39,7%	44,6%	35,1%
3	Media	474,00	764,00	3188742,00	1926469,00	15282573,00
	N	1	1	1	1	1
	Desv. típ.	.	.	.	.	.
	Máximo	474	764	3188742	1926469	15282573
	Mínimo	474	764	3188742	1926469	15282573
	% de la suma total	15,8%	11,5%	24,0%	2,4%	22,9%
Total	Media	176,00	389,88	782001,71	4784113,18	3921738,24
	N	17	17	17	17	17
	Desv. típ.	173,210	122,566	829326,923	5070625,437	4509724,440
	Máximo	585	764	3188742	19324988	15282573
	Mínimo	22	234	120135	769674	526496
	% de la suma total	100,0%	100,0%	100,0%	100,0%	100,0%

Andalucía, Cataluña, Valencia

Aragón, Asturias, Baleares, Canarias, Cantabria, Castilla_La Mancha, Castilla_León, Extremadura, Galicia, Murcia, País Vasco, La Rioja

Madrid

Interpretacion de resultados por cluster

CARACTERÍSTICAS DE CADA CONGLOMERADO

CLU3_1		Cines	Peliculas	Pelis_España	Pelis_Extran	Recaudación
1	Media	444,33	422,33	1609004,00	14383609,67	9335092,00
	N	3	3	3	3	3
	Desv. típ.	142,535	86,697	497029,461	4750771,171	4322058,459
	Máximo	585	502	2179229	19324988	14234196
	Mínimo	300	330	1267581	9849692	6061359
	% de la suma total	44,6%	19,1%	36,3%	53,1%	42,0%
2	Media	91,15	353,62	406021,15	2788663,54	1798592,38
	N	13	13	13	13	13
	Desv. típ.	58,452	73,656	262767,108	1577430,521	1018943,994
	Máximo	211	523	1049698	5319556	3673712
	Mínimo	22	234	120135	769674	526496
	% de la suma total	39,6%	69,4%	39,7%	44,6%	35,1%
3	Media	474,00	764,00	3188742,00	1926469,00	15282573,00
	N	1	1	1	1	1
	Desv. típ.	.	.	.	.	.
	Máximo	474	764	3188742	1926469	15282573
	Mínimo	474	764	3188742	1926469	15282573
	% de la suma total	15,8%	11,5%	24,0%	2,4%	22,9%
Total	Media	176,00	389,88	782001,71	4784113,18	3921738,24
	N	17	17	17	17	17
	Desv. típ.	173,210	122,566	829326,923	5070625,437	4509724,440
	Máximo	585	764	3188742	19324988	15282573
	Mínimo	22	234	120135	769674	526496
	% de la suma total	100,0%	100,0%	100,0%	100,0%	100,0%

- **El primer conglomerado**, formado por tres Comunidades Autónomas, presenta una cuota de pantalla de películas españolas (películas españolas/total de espectadores) del 10%. El gasto medio por espectador es de 584.
- **El segundo conglomerado**, formado por trece Comunidades Autónomas, destaca por el pequeño número de salas de cine (por debajo de la media nacional), siendo la que menos películas estrena, presenta una cuota de pantalla de películas españolas (películas españolas/total de espectadores) del 12,7%. El gasto medio por espectador es de 563, el más bajo de todos los conglomerados.
- **El tercer conglomerado**, formado por una Comunidad Autónoma (Madrid), presenta una cuota de pantalla de películas españolas (películas españolas/total de espectadores) del 62,3%, el más alto de todos los conglomerados. El gasto medio por espectador es de 2988, el más alto de los conglomerados.

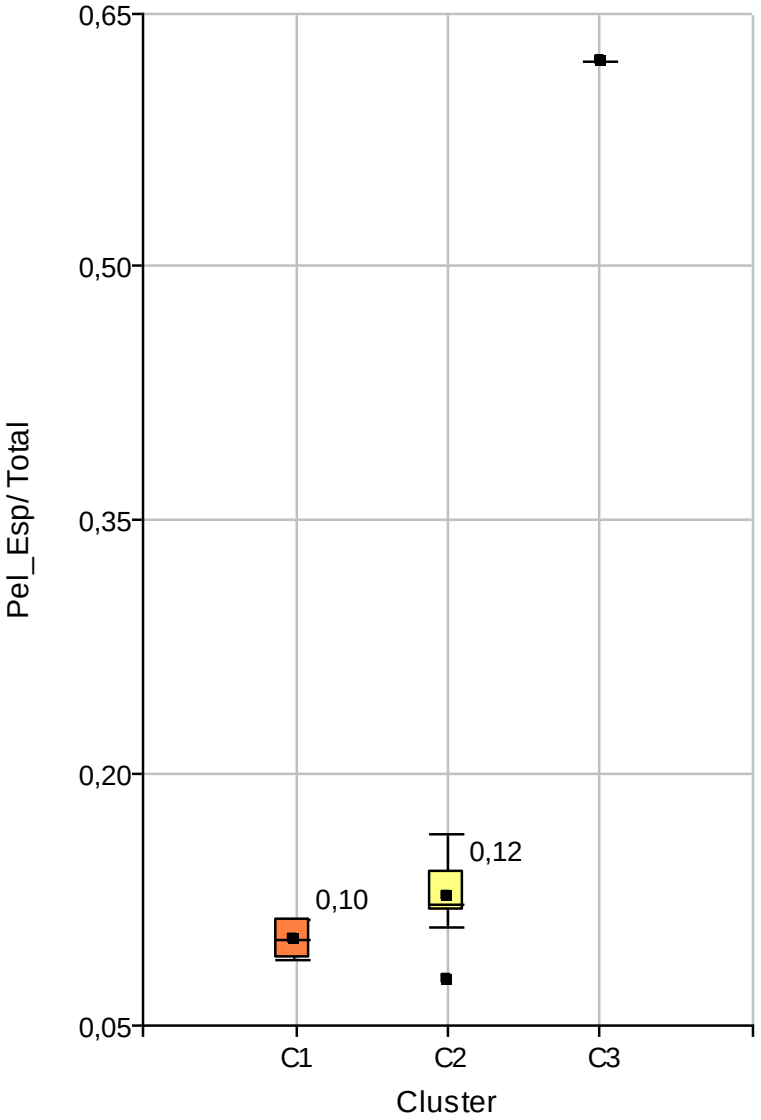
Interpretacion de resultados por cluster

			Espectadores					
CCAA	Nº Cines	Nº Películas	Películas Españolas	Películas Extranjeras	Recaudación	Gasto por espectador	Pel_Esp/ Total	Cluster
Andalucí-a	448	330	1.380.202	13.976.149	7.709.721	502	9,0%	C1
Aragón	76	310	580.526	3.513.294	2.370.874	579	14,2%	C2
Asturias	55	383	207.100	1.524.423	1.000.709	578	12,0%	C2
Baleares	68	523	280.851	2.081.987	1.496.299	633	11,9%	C2
Canarias	94	394	345.213	4.056.725	2.288.764	520	7,8%	C2
Cantabria	26	315	190.540	1.149.257	847.231	632	14,2%	C2
Cast. Mancha	211	295	1.049.698	5.319.556	3.464.668	544	16,5%	C2
Cast. Leon	102	234	404.716	2.406.798	1.490.303	530	14,4%	C2
Cataluña	585	502	2.179.229	19.324.988	14.234.196	662	10,1%	C1
Valencia	300	435	1.267.581	9.849.692	6.061.359	545	11,4%	C1
Extremadura	69	309	226.139	1.614.986	912.405	496	12,3%	C2
Galicia	166	341	570.921	4.465.381	2.680.531	532	11,3%	C2
Madrid	474	764	3.188.742	1.926.469	15.282.573	2.988	62,3%	C3
Murcia	88	358	326.445	2.669.391	1.647.870	550	10,9%	C2
Navarra	37	441	245.750	1.403.940	981.839	595	14,9%	C2
País Vasco	171	385	730.241	5.277.214	3.673.712	612	12,2%	C2
La Rioja	22	309	120.135	769.674	526.496	592	13,5%	C2

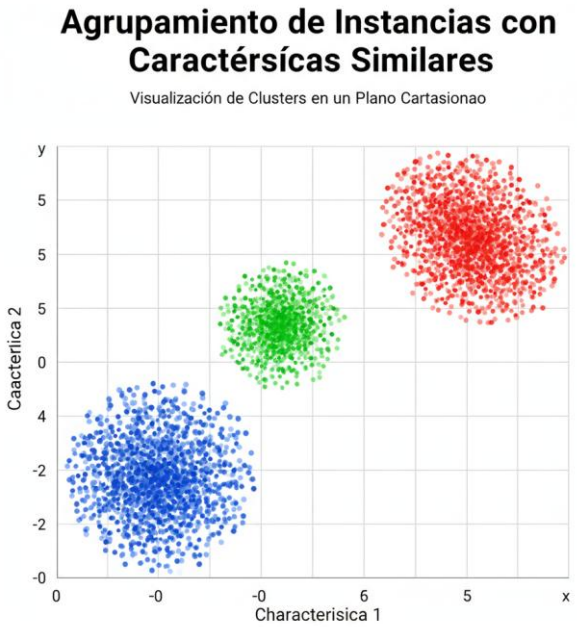
- **El primer conglomerado**, formado por tres Comunidades Autónomas, presenta una cuota de pantalla de películas españolas (películas españolas/total de espectadores) del 10%. El gasto medio por espectador es de 584.
- **El segundo conglomerado**, formado por trece Comunidades Autónomas, destaca por el pequeño número de salas de cine (por debajo de la media nacional), siendo la que menos películas estrena, presenta una cuota de pantalla de películas españolas (películas españolas/total de espectadores) del 12,7%. El gasto medio por espectador es de 563, el más bajo de todos los conglomerados.
- **El tercer conglomerado**, formado por una Comunidad Autónoma (Madrid), presenta una cuota de pantalla de películas españolas (películas españolas/total de espectadores) del 62,3%, el más alto de todos los conglomerados. El gasto medio por espectador es de 2988, el más alto de los conglomerados.

Resumen por cluster

Cluster	Variable	n	Media	Mín	Máx
C1	Gasto	**3**	569	502	661
C1	Pel_Esp/Total	**3**	0,1	0,09	0,11
C2	Gasto	**13**	568	495	633
C2	Pel_Esp/Total	**13**	0,13	0,08	0,16
C3	Gasto	**1**	2987	2987	2987
C3	Pel_Esp/Total	**1**	0,62	0,62	0,62

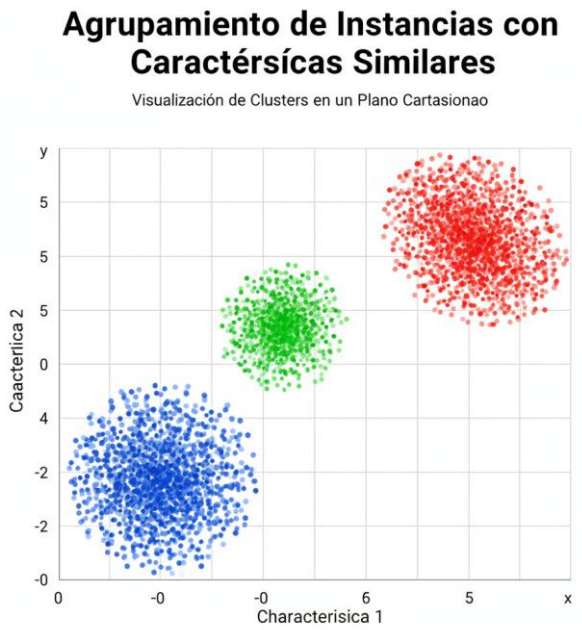


K-MEDIAS


Agrupamiento de Instancias con Caractérsícas Similares
Visualización de Clusters en un Plano Cartasionao
Caacterrica 2
Characterisica 1
y
x
5
5
5
0
4
-2
-2
-0
0
-0
-0
6
5

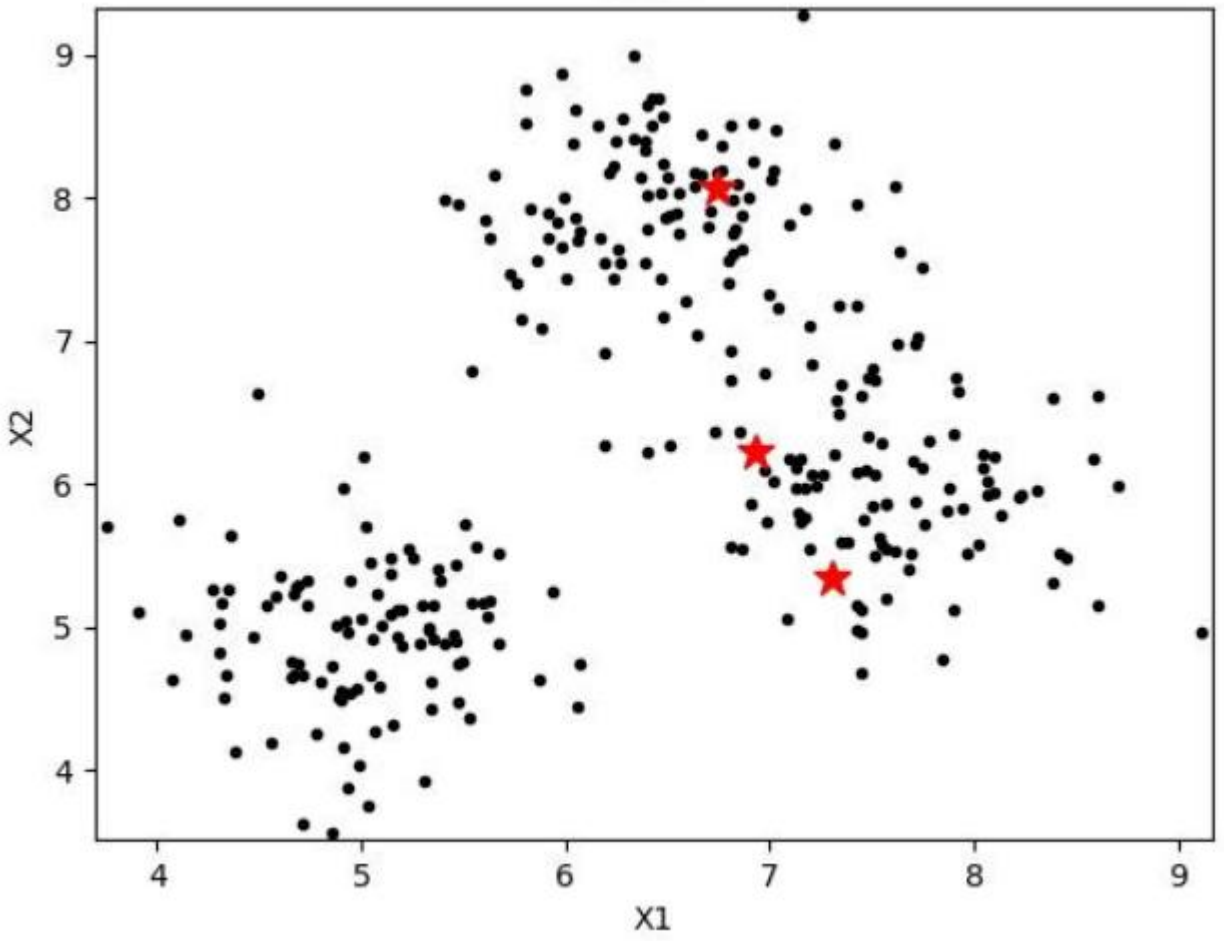
K-MEDIAS

- El algoritmo K-Medias fue propuesto por MacQueen, en 1967.
- Requiere conocer a priori el número K de grupos a formar.
- El algoritmo está basado en la minimización de la distancia interna (la suma de las distancias de los ejemplos asignados a un agrupamiento al centroide de dicho agrupamiento).
- De hecho, este algoritmo minimiza la suma de las distancias al cuadrado de cada ejemplo al centroide de su agrupamiento.

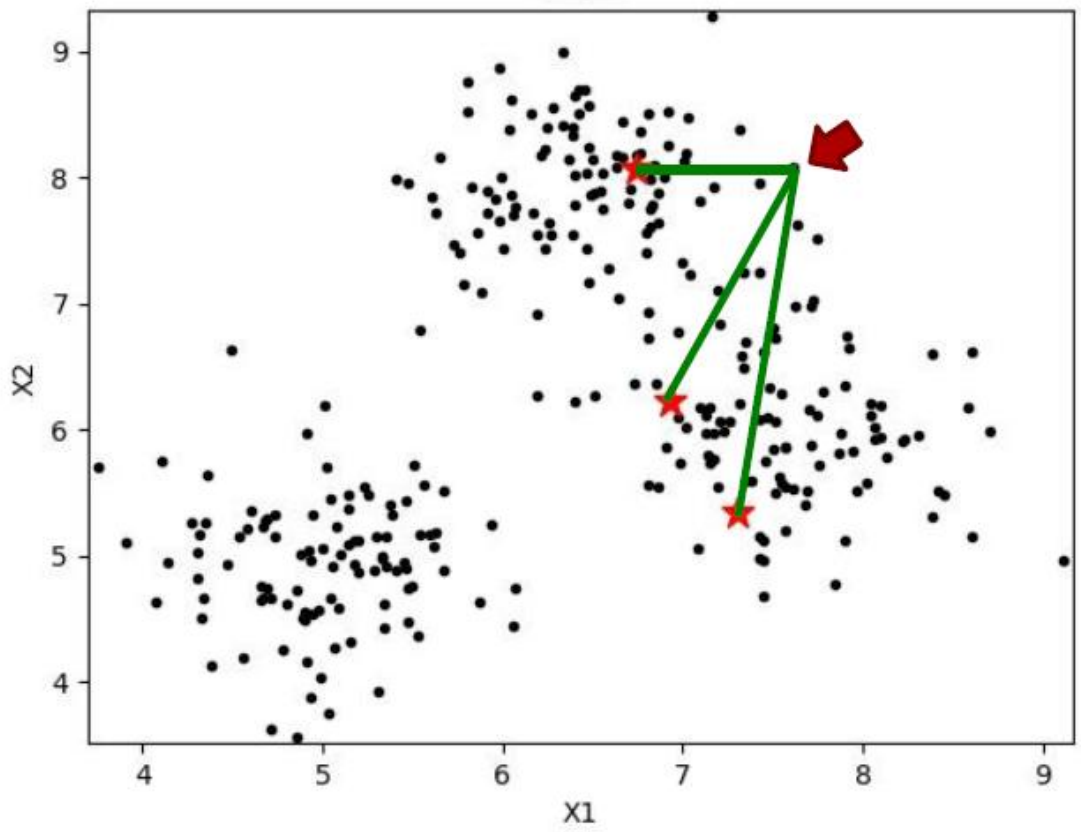


Algoritmo K-MEDIAS

- Definir k (cantidad de cluster)
- Elegir aleatoriamente K ejemplos de entrada como centros iniciales.
- Procedimiento:
  - Redistribuir los ejemplos entre los clusters utilizando la mínima distancia euclídea al cuadrado como clasificador.
  - Calcular los nuevos centros de los K clusters.
- Repetir procedimiento
  - hasta que no cambien los centros de los clusters



Procedimiento k medias



K=3

Para cada individuo se calcula la distancia al centro y se coloca en el grupo con más cercano . Luego se vuelve a calcula la media del grupo y se repite para individuo.

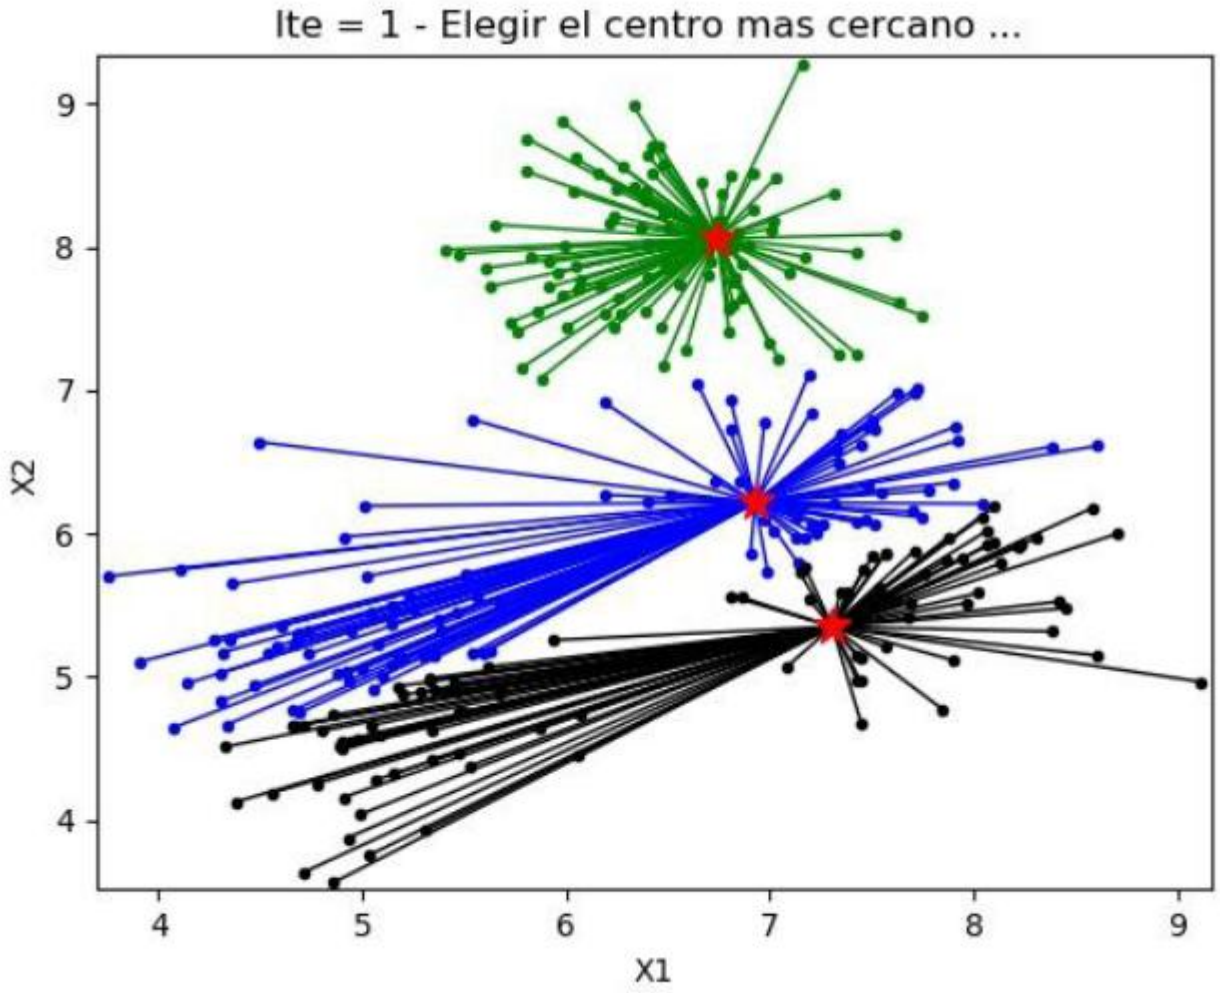
$$X = (x_1, x_2)$$

$$C_i = (c_{i1}, c_{i2}) \qquad i=1,2,3$$

$$list^2(C_i,X) = (c_{i1} - x_1)^2 + (c_{i2} - x_2)^2$$

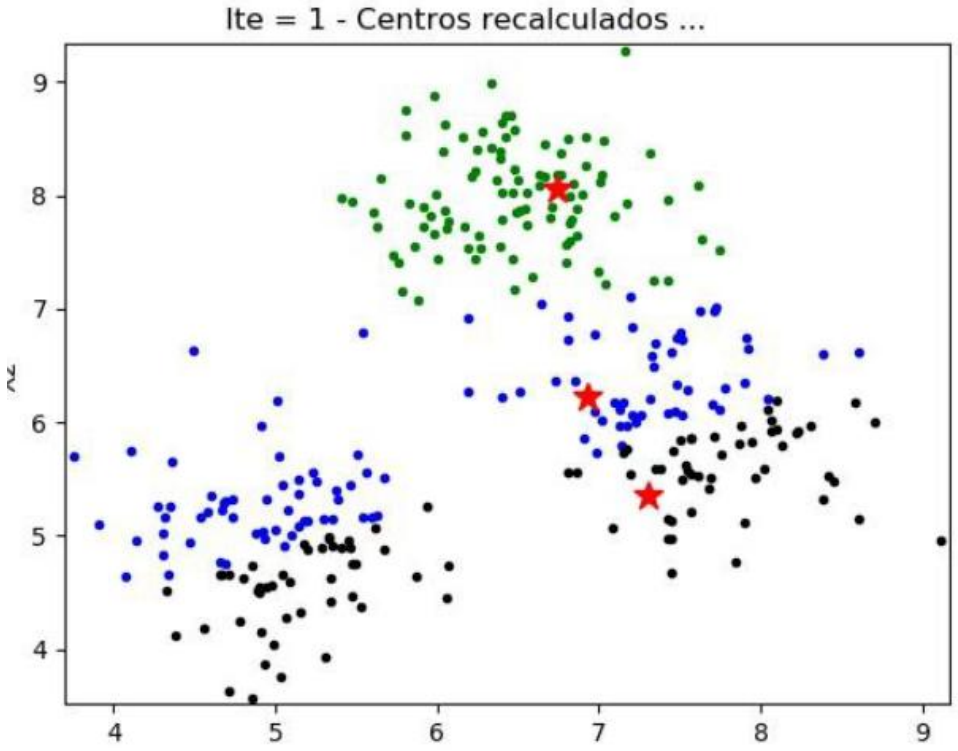
Procedimiento

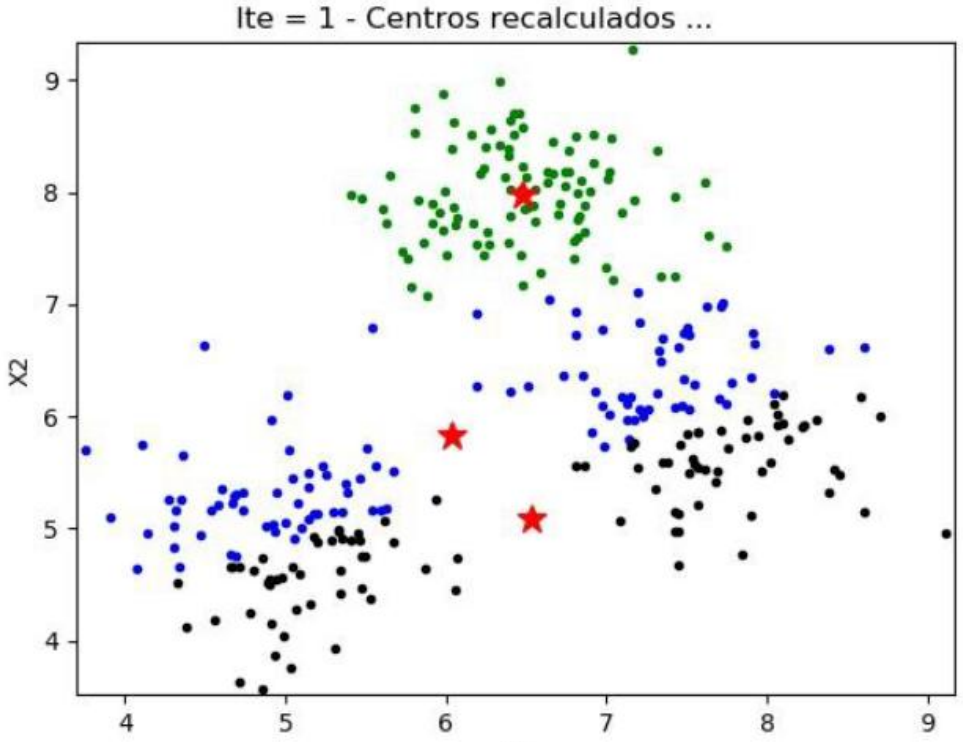
- Recalcular la posición de los centros.
- Cada centro se reubica promediando los valores de los atributos de los ejemplos que los conforman.
- Recalculo hasta que el centro no cambie

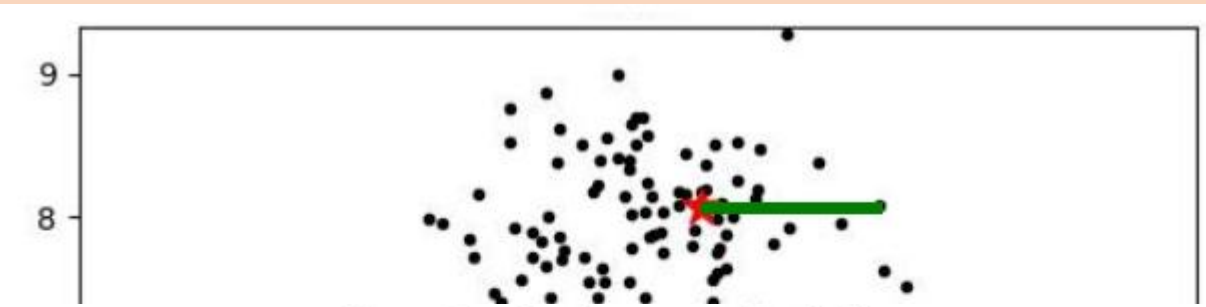


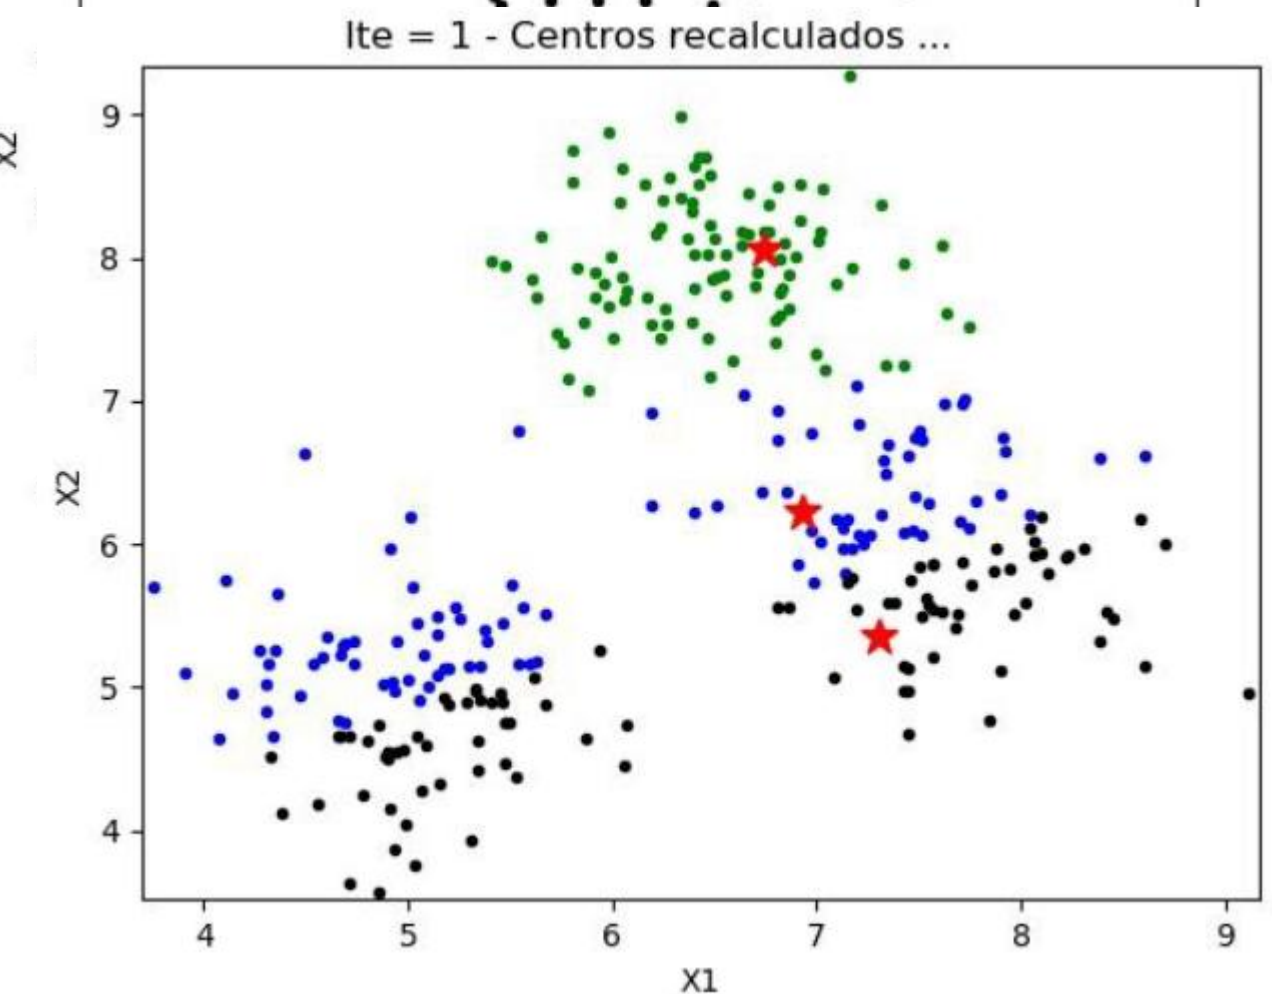
Repetir

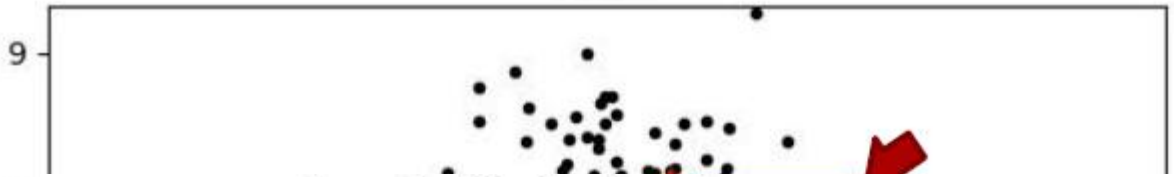
- Recalcular la posición de los centros.
- Cada centro se reubica promediando los valores de los atributos de los ejemplos que los conforman.
- Volver a asignas los ejemplos al centro más cercano y recalcular los centros

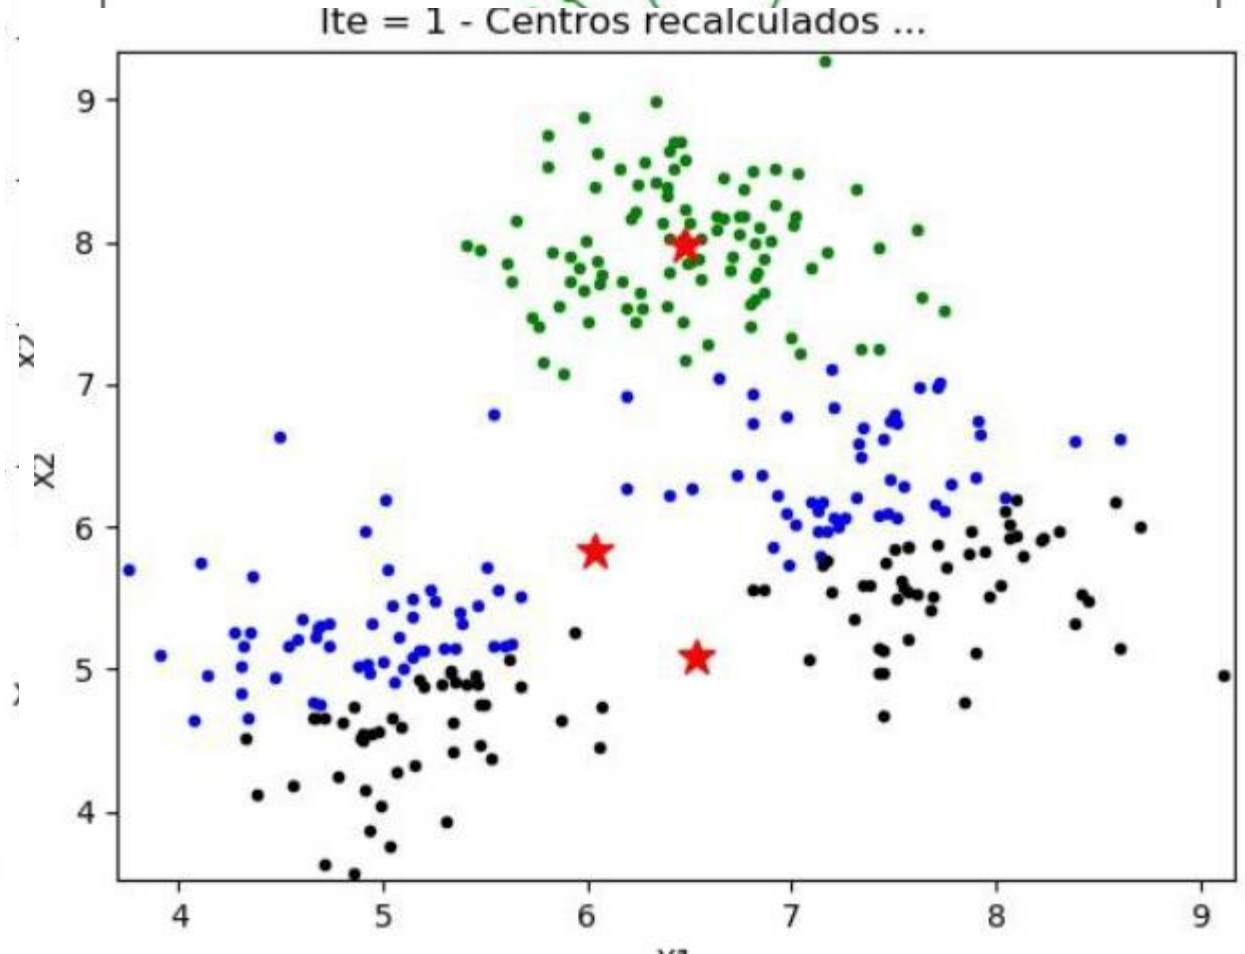


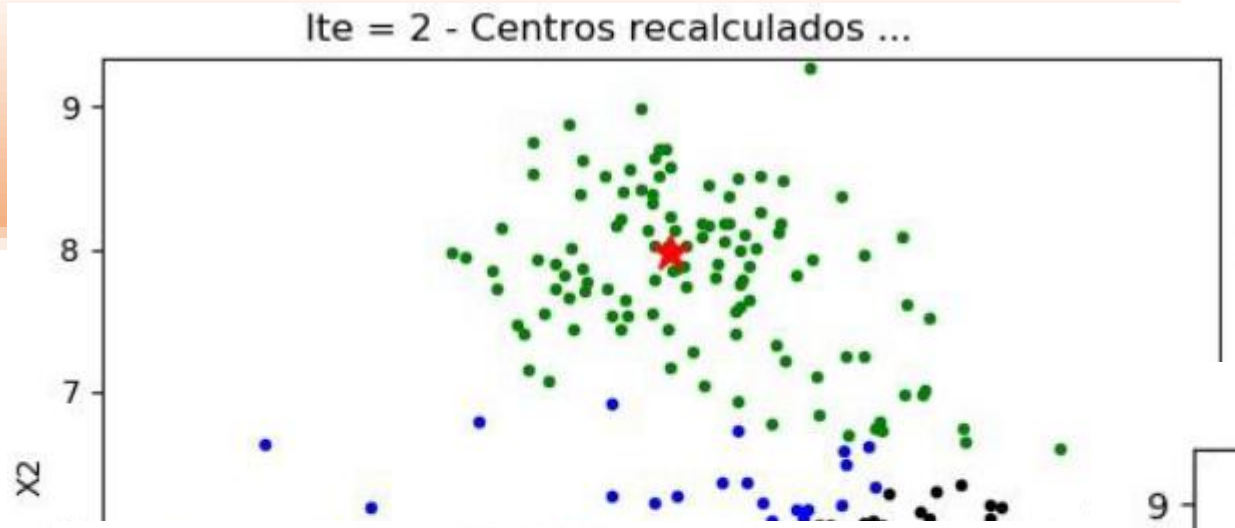




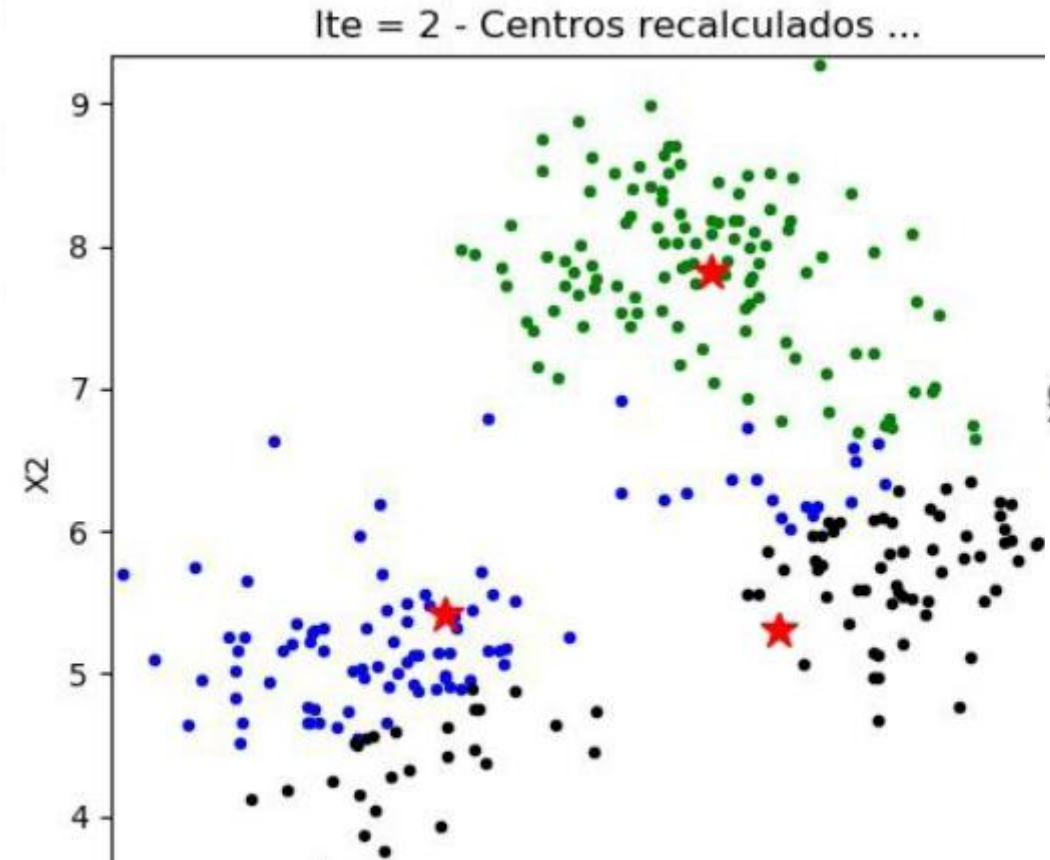

Ite = 1 - Centros recalculados ...
X1
X2

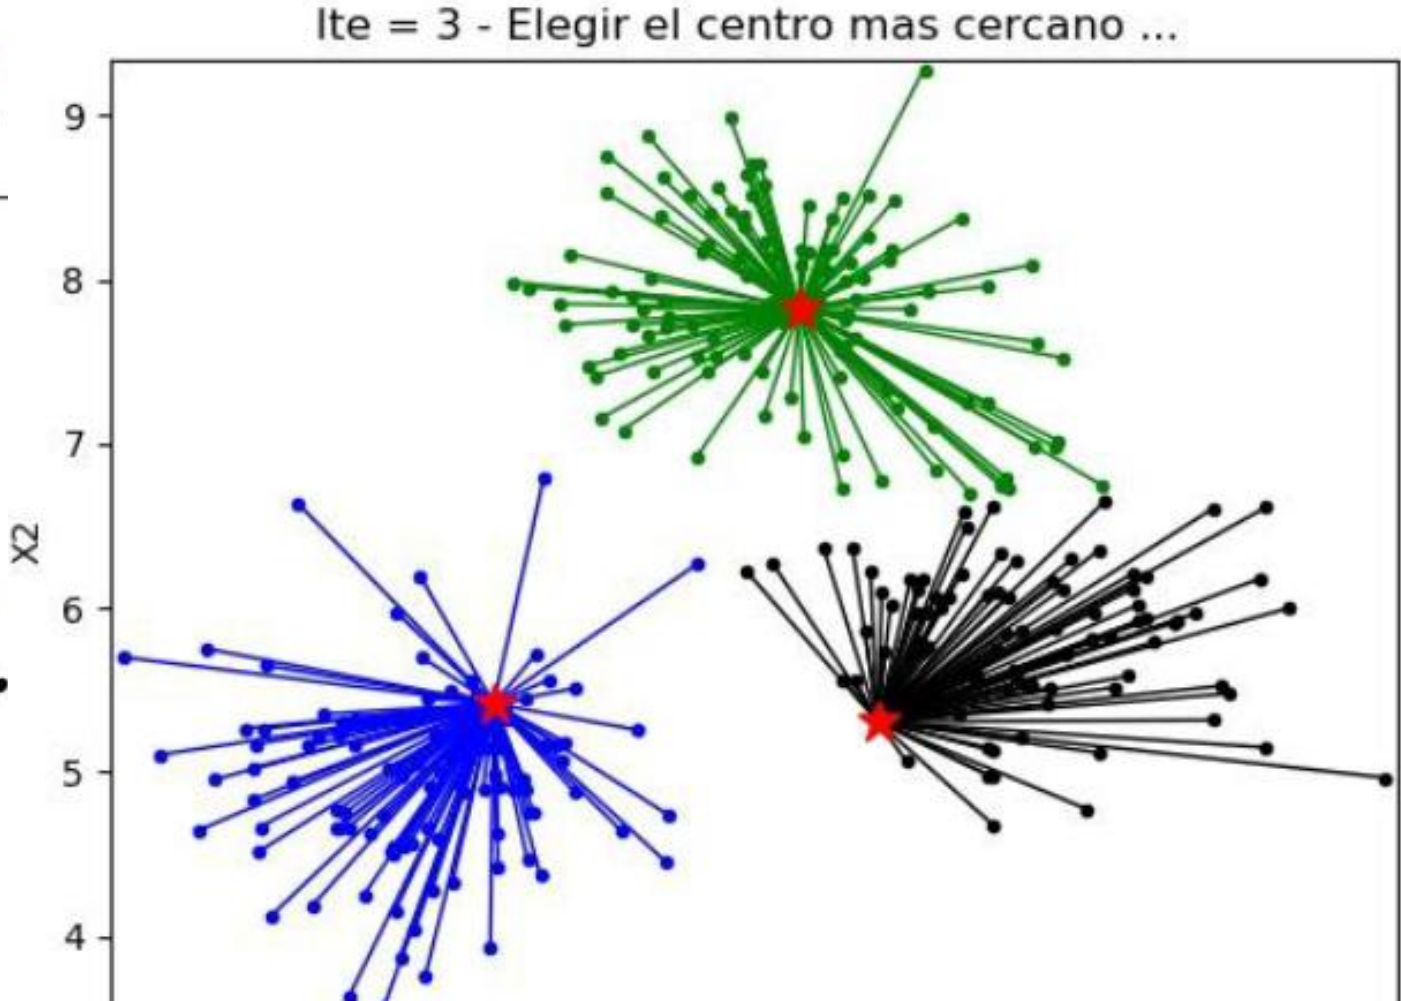

Ite = 1 - Elegir el centro mas cercano ...

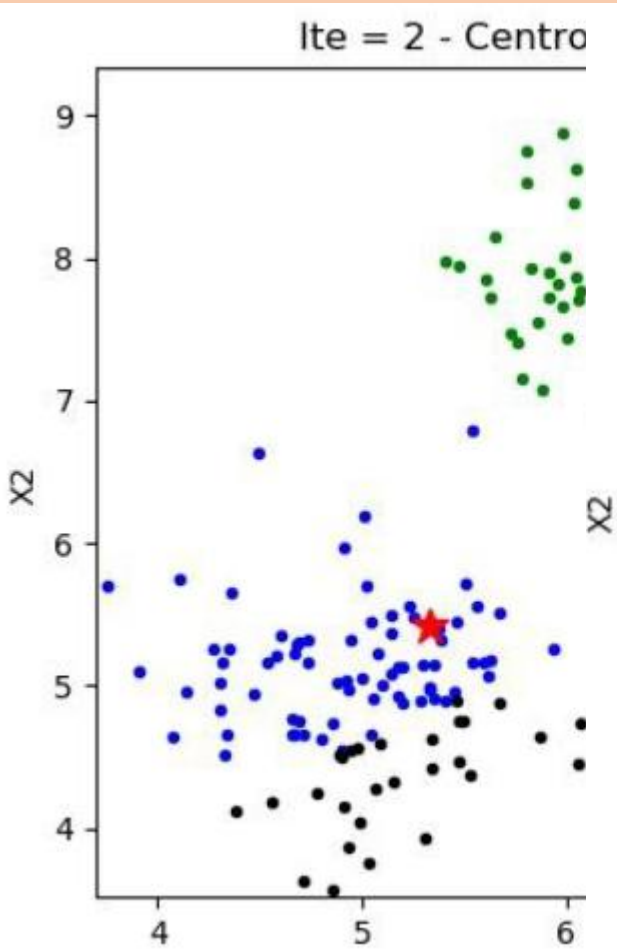

Ite = 1 - Centros recalculados ...
X2

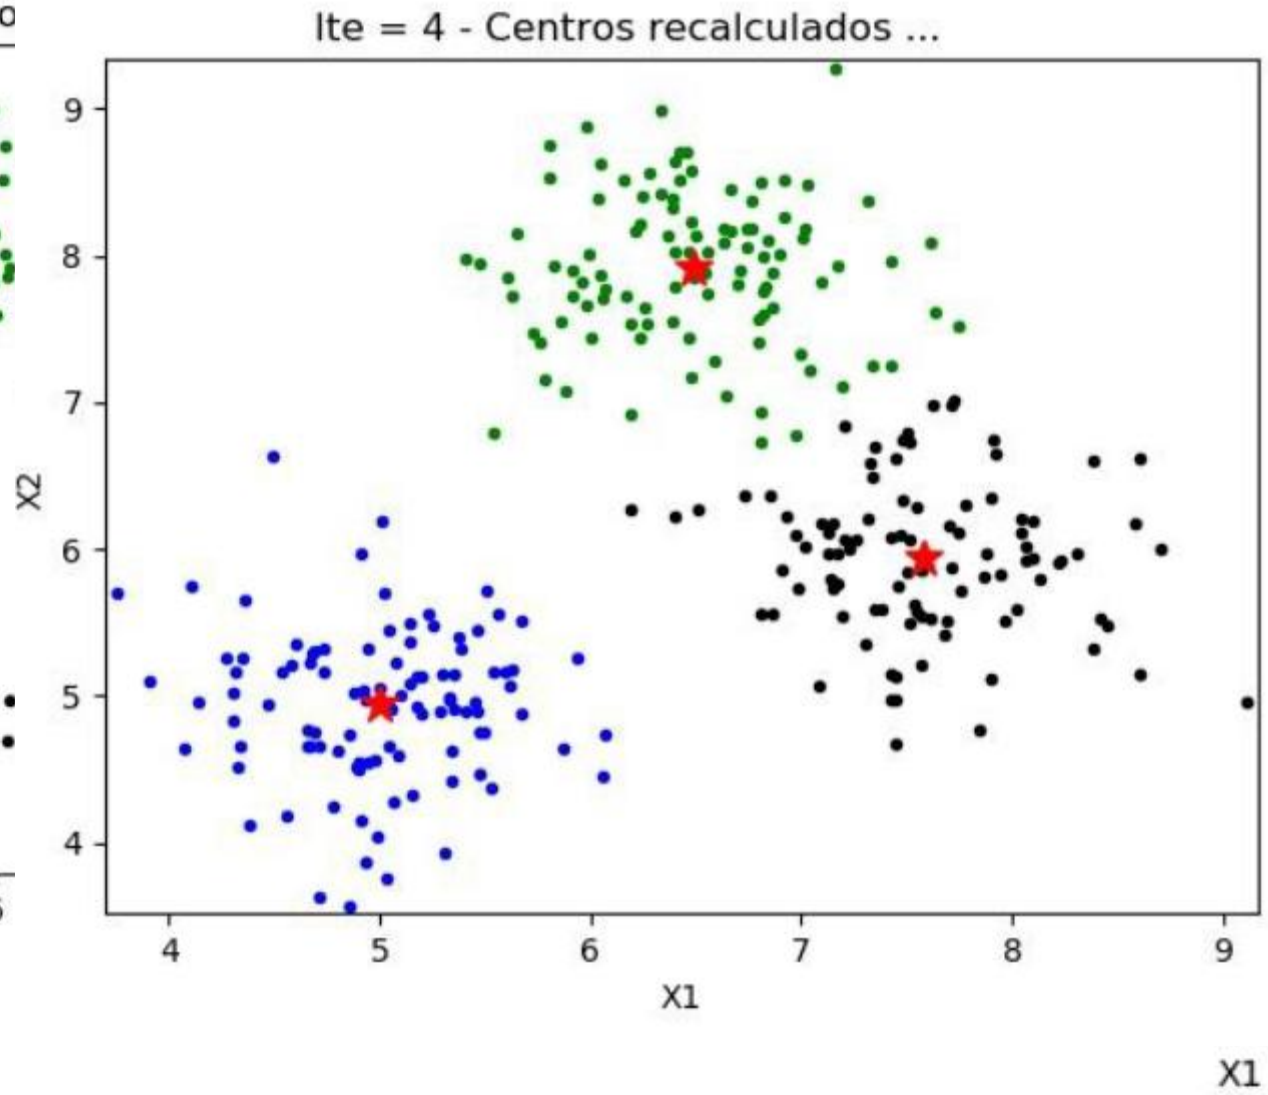

Ite = 2 - Centros recalculados ...
X2
9
8
7

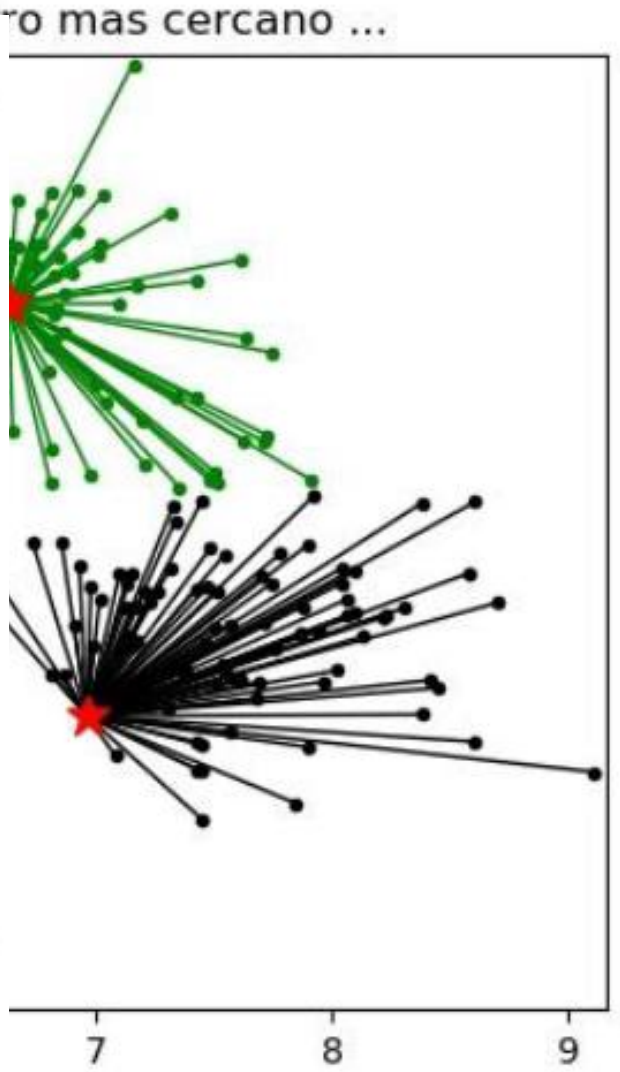

Ite = 2 - Elegir el centro mas cercano ...
9
8


Ite = 2 - Centros recalculados ...
X2
9
8
7
6
5
4


Ite = 3 - Elegir el centro mas cercano ...
X2
9
8
7
6
5
4

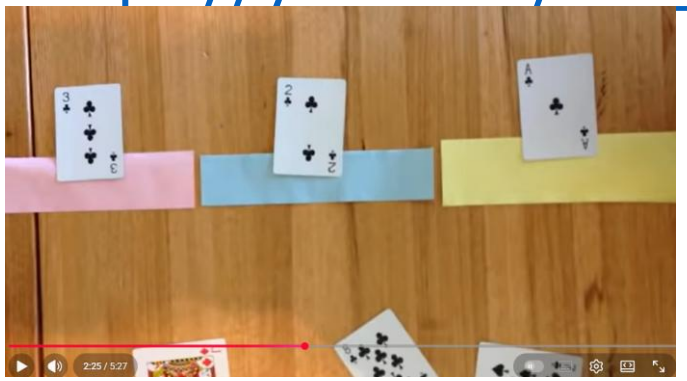

Ite = 2 - Centro
X2
9
8
7
6
5
4
4
5
6

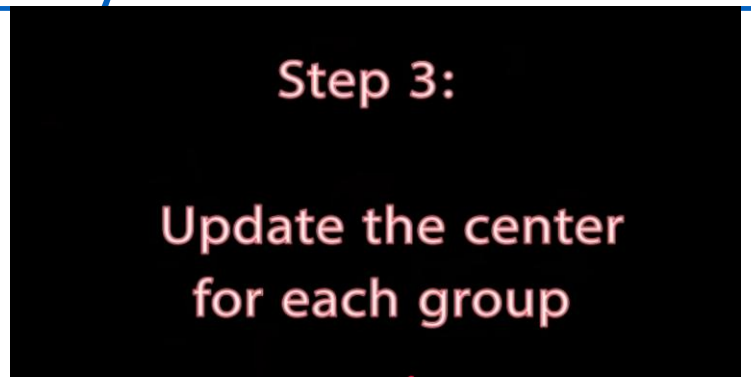

Ite = 4 - Centros recalculados ...
X2
9
8
7
6
5
4
4
5
6
7
8
9
X1

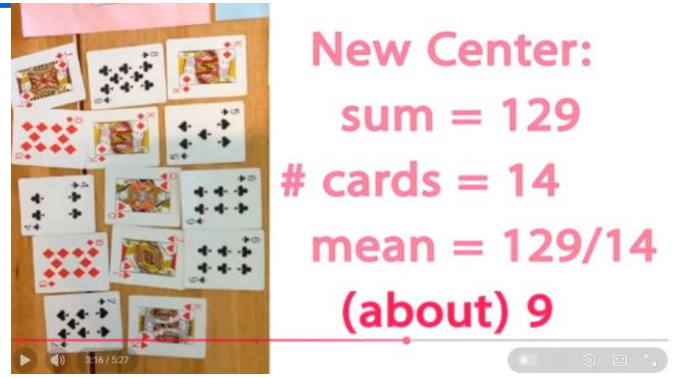

ro mas cercano ...
7
8
9
X1

Demostración de K-MEANS mediante un ejemplo de cartas de póker

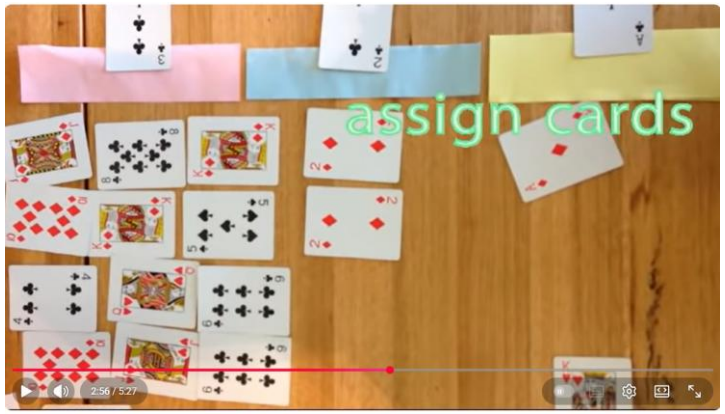
- https://youtu.be/zHbxbb2ye3E?si=AL-BuXON6fz8Ow_8

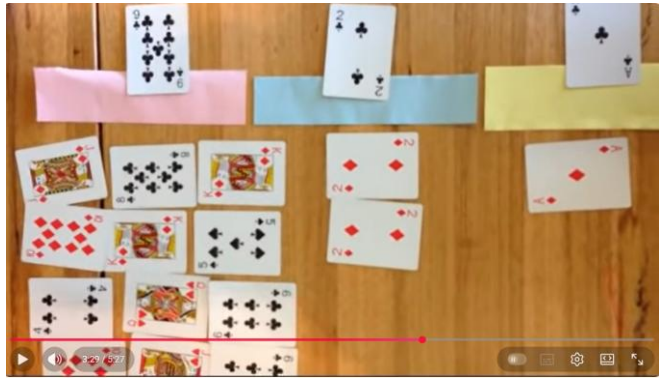












Iteración hasta que el centro no cambie

Result after Iteration 2:

Pink
Cards: 11, 8, 13, 10, 13, 12, 6, 10, 11, 6, 7, 13
New center: 10

Blue
Cards: 2, 2, 4, 5
New center: 3

The center of yellow group does not change.







kmeans

Procedimiento función (kmeans)

El proceso iterativo de cálculo del algoritmo k-means es el siguiente:

1. Se establece el número inicial de grupos (o clusters)
2. Se establece un centroide aleatorio inicial de cada grupo
3. Se calcula la distancia y asigna a cada grupo los puntos más cercanos al centroide del grupo.
4. Se recalcula el centroide de cada grupo con los puntos asignados al mism
5. Se repite = vuelve al paso 3.. y así

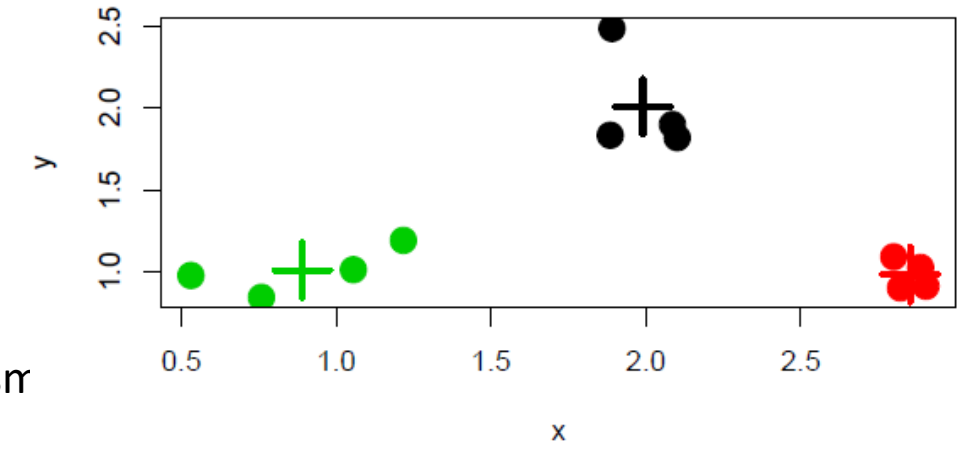


Figura 7.12: agrupamiento con método kmeans

Este proceso requiere de partida:

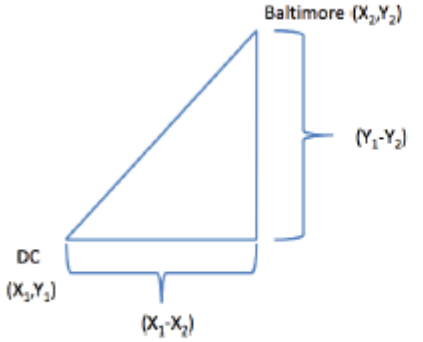
- definir la función de distancia (euclídea más utilizada).
- dar el número inicial de agrupaciones (o clusters) (en el gráfico 3)
- sugerir la posición inicial de cada centroide para cada agrupación (puedo ser aleatoria).
- El centroide es el promedio con distancia definida
- Demanda computacional alta

Agrupamiento

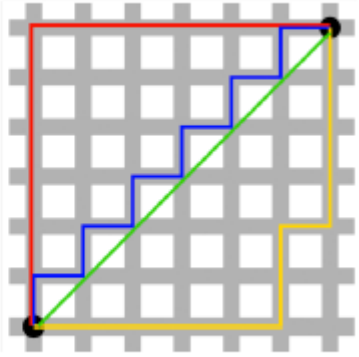
- Un algoritmo de agrupamiento (en inglés, **clustering**) es un procedimiento de agrupación de una serie de vectores de acuerdo con un criterio. Esos criterios son por lo general distancia o similitud.

- El agrupamiento de datos puede desarrollarse con diferentes técnicas estadísticas, pero las más usuales y las que veremos en este capítulo de análisis exploratorio de datos son las tres siguientes:
- 1. K-means Clustering
- 2. El agrupamiento jerárquico (Hierarchical Clustering)
- 3. DBSCAN: Agrupamiento Espacial Basado en la Densidad

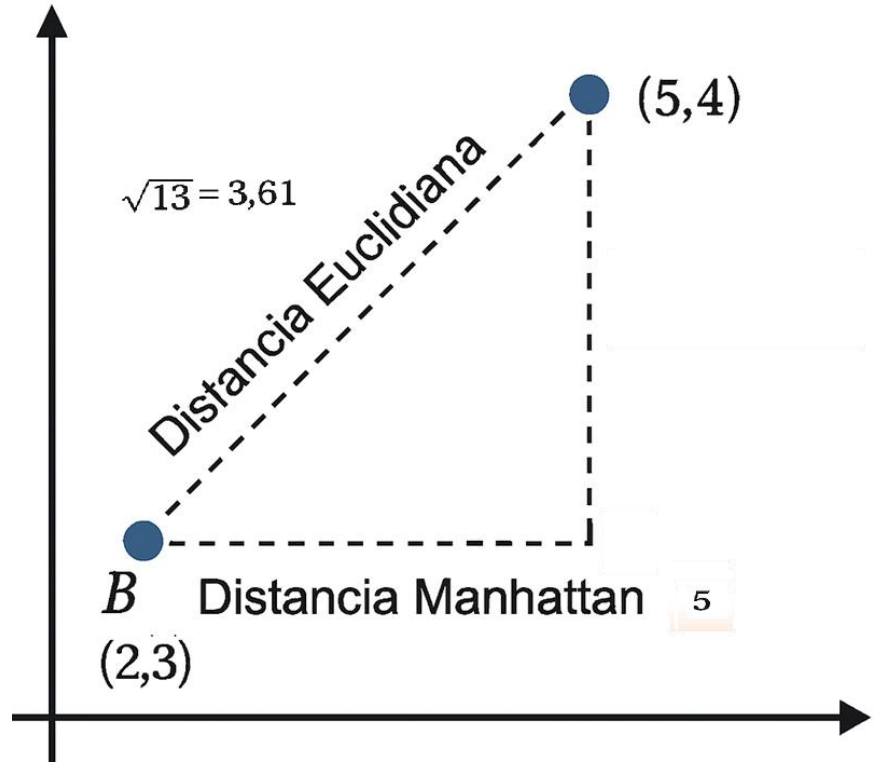
de Aplicaciones con Ruido



Euclidean Distance



Binary Distance



Medidas de distancia

Medidas de distancia

Distancia Euclidiana: Es la distancia clásica, como la longitud de la recta que une dos puntos en el espacio euclídeo:

$$d(x,y) = \sqrt{\sum_{i=1}^{n}(x_i - y_i)^2}$$

Distancia de Manhattan: o distancia por cuadras (city-block). Como su nombre indica, hace referencia a recorrer un camino no en diagonal (por el camino más corto), sino zigzagueando, como se haría en Manhattan:

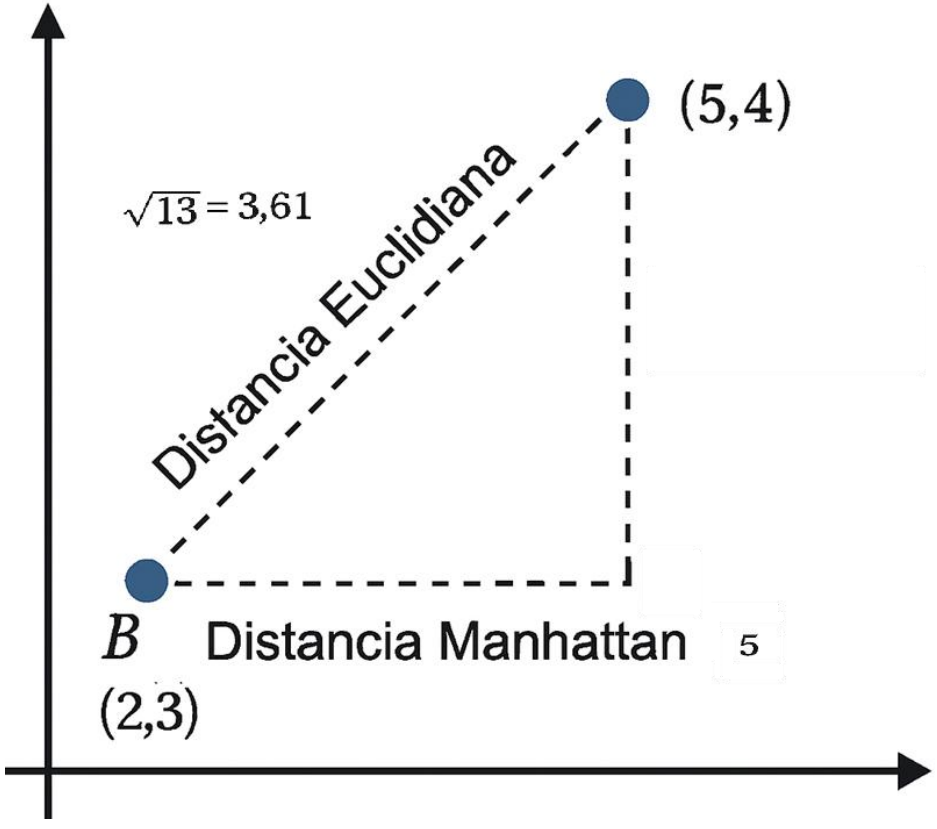
$$d(x,y) = \sum_{i=1}^{n} |x_i - y_i|$$

- Si tenés dos puntos en un plano:
- A = (2, 3) B = (5, 1)

- Entonces:

$d_{Manhattan}(A,B) = |2-5| + |3-1| = 3+2 = 5$

$d_{euclidea}(A;B) = \sqrt{(2-5)^2 + (3-1)^2} = \sqrt{13} = 3{,}61$



Correlación medida de similaridad

- Distancia correlación
- Variables cuantitativas
- Comparar con ACP: Media vs Variancia

Fórmula

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}$$

r = coeficiente de correlación

x_i = valores de la variable x en una muestra

$\bar{x}$ = media de los valores de la variable x

y_i = valores de la variable y en una muestra

$\bar{y}$ = media de los valores de la variable y

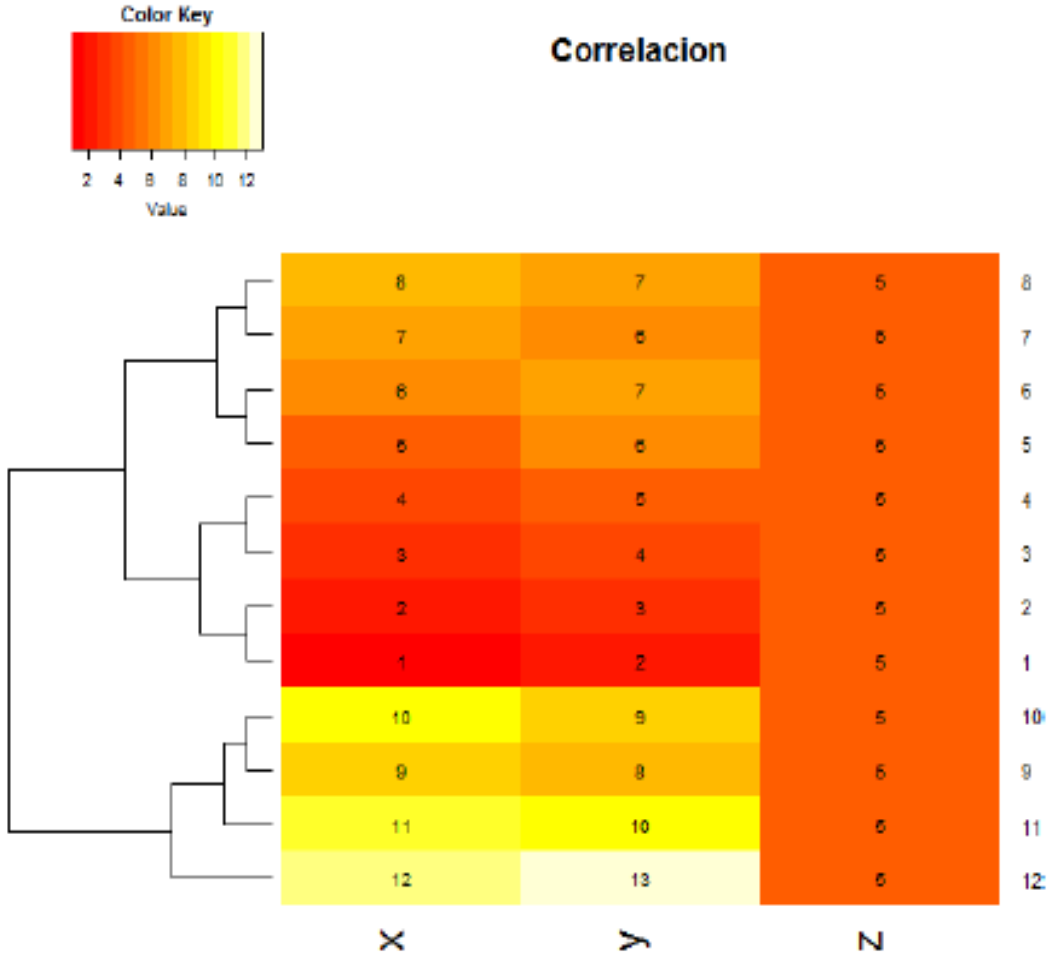


Figura 7.7: Mapas de calor con ggplot heatmap.2

Distacia en datos nominales

		Y	
		0	1
X	0	a	b
	1	c	d

Tabla 10.5: Entradas de vectores binarios

Tabla de Coeficientes de Similitud

Coeficiente	Fórmula	Descripción
Coincidencias simples	$\frac{a+d}{a+b+c+d}$	Mide la proporción de emparejamiento entre dos observaciones.
Jaccard	$\frac{d}{b+c+d}$	Mide la proporción de emparejamiento si al menos uno de los vectores admite un 1.
Phi	$\frac{ad-bc}{\sqrt{(a+b)(a+c)(b+d)(c+d)}}$	Mide la correlación lineal entre los vectores.
Anderberg	$\frac{t_1-t_2}{2(a+b+c+d)}$, con: $t_1=\max\{a,b\}+\max\{a,c\}+\max\{b,d\}+\max\{c,d\}$ $t_2=\max\{a+c,b+d\}+\max\{a+b,c+d\}$	Mide la predicción del estado de una característica en un vector dado el estado de la misma en el otro vector.
Dice	$\frac{2d}{b+c+2d}$	Es similar a Jaccard asignando doble peso a la coincidencia de 1.

Ejemplo Similitud (individuos)

Coeficiente	Fórmula
Coincidencias simples	$\frac{a+d}{a+b+c+d}$

Diagonal a+d = 2/5

		Y 0	Y 1
X	0	a	b
	1	c	d

ID	P1	P2	P3	P4	P5
ID1	**Si**	Si	**No**	**No**	Si
ID2	**Si**	No	**No**	**No**	No
ID3	Si	No	Si	Si	Si
ID4	Si	No	Si	Si	Si
ID5	Si	No	No	Si	Si
ID6	Si	No	No	Si	Si
ID7	Si	No	No	Si	Si
ID8	Si	No	Si	Si	Si
ID9	No	No	Si	Si	Si
ID10	No	No	Si	Si	Si
ID11	No	No	Si	Si	Si
ID12	No	No	Si	No	Si
ID13	No	Si	Si	No	Si
ID14	Si	Si	No	Si	Si
ID15	Si	Si	No	Si	Si
ID16	Si	Si	Si	Si	Si
ID17	Si	No	Si	Si	Si
ID18	Si	No	Si	Si	Si
ID19	Si	No	Si	No	Si
ID20	Si	No	Si	No	Si

ID1

	ID2	
ID 1-2	**Si**	**No**
Si	1	0
No	2	2

ID 1-2 **d=(1+2)/(1+2+2+0)=** 0,6 = 3/5

	ID1	
ID 1-1	**Si**	**No**
Si	3	0
No	0	2

ID 1-1 **d=(3+2)/(3+2+0+0)=** **1**

	ID3	
ID 1-3	**Si**	**No**
Si	2	2
No	1	0

ID 1-3 **d=(1+2)/(1+2+2+0)=** **0,4** = 2/5

	ID1	ID2	ID3	ID4
ID1	1	0,6	0,4	
ID2	0,6	1		
ID3	0,4		1	
ID4				1
ID5				
ID6				
ID7				
ID8				
ID9				
ID10				
ID11				
ID12				
ID13				
ID14				
ID15				
ID16				
ID17				
ID18				
ID19				
ID20				

Tabla de Coeficientes de Similitud

Coeficiente	Fórmula	Descripción
Ochiai	$\frac{d}{\sqrt{(b+d)(c+d)}}$	Mide la cohesión entre agrupamientos.
Russel-Rao	$\frac{a+d}{\sqrt{a+d+2(b+c)}}$	Es el valor predeterminado para los datos de similitud binarios.
Hamann	$\frac{(a+d)-(b+c)}{a+b+c+d}$	Mide la proporción de la diferencia entre coincidencias y discrepancias.
Sneath-Sokal	$\frac{2(a+d)}{2(a+d)+b+c}$	Es similar a coincidencias simples asignando doble peso a los emparejamientos.
Rogers-Tanimoto	$\frac{a+d}{a+d+2(b+c)}$	Es opuesto a Sneath-Sokal asignando doble peso a las discrepancias.
Yule	$\frac{ad-bc}{ad+bc}$	Mide la fracción de asociación perfecta de 1.

		Y	
		0	1
X	0	a	b
	1	c	d

Tabla 10.5: Entradas de vectores binarios

¿Cómo validar k?

¿Cómo validar?

- El *clustering* es uno de los métodos de aprendizaje **no supervisado** más importantes y busca caracterizar conceptos desconocidos a partir de los ejemplos disponibles.
- Generalmente, en un problema real **se desconoce la clase** y es allí donde el agrupamiento puede ayudar a identificar las características comunes entre instancias.
- Al no disponer de la clase utiliza una **medida de similitud** para determinar el parecido entre instancias.

Métricas de Validación

- Como el objetivo del clusteringes agrupar objetos similares en el mismo clustery objetos diferentes en distintos clusters, las métricas de validación están basadas usualmente en los siguientes criterios:
  - Cohesión
  - Separación

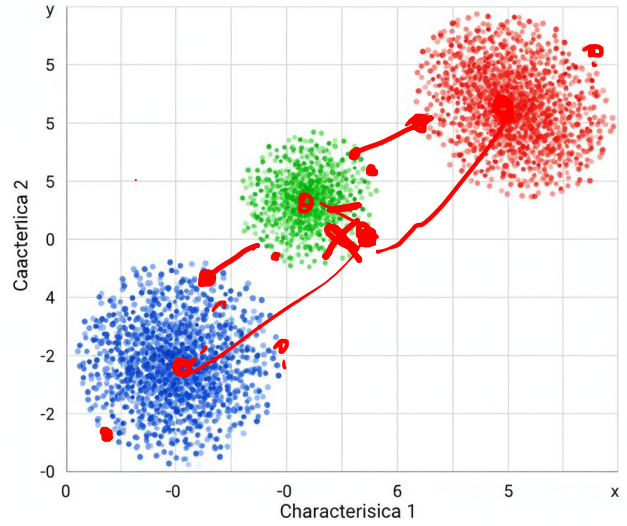
Criterios de las Métricas de Validación

Cohesión

- Se busca que los miembros de un mismo grupo se encuentren lo más cerca que sea posible unos de otros.

Separación

- Los clusters deben estar ampliamente separados entre ellos.
- Existen varios enfoques para medir esta distancia entre clusters:
  - distancia entre los miembros más cercanos,
  - distancia entre los miembros más distantes,
  - distancia entre los centroides.

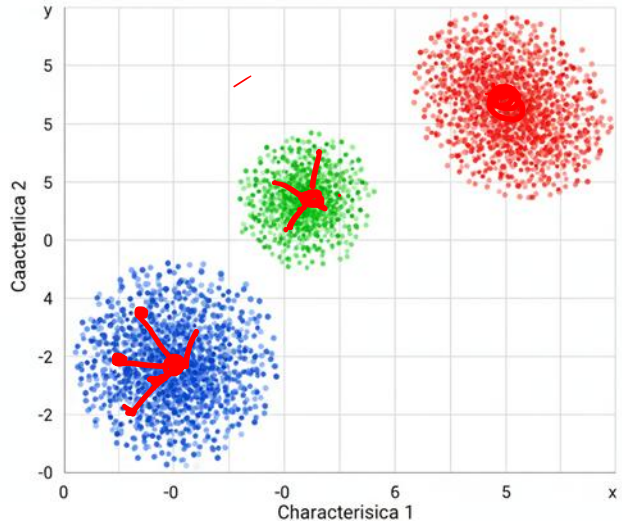


Métrica SSW (Sum-of-Squares Within)

- Se usa para evaluar la Cohesión (distancia intra-cluster) de los clustersgenerados por el algoritmo de agrupamiento.

Suma de cuadrados Totales

$$SSW = \sum_{i=1}^{k} \sum_{x \epsilon C_i} dist^2(m_i, x)$$



- Siendo k el número de clusters, x un elemento del cluster Ci y mi el centroide de
- Suma de la distancia al cuadrado de cada elemento x a su centro *mi* y sumado para todos los cluster *Ci*

Métrica SSB (Sum-of-Squares Between)

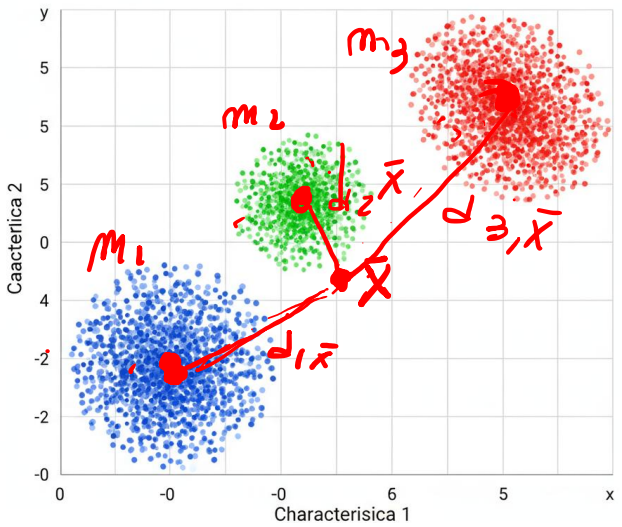
DISTANCIA ENTRE

- Es una medida de separación utilizada para evaluar la distancia inter-cluster

$$SSB = \sum_{j=1}^{k} n_j \, dist^2(m_j - \bar{x})$$

50 $dist^2(m_1 - \bar{x})$

$m_1 = 50$
$m_2 = 20$
$m_3 = 40$



- siendo k el número de clusters, nj el número de elementos en el cluster Cj, mj el centroide del cluster Cj y $\bar{x}$ es la media del conjunto de datos completo.
- La suma Distancia al cuadrado entre los centros de los clusters y el promedio general

Indice Silhouette

- Dado un ejemplo x del conjunto de datos :

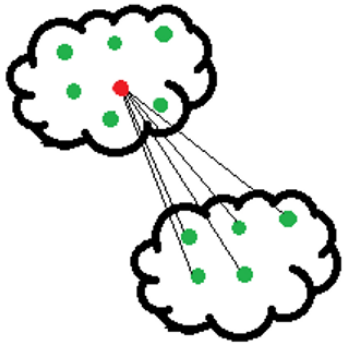
- **Cohesión a(x)**: distancia promedio de x a todos los demás ejemplos en el mismo cluster.



- **Separación b(x)** : distancia promedio de x a todos los demás ejemplos en el cluster más cercano.

$\bar{x}$







Indice Silhouette para un elemento *x*

- El índice silhouette para el ejemplo x está definido como

$$s(x) = \frac{b(x) - a(x)}{\max\{b(x), a(x)\}}$$



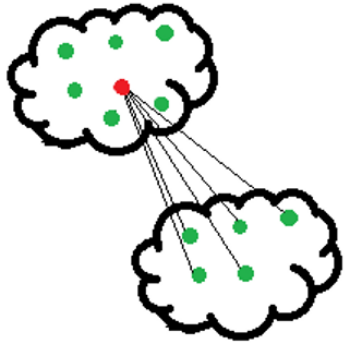
- El valor de s(x) puede variar entre -1 y 1.
  - -1 = mal agrupamiento
  - 0 = indiferente
  - 1 = bueno

Indice Silhouette del agrupamiento

- Para todo el agrupamiento es el promedio de la separación individual de ***Xi***

$$SC = \frac{1}{N}\sum_{i=1}^{N} s(x_i)$$







- Será mejor cuanto mayor el índice

Indice Davies-Bouldin

- Este índice compara a cada cluster con su vecino más cercano.
- Para medir la calidad del agrupamiento tiene en cuenta los siguientes dos conceptos
  - dispersión de cada cluster.
  - distancia entre clusters.

Indice Davies-Bouldin→ Dispersion

- La dispersión Si del cluster Ci se define como la distancia promedio entre los ejemplos que pertenecen al cluster y el centro del mismo.

$$S_i = \frac{1}{|C_i|} \sum_{x \in C_i} dist(x, m_i)$$

donde $|Ci|$ es la cantidad de elementos que pertenecen al cluster Ci, x es un elemento y mi es el centroide de dicho cluster.

Promedio de las distancias de cada elemento a su centro sumado

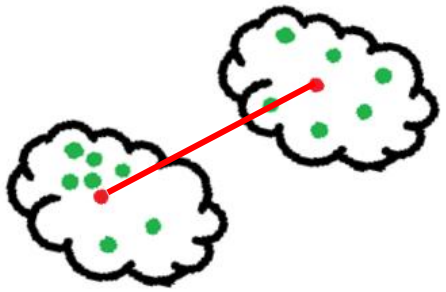
Cuanto más cerca del centro estén los ejemplos, menor será la dispersión del cluster.

Indice Davies-Bouldin→ Distancia

- La distancia Dij entre los centros de los clusters Ciy Cj se calcula de la siguiente forma

$$D_{ij} = dist(m_i, m_j)$$

$$R_{ij} = \frac{S_i + S_j}{D_{ij}}$$



donde mi y mj son los centroides de los clusters Ciy Cj respectivamente.

- Dados dos clusters Ci y Cj, para calificar la manera en que los elementos queda define la siguiente expresión Rij
- Mientras más compactos sean los clusters Ci y Cj **menores** serán Si y Sj, y mientras más separados estén, **mayor** será Dij.
- Por lo tanto, cuanto más compactos sean los grupos y más separados se encuentren, **menor** será el valor de Rij

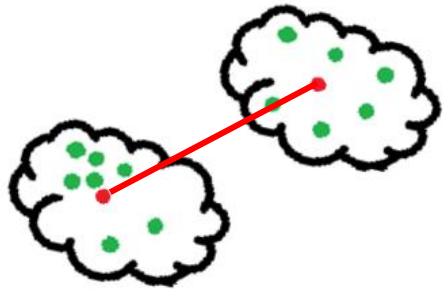
Indice Davies-Bouldin→ Disperción + Distancia

- El índice Davies-Bouldinse define como

$$DB = \frac{1}{k}\sum_{i=1}^{k} \max_{i \neq j}(R_{ij})$$

donde

- k es el número de clusters
- Max(Rij) con $i \neq j$, es el “peor caso” para el cluster Ci



- Será mejor cuanto menor sea el valor del índice Davies-Bouldin.
- El valor del índice no está acotado. Puede tomar un valor arbitrario.

kmedias

- Se debe indicar el K (cantidad de cluster) al inicio.
- Inicialmente los centros son aleatorios y los resultados pueden depender de la seleccion de estos centros, dependiendo de la estructura de los datos.
- Diferentes ejecusiones del algoritmo Kmedias llegan a distintas soluciones y no necesariamente a la solución optima.
- Los valores que sean muy diferentes del resto formarán un grupo separado y notoriamente minoritario. Esto es lo que se utiliza por ejemplo en la detección de fraudes → ATÍPICOS
- Se calculan la distancia de los centros a todos los casos. Cuanto mas grupos mayor cantidad de cálculos y mayor tiempo de ejecución.
- **El índice Silhouette (Silueta):**
  - Da valores entre -1 y 1
  - Mide la cohesión de un elemento calculando su distancia promedio al resto de los elementos del mismo cluster.
- **El índice Davies-Bouldin**
  - Es el promedio de valores que resultan de calcular el cociente entre la suma de dos medidas de dispersión y una distancia entre centros. No puede ser negativo.

Criterios para selección de número k de cluster

• La mayoría de las medidas de evaluación que hemos visto en el capítulo se basan en criterios que utilizan el número de ejemplos que el modelo contempla. Existen otras aproximaciones que evalúan modelos basándose en criterios tales como:

• **Interés**: el interés de un modelo intenta medir la capacidad de ese modelo de suscitar la atención del usuario del modelo.

• **Novedad**: criterio relacionado con la capacidad de un modelo de sorprender al usuario con respecto al conocimiento previo que tenía sobre determinado problema. Criterio muy afín al interés.

• **Comprensibilidad o Inteligibilidad**: como hemos comentado en varias ocasiones a lo largo del libro, la comprensibilidad de un modelo es en algunas ocasiones un factor muy importante.

• **Simplicidad**: este criterio se basa en establecer el tamaño o complejidad del modelo. Obviamente, este criterio está muy relacionado con el criterio de comprensibilidad.

• **Aplicabilidad**: en este caso, la calidad de un modelo se basa en su capacidad de ser utilizado con éxito en el contexto real donde va a ser aplicado.

Algunos de estos criterios están muy relacionados, por ejemplo, el interés y la novedad, el interés y la aplicabilidad, así como la comprensibilidad y la simplicidad.

	cluster	Murder	Assault	UrbanPop	Rape
1	1	14.671429	251.2857	54.28571	21.68571
2	2	10.966667	264.0000	76.50000	33.60833
3	3	6.210526	142.0526	71.26316	19.18421
4	4	3.091667	76.0000	52.08333	11.83333

Ejemplo Arrestos en USA: USArrests

Los datos del conjunto **USArrests** corresponden al año **1973**

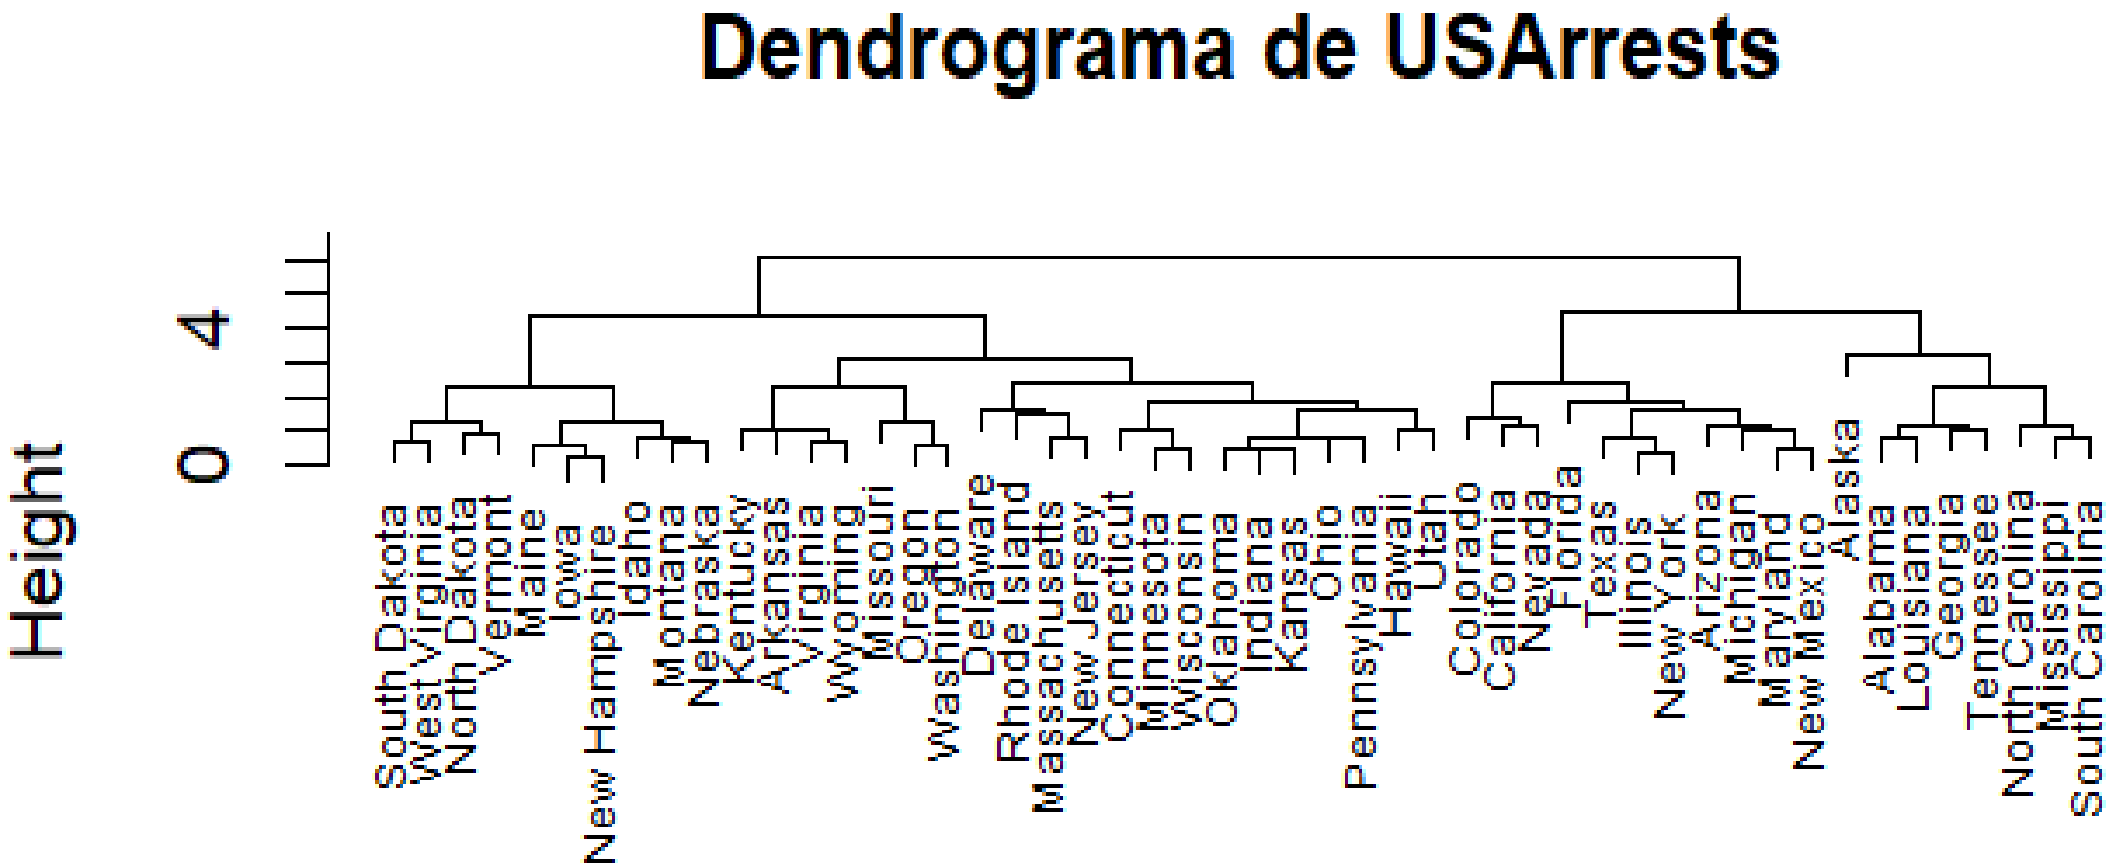
Ejemplo Arrestos en USA: USArrests

Variable	Tipo	Descripción	Unidad
Murder	Numérica	Tasa de arrestos por asesinato	Arrestos por cada 100,000 habitantes
Assault	Numérica	Tasa de arrestos por asalto	Arrestos por cada 100,000 habitantes
UrbanPop	Numérica	Porcentaje de población urbana	Porcentaje (%)
Rape	Numérica	Tasa de arrestos por violación	Arrestos por cada 100,000 habitantes

Los datos del conjunto **USArrests** corresponden al año **1973**

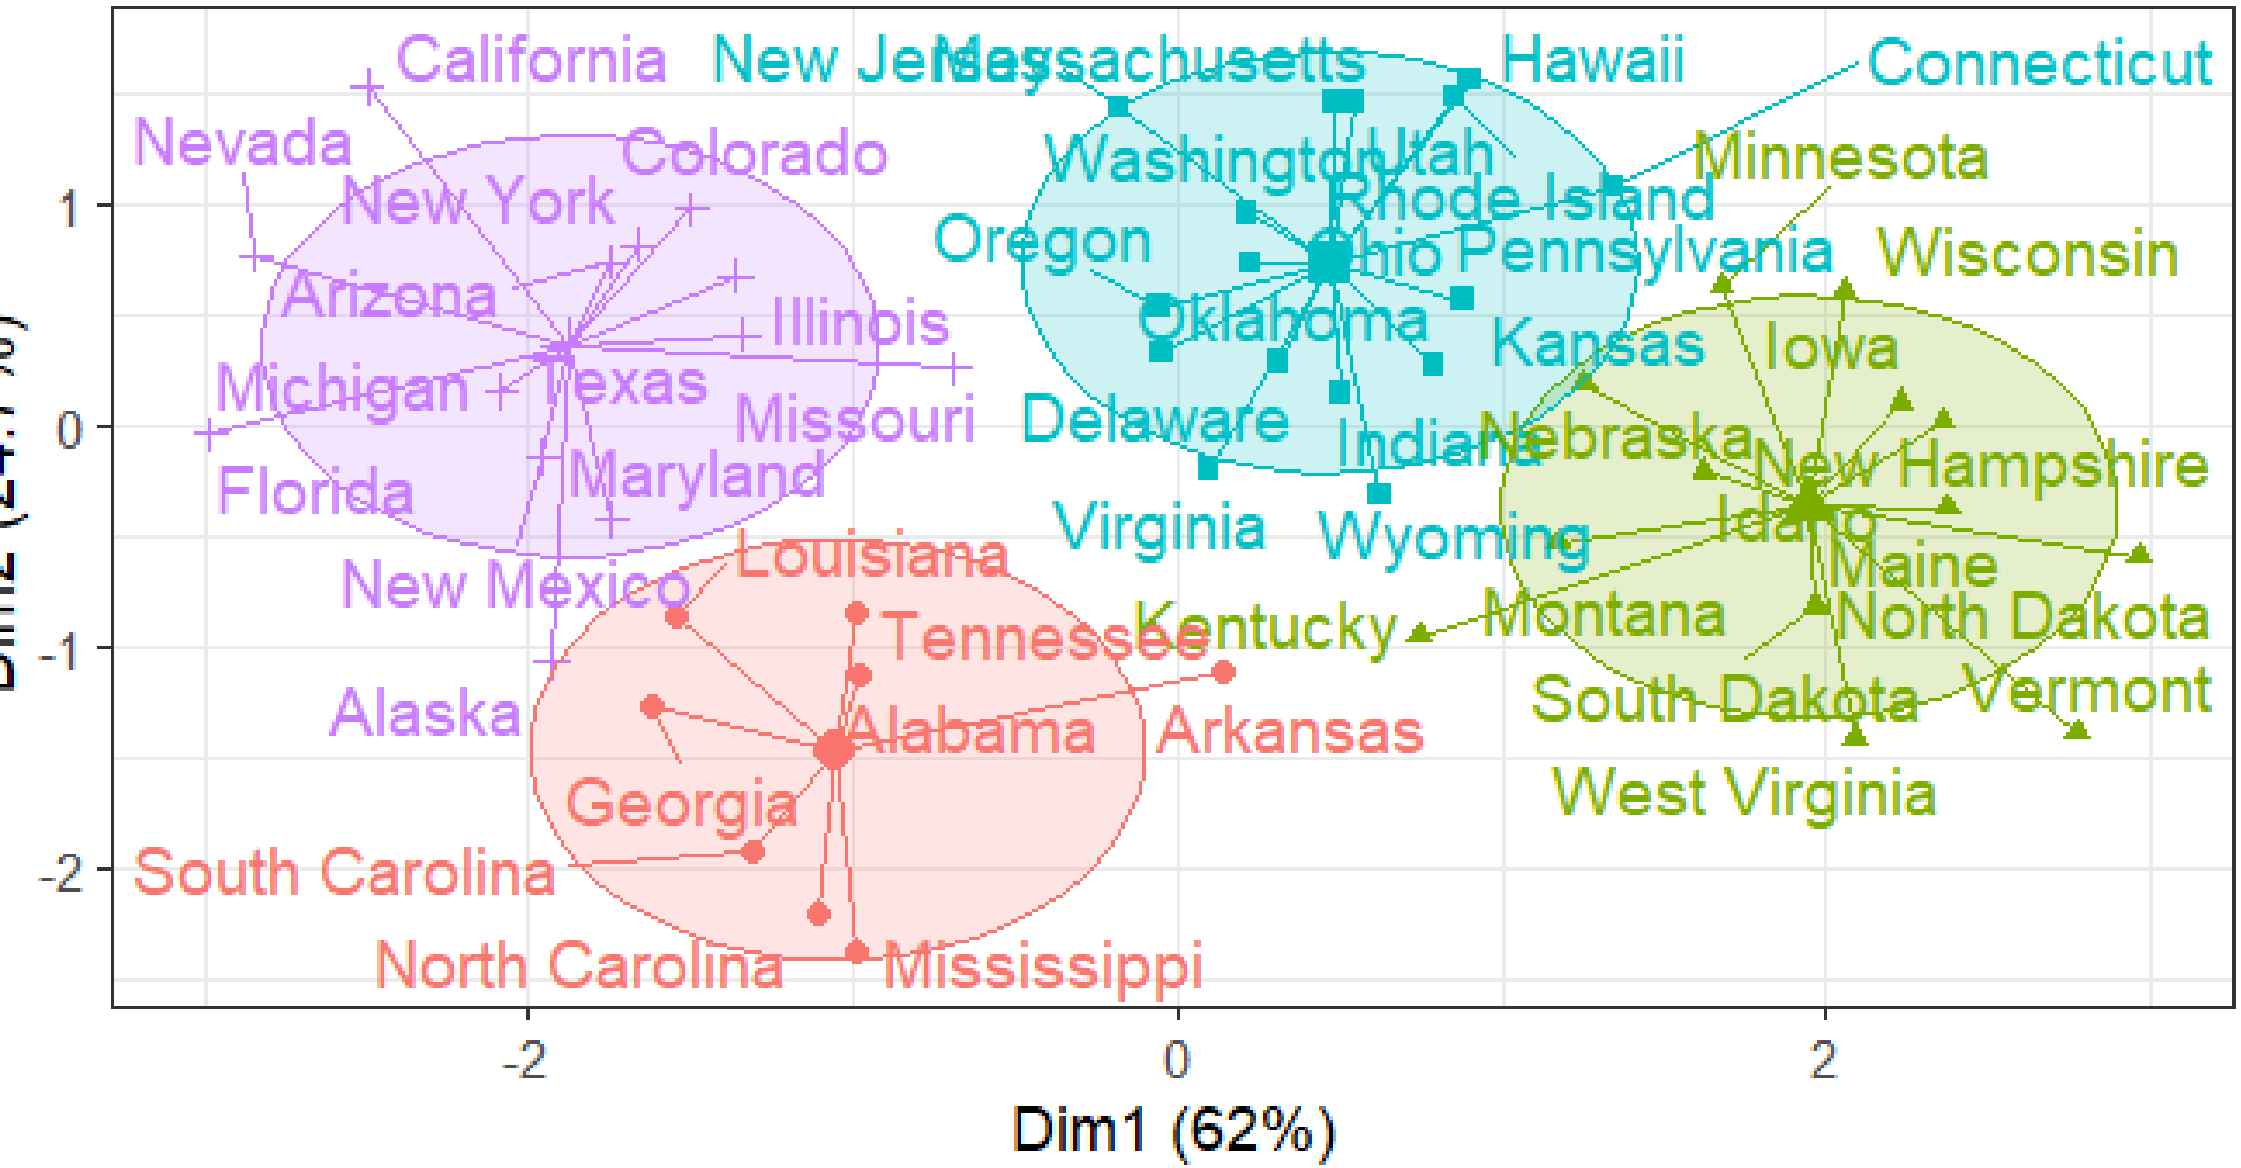
	cluster	Murder	Assault	UrbanPop	Rape
1	1	14.671429	251.2857	54.28571	21.68571
2	2	10.966667	264.0000	76.50000	33.60833
3	3	6.210526	142.0526	71.26316	19.18421
4	4	3.091667	76.0000	52.08333	11.83333

Ejemplo Arrestos en USA



Dendrograma de USArrests
Height
0
4
South Dakota
West Virginia
North Dakota
Vermont
Maine
Iowa
New Hampshire
Idaho
Montana
Nebraska
Kentucky
Arkansas
Virginia
Wyoming
Missouri
Oregon
Washington
Delaware
Rhode Island
Massachusetts
New Jersey
Connecticut
Minnesota
Wisconsin
Oklahoma
Indiana
Kansas
Ohio
Pennsylvania
Hawaii
Utah
Colorado
California
Nevada
Florida
Texas
Illinois
New York
Arizona
Michigan
Maryland
New Mexico
Alaska
Alabama
Louisiana
Georgia
Tennessee
North Carolina
Mississippi
South Carolina

Resultados con k=4 óptimo del método de codo



Cluster luego de aplicar PCA

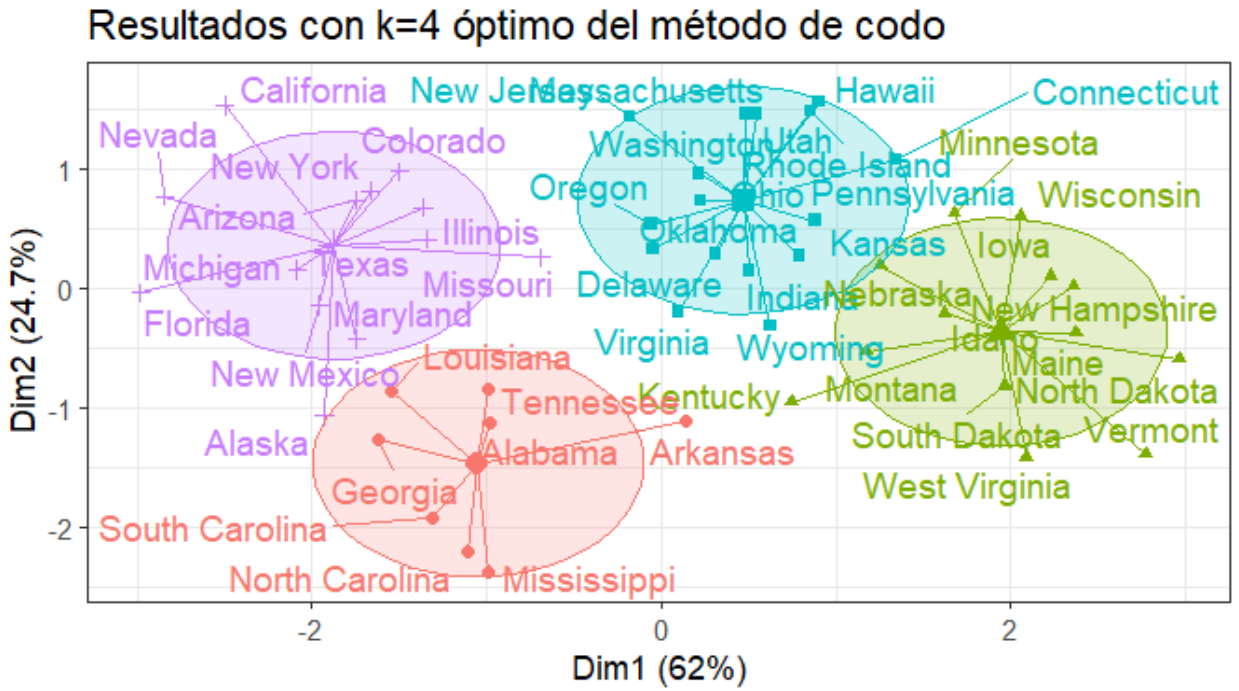
Aunque **no aparece explícitamente** ninguna línea que diga prcomp() o "PCA", la función **fviz_cluster()** **aplica PCA automáticamente** (ACP) si los datos (datos) tienen más de dos variables.

Esto se hace para:

- Reducir la dimensionalidad a 2 componentes principales.
- Permitir una visualización clara en un plano 2D.
- Mostrar los grupos formados por kmeans() en ese espacio reducido.

Por eso, en el gráfico ves los ejes como:

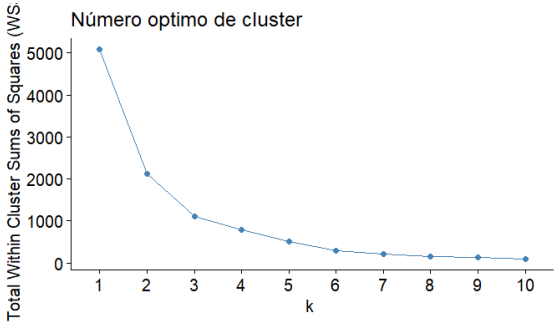
- **Dim 1 (62%)** → Primera componente principal (PC1), que explica el 62% de la variabilidad.
- **Dim 2 (24.7%)** → Segunda componente principal (PC2), que explica el 24.7%.



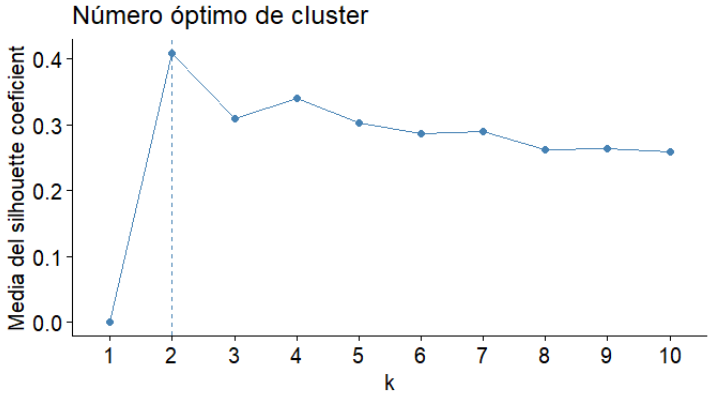
ACP + Cluster

Métodos para la determinación del valor de k en K-medias

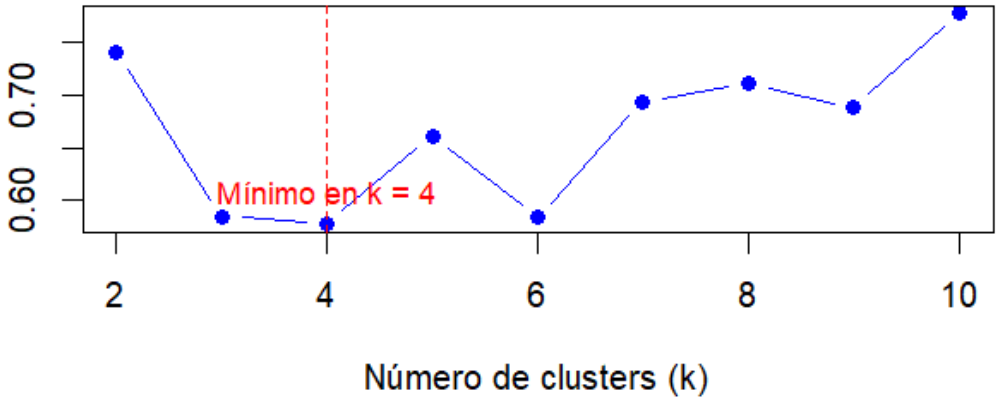
- Método Codo Valor de k se tiene una estabilización del valor de **total within sums of squares** (**WSS**).



- Silhouette coeficient (índices de silueta).



- Índice Davies Bouldin

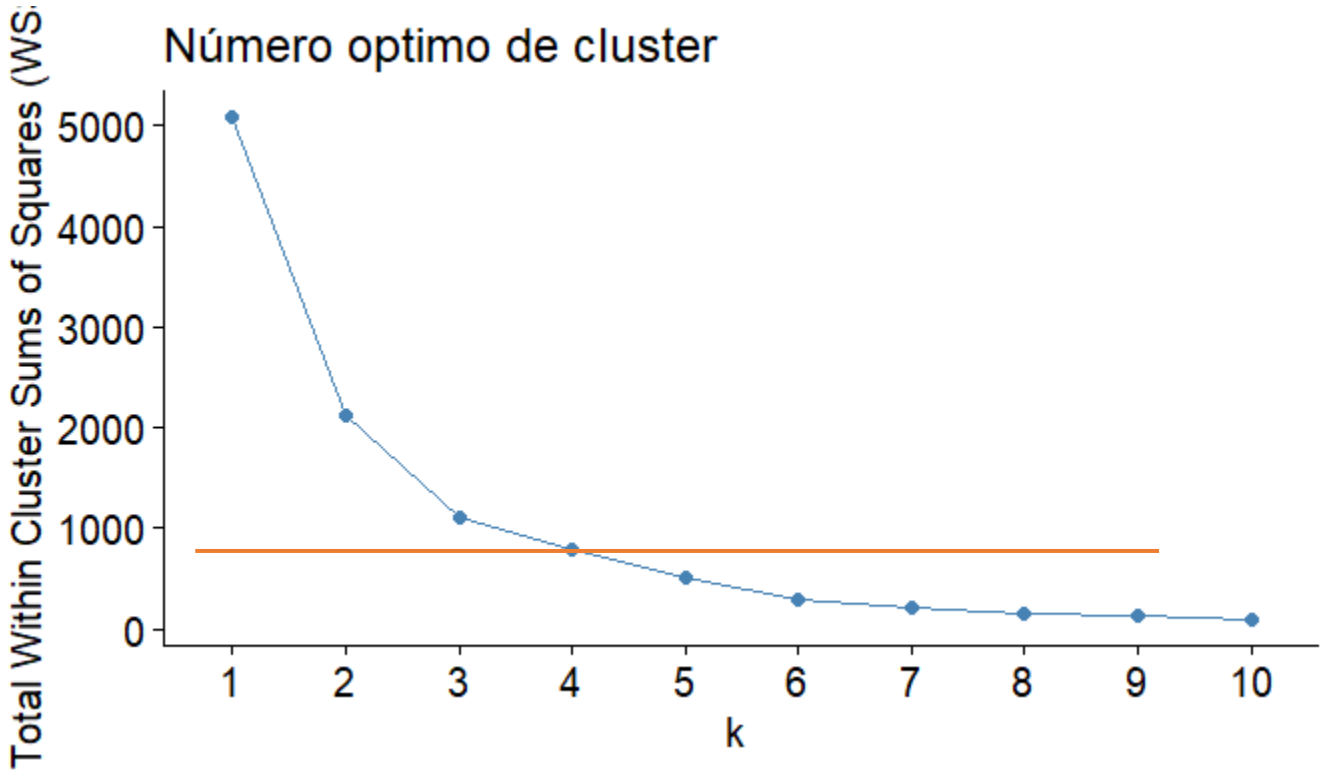


- No necesarimente coinciden
- Importante la **Explicabilidad** de los clusters…
- **Cluster → exploratorio**

Método del codo para la determinación de un valor de k

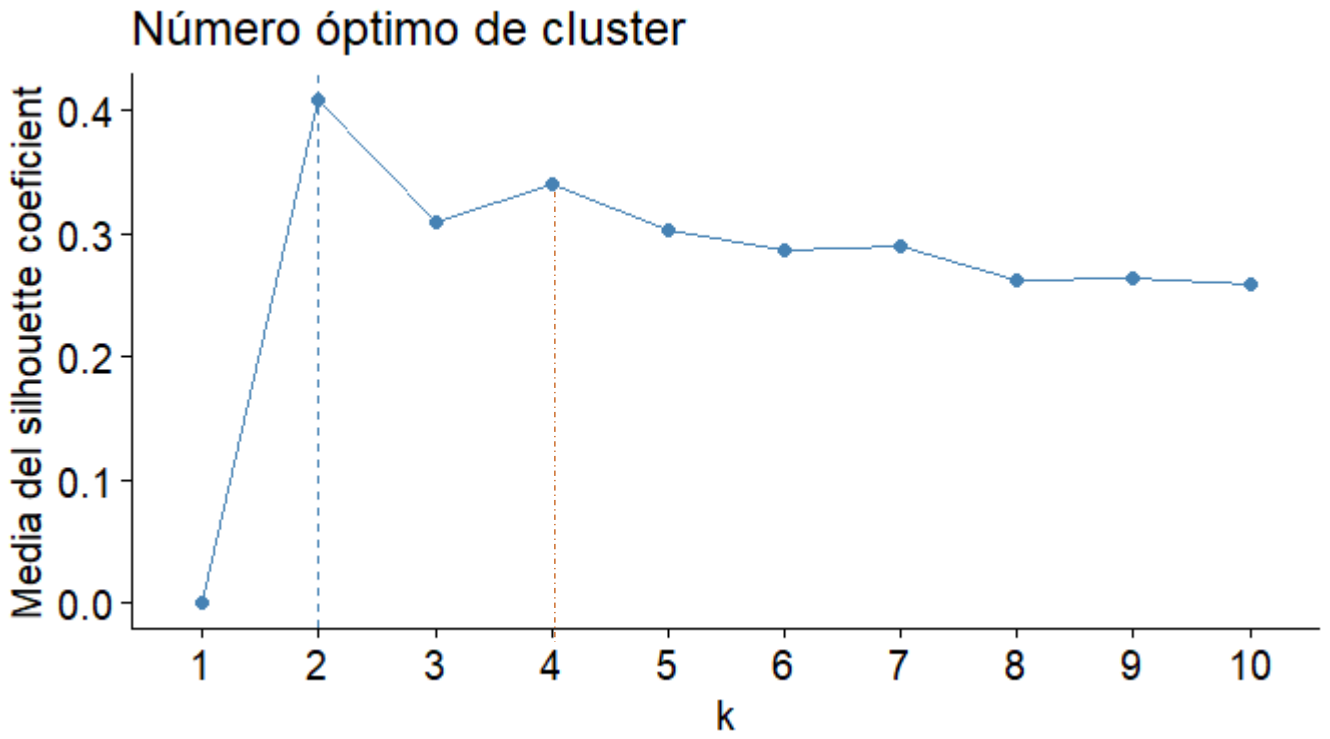
- Método del codo para la determinación de un valor de k optimo, para ello se determina en cual valor de k se tiene una estabilización del valor de la Suma de Cuadrados totales: **total within sums of squares** (**WSS**).
- Cuando la mejora en el valor de compacidad según WSS deja de ser sustancial. En este caso muestra una estabilización en la compacidad en un valor de

  k = 4.

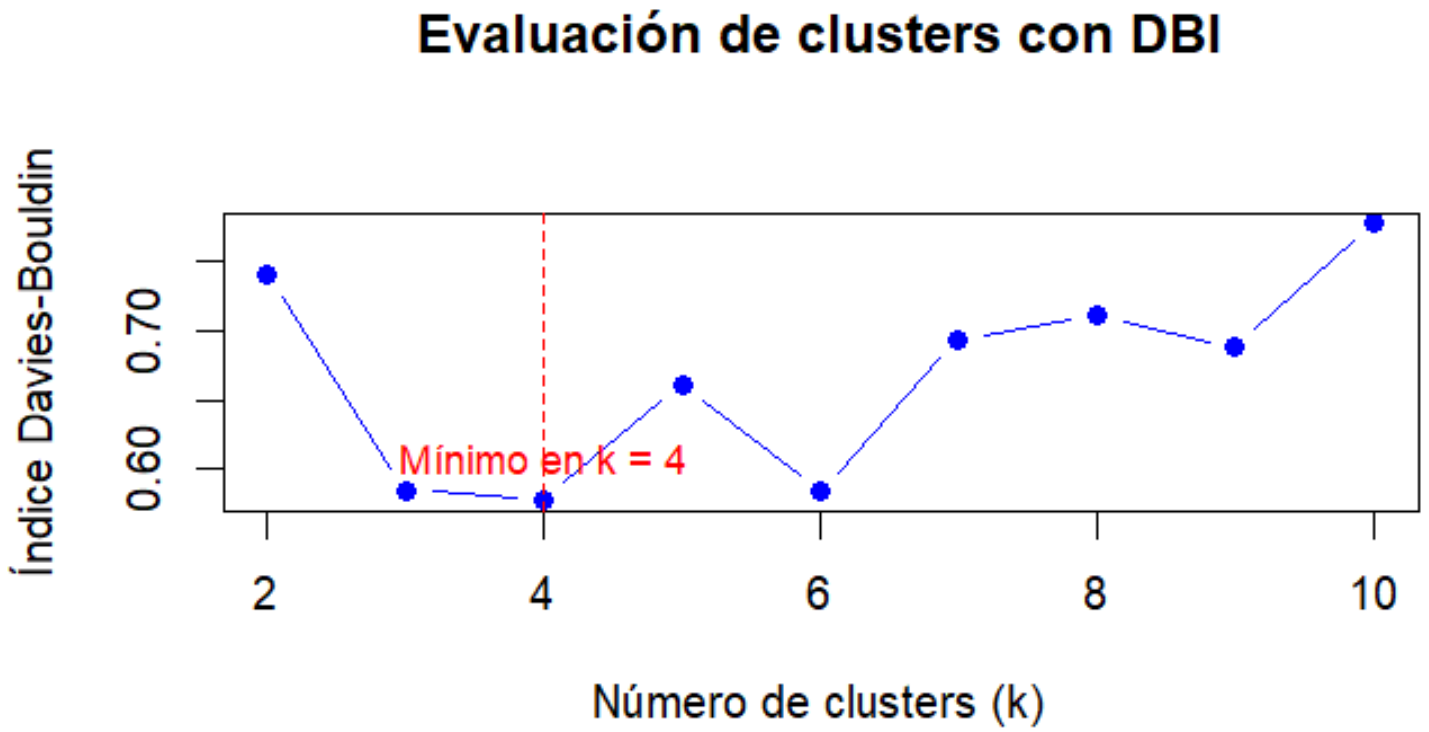


Coeficiente Silhouette (índice de silueta) para determinar k

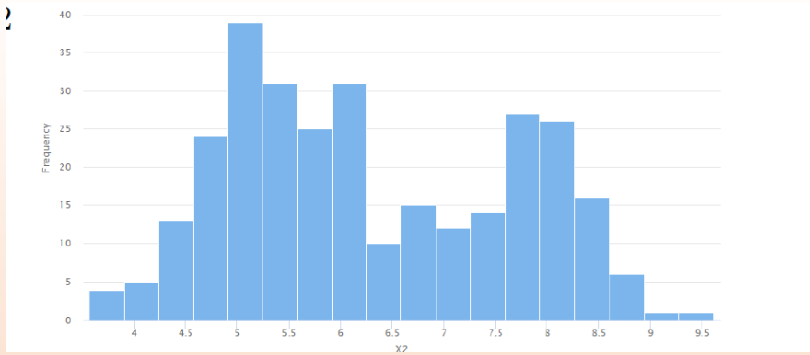
- Otro de los métodos para encontrar un valor óptimo de k agrupaciones para un algoritmo de agrupación particionada es el método de **media del coeficiente silhouette**.
- En este método se maximiza la media de los silhouette coeficient (índice de silueta), el cual determina cuan buena se ha realizado la asignación de un elemento a una agrupación. En este caso muestra que el valor máximo para el silhouette coeficient se da en un valor de k = 2.
- K=4 es el 2do máximo.



Índice de Davies Bouldin



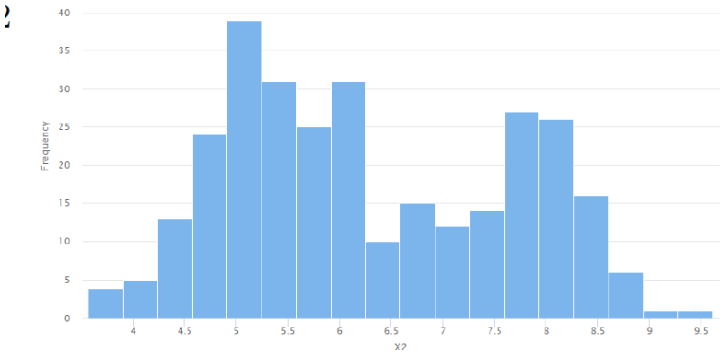
	k	DB
1	2	0.7409209
2	3	0.5843632
3	4	0.5778283
4	5	0.6614593
5	6	0.5829566
6	7	0.6941222
7	8	0.7110929
8	9	0.6879357
9	10	0.7778287



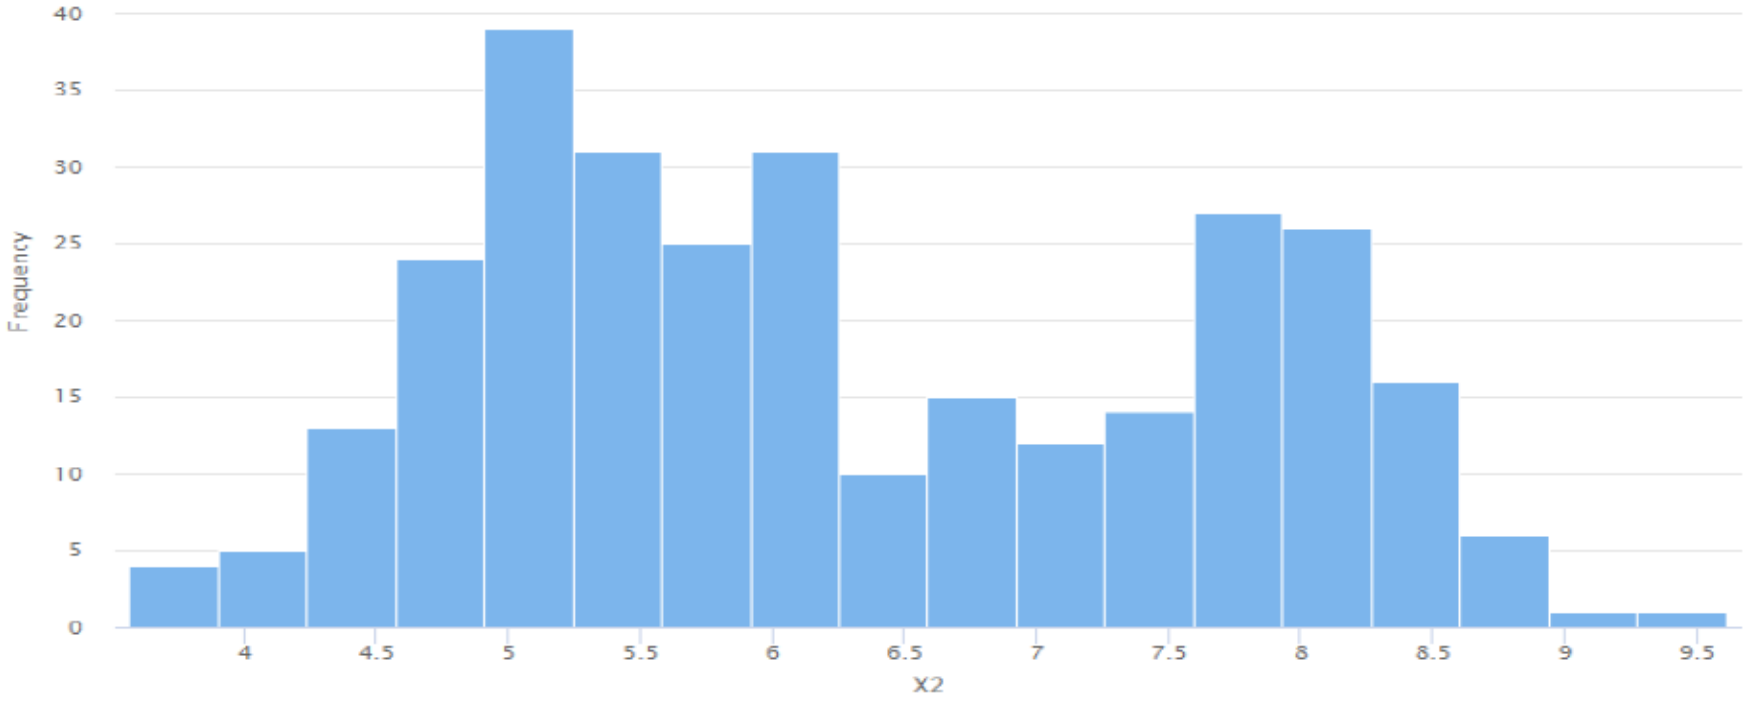
Algoritmo EM (Expectation-maximization)

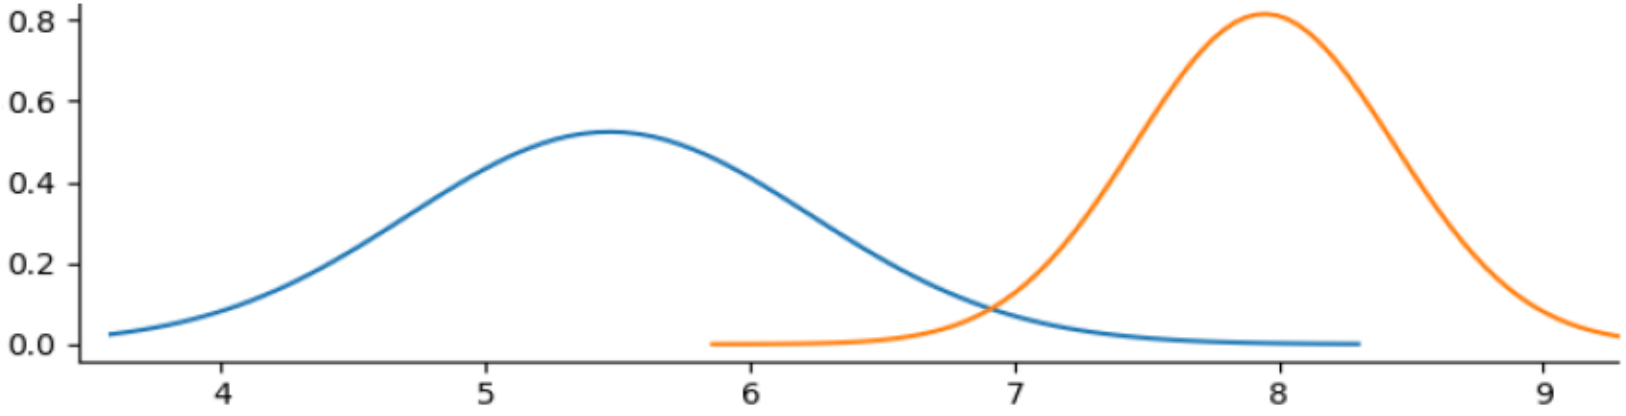
Algoritmo EM (Expectation-maximization)

- Estimar los valores de los parámetros que modelan los clusters.
- Repetir hasta que no mejoren los agrupamientos
- **Esperanza (*expectation*):** Utiliza los valores de los parámetros, iniciales o proporcionados por el paso *Maximization*, obteniendo diferentes formas de la *fdp*(función de densidad de probabilidad) buscada.
- **Maximización (*maximization*):** Recalcular los parámetros de la distribución haciendo uso de los datos proporcionados por el paso anterior.



Algoritmo EM





Cluster Model

```
Cluster 0: 200 items
Cluster 1: 100 items
Total number of items: 300

-------------------------------

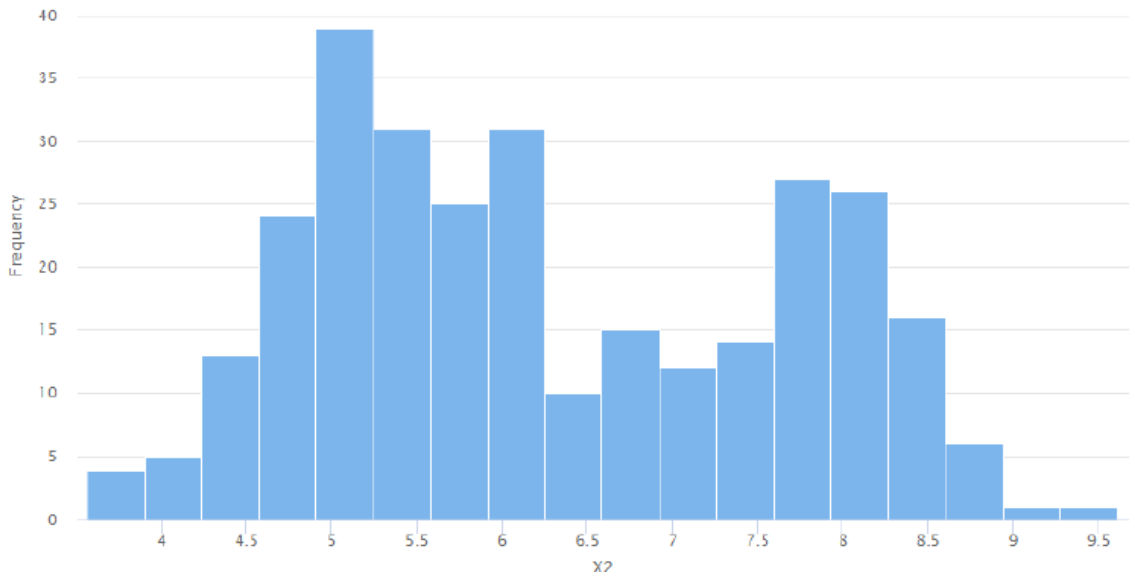
cluster probabilities:
Cluster 0: 0.6697867226226227
Cluster 1: 0.33021327737737705

cluster means:
Cluster 0: 5.468834450684805
Cluster 1: 7.945926591623768

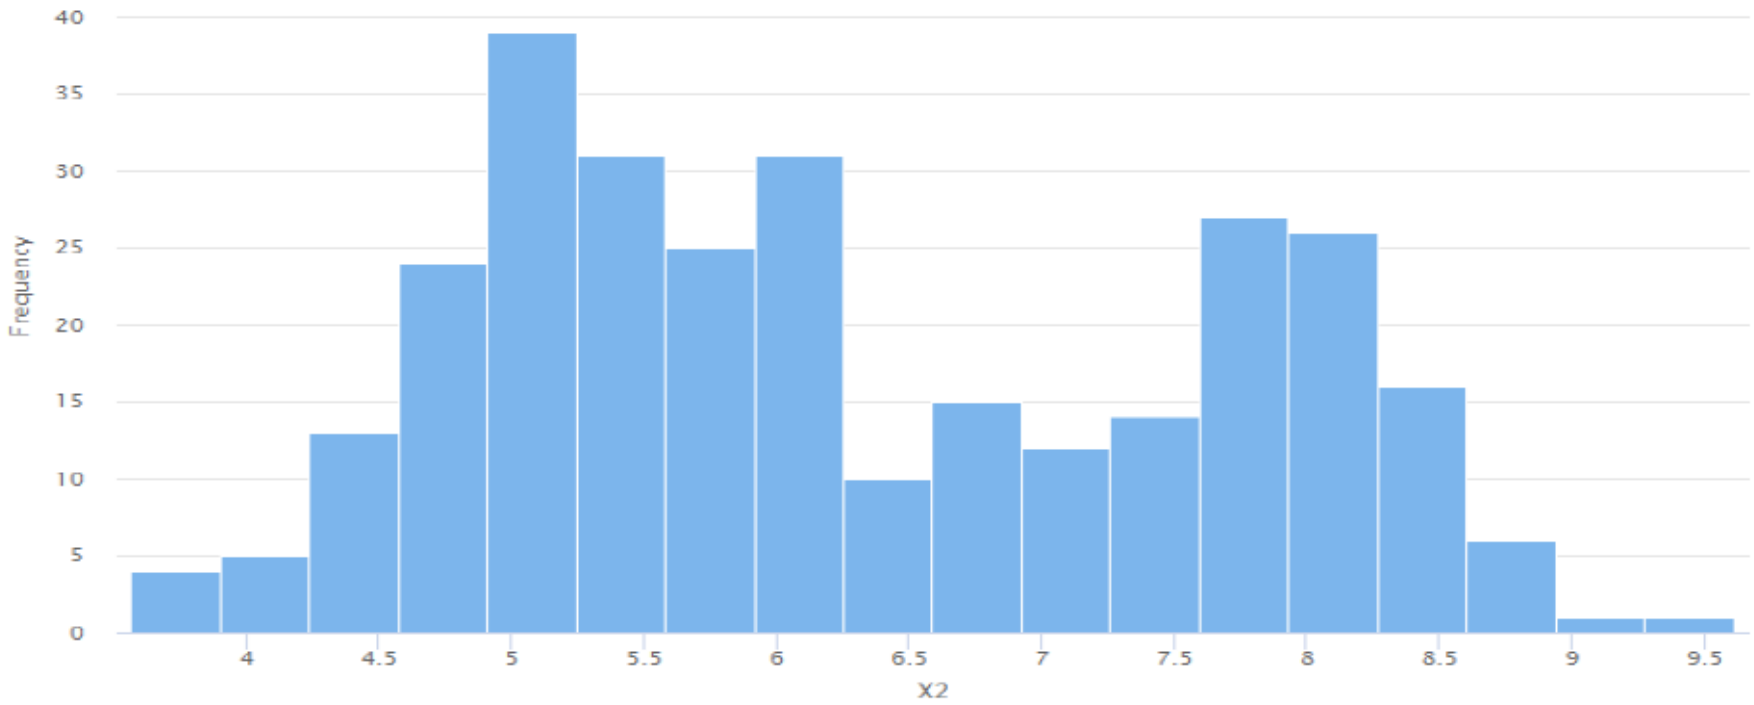
cluster covariance matrices:
Cluster 0:
0.579384540264987
Cluster 1:
0.23957506465667355
```

Ejemplo PuntosClusters

- Analice los valores del atributo X2 del archivo PuntosClusters.csv utilizando:
  - K-medias con K=2
  - Agrupamiento jerárquico visualizando sólo 2 grupos
  - EM con K=2

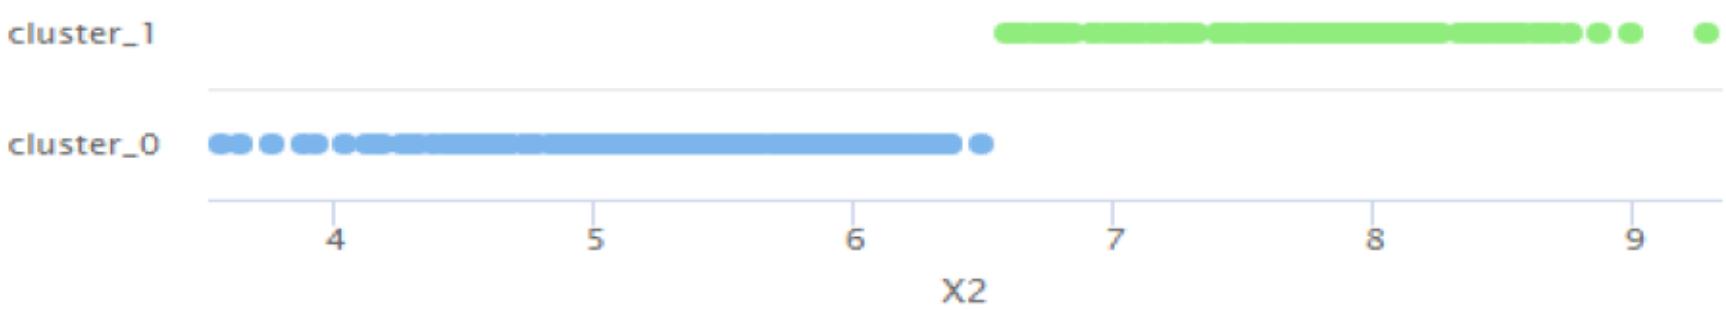


Algoritmo k-medias con k=2



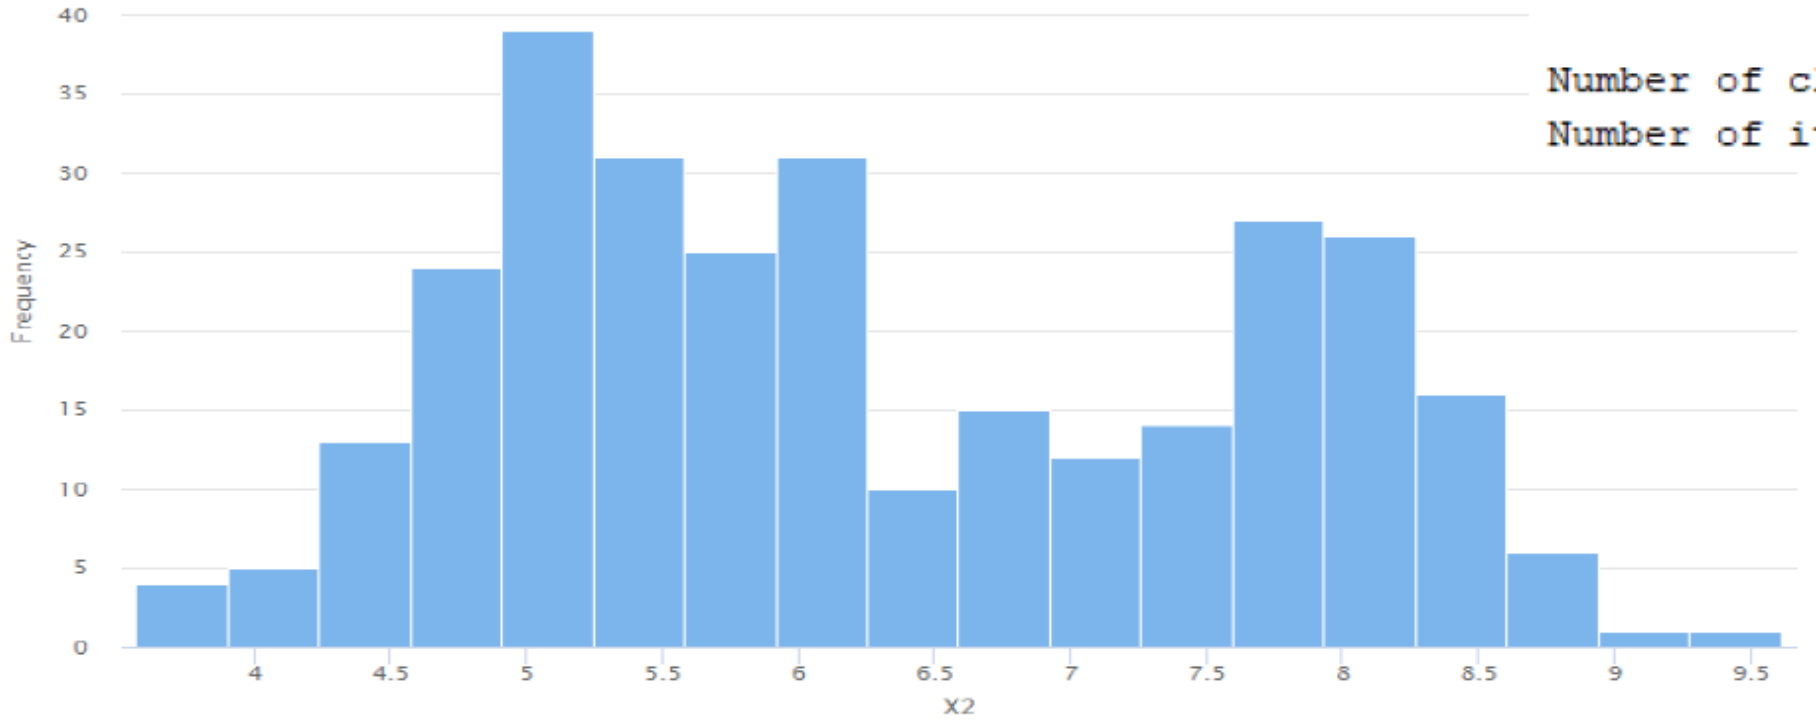
Cluster Model

```
Cluster 0: 181 items
Cluster 1: 119 items
Total number of items: 300
```



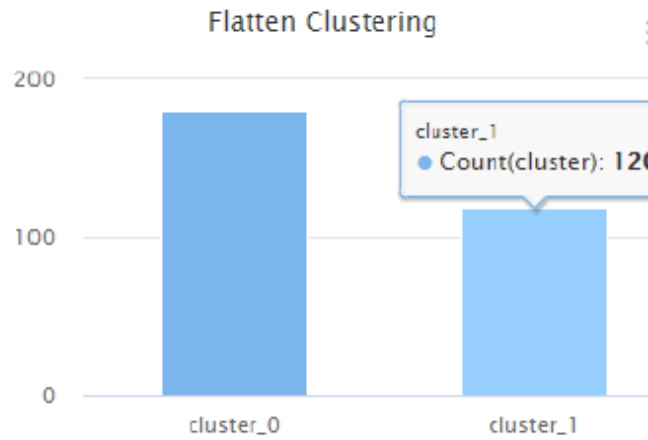
cluster_0	cluster_1
5.316	7.764

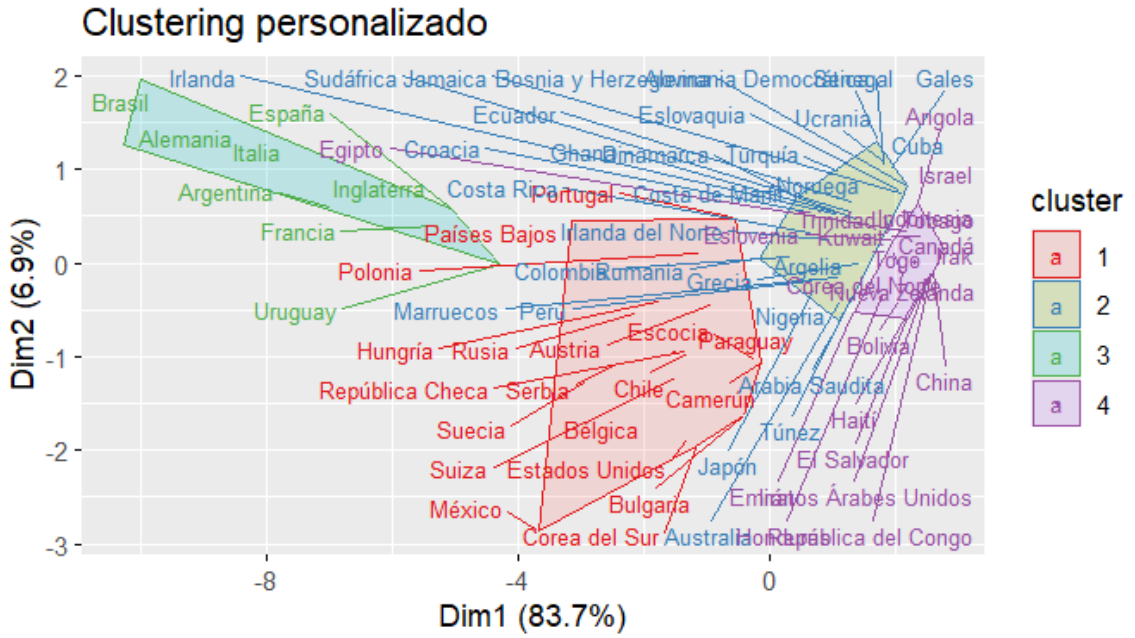
Agrupamiento jerárquico



Hierarchical Cluster Model

Number of clusters :599
Number of items :300





Ejemplo Futbol en Mundiales

https://ria.utn.edu.ar/items/0fa0e508-435a-47c4-afd7-662f270a204a

Libro: Análisis Inteligente de Datos

Autores: Chan, Débora, Badano, Cristina Inés, Rey, Andrea Alejandra

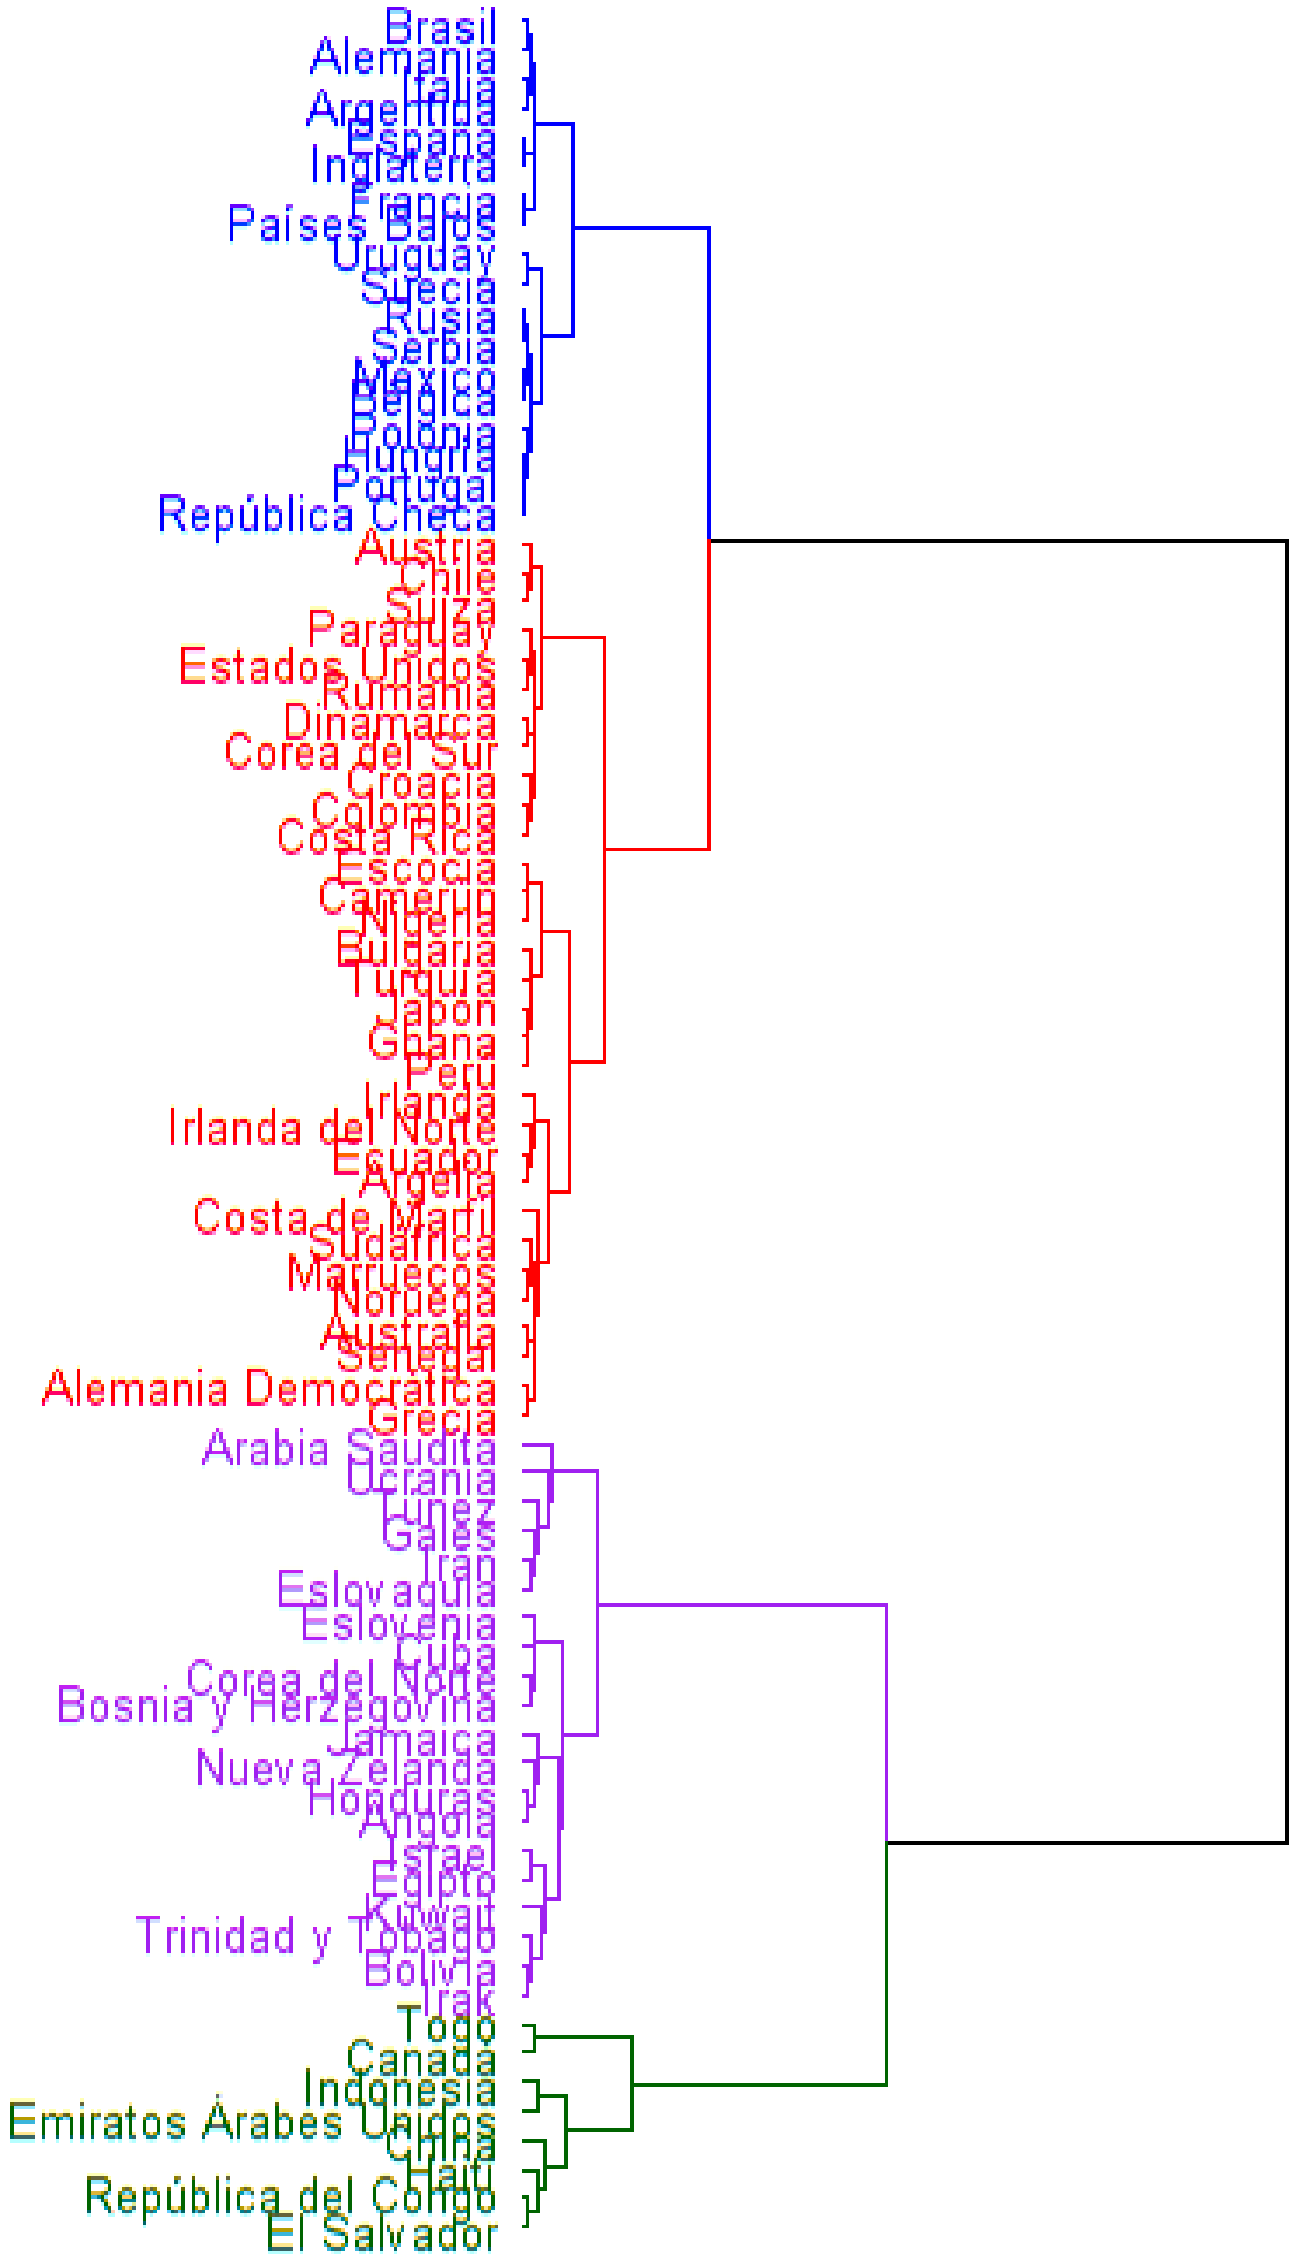
Ejemplo Futbol.xls

País	Mundiales	Puntos	PJ	PG	PE	PP	Rendimiento	GF	GC	Campeón
Brasil	20	227	104	70	17	17	0,73	221	102	1
Alemania	18	218	106	66	20	20	0,69	224	121	1
Italia	18	156	83	45	21	17	0,63	128	77	1
Argentina	16	140	77	42	14	21	0,61	131	84	1
España	14	99	59	29	12	18	0,56	92	66	1
Inglaterra	14	98	62	26	20	16	0,53	79	56	1
Francia	14	96	59	28	12	19	0,54	106	71	1
Países Bajos	10	93	50	27	12	11	0,62	86	48	0
Uruguay	12	72	51	20	12	19	0,47	80	71	1
Suecia	11	61	46	16	13	17	0,44	74	69	0
Rusia	10	59	40	17	8	15	0,49	66	47	0
Serbia	11	59	43	17	8	18	0,46	64	58	0
México	15	56	53	14	14	25	0,35	57	92	0
Bélgica	12	51	41	14	9	18	0,41	52	66	0
Polonia	7	50	31	15	5	11	0,54	44	40	0
Hungría	9	48	32	15	3	14	0,5	87	57	0
Portugal	6	43	26	13	4	9	0,55	43	29	0
República Checa	9	41	33	12	5	16	0,41	47	49	0
Austria	7	40	29	12	4	13	0,46	43	47	0
Chile	9	40	33	11	7	15	0,4	40	49	0
Suiza	10	39	33	11	6	16	0,39	45	59	0



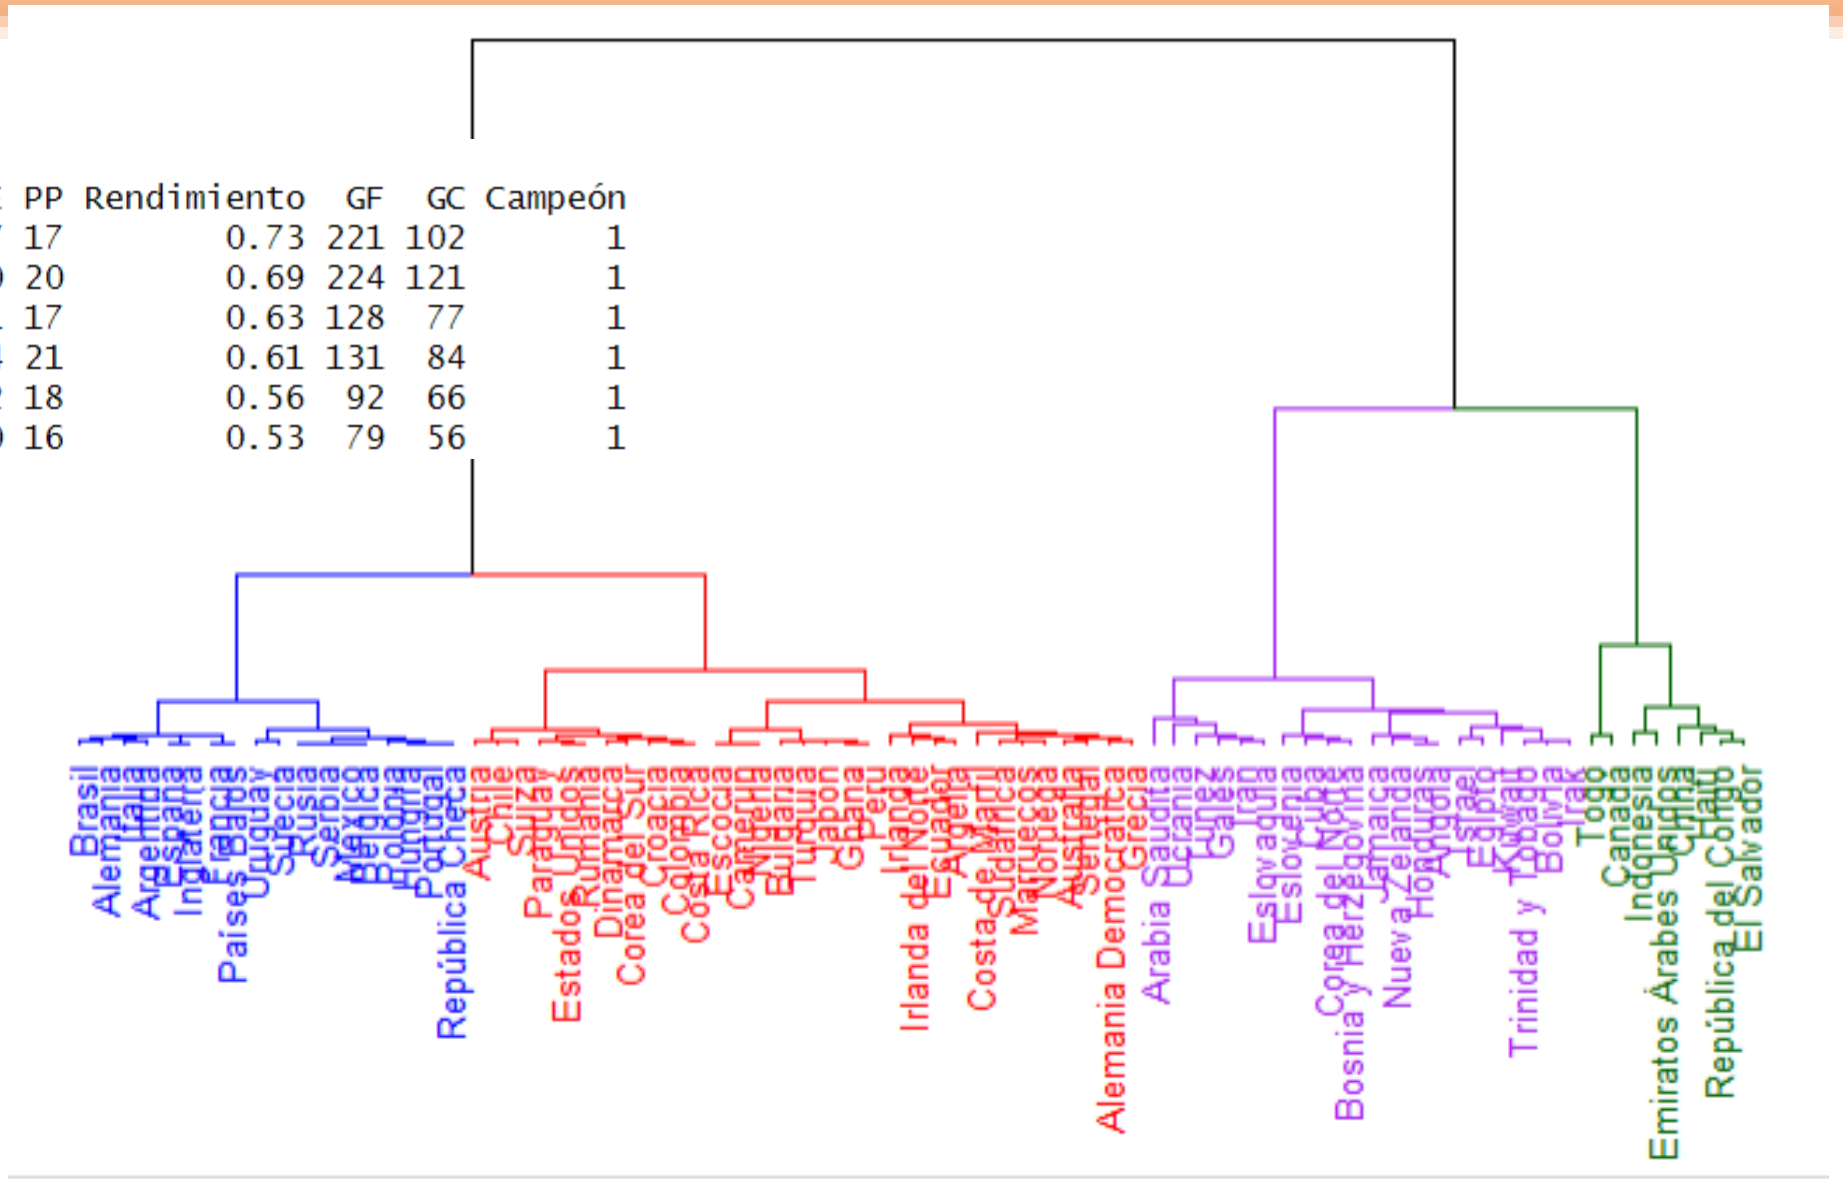
Ejemplo datos Futbol

	A	B	C	D	E	F	G	H	I	J	K
1	**País**	**Mundiales**	**Puntos**	**PJ**	**PG**	**PE**	**PP**	**Rendimiento**	**GF**	**GC**	**Campeón**
2	Brasil	20	227	104	70	17	17	0,73	221	102	1
3	Alemania	18	218	106	66	20	20	0,69	224	121	1
4	Italia	18	156	83	45	21	17	0,63	128	77	1
5	Argentina	16	140	77	42	14	21	0,61	131	84	1
6	España	14	99	59	29	12	18	0,56	92	66	1
7	Inglaterra	14	98	62	26	20	16	0,53	79	56	1
8	Francia	14	96	59	28	12	19	0,54	106	71	1
9	Países Bajos	10	93	50	27	12	11	0,62	86	48	0
10	Uruguay	12	72	51	20	12	19	0,47	80	71	1
11	Suecia	11	61	46	16	13	17	0,44	74	69	0
12	Rusia	10	59	40	17	8	15	0,49	66	47	0
13	Serbia	11	59	43	17	8	18	0,46	64	58	0
14	México	15	56	53	14	14	25	0,35	57	92	0
15	Bélgica	12	51	41	14	9	18	0,41	52	66	0
16	Polonia	7	50	31	15	5	11	0,54	44	40	0
17	Hungría	9	48	32	15	3	14	0,5	87	57	0
18	Portugal	6	43	26	13	4	9	0,55	43	29	0
19	República Checa	9	41	33	12	5	16	0,41	47	49	0
20	Austria	7	40	29	12	4	13	0,46	43	47	0
21	Chile	9	40	33	11	7	15	0,4	40	49	0
22	Suiza	10	39	33	11	6	16	0,39	45	59	0
23	Paraguay	8	31	27	7	10	10	0,38	30	38	0
24	Estados Unidos	10	30	33	8	6	19	0,3	37	62	0
25	Rumania	7	29	21	8	5	8	0,46	30	33	0
26	Dinamarca	4	26	16	8	2	6	0,54	27	24	0


Brasil
Alemania
Italia
Argentina
España
Inglaterra
Francia
Países Bajos
Uruguay
Suecia
Rusia
Serbia
México
Bélgica
Polonia
Hungría
Portugal
República Checa
Austria
Chile
Suiza
Paraguay
Estados Unidos
Rumania
Dinamarca
Corea del Sur
Croacia
Colombia
Costa Rica
Escocia
Camerún
Nigeria
Bulgaria
Turquía
Japón
Ghana
Perú
Irlanda
Irlanda del Norte
Ecuador
Argelia
Costa de Marfil
Sudáfrica
Marruecos
Noruega
Australia
Senegal
Alemania Democrática
Grecia
Arabia Saudita
Ucrania
Túnez
Gales
Irán
Eslovaquia
Eslovenia
Cuba
Corea del Norte
Bosnia y Herzegovina
Jamaica
Nueva Zelanda
Honduras
Angola
Israel
Egipto
Kuwait
Trinidad y Tobago
Bolivia
Irak
Togo
Canadá
Indonesia
Emiratos Árabes Unidos
China
Haití
República del Congo
El Salvador

Futbol

```
> head(futnum)
  Mundiales Puntos  PJ PG PE PP Rendimiento  GF  GC Campeón
1        20    227 104 70 17 17         0.73 221 102       1
2        18    218 106 66 20 20         0.69 224 121       1
3        18    156  83 45 21 17         0.63 128  77       1
4        16    140  77 42 14 21         0.61 131  84       1
5        14     99  59 29 12 18         0.56  92  66       1
6        14     98  62 26 20 16         0.53  79  56       1
```

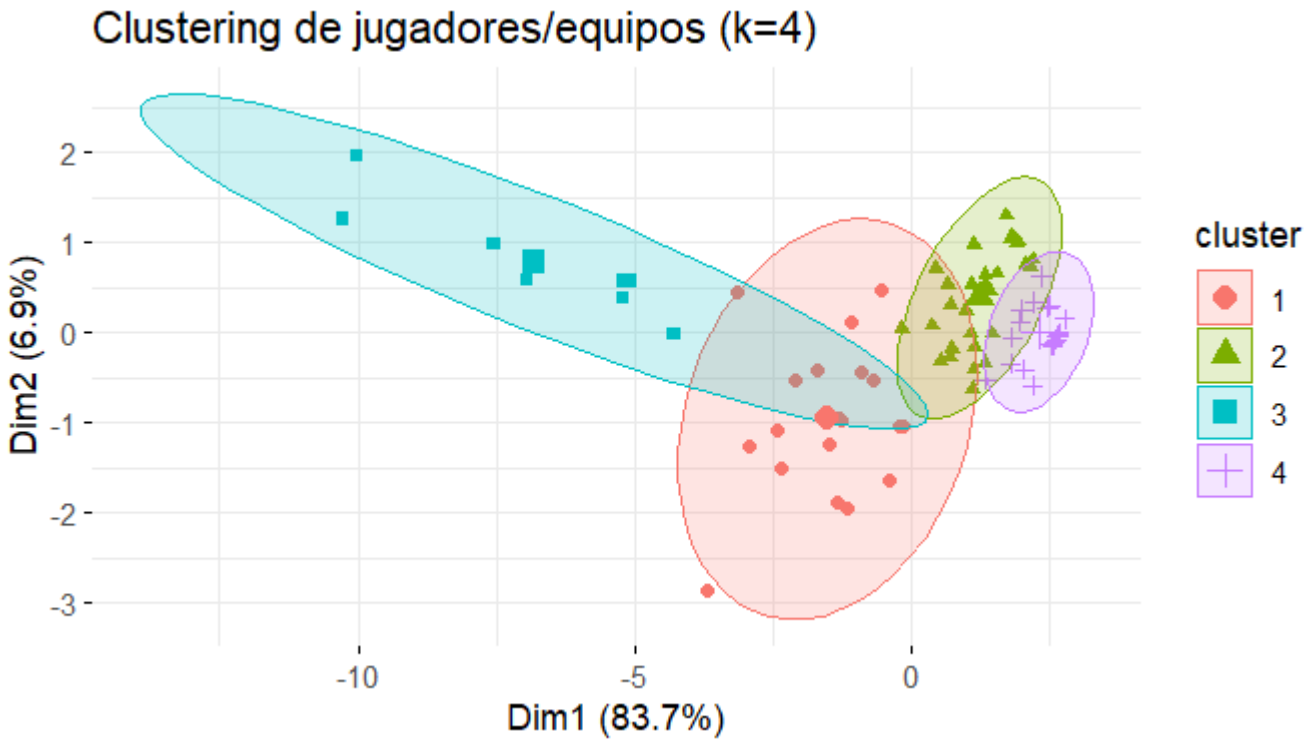


PCA y Kmedias

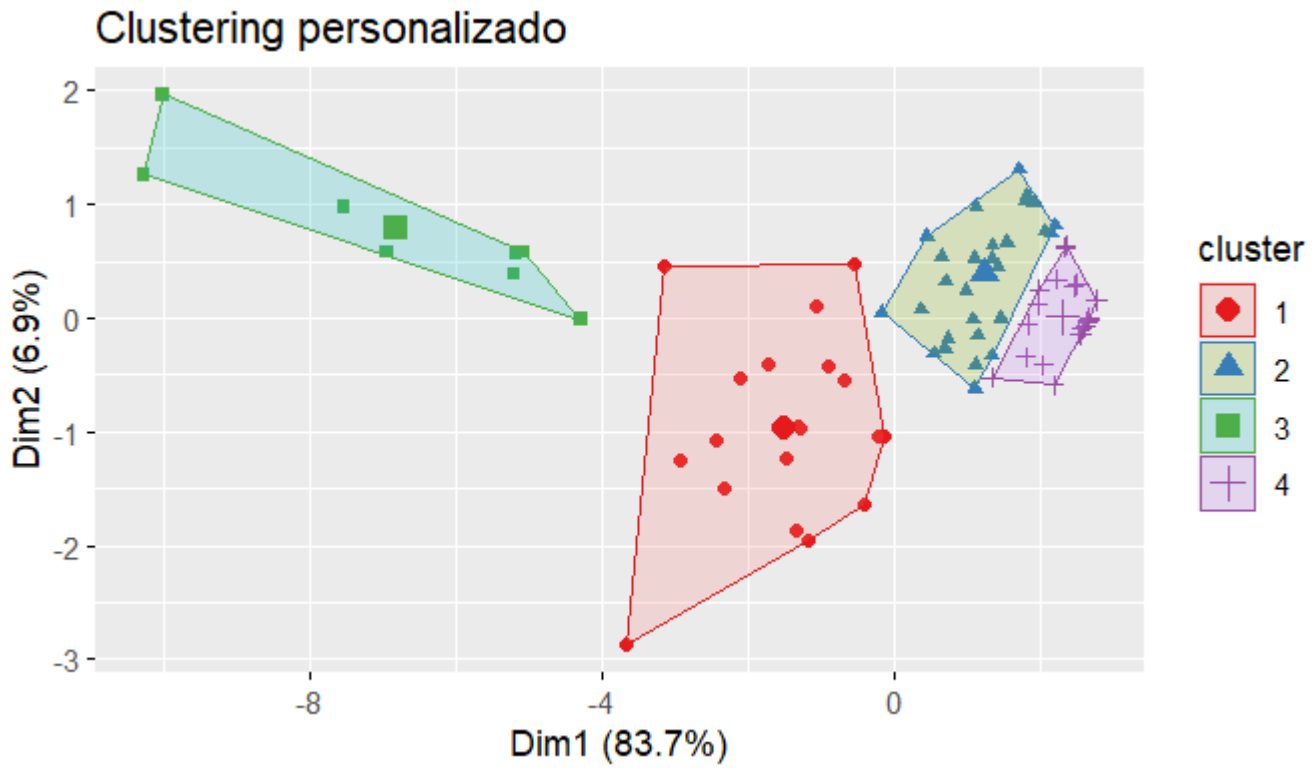
- **fviz_cluster**(kmfutbol, data = df, geom = "point", ellipse.type = "norm", ellipse.alpha = 0.3, pointsize = 2, alpha = 0.7,

ggtheme = theme_minimal(), main = "Clustering de jugadores/equipos (k=4)") +

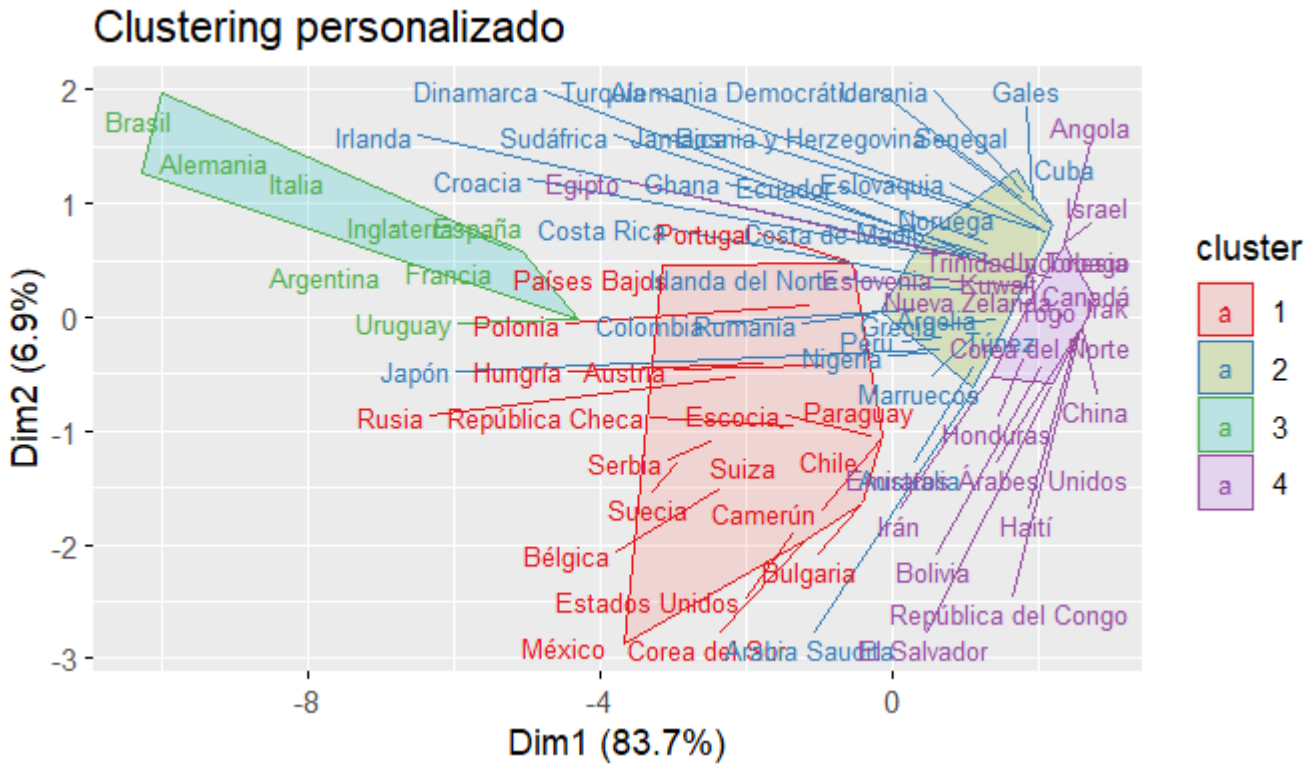
theme(legend.position = "right") + scale_color_manual(values = c("#E41A1C", "#377EB8", "#4DAF4A", "#984EA3")) + scale_fill_manual(values = c("#E41A1C", "#377EB8", "#4DAF4A", "#984EA3"))



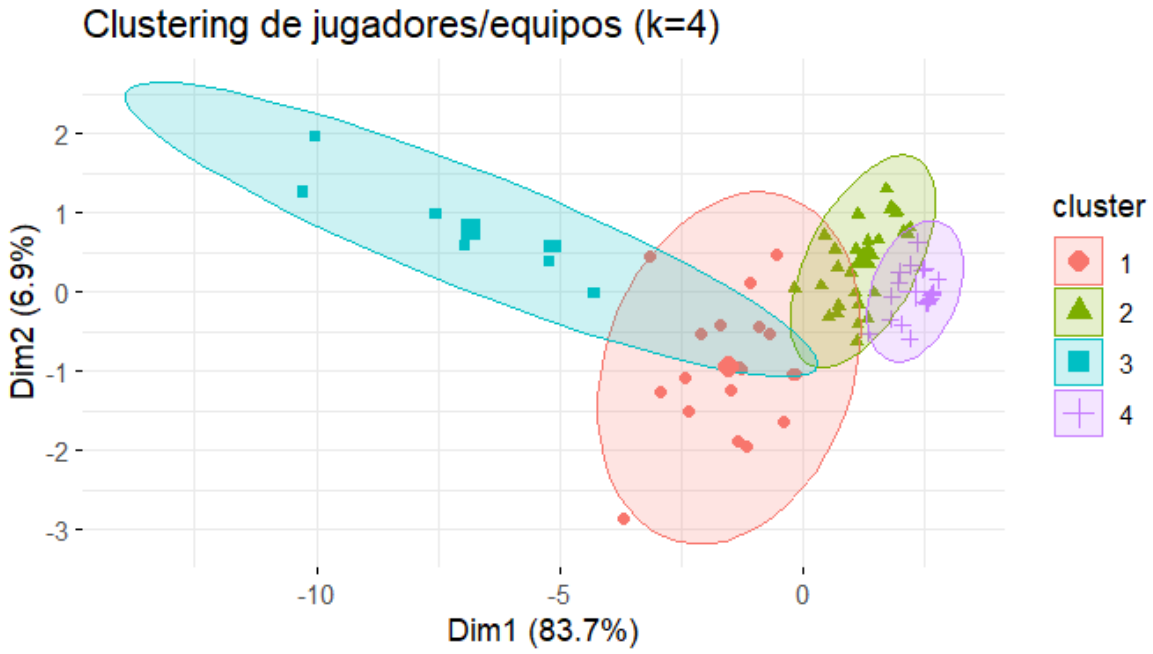
- # Clasificación personalizada con factoextrafviz_cluster(kmfutbol, data=df, geom=“point", labelsize=8, repel=TRUE) + scale_color_brewer(palette="Set1") + ggtitle("Clustering personalizado")

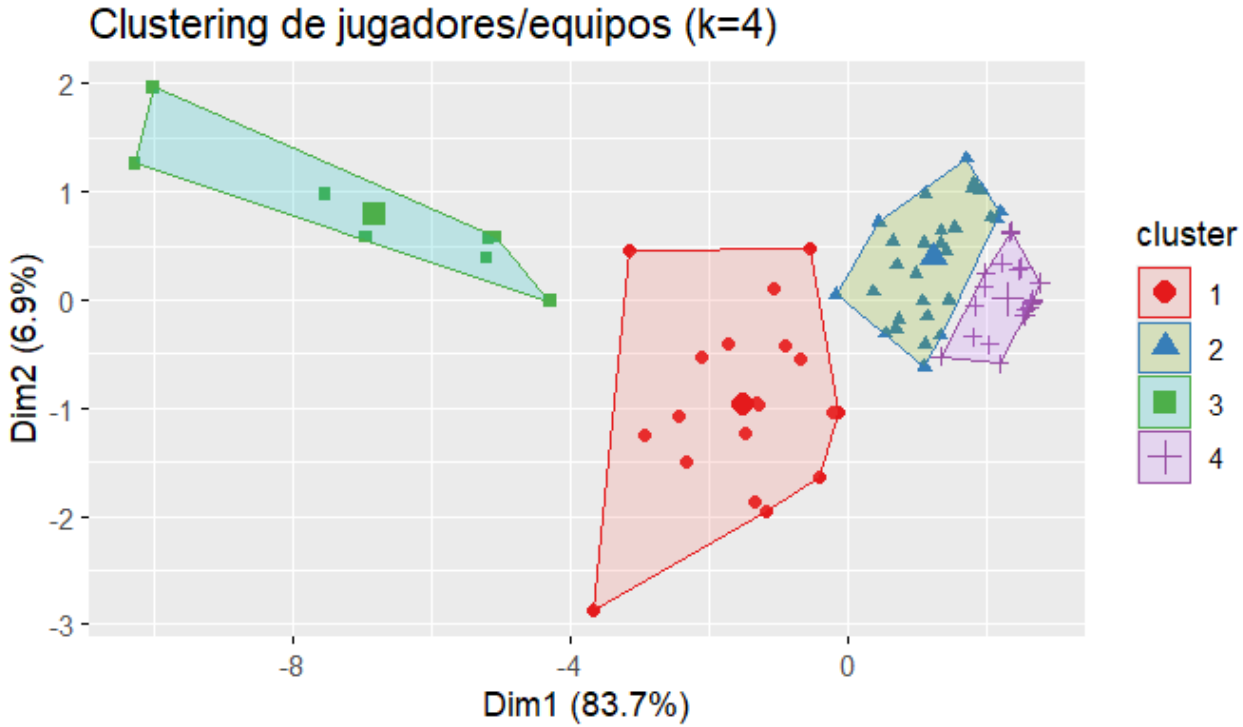


- # Clasificación personalizada con factoextrafviz_cluster(kmfutbol, data=df, geom="text", labelsize=8, repel=TRUE) + scale_color_brewer(palette="Set1") + ggtitle("Clustering personalizado")



Son los mismo cluster pero se visualizan diferente

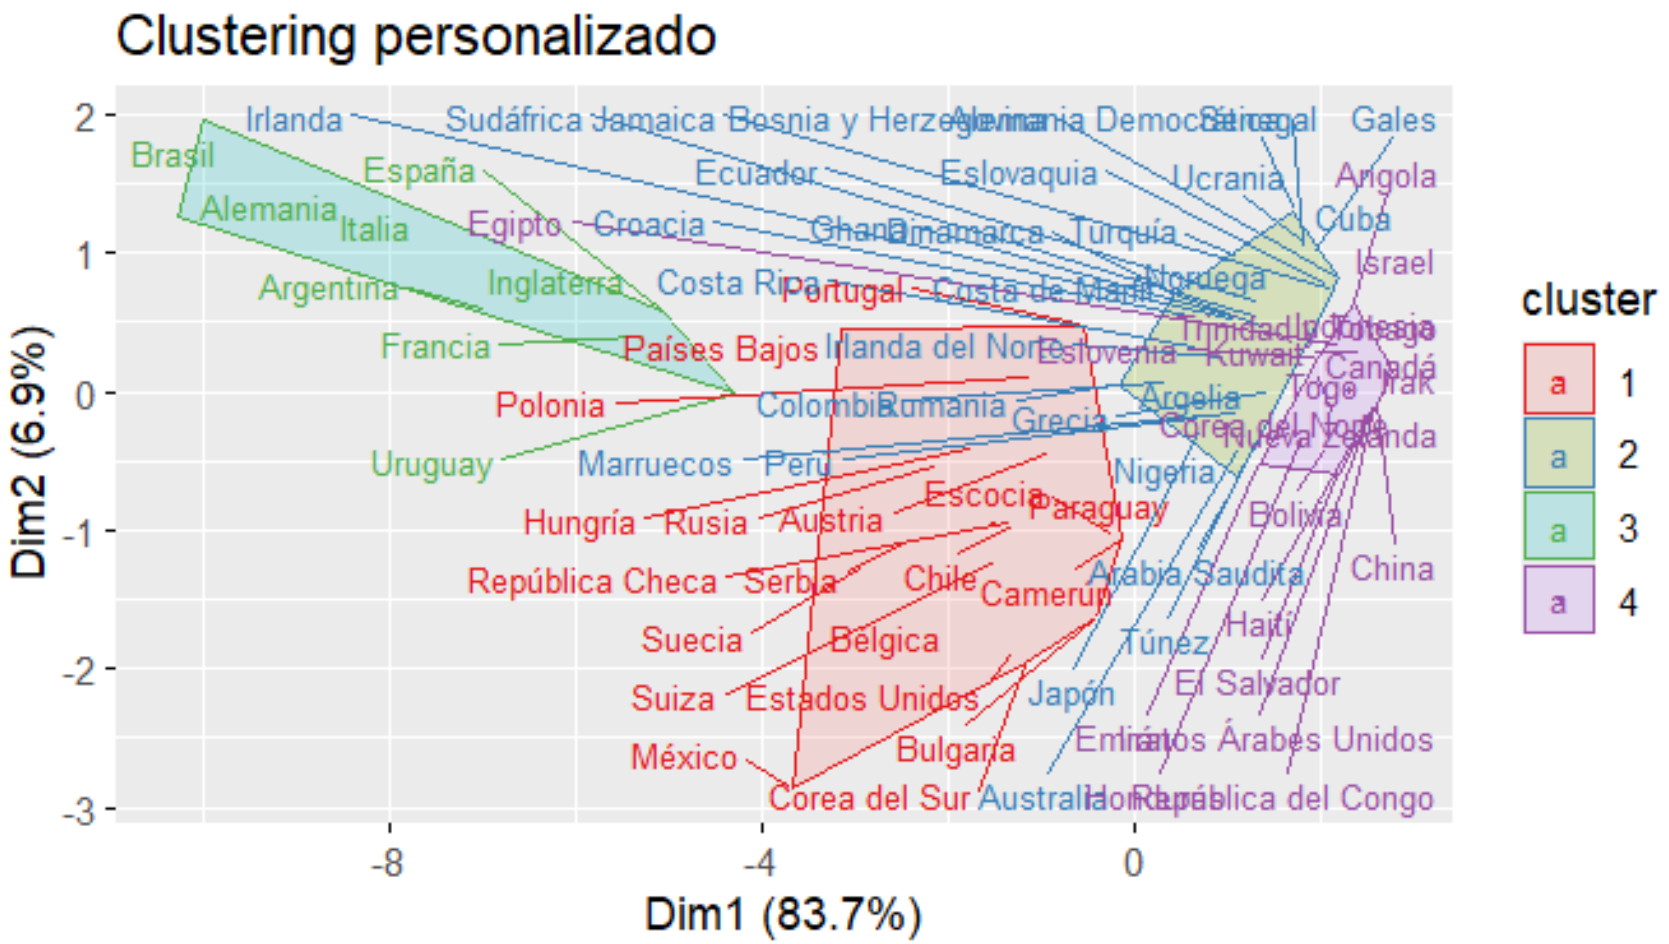




fviz_cluster(kmfutbol, data = df,
geom = "point",
ellipse.type = "norm",
ellipse.alpha = 0.3, pointsize = 2, alpha = 0.7,

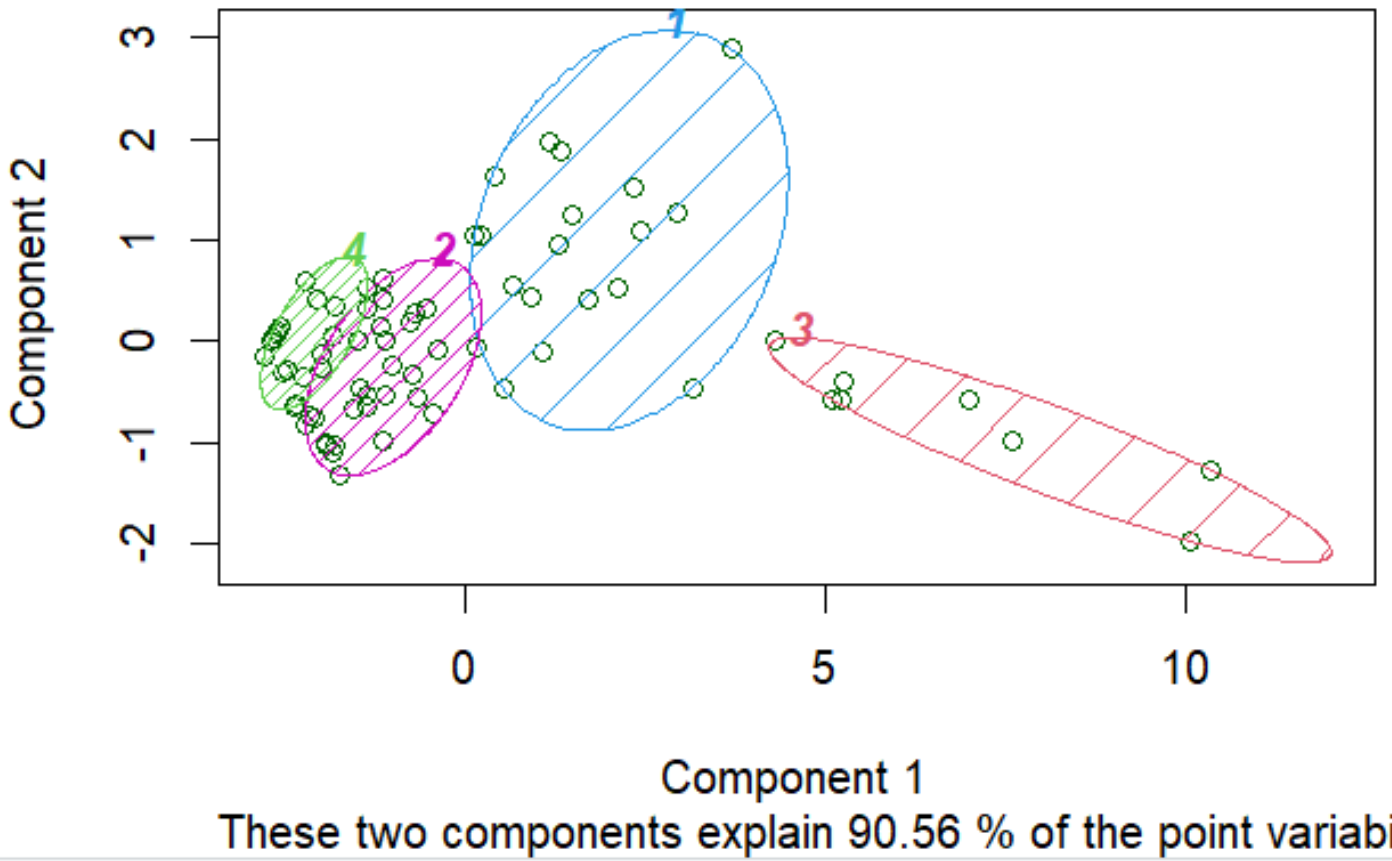
fviz_cluster(kmfutbol, data=df, geom="point", labelsize=8, repel=TRUE) + scale_color_brewer(palette="Set1") + ggtitle("Clustering personalizado")

Con etiquetas de individuos (países)

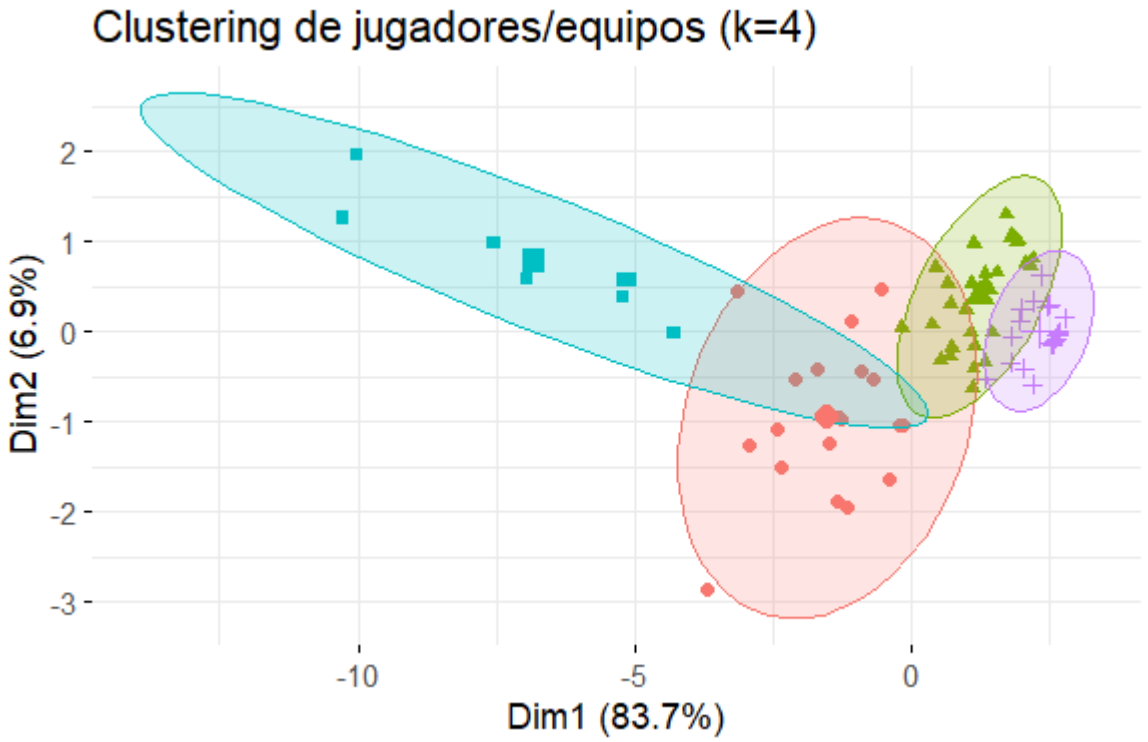


PCA y Kmedias

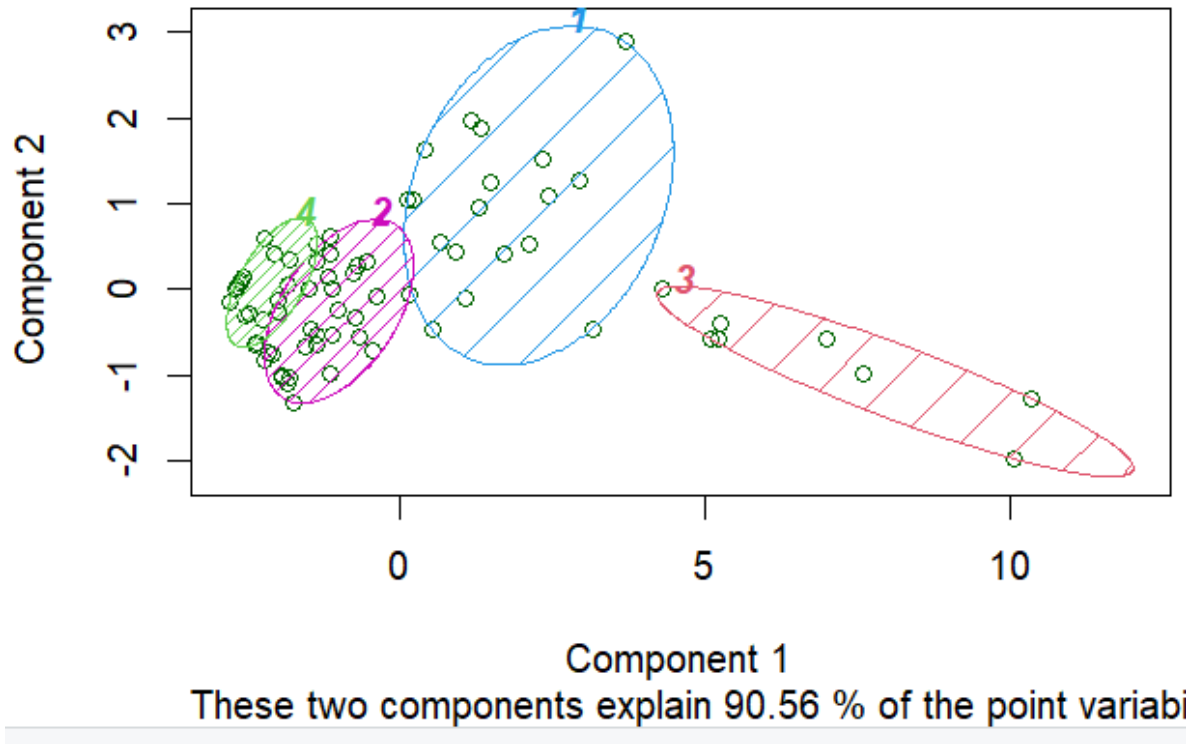
- clusplot(df, kmfutbol$cluster, main=NULL, color=TRUE, shade=TRUE, labels=4, lines=0, plotchar=FALSE)



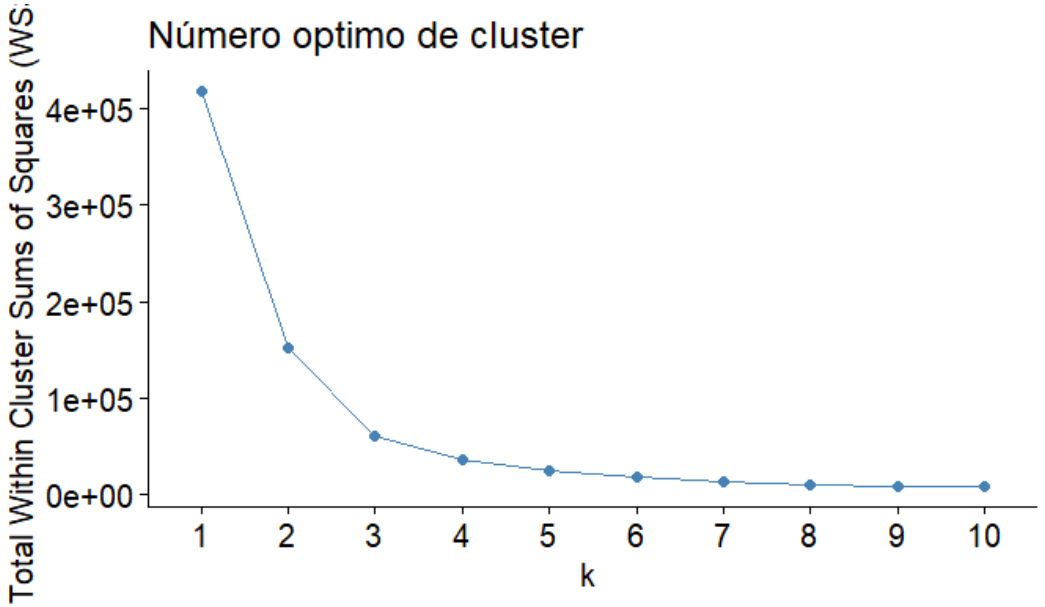
PCA invierte los ejes Dim1 y Dim2 (pos con neg)

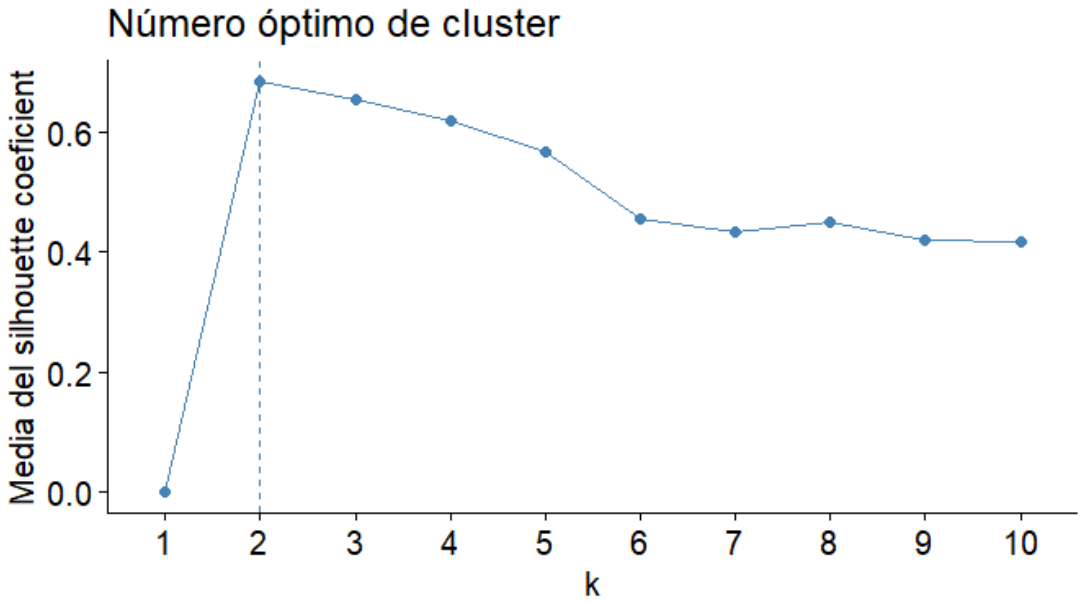


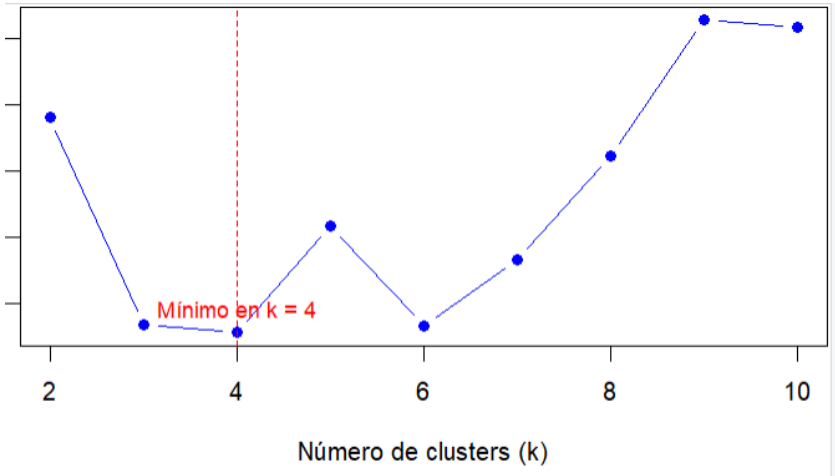




Kmedias
Metodo codo y DB→ K=4 --- Silhouette: K=2

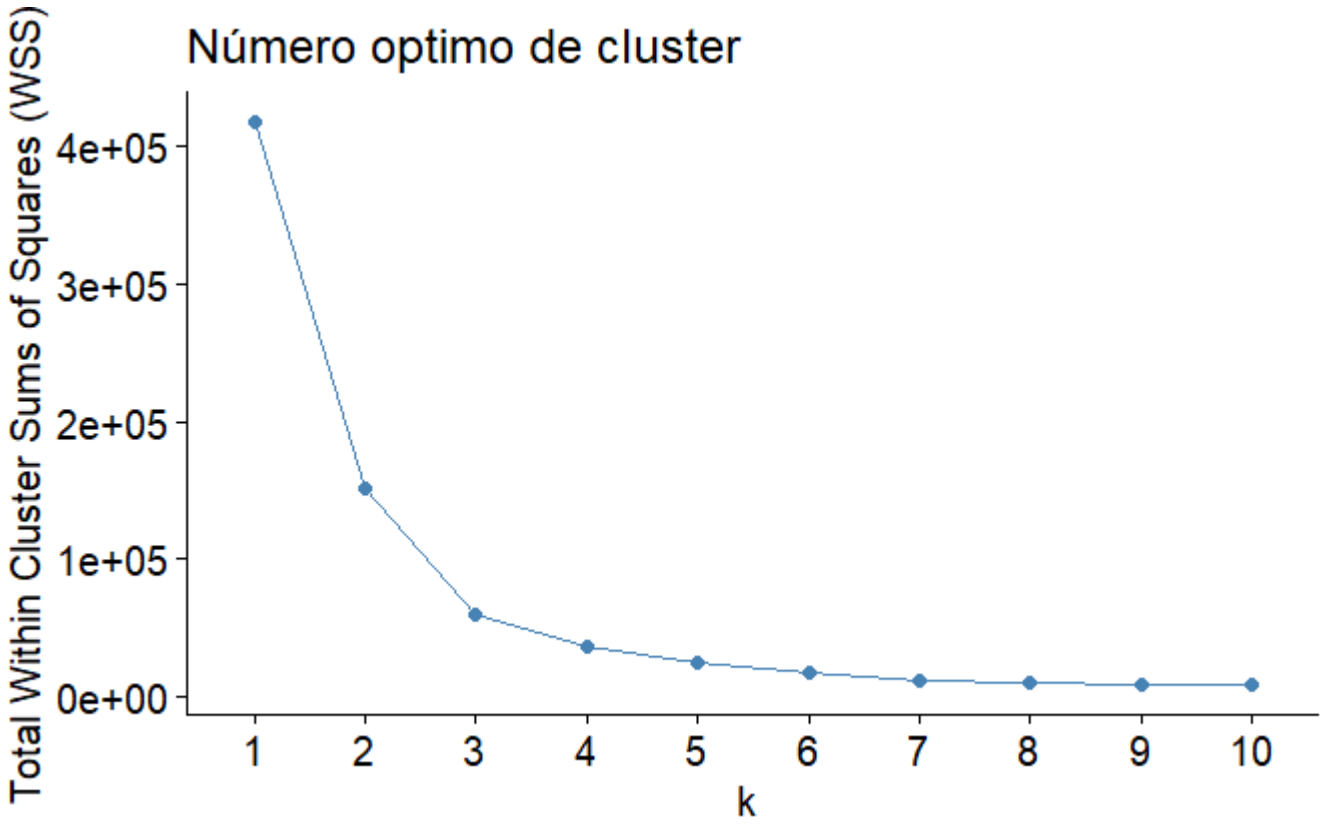






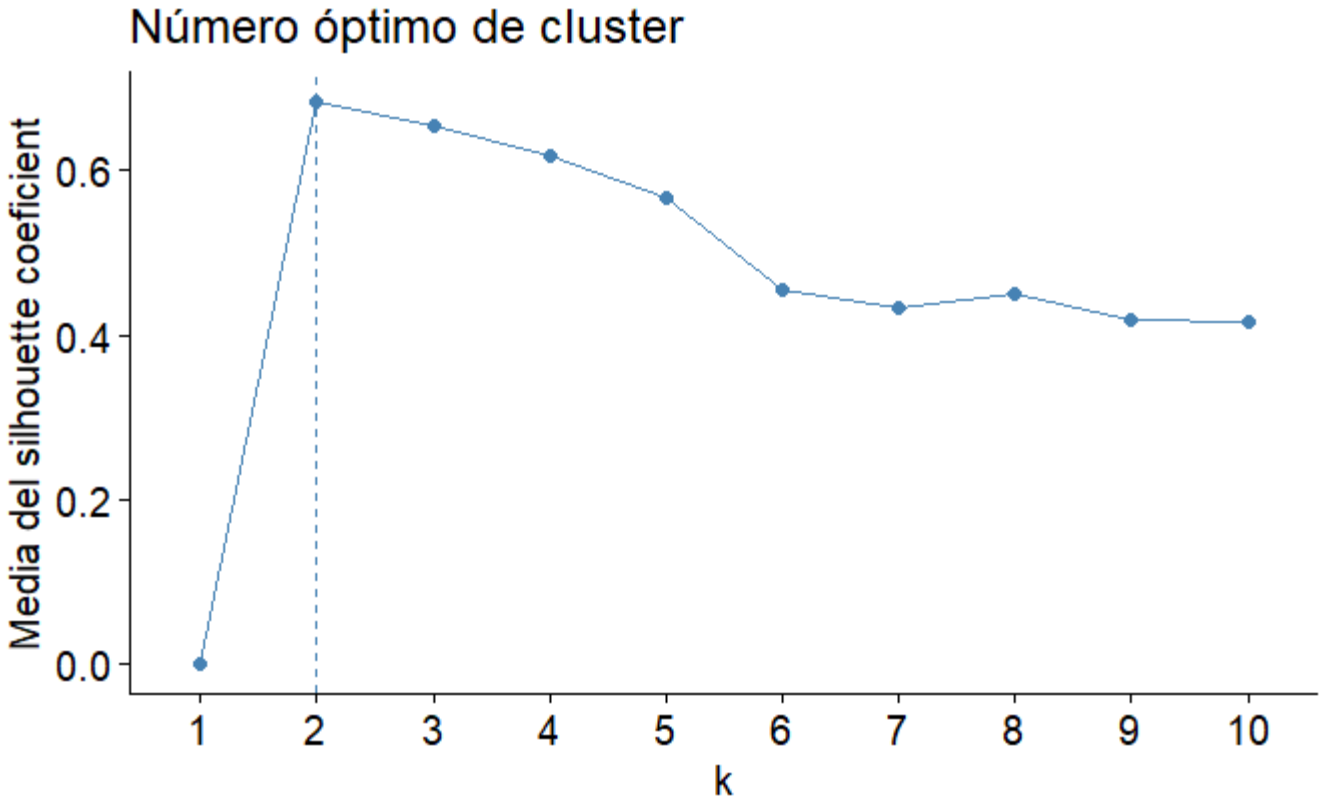
WSS

```
fviz_nbclust(futnum, FUNcluster = kmeans,
method = "wss", k.max = 10,              diss =
get_dist(futnum, method = "euclidean"),
nstart = 50)+   labs(title= "Número optimo de
cluster") +   xlab("k ") +   ylab("Total Within
Cluster Sums of Squares (WSS)")
```



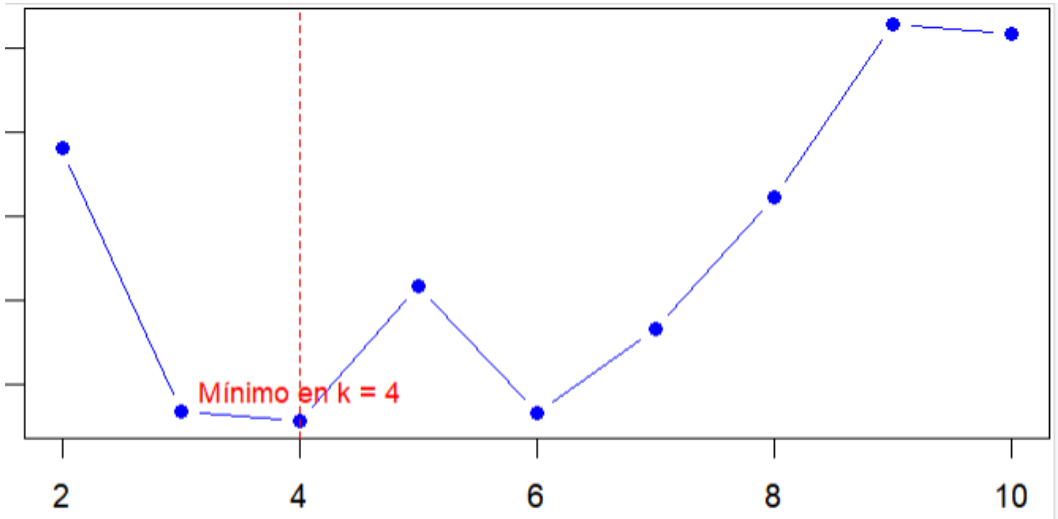
Silhouette

```
# Utilizar el método de average silhouette para determinar # el número de k agrupaciones óptimo
fviz_nbclust(futnum, kmeans, method = "silhouette", k.max = 10, diss = get_dist(futnum, method = "euclidean"), nstart = 50)+ labs(title= "Número óptimo de cluster") + xlab("k") +  ylab("Media del silhouette coeficient")
```



Davies Bouldin

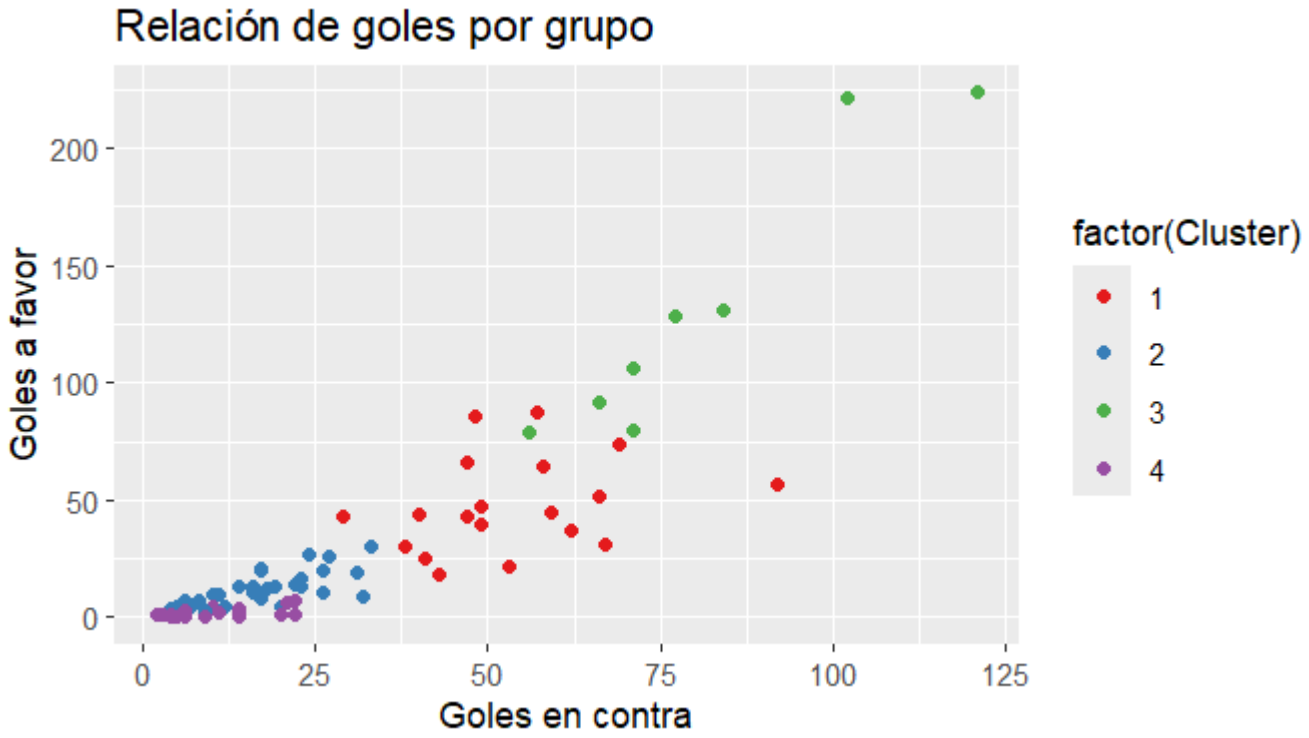
```
# Evaluar DBI para distintos valores de kdbi_valores <-
sapply(2:10, function(k) {  km <- kmeans(futnum, centers = k,
nstart = 25)  index.DB(x = futnum, cl = km$cluster, centrotypes
= "centroids")$DB})
 # Calcular valores DBdbi_valores <- sapply(2:10, function(k) {
km <- kmeans(futnum, centers = k, nstart = 50)  # Aumenta
nstart para mayor estabilidad   clusterSim::index.DB(x =
futnum, cl = km$cluster, centrotypes = "centroids")$DB})#
Imprimir valoresvalores_db <- data.frame(k = 2:10, DB =
dbi_valores)print(valores_db) # Mostrar tabla print(tabla_dbi)
```




```
> print(valores_db)
   k        DB
1  2 0.7409209
2  3 0.5843632
3  4 0.5778283
4  5 0.6581695
5  6 0.5829566
6  7 0.6329225
7  8 0.7110929
8  9 0.8142790
9 10 0.8080887
>  # Mostrar tabla
>  print(tabla_dbi)
  Clusters   DBI
1        2 0.741
2        3 0.584
3        4 0.670
4        5 0.658
5        6 0.712
6        7 0.694
7        8 0.711
8        9 0.774
9       10 0.746
```

Guardar grupo de pertencia

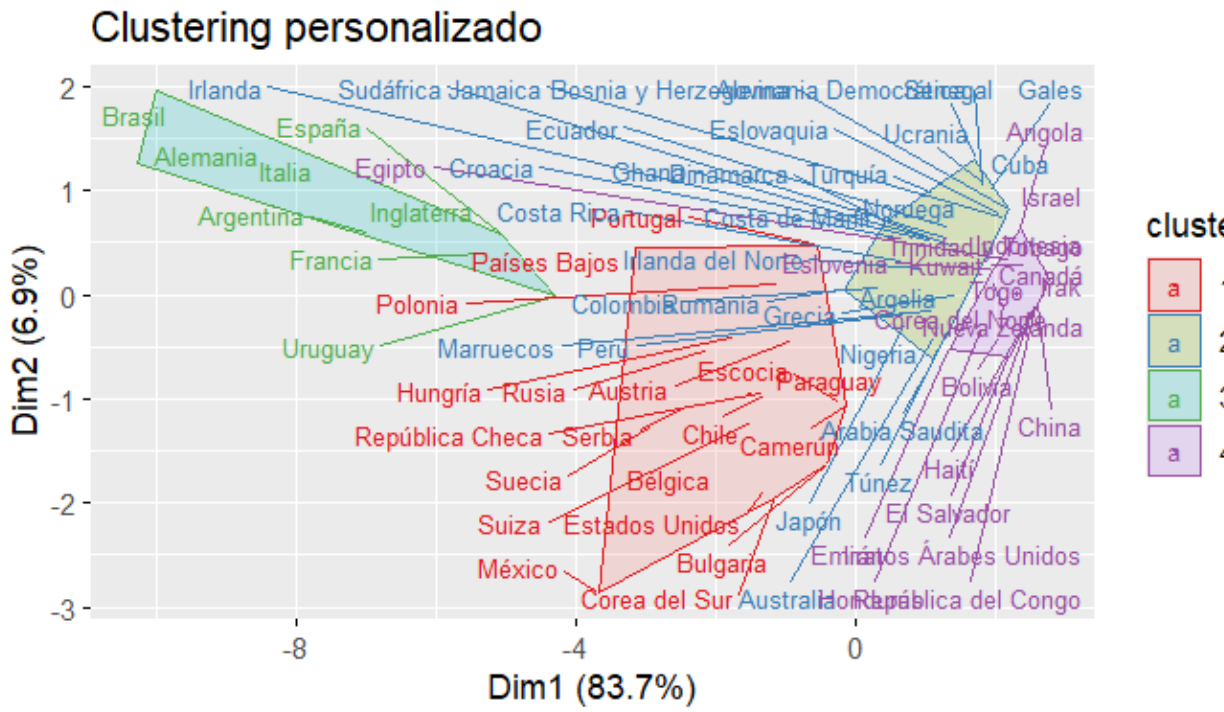
```
# ==========================================#
Guardar el grupo de pertenencia de cada país#
==========================================Clus
ter <- kmfutbol$clusterdatos <- data.frame(cbind(futbol,
Cluster))
```



Media del Cluster y ejemplo

	Cluster	N	GF_Media	GF_Mediana	GF_Desvio	Ejemplo
1	1	19	47,9	44	20,1	Chile
2	2	30	12,2	11	7,37	Noruega
3	3	8	133	117	58,8	Argentina
4	4	20	2	1	2,08	Bolivia

Cluster	N	GC_Media	GC_Mediana	GC_Desvio	Ejemplo
1	19	53,4	49	14,2	Chile
2	30	16,8	17	8,64	Noruega
3	8	81	74	21,1	Argentina
4	20	10,6	9,5	6,65	Bolivia



Guardar el Cluster de pertenencia y Analizar

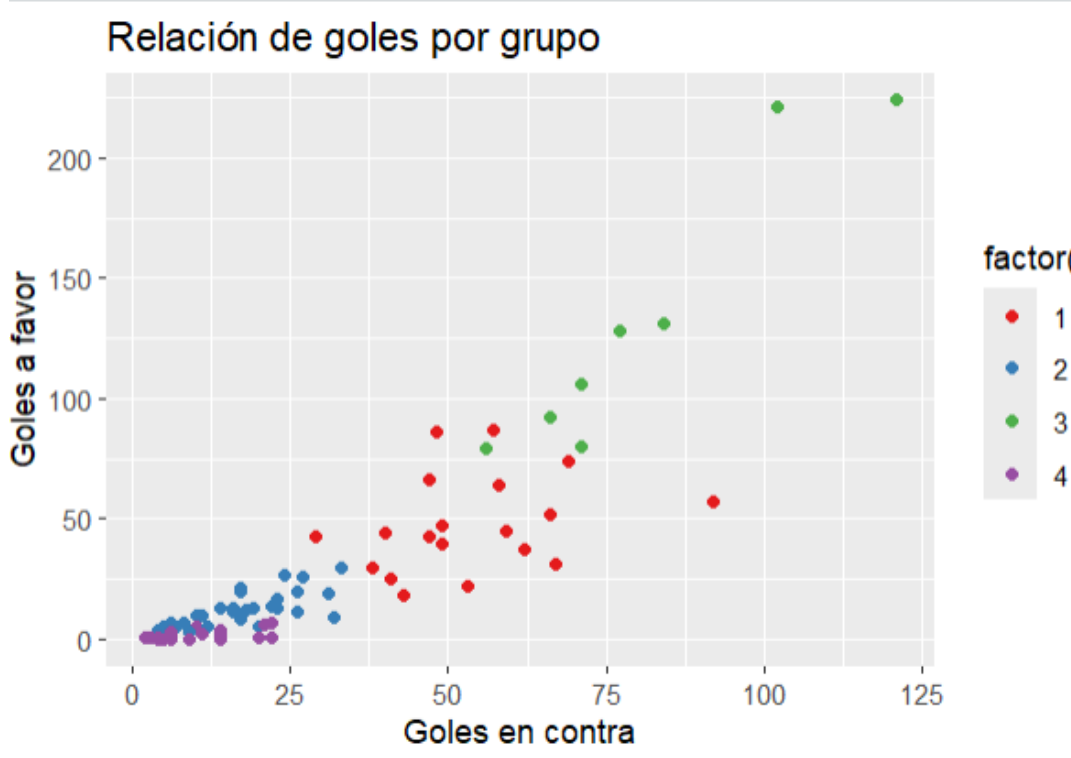
```
> head(datos)
                País Mundiales Puntos  PJ PG PE PP Rendimiento  GF  GC Campeón Cluster
Brasil         Brasil        20    227 104 70 17 17        0.73 221 102       1       3
Alemania     Alemania        18    218 106 66 20 20        0.69 224 121       1       3
Italia         Italia        18    156  83 45 21 17        0.63 128  77       1       3
Argentina   Argentina        16    140  77 42 14 21        0.61 131  84       1       3
España         España        14     99  59 29 12 18        0.56  92  66       1       3
Inglaterra Inglaterra        14     98  62 26 20 16        0.53  79  56       1       3
```

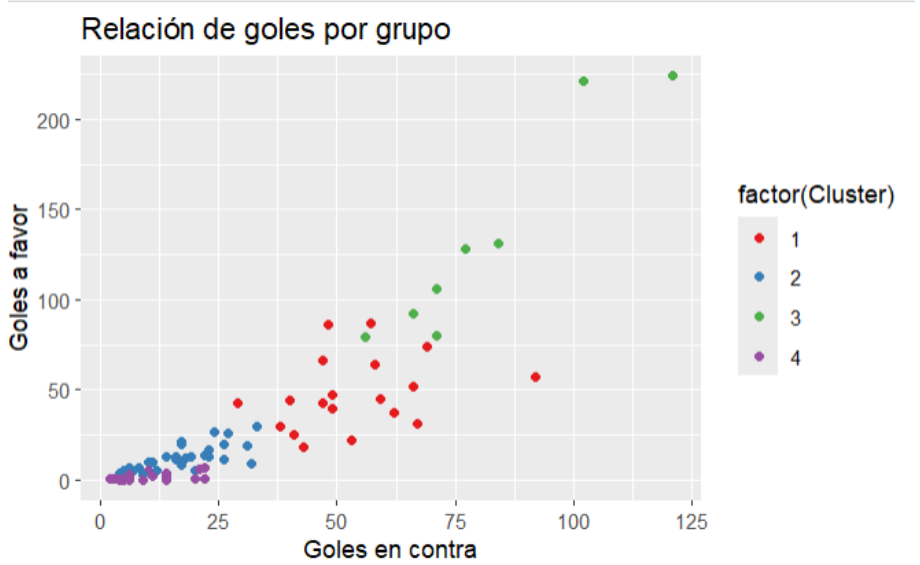
Table: Estadísticas de GF y GC por Cluster

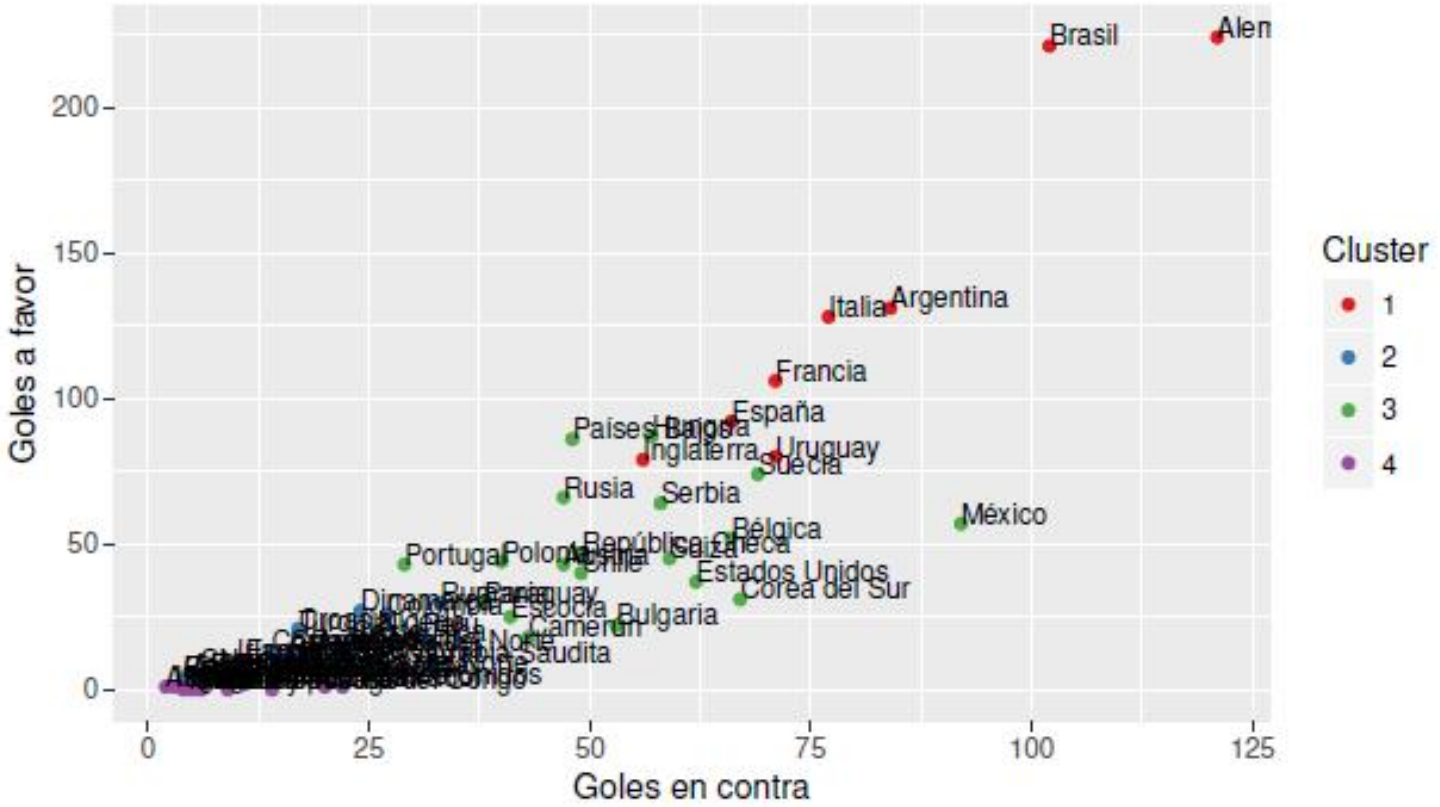
Cluster	N	GF_Media	GF_Mediana	GF_Desvio	GC_Media	GC_Mediana	GC_Desvio
1	19	47.947	44	20.134	53.368	49.0	14.221
2	30	12.233	11	7.366	16.800	17.0	8.644
3	8	132.625	117	58.783	81.000	74.0	21.098
4	20	2.000	1	2.077	10.650	9.5	6.651

Table: Estadísticas de GF y GC por Cluster (formato largo)

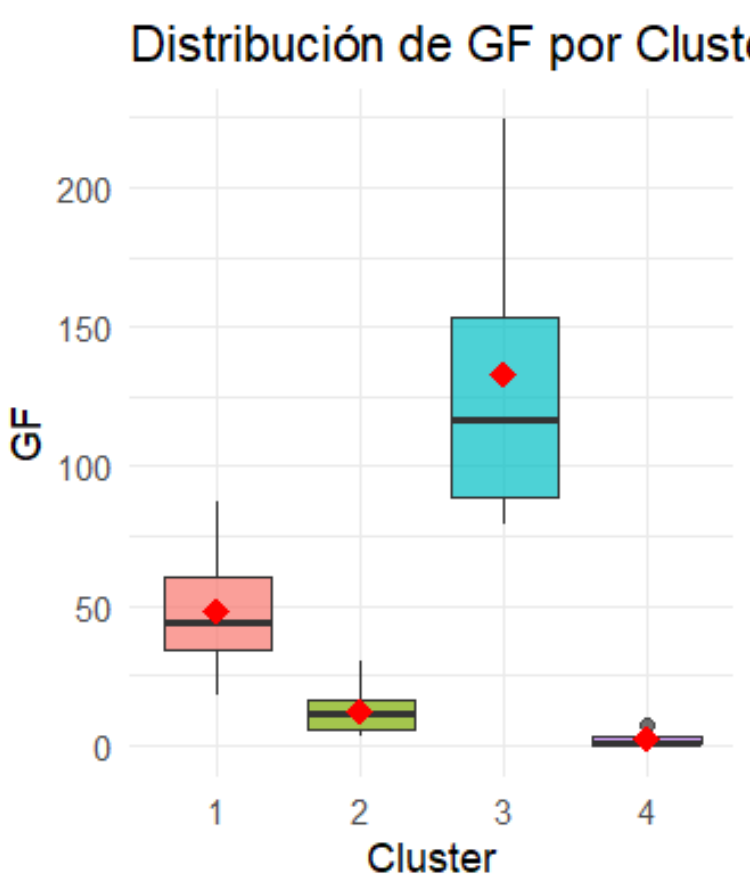
Cluster	N	Variable	Media	Mediana	Desvio
1	19	GF	47.947	44.0	20.134
1	19	GC	53.368	49.0	14.221
2	30	GF	12.233	11.0	7.366
2	30	GC	16.800	17.0	8.644
3	8	GF	132.625	117.0	58.783
3	8	GC	81.000	74.0	21.098
4	20	GF	2.000	1.0	2.077
4	20	GC	10.650	9.5	6.651

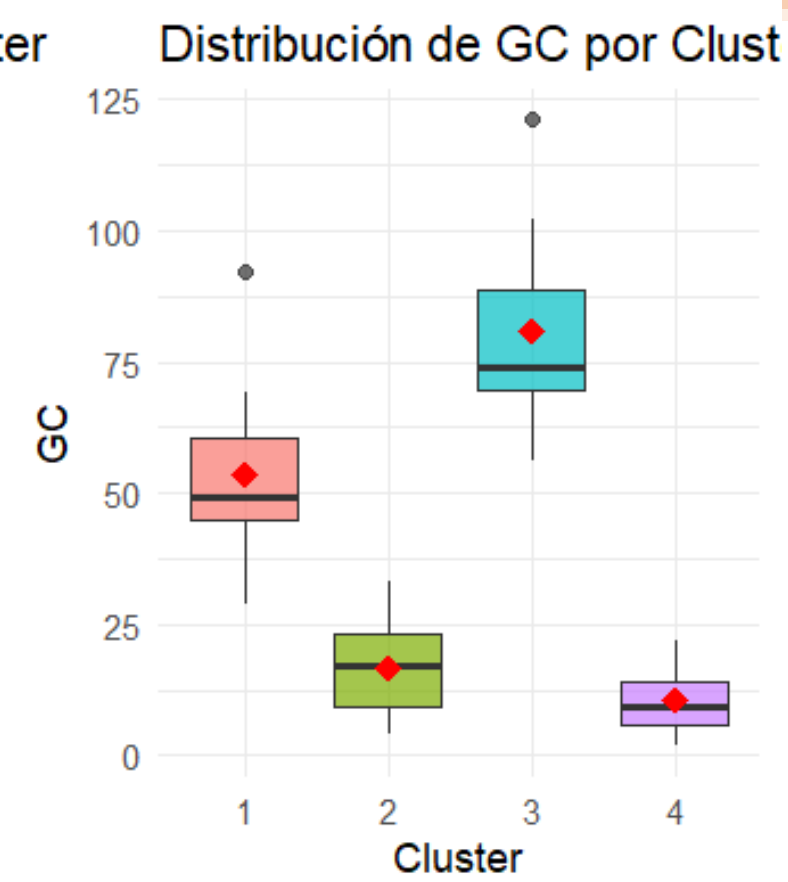



Relación de goles por grupo
Goles a favor
Goles en contra
0
50
100
150
200
0
25
50
75
100
125
factor(Cluster)
1
2
3
4


Goles a favor
Goles en contra
0
50
100
150
200
0
25
50
75
100
125
Brasil
Italia
Argentina
Francia
España
Uruguay
Suecia
Rusia
Serbia
México
Bélgica
Portugal
Estados Unidos
Corea del Sur
Bulgaria
Cluster
1
2
3
4

Diferencia de medias/medianas





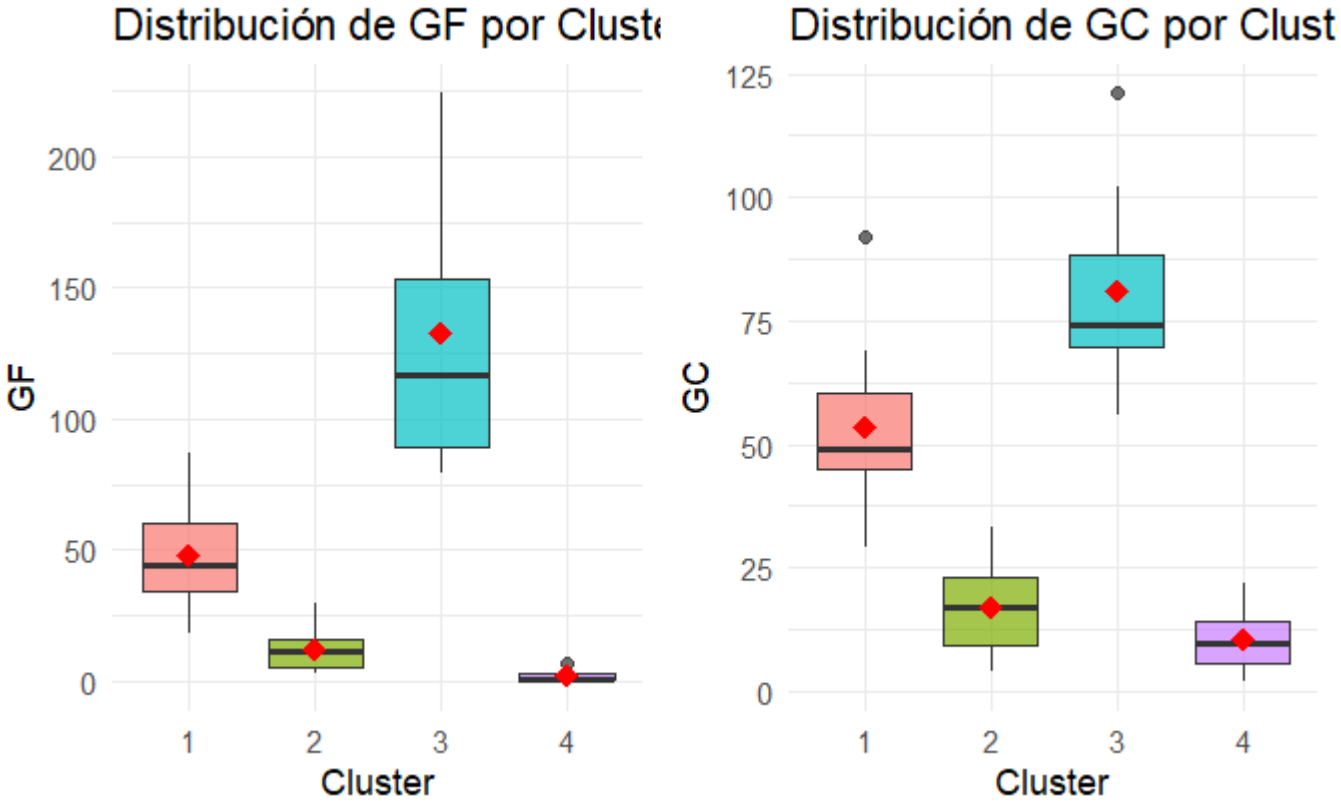
Cluster	N	GF_Media	GF_Mediana	GF_Desvio	Ejemplo
1	19	47,9	44	20,1	Chile
2	30	12,2	11	7,37	Noruega
3	8	133	117	58,8	Argentina
4	20	2	1	2,08	Bolivia

Cluster	N	GC_Media	GC_Mediana	GC_Desvio	Ejemplo
1	19	53,4	49	14,2	Chile
2	30	16,8	17	8,64	Noruega
3	8	81	74	21,1	Argentina
4	20	10,6	9,5	6,65	Bolivia

Ver las escalas

```
PRUEBAS DE KRUSKAL-WALLIS:
> cat("GF - p-valor:", kruskal.test(GF ~ Cluster, data = datos)$p.value, "\n")
GF - p-valor: 4.858819e-14
> cat("GC - p-valor:", kruskal.test(GC ~ Cluster, data = datos)$p.value, "\n")
GC - p-valor: 4.877033e-12
```

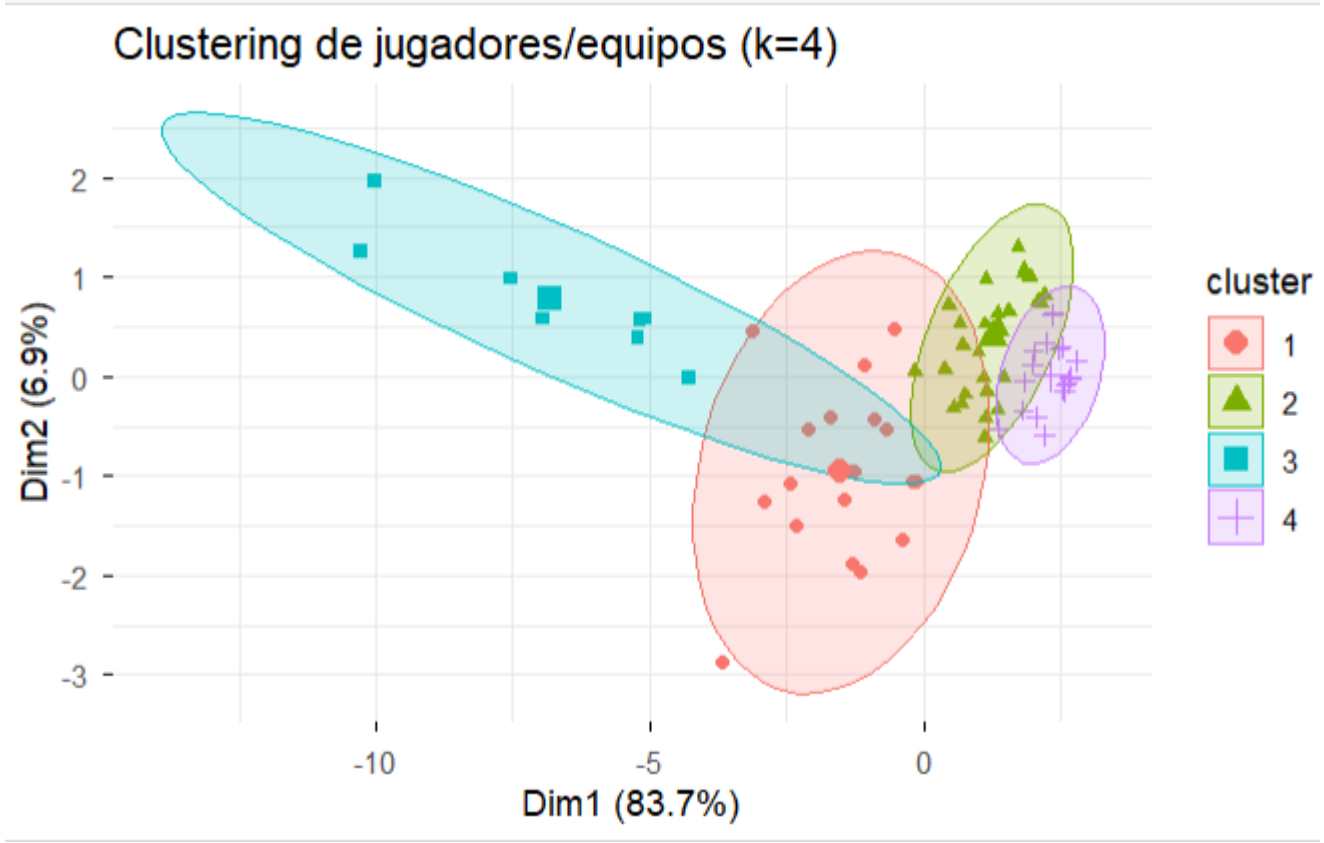
Diferencia de medias por cluster Kruscal-Wallus (no paramétrica)

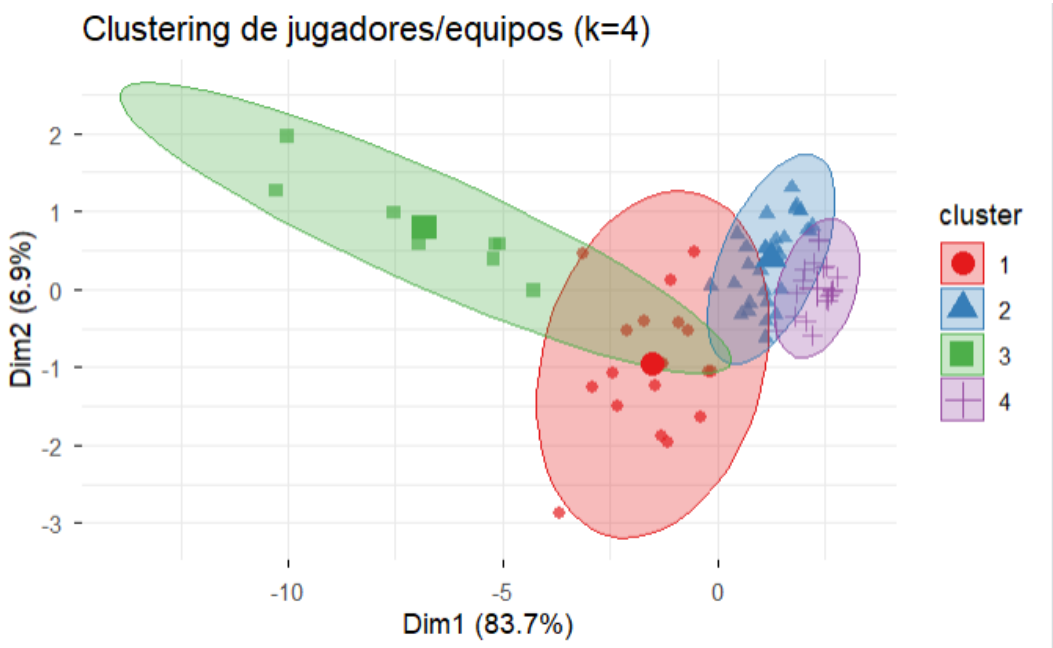



```
PRUEBAS DE KRUSKAL-WALLIS:
> cat("GF - p-valor:", kruskal.test(GF ~ Cluster, data = datos)$p.value, "\n")
GF - p-valor: 4.858819e-14
> cat("GC - p-valor:", kruskal.test(GC ~ Cluster, data = datos)$p.value, "\n")
GC - p-valor: 4.877033e-12
> |
```

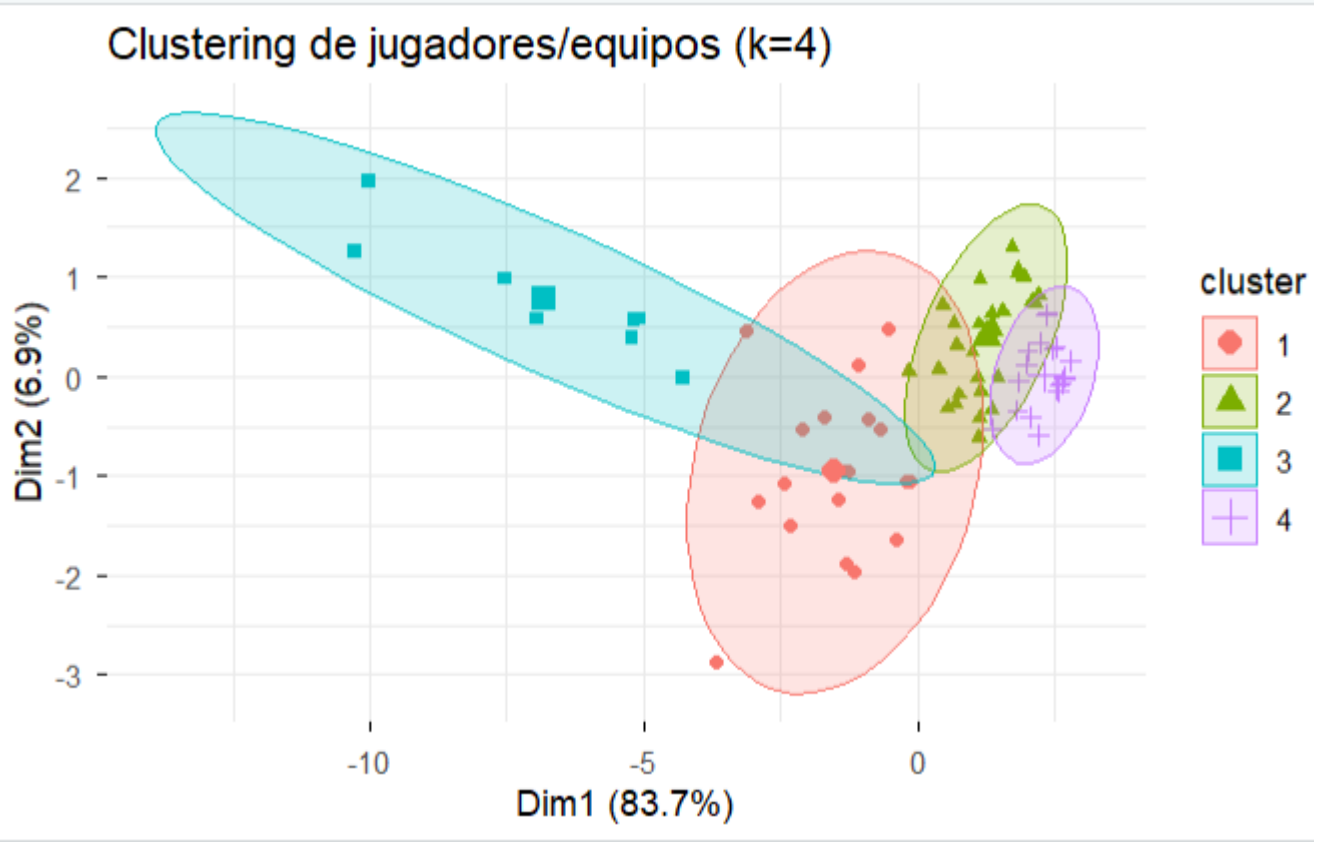
ANOVA NO PARAMÉTRICO. Diferencias significativas

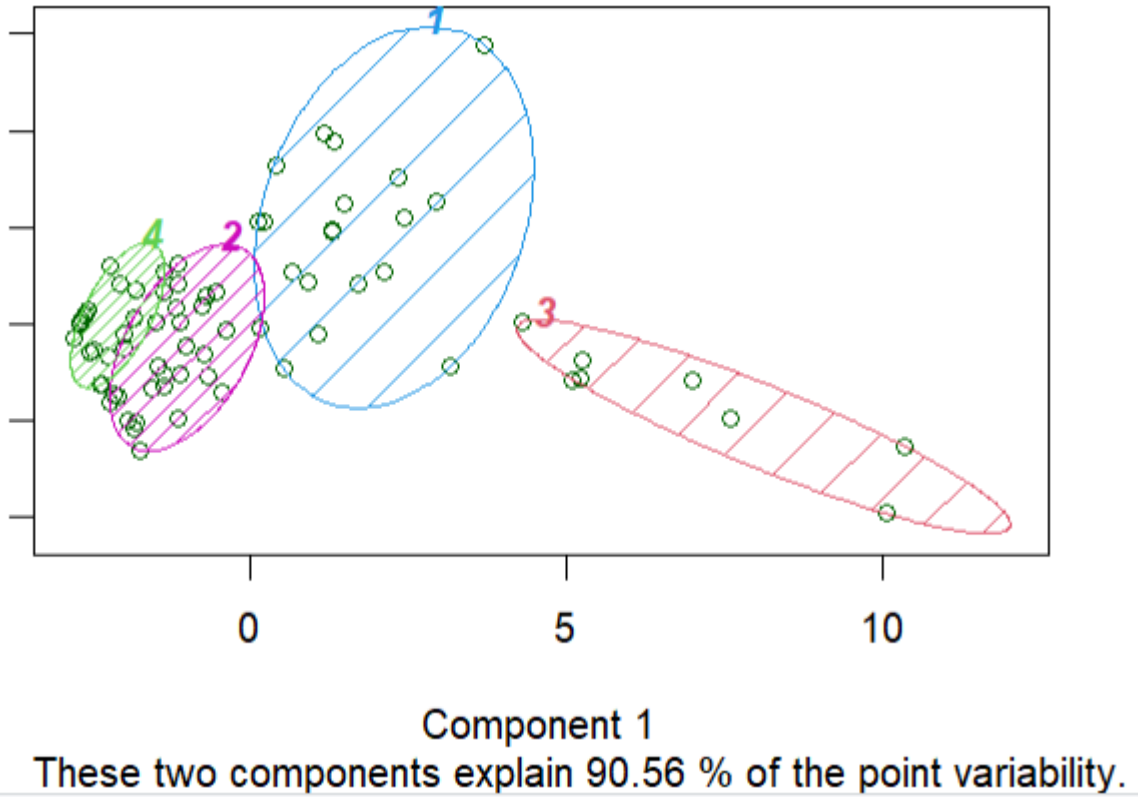
```
[1] "RESUMEN DE ANÁLISIS NO PARAMÉTRICO (KRUSKAL-WALLIS):"
> print(resumen_kruskal)
                                          Variable H_estadistico      p_valor significativa
Mundiales.Kruskal-Wallis chi-squared     Mundiales      59.11444 9.086952e-13            Sí
Puntos.Kruskal-Wallis chi-squared          Puntos      66.18739 2.794715e-14            Sí
PJ.Kruskal-Wallis chi-squared                  PJ      62.20457 1.986648e-13            Sí
PG.Kruskal-Wallis chi-squared                  PG      65.26275 4.407121e-14            Sí
PE.Kruskal-Wallis chi-squared                  PE      55.49659 5.379808e-12            Sí
PP.Kruskal-Wallis chi-squared                  PP      54.58656 8.412210e-12            Sí
Rendimiento.Kruskal-Wallis chi-squared Rendimiento      52.46744 2.381106e-11            Sí
GF.Kruskal-Wallis chi-squared                  GF      65.06465 4.858819e-14            Sí
GC.Kruskal-Wallis chi-squared                  GC      55.69629 4.877033e-12            Sí
Campeón.Kruskal-Wallis chi-squared       Campeón      76.00000 2.211883e-16            Sí
```


Clustering de jugadores/equipos (k=4)
Dim2 (6.9%)
Dim1 (83.7%)
2
1
0
-1
-2
-3
-10
-5
0
cluster
1
2
3
4

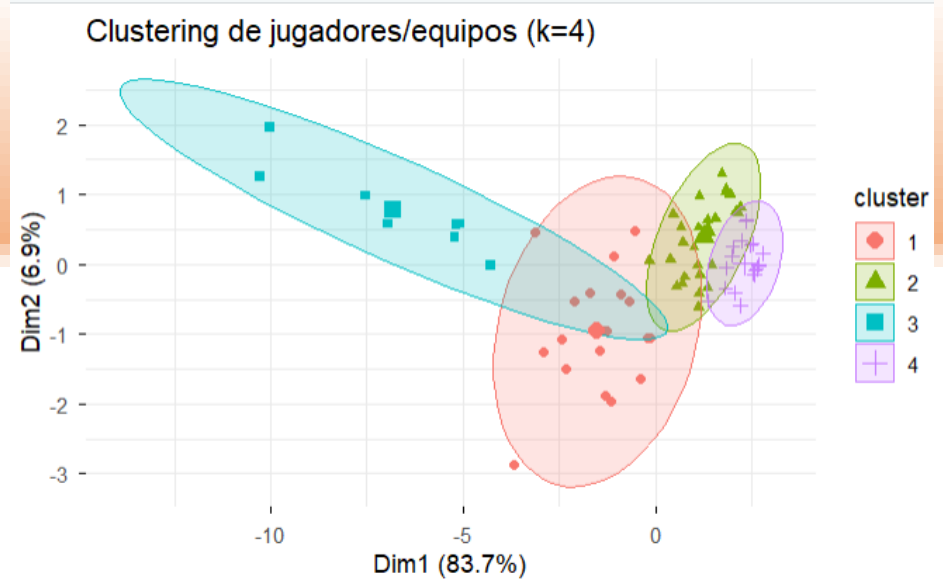

Clustering de jugadores/equipos (k=4)
Dim2 (6.9%)
Dim1 (83.7%)
2
1
0
-1
-2
-3
-10
-5
0
cluster
1
2
3
4

ACP quedo rotodo a la derecha pero es equivalente, los grupos son los mismos

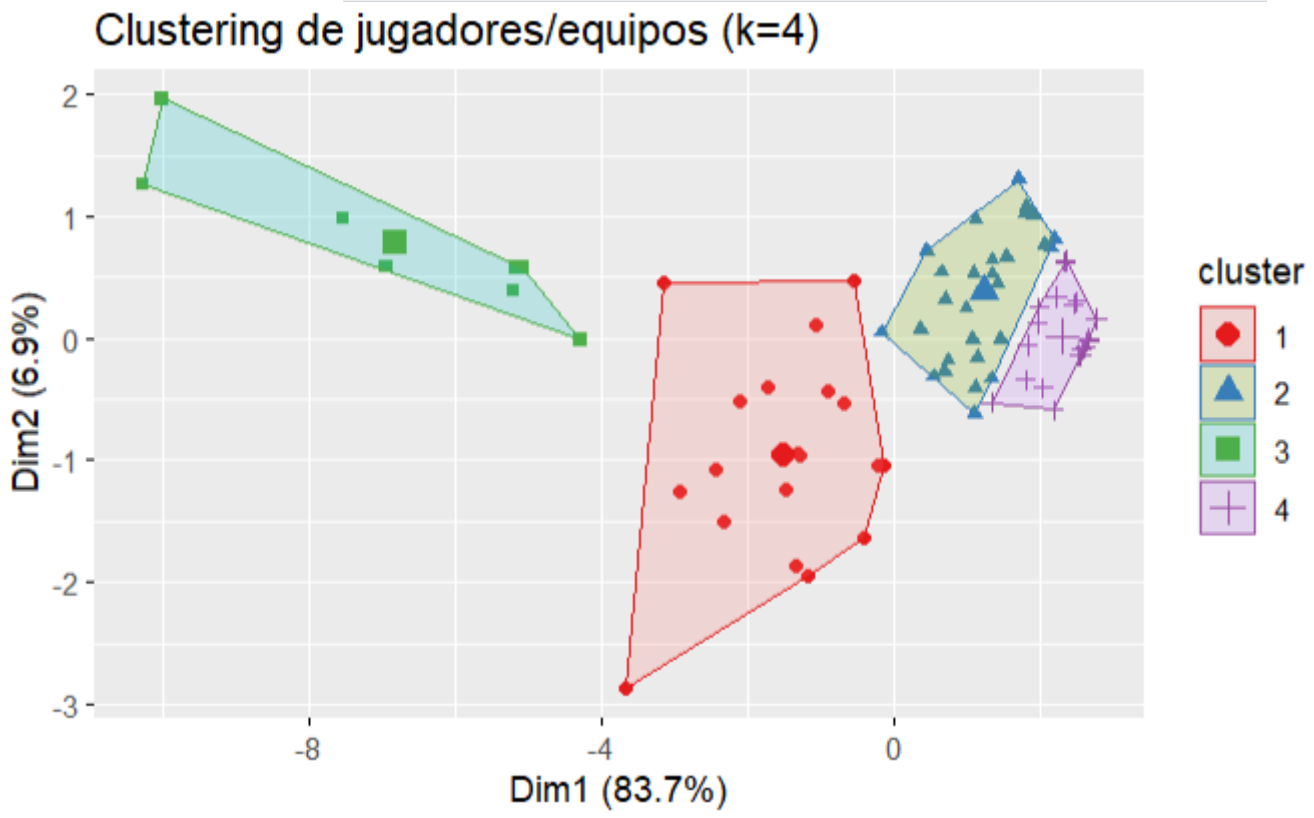




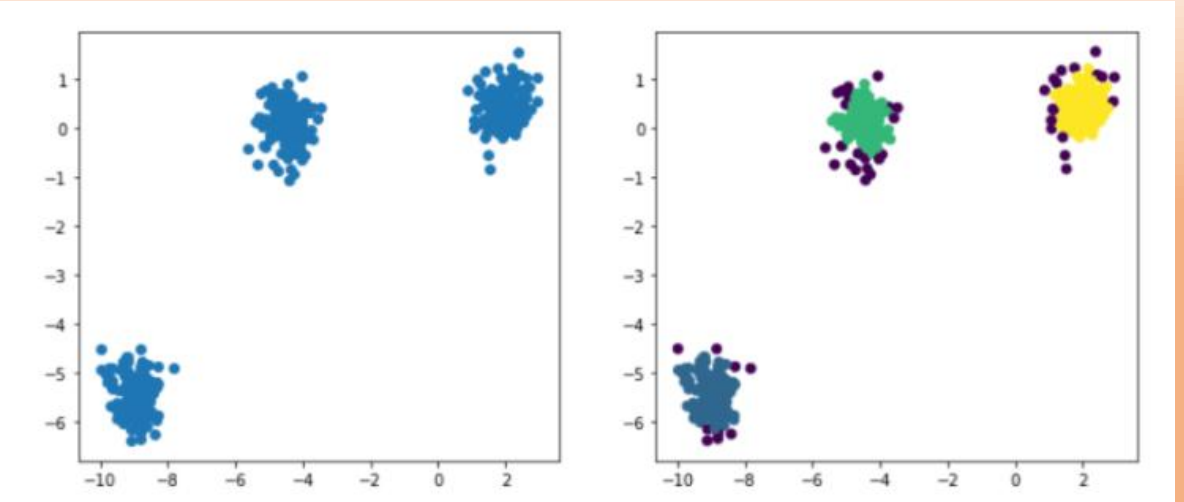
En el gráfico superior los cluster parecen superpuesto pero no lo están



Clasificación personalizada con factoextra
sin las etiquetasfviz_cluster(kmfutbol, data=df, geom="point", labelsize=8, repel=TRUE) + scale_color_brewer(palette="Set1") + ggtitle("Clustering de jugadores/equipos (k=4)")



DBSCAN, or Density-Based Spatial Clustering of Applications with Noise



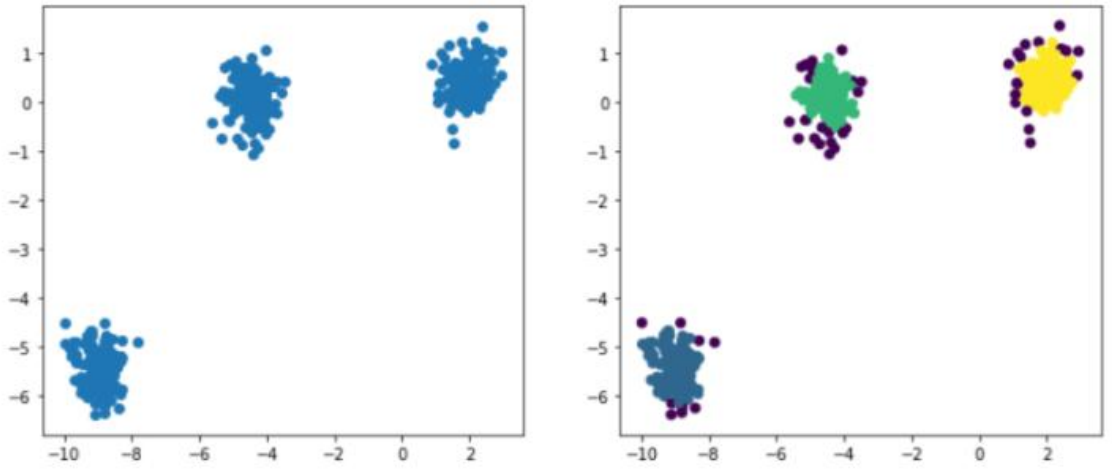
DBSCAN, or Density-Based Spatial Clustering of Applications with Noise

DBSCAN: Agrupamiento Espacial Basado en la Densidad de Aplicaciones con Ruido.

Es un algoritmo de agrupación en clústeres que funciona bajo el principio de agrupar puntos de datos que están muy juntos en regiones de alta densidad y separarlos de regiones de baja densidad.

Este enfoque permite que el algoritmo descubra grupos con formas arbitrarias, maneje el ruido (valores atípicos) y no requiera especificar el número de clústeres de antemano.

https://datascientest.com/es/machine



Etapas DBSCAN

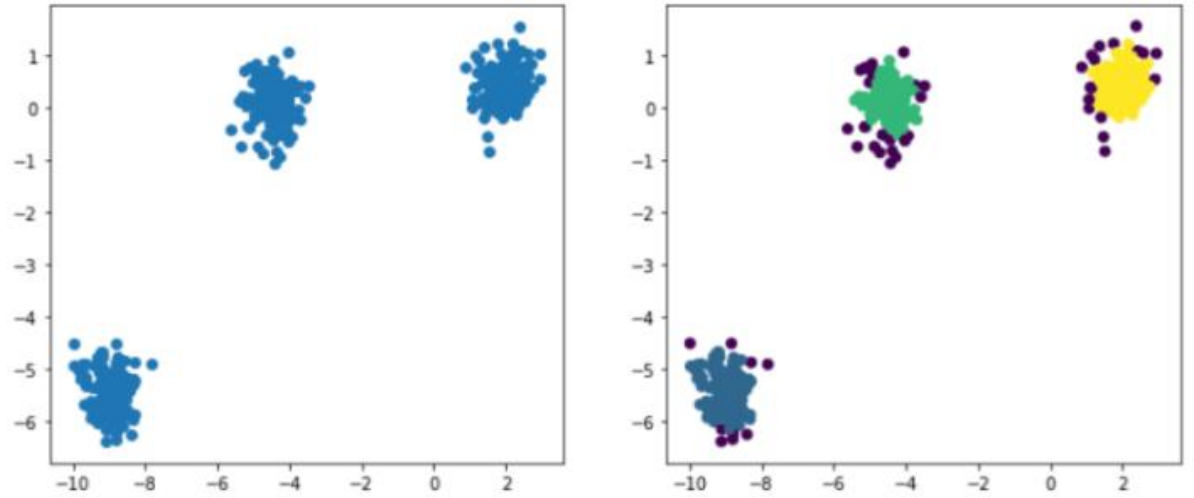
El DBSCAN es un algoritmo sencillo que define los clústeres mediante la **estimación de la densidad local**.

Se puede dividir en 4 etapas:

- Para cada observación miramos el número de puntos a una distancia máxima $\boldsymbol{\varepsilon}$ de ella. Esta zona se denomina $\boldsymbol{\varepsilon}$**-vecindad de la observación**.
- Si una observación tiene al menos un cierto número de vecinos, incluida ella misma, se considera una **observación central**. En este caso, se ha detectado una **observación de alta densidad**.
- Todas las observaciones en la vecindad de una observación central pertenecen al mismo clúster. Puede haber observaciones centrales cercanas entre sí. **Por lo tanto, de un paso a otro, se obtiene una larga secuencia de observaciones centrales que constituyen un único clúster.**
- Cualquier observación que no sea una observación central y que no tenga ninguna observación central en su vecindad se considera una **anomalía**.

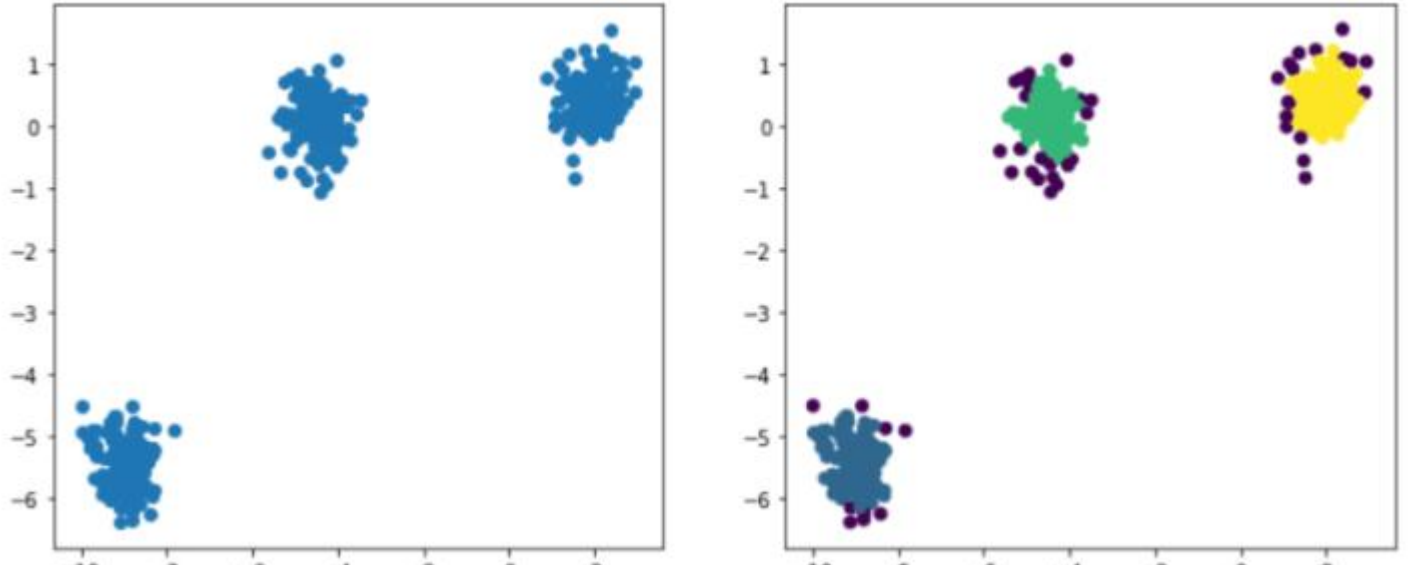
Por tanto, es necesario definir dos datos antes de utilizar DBSCAN:

- ¿Qué distancia **ε** hay que determinar para cada observación la **ε-**vecindad?
- ¿Cuál es el **número mínimo de vecinos necesario** para considerar una observación como una **observación central**?
- Obviamente, dependiendo del valor de **ε** y del número de vecinos mínimos, la partición puede variar.



Por tanto, es necesario definir dos datos antes de utilizar DBSCAN:

- Otra ventaja de DBSCAN es que también permite **gestionar los valores atípicos o las anomalías**.
- En la figura anterior se observa que el algoritmo ha determinado 3 clústeres principales: azul, verde y amarillo. Los puntos de color morado son anomalías detectadas por el DBSCAN.

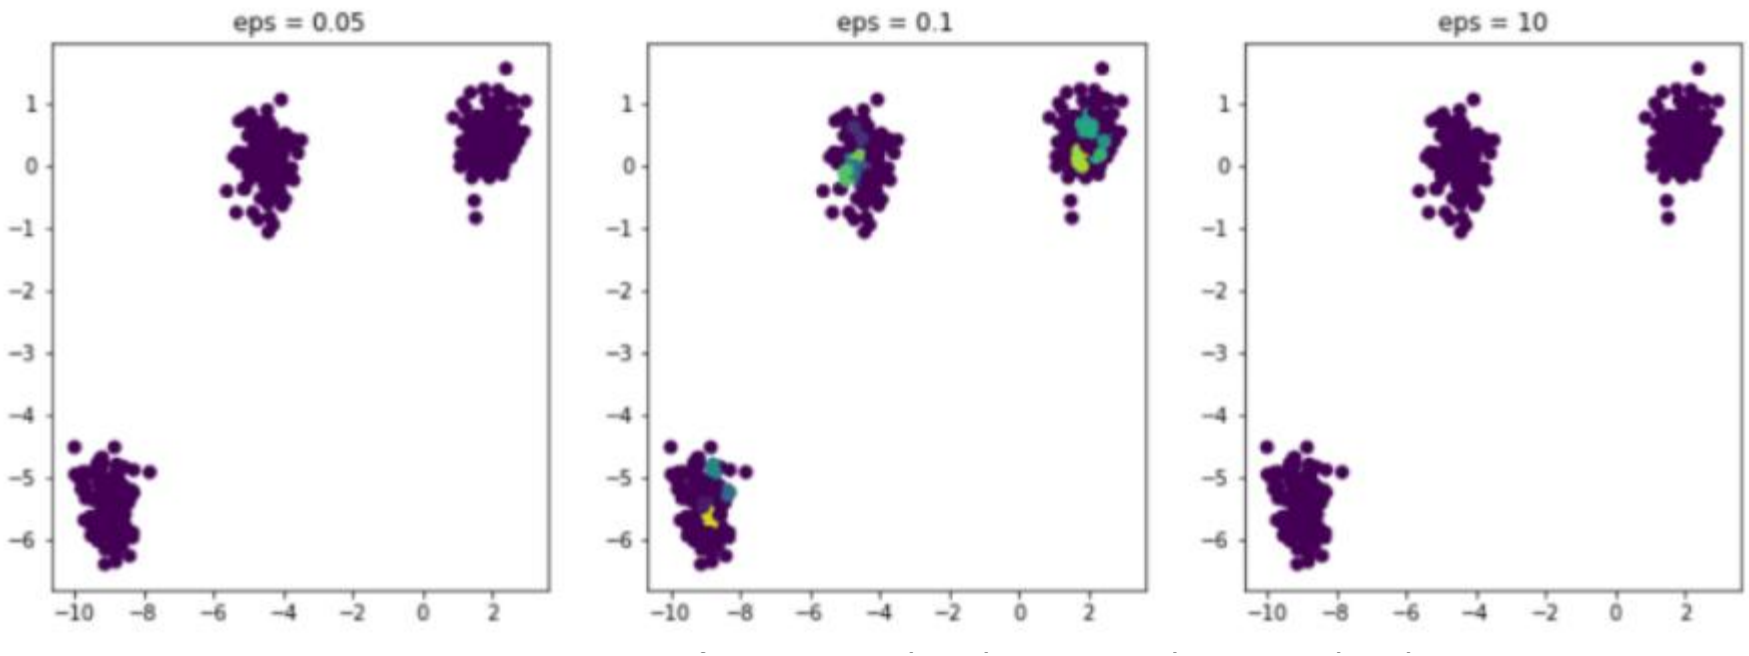


Definir **ε**

En los tres ejemplos, el número mínimo de vecinos está fijado siempre en 5.
Si **ε** es demasiado pequeña, la **ε-**vecindad es **demasiado pequeña** y **todas las observaciones** del conjunto de datos se consideran **anomalías**.
Es el caso de la figura de la izquierda eps = 0,05.
Por otro lado, si **épsilon es demasiado grande**, cada observación contiene en su **ε**-vecindad todas las demás observaciones del conjunto de datos. En consecuencia, obtenemos **un único clúster**. Por tanto, es muy importante calibrar **adecuadamente la ε** para obtener una partición de calidad.
Un método sencillo para optimizar la **ε** consiste en buscar para cada observación a qué distancia se sitúa su vecino más cercano. Entonces basta con fijar una **ε** que permita que una proporción «suficientemente grande» de las observaciones tenga una distancia a su vecino más cercano inferior a **ε**. Por «suficientemente grande» entendemos el 90-95 % de las observaciones que deben tener al menos un vecino en su **ε**-vecindad.

Definir **ε**

En los tres
Si **ε** es d **as las**
observa
Es el caso
Por otr ne en
su **ε**-ve
consecu
importa
calidad
Un métod e sitúa
su vecino emente



grande» de las observaciones tenga una distancia a su vecino más cercano inferior a **ε**. Por «suficientemente grande» entendemos el 90-95 % de las observaciones que deben tener al menos un vecino en su **ε**-vecindad.

¿Cómo implementar el DBSCAN con Python?

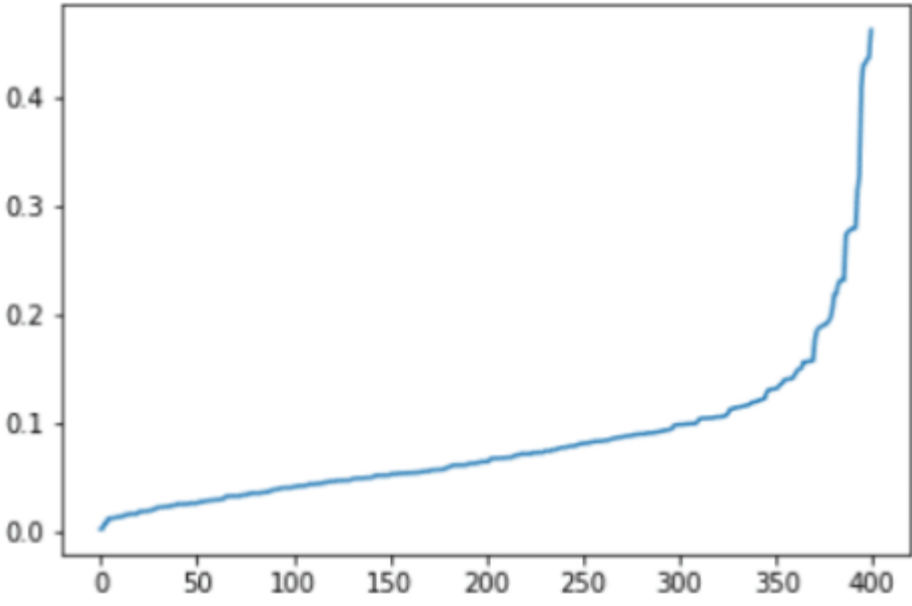
El aprendizaje de DBSCAN se facilita con la biblioteca Scikit-Learn. Nuestro conjunto de datos de ejemplo se crea fácilmente con la función make_blobs de Scikit-Learn. Así es como se implementa en código:
Ahora que tenemos nuestro conjunto de datos, intentaremos determinar la ε óptima para obtener una mejor partición de nuestro conjunto de datos.
Scikit-Learn nos permite determinar los vecinos más cercanos de cada observación, así como las distancias. Así es como se implementa en código:

¿Cómo implementar el DBSCAN con Python?

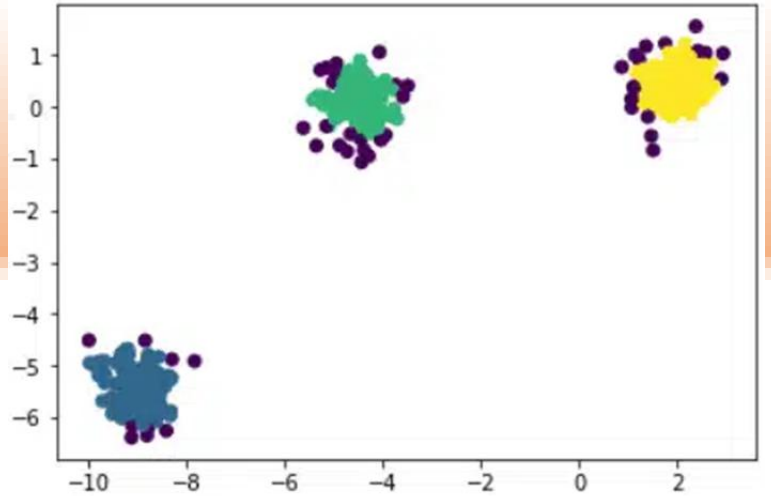
El aprendizaje de DBSCAN se facilita con la biblioteca Scikit-Learn.

Así es como se implementa en código:

- Como hemos visto antes, elegiremos una **ε** para que el 90 % de las observaciones tengan una distancia de vecindad inferior a **ε**. En nuestro ejemplo, 0,2 parece adecuado.
- Ahora que hemos optimizado nuestra **ε** podemos realizar nuestra partición utilizando DBSCAN que ya está implementada en Scikit-Learn.

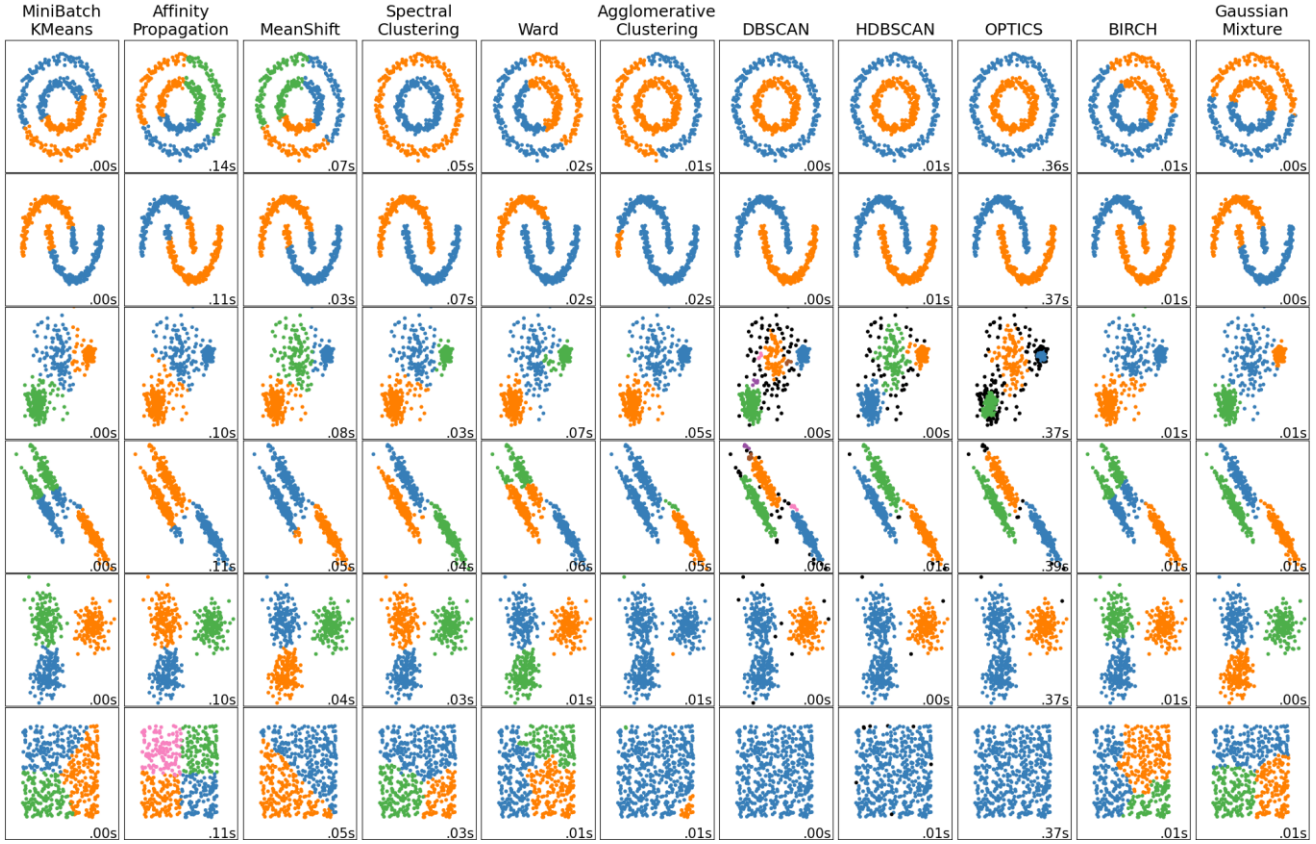


Resultados



- Los argumentos eps y min_samples se utilizan para establecer los parámetros del algoritmo, es decir, la distancia ε y el número mínimo de vecinos que deben considerarse como una observación central.
- De esta manera, el algoritmo detectó 3 clústeres principales y algunas anomalías. Cada una de las observaciones se etiqueta con la etiqueta del clúster correspondiente (por ejemplo, 0,1,2). Las anomalías se etiquetan con -1 y, por tanto, forman una clase separada además de los 3 clústeres detectados.
- El uso de un algoritmo de clustering como el DBSCAN no es fácil dependiendo de los datos que se tengan. Suele ser necesario repasarlos.

Tipos de clustering



https://scikit-learn.org/stable/modules/clustering.html?utm_source=chatgpt.com

Tipos de clustering

Aglomerativos	Divisivos
Enlace simple (vecino más próximo)	*Linkage* simple
Enlace completo (vecino más lejano)	*Linkage* completo
Promedio entre grupos	Promedio entre grupos
Método del centroide	Método del centroide
Método de la mediana	Método de la mediana
Método de Ward	Método de Ward
	Análisis de asociación

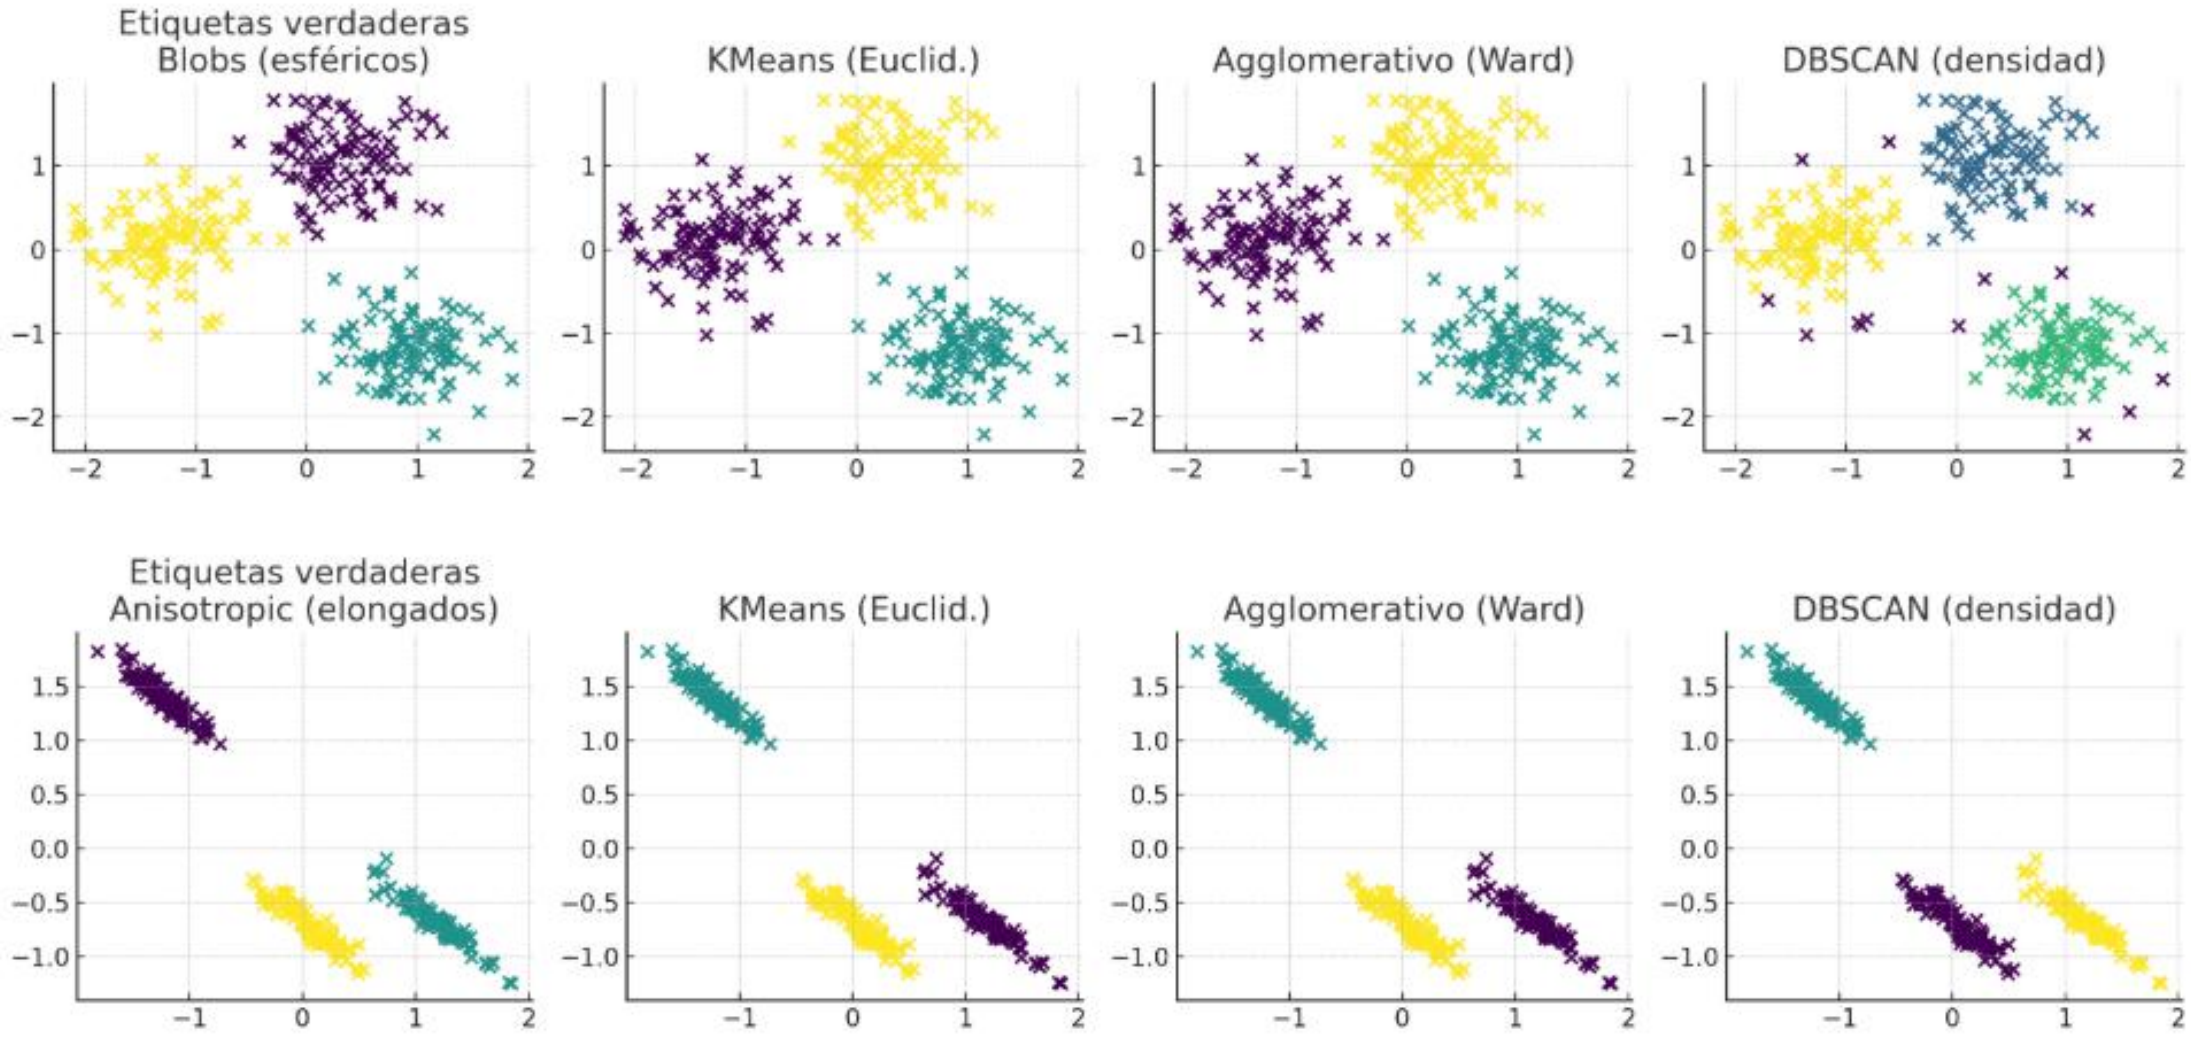
Método Ward

- Método de Ward o varianza mínima" en el contexto de clustering jerárquico. Se describe cómo se calcula la distancia entre clusters mediante la suma de cuadrados entre grupos del ANOVA, y se menciona la minimización de la suma de cuadrados dentro de los clusters en cada paso de fusión.
- También se resalta la utilización de la distancia euclídea y de Manhattan para el método de Ward y la importancia de la forma en que se calcula la distancia entre objetos para obtener maneras distintas de agrupar.

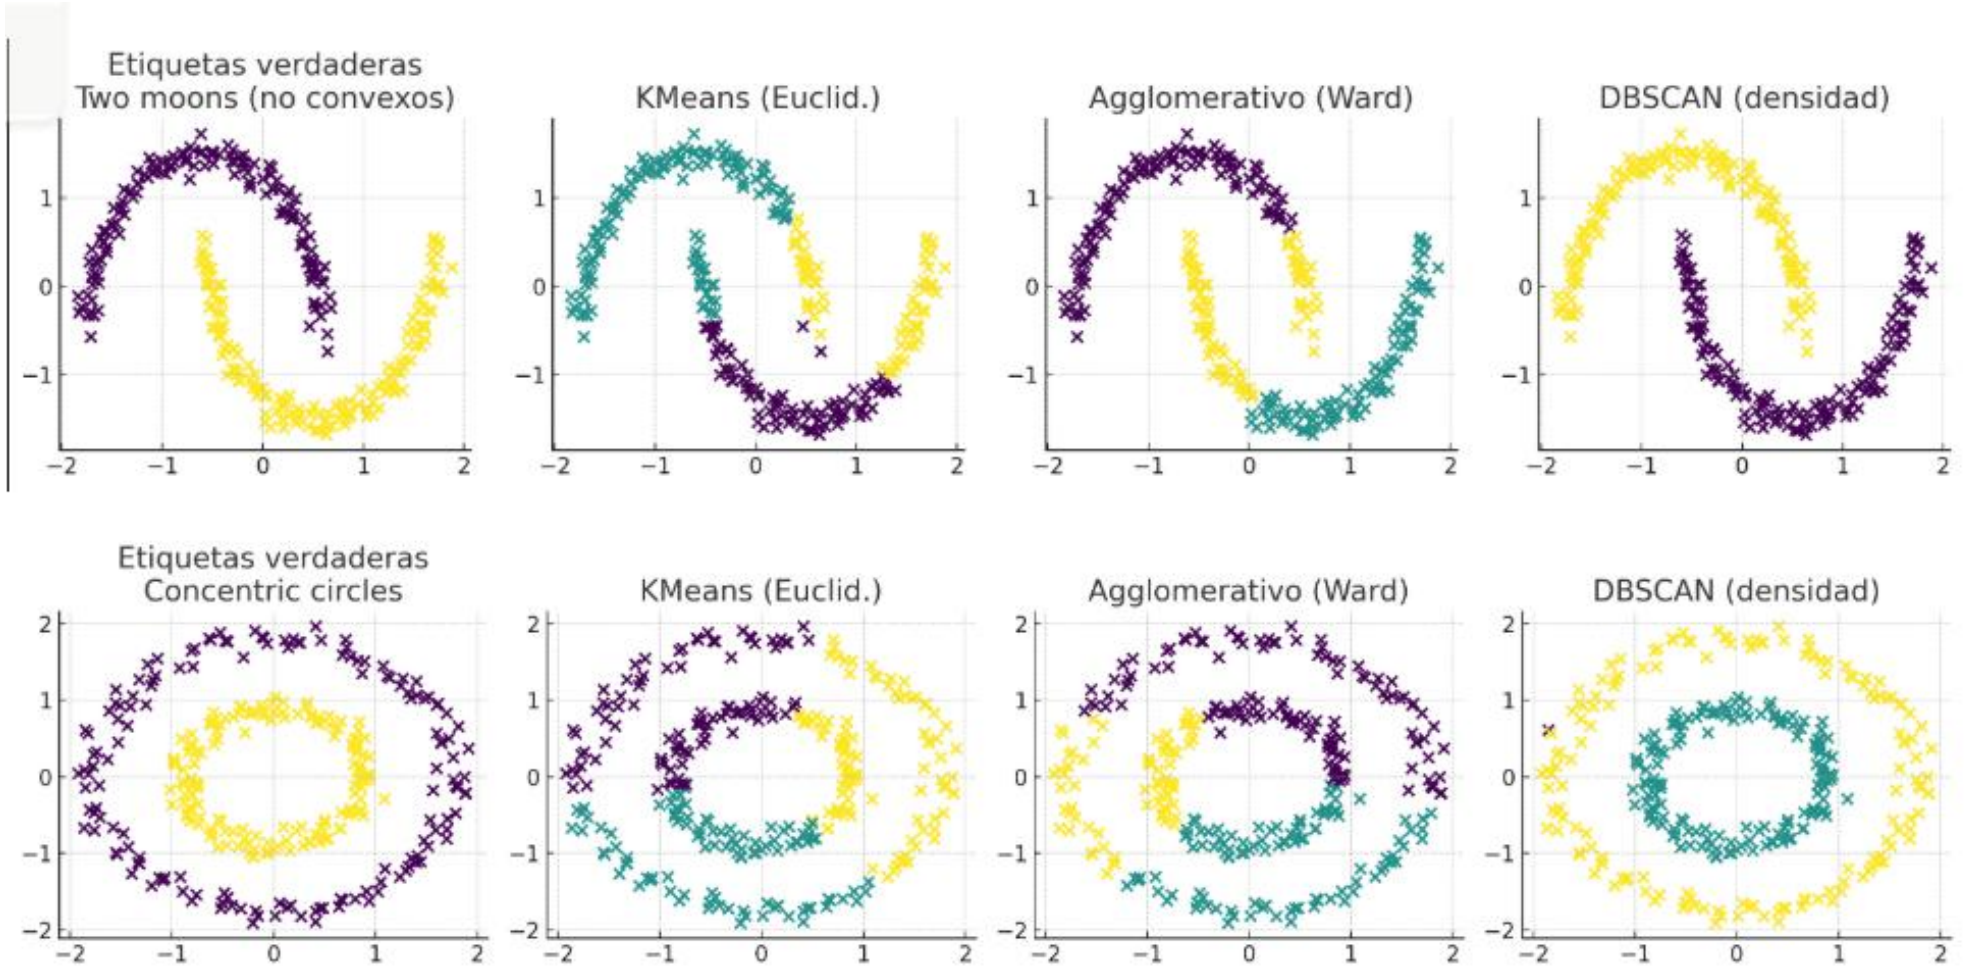
Medidas de distancia: definiciones y cuándo usarlas

- **Distancia euclidiana** — distancia geométrica “clásica” en el espacio ℓ2\ell_2ℓ2. Es la más usada y es la que minimiza K-Means (inercia). Es adecuada cuando las variables están en la misma escala o han sido estandarizadas.
- **Distancia de Manhattan**— suma de diferencias absolutas (ℓ1\ell_1ℓ1). Menos sensible a outliers en una dimensión y útil cuando las diferencias por dimensión deben sumarse linealmente.
- **Distancia de Mahalanobis** — distancia que incorpora la covarianza entre variables; mide distancia a una distribución (escala y correlación). Buena opción si las variables están correlacionadas y se quiere tener en cuenta la forma de la nube de datos (invariante ante escalado y correlación).
- **Similitud coseno / distancia coseno** — mide el ángulo entre vectores (útil para datos de alta dimensión, p.ej. texto/TF-IDF). Es independiente de la magnitud y sensible sólo a la orientación.
- **Otras (correlación 1−ρ, distancias basadas en ranks, etc.)** — usadas en contextos específicos (series temporales, datos ordinales, etc.). Revisiones amplias comparan múltiples medidas y muestran que la elección puede afectar mucho los resultados del clustering.

Formas de cluster → Tipos



Formas de cluster → Tipos



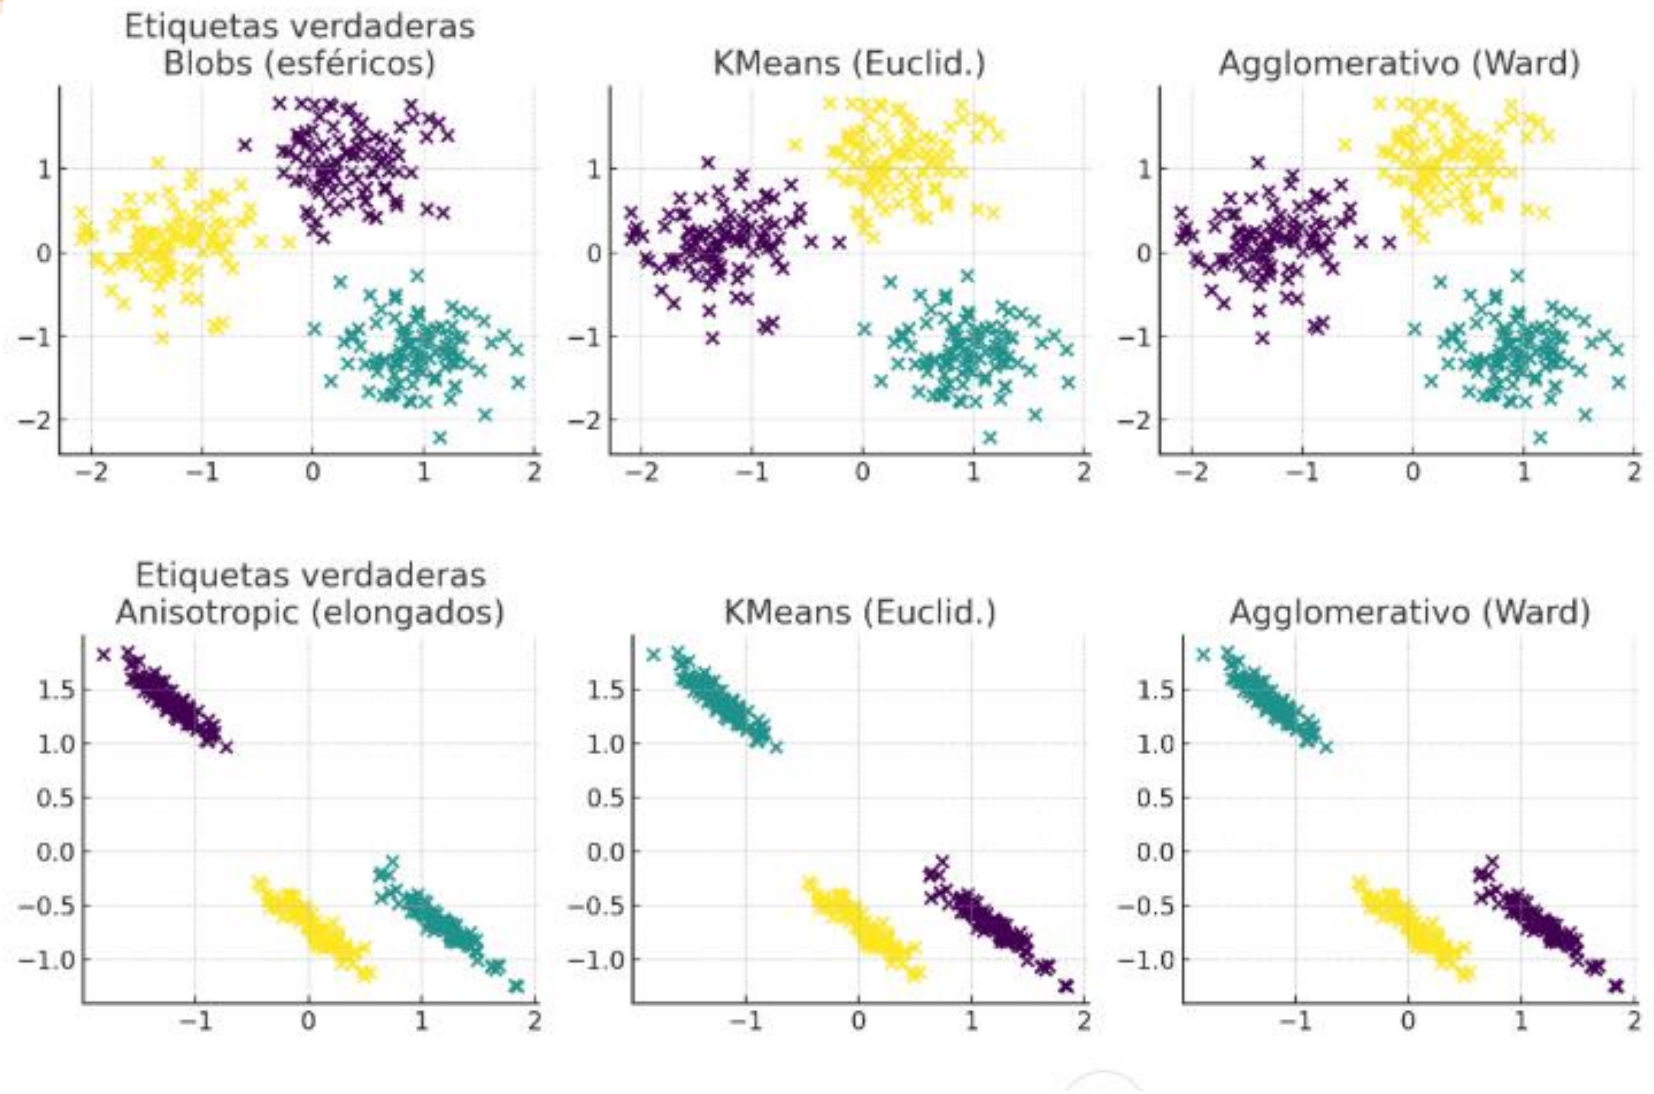
Formas de clústeres y qué algoritmo/medida funciona mejor

Clusters esféricos y bien separados

- Ejemplo: *blobs* (gráficos que viste).
- Algoritmos que funcionan bien: **K-Means**, **Ward (agglomerative)** con distancia euclidiana.
- Medida típica: Euclidiana.

Clusters elongados / anisotrópicos

- Si los grupos están estirados por transformaciones lineales (covarianza no identidad), **Mahalanobis** o estandarizar + euclidiana suelen mejorar; Ward/KMeans pueden fallar si no se normaliza.



Formas de clústeres y qué algoritmo/medida funciona mejor

Clusters no convexos (formas en “media luna”, anillos, etc.)

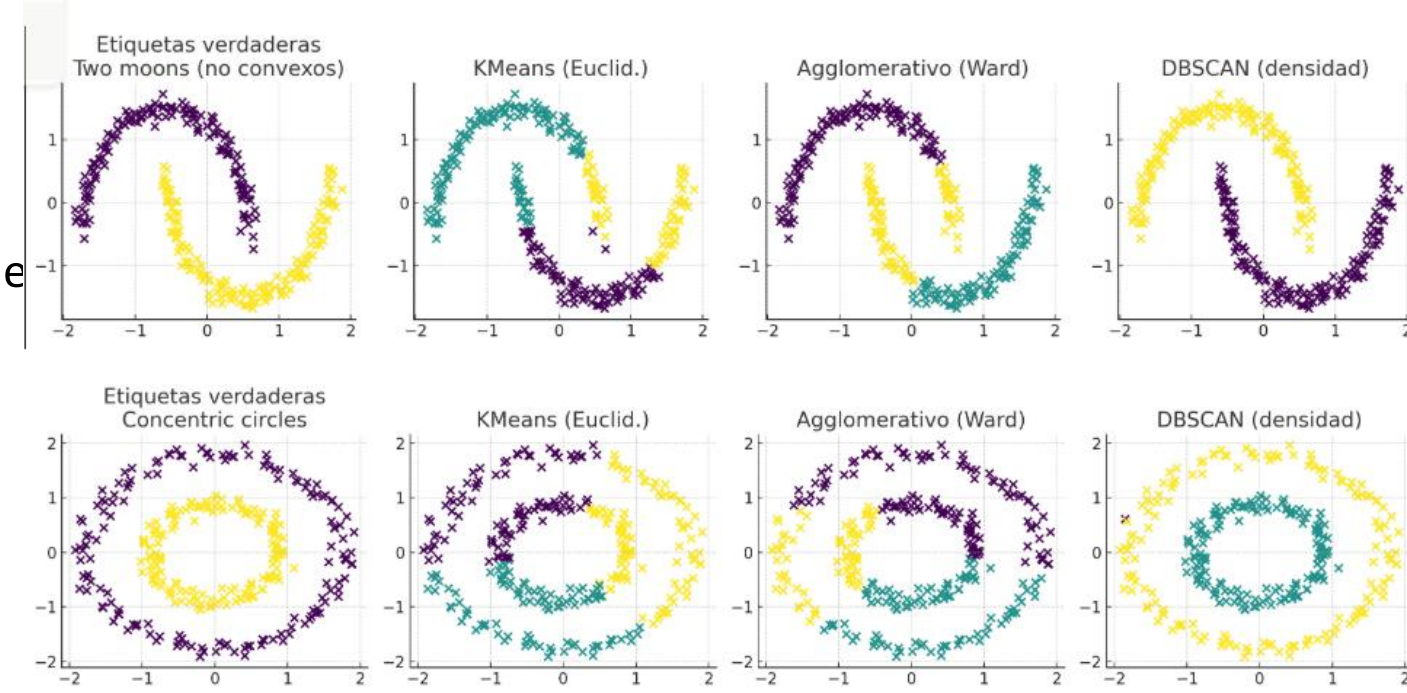
- Ejemplo: *two moons* y *concentric circles*.
- Algoritmos adecuados: **DBSCAN** (basado en densidad), métodos espectrales o clustering por grafo; **K-Means** falla frecuentemente porque asume convexidad/simetría.

Clusters con diferentes densidades / ruido

- **DBSCAN** identifica ruido y clusters de distintas formas siempre que la densidad local sea coherente; elegir eps y min_samples es crítico.

Clusters en alta dimensión

- La elección de distancia (coseno, Mahalanobis, distancia basada en subespacios) y la reducción dimensional (PCA) antes de clusterizar frecuentemente mejora resultados.



Ejemplo de text mining: Poemas de Neruda

Ejemplo de text mining: Poemas de Neruda

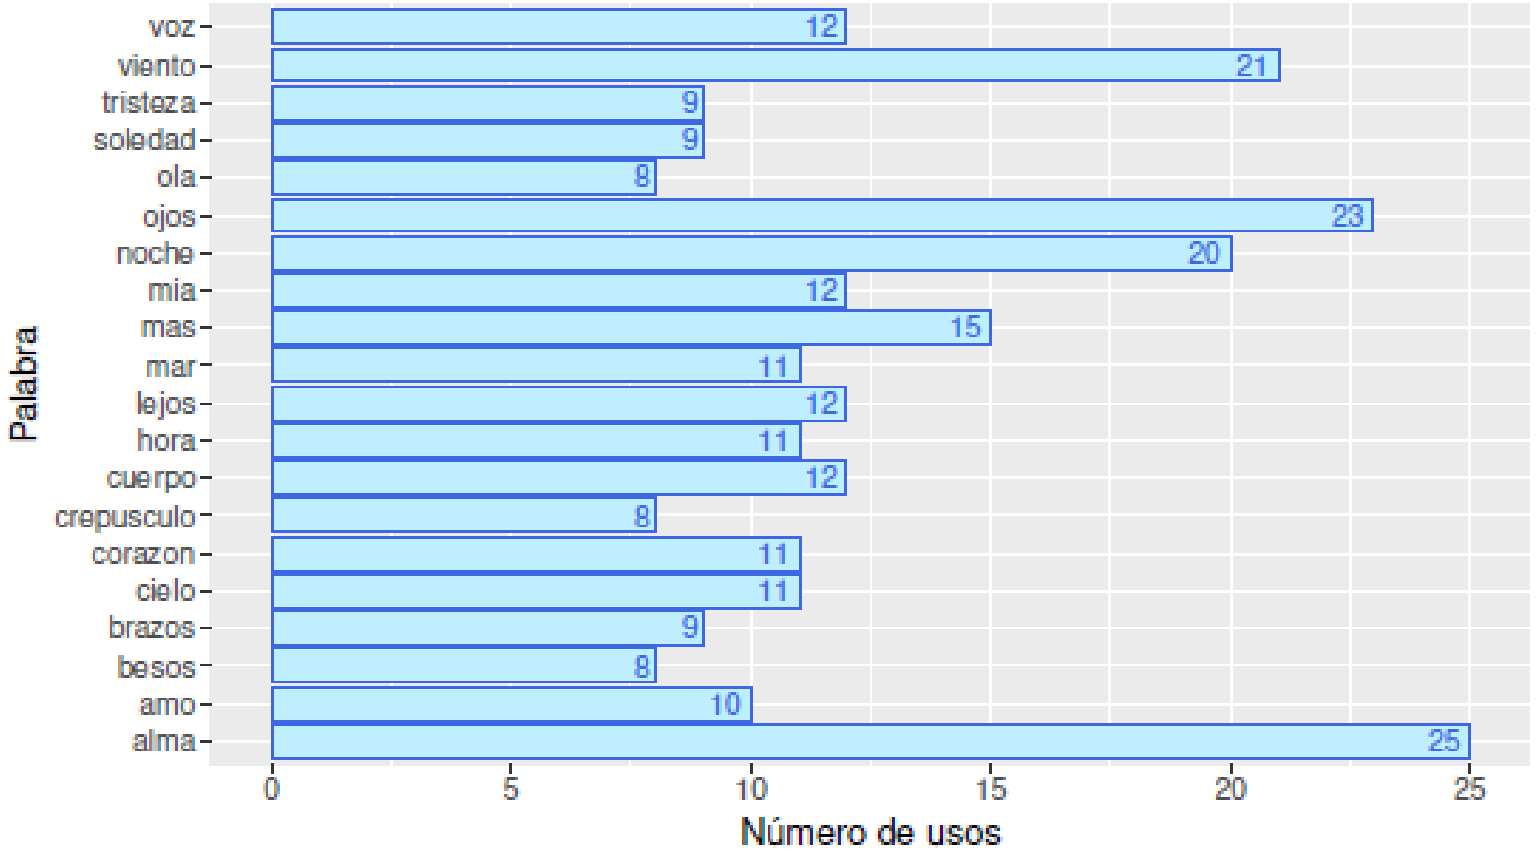


Figura 10.24: Palabras más frecuentes en poemas de Neruda



Figura 10.25: Nube de palabras más frecuentes en poemas de Neruda

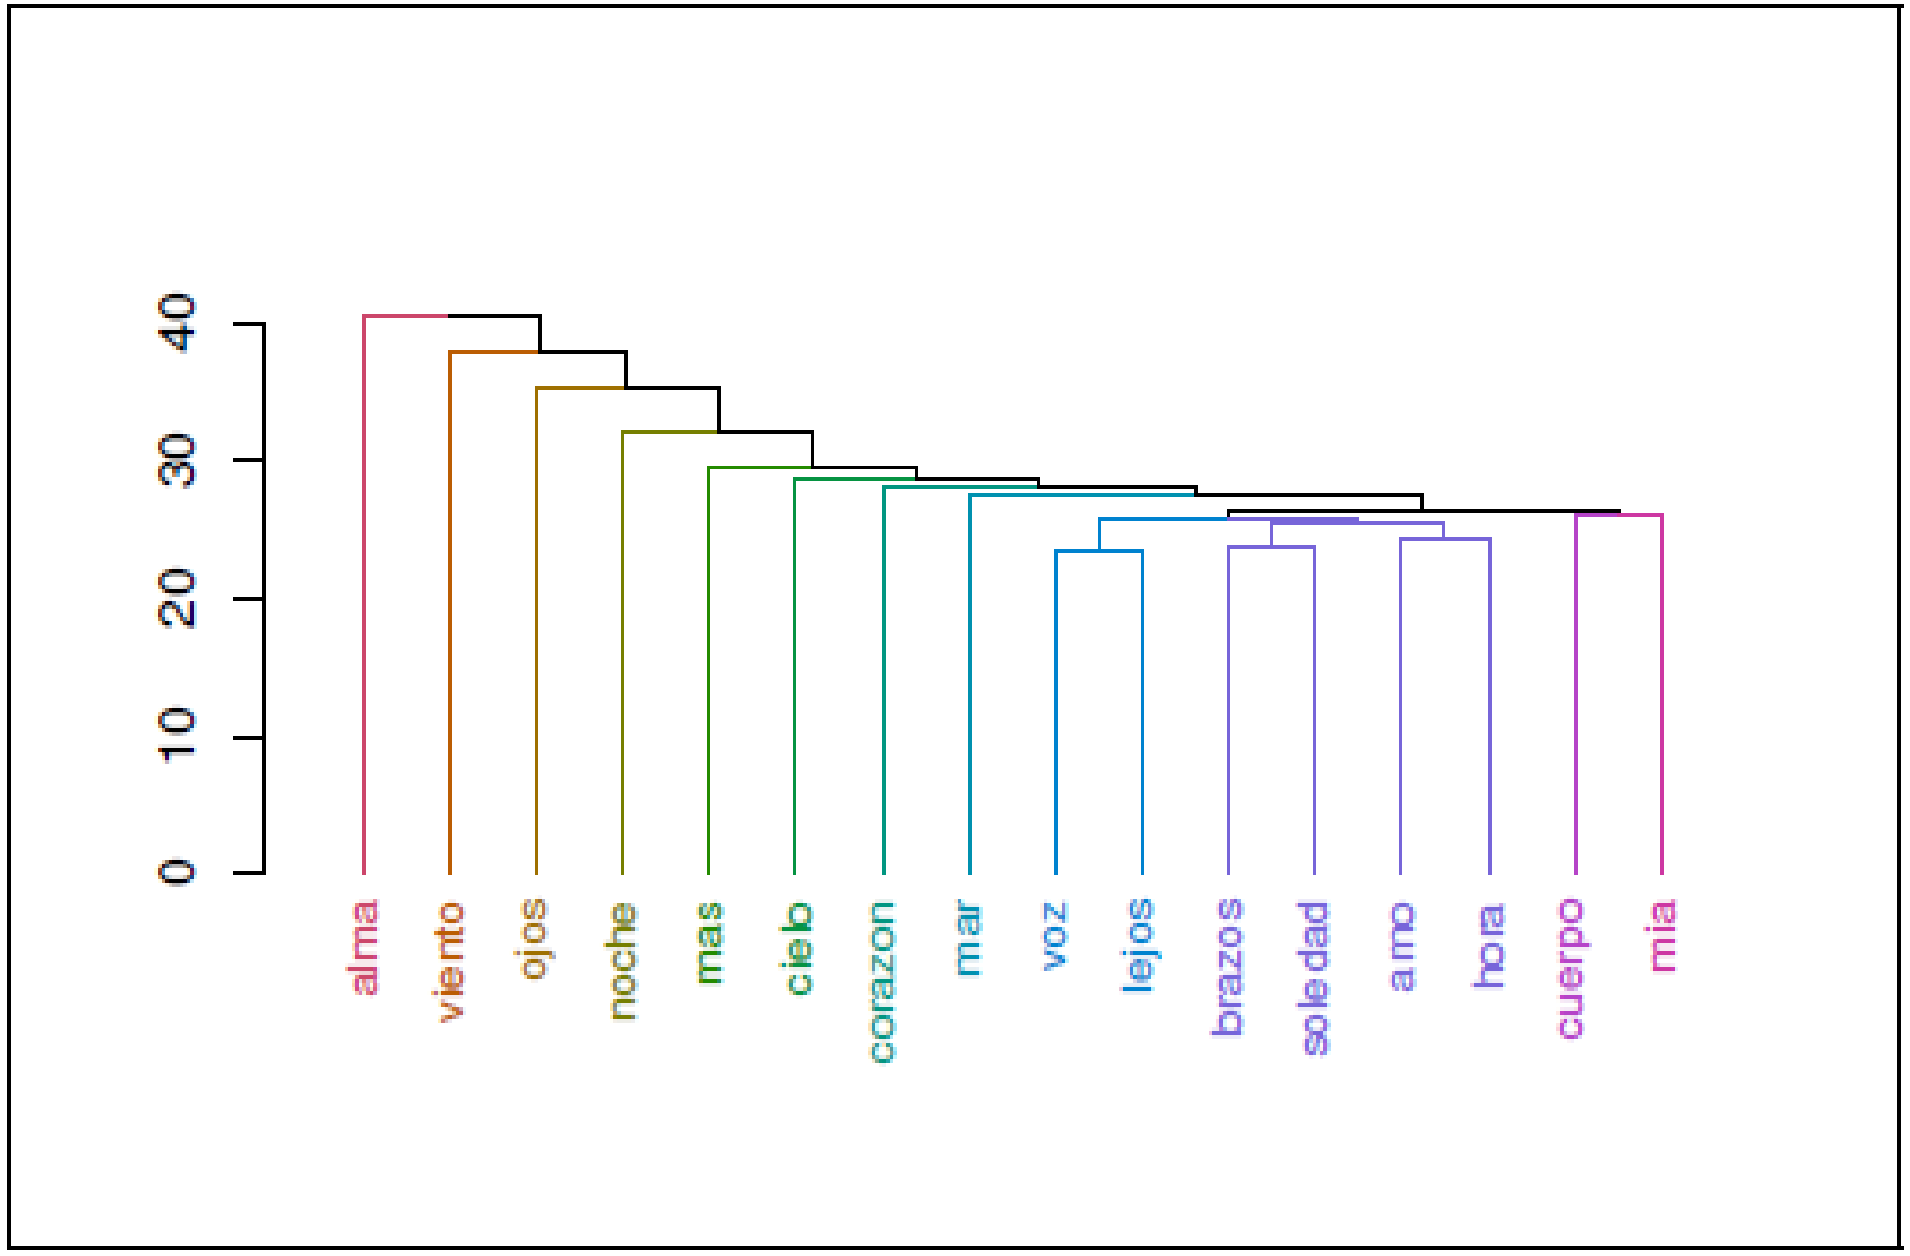


Figura 10.29: Dendograma de palabras más frecuentes en poemas de Neruda

Asociación entre palabras

- findAssocs(dtm.nuevo, terms=c("alma","ojos","cuerpo","amo","corazon", "noche","viento"), corlimit=.3)
- # Calcula la asociación entre términos frecuentes

Se puede identicar, por ejemplo, qué palabras están asociadas con la palabra "noche": "escribir" (0.44), "versos" (0.32) y "estrellada" (0.31).

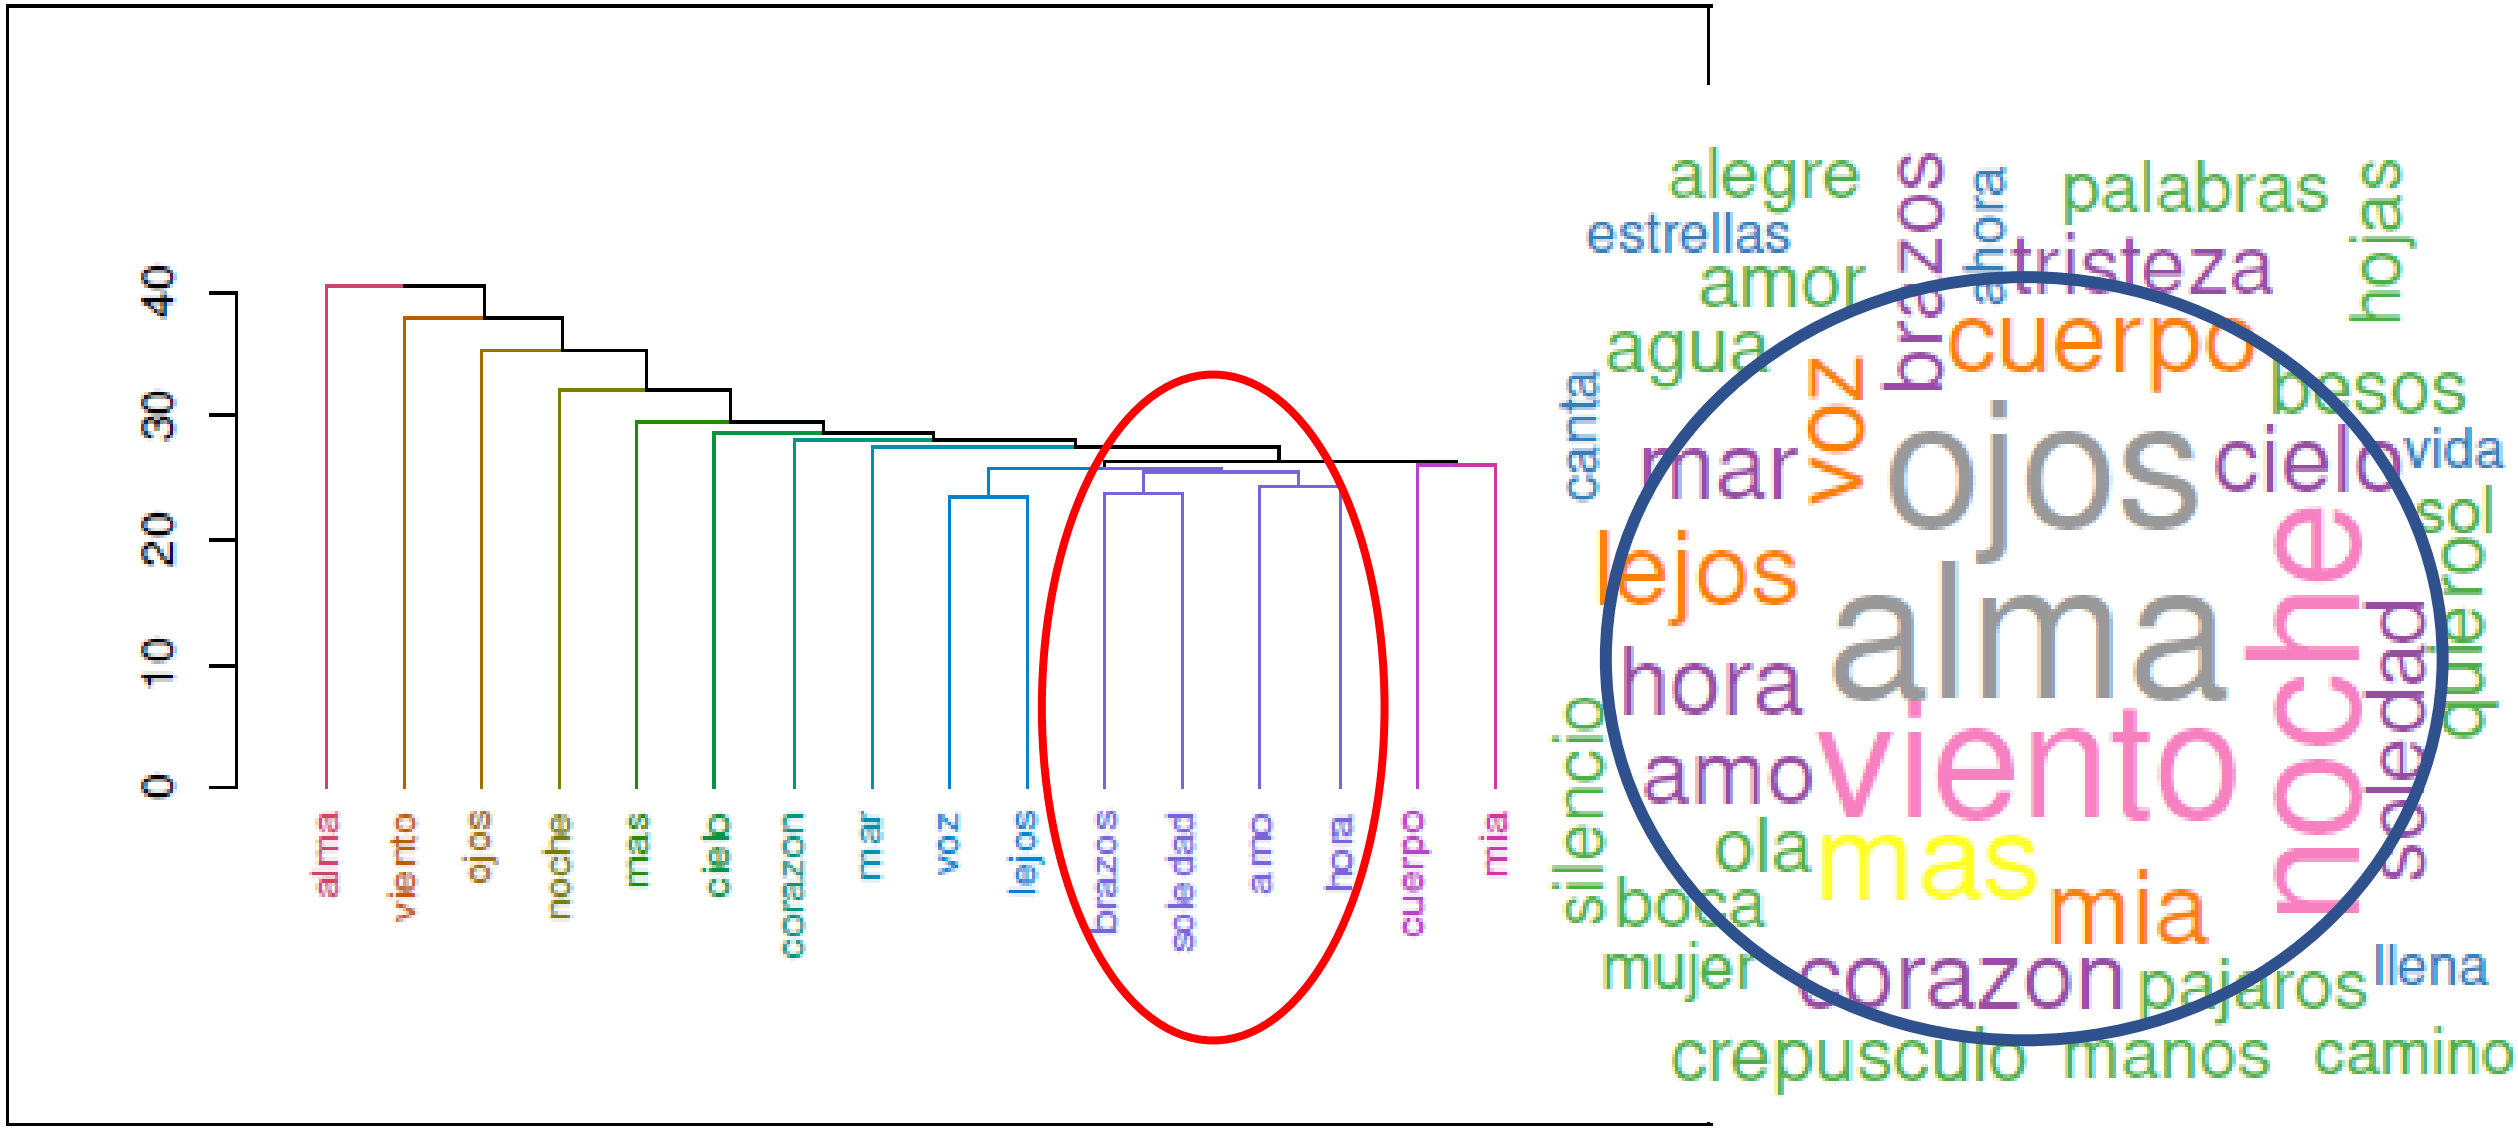


Figura 10.29: Dendograma de palabras más frecuentes en poemas de Neruda

Gracias