Parcial 1

Análisis inteligente de Datos

2025

Clustering

Las técnicas de clustering se utilizan en aprendizaje no supervisado para agrupar instancias según su similitud. Indique cuáles de las siguientes afirmaciones son correctas.

Selecciona las instancias verdaderas.

Se penalizan respuestas incorrectas.

Seleccione una o más de una:

- [x] a. La técnica de clustering permite agrupar instancias similares ✓
- [ ] b. Los clustering se hace solo sobre variables numéricas.
- [ ] c. El algoritmo de k medias es una técnica de aprendizaje supervisado y requiere de los casos etiquetados.
- [x] d. Un buen método de agrupamiento buscará maximizar la distancia intercluster. ✓ Verdadero se busca que la distancia entre los cluster sea maxima, que esten separados
- [x] e. Las instancias a agrupar pueden ser variables o casos según el interés de la investigación ✓
- [x] f. Puede utilizarse la técnica de clustering para detectar valores atípicos ✓ Los valores que sean muy diferentes del resto formarán un grupo separado y notoriamente minoritario. Esto es lo que se utiliza por ejemplo en la detección de fraudes.
- [ ] g. Un buen método de agrupamiento buscará minimizar la distancia intercluster.

El algoritmo K-means es una técnica de agrupamiento utilizada en aprendizaje no supervisado para dividir datos en grupos según su similitud. A continuación, se presentan afirmaciones relacionadas con su funcionamiento. .

Indicar las respuestas correctas.

Se penalizan las incorrectas.

Seleccione una o más de una:

- [x] a. Diferentes ejecusiones del algoritmo Kmedias llegan a distintas soluciones y no necesariamente a la solución optima. ✓ Verdadero la solución no es única ni óptima.
- [x] b. La cantidad de grupos a obtener debe ser conocida de antemano. ✓ Verdadero se debe indicar el K (cantidad de cluster) al inicio.
- [x] c. Los resultados dependen de la elección de los centros iniciales ✓ Inicialmente los centros son aleatorios y los resultados pueden depender de la seleccion de estos centros, dependiendo de la estructura de los datos.
- [ ] d. Los grupos encontrados tienen estructura jerárquica.
- [x] e. El tiempo de ejecución del algoritmo depende de la cantidad de grupos ✓ Cuanto mas grupos mayor cantidad de cálculos y mayor tiempo de ejecusión

Se realiza un agrupamiento de un conjunto de datos utilizando k-medias con K=3 y se obtienen 3 grupos: A, B y C.

Se dice que un ejemplo "pertenece" al cluster o grupo A si la distancia del ejemplo al centro del grupo A es:

(indique opciones correctas)

Seleccione una:

- ( ) a. La distancia del ejemplo al centro del grupo A es mayor que la distancia del ejemplo al centro de B, y también al centro de C.
- (•) b. La distancia del ejemplo al centro del grupo A es menor que la distancia del ejemplo al centro de B, y también al centro de C. ✓ Verdadero
- ( ) c. La distancia del ejemplo al centro del grupo A es 0.

Indicar las opciones correctas.

Se penalizan respuestas incorrectas.

Seleccione una o más de una:

- [x] a.
  El **índice Silhouette** mide la cohesión de un elemento calculando su distancia promedio al resto de los elementos del mismo cluster.
  ✓
  Verdadero
- [ ] b. El **índice Davies-Bouldin** puede tomar valores negativos.
- [ ] c. El **índice Silhouette** Está normalizado (divido por) con el valor mínimo entre la separación y la cohesión del elemento.
- [x] d. El **índice Davies-Bouldin** es el promedio de valores que resultan de calcular el cociente entre la suma de dos medidas de dispersión y una distancia entre centros. No puede ser negativo. ✓
- [x] e.
  El **índice Silhouette** da valores entre -1 y 1 ✓
- [ ] f. El **índice Silhouette** da valores entre 0 y 1

Sobre una muestra de 200 unidades extraída en forma probabilística, se midieron variables relativas a las preferencias de los individuos para pasar sus vacaciones y otras de tipo demográfico. Las primeras fueron medidas en una escala Likert de 7 puntos, donde 1 significa "totalmente en desacuerdo" y 7 "totalmente de acuerdo". Luego de aplicar el análisis de cluster jerárquico quedaron conformados tres grupos, cuyas medias para cada variable se muestran en el cuadro siguiente.

Tabla Resultante del Análisis de Clustering: media de las variables por grupo

Variables	Grupo 1 n = 55	Grupo 2 n = 78	Grupo 3 n = 67
Prefiero viajar al exterior	4,26	3,72	5,35
Prefiero visitar varios lugares	2,27	3,61	4,77
Prefiero ir siempre al mismo lugar	4,39	4,64	1,92
Me gusta el turismo aventura	3,26	2,76	4,4
Me gusta la playa	4,1	2,72	3,85
Me gusta la montaña	2,09	2,06	5,22
Me gusta recorrer lugares que no conozco	3,21	2,89	4,57
Gasto promedio por día	47	25	80
Edad	28,6	54,8	36,4
Ingreso personal mensual promedio	800	1800	1500
N° de días de vacaciones promedio en los últimos 4 años	15	30	20

Se pide caracterizar a cada uno de los grupos comparando las medias en relación con las medias de los otros grupos.

- Sujeto medio (parangon, típico
- Escala 1 a 7
- Valor 4 Indiferen
- Tamaño de los grupos

Grupo 1: Grupo Joven, Promedio de edd 28 años.Grupo que prefiere viajar al exterior de forma moderada, con poco interes por visitar varios lugares, prefiriendo un lugar único. Con preferencia por la playa sobre la montaña. Grupo dispuesto a gastar una buena parte de su dinero en vacaciones en base a su bajo ingreso, si bien es necesario destacar que los periodos de vacaciones no suelen ser extensos, 15 dias en promedio. Grupo 2: Adultos. Promedio de Edad 54 años. Grupo con los ingresos mas altos y con las vacaciones más extensas probablemente por mayotr disponibilidad de tiempo y antiguedad laboral, que realiza un gasto por día en sus vacaciones muy bajo y que suele preferir ir siempre al mismo lugar de vacaciones, y no tiene pasión especial por viajar al exterior, con una leve preferencia de la playa sobre la montaña. Grupo 3: Adulto joven, promedio 36 años. Grupo con un salario intermedio y unas vacaciones moderadas en extensión posiblemente relacionadas con temas de maternidad o paternidad, con un gran gasto por dia en tiempo te vacaciones y una clara preferencia de la montaña por sobre la playa. Con preferencia en viajar al exterior, la mas marcada de los 3 grupos y en visitar varios lugares durante sus vacaciones. Poco interes en ir siempre al mismo lugar. Prefieren el movimiento.

ACP

Indicar la relación entre las definiciones y los

Suma de todas las cargas factoriales al cuadrado para uno componentes principales retenidos	autovalor del componente ✓
La proporción de la varianza de una variable que es explicada por el componente principal específico, tiene valores entre 0 y 1.	coseno cuadrado (cos2) ✓
Fracción de variancia explicada por un componente principal	autovalor del componente / cantidad de variables ✓
Correlación entre la Variable y el Componente Principal con valores entre -1 y 1.	Carga factorial ✓
Cantidad total de la varianza de la variable que es explicada por todos los componentes principales retenidos en el modelo, tiene valores entre 0 y 1.	Comunalidad ✓

En el contexto del Análisis de Componentes Principales (ACP),

Indicar cuáles de las siguientes afirmaciones son verdaderas.

Tener en cuenta que se penalizan las incorrectas.

Seleccione una o más de una:

- [x] a. Las variables originales se proyectan el espacio formado por las componentes seleccionadas. ✓
- [x] b. La cantidad de componentes que se calculan son igual a la cantidad de variables originales ✓ La cantidad componentes son iguales a la cantidad de variables pero el objetivo es reducir la cantidad de componentes
- [ ] c. El criterio de la cantidad de componentes seleccionadas tienen en cuenta valores estadísticos y no tiene en cuenta el contexto del problema.
- [x] d. El % de variancia explicada por las componentes se calcula con la proporción que representan los autovalores del total. ✓ Verdadero
- [x] e. Como criterio de seleccion de componetes se puede seleccionar los que tienen autovaores (valores propios) mayor a 1 (uno). ✓ Si el autovalor es mayor a 1 indica que la componente explica más que 1 variable
- [ ] f. Las componentes son ortoganes entre sí lo que indica que no se sabe si son variables independientes entre si

Indicar las frases verdaderas.

Se penalizan las respuestas incorrectas.

Seleccione una:

- (●) a. Si las componentes se rotan por ejemplo con la técnica Varimax cambian las cargas factoriales de las variables originales en el espacio selecionado y rotado. ✓
- ( ) b. Si se eligen 3CP componentes en lugar de 2CP las cargas factoriales de las variables originales en el espacio selecionado cambian.

En el contexto del Análisis de Componentes Principales (ACP),

Indicar cuales de las afimaciones son verdaderas

Seleccione una o más de una:

- [ ] El ACP genera solo dos componentes con todas las variables combinadas linealmente según las cargas factoriales.

- [x] Se puede utilizar ACP en conjuntos de datos grandes.

  ✓

  Verdadero se puede aplica a grandes conjuntos de datos y a no tan grandes

- [x] El primer eje de componentes principales se elige para explicar la mayor parte de la varianza de los datos y es el más cercano a todas las "n" observaciones.

  ✓

  Verdadero

- [x] Si todas las variables no están en la misma escala, debemos normalizar.

  ✓

  Verdadero

- [ ] El ACP genera nuevas variables o componentes que son combinación lineal de las variables originales según las cargas factoriales y que siempre tienen significado en el contexto del problema.

- [x] El PCA se puede utilizar para selección de características o variables

  ✓

  Se pueden elegir entre las variables con las mismas o similar cargas factoriales

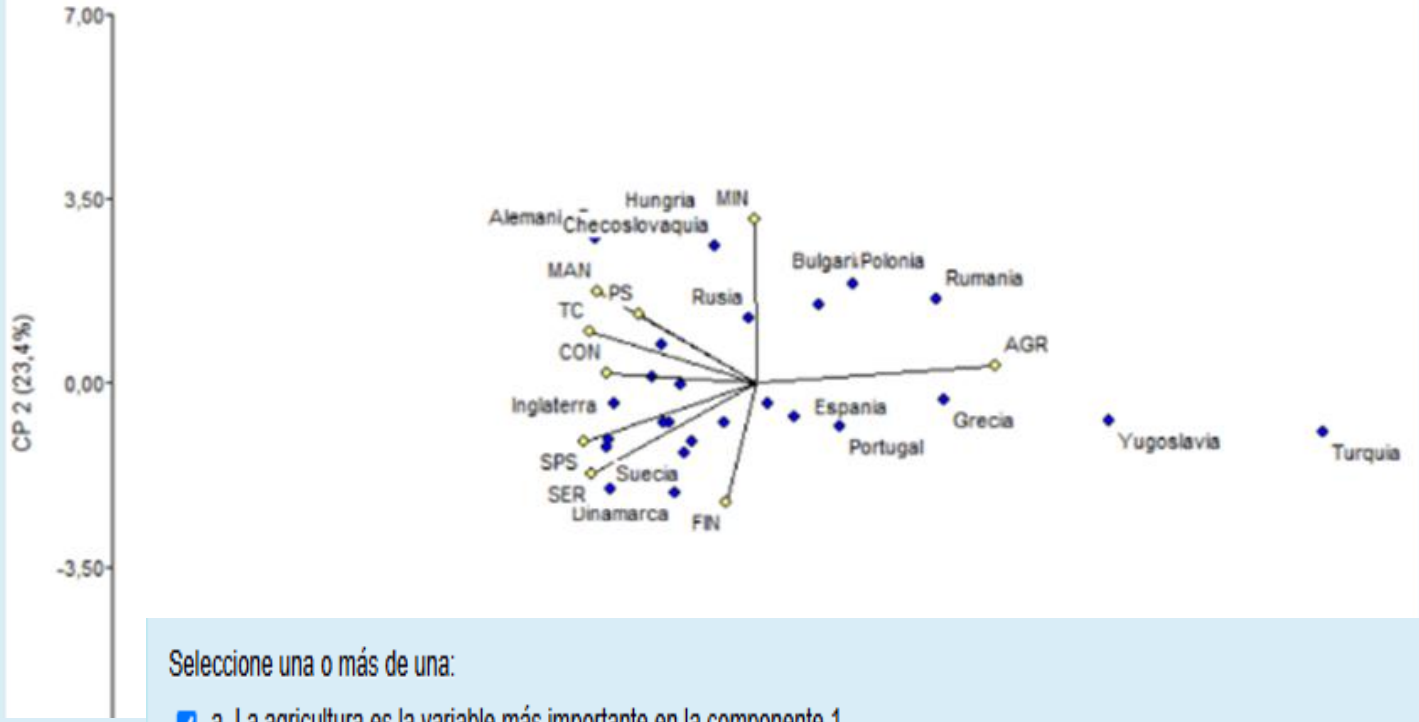
Se desea analizar la economía de distintos países de acuerdo a las variables siguientes:

Se realiza el ACP y se obtienen los siguientes resultados:

Autovalores

Lambda	Valor	Proporción de Varianza explicada	Prop Acum de Varianza explicada
1	3,46	0,38	0,38
2	2,11	0,23	0,62
3	1,1	0,12	0,74
4	1	0,11	0,85
5	0,54	0,06	0,91
6	0,42	0,05	0,96
7	0,23	0,03	0,98
8	0,14	0,02	1
9	8,50E-04	9,50E-05	1

Variables	CP 1	CP 2	CP 3	CP 4	CP 5
Agricultura	0,98	0,09	-0,05	-0,02	0,16
Mineria	-0,01	0,9	0,21	-0,06	-0,11
Manufactura	-0,66	0,5	0,17	0,34	-0,27
Energia	-0,48	0,37	0,57	-0,42	0,21
Construcción	-0,62	0,05	-0,13	0,67	0,35
Servicios	-0,68	-0,51	0,14	0,08	-0,22
Finanzas	-0,13	-0,66	0,61	0	0,21
Servicio Social	-0,71	-0,33	-0,35	-0,41	-0,17
Transporte	-0,69	0,28	-0,41	-0,3	0,37



Seleccione una o más de una:

- [x] a. La agricultura es la variable más importante en la componente 1
- [ ] b. La cantidad de componentes por el criterio de los autovalores mayores a 1 indica 5 componentes
- [x] c. Con otro algoritmo podria suceder que Minería tiene carga negativa en CP2 y Finanzas positiva en CP2, pero seguirían siendo opuestos
- [ ] d. Inglaterra no contribuye en la componente 1
- [x] e. Yugoslavia contribuye positivamente en la componente 1, tiene mayor contribución en este sector.
- [x] f. La contribución en el sector Mineria es opuesto a la contribución en Finanzas por eso tienen distinto signo las cargas factoriales en la componente 2

Empleos

Los datos corresponden a los porcentajes de empleo en distintos sectores laborales para un conjunto de países Europeos. Las columnas del archivo correspondientes

AGR: agricultura, MIN: mineria: MAN: manufactura, PS: previsión social,

SER: servicios, FIN:finanzas, SPS:Seguros, TC: transporte y comunicación

Se obtuvieron los siguientes resultados

Autovalores

Lambda	Valor	Proporción	Prop Acum
1	3,46	0,38	0,38
2	2,11	0,23	0,62
3	1,10	0,12	0,74
4	1,00	0,11	0,85
5	0,54	0,06	0,91
6	0,42	0,05	0,96
7	0,23	0,03	0,98
8	0,14	0,02	1,00
9	8,5E-04	9,5E-05	1,00

Correlaciones con las variables originales

Variables	CP 1	CP 2	CP 3	CP 4
AGR	0,98	0,09	-0,05	-0,02
MIN	-0,01	0,90	0,21	-0,06
MAN	-0,66	0,50	0,17	0,34
PS	-0,48	0,37	0,57	-0,42
CON	-0,62	0,05	-0,13	0,67
SER	-0,68	-0,51	0,14	0,08
FIN	-0,13	-0,66	0,61	1,4E-03
SPS	-0,71	-0,33	-0,35	-0,41
TC	-0,69	0,28	-0,41	-0,30

1) Explicar las característica de cada componente en función de las variables

2) Analice la diferencias de interpretación si se eligen dos componentes o si s

- Variancia explicada
- Variables con Carga negativa y positiva alta.
- Caracterización conceptual (teoría implicita)
- Ver relación Individuos (países) y Variables (empleso

1) Se decidió analizar las primeras cuatro componentes porque son las que concentran la mayor parte de la información relevante del conjunto de datos. Según los autovalores obtenidos, las cuatro primeras presentan valores mayores o cercanos a 1 y explican, en conjunto, alrededor del 85% de la varianza total, mientras que las restantes componentes aportan muy poca información adicional. A partir de los autovalores y de las correlaciones de las variables con las componentes principales, se identifican distintas características.

El primer componente **CP1**, que explica el 38% de la varianza total, presenta una correlación positiva muy alta con Agricultura (AGR = 0,98) y negativa con los sectores d servicios, manufactura, finanzas y seguros. Esto indica que hay paises con una economia con alta participacion agricola, mientras que los demas, con indices negativos demuestran que son economias mas insutrializadas y de servicios.

El segundo componente **CP2**, que explica el 23% de la varianza, muestra una alta correlación positiva con Minería (MIN = 0,90) y Manufactura (MAN = 0,50), y una correlación negativa con Servicios (SER = -0,51) y Finanzas (FIN = -0,66). Esta componente refleja un eje que diferencia las economías basadas en la industrialización la minería respecto de aquellas más orientadas a los servicios y las finanzas.

El tercer componente **CP3**, que explica el 11% de la varianza, se asocia positivamente con Finanzas (FIN = 0,61) y, en menor medida, con Manufactura, mientras que se relaciona negativamente con los sectores de transporte y seguros. En este sentido, representa la diferencia entre economías centradas en la actividad financiera e industria y aquellas vinculadas a servicios públicos o transporte.

Mientras que, el cuarto componente **CP4**, que explica el 9% de la varianza, muestra una fuerte correlación con Construcción (CON = 0,67), lo que permite distinguir países en lo

Empleos

Los datos corresponden a los porcentajes de empleo en distintos sectores lab

AGR: agricultura, MIN: mineria: MAN: manufactura, PS: previsión social,

SER: servicios, FIN:finanzas, SPS:Seguros, TC: transporte y comunicación

Se obtuvieron los siguientes resultados

Autovalores

Lambda	Valor	Proporción	Prop Acum
1	3,46	0,38	0,38
2	2,11	0,23	0,62
3	1,10	0,12	0,74
4	1,00	0,11	0,85

Correlaciones con las variables origina

Variables	CP 1	CP 2	CP 3	CP 4
AGR	0,98	0,09	-0,05	-0,02
MIN	-0,01	0,90	0,21	-0,06
MAN	-0,66	0,50	0,17	0,34
PS	-0,48	0,37	0,57	-0,42
CON	-0,62	0,05	-0,13	0,67
SER	-0,68	-0,51	0,14	0,08
FIN	-0,13	-0,66	0,61	1,4E-03
SPS	-0,71	-0,33	-0,35	-0,41
TC	-0,69	0,28	-0,41	-0,30

o correspondientes

- Variancia explicada
- 4 componentes principales ¿Qué evidencian que no se ve con 2 componentes?
- Rotación Varimax trata de desacoplar las componentes principales en factores alineados con las variables

2) Si se eligen únicamente dos componentes (CP1 y CP2), se logra explicar el 62% de la varianza total. Esta elección permite una interpretación más sencilla y posibilita representar los resultados en un plano bidimensional, facilitando la visualización de los datos en un biplot. Con dos componentes, se obtiene una visión general en la que el primer eje refleja la oposición entre agricultura y servicios, mientras que el segundo distingue entre minería e industria frente a sectores financieros o de servicios. No obstante, con solo dos componentes se pierde información relevante sobre sectores específicos como la construcción o las finanzas.

Por otra parte, al considerar cuatro componentes (CP1 a CP4 como se realizo en el punto anterior), se alcanza un 85% de varianza explicada, lo que ofrece una interpretación más completa del conjunto de sectores económicos, incluyendo actividades como la construcción y el transporte. Este enfoque permite identificar patrones más detallados entre los países, aunque la interpretación resulta compleja y cuesta más entender los gráficos con tantas dimensiones. En conclusión, trabajar con dos componentes brinda una visión general clara y útil para análisis exploratorios, mientras que utilizar cuatro componentes proporciona una descripción más exhaustiva y precisa, a costa de simplicidad e interpretabilidad.