Análisis Inteligente de datos

Monica Giuliano

Maria Laura Vranic

Temas de investigación de profesoras

- Mónica Giuliano
  - Procesamiento de audio
  - Clasificación automática de habla de personas con y sin Parkinson

- María Laura Vranic
  - Procesamiento de imágenes
  - Análisis multivariado de datos en el INTA

Análisis Inteligente de datos

OBJETIVOS DE LA ASIGNATURA

- Comprender y organizar las fases de un proyecto de minería y Ciencia de Datos aplicado en un contexto específico.
- Proponer y ajustar objetivos de análisis en función de las características de la información disponible de un conjunto de datos.
- Valorar modelos y tecnologías de software disponibles, más adecuadas para responder los objetivos propuestos.
- Utilizar herramientas tecnológicas adecuadas al problema y evaluar rendimientos de acuerdo con el diseño y los objetivos del proyecto.
- Interpretar, valorar y comunicar de modo adecuado los resultados del proyecto, tomando en cuenta el contexto específico de aplicación.
- Construir una actitud crítica y flexible con capacidades de análisis científico y comunicación eficaz de resultados.

Análisis Inteligente de datos

TEMAS

Unidad 1: Introducción a técnicas estadísticas para procesar datos de diferente tipo. Obtención de conocimiento a partir de los datos. Tareas predictivas y descriptivas. Uso de R y Python.

Unidad 2. Clasificación no supervisada

- Análisis Exploratorio Multivariante. Explorar y describir las variables que componen la matriz de datos. Identificación de casos atípicos multivariantes.
- Reducción de la dimensionalidad. Análisis de componentes principales (ACP).
- Métodos de agrupamiento. Medidas de distancia. Algoritmos de clustering jerárquicos aglomerativos y divisivos. Clasificación Jerárquica y métodos. K-medias. Métricas de calidad del agrupamiento.
- Aplicación de técnicas exploratorias combinadas.

Análisis Inteligente de datos

TEMAS

- **Unidad 3:** - Clasificación supervisada.
- Análisis discriminante lineal y cuadrático. Condiciones de validez. Evaluación del ajuste. Matriz de confusión.
- Árboles de clasificación y regresión. Métricas de selección de atributos. Entropía. Ganancia de Información. Tasa de Ganancia. Poda y Sobreajuste. Algoritmos Id3, C4.5 y Random Forest. Matriz de confusión.
- Comparación de diferentes técnicas.

- Explicación en clase sincrónica → videos
- Guías de ejercicios
- Resolución de los ejercicios → videos
- Evaluaciones
- 1ra cuestionario sincrónico: **30/10/25**
- 2do ?

Análisis Inteligente de datos

Cronograma

Clase 6 y 8:

- Árboles de clasificación y regresión. Métricas de selección de atributos. Ejemplos prácticos y aplicaciones

Clase 7 y 9:

- Análisis de correspondencias.
- Análisis combinados ACP y Clustering
- Análisis discriminante lineal y cuadrático.

Clase 10: 4/12/25. Evaluación final

Clase 11: 11/12/25. Recuperatorios

Análisis Inteligente de datos

Cronograma

Clase 1 y 2:

´Análisis exploratorio de los datos

- Reducción de dimensionalidad: ACP.
- Ejemplos prácticos y aplicaciones

Clase 3 y 4.

- Clustering
- Agrupamiento de distintos tipos: k medias, jerárquicos

Clase 5: 30/10/25

- **Evaluación individual cuestionario a través del campus**

Datos vs Información

- Los avances tecnológicos hacen que las **capacidades para generar y almacenar datos** se incrementen día a día.

- Automatización de todo tipo de transacciones
- Comerciales, negocios, gubernamentales, científicas.
- Avances en la recopilación de datos (Lectores)
- Mejora en la relación precio-capacidad de los dispositivos de almacenamiento masivo.



Inteligencia de negocios

Operaciones de negocios



¿Qué es Minería de Datos?

- Es el área informática que busca descubrir **patrones** en grandes volúmenes de datos.



- Características
  - Válidos
  - Novedosos
  - Potencialmente útiles
  - Comprensibles

Tipos de variables

Cuantitativas o numéricas

- DISCRETAS (cant. de empleados, cant. de alumnos, etc)
- CONTINUAS (sueldo, metros cuadrados, beneficios, etc)

Cualitativas o categóricas

- NOMINALES: nombran al objeto al que se refieren sin poder establecer un orden (estado civil, raza, idioma, etc.)
- ORDINALES: se puede establecer un orden entre sus valores (alto, medio, bajo, etc)

Analizar datos disponibles

Se busca determinar una primera medida de **calidad de los datos**

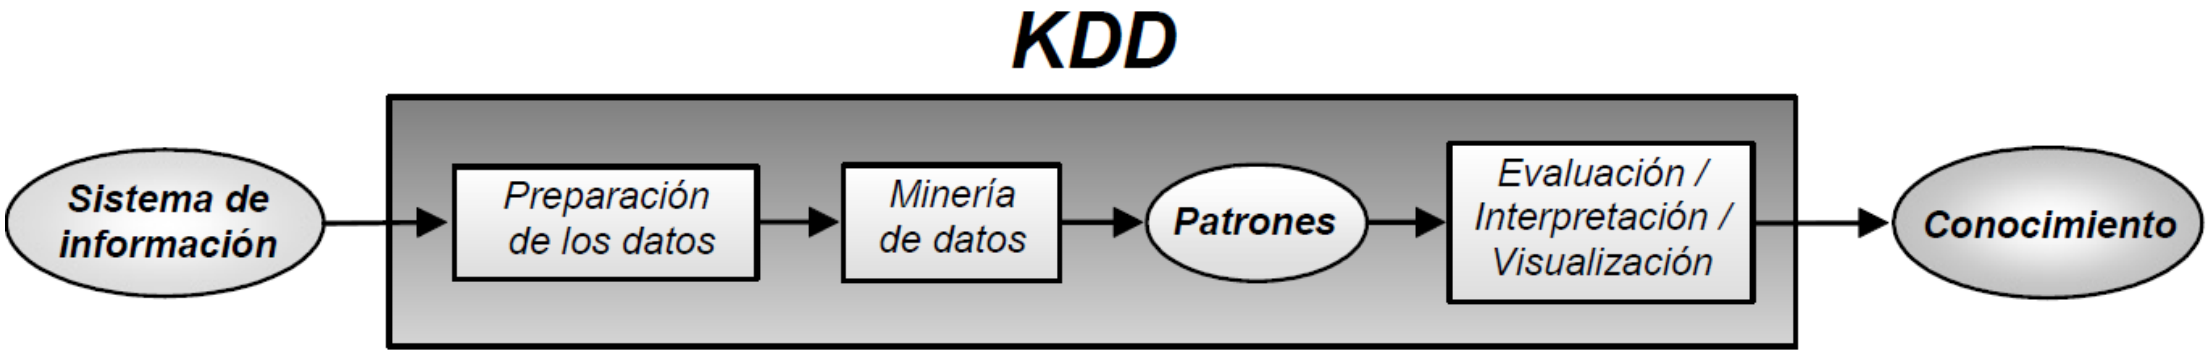
Variables Cuantitativas o numéricas

- Utilizar medidas tales como: mínimo, máximo, media, varianza, moda, mediana, etc.
- También pueden usarse gráficos como los diagramas de cajas o los histogramas.
- Identificar: atípicos, datos faltantes.

Variables Cualitativas o Categóricas

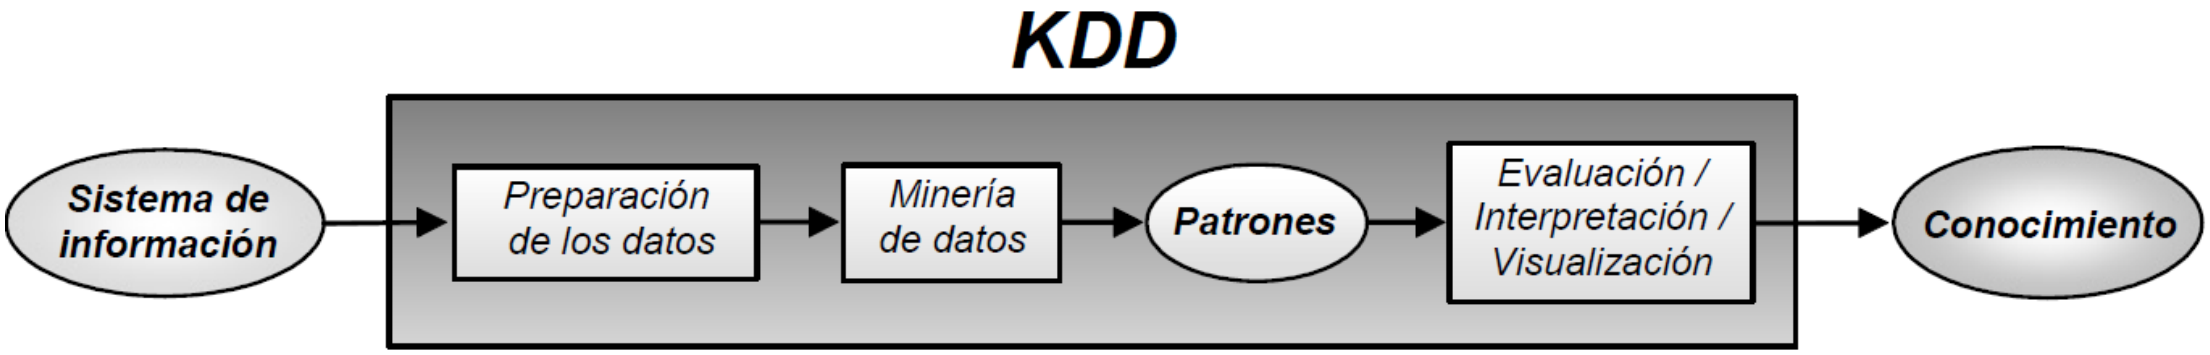
- Análisis de frecuencia mediante diagramas de barras o gráficos de sectores.

Extracción o “descubrimiento de conocimiento en bases de datos” (*Knowledge Discovery in Databases, KDD*)



- La Minería de Datos busca el descubrimiento del conocimiento sin una hipótesis preconcebida.
- “KDD” es el proceso no trivial de identificar patrones a partir de los datos, que sean novedosos y potencialmente útiles.
- La minería de Datos va más allá de clasificar patrones como “bien o mal”, que es algo que intentamos hacer con Aprendizaje Automático.

Extracción o "descubrimiento de conocimiento en bases de datos" (*Knowledge Discovery in Databases, KDD*)



- Generalmente registrado en forma previa al proceso de KDD.
  - Almacena información histórica
  - No necesariamente centralizada

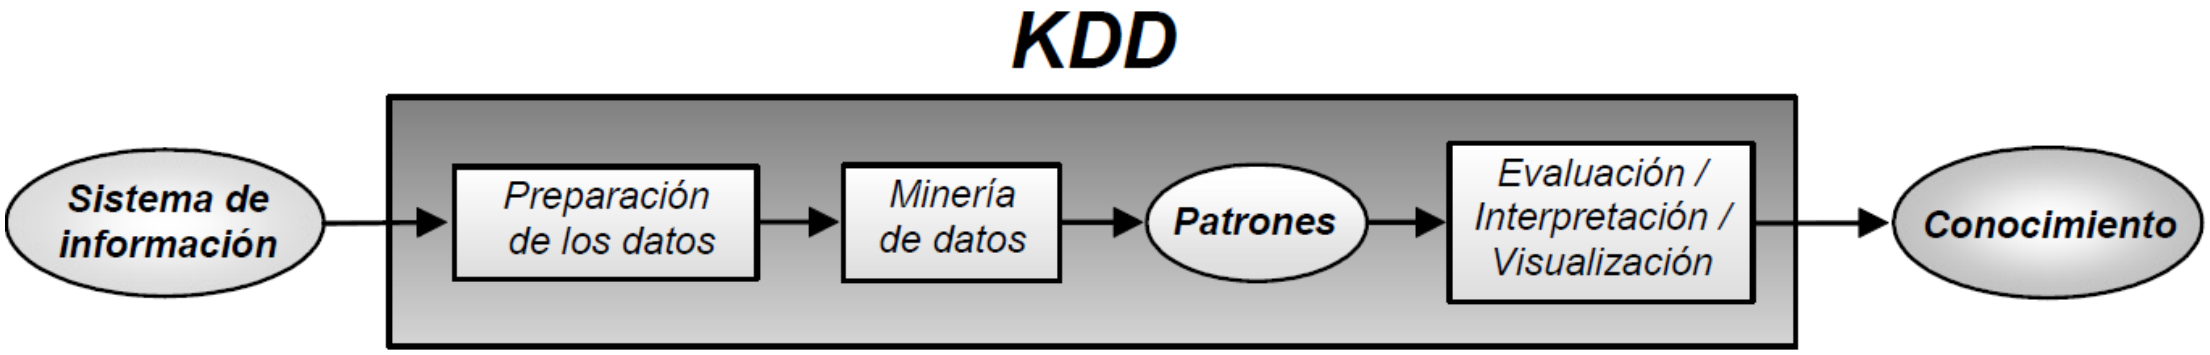
- Elegidos en base al problema
- Medidas subjetivas y objetivas

- Uniformar la notación.
  - Datos faltantes
  - Fuera de los rangos esperados (outliers)

Minería de Datos



Extracción o “descubrimiento de conocimiento en bases de datos” (*Knowledge Discovery in Databases, KDD*)



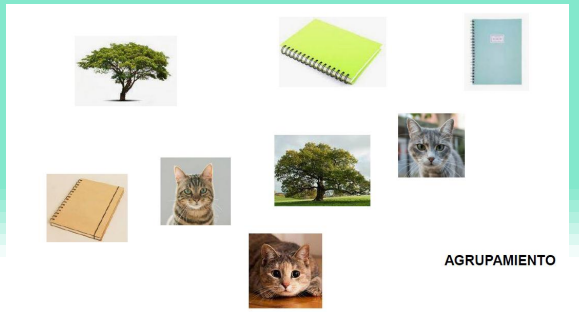
- Técnicas no supervisadas:
  - Análisis de Componentes Principales
  - Clustering
- Técnicas supervisadas
  - Arboles
  - Análisis Discriminante

¿Cuándo se utilizan las técnicas no supervisadas?

- Las técnicas no supervisadas se utilizan cuando se desea descubrir patrones emergentes en los datos, explorar la estructura subyacente y descubrir información valiosa que no es evidente a simple vista.
- Son particularmente útiles cuando se trabaja con grandes conjuntos de datos, cuando la información etiquetada disponible es limitada o cuando no se sabe de antemano lo que se está buscando.
- En contraste, el aprendizaje no supervisado trabaja con datos **no etiquetados**. El modelo intenta encontrar patrones o estructuras ocultas dentro del conjunto de datos sin tener una “respuesta” definida que aprender.


No supervisadas
Clustering
K medias
Jerárquico
Variables categóricas
Variables numéricas
Reducción de dimensión
Correspondencias
Variables categóricas
ACP
Componentes principales
Variables numéricas
Otros
Modelos Generativos (Autoencoders, reglas de asociación)

Aprendizaje no supervizado



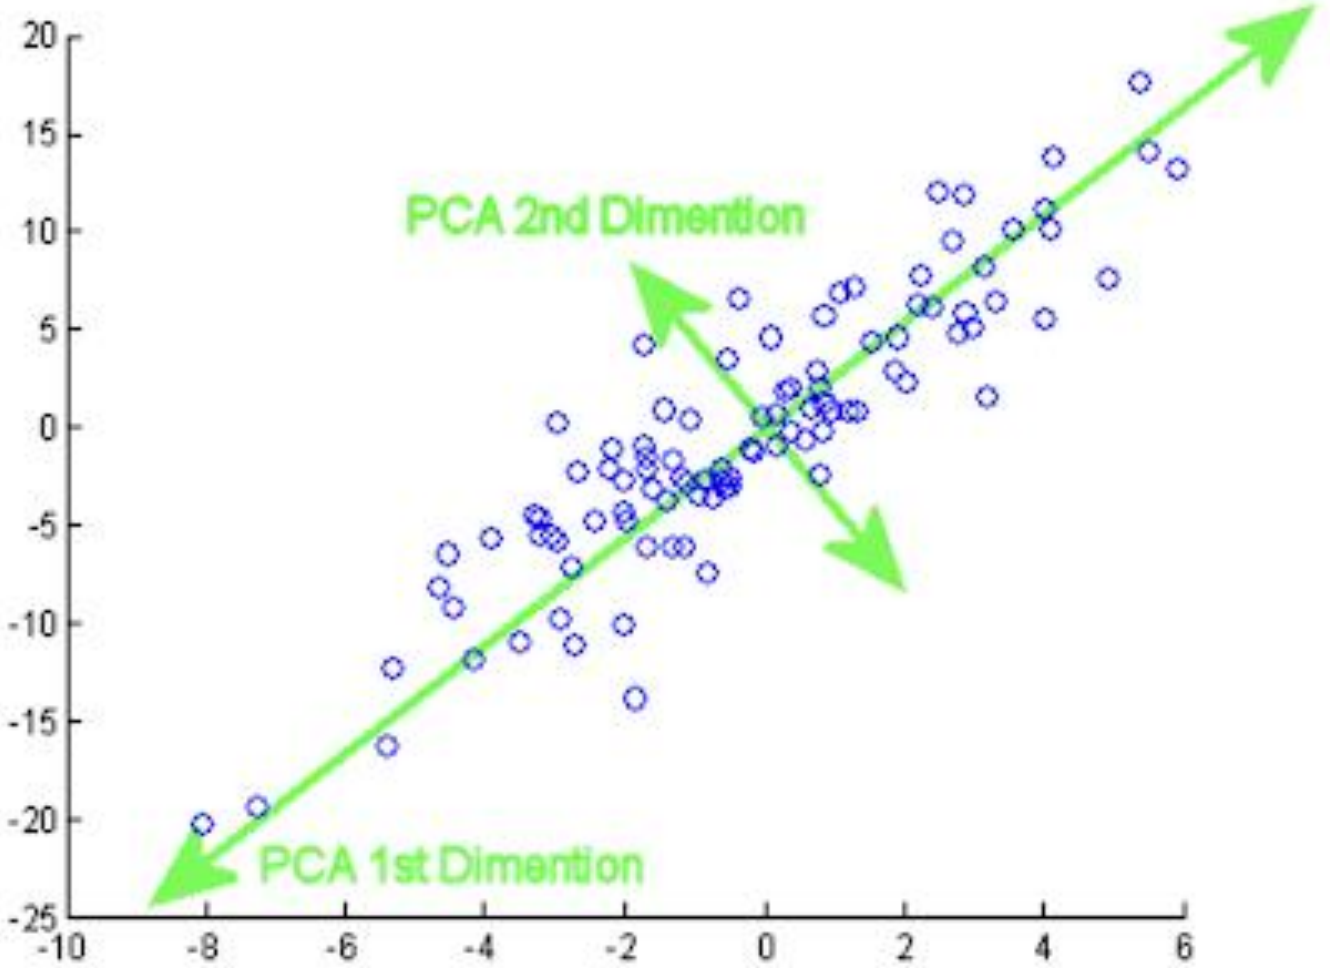
Ventajas

- **No necesita etiquetas:** Ideal cuando no se dispone de datos etiquetados o cuando hay muchos datos sin clasificar.
- **Detecta estructuras ocultas:** Puede descubrir patrones interesantes o agrupaciones inesperadas.
- **Útil para exploración de datos:** Ayuda a entender la distribución o relaciones internas dentro del conjunto de datos.
- **Escalable a grandes volúmenes de datos:** Puede aplicarse a datasets masivos sin intervención manual previa.

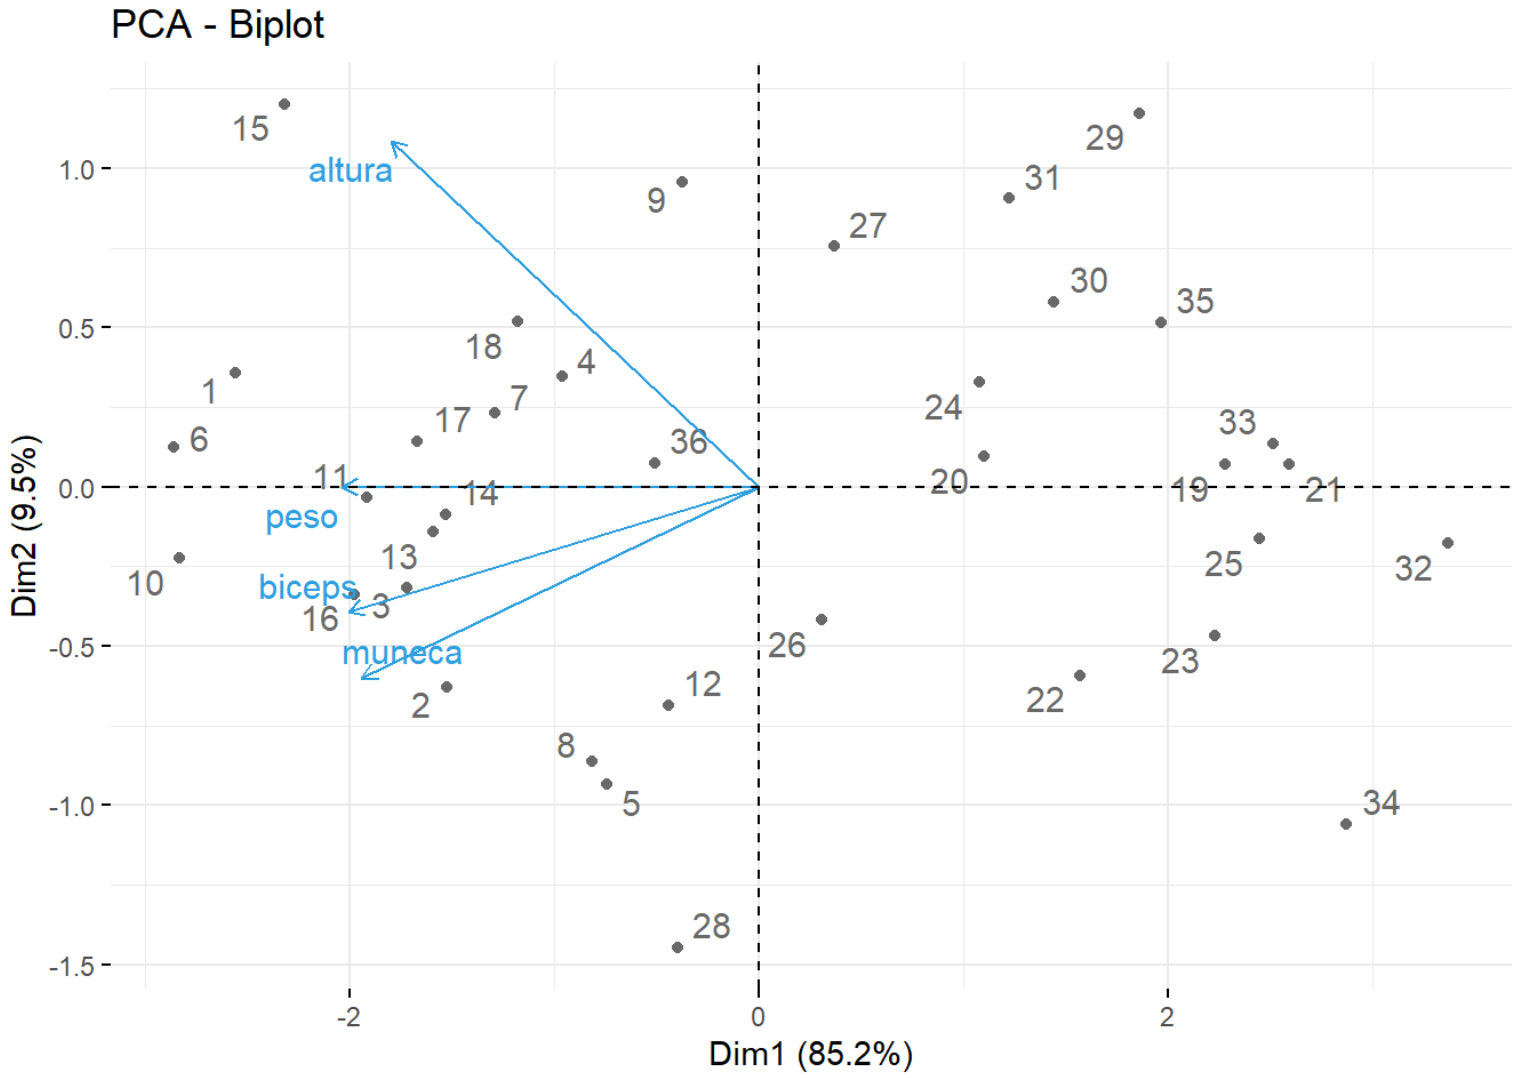
Desventajas

- **Difícil de evaluar:** No hay una "respuesta correcta" con la cual comparar los resultados.
- **Resultados menos interpretables:** Algunos algoritmos generan salidas difíciles de entender o explicar.
- **Mayor riesgo de ruido o agrupaciones incorrectas:** Puede detectar patrones que no tienen sentido real o práctico.

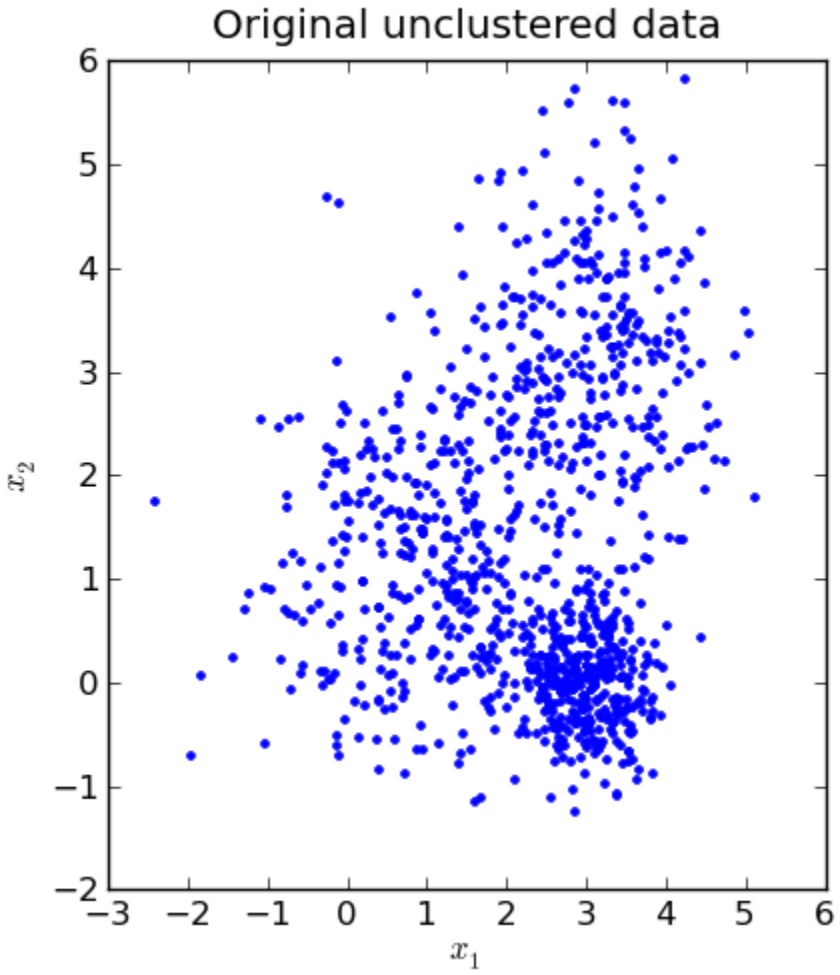
Análisis de Componentes Principales (ACP-PCA)

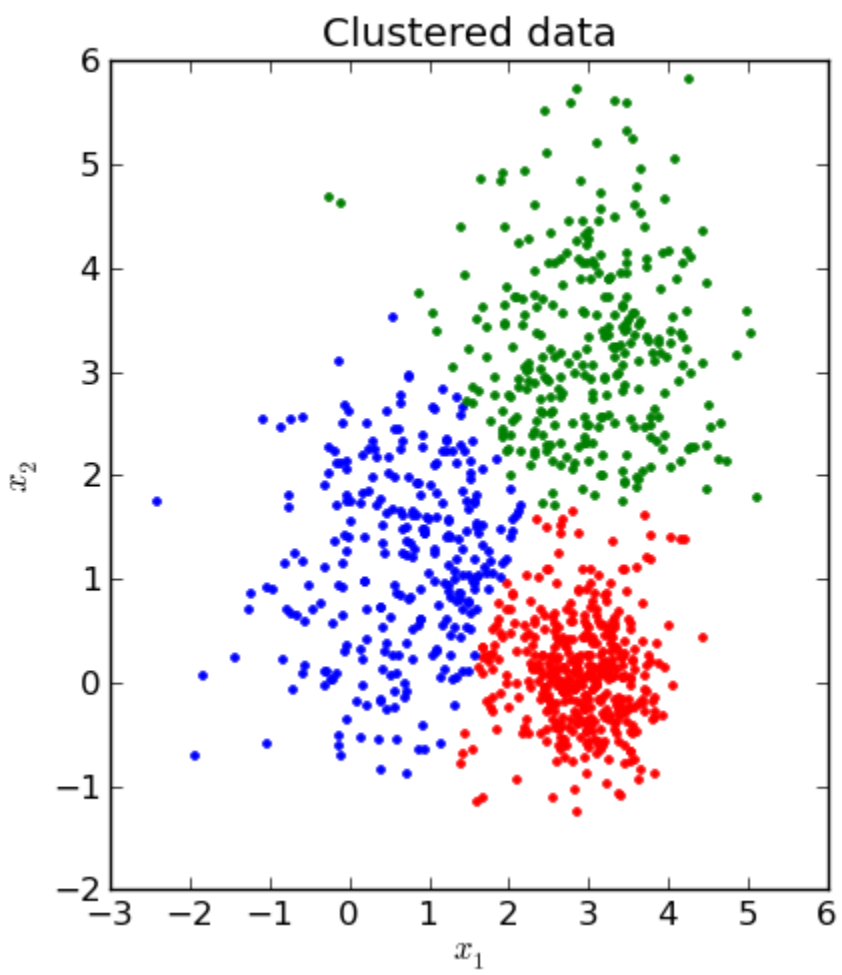


ACP-PCA Biplot: Variables y Casos



Clustering o Agrupamiento

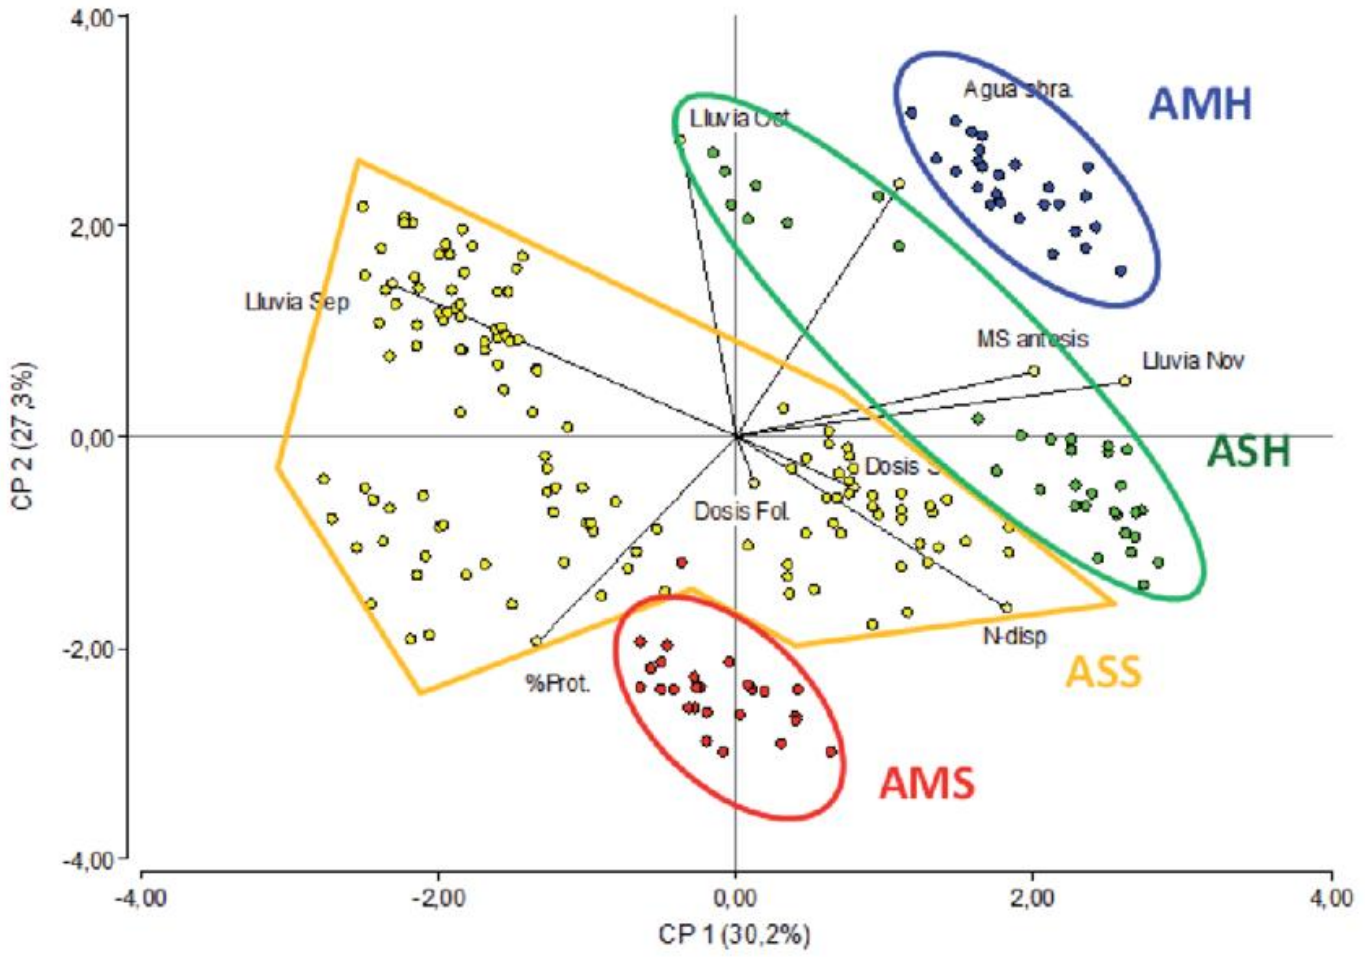




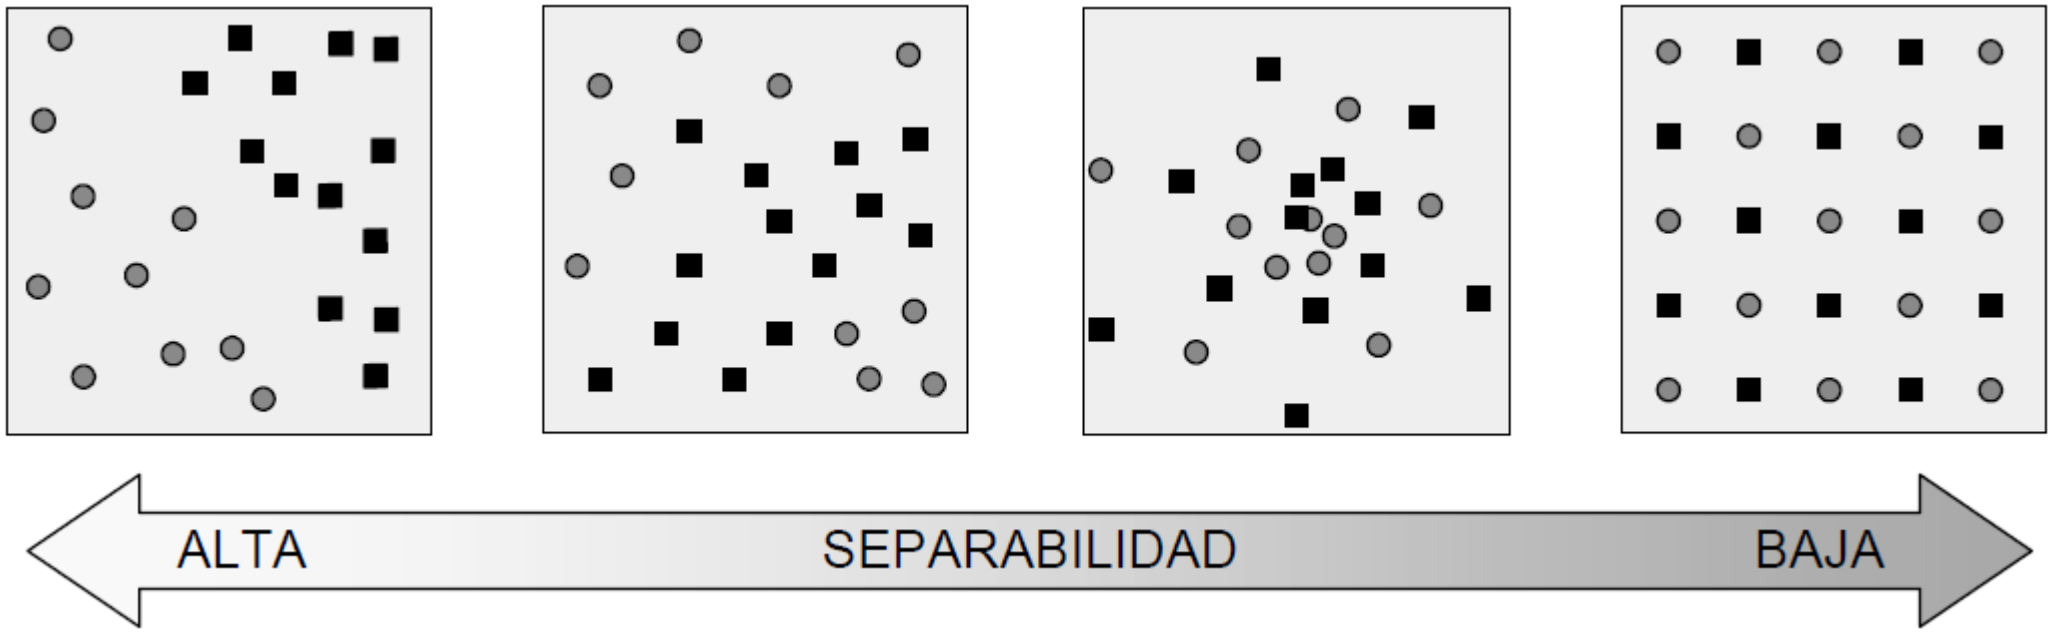
Medidas de distancia para diferentes tipos de variables.

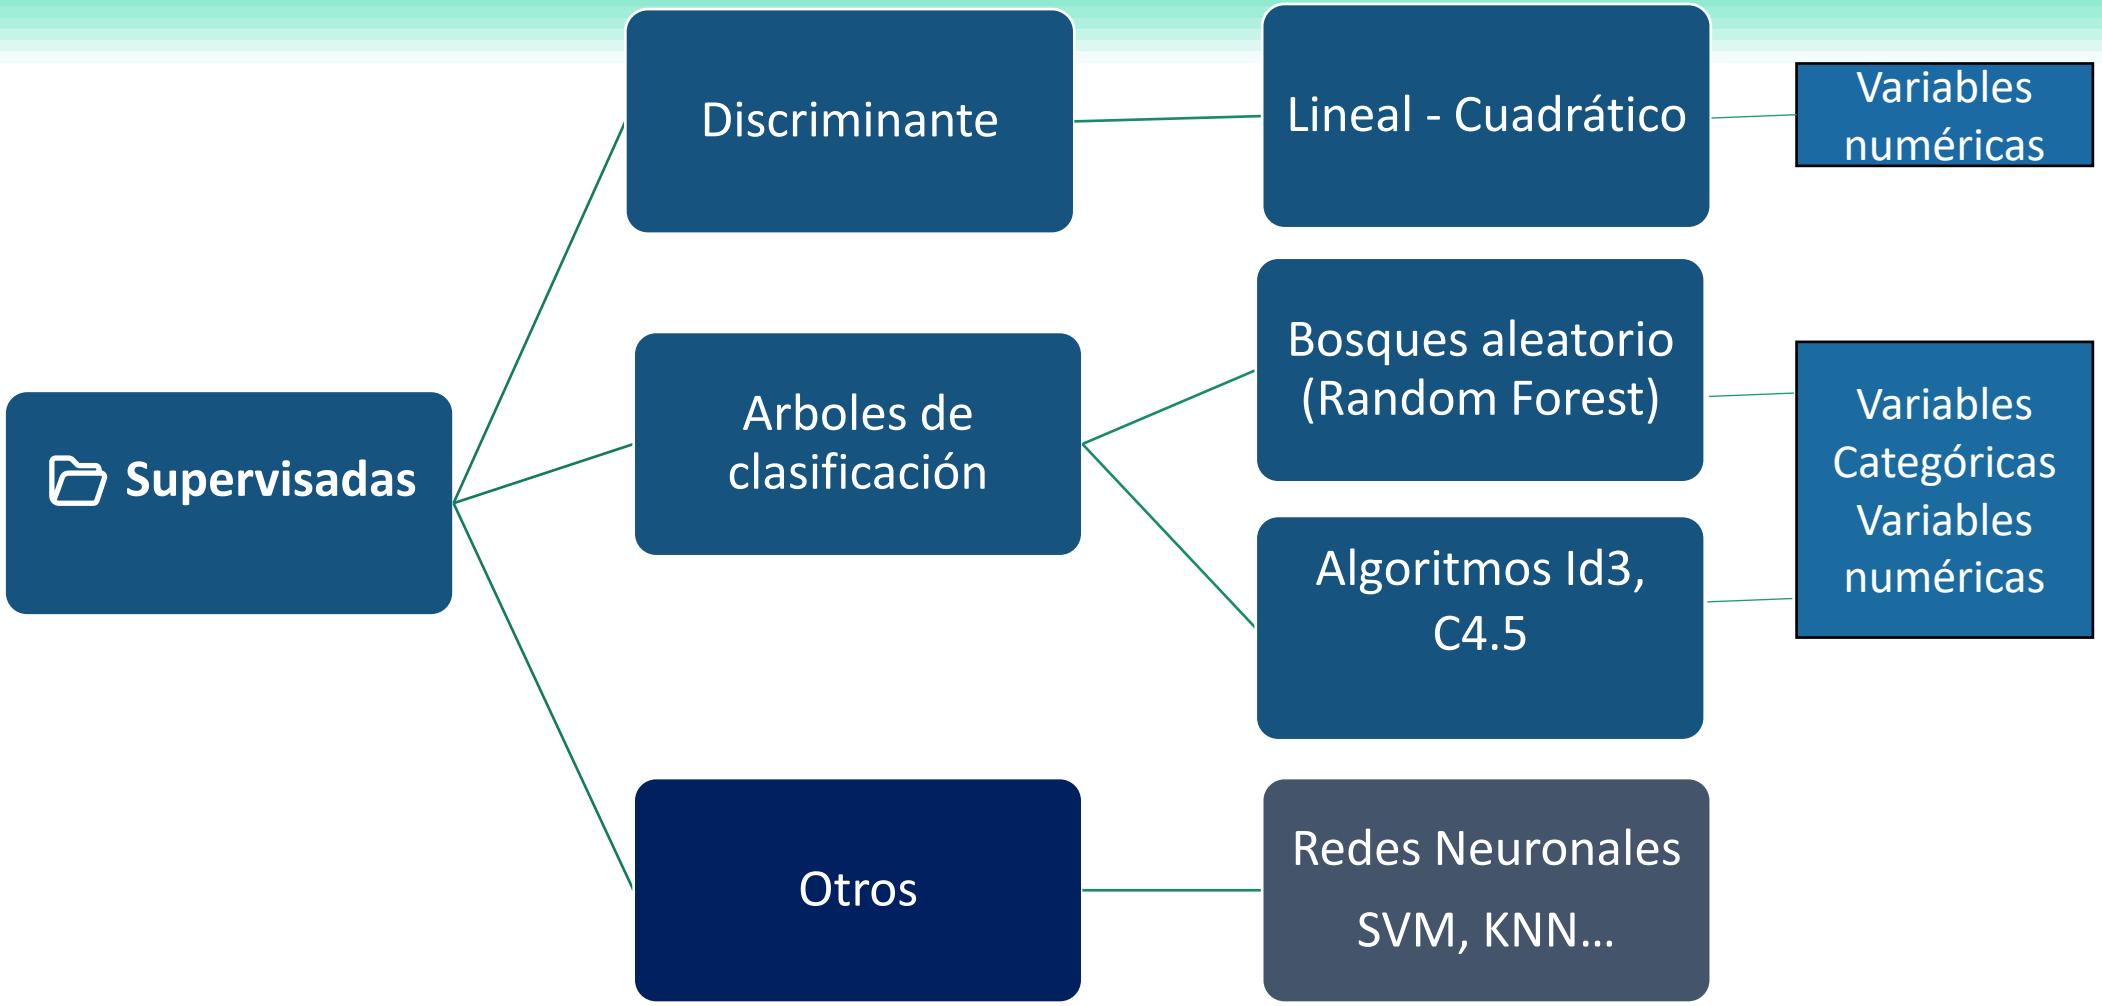
Cluster de casos o variables

Clustering y ACP



Separabilidad de los datos




Supervisadas
Discriminante
Lineal - Cuadrático
Variables numéricas
Arboles de clasificación
Bosques aleatorio (Random Forest)
Algoritmos Id3, C4.5
Variables Categóricas Variables numéricas
Otros
Redes Neuronales SVM, KNN…

Análisis discriminante (paramétrico)

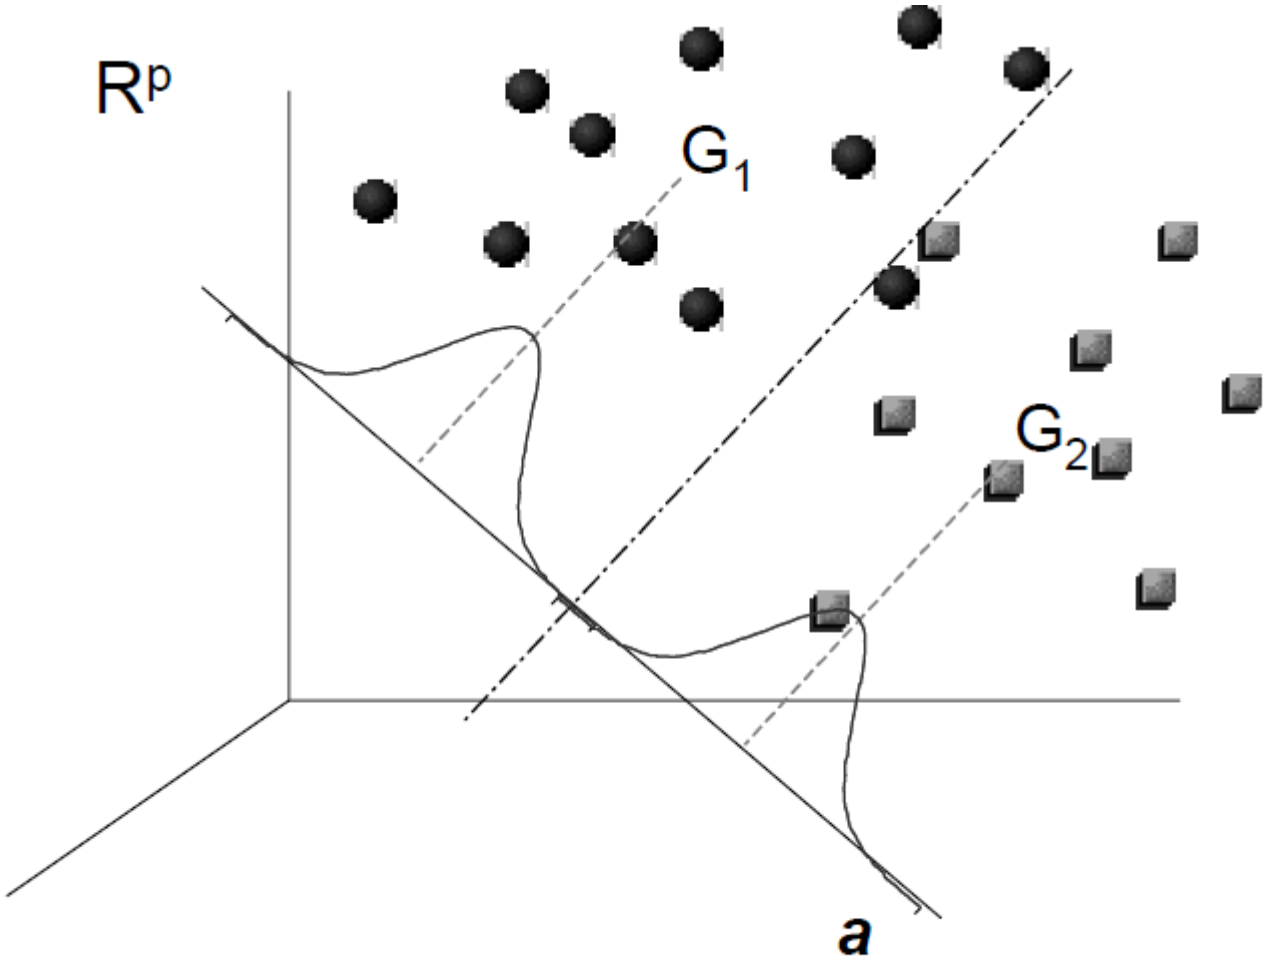
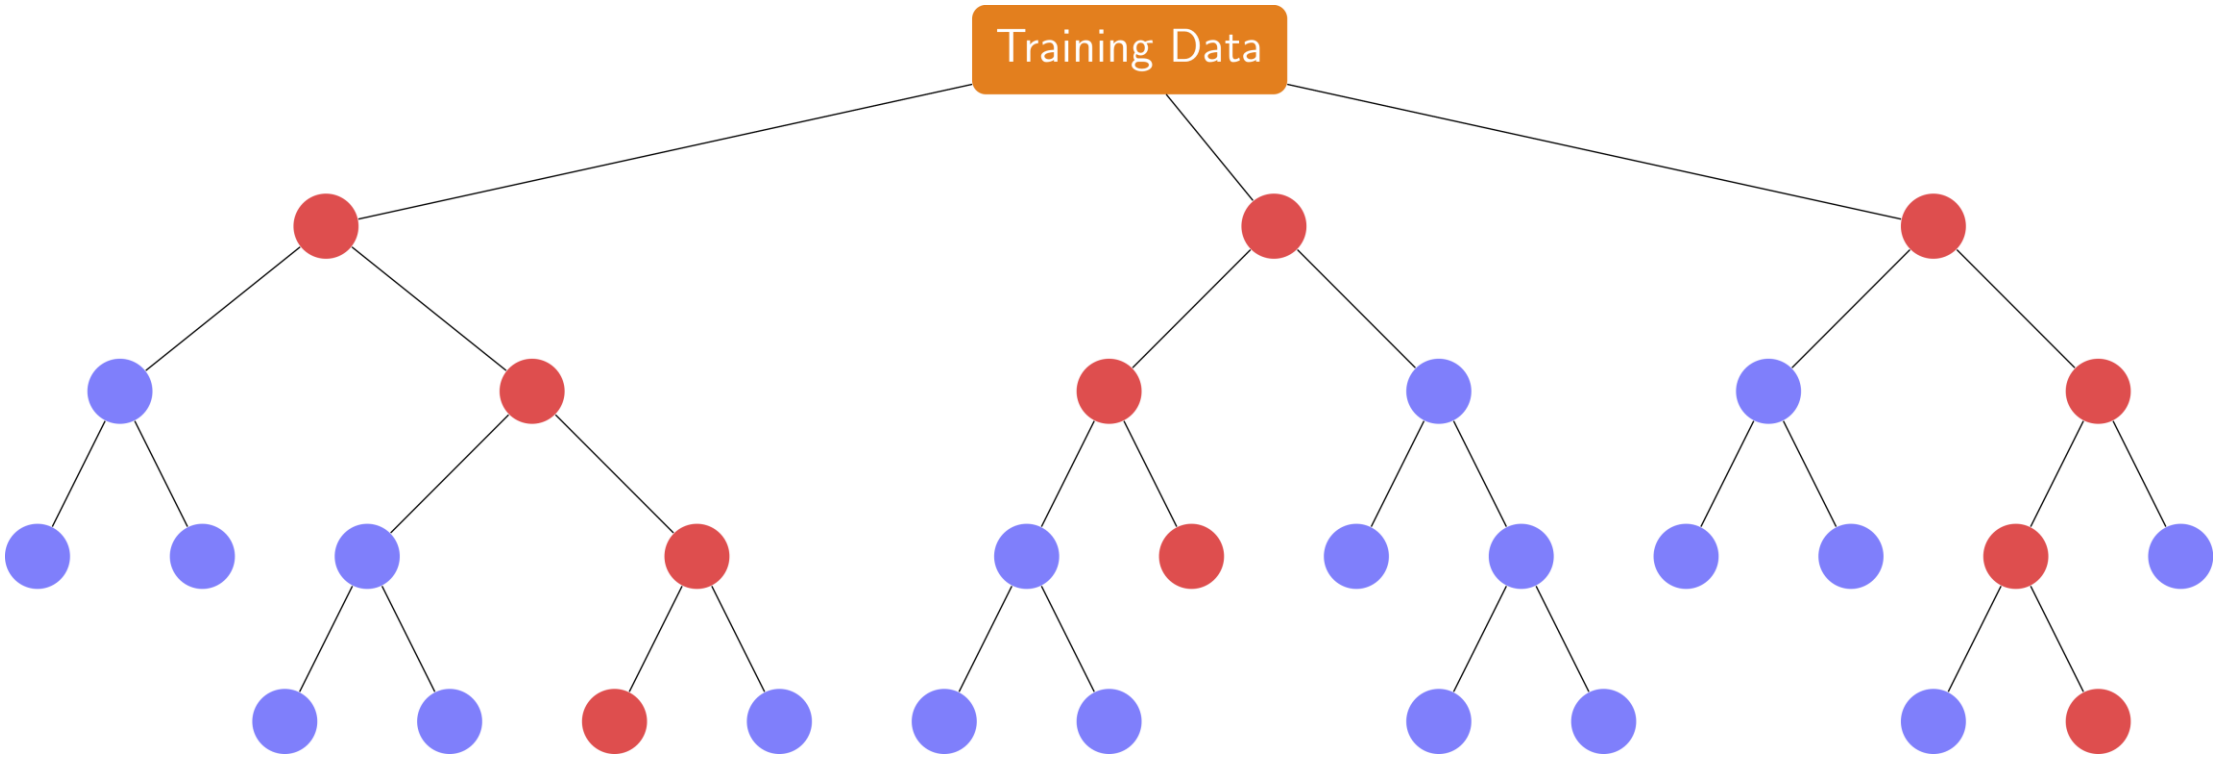


Figura 7.22. Función discriminate de Fisher para el caso de dos grupos.

Árboles de clasificación y regresión

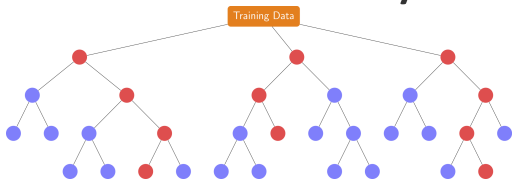


¿Cuándo se utilizan las técnicas supervisadas?

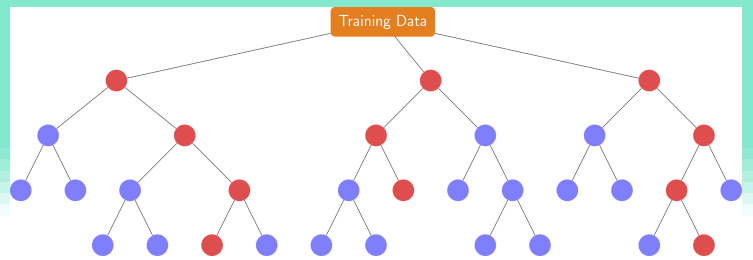
Se utilizan cuando existe un conjunto de datos de los cuales se conoce la clase a la que pertenecen.
Generalmente se intenta minimizar cierto error de clasificación o regresión.

Algoritmos de aprendizaje supervizado

- **Regresión Lineal:** Ideal para predecir valores numéricos continuos, como el precio de una casa o el ingreso mensual.
- **Support Vector Machines (SVM):** Muy eficaz para clasificación binaria o multiclase, especialmente en espacios de alta dimensión.
- **Árboles de Decisión y Random Forests:** Fáciles de interpretar y potentes para clasificación y regresión; buenos cuando se necesitan decisiones explicables.
- **Redes Neuronales Supervisadas:** Altamente flexibles para tareas complejas como visión por computadora o reconocimiento de voz, aunque requieren más datos y potencia de cómputo.
- Otras técnicas: lógica borrosa, algoritmos genéticos, etc



Aprendizaje supervisado



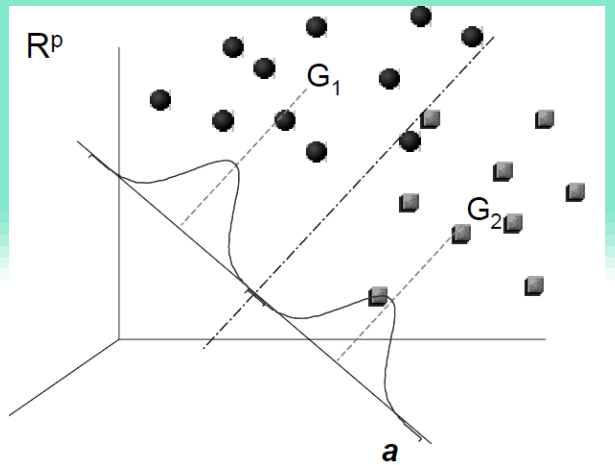
Ventajas

- **Alta precisión:** Puede lograr muy buenos resultados cuando se entrena con datos etiquetados de calidad.
- **Rendimiento medible:** Es fácil evaluar qué tan bien funciona usando métricas claras (precisión, recall, etc.).
- **Generalización efectiva:** Si se entrena correctamente, puede predecir con precisión sobre nuevos datos.
- **Amplio soporte en herramientas y librerías:** Muy bien documentado y con muchas implementaciones disponibles.

Desventajas

- **Requiere datos etiquetados:** Etiquetar grandes volúmenes de datos puede ser costoso y lento.
- **Sesgo por datos de entrenamiento:** Si los datos están mal etiquetados o no son representativos, el modelo falla.
- **No descubre patrones ocultos por sí solo:** Aprende solo lo que se le enseña explícitamente.

Minería de Datos



- Los sistemas tradicionales de explotación de datos están basados en la existencia de hipótesis o modelos previos como la Normalidad de los datos

Problemas

- Quien formula la hipótesis debe saber cuál es la información que necesita.
- La complejidad de los datos almacenados y sus interrelaciones dificulta la verificación del modelo.

La Minería de Datos busca el descubrimiento del conocimiento sin una hipótesis preconcebida.

Caracterizar los datos → Análisis exploratorio

Se dispone de información de 3 tipos de flores Iris



Tipos de conocimiento a extraer

Predictivo

- En base al modelo construido es posible predecir hechos futuros.
- Por ejemplo se busca predecir:
  - Cuál medicamento suministrar a un paciente dado.
  - Si un mail recibido es spam o no.

Descriptivo

- Muestran nuevas relaciones entre las variables.
- Por ejemplo se buscará describir:
  - Tipos de clientes para diseñar campañas de marketing
  - Transacciones en una tarjeta de crédito para detectar casos anómalos.



No supervisado

















AGRUPAMIENTO

Supervisado → predecir

GATO



GATO



GATO



ARBOL



ARBOL



CUADERNO



CUADERNO



CUADERNO



GATO



?

- Comenzamos…