

Análisis Inteligente de datos

Clase 23/10/2025

Vranic, Maria Laura

Clase 16 de octubre de 2025 (Mónica)

Tipos de Algoritmos de Clustering

- K-Means (basado en centroides)
- Jerárquico
- DBSCAN (densidad)
- EM (Expectation-Maximization)

Validación del Agrupamiento

- SSW / SSB
- Silhouette (–1 a 1 → mejor cuanto más alto)
- Davies-Bouldin (menor es mejor)

Medidas de Distancia y Tipos de Clusters

- Euclidiana, Manhattan, Mahalanobis, Coseno
- Formas de clusters y adecuación del método

Casos Prácticos y Ejemplos

- Comunidades Autónomas (cine)
- Arrestos en USA
- Fútbol (PCA + K-Means)
- Minería de texto (Neruda)

Tipos de Algoritmos de Clustering

K-Means (basado en centroides)

- Es un método de agrupamiento particional.
- Divide los datos en k clusters minimizando la suma de distancias cuadradas entre los puntos y el centroide del cluster.
- Itera entre: Asignar cada punto al cluster más cercano.
- Recalcular los centroides.
- **Ventajas**: rápido y sencillo.
- **Limitaciones**: requiere definir k previamente, sensible a outliers y a la forma de los clusters (asume forma esférica).

Jerárquico

- Construye una jerarquía de clusters mediante:
  - **Aglomerativo**: empieza con cada punto como un cluster y los va fusionando.
  - **Divisivo**: empieza con todos los puntos juntos y los va separando.
- Representa la estructura en un **dendrograma**.
- Ventajas: no necesita definir **k** al inicio, permite explorar diferentes niveles de agrupamiento.
- Limitaciones: costoso computacionalmente para grandes datasets.

DBSCAN (basado en densidad)

- Agrupa puntos que están **densamente conectados**.
- Define clusters según:
  - **ε (epsilon)**: radio de vecindad.
  - **minPts**: número mínimo de puntos en la vecindad.
- Identifica:
  - **Core points** (núcleo), **border points** y **ruido**.
- **Ventajas**: detecta clusters de forma arbitraria y maneja ruido.
- **Limitaciones:** sensible a la elección de parámetros ε y minPts.

EM (Expectation-Maximization)

- Basado en **modelos probabilísticos**, generalmente **mezcla de Gaussianas**.
- Itera entre:
  - **Expectation**: calcula la probabilidad de pertenencia de cada punto a cada cluster.
  - **Maximization**: actualiza parámetros del modelo (medias, covarianzas).
- **Ventajas**: permite clusters elípticos y asignación probabilística.
- **Limitaciones**: puede converger a óptimos locales, requiere definir número de componentes.

Validación del Agrupamiento

- Cohesión → proximidad interna
- Separación → distancia entre clusters

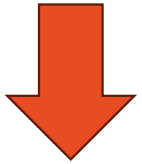
Índices:

- Silhouette (−1 a 1 → mejor cuanto más alto)
- Davies-Bouldin (menor es mejor)
- SSW / SSB

Validación del Agrupamiento

SSW / SSB

- Cohesión → proximidad interna





$$SSW = \sum_{i=1}^{k} \sum_{x \epsilon C_i} dist^2(m_i, x)$$

- k: número de clusters.
- C_i: conjunto de puntos que pertenecen al cluster i.
- m_i: centroide (o media) del cluster i.
- x: un punto dentro del cluster C_i.
- $\text{dist}^2(m_i, x)$: distancia al cuadrado entre el punto x y el centroide m_i.

Interpretación:

- Se calcula la **distancia al cuadrado entre cada punto y el centroide de su cluster**.
- **Se suman todas esas distancias para todos los clusters**.
- Cuanto **menor** sea el valor de SSW**, mayor es la cohesión del cluster,** porque los puntos están más cerca del centroide.
- **Indica** qué tan **compactos son los clusters**: valores bajos implican clusters más homogéneos.



Separación → distancia entre clusters

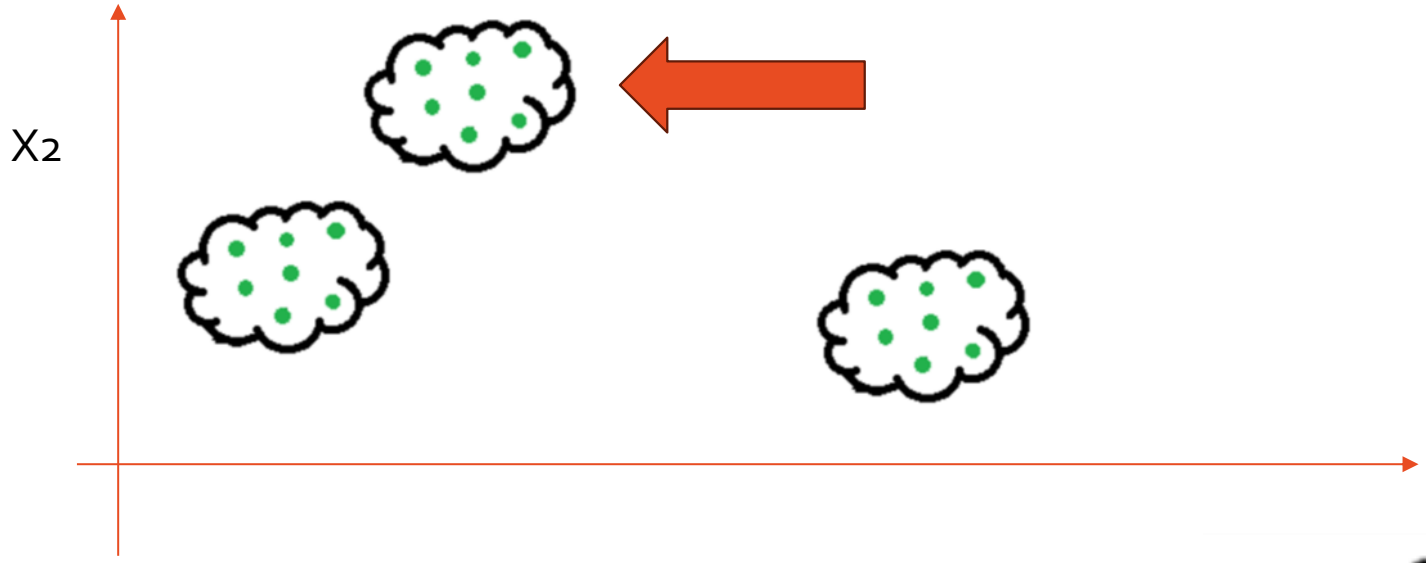
$$SSB = \sum_{j=1}^{k} n_j \; dist^2(m_j - \bar{x})$$

- k: número de clusters o grupos.
- n_j: cantidad de elementos en el cluster j.
- m_j: centroide (media) del cluster j.
- $\bar{x}$: media global de todos los datos.
- $\text{dist}^2(m_j - \bar{x})$: distancia al cuadrado entre el centroide del cluster y la media global.

Interpretación:
SSB mide la separación entre clusters: cuanto más alejados estén los centroides respecto a la media global, mayor será el valor.

Un **SSB alto indica que los clusters están bien separados** (buena discriminación).

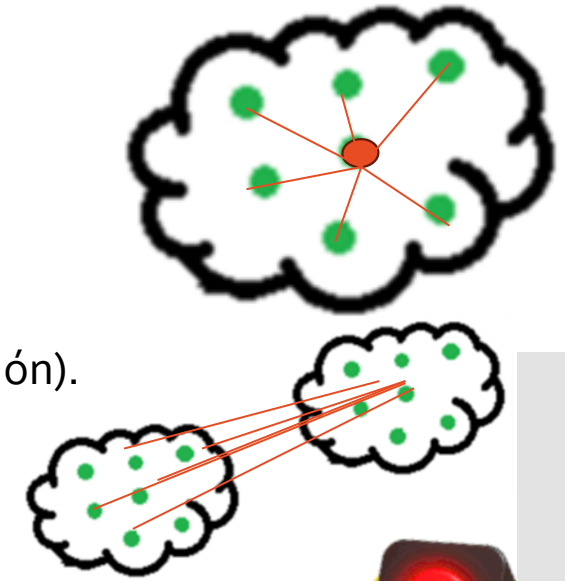
Indice de Silhouette



Para cada punto i :

a(x_i) = distancia promedio a los puntos del mismo cluster (cohesión).

b(x_i) = distancia promedio al cluster más cercano (separación).



El índice para el punto es:

$$S(x_i) = \frac{b(x_i) - a(x_i)}{\max\{b(x_i), a(x_i)\}}$$

$b(x_i) < a(x_i)$ $S(x_i) = \frac{b(x_i) - a(x_i)}{a(x_i)} < 0$ El punto podría estar en un cluster incorrecto

$b(x_i) \cong a(x_i)$ $S(x_i) \cong 0$ El punto esta en el limite entre 2 clusters

$b(x_i) > a(x_i)$ $S(x_i) = \frac{b(x_i) - a(x_i)}{b(x_i)} \cong 1$ El punto esta bien asignado al cluster

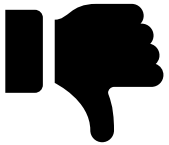


Indice de Silhouette Medida Global

$$SC = \frac{1}{N}\sum_{i=1}^{N} s(x_i)$$

SC >0,5 

0,25 < SC ≤ 0,5 

SC < 0,25 

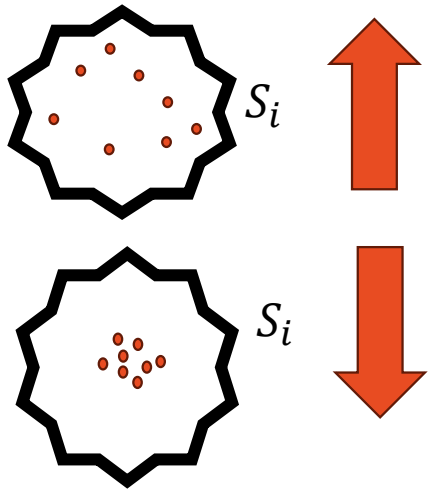
Indice Davies-Bouldin

Interpretación:
DB bajo (≈ 0.3 - 0.7) → Clusters bien definidos.DB alto (> 1.5) → Clusters poco separados o muy dispersos.

Compara a cada cluster con su vecino más cercano.

dispersión de cada cluster

$$S_i = \frac{1}{|C_i|} \sum_{x \in C_i} dist(x, m_i)$$

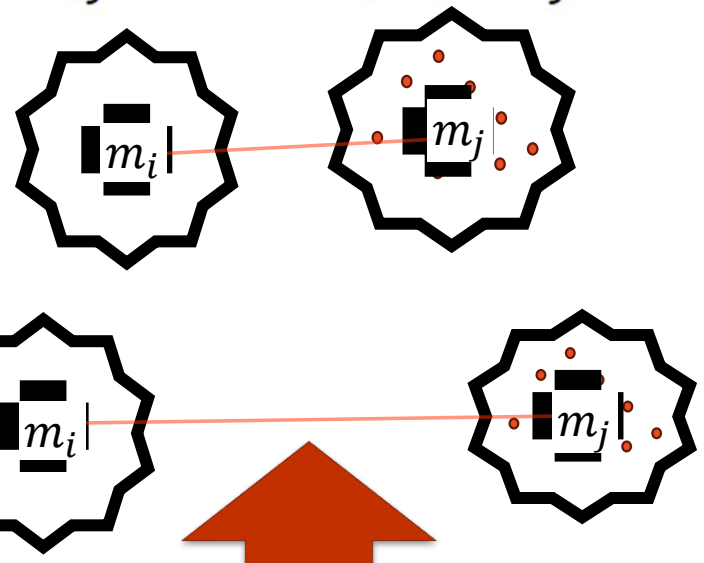


> dispersión

< dispersión

distancia entre clusters.

$$D_{ij} = dist(m_i, m_j)$$

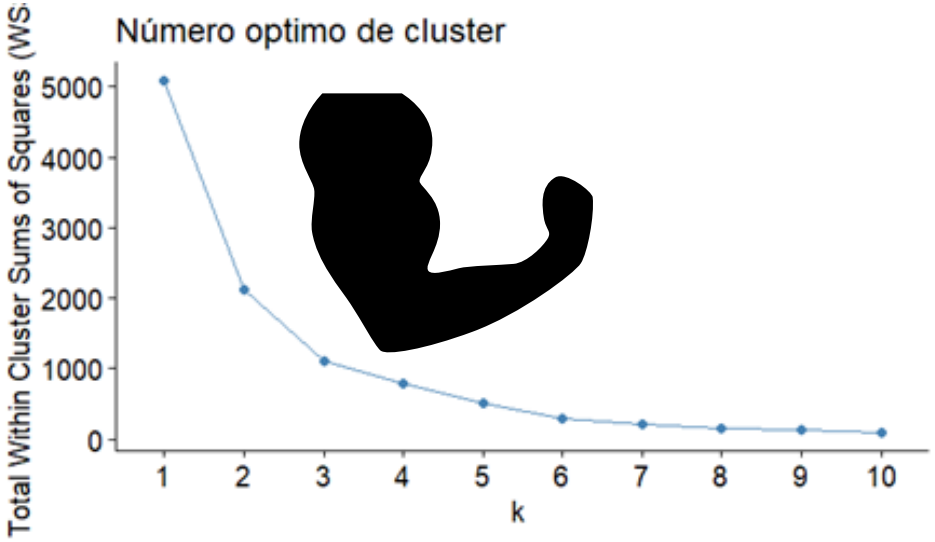


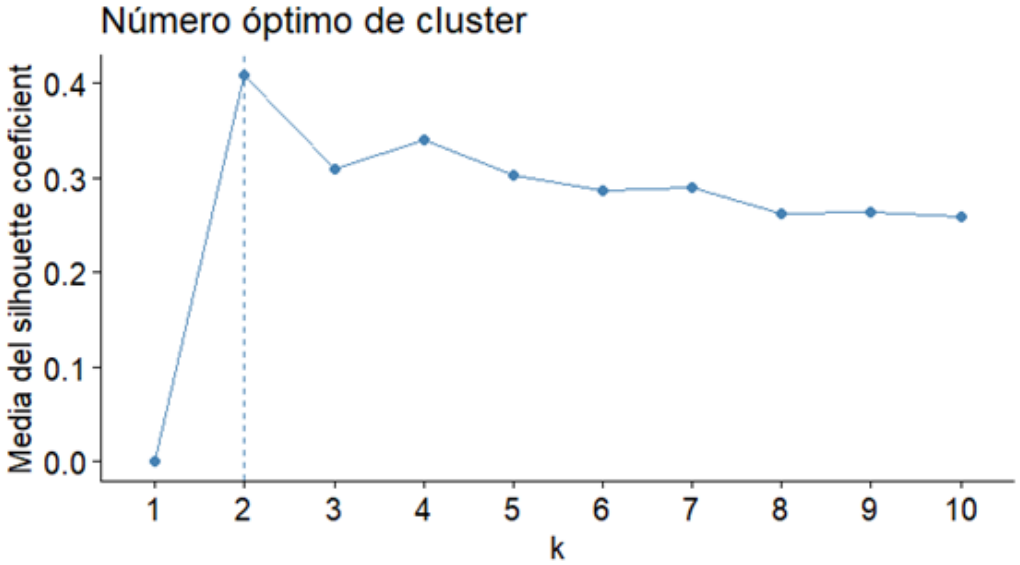
$$R_{ij} = \frac{S_i + S_j}{D_{ij}}$$

D_{ij} ↓ R_{ij} ↑

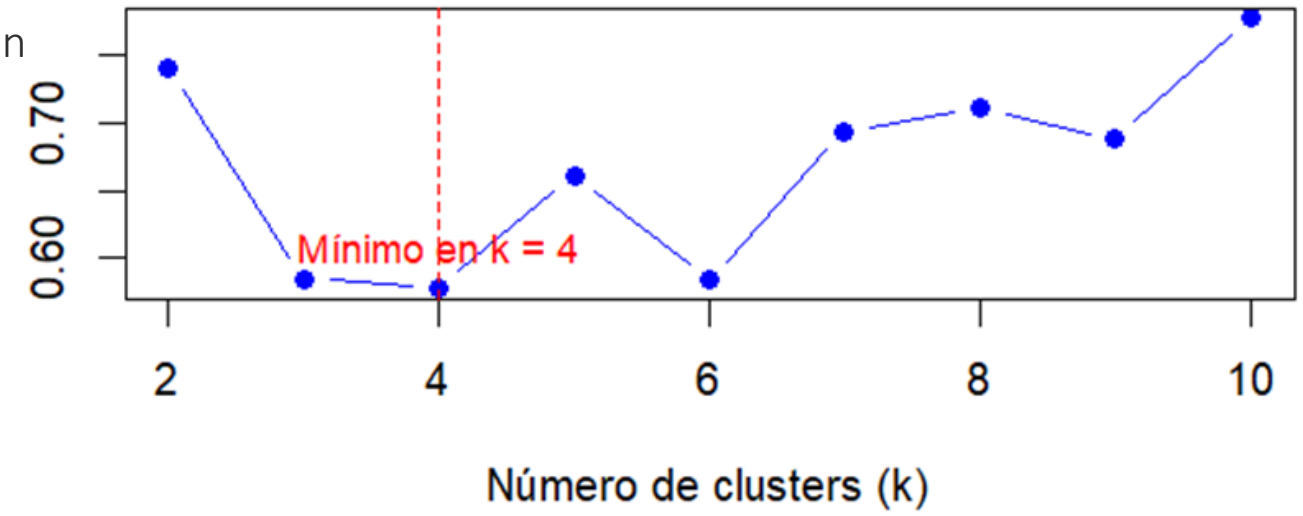
D_{ij} ↑ R_{ij} ↓

Más compactos y mas separados





Indice Davies-Bouldin



¿Cómo se construye un dendograma?

Ejemplo 10.5. Supongamos que disponemos de un conjunto de ocho objetos sobre los cuales se han observado las tres variables que figuran en la Tabla 10.11 y que se representan en la Figura 10.4.

Cluster	X_1	X_2	X_3
1	1	1	2
2	1	2	5
3	2	1	4
4	5	5	2
5	5	5	6
6	7	5	4
7	8	8	5
8	7	6	5

Tabla 10.11: Observaciones originales

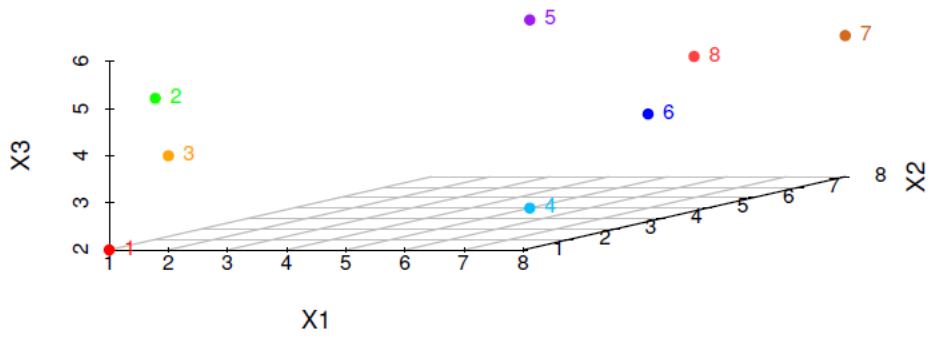


Figura 10.4: Representación de las observaciones originales

Todas las observaciones son un cluster

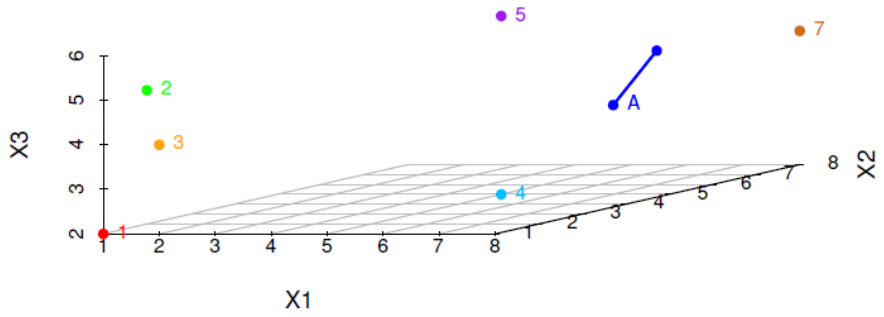


de estos datos consideramos la matriz de distancias euclíd
s, que está dada por la Tabla 10.12.

	1	2	3	4	5	6	7
2	3.16						
3	2.24	1.73					
4	5.66	5.83	5.39				
5	6.93	5.10	5.39	4.00			
6	7.48	6.78	6.40	2.83	2.83		
7	10.34	9.22	9.27	5.20	4.36	3.32	
8	8.37	7.21	7.14	3.74	2.45	1.41	2.24

Tabla 10.12: Distancias euclídeas: primer paso

Calculo de la matriz de distancias euclídeas



Para este ejemplo lo que haremos es tomar como representante del grupo al centroide de los puntos que forman el *cluster*; es decir, el vector medio de los elementos que constituyen el *cluster*. De este modo, las coordenadas de A resultan:

$$A = \left(\frac{7+7}{2}, \frac{5+6}{2}, \frac{4+5}{2}\right) = (7, 5.5, 4.5).$$

Figura 10.5: Representación del primer paso de clusterización

Cluster	X_1	X_2	X_3
A	7	5.5	4.5
1	1	1	2
2	1	2	5
3	2	1	4
4	5	5	2
5	5	5	6
7	8	8	5

Tabla 10.13: *Clusters* luego del prin

	A	1	2	3	4	5
1	7.91					
2	6.96	3.16				
3	6.75	2.24	1.73			
4	3.24	5.66	5.83	5.39		
5	2.55	6.93	5.10	5.39	4.00	
7	2.74	10.34	9.22	9.27	5.20	4.36

Tabla 10.14: Distancias euclídeas: segundo paso

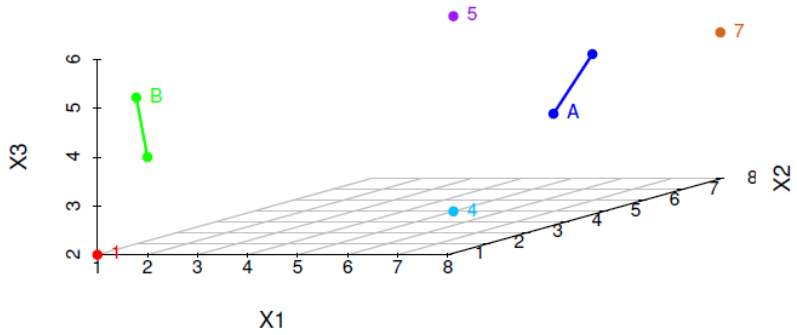


Figura 10.6: Representación del segundo paso de clusterización

B nuevo *cluster* es el punto $(1.5, 1.5, 4.5)$.

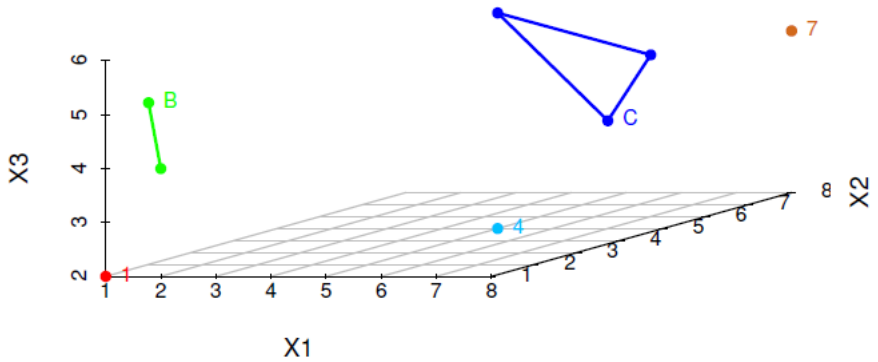
Cluster	X_1	X_2	X_3
A	7	5.5	4.5
B	1.5	1.5	4.5
1	1	1	2
4	5	5	2
5	5	5	6
7	8	8	5

Tabla 10.15: *Clusters* luego del segundo paso

Recalculando la matriz de distancias euclídeas para los nuevos elementos, obtenemos la Tabla 10.16.

	A	B	1	4	5
B	6.80				
1	7.91	2.60			
4	3.24	5.55	5.66		
5	2.55	5.17	6.93	4.00	
7	2.74	9.21	10.34	5.20	4.36

Tabla 10.16: Distancias euclídeas: tercer paso



C=$(6.\widehat{3}, 5.\widehat{3}, 5)$.

Cluster	X_1	X_2	X_3
B	1.5	1.5	4.5
C	$6.\widehat{3}$	$5.\widehat{3}$	5
1	1	1	2
4	5	5	2
7	8	8	5

Tabla 10.17: *Clusters* luego del tercer paso

	B	C	**1**	**4**
C	6.19			
1	2.60	7.50		
4	5.55	3.30	5.66	
7	9.21	3.14	10.34	5.20

Tabla 10.18: Distancias euclídeas: cuarto paso

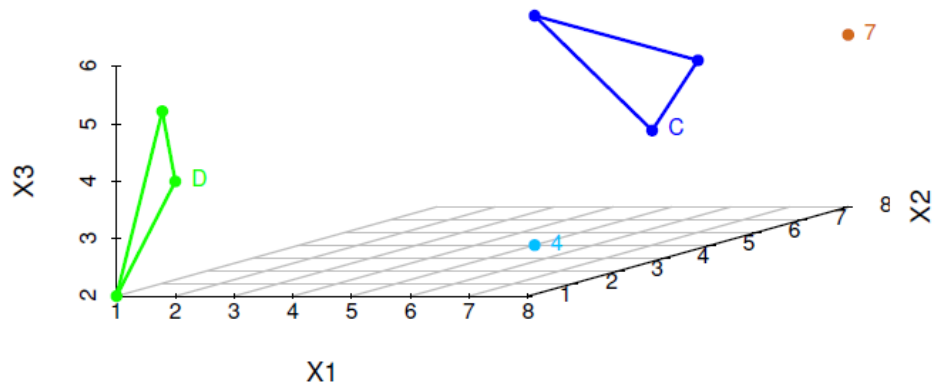


Figura 10.8: Representación del cuarto paso de clusterización

Ahora vemos que la distancia más pequeña es 2.60, por lo que agrupamos en el *cluster* D los objetos B y 1, con centroide $(1.\widehat{3}, 1.\widehat{3}, 3.\widehat{6})$, obteniendo la representación dada por la Figura 10.8, los *clusters* de la Tabla 10.19 y las distancias de la Tabla 10.20.

Cluster	X_1	X_2	X_3
C	$6.\widehat{3}$	$5.\widehat{3}$	5
D	$1.\widehat{3}$	$1.\widehat{3}$	$3.\widehat{6}$
4	5	5	2
7	8	8	5

Tabla 10.19: *Clusters* luego del cuarto paso

	C	D	4
D	6.54		
4	3.30	5.45	
7	3.14	9.52	5.20

Tabla 10.20: Distancias euclídeas: quinto paso

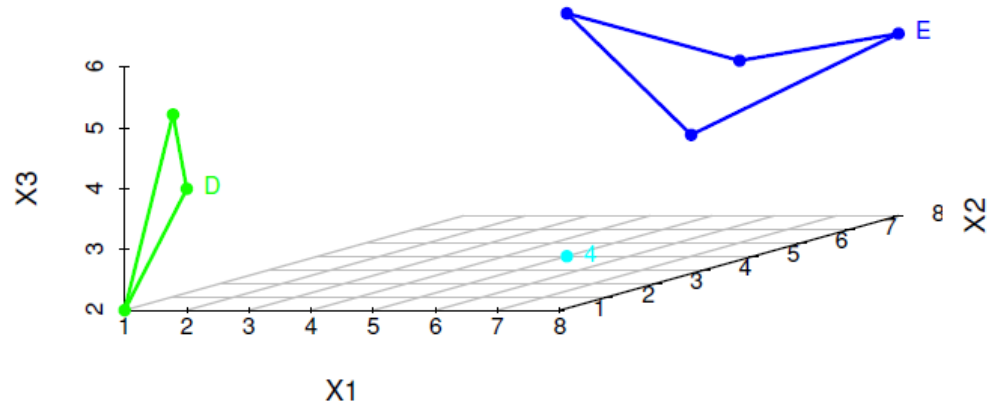


Figura 10.9: Representación del quinto paso de clusterización

Debido a que la mínima distancia es de 3.14 y se realiza entre los *clusters* C y 7, los agrupamos en un nuevo *cluster* llamado E tal como se muestra en la Figura 10.9.

Cluster	X_1	X_2	X_3
D	$1.\widehat{3}$	$1.\widehat{3}$	$3.\widehat{6}$
E	6.75	6	5
4	5	5	2

Tabla 10.21: *Clusters* luego del quinto paso

Las nuevas distancias se muestran en la Tabla 10.22. Siendo la menor, 3.61. Agrupamos en el *cluster* F a los elementos E y 4, como se muestra en la Figura 10.10.

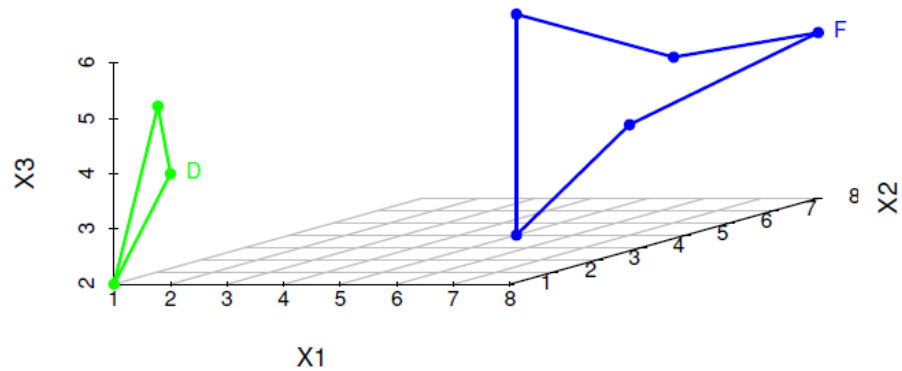


Figura 10.10: Representación del sexto paso de clusterización

	D	E
E	7.27	
4	5.45	3.61

Tabla 10.22: Distancias euclídeas: sexto paso

Si dos observaciones se unen a nivel 2, significa que su distancia (o disimilitud) es 2.
Si dos clusters se unen a nivel 20, significa que son mucho más diferentes (distancia = 20).
Las líneas horizontales indican el nivel de corte para decidir cuántos clusters formar:Por ejemplo, si cortás en 12 (línea roja), obtendrás 3 clusters.Si cortás en 8 (línea gris), obtendrás 4 clusters.En resumen:El ejeY indica la altura a la que se fusionan los clusters, que corresponde a la distancia entre ellos según la métrica elegida.

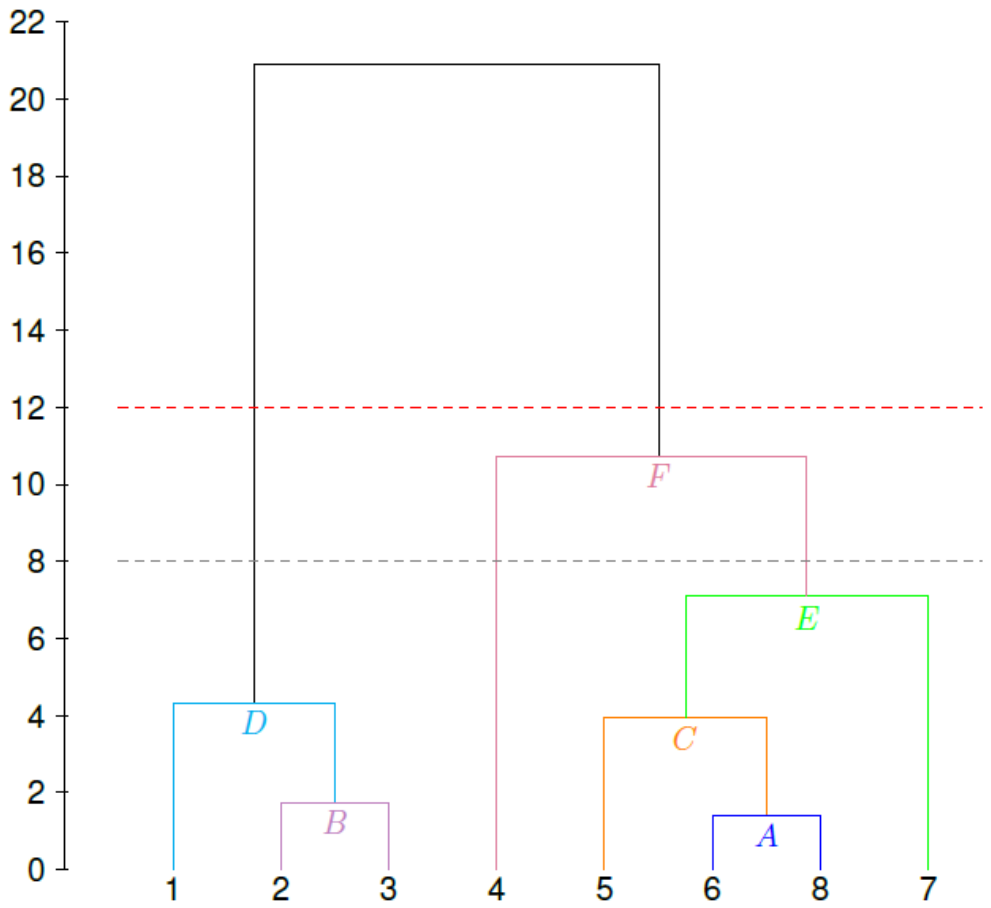


Figura 10.12: Dendograma con elección de cantidad de *clusters*

De esta manera nos han quedado solamente los dos *clusters* de la Tabla 10.21 con distancia 10.3 y que se fusionarán en el paso siguiente terminando de este modo el proceso.

Cluster	X_1	X_2	X_3
D	$1.\widehat{3}$	$1.\widehat{3}$	$3.\widehat{6}$
F	8	7.25	5.5

Tabla 10.23: *Clusters* luego del quinto paso

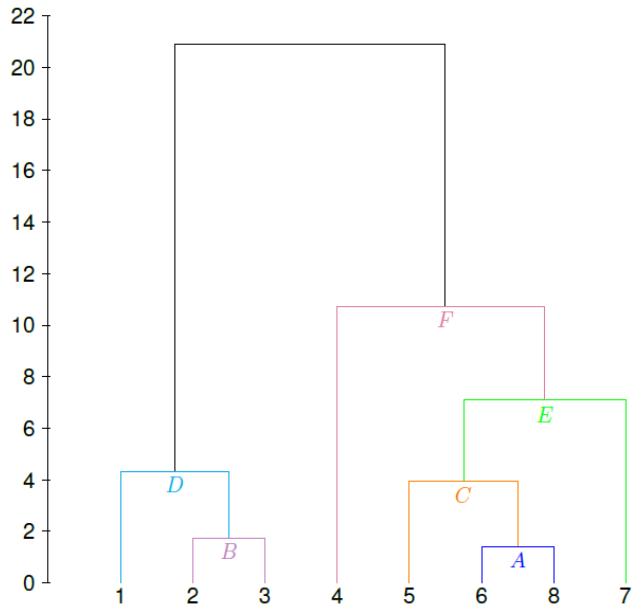


Figura 10.11: Dendograma

El proceso completo de fusiones se resume en el dendograma de la Figura10.11.



Gracias

mlvranic@gmail.com