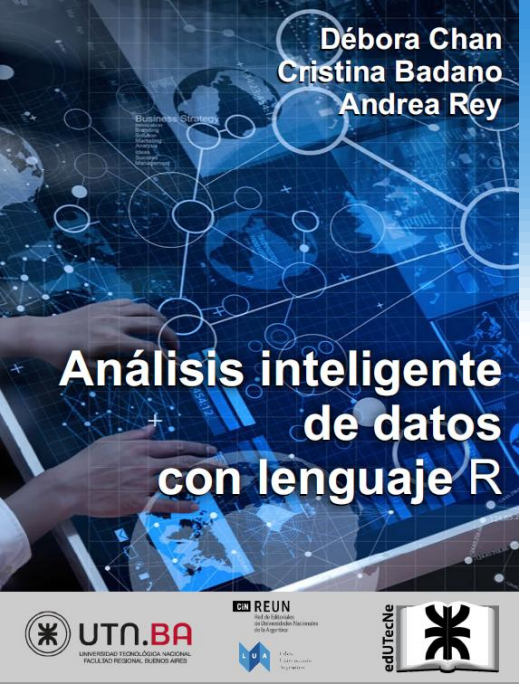
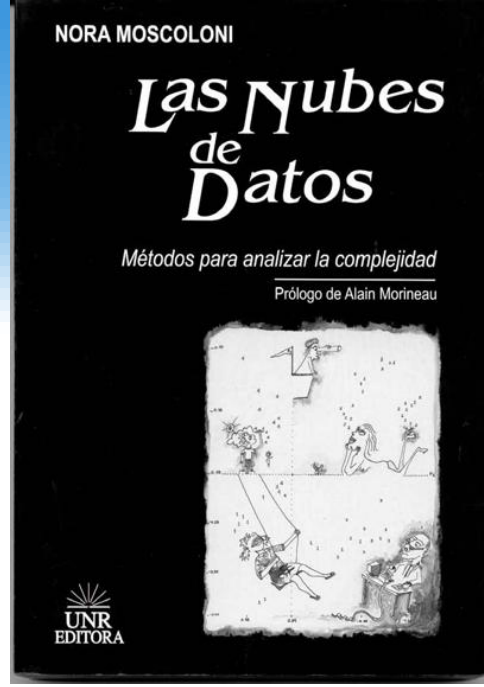


ANALISIS DE CORRESPONDENCIAS

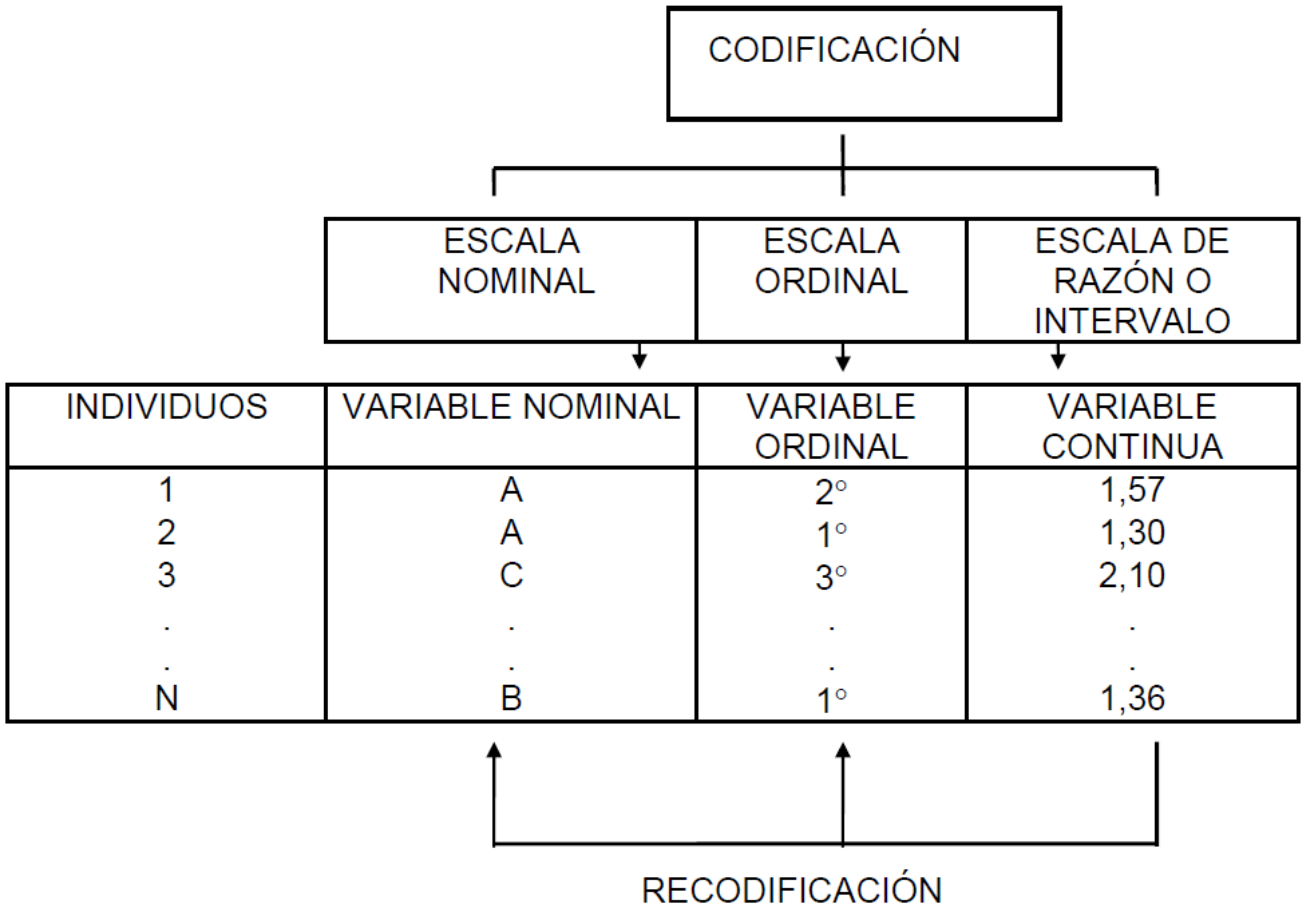


Fuentes:

Chan, Débora, Badano, Cristina Inés, Rey, Andrea Alejandra. (2020).Análisis inteligente de datos con lenguaje R: con aplicaciones a imágenes. HTTP://HDL.HANDLE.NET/20.500.12272/4371

Moscoloni N. "Las nubes de datos. Métodos para analizar la complejidad", UNR editora, rosario, 2005; 253 pags. Isbn 950-673-485-2. Https://rephip.Unr.Edu.Ar/items/b6bcffda-e2d2-4583-ab66-74d70fc7cc7c

Greenacre, M. J. (1984). *Correspondence analysis*. Academic press.



Tipos de recodificaciones

Hogares	Número de miembros	Ingreso per capita	Sexo del jefe	Escolaridad del jefe
1	8	120	Masculino	1
2	2	700	Masculino	2
3	4	400	Femenino	3

1. niños (de 0 a 12 años)
2. jóvenes (de 13 a 19 años)
3. adultos (de 20 a 69 años)
4. edad avanzada (más de 70 años)

CODIFICACIÓN

EDAD-ESCOLARIDAD	EDAD ORDINAL	ESCOLARIDAD
1	1 y 2	1 ó 2 ó 3
2	3	1 ó 2
3	3	3
4	4	1 ó 2
5	4	3

1. niños y jóvenes
2. adultos, sin escolaridad o escolaridad primaria
3. adultos, escolaridad media o superior
4. edad avanzada, sin escolaridad o primaria
5. edad avanzada, escolaridad media o superior

TABLA DE CONTINGENCIA RESUME 2 VARIABLES

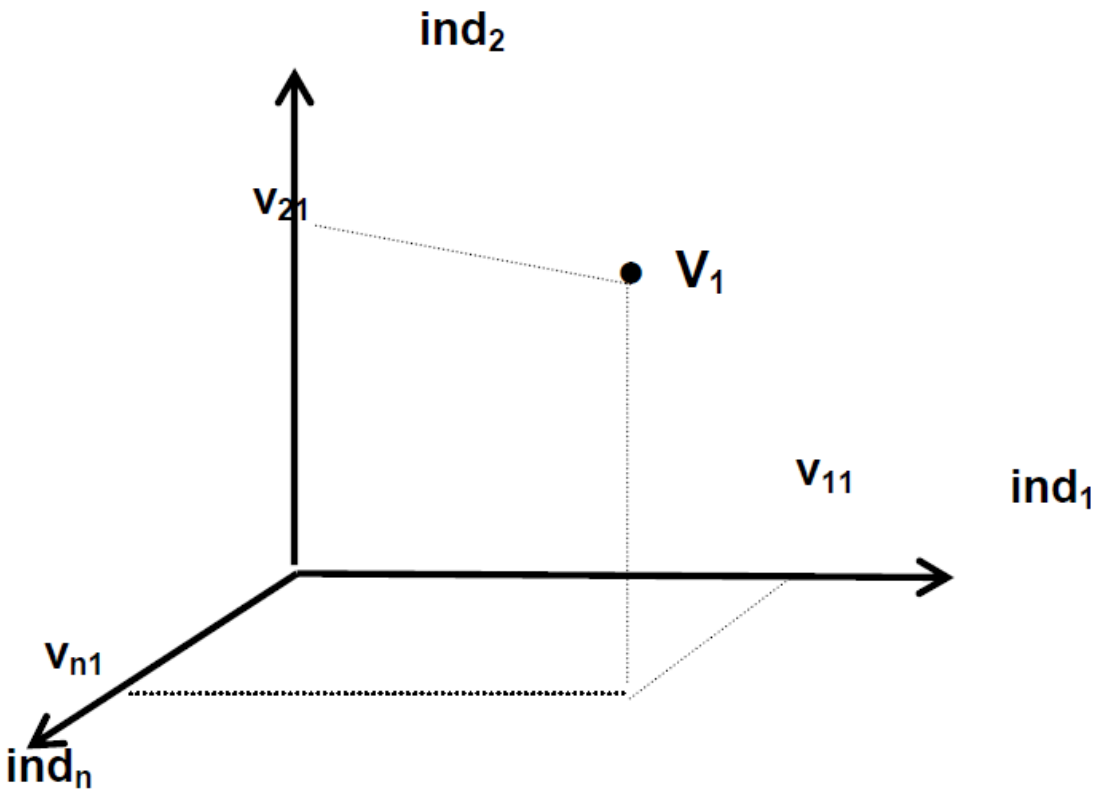
UA	V_1	V_2	…	V_p
ind_1	v_{11}	v_{12}		v_{1p}
ind_2	v_{21}	v_{22}		v_{2p}
…				
ind_n	v_{n1}	v_{n2}		v_{np}

Consumo de cigarrillos	Varones	Mujeres
Ninguno	48	55
menos de 5	24	31
entre 5 y 10	14	10
más de 10	5	6

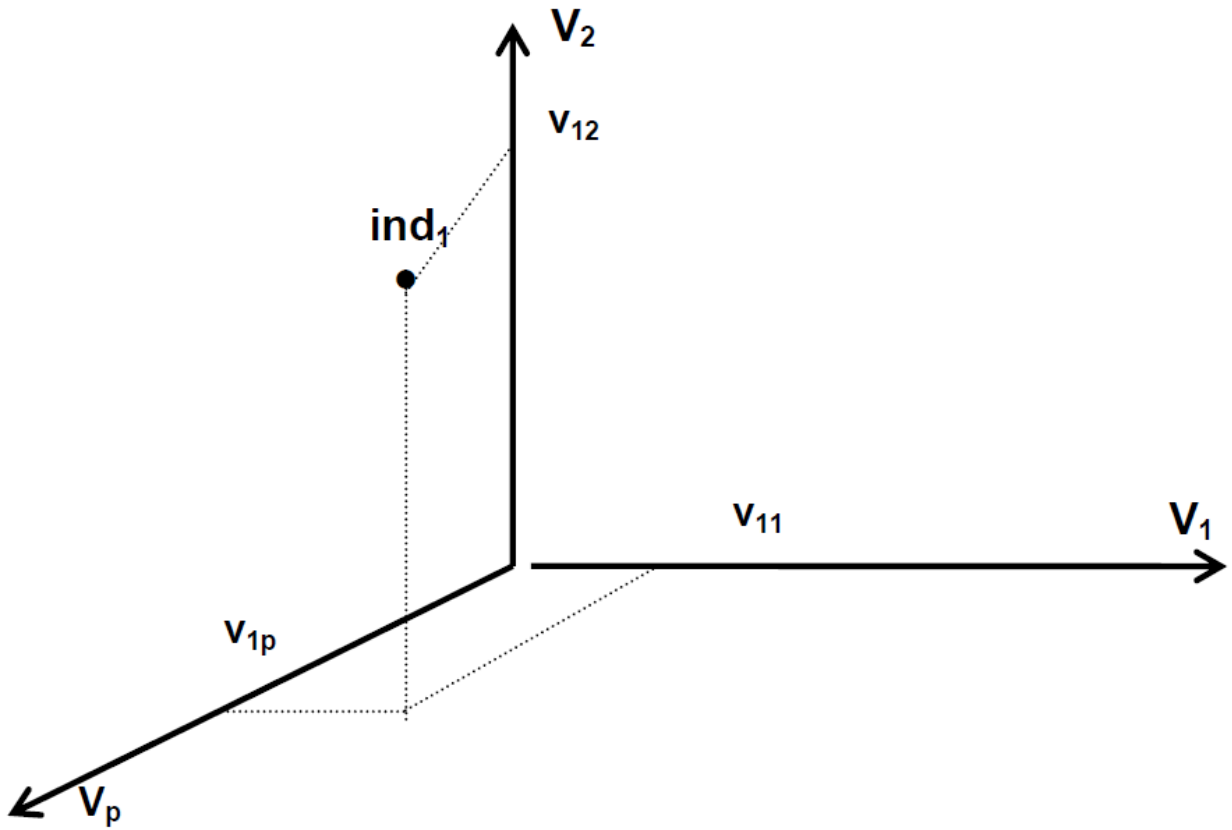
Descripción gráfica de la población: la proximidad entre individuos es función de la semejanza de las respuestas a las variables activas.

DOS ESPACIOS DE INDIVIDUOS Y VARIABLES

Espacio de los individuos: R^n

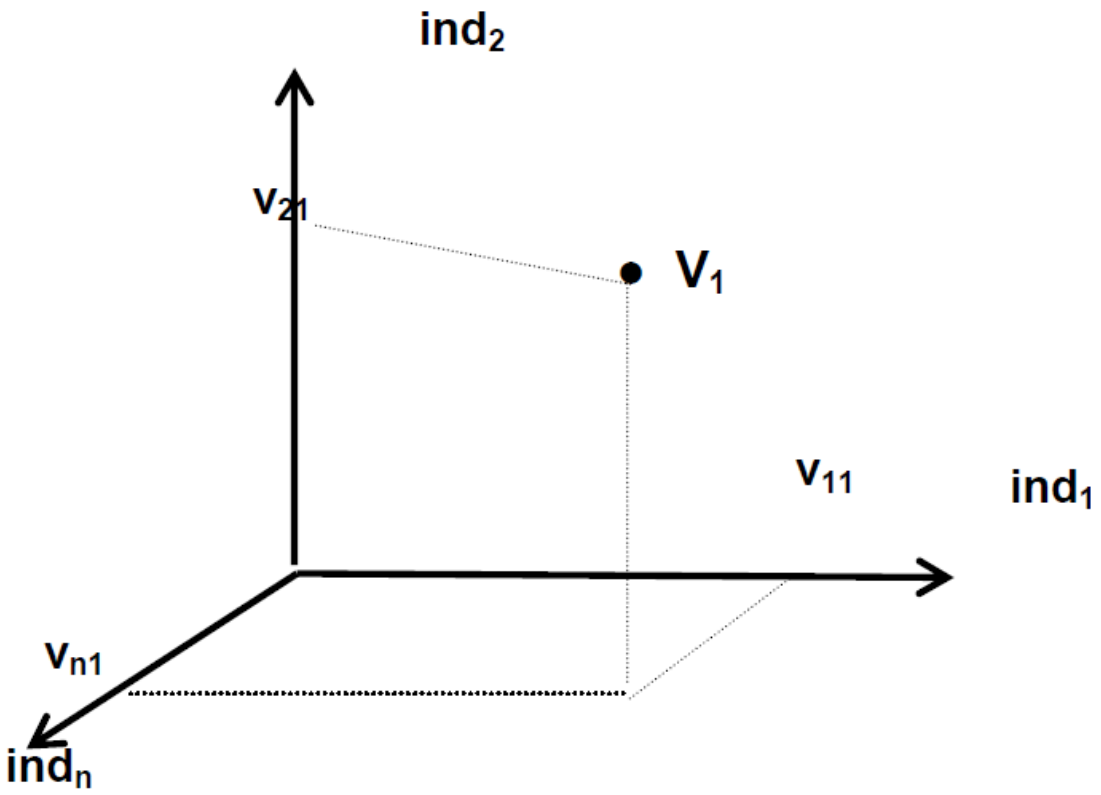


Espacio de las variables: R_p

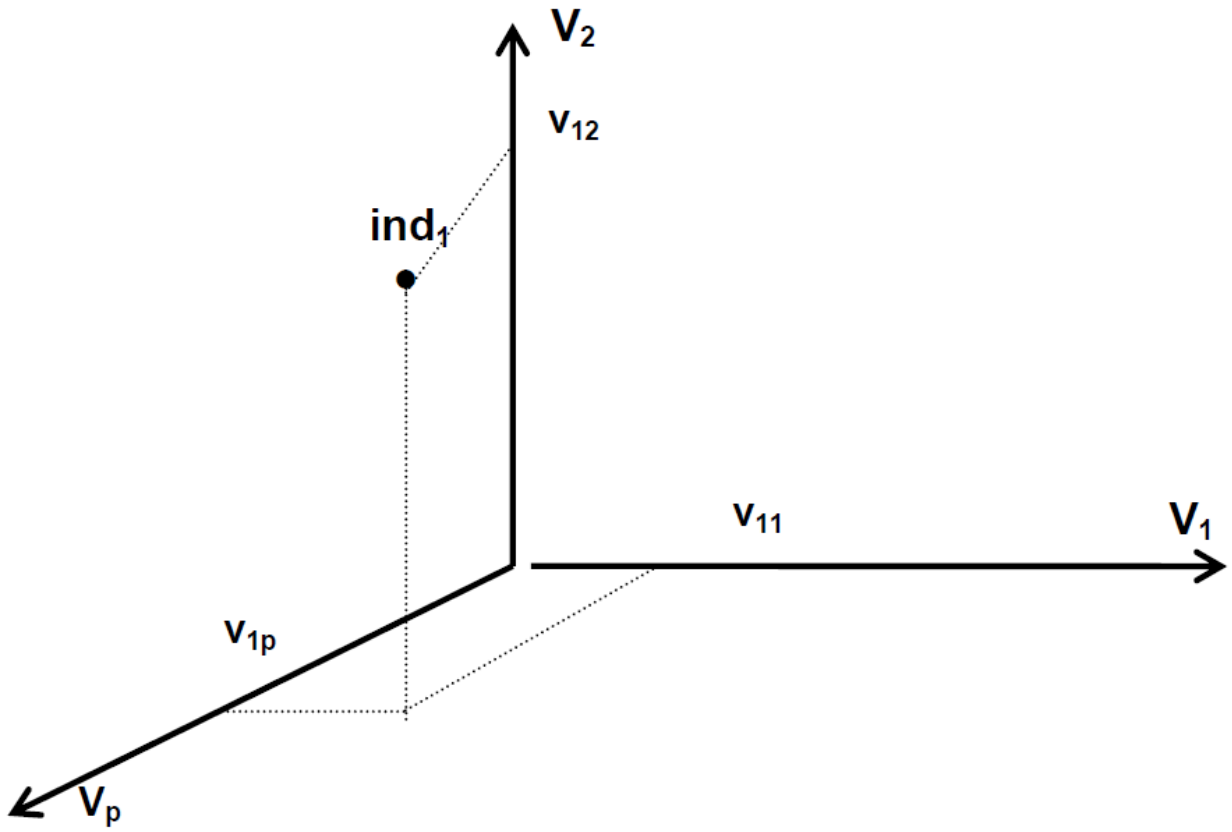


2 ESPACIOS DE INDIVIDUOS Y VARIABLES

Espacio de los individuos: R^n

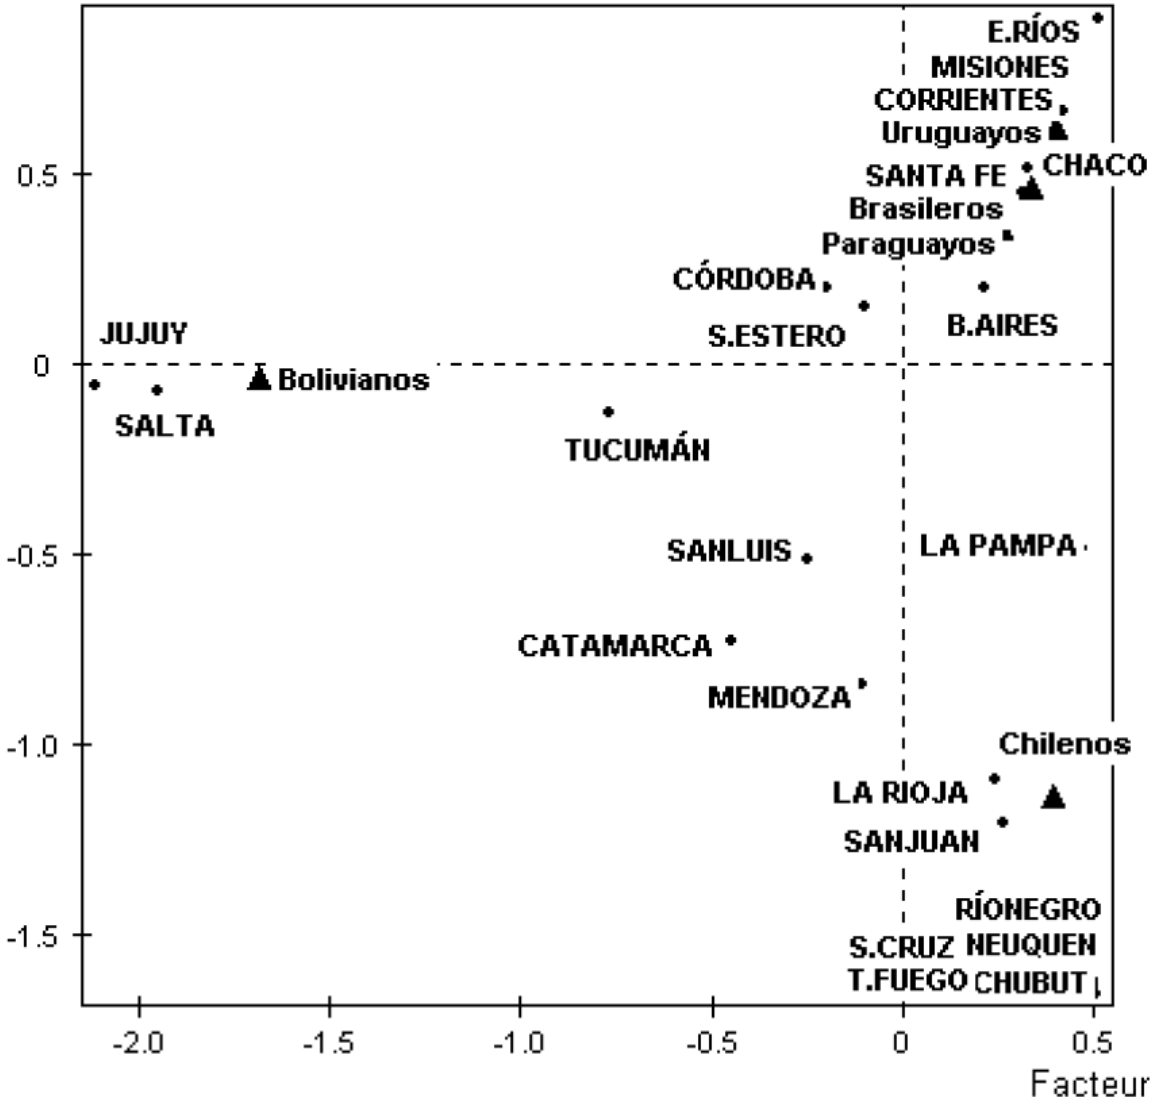


Espacio de las variables: R_p



CERCANIA POR SEMEJANZA: VARIABLES - INDIVIDUOS

Provincias	Bolivianos	Brasileros	Chilenos	Paraguayos	Uruguayos	Total
Buenos Aires	27544	33019	59912	117476	91856	329807
Catamarca	100	9	141	14	21	285
Córdoba	1814	2234	1014	756	1453	7271
Corrientes	14	1588	73	3638	1153	6466
Chaco	80	261	149	13570	433	14493
Entre Ríos	54	613	134	515	46672	47988
Chubut	54	42	16080	98	174	16448
Jujuy	40978	48	413	618	37	42094
La Pampa	15	155	714	45	440	1369
La Rioja	28	23	217	14	17	299
Mendoza	3622	2546	9476	259	416	16319
Misiones	116	21106	149	618	37	22026
Neuquén	34	36	11040	36	61	11207
Río Negro	86	136	22453	83	169	22927
Salta	27505	99	1036	1579	86	30305
San Juan	450	559	4037	66	91	5203
San Luis	134	49	209	30	64	486
Santa Cruz	96	21	16122	54	128	16421
Santa Fe	414	3387	800	2469	2013	9083
S.del Estero	88	105	72	64	89	418
T. del Fuego	0	3	3223	9	7	3242
Tucumán	1101	344	471	306	163	2385
Total	104327	66383	147935	142317	145580	606542



2 ESPACIOS DE INDIVIDUOS Y VARIABLES

Espacio individuos: R^{22} (provincias)

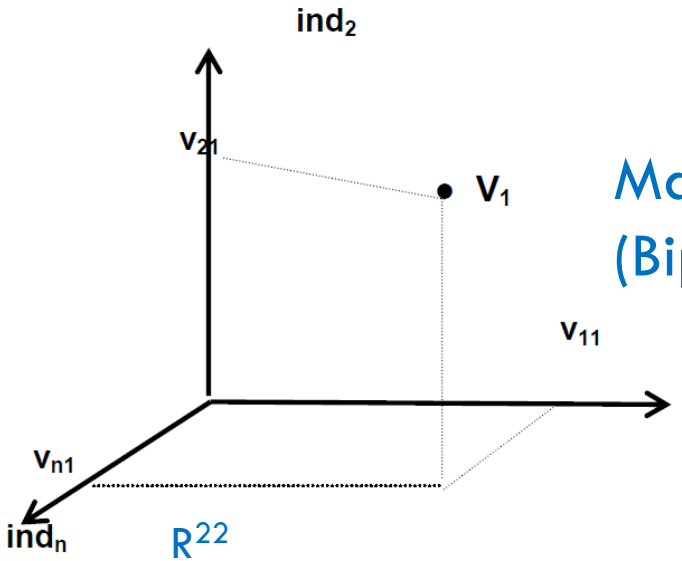
Espacio variables: R^5 (nacionalidades)

Proyección en:

Mapa Perceptual → R^2 (2 dimensiones)

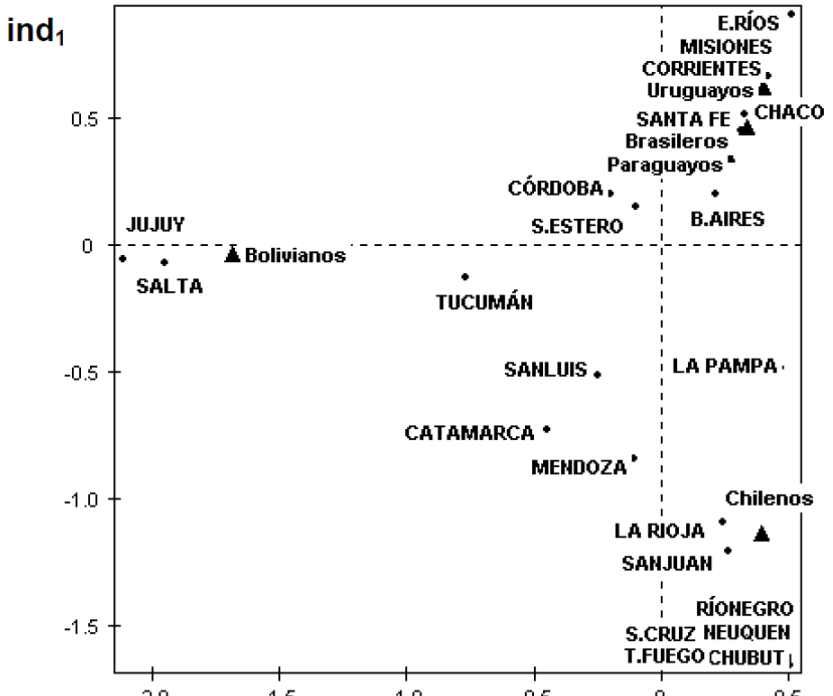
(Biplot: Variables e Individuos)

Espacio de los individuos: R^n

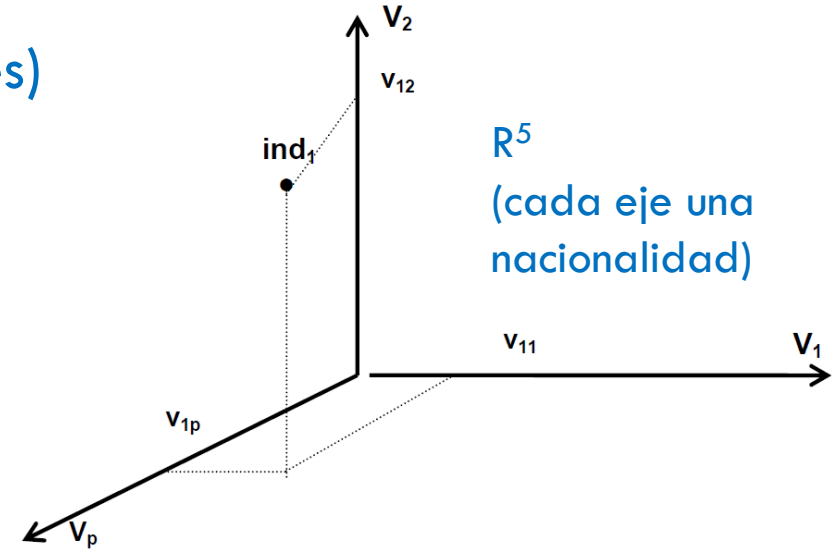


R^{22}

(cada eje una provincia)



Espacio de las variables: R_p



R^5

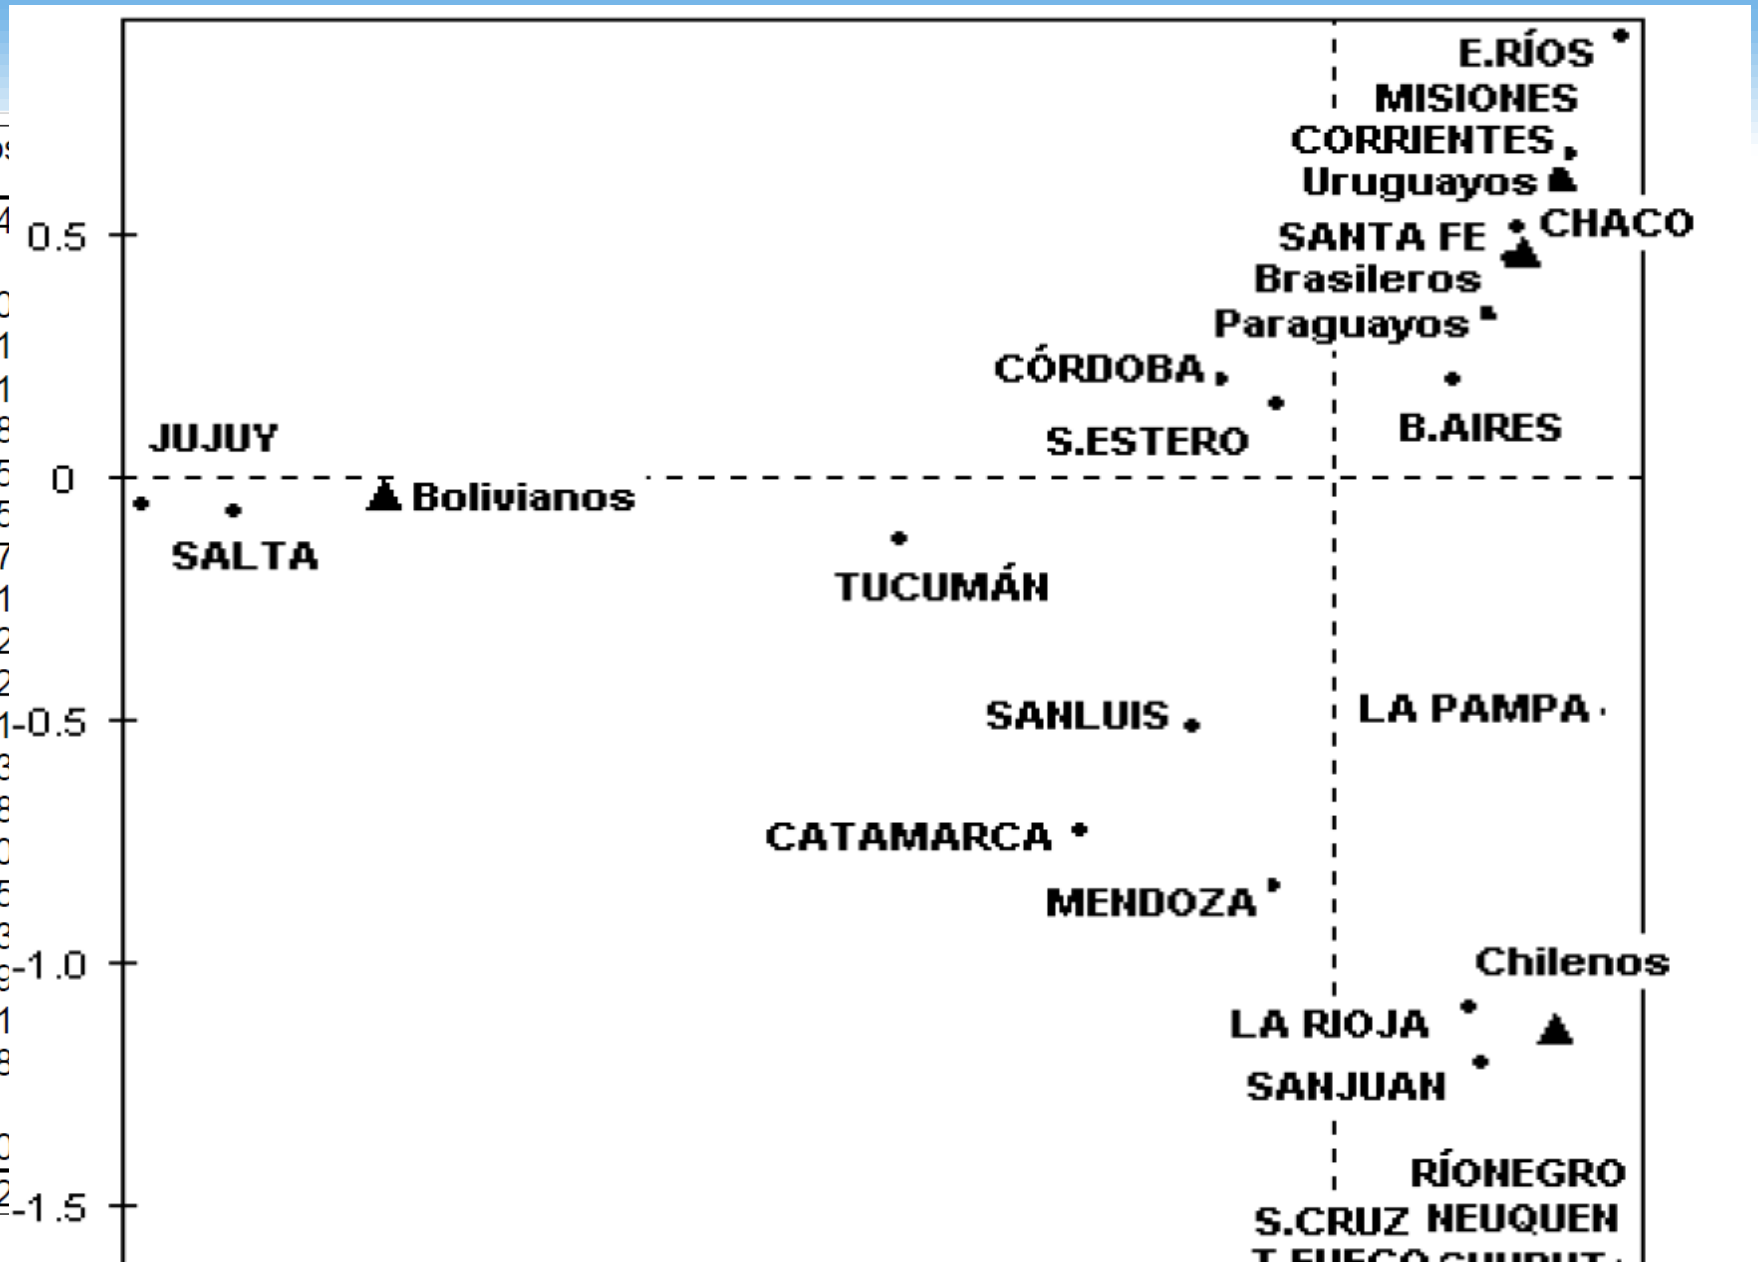
(cada eje una nacionalidad)

$$\Phi_i = \beta \sum_{j=1..p} (f_{ij} / f_{i.}) \Psi_j$$

$$\Psi_j = \beta \sum_{i=1...n} (f_{ij} / f_{j.}) \Phi_i$$

CERCANIA POR SEMEJANZA: VARIABLES - INDIVIDUOS

Provincias	Bolivianos
Buenos Aires	2754
Catamarca	10
Córdoba	181
Corrientes	1
Chaco	8
Entre Ríos	5
Chubut	5
Jujuy	4097
La Pampa	1
La Rioja	2
Mendoza	362
Misiones	11
Neuquén	3
Río Negro	8
Salta	2750
San Juan	45
San Luis	13
Santa Cruz	9
Santa Fe	41
S.del Estero	8
T. del Fuego	
Tucumán	110
Total	10432



INERCIA: IMPORTANTE

En las situaciones 2 y 4, las nubes tienen tasas de inercia idénticas pero una inercia total diferente. Por otro lado, las situaciones 3 y 4 revelan dos nubes de la misma inercia total y tasas de inercia diferentes.

El test de Chi cuadrado permite detectar estas dos últimas situaciones, pero no permite poner en evidencia la situación 2
En síntesis, la inercia de un factor mide la asociación que el mismo pone en evidencia y ella no puede ser superior a 1. Un

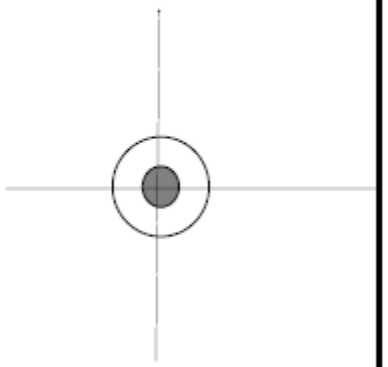
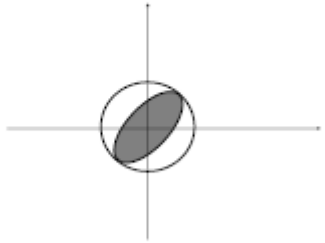
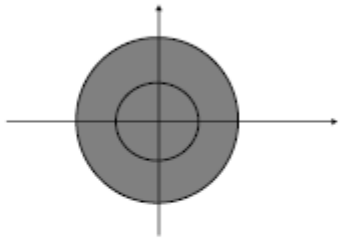
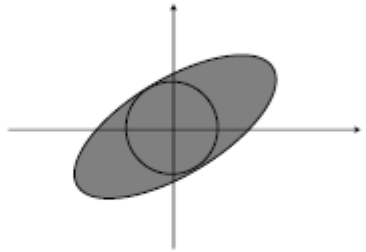
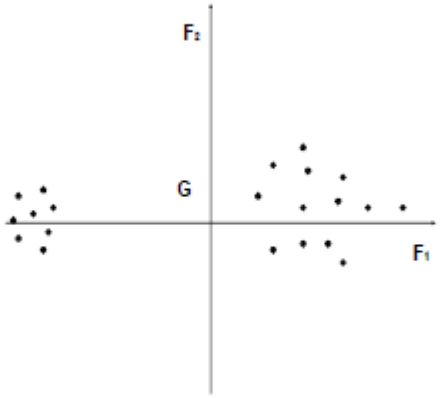
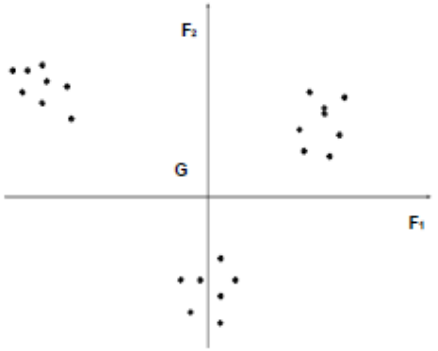
Nube		Direcciones Tasas de inercia de los ejes Forma "esférica"	Forma "no esférica"
Inercia	Inercia débil	 1.- INDEPENDENCIA Débil inercia total No hay dirección privilegiada	 2.- DEPENDENCIA Débil inercia total Dirección privilegiada
	Inercia fuerte	 3.- DEPENDENCIA Fuerte inercia total No hay dirección privilegiada	 4.- DEPENDENCIA Fuerte inercia total Dirección privilegiada

Diagrama tomado de Lebart , Morineau, Piron (1995)

EJEMPLOS DE NUBES



	J_1	J_2
I_1		0
I_2	0	

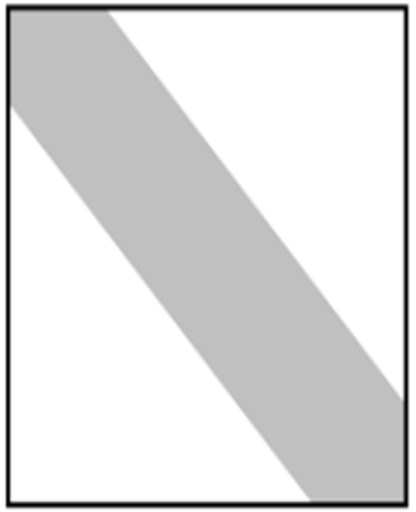


	J_1	J_2	J_3
I_1		0	0
I_2	0		0
I_3	0	0	

Efecto Guttman:

Cuando la nube de puntos presenta una forma de parábola se dice que posee el efecto Guttman. La matriz correspondiente presenta una diagonal principal relativamente cargada.





CORRESPONDENCIAS MULTIPLES→ MATRIZ DIJUNTIVA (0-1)

Provincias	Bolivianos	Brasileros	Chilenos	Paraguayos
Buenos Aires	27544	33019	59912	11747(
Catamarca	100	9	141	1
Córdoba	1814	2234	1014	75(
Corrientes	14	1588	73	363
Chaco	80	261	149	1357(
Entre Ríos	54	613	134	51
Chubut	54	42	16080	9
Jujuy	40978	48	413	61
La Pampa	15	155	714	4
La Rioja	28	23	217	1
Mendoza	3622	2546	9476	25
Misiones	116	21106	149	61
Neuquén	34	36	11040	3(
Río Negro	86	136	22453	8
Salta	27505	99	1036	157
San Juan	450	559	4037	6(
San Luis	134	49	209	3(
Santa Cruz	96	21	16122	5
Santa Fe	414	3387	800	246
S.del Estero	88	105	72	6
T. del Fuego	0	3	3223	
Tucumán	1101	344	471	30(
Total	104327	66383	147935	14231

22 provincias

BsAs		Tucumán
1	0	...
1	0	0
...	.	...
	.	
1	0	0
1	0	0
...	.	...
	.	
...	.	...
	.	
0	0	1
0	0	1
...	.	...
	.	
...	.	...
	.	
...	.	...
	.	

5 nacionalidades

Bolivia	Brasil	Chile	Paraguay	Uruguay
1	0	0	0	0
1	0	0	0	0
...	...	...	...	...
0	1	0	0	0
0	1	0	0	0
...	...	...	...	...
...	...	...	...	...
0	0	0	0	1
0	0	0	0	1
...	...	...	...	...
...	...	...	...	...
...	...	...	...	...

27544 filas iguales

33019 filas iguales

...

163 filas iguales

606542 filas en total

CORRESPONDENCIAS MULTIPLES

- Tabla Individuos y Variables
- Matriz Disjuntiva (0-1)

s = 3 p = 9

R (n,s)

V1	V2	V3
2	2	4
2	1	3
3	1	2
1	2	4
1	2	3
2	2	3
3	1	1
1	1	1
2	1	2
2	2	3
3	2	2
1	1	4

⇒ Z= (n,p)

V1			V2		V3			
M1	M2	M3	M1	M2	M1	M2	M3	M4
0	1	0	0	1	0	0	0	1
0	1	0	1	0	0	0	1	0
0	0	1	1	0	0	1	0	0
1	0	0	0	1	0	0	0	1
1	0	0	0	1	0	0	1	0
0	1	0	0	1	0	0	1	0
0	0	1	1	0	1	0	0	0
1	0	0	1	0	1	0	0	0
0	1	0	1	0	0	1	0	0
0	1	0	0	1	0	0	1	0
0	0	1	0	1	0	1	0	0
1	0	0	1	0	0	0	0	1

- Matriz de Burt → cruza modalidades

B (p,p)

		V1			V2		V3			
		M1	M2	M3	M1	M2	M1	M2	M3	M4
V1	M1	4	0	0	2	2	1	0	1	2
	M2	0	5	0	2	3	0	1	3	1
	M3	0	0	3	2	1	1	2	0	0
V2	M1	2	2	2	6	0	2	2	1	1
	M2	2	3	1	0	6	0	1	3	2
V3	M1	1	0	1	2	0	2	0	0	0
	M2	0	1	2	2	1	0	3	0	0
	M3	1	3	0	1	3	0	0	4	0
	M4	2	1	0	1	2	0	0	0	3

DISTANCIA CHI2

- Distancia entre fila i y fila i´
- Suma para todas las columnas la *fi.*=suma para todos los *j y pondera por la inversa*

distancia sería:

$$d^2(i, i') = \sum_{j=1..p} \left(f_{ij} / f_{i.} - f_{i'j} / f_{i'.} \right)^2$$

Sin embargo esta distancia favorece las columnas que tienen una masa $f_{.j}$ importante, es decir los países con frecuencias más altas, por lo tanto para atenuar este efecto, se la pondera con la inversa del total de columna.

$$\Phi_i = \beta \sum_{j=1..p} (f_{ij} / f_{i.}) \Psi_j$$

$$\Psi_j = \beta \sum_{i=1...n} (f_{ij} / f_{j.}) \Phi_i$$

PERFILES FILAS Y COLUMNAS

MIGRANTES DE PAÍSES LIMÍTROFES: PERFILES FILAS

Provincias	Bolivianos	Brasileros	Chilenos	Paraguayos	Uruguayos	Total
Buenos Aires	8,35	10,01	18,17	35,62	27,85	100,00
Catamarca	35,09	3,16	49,47	4,91	7,37	100,00
Córdoba	24,95	30,72	13,95	10,40	19,98	100,00
Corrientes	0,22	24,56	1,13	56,26	17,83	100,00
Chaco	0,55	1,80	1,03	93,63	2,99	100,00
Entre Ríos	0,11	1,28	0,28	1,07	97,26	100,00
Chubut	0,33	0,26	97,76	0,60	1,06	100,00
Jujuy	97,35	0,11	0,98	1,47	0,09	100,00
La Pampa	1,10	11,32	52,15	3,29	32,14	100,00
La Rioja	9,36	7,69	72,58	4,68	5,69	100,00
Mendoza	22,19	15,60	58,07	1,59	2,55	100,00
Misiones	0,53	95,82	0,68	2,81	0,17	100,00
Neuquén	0,30	0,32	98,51	0,32	0,54	100,00
Río Negro	0,38	0,59	97,93	0,36	0,74	100,00
Salta	90,76	0,33	3,42	5,21	0,28	100,00
San Juan	8,65	10,74	77,59	1,27	1,75	100,00
San Lui						
Santa C						
Santa F						
S.del Es						
T. del F						
Tucumá						
Total						

MIGRANTES DE PAÍSES LIMÍTROFES: PERFILES COLUMNAS

Provincias	Bolivianos	Brasileros	Chilenos	Paraguayos	Uruguayos	Total
Buenos Aires	26,40	49,74	40,50	82,55	63,10	54,37
Catamarca	0,10	0,01	0,10	0,01	0,01	0,05
Córdoba	1,74	3,37	0,69	0,53	1,00	1,20
Corrientes	0,01	2,39	0,05	2,56	0,79	1,07
Chaco	0,08	0,39	0,10	9,54	0,30	2,39
Entre Ríos	0,05	0,92	0,09	0,36	32,06	7,91
Chubut	0,05	0,06	10,87	0,07	0,12	2,71
Jujuy	39,28	0,07	0,28	0,43	0,03	6,94
La Pampa	0,01	0,23	0,48	0,03	0,30	0,23
La Rioja	0,03	0,03	0,15	0,01	0,01	0,05
Mendoza	3,47	3,84	6,41	0,18	0,29	2,69
Misiones	0,11	31,79	0,10	0,43	0,03	3,63
Neuquén	0,03	0,05	7,46	0,03	0,04	1,85
Río Negro	0,08	0,20	15,18	0,06	0,12	3,78
Salta	26,36	0,15	0,70	1,11	0,06	5,00
San Juan	0,43	0,84	2,73	0,05	0,06	0,86
	0,13	0,07	0,14	0,02	0,04	0,08
	0,09	0,03	10,90	0,04	0,09	2,71
	0,40	5,10	0,54	1,73	1,38	1,50
	0,08	0,16	0,05	0,04	0,06	0,07
					0.00	0,53
					0,11	0,39
					100,00	100,00

La distancia entre dos puntos - fila i e i'estará dada por:

$$d^2 (i , i') = \sum_{j=1..p} 1/f_{.j} \left(f_{ij} / f_{i.} - f_{i'j} / f_{i'.} \right)^2$$

De la misma forma la distancia entre dos puntos - columna j y j´ estará dada por:

$$d^2 (j\, j')^2 = \sum_{i=1..n} 1/f_{i.} \left(f_{ij} / f_{.j} - f_{ij'} /f_{.j'} \right)^2$$

$$\Phi_i = \beta \sum_{j=1..p} (f_{ij} / f_{i.}) \Psi_j$$

$$\Psi_j = \beta \sum_{i=1...n} (f_{ij} / f_{j.}) \Phi_i$$

PERFILES FILAS Y COLUMNAS: DISTANCIA CHI2

MIGRANTES DE PAÍSES LIMÍTROFES: PERFILES FILAS

Provincias	Bolivianos	Brasileros	Chilenos	Paraguayos	Uruguayos	Total
Buenos Aires	8,35	10,01	18,17	35,62	27,85	100,00
Catamarca	35,09	3,16	49,47	4,91	7,37	100,00
Córdoba	24,95	30,72	13,95	10,40	19,98	100,00
Corrientes	0,22	24,56	1,13	56,26	17,83	100,00
Chaco	0,55	1,80	1,03	93,63	2,99	100,00
Entre Ríos	0,11	1,28	0,28	1,07	97,26	100,00
Chubut	0,33	0,26	97,76	0,60	1,06	100,00
Jujuy	97,35	0,11	0,98	1,47		
La Pampa	1,10	11,32	52,15	3,29		
La Rioja	9,36	7,69	72,58	4,68		
Mendoza	22,19	15,60	58,07	1,59		
Misiones	0,53	95,82	0,68	2,81		
Neuquén	0,30	0,32	98,51	0,32		
Río Negro	0,38	0,59	97,93	0,36		
Salta	90,76	0,33	3,42	5,21		
San Juan	8,65	10,74	77,59	1,27		
San Lui						
Santa C						
Santa F						
S.del Es						
T. del F						
Tucumá						
Total						

MIGRANTES DE PAÍSES LIMÍTROFES: PERFILES COLUMNAS

Provincias	Bolivianos	Brasileros	Chilenos	Paraguayos	Uruguayos	Total
Buenos Aires	26,40	49,74	40,50	82,55	63,10	54,37
Catamarca	0,10	0,01	0,10	0,01	0,01	0,05
Córdoba	1,74	3,37	0,69	0,53	1,00	1,20
Corrientes	0,01	2,39	0,05	2,56	0,79	1,07
Chaco	0,08	0,39	0,10	9,54	0,30	2,39
Entre Ríos	0,05	0,92	0,09	0,36	32,06	7,91
Chubut	0,05	0,06	10,87	0,07	0,12	2,71
			,28	0,43	0,03	6,94
			,48	0,03	0,30	0,23
			,15	0,01	0,01	0,05
			,41	0,18	0,29	2,69
			,10	0,43	0,03	3,63
			,46	0,03	0,04	1,85
			,18	0,06	0,12	3,78
			,70	1,11	0,06	5,00
			,73	0,05	0,06	0,86
				02	0,04	0,08
				04	0,09	2,71
				73	1,38	1,50
				04	0,06	0,07
				01	0.00	0,53
				22	0,11	0,39
				00	100,00	100,00

Se ponderan las filas en relación a las columnas y viceversa.
Son espacios equivalentes y relacionados

La distancia entre dos puntos - fila i e i'estará dada por:

$$d^2 (i , i') = \sum_{j=1..p} 1/f_{.j} \left(f_{ij} / f_{i.} - f_{i'j} / f_{i'.} \right)^2$$

De la misma forma la distancia entre dos puntos - columna j y j´ estará dada por:

$$d^2 (j j')^2 = \sum_{i=1..n} 1/f_{i.} \left(f_{ij} / f_{.j} - f_{ij'} / f_{.j'} \right)^2$$

$$\Phi_i = \beta \sum_{j=1..p} (f_{ij} / f_{i.}) \Psi_j$$

$$\Psi_j = \beta \sum_{i=1...n} (f_{ij} / f_{j.}) \Phi_i$$

ANALISIS DE CORRESPONDENCIA

- **El análisis de correspondencias (AC)** es una técnica descriptiva o exploratoria, cuyo objetivo es resumir una gran cantidad de datos en un número reducido de dimensiones con la menor pérdida de información posible
- No se requiere el cumplimiento de ningún supuesto para poder aplicarla.
- El objetivo de esta técnica es similar al de otros métodos factoriales, como ACP, en el caso del análisis de correspondencias el método se aplica sobre variables categóricas u ordinales.
- Se busca una representación en coordenadas de las filas y columnas de una tabla de contingencia, de modo tal que los patrones de asociación presentes en la tabla se reflejen en estas nuevas coordenadas.
- Recordemos que una **tabla de contingencia** es un arreglo matricial de números no negativos donde en cada casilla se presenta la frecuencia absoluta observada la combinación de categorías.
- Este método trabaja con las proporciones que se encuentran en cada combinación de categorías de la variable XXX y de la variable YYY (Filas y Columnas).

Frecuencia en la práctica deportiva	Ausencia de depresión	Presencia de depresión
Sin práctica	31	22
Hasta tres veces por semana	38	10
Más de tres veces por semana	40	6

ANALISIS CORRESPONDENCIA: SIMPLE Y MULTIPLES

- **El análisis de correspondencias (AC)** es una técnica descriptiva o exploratoria, cuyo objetivo es resumir una gran cantidad de datos en un número reducido de dimensiones con la menor pérdida de información posible
- No se requiere el cumplimiento de ningún supuesto para poder aplicarla.
- El objetivo de esta técnica es similar al de otros métodos factoriales, como ACP, en el caso del análisis de correspondencias el método se aplica sobre variables categóricas u ordinales.
- Se busca una representación en coordenadas de las filas y columnas de una tabla de contingencia, de modo tal que los patrone
- Recordemos que una **tabl** cada casilla se presenta l variables.
- Este método trabaja con l variable XXX y de la var

Frecuencia en la práctica deportiva	Ausencia de depresión	Presencia de depresión	Totales
Sin práctica	31	22	53
Hasta tres veces por semana	38	10	48
Más de tres veces por semana	40	6	46
Totales	109	38	147

Tabla 5.19: Distribución de depresión según práctica deportiva

INDEPENDENCIA ENTRE VARIABLES: PERFILES FILAS Y COLUMNAS

	Y_1	Y_2	$\cdots$	Y_j	$\cdots$	Y_k
X_1	f_{11}	f_{12}	$\cdots$	f_{1j}	$\cdots$	f_{1k}
X_2	f_{21}	f_{22}	$\cdots$	f_{2j}	$\cdots$	f_{2k}
$\vdots$	$\vdots$	$\vdots$		$\vdots$		$\vdots$
X_i	f_{i1}	f_{i2}	$\cdots$	f_{ij}	$\cdots$	f_{ik}
$\vdots$	$\vdots$	$\vdots$		$\vdots$		$\vdots$
X_r	f_{r1}	f_{r2}	$\cdots$	f_{rj}	$\cdots$	f_{rk}

$$\widehat{p}_{i\cdot} = \frac{f_{i\cdot}}{n} \quad \text{y} \quad \widehat{p}_{\cdot j} = \frac{f_{\cdot j}}{n}.$$

$$\widehat{e}_{ij} = n \times \widehat{p}_{i\cdot} \times \widehat{p}_{\cdot j}$$

$$\widehat{e}_{ij} = n \times \frac{f_{i\cdot}}{n} \times \frac{f_{\cdot j}}{n} = \frac{f_{i\cdot} f_{\cdot j}}{n}.$$

$$f_{i\cdot} = \sum_{j=1}^{r} f_{ij}.$$

¿Cómo se reflejaría la independencia de las variables en la representación de AC?

¿Cómo se podría observar este hecho en una tabla?

Para responder a estos planteos, recordemos primero el concepto de **probabilidad condicional**

$$P(A/B) = \frac{P(A \cap B)}{P(B)},$$

siendo $P(B) > 0$. La probabilidad condicional de que ocurra A, sabiendo que ocurrió B, es el cociente entre la probabilidad conjunta de ambas y la probabilidad marginal de B. En términos coloquiales, se dice que dos eventos son **independientes** cuando la ocurrencia de uno de ellos no altera la probabilidad de ocurrencia del otro. Simbólicamente esto significa que

$$P(A/B) = P(A).$$

Lo cual se traduce en que $\frac{P(A \cap B)}{P(B)} = P(A)$, y por lo tanto

$$P(A \cap B) = P(A)P(B).$$

DISTANCIA CHI2

$$\hat{p}_{ij} = \frac{f_{ij}}{n},$$

siendo n el total de observaciones.

	Y_1	Y_2	$\cdots$	Y_j	$\cdots$	Y_k
X_1	$\hat{p}_{11}$	$\hat{p}_{12}$	$\cdots$	$\hat{p}_{1j}$	$\cdots$	$\hat{p}_{1k}$
X_2	$\hat{p}_{21}$	$\hat{p}_{22}$	$\cdots$	$\hat{p}_{2j}$	$\cdots$	$\hat{p}_{2k}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$		$\vdots$
X_i	$\hat{p}_{i1}$	$\hat{p}_{i2}$	$\cdots$	$\hat{p}_{ij}$	$\cdots$	$\hat{p}_{ik}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$		$\vdots$
X_r	$\hat{p}_{r1}$	$\hat{p}_{r2}$	$\cdots$	$\hat{p}_{rj}$	$\cdots$	$\hat{p}_{rk}$

Definimos la **distancia Chi cuadrado** como

$$D^2(R_{a\cdot}, R_{b\cdot}) = \sum_{j=1}^{r} \frac{1}{f_{\cdot j}} \left(\frac{f_{aj}}{f_{a\cdot}} - \frac{f_{bj}}{f_{b\cdot}} \right)^2,$$

siendo f_{aj} (resp. f_{bj}) el elemento de la fila a (resp. b) en la columna j, $f_{a\cdot}$ el total de la fila a y $f_{\cdot j}$ el total de la columna j. Que puede expresarse matricialmente como

$$D^2(R_{a\cdot}, R_{b\cdot}) = (R_{a\cdot} - R_{b\cdot}) D_c^{-1} (R_{a\cdot} - R_{b\cdot})^t,$$

ANALISIS CORRESPONDENCIA: SIMPLE Y MULTIPLES

- El análisis de correspondencias simple → en una tabla de contingencia de dos variables cualitativas,
- Las categorías de XXX una de las variables aparecen en las filas de la tabla, mientras que las de la otra variable en las columnas YYY.
- Objetivo: resumir la información presente en las filas y columnas,

de manera que pueda proyectarse sobre un

subespacio reducido (plano)

y representarse puntos fila y los puntos columna,

pudiéndose obtener conclusiones acerca de las relaciones entre ellos.

	Y_1	Y_2	$\cdots$	Y_j	$\cdots$	
X_1	f_{11}	f_{12}	$\cdots$	f_{1j}	$\cdots$	
X_2	f_{21}	f_{22}	$\cdots$	f_{2j}	$\cdots$	
$\vdots$	$\vdots$	$\vdots$		$\vdots$		
X_i	f_{i1}	f_{i2}	$\cdots$	f_{ij}	$\cdots$	
$\vdots$	$\vdots$	$\vdots$		$\vdots$		
X_r	f_{r1}	f_{r2}	$\cdots$	f_{rj}	$\cdots$	

Tabla 5.1: Tabla de contingencia

EJEMPLO 5.1. (CHAN ET AL.)

- El objetivo de este estudio es analizar la asociación entre el nivel cultural, representado en columnas, y el trastorno de la atención en los niños, representado en filas. Para ello, se observaron 1600 niños pacientes de un centro asistencial focalizando en su nivel cultural y en su respuesta a un test de trastornos de la atención. Los resultados obtenidos se muestran en la Tabla 5.3.
- Nos interesa estudiar si existe alguna vinculación entr aciente y sus resultados en el test de atención.
- https://www.flickr.com/photos/roqueestrada/34691



	A	B	C	D	E	F	**Totales**
Atento	64	57	57	72	36	21	**307**
Síntomas leves	94	94	105	141	97	51	**582**
Síntomas moderados	58	54	65	77	54	34	**342**
Disperso	46	40	60	94	78	51	**369**
Totales	**262**	**245**	**287**	**384**	**265**	**157**	**1600**

	A	B	C	D	E	F	Totales
Atento	64	57	57	72	36	21	307
Síntomas leves	94	94	105	141	97	51	582
Síntomas moderados	58	54	65	77	54	34	342
Disperso	46	40	60	94	78	51	369
Totales	262	245	287	384	265	157	1600

Tabla 5.3: Nivel cultural según atención

```r
library(ca)     # Paquete para análisis de correspondencias
library(FactoMineR) # Paquete con métodos de análisis exploratorio de
library(factoextra) # Paquete para análisis multivariado de datos
library(ggplot2) # Paquete para confeccionar dibujos

# Armamos la base de datos
atento=c(64,57,57,72,36,21)
leve=c(94,94,105,141,97,51)
moderado=c(58,54,65,77,54,34)
disperso=c(46,40,60,94,78,51)
base=rbind(atento, leve, moderado, disperso)
colnames(base)=c("A", "B", "C", "D", "E", "F")
rownames(base)=c("Atento", "Sínt. leves", "Sínt. moderados", "Dispersc

atencion.ac=CA(base, graph=FALSE) # Realiza el analisis de correspond
get_ca_row(atencion.ac) # Muestra lo que se guarda de las filas
get_ca_col(atencion.ac) # Muestra lo que se guarda de las columnas

fviz_contrib(atencion.ac, choice="row", axes=1, fill="royalblue",
color="black") +
theme_gray() +
theme(axis.text.x = element_text(angle=0)) +
xlab('Nivel de atención') +
ylab('Contribuciones (%)') +
ggtitle('')
# Grafica las categorías de las filas

fviz_contrib(atencion.ac, choice="col", axes=1, fill="royalblue",
color="black") +
theme_gray() +
theme(axis.text.x = element_text(angle=0)) +
xlab('Nivel cultural') +
ylab('Contribuciones (%)') +
ggtitle('')
# Grafica las categorías de las columnas

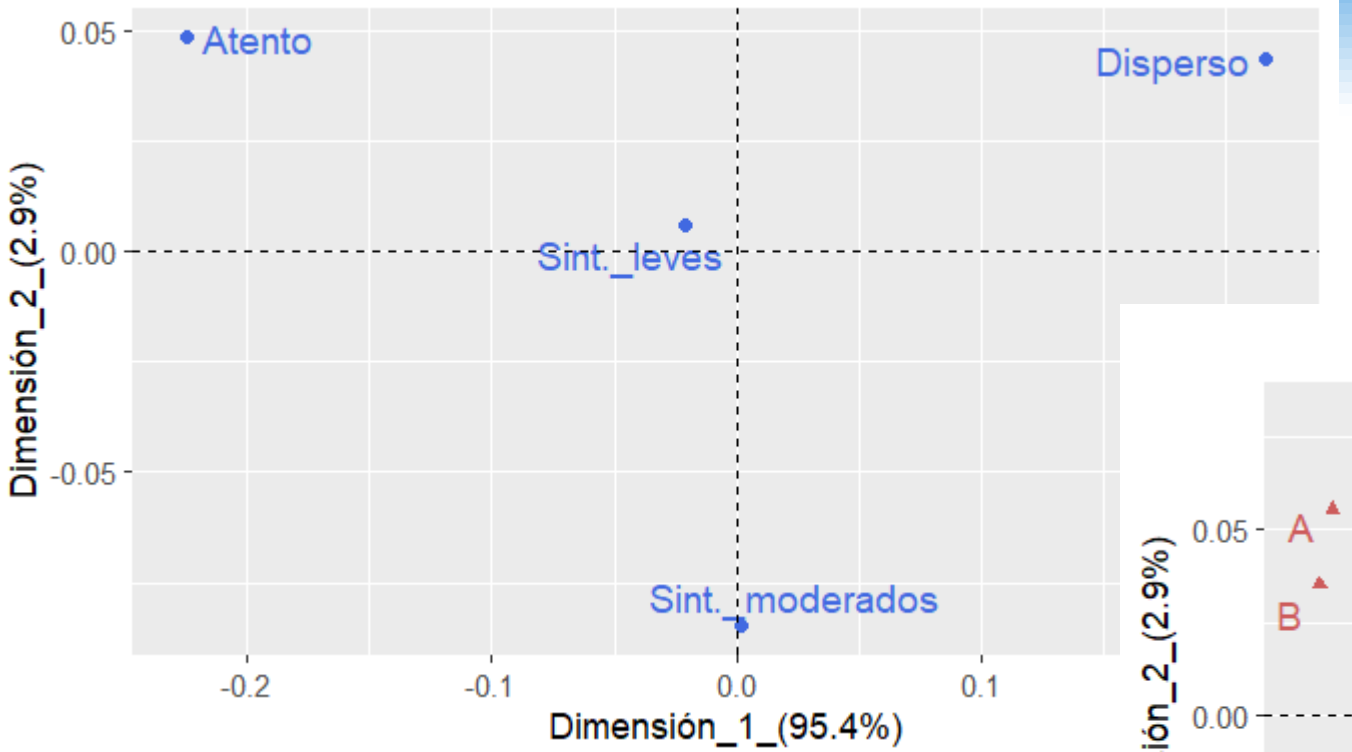
fviz_ca_row(atencion.ac, repel=TRUE, col.row="royalblue") +
theme_gray() +
xlab('Dimensión 1 (95.4%)') +
ylab('Dimensión 2 (2.9%)') +
ggtitle('')
# Grafica los puntos fila

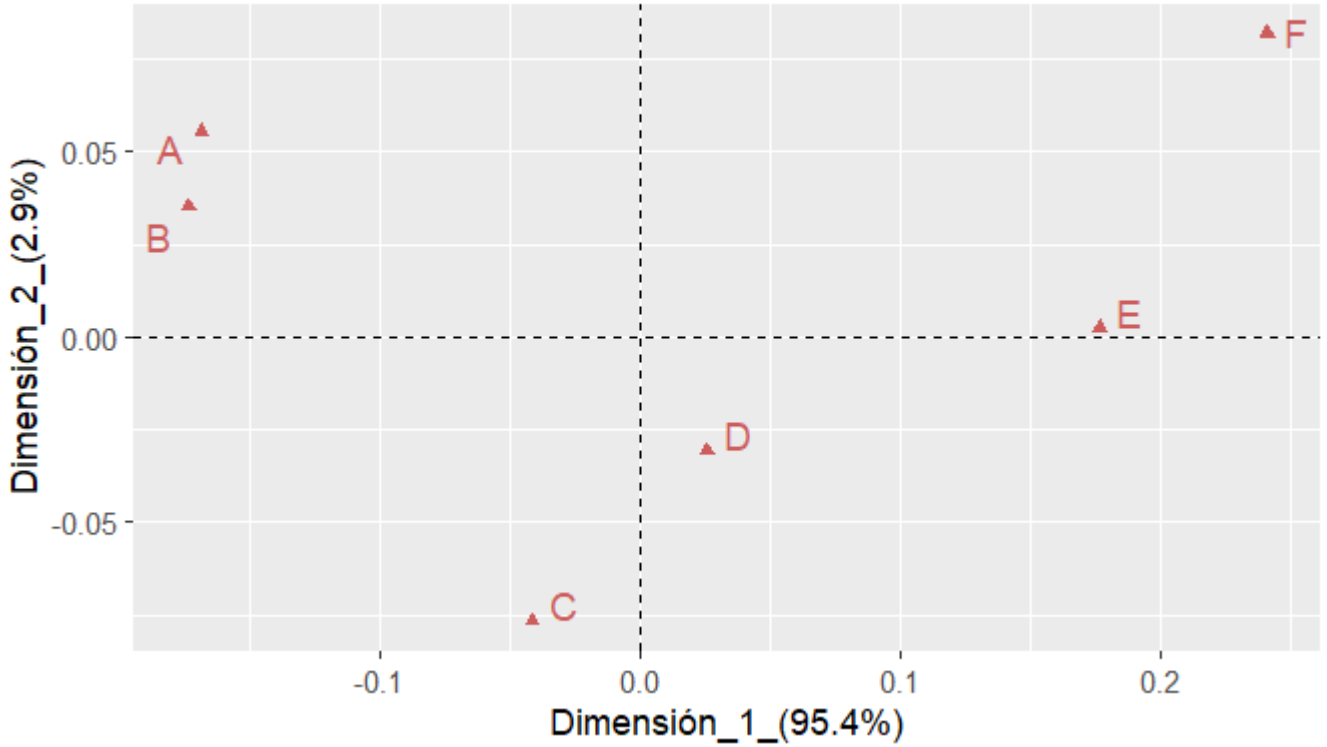
fviz_ca_col(atencion.ac, repel=TRUE, col.col="indianred") +
theme_gray() +
xlab('Dimensión 1 (95.4%)') +
ylab('Dimensión 2 (2.9%)') +
ggtitle('')
# Grafica los puntos columna

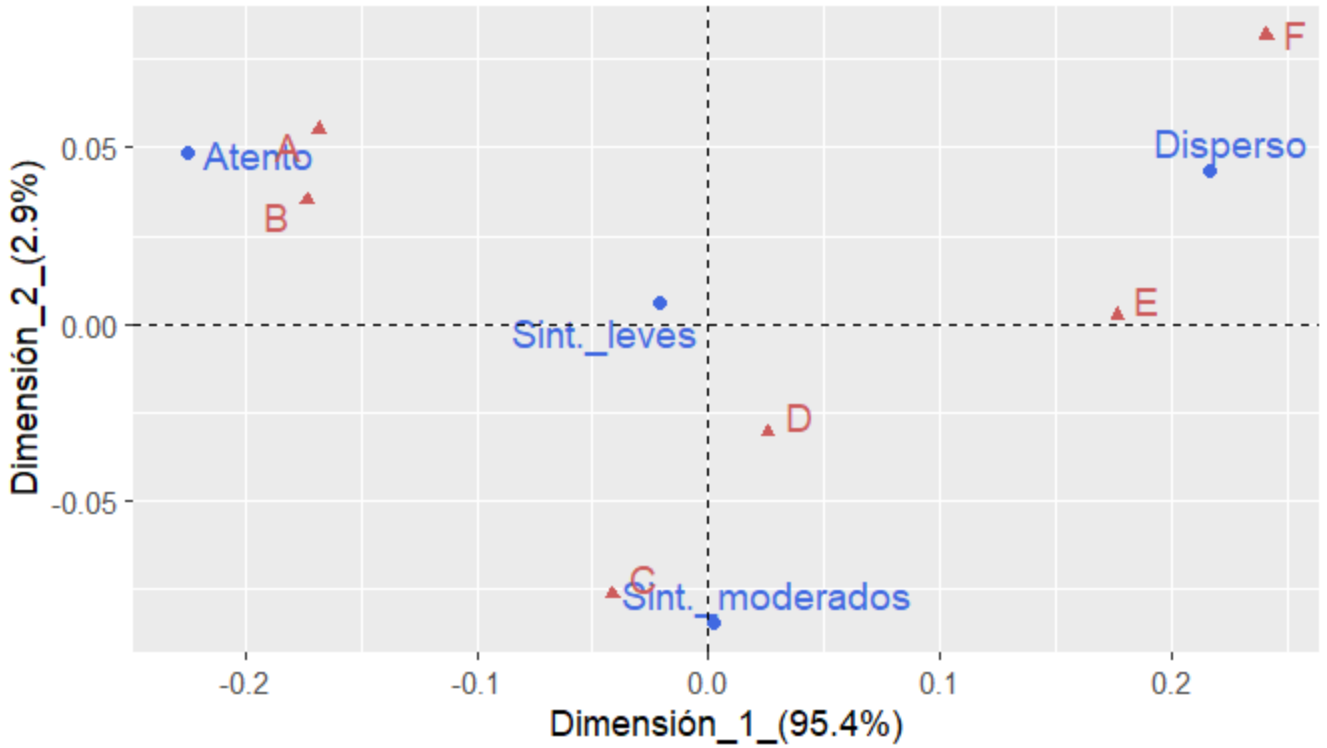
fviz_ca_biplot(atencion.ac, repel=TRUE, col.row="royalblue",
col.col="indianred") +
theme_gray() +
xlab('Dimensión 1 (95.4%)') +
ylab('Dimensión 2 (2.9%)') +
ggtitle('')
# Realiza el biplot simétrico

# Aplicamos ahora el paquete ca
atencion_ac=ca(base, graph = FALSE) # Realiza el análisis de corresponder
summary(atencion_ac)
atencion_ac$rowcoord # Arroja las coordenadas del biplot de las filas
atencion_ac$colcoord # Arroja las coordenadas del biplot de las columnas
```

Código 5.4: AC para niveles cultural y de atención


Atento
Disperso
Sint._leves
Sint._moderados
0.05
0.00
-0.05
-0.2
-0.1
0.0
0.1
Dimensión_2_(2.9%)
Dimensión_1_(95.4%)


A
B
C
D
E
F
0.05
0.00
-0.05
-0.1
0.0
0.1
0.2
Dimensión_2_(2.9%)
Dimensión_1_(95.4%)


F
Disperso
A
Atento
B
E
Sint._leves
D
C
Sint._moderados
0.05
0.00
-0.05
-0.2
-0.1
0.0
0.1
0.2
Dimensión_2_(2.9%)
Dimensión_1_(95.4%)

CHAN ET AL.

Ejemplo 5.1. El objetivo de este estudio es analizar la asociación entre el nivel cultural, representado en columnas, y el trastorno de la atención en los niños, representado en filas. Para ello, se observaron 1600 niños pacientes de un centro asistencial focalizando en su nivel cultural y en su respuesta a un test de trastornos de la atención. Los resultados obtenidos se muestran en la Tabla 5.3.

Nos interesa estudiar si existe alguna vinculación entre el nivel sociocultural del paciente y sus resultados en el test de atención.

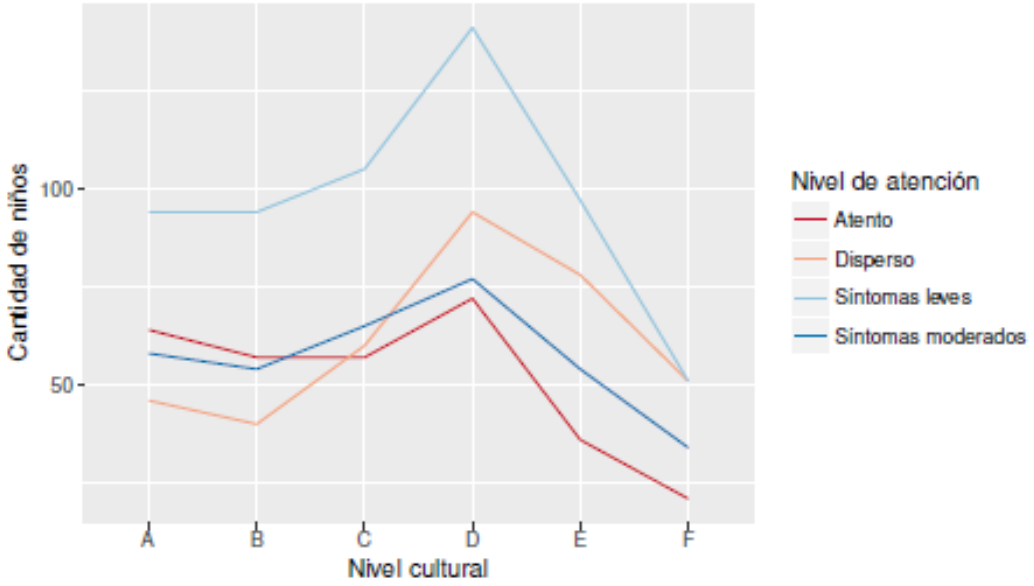


Figura 5.2: Perfiles de nivel cultural según atención

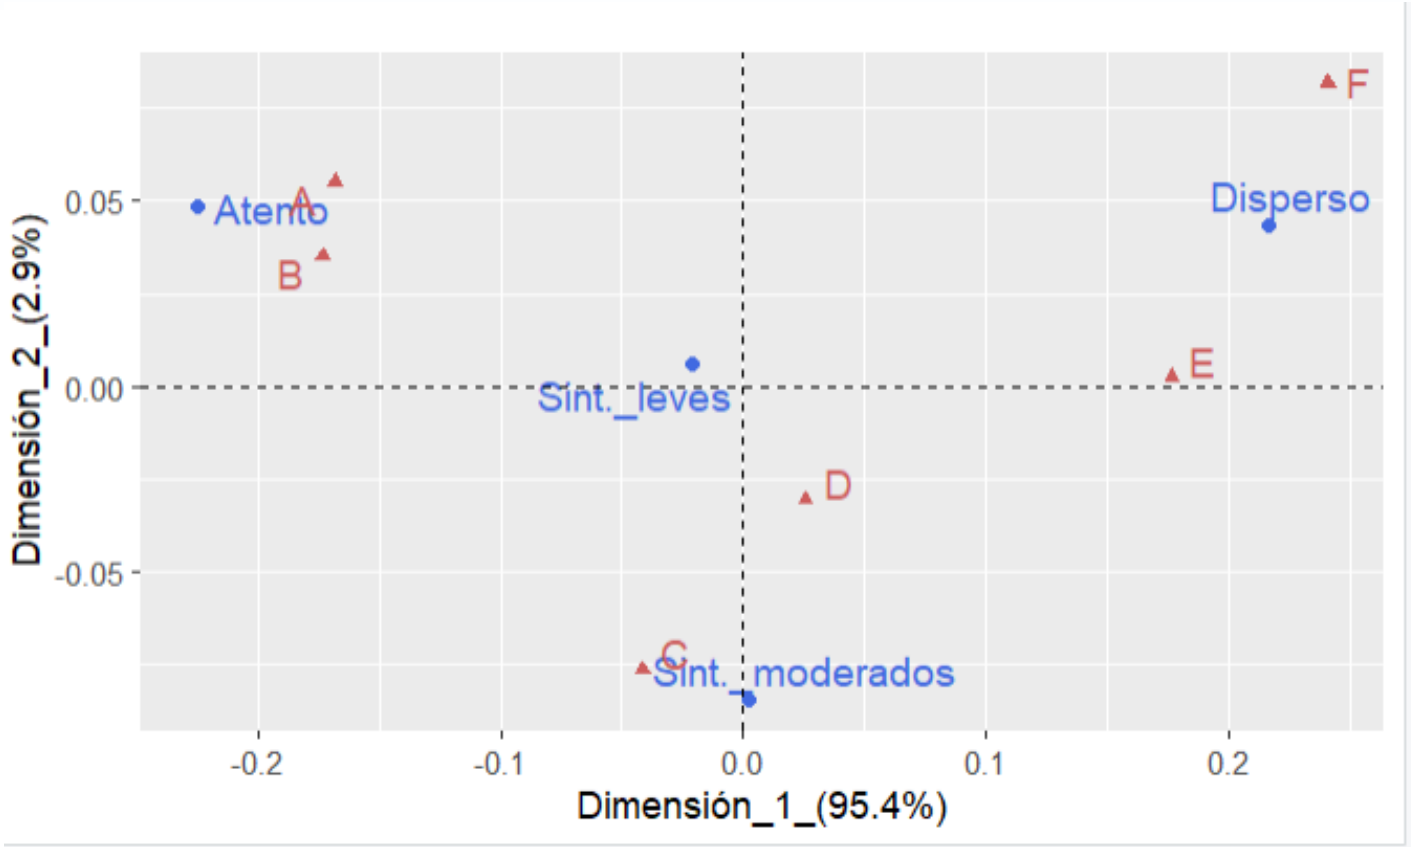


https://flic.kr/p/6hyajx

	A	B	C	D	E	F	Totales
Atento	64	57	57	72	36	21	307
Síntomas leves	94	94	105	141	97	51	582
Síntomas moderados	58	54	65	77	54	34	342
Disperso	46	40	60	94	78	51	369
Totales	262	245	287	384	265	157	1600

Tabla 5.3: Nivel cultural según atención

CHAN ET AL.





https://flic.kr/p/6hyajx

	A	B	C	D	E	F	Totale
Atento	64	57	57	72	36	21	30
Síntomas leves	94	94	105	141	97	51	58
Síntomas moderados	58	54	65	77	54	34	34
Disperso	46	40	60	94	78	51	36
Totales	262	245	287	384	265	157	160

Tabla 5.3: Nivel cultural según atención

EJEMPLO 5.1 (CHAN ET AL.)

- Con el AC se construye una gráfica, llamada **mapa perceptual,** que señala la interacción de dos variables categóricas a través de la relación entre las filas y las columnas.
- Se cuantifica además el grado de asociación presente e conjunto de variables.
- Por ejemplo, consideremos la variable cualitativa fila qu representa el grado de atención
- Mientras que la variable columna el nivel cultural
- El análisis de correspondencias estudia las frecuencias d distribución conjunta de ambas variables y produce un gráfico con dos ejes en los cuales cada categoría de la variable ubicada en las filas y cada categoría de la variable ubicada en las columnas está representada po punto.

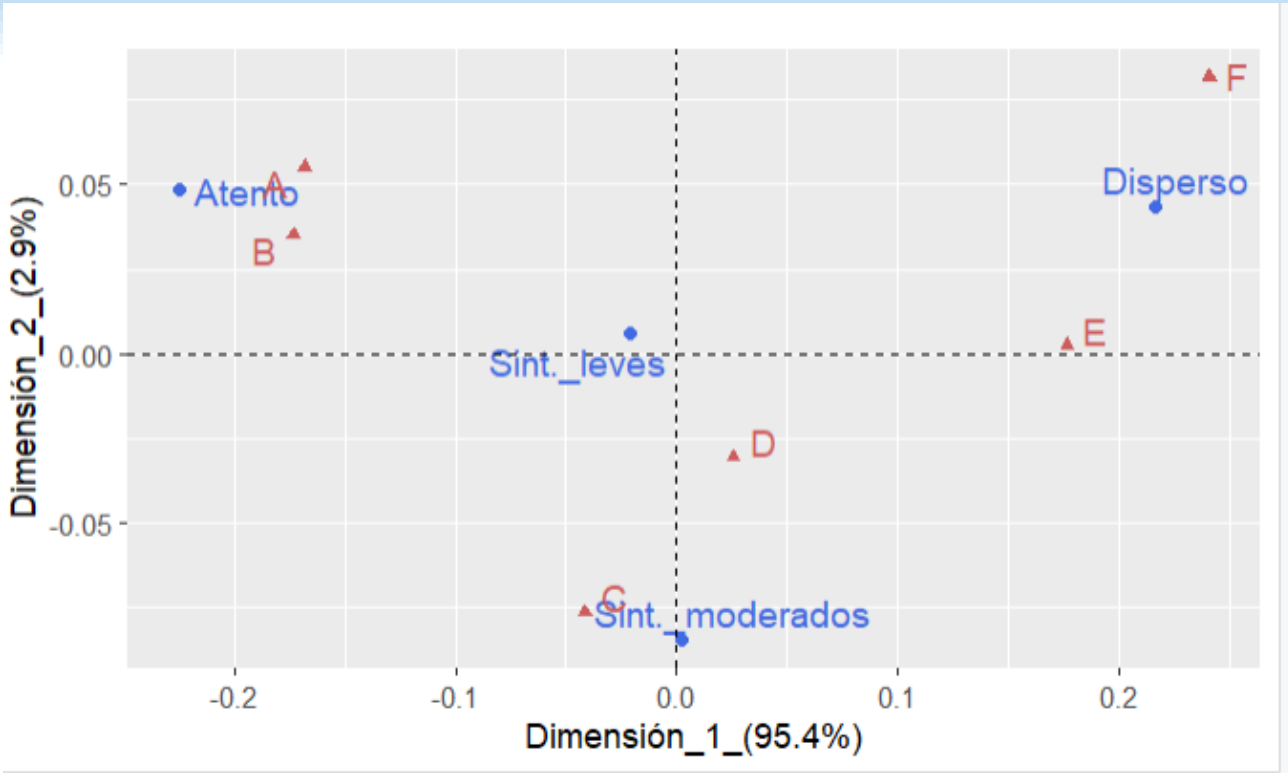


https://flic.kr/p/6hyajx

	A	B	C	D	E	F	Totales
Atento	64	57	57	72	36	21	307
Síntomas leves	94	94	105	141	97	51	582
Síntomas moderados	58	54	65	77	54	34	342
Disperso	46	40	60	94	78	51	369
Totales	262	245	287	384	265	157	1600

Tabla 5.3: Nivel cultural según atención

- Con el AC se construye una gráfica, llamada **mapa perceptual,** que señala la interacción de dos variables categóricas a través de la relación entre las filas y las columnas.
- Se cuantifica además el grado de asociación presente e conjunto de variables.
- Por ejemplo, consideremos la variable cualitativa fila qu representa el grado de atención
- Mientras que la variable columna el nivel cultural
- El análisis de correspondencias estudia las frecuencias d distribución conjunta de ambas variables y produce un gráfico con dos ejes en los cuales cada categoría de la variable ubicada en las filas y cada categoría de la variable ubicada en las columnas está representada po punto.

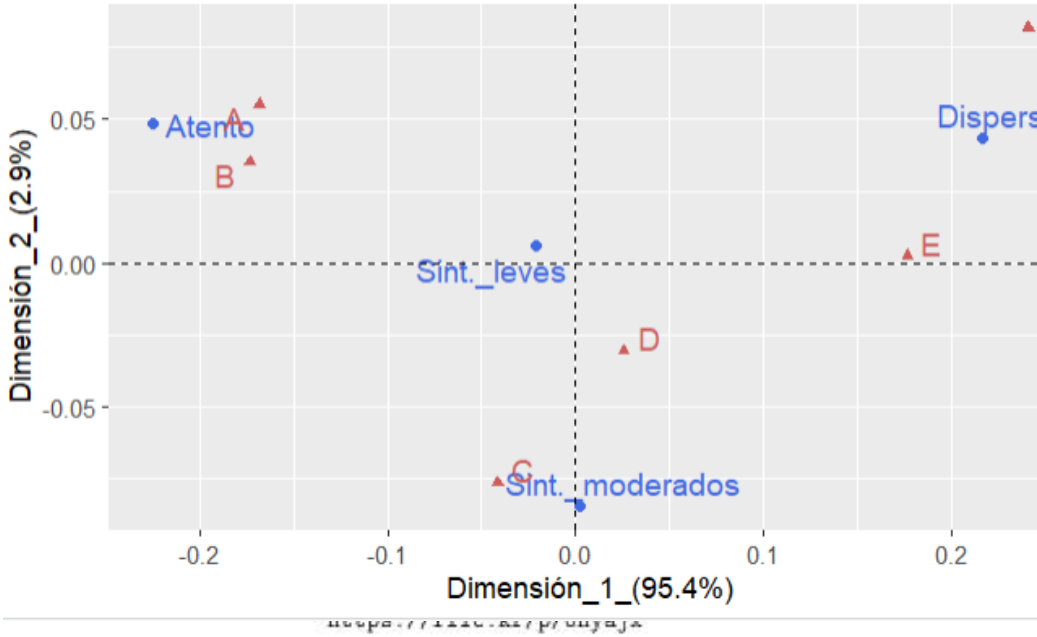


	A	B	C	D	E	F	Totales
Atento	64	57	57	72	36	21	307
Síntomas leves	94	94	105	141	97	51	582
Síntomas moderados	58	54	65	77	54	34	342
Disperso	46	40	60	94	78	51	369
Totales	262	245	287	384	265	157	1600

Tabla 5.3: Nivel cultural según atención

GUÍA PARA LA INTERPRETACIÓN GRÁFICA DEL *BIPLOT* SIMÉTRICO

1. Las columnas (respectivamente, filas) cercanas al origen reflejan categorías similares a la columna (respectivamente, fila) promedio.
2. Las columnas (respectivamente, filas) cercanas entre sí reflejan categorías de similar perfil en términos de columnas (respectivamente, filas).
3. Las columnas (respectivamente, filas) cercanas y lejanas al origen reflejan alta asociación positiva entre las categorías representadas.
4. Los ejes representan 'factores ocultos' o 'variables latentes'.
5. En cada eje se indica el porcentaje de la inercia que logra representar el mismo.
6. DISTANCIAS RELATIVAS NO ABSOLUTAS
7. Se observa un punto fila en el conjunto del espacio de las columnas
8. Se observa un punto columna en el conjunto del espacio de las filas.



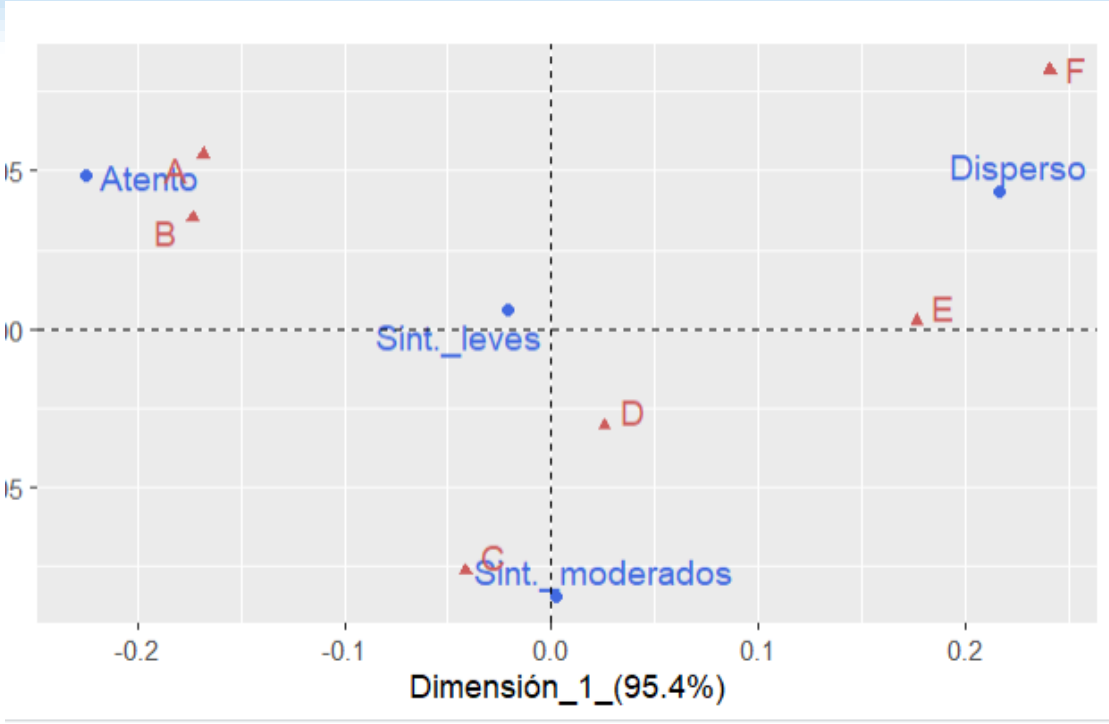
	A	B	C	D	E	F	Totales
Atento	64	57	57	72	36	21	307
Síntomas leves	94	94	105	141	97	51	582
Síntomas moderados	58	54	65	77	54	34	342
Disperso	46	40	60	94	78	51	369
Totales	262	245	287	384	265	157	1600

Tabla 5.3: Nivel cultural según atención

INTERPRETACIÓN GRÁFICA DEL *BIPLOT* SIMÉTRICO

Teniendo en cuenta lo anterior, realizamos las siguientes observaciones para el biplot simétrico:

- El nivel de atención más usual presentan síntomas leves y el nivel de cultural D (cerca de (0,0) (perfil medio)
- El nivel cultural A es el más próximo a la categoría de 'atento'.
- El nivel de cultura D es el más usual mas cercano al velor medio de los niveles de cultura.
- Los síntomas "leves" en grado de atención se asocian con la categoría de cultura D.
- Los síntomas "moderados" en grado de atención se asocian con la categoría de cultura C.



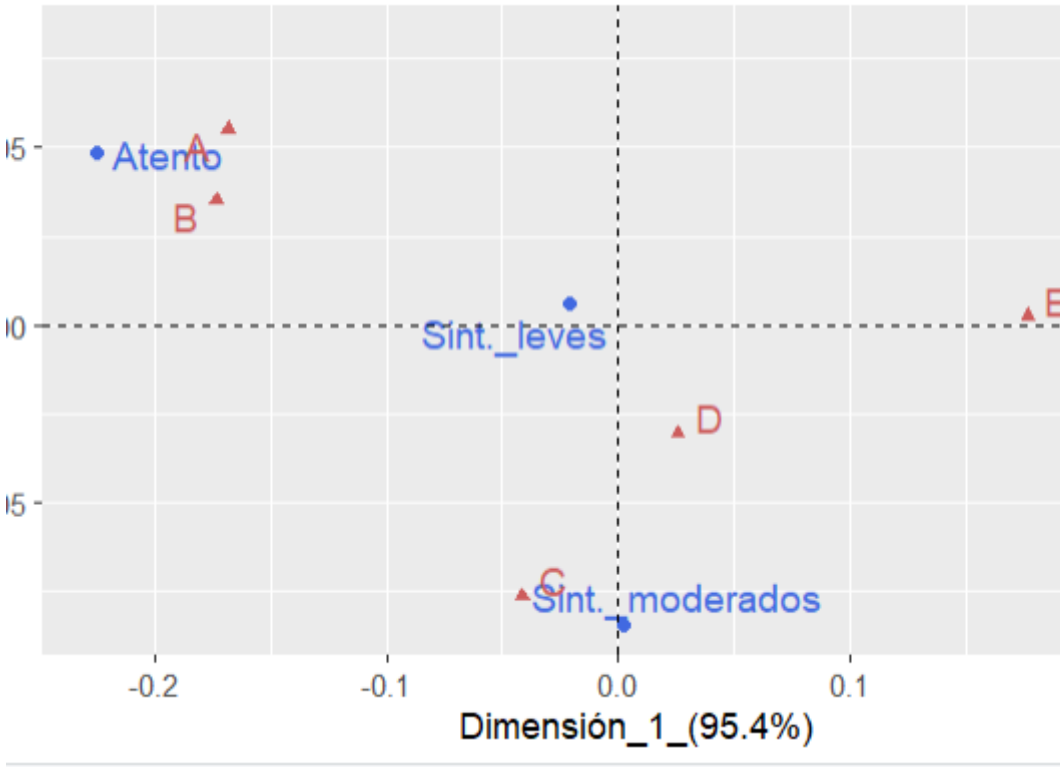
DIMENSIÓN 1 Y DIMENCIÓN 2

	Atento	Síntomas leves	Síntomas moderados	Disperso
Masa	0.191875	0.363750	0.213750	0.230625
Distancia Chi	0.206391	0.040579	0.047857	0.232132
Inercia	0.008173	0.000599	0.000490	0.012427
Dimensión 1	-1.418216	-0.162976	-0.185590	1.608987
Dimensión 2	-0.835542	1.307591	-0.931956	-0.503463

Tabla 5.14: Perfiles de las filas

	A	B	C	D	E	F
Masa	0.1638	0.1531	0.1794	0.2400	0.1656	0.0981
Distancia Chi	0.1667	0.1722	0.0550	0.0427	0.1856	0.2455
Inercia	0.0046	0.0045	0.0005	0.0004	0.0057	0.0059
Dimensión 1	-1.1369	-1.1869	-0.3268	0.2148	1.2756	1.6677
Dimensión 2	-1.1737	0.7788	-0.1535	0.5280	1.0690	-2.0717

Tabla 5.15: Perfiles de las columnas



INERCIA → AUTOVALORES (SON MENORES A 1)

	1	2	3
Valor	0.020682	0.000639	0.000369
Porcentaje	95.35%	2.95%	1.70%

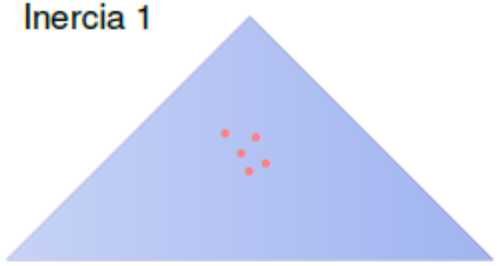
Tabla 5.13: Inercias principales (autovalores)

En cada eje se indica el porcentaje de la inercia que logra representar el mismo.

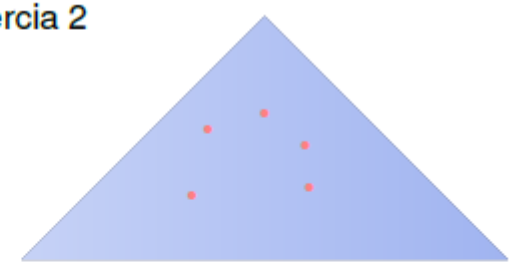
Tabla 5.13: Inercias principales (autovalores)

INERCIA	1	2	3
Valor	0.020682	0.000639	0.000369
Porcentaje	95.35%	2.95%	1.70%

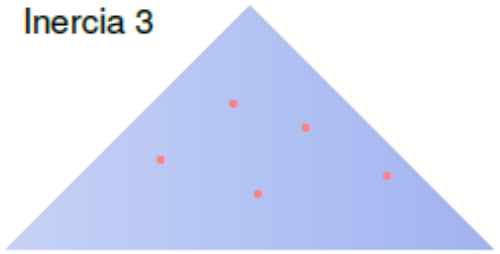
Inercia 1



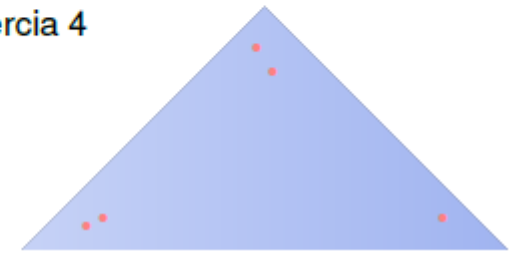
Inercia 2



Inercia 3



Inercia 4



Podemos observar la siguiente relación de orden entre las inercias

$$\text{Inercia 1} < \text{Inercia 2} < \text{Inercia 3} < \text{Inercia 4}.$$

¿Qué sucede con las posiciones relativas de los perfiles fila a medida que la inercia aumenta?

¿Cómo se vincula esto con la hipótesis de independencia?

Ejemplo 5.11. En la Tabla 5.22 se puede visualizar lo que muestra la Figura 5.16, donde el total de observaciones se mantiene constante y se van polarizando las distribuciones.

Tabla 1

	B1	B2	B3
A1	10	12	11
A2	12	10	13
A3	15	14	13

inercia1 = 0.0064

Tabla 2

	B1	B2	B3
A1	4	12	11
A2	12	10	13
A3	15	14	19

inercia2 = 0.0354

Tabla 3

	B1	B2	B3
A1	5	16	13
A2	12	5	13
A3	15	14	19

inercia3 = 0.0838

Tabla 4

	B1	B2	B3
A1	5	16	20
A2	2	5	19
A3	25	14	11

inercia4 = 0.2678

Tabla 5.22: Inercia creciente - Asociación creciente

ANÁLISIS DE CORRESPONDENCIAS MÚLTIPLES,

- La extensión del análisis de correspondencias simples al caso de varias variables categóricas, representadas en tablas de contingencia multidimensionales, se denomina **análisis de correspondencias múltiples**, y utiliza los mismos principios generales que la técnica antes descripta
- Dentro de los ejemplos de aplicación del análisis de correspondencias simple y múltiple podemos citar los siguientes:
  - Estudios de preferencias o estilos de consumo, muy usuales en Investigación de Mercados.
  - Estudios que buscan tipologías de individuos respecto a variables cualitativas, como pueden ser el comportamiento de especies en Biología, los patrones de enfermedades en Medicina, los perfiles psicológicos, entre otros.
  - Estudios de posicionamiento de empresas a partir de las preferencias de consumidores.
  - Estudios para elegir tratamientos efectivos para una misma patología pero con diferentes etiologías.

CORRESPONDENCIAS MULTIPLES

https://drive.google.com/file/d/1sddftTzuRh3iRg4eRC0rsFAXi_5iom8z/view

- Personas

Observación	Género	Edad	Estado	Color
1	M	joven	soltero	castaño
2	M	adulto	soltero	rojizo
3	F	mayor	casado	rubio
4	M	adulto	soltero	negro
5	F	mayor	casado	negro
6	F	mayor	soltero	castaño
7	M	joven	casado	rojizo
8	M	adulto	casado	rubio
9	M	mayor	soltero	castaño
10	F	joven	casado	negro
11	F	adulto	soltero	castaño
12	M	joven	casado	rubio

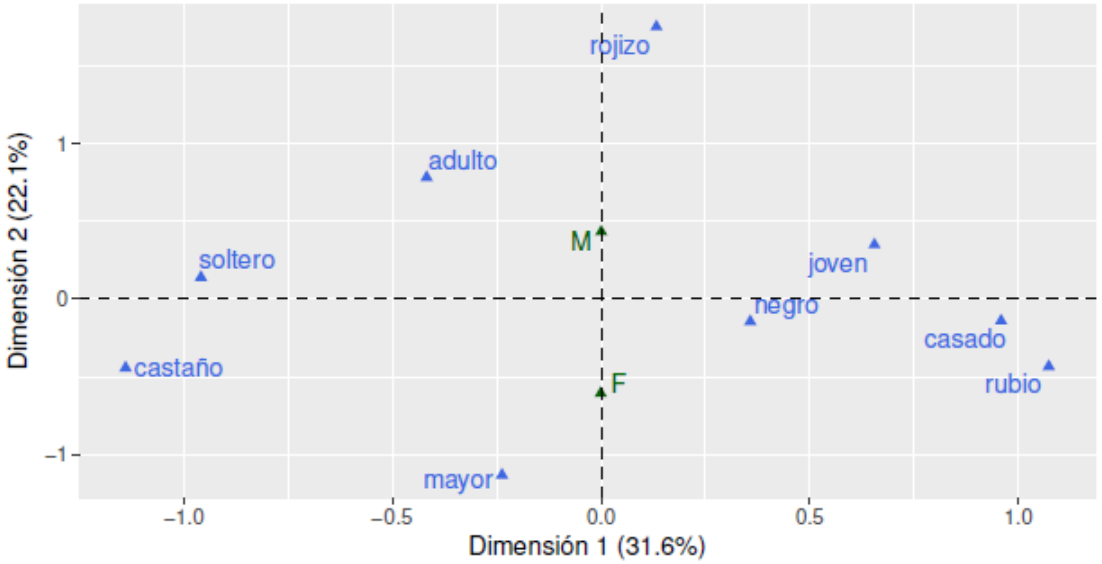


Figura 5.20: Categorías variables - ACM

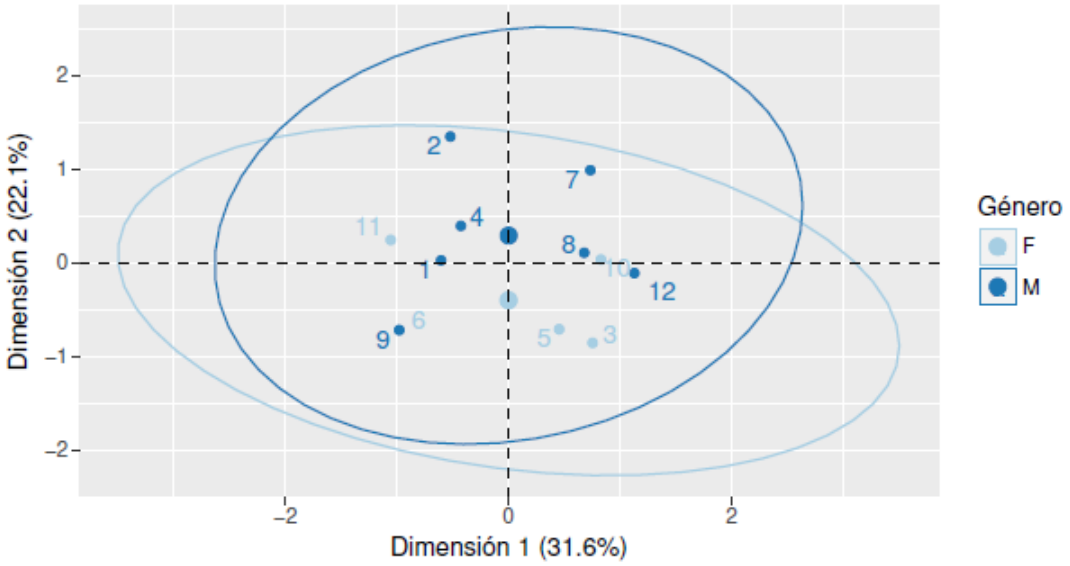


Figura 5.21: Individuos agrupados por género - ACM

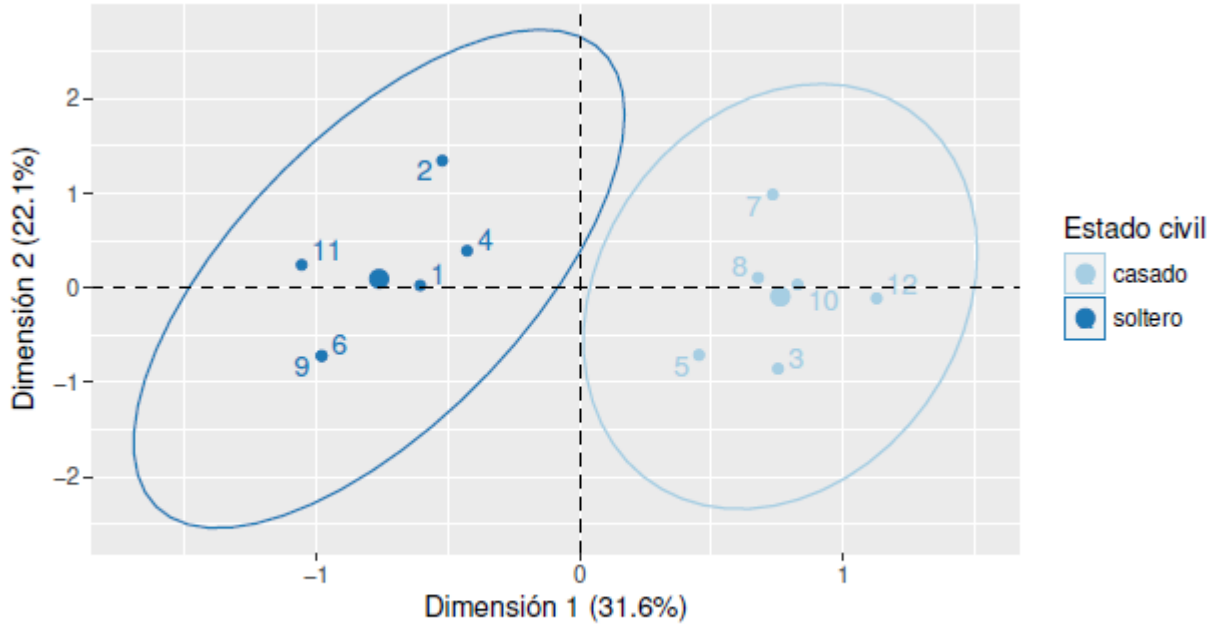
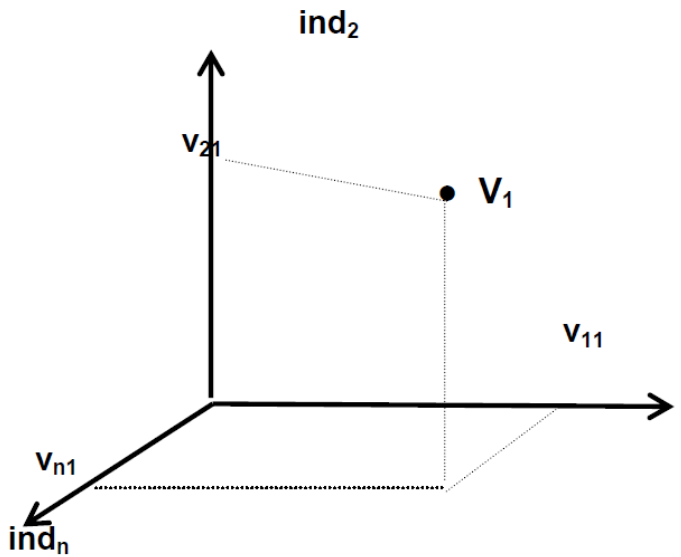


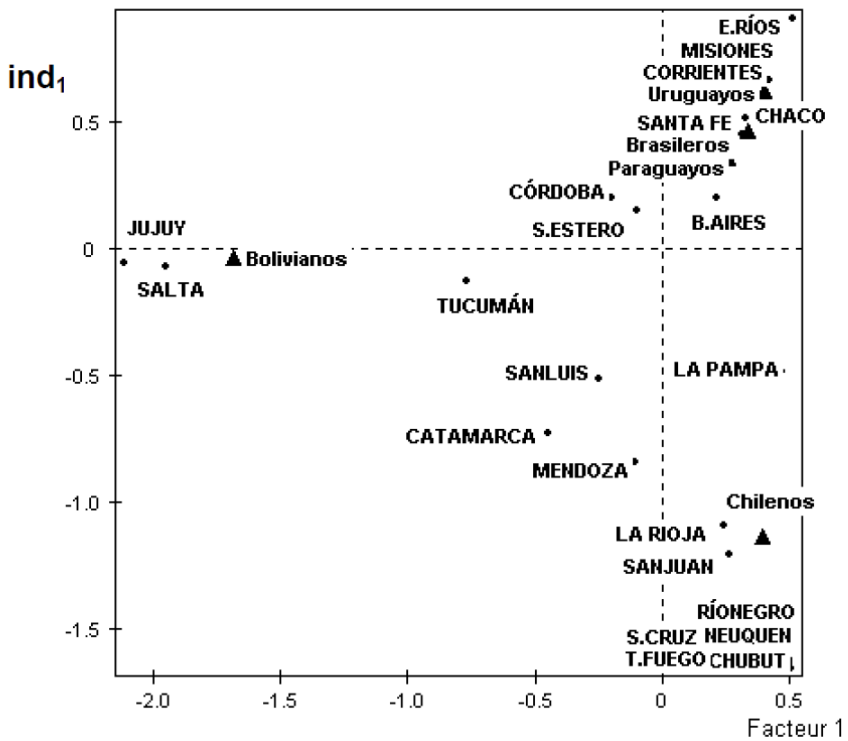
Figura 5.22: Individuos agrupados por estado civil - ACM

CORRESPONDENCIA MÚLTIPLES Y SIMPLES

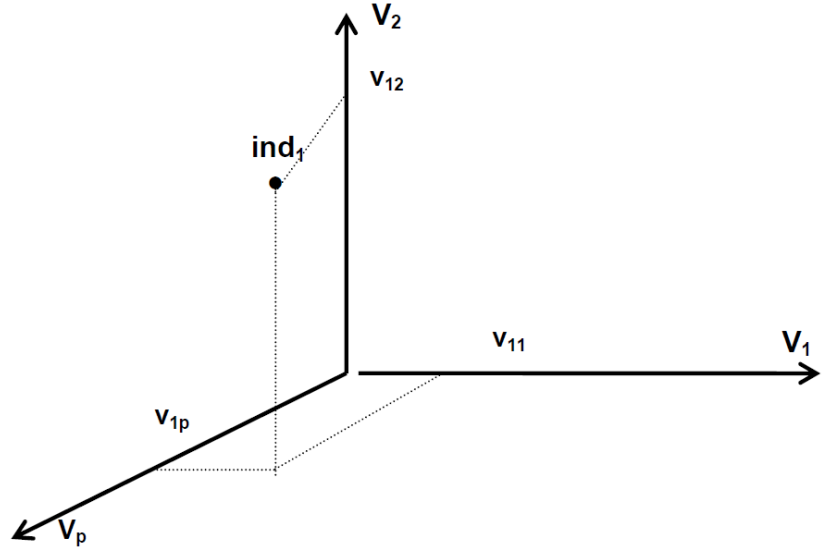
- El valor del método depende de los datos.
- Método exploratorio para variables categóricas.
- Distancia Chi2 → autovalores (inercia) y autovectores (ejes)
  - Autovalores → inercia
  - Autovectores → ejes
- Biplot → variables e individuos

Espacio de los individuos: R^n





Espacio de las variables: R_p



EJEMPLO

- Buenos Aires es el más frecuente y no diferencia perfiles
- El (0,0) representa perfiles medios.
- Jujuy y Salta reciben frecuentemente Bolivia
- Los chilenos se dirigen a La Rioja y San Juan, con más frecuencia pero también a Rio Negro y Neuquen.

