Apache Kakfa

Aplicaciones del aprendizaje profundo en el análisis de grandes volúmenes de datos.
Especialización en Ciencia de Datos.

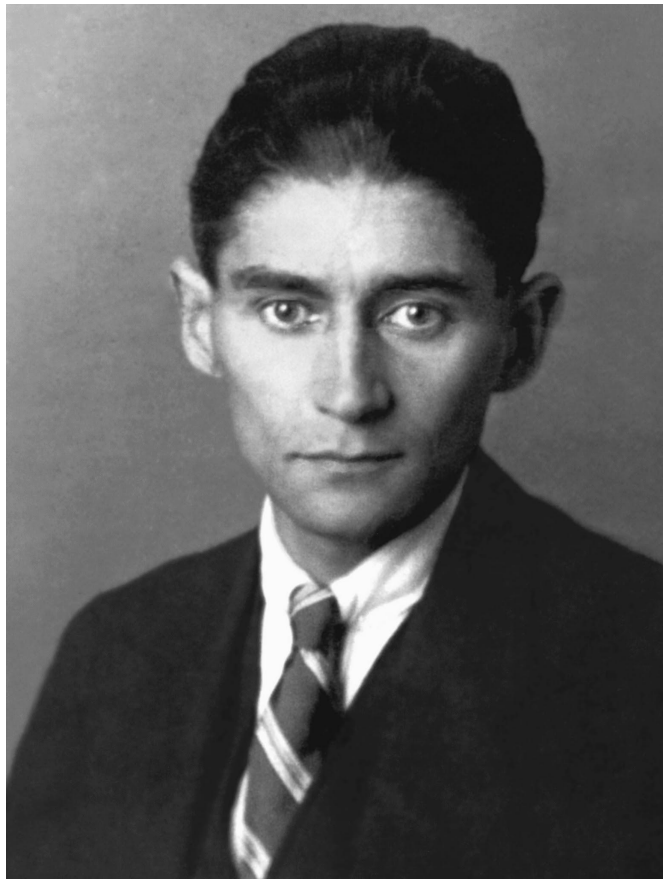


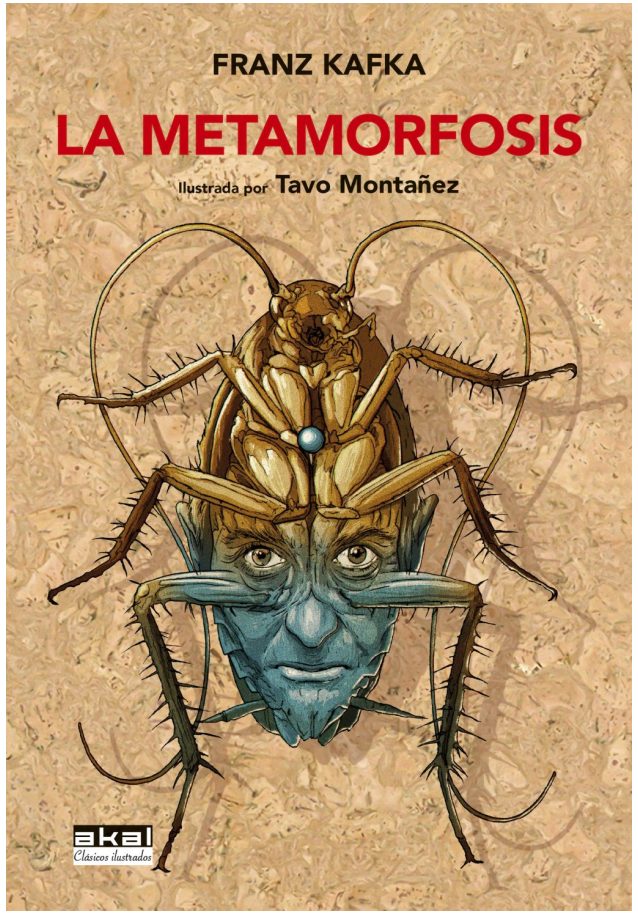
Mg. Diego Encinas - Ing. Román Bond

Agenda

- ¿Qué es Kafka?
- Componentes
- Kafka Cluster
- Conceptos
- Instalación
- Comandos
- Ejemplos!

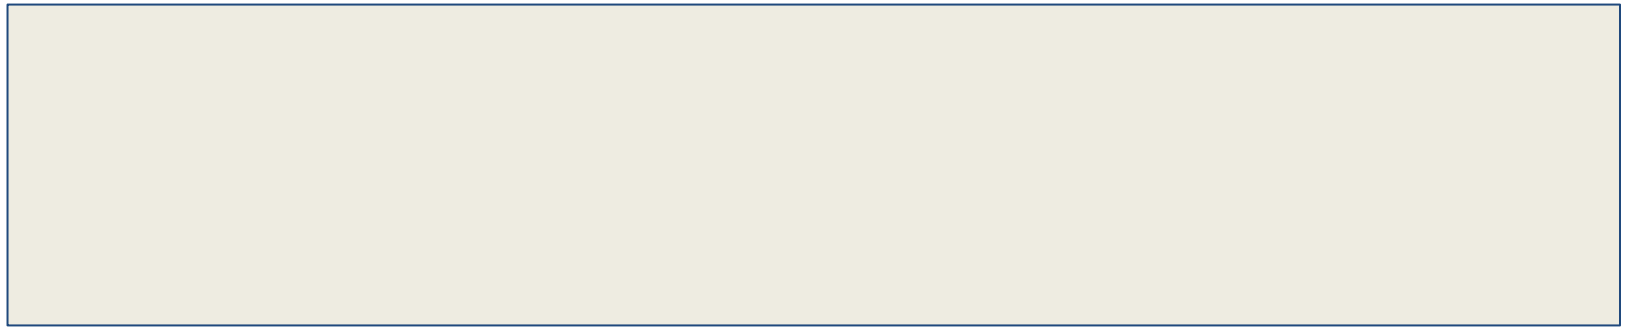
¿Qué es Kafka?




FRANZ KAFKA
LA METAMORFOSIS
Ilustrada por Tavo Montañez
akal
Clásicos ilustrados

¿Qué es Kafka?

Es una plataforma de streaming



que puede ser utilizada para almacenar y procesar **flujos de datos (data streams)**".

¿Qué es Kafka?

Es una plataforma de streaming
escalable,
tolerante a fallos
y distribuida con alta disponibilidad,
que puede ser utilizada para almacenar y procesar **flujos de datos (data streams)**".

Componentes

Kafka está conformado por 3 componentes clave:

- Kafka cluster.
- Connect framework (Connect API).
- Librería de programación para Streams (Streams API).

Componentes

Kafka Cluster.

Almacena data streams, que son una secuencia de mensajes/eventos continuos que producen las aplicaciones.

Los streams de datos pueden ser “consumidos” secuencial e incrementalmente por otras aplicaciones.

Componentes

Connect API.

Se utiliza para consumir datos en el contexto de Kafka.

Además, permite export data streams a sistemas externos como por ejemplo, sistemas de archivos paralelos y distribuidos, base de datos, etc.

Componentes

Streams API.

Permite el procesamiento de data streams.

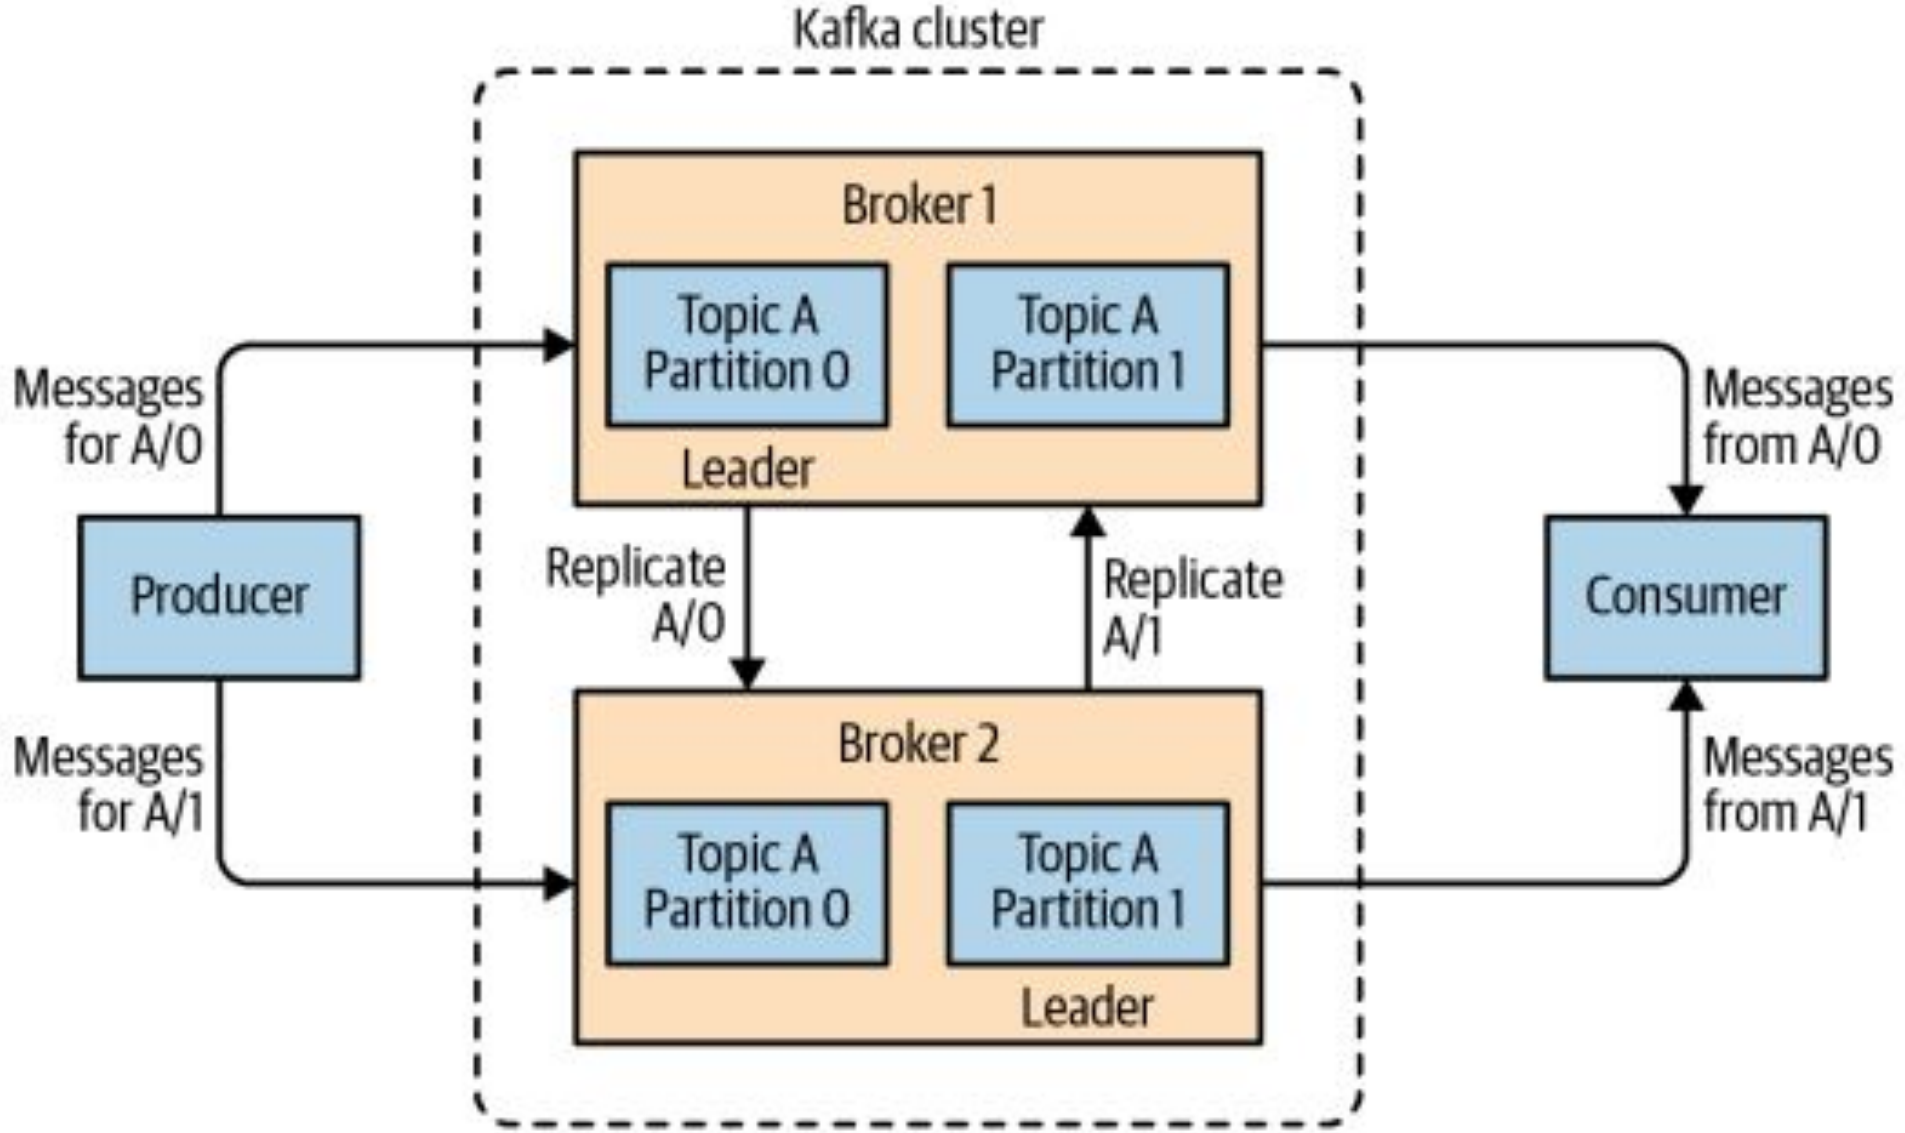
De esta forma se pueden crear pipelines de procesamiento complejos que reciben streams desde el cluster Kafka.

Asimismo es posible escribir resultados en el cluster Kafka

Kafka cluster

La arquitectura del cluster provee un servicio de mensajes suscriptor-publicador.

Kafka cluster



Kafka cluster

Productores crean (escriben y publican) mensajes en el cluster.

Consumidores leen mensajes del cluster Kafka.

Los mensajes se almacenan en servidores Kafka llamados brokers. Los mensajes se organizan en tópicos.

Formalmente, un tópico es una secuencia de mensajes (log).

Kafka cluster

Cada vez que un mensaje se escribe en un tópico se agrega al final del mismo.

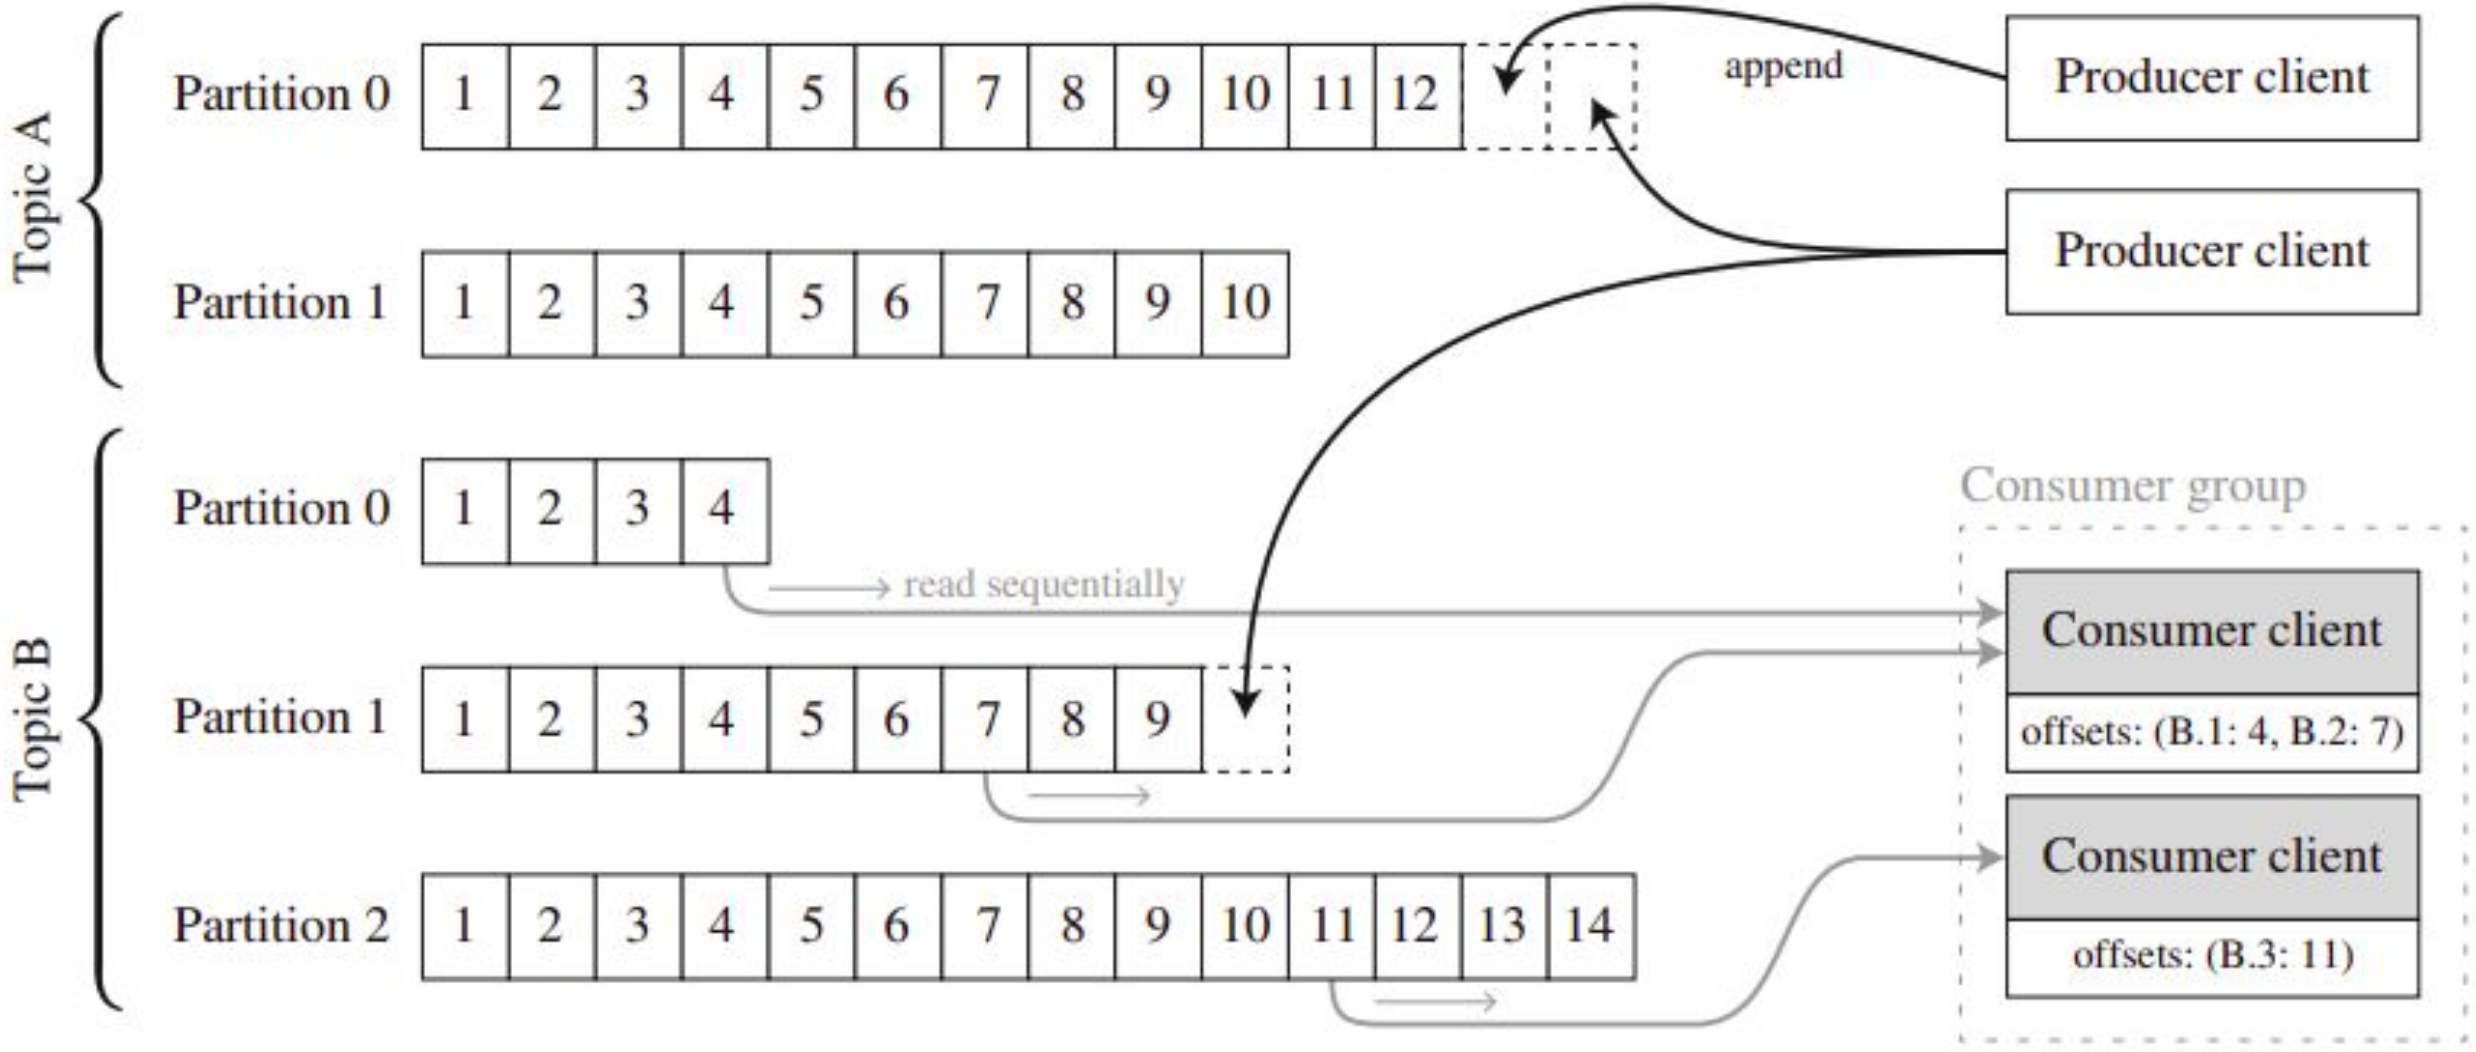
Los mensajes en Kafka se definen bajo el esquema clave-valor.

Las claves y valores son de tamaño variable en formato byte array. Además, por cada mensaje se almacena un timestamp en formato entero de 64 bits.

Kafka cluster

Los tópicos se dividen en particiones. Cuando un mensaje se escribe en un tópico, el productor debe especificar la partición del mensaje.

Kafka cluster



Kafka cluster

Productores pueden usar diferentes estrategias de particionamiento. Por defecto, los mensajes se particionan utilizando el algoritmo de hashing por clave.

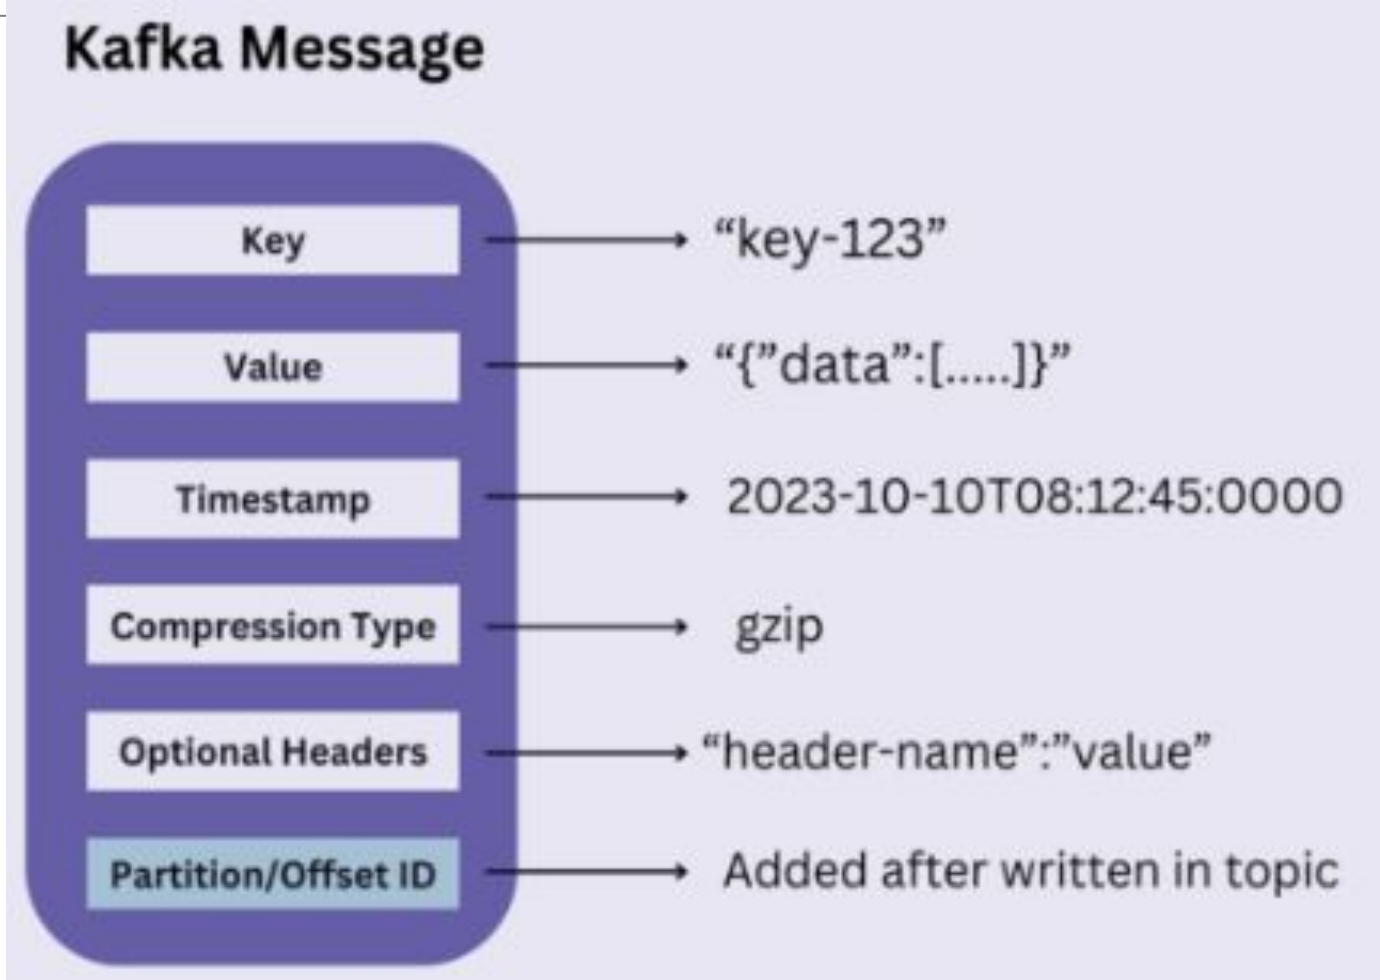
Los mensaje con misma clave comparten la misma partición.

Kafka cluster

Cada mensaje tiene asociado un offset que responde a la posición del mensaje dentro de la partición.

Como los mensajes se agregan al final de la partición, el valor del offset se determina de forma implícita.

Kafka cluster



Kafka cluster

Kafka asegura el orden de los mensajes dentro de una partición. De esta forma, todos los consumidores que leen desde una única partición reciben los mensajes en el orden en el que se agregaron a la partición.

No hay garantía de orden entre mensajes de diferentes particiones o diferentes tópicos.

Kafka cluster

Los Brokers tienen capacidad para almacenar, de forma confiable, mensajes en disco.

En comparación con otros sistemas de mensajes suscriptor-publicador, Kafka puede implementarse para almacenamiento a largo plazo. Es decir, los mensajes no se borran una vez salen del tópico.

Para esto, es necesario configurar los tópicos con el tiempo de retención de los mensajes. Otra posibilidad es indicar la retención en términos de bytes.

Kafka cluster

No existe la noción de nodo maestro en el cluster Kafka.

Todos los brokers tienen la capacidad de ejecutar los servicios que necesita el cluster. Este diseño permite escalar linealmente, evitando un posible cuello de botella.

Aun así, los brokers deben estar coordinados. Para esto, se utiliza Apache ZooKeeper como coordinador (escalable, tolerante a fallos y distribuido).

Kafka utiliza ZooKeeper para almacenar metadatos de los tópicos, particiones, etc.

Kafka cluster

Para garantizar tolerancia a fallos y alta disponibilidad, las particiones se replican en diferentes brokers.

Cada tópico puede configurarse con un factor de replicación que indica la cantidad de copias de la partición que se tienen que tener en el clúster.

Kafka cluster

Como se mencionó anteriormente, los brokers no eliminan mensajes después de la entrega. Como ventajas se tiene:

- Brokers no necesitan realizar un seguimientos del progreso de lectura de los consumidores, permitiendo un mayor rendimiento en operaciones de lectura (clave en big data).
- Garantiza la lectura de mensajes en orden sin un sistema complejo (como ACK's).
- Consumidores pueden leer los mensajes la cantidad de veces que sea necesario al igual que nuevos consumidores.·

Kafka cluster

Como se mencionó anteriormente, los brokers no eliminan mensajes después de la entrega. Como principal desventaja, se tiene que los consumidores/clientes son los responsables de realizar el seguimiento de la cantidad de mensajes leídos/procesados.

Esto se realizando almacenando los offsets de los mensajes. Por ejemplo, realizar un promedio en los offsets impares.

¿Consultas?



Ejemplos!!!

