Pipeline de Modelado Predictivo

Predicción de Prescripciones Médicas

Un recorrido por las 4 etapas del proceso de Machine Learning con Series Temporales

Visión General del Pipeline

01_FE
Feature Engineering

02_TS
Training Strategy

03_HT
Hyperparameter Tuning

04_ZZ
Prediction

Pipeline de 4 etapas secuenciales e independientes

Cada etapa tiene su configuración YAML y genera archivos que alimentan la siguiente.

Arquitectura modular: permite experimentar sin reejecutar todo.

Objetivo: Predecir prescripciones de diciembre 2021 con datos de 24 meses.

ETAPA

Feature Engineering

¿Qué se hace?

Transformación de datos crudos en características predictivas mediante ingeniería automática.

Transformaciones aplicadas

Lags: Valores de 1 y 2 meses atrás

Deltas: Diferencias con períodos previos

Tendencias: Pendientes en ventanas

Promedios: Medias móviles 3, 6, 12 meses

Ratios: Valor actual / promedio

Estacionalidad: Variable mes

⚙️ **Canaritos Asesinos:** Técnica que elimina el 30% de variables menos importantes comparándolas con features aleatorias.

ETAPA

Training Strategy

¿Qué se hace?

Particionamiento temporal respetando el orden cronológico para evitar data leakage.

División temporal sin solapamiento

TRAIN	VAL	TEST	GAP	FUTURE
202001-202104	202105	202106	202107-202111	202112
(16 meses)	(1 mes)	(1 mes)	(5 meses)	(1 mes)

⚠️ **¿Por qué el GAP de 6 meses?**

En FE se aplicó un **frollmean de 6 meses + lead** sobre la clase para estabilizar la volatilidad. Esto hace que los últimos 6 meses de datos (julio-diciembre) tengan valores futuros incorporados y no puedan usarse para entrenar sin causar data leakage.

🎯 **Diferencia clave:** NO se crean variables. Solo se separa el dataset en conjuntos temporales.

ETAPA

Hyperparameter Tuning

¿Qué se hace?

Búsqueda automática de mejores hiperparámetros mediante Optimización Bayesiana (50 iteraciones).

Hiperparámetros optimizados

learning_rate
Tasa de aprendizaje: 0.02 - 0.3

feature_fraction
% de features: 0.1 - 1.0

num_leaves
Hojas por árbol: 10 - 36,000

min_data_in_leaf
Mínimo muestras: 0 - 100,000

🏆 **Mejor resultado (Iteración 12)**

RMSE: 0.877055

822 árboles | 29,098 hojas | LR: 0.212 | FF: 0.983

ETAPA

Prediction

¿Qué se hace?

Entrenamiento del modelo final con mejores hiperparámetros y predicciones para diciembre 2021.

Proceso de predicción

Cargar Train Final	Entrenar LightGBM	Predecir Future	Guardar Resultados

🔑 **Diferencia clave:** NO se buscan parámetros. Se usa el modelo optimizado para predicciones finales.

Salidas generadas:

- KA741-prxs_01a.txt: Predicciones por médico
- impo_val.txt: Importancia de variables

Comparación de las 4 Etapas

01_FE

Crea variables nuevas usando lags, tendencias y ratios.

🎯 Enriquece datos

02_TS

Separa datos en períodos temporales sin modificar variables.

🎯 Organiza

03_HT

Busca mejores hiperparámetros mediante optimización.

🎯 Optimiza modelo

04_ZZ

Usa modelo optimizado para predicciones finales.

🎯 Produce resultados

Pipeline modular: Cada etapa es independiente y se ejecuta secuencialmente. Los resultados alimentan la siguiente sin reejecutar todo.

Pipeline Completo

De datos crudos a predicciones mediante un proceso modular, reproducible y optimizado automáticamente

Etapas	Variables engineered	Mejor RMSE
4	18	0.877