TP Final: Desafío de Machine Learning en Economía de la Salud

Universidad	Universidad Nacional del Oeste
Carrera	Esp. en Ciencia de Datos
Materia	Aplicaciones de Ciencia de Datos (07102)
Profesor	Dr. Francisco Fernandez (franaf@gmail.com)
Alumnos	Grupo = {Lic. Leticia Sosa, Ing. Federico Czerniawski, Mg. Ing. Pablo Pandolfo}
Fecha	Diciembre 2025

Objetivo del Proyecto

- Aplicar técnicas de Machine Learning para predecir el **gasto de bolsillo (Out-of-Pocket) per cápita en PPP** (Purchasing Power Parity, Paridad de Poder Adquisitivo en español) que los ciudadanos realizarán en salud durante el año **2022**, utilizando datos históricos de 23 países del período 2000-2021

Objetivos del desafio

1. Ejecutar el pipeline completo desde cero
2. Crear y probar diferentes experimentos
3. Comparar resultados entre experimentos
4. Decidir cuál es el mejor modelo

1. Ejecutar el pipeline completo desde cero

Se ejecutó el pipeline completo, estableciendo un modelo base, cuyos resultados son los que se tomaron en cuenta como referencia.

2. Crear y probar diferentes experimentos

- Se propusieron las siguientes nuevas variables para ser incluidas, a fin de probar si mejoran el modelo:

Indicador	Fórmula	Interpretación	Utilidad
Índice de envejecimiento	SP.POP.65UP.TO.ZS / SP.POP.0014.TO.ZS	Compara el peso de adultos mayores frente a niños y jóvenes.	Evalúa el grado de envejecimiento demográfico y anticipa presión sobre salud y

Indicador	Fórmula	Interpretación	Utilidad
			pensiones.
Ratio gasto público/privado	NE.CON.GOVT.ZS / NE.CON.PRVT.ZS	Relación entre financiamiento estatal y privado del consumo.	Permite analizar el modelo económico y la intensidad del financiamiento estatal.
Intensidad de emisiones por concentración urbana	EN.GHG.CO2.PC.CE.AR5 / EN.URB.MCTY.TL.ZS	Emisiones de CO_2 per cápita por cada punto porcentual de población en megaciudades.	Evalúa sostenibilidad de la urbanización y orienta políticas de transporte y energía.

- Cada integrante del grupo ejecutó los siguientes 3 experimentos, con semillas diferentes:

```
- Exp1: Baseline (sin modificar)
- Exp2: Con las tres variables propuestas sin COVID
- Exp3: Con las tres variables propuestas con COVID
```

3. Comparar resultados entre experimentos

- **Configuración de Estrategia común**:
  - orden_lead: 1 -> Predecir el año siguiente (desde 2021 predecir 2022)
  - presente: 2021

- **Configuración sin COVID**:
  - excluir: [2020, 2021] -> Excluir estos años por pandemia, para que no genere sesgo en el resultado dadas los índices seleccionados

- Los resultados de los experimentos fueron los siguientes:

Experimento	Seed	Iteraciones de boosting	variables nuevas	RMSE_test	Variación RMSE	Notas
Leti_Baseline	999983	121	no	83,01255	-	
Leti_concovid_convariables	999983	228	sí	82,50126	0,51129	Mejor
Leti_sincovid_convariables	999983	228	sí	82,50126	0,51129	Mejor
Pablo_Baseline	123456	7084	no	82,04489	0,96766	Mejor
Pablo_concovid_convariables	123456	1458	sí	83,59572	-0,58317	Peor
Pablo_sincovid_convariables	123456	206	sí	82,05489	0,95766	Mejor
Fede_Baseline	881210	166	no	80,44716	**2,56539**	Mejor

Experimento	Seed	Iteraciones de boosting	variables nuevas	RMSE_test	Variación RMSE	Notas
Fede_concovid_convariables	881210	487	sí	81,41682	1,59573	Mejor
Fede_sincovid_convariables	881210	487	sí	81,41682	1,59573	Mejor

- **Conclusiones:**
  - Todos los experimentos ejecutados mejoraron el modelo base
  - Cambiar la semilla también modifica el resultado del modelo
  - No hay una regla universal: agregar variables nuevas mejora en algunos casos (Leti), pero no en otros (Pablo, Fede)

- **Analizar Importancia de las variables en el modelo ganador**

El modelo ganador NO incluye nuevas variables, por lo que se analiza la importancia del modelo siguiente, **Fede_concovid_convariables**
Las variables no aparecen en el TOP 20

Rank	Variable	Gain
1	NE.CON.PRVT.PC.KD	0.4912
...	...	...
95	INDICE_ENVEJECIMIENTO	2.960093e-04
...	...	...
1176	RATIO_GASTO	2.102263e-08
...	...	...
1216	INTENS_EMISIONES_CONCENTR_URB	1.494589e-08
...	...	...

Las variables elegidas no mejoraron el RMSE del modelo baseline, por lo tanto no se consideran relevantes para predecir el gasto de bolsillo en salud

4. Decidir cuál es el mejor modelo

- El RMSE más bajo absoluto lo logra Fede Baseline (80,44), lo que lo convierte en el mejor modelo de todos los experimentos