La Investigación Científica aplicada a la Ciencia de Datos: Un Marco Integrado

1. Introducción

La ciencia, la tecnología y la innovación constituyen la tríada fundamental sobre la cual se construye el progreso de las sociedades modernas. La Ciencia de Datos emerge en este contexto no como una disciplina aislada, sino como un campo de convergencia que sintetiza el conocimiento de las ciencias básicas, los métodos de investigación y la praxis ingenieril, todo orientado por un objetivo último: extraer valor y conocimiento accionable a partir de los datos.

Este campo se erige, por tanto, como un exponente del concepto I+D+i (Investigación, Desarrollo e innovación), integrando sus tres componentes de manera intrínseca:

- **Investigación (I)**: Representa la indagación metódica y original para descubrir patrones, correlaciones y conocimientos ocultos dentro de los datos. Es el componente que busca entender el "por qué" y el "qué" a través del análisis exploratorio y la formulación de hipótesis basadas en datos.

- **Desarrollo (D)**: Corresponde a la aplicación concreta de los hallazgos de la investigación para la construcción de artefactos: algoritmos, modelos predictivos, sistemas de recomendación y pipelines de datos. Transforma el conocimiento teórico en una solución técnica viable.

- **Innovación (i)**: Es el resultado de la implementación exitosa de estas soluciones técnicas en un entorno productivo, generando un avance sustancial en procesos, productos o servicios. La innovación en ciencia de datos se mide por el impacto real y la mejora continua.

En esencia, la Ciencia de Datos opera en el cruce de caminos: la ciencia aporta el marco metodológico y la rigurosidad para comprender los fenómenos; la tecnología proporciona las herramientas y plataformas para implementar soluciones; y la innovación impulsa la adopción y evolución de estas soluciones para generar transformación tangible.

2. Definiciones Básicas: Ciencia, Tecnología y el Lugar de la Ciencia de Datos

El debate sobre la naturaleza científica de disciplinas como la Informática y, por extensión, la Ciencia de Datos, es relevante para entender su método. Como señalaba Snodgrass[1] en su crítica, existe una percepción de que el componente científico (entendido como el método hipotético-deductivo clásico) ha estado históricamente menos desarrollado que los componentes matemático e ingenieril.

Sin embargo, la Ciencia de Datos no debe encasillarse en los paradigmas tradicionales. Es una disciplina híbrida que se nutre de ambos mundos:

- De las **Ciencias Formales** (Matemáticas, Lógica, Estadística) adopta su lenguaje, rigor y estructura axiomática para construir modelos cuantitativos robustos.

- De las **Ciencias Fácticas** (Física, Biología, Ciencias Sociales) adopta la preocupación por los fenómenos empíricos, la observación y la validación contra la realidad, aunque no siempre siga estrictamente el método de contrastación de hipótesis en su forma pura.

- De la **Ingeniería** y el **Desarrollo Tecnológico** adopta el enfoque pragmático de diseño, construcción, implementación y escalabilidad de soluciones.

Por lo tanto, su método es una adaptación que podríamos denominar **"científico-tecnológico"**, donde el ciclo de investigación está intrínsecamente ligado al ciclo de desarrollo de software y a la generación de valor empresarial.

[1] SNODGRASS, Richard T. Towards a science of temporal databases. En Temporal Representation and Reasoning, 14th International Symposium on. IEEE, 2007. p. 6-7.

3. Clasificación de las Ciencias y el Posicionamiento de la Ciencia de Datos

a. Ciencias básicas, aplicadas y desarrollo tecnológico

Esta clasificación resulta muy útil para desglosar las actividades dentro de la Ciencia de Datos:

- **Ciencias Básicas**: Proporcionan el sustrato teórico indispensable. La Teoría de Probabilidades, el Álgebra Lineal, el Cálculo, la Estadística Inferencial y la Teoría de la Información son los pilares sobre los que se construyen todos los algoritmos de aprendizaje automático. El fin aquí es el conocimiento puro y abstracto.

- **Ciencias Aplicadas**: La Ciencia de Datos actúa predominantemente como una ciencia aplicada. Aplica los conocimientos de las ciencias básicas para resolver problemas específicos en dominios como la salud (medicina predictiva), las finanzas (detección de fraudes) o el marketing (clustering de clientes). Investiga problemas de interés social y comercial.

- **Desarrollos Tecnológicos**: Este es el aspecto de "ingeniería de machine learning". Implica la aplicación del conocimiento científico para producir sistemas en funcionamiento: APIs de modelos, pipelines de ETL (Extract, Transform, Load), plataformas de despliegue (MLOps) y productos data-driven. El resultado es un artefacto tecnológico tangible.

Un científico de datos competente debe moverse con soltura entre estos tres niveles, comprendiendo la teoría detrás de un modelo (básico), adaptándolo a un problema business (aplicado) e implementándolo de manera eficiente y confiable (tecnológico)

b. Ciencias formales vs. Fácticas

- **Ciencias Formales**: La Ciencia de Datos es formal en su núcleo algorítmico. La derivación de una función de coste, la optimización de parámetros o la demostración de la convergencia de un algoritmo son ejercicios propios de las matemáticas.

- **Ciencias Fácticas**: Es fáctica en su aplicación y validación. Un modelo de predicción no se valida por su elegancia matemática, sino por su desempeño en datos reales no vistos ("test set"). La contrastación final es empírica: ¿el modelo predice correctamente? ¿Generaliza bien?

La tensión entre estos dos polos define gran parte del trabajo en la disciplina: lograr un balance entre un modelo formalmente correcto y práctico para el problema factual al que se enfrenta.

c. Investigación cualitativa vs. Cuantitativa

Si bien la Ciencia de Datos es inherentemente **cuantitativa** en sus métodos de análisis (estadística, modelos numéricos), integra crucialmente elementos **cualitativos** en dos etapas clave:

1. **Comprensión del Problema y del Contexto de Negocio (Cualitativo)**: Antes de cualquier análisis, es esencial una fase de inmersión cualitativa: entrevistas con expertos de dominio, comprensión de los procesos business y definición de lo que realmente significa "valor" en ese contexto. Sin esta comprensión profunda, el análisis cuantitativo puede ser técnicamente impecable pero irrelevante

2. **Interpretación y Comunicación de Resultados (Cualitativo)**: Los hallazgos cuantitivos (ej.: "el modelo tiene un 95% de precisión") deben traducirse en narrativas cualitativas comprensibles y accionables para la toma de decisiones ("este modelo nos permite reducir el desperdicio de inventario en un 15%, lo que se traduce en un ahorro de X millones anuales").

Por lo tanto, el ciclo completo de un proyecto de ciencia de datos es **mixto**: comienza y termina con fases de naturaleza cualitativa, con una fase central de análisis cuantitativo masivo.

3. El Método de la Ciencia de Datos: Una Metodología Híbrida Científico-Tecnológica

El proceso de la Ciencia de Datos puede conceptualizarse como una adaptación rigurosa y cíclica del método científico, ampliado para incluir las fases de implementación tecnológica y monitoreo continuo. Este método se estructura en tres macro-fases:

a. Identificación del Problema de Negocio y de Datos

- **Objetivo Fundamental**: Realizar la traducción crítica de un objetivo empresarial vago ("aumentar las ventas") en un problema de ciencia de datos accionable y bien definido ("predecir la propensión a la compra de cada cliente en el siguiente mes para personalizar campañas de marketing").

- **Actividades Clave Ampliadas**:

    - **Preguntas Orientadas a Datos**: Formular las preguntas correctas es un arte. ¿Qué necesitamos predecir? ¿Qué queremos entender? ¿Es un problema de clasificación, regresión, clustering?

    - **Evaluación de Viabilidad**: Auditar la disponibilidad, calidad, y accesibilidad de los datos necesarios. ¿Tenemos los datos? ¿Están limpios? ¿Son representativos? ¿Respetan la privacidad?

    - **Definición de Métricas de Éxito**: Establecer métricas duales: 1) **Métricas Técnicas** (Precisión, Recall, F1-Score, RMSE) para evaluar el modelo, y 2) **Métricas de Negocio** (ROI, incremento en ventas, reducción de costos) para medir el impacto real. La alineación entre ambas es crucial.

b. Diseño, Procesamiento y Modelado de Datos

- **Objetivo Fundamental**: Transformar datos crudos y heterogéneos en un conjunto de características (*features*) depuradas y significativas, y desarrollar un modelo predictivo robusto y generalizable.

- **Actividades Clave Ampliadas**:

    - **Ingeniería de Datos**: Diseñar y construir arquitecturas robustas para la recolección, almacenamiento (data lakes, warehouses) y procesamiento inicial (ETL/ELT) de grandes volúmenes de datos de fuentes diversas.

- **Limpieza y Preprocesamiento**: Esta es una de las tareas más críticas. Imputación de valores faltantes, detección y tratamiento de outliers, normalización, estandarización y codificación de variables categóricas. Un modelo es tan bueno como los datos que lo alimentan.

- **Ingeniería de Características (Feature Engineering)**: El proceso creativo y técnico de crear nuevas variables a partir de las existentes que capturen mejor la información relevante para el modelo (ej.: crear "edad del cliente" a partir de la fecha de nacimiento, o "días desde la última compra").

- **Diseño y Entrenamiento del Modelo**: Seleccionar la familia de algoritmos apropiada (lineal, árboles de decisión, redes neuronales), entrenarlos utilizando técnicas de validación cruzada para evitar overfitting, y optimizar sus hiperparámetros.

d. Evaluación, Implementación y Mejora Continua

- **Objetivo Fundamental**: Validar que la solución no solo es técnicamente sólida, sino que cumple con los objetivos de negocio, integrarla en los sistemas productivos y establecer un ciclo de retroalimentación para su evolución continua.

- **Actividades Clave Ampliadas**:

    - **Evaluación Rigurosa**: La evaluación final debe hacerse sobre un conjunto de datos de prueba que el modelo nunca vio durante el entrenamiento. Se analizan tanto las métricas técnicas como se realizan pruebas de concepto para estimar el impacto business

    - **Implementación (Despliegue - Deployment)**: Llevar el modelo más allá del notebook de Jupyter. Esto implica integrarlo en los sistemas existentes mediante APIs, microservicios o servicios en la nube, garantizando su escalabilidad, latencia y confiabilidad (área de MLOps).

    - **Monitoreo y Mantenimiento**: Los modelos en producción se "desgastan" con el tiempo debido al concept drift (cambios en las relaciones subyacentes de los datos). Es esencial monitorear continuamente su desempeño y detectar caídas en la precisión.

    - **Mejora Iterativa**: Establecer pipelines automatizados para re-entrenar el modelo con nuevos datos o refinarlo. La ciencia de datos es un ciclo, no un proyecto lineal con un final.

4. Conclusión: La Ciencia de Datos como Disciplina de Síntesis

Retomando la pregunta inicial sobre la naturaleza científica de la informática y, por extensión, de la ciencia de datos, podemos concluir que su fuerza radica precisamente en su hibridez. No es una ciencia básica pura, ni una mera aplicación tecnológica. Es una disciplina de síntesis que construye sobre el método científico y lo adapta pragmáticamente para la era de los datos.

Su método es una fusión entre:

- El rigor formal de las matemáticas y la estadística.
- La curiosidad exploratoria y la validación empírica de las ciencias fácticas.
- El enfoque en la solución y la construcción de sistemas de la ingeniería.

En definitiva, la Ciencia de Datos ha desarrollado su propio marco metodológico robusto y reconocible, que respeta los principios de rigor, reproducibilidad y validación de la ciencia, pero que está orientado de manera intrínseca a la creación de valor a través de la tecnología. Es, en esencia, la materialización del ciclo de I+D+i aplicado al mundo de los datos.

Referencias

Barsky, O. (2015). La evaluación de la ciencia, la crisis del sistema internacional de revistas científicas y propuestas de políticas. Debate Universitario, 3(5), 109-124.

Bunge, M. (2002). *La investigación científica: su estrategia y su filosofía*. 2a.ed. Buenos Aires: Siglo XXI Editores Argentina.

Bunge, M. (2014). *La ciencia, su método y su filosofía*. Sudamericana.

Chalmers, A. F., Villate, J. A. P., Máñez, P. L., & Sedeño, E. P. (2000). ¿ Qué es esa cosa llamada ciencia? Madrid: siglo XXI

Hernández Sampieri, R., Fernández Collado, C., & Baptista Lucio, P. (2006). *Metodología de la investigación (Vol. 3)*. México: McGraw-Hill.

Ivan, A. (2013). Las Ciencias Computacionales como CIENCIA. En *Revista Antioqueña de las Ciencias Computacionales, 3*(2).

Schokosva, N. & Buskova, I. (2013). What is that Thing Called Computer Science? Revista Antioqueña de las Ciencias Computacionales y la Ingeniería de Software (RACCIS), 3(1), pp. 12-18.

SNODGRASS, Richard T. Towards a science of temporal databases. En Temporal Representation and Reasoning, 14th International Symposium on. IEEE, 2007. p. 6-7.